

## *Bài giảng 1: Giới thiệu về Xử lý Số liệu Thống kê*

TS. Tô Đức Khánh

Khoa Toán-Tin Học, ĐH Khoa Học Tự Nhiên, Tp. HCM

**Học phần: Xử lý Số liệu Thống kê**



## Thông tin của môn học

### Giảng viên:

TS. Tô Đức Khánh (tôi)

Bộ môn Xác suất-Thống kê, khoa Toán-Tin học

Trường Đại Học Khoa Học Tự Nhiên, Tp. HCM

e-mail: [tdkhanh@hcmus.edu.vn](mailto:tdkhanh@hcmus.edu.vn)

Phòng F.012, Trường Đại Học Khoa Học Tự Nhiên, 227 Nguyễn Văn Cừ,  
Quận 5, Tp. Hồ Chí Minh.

## Thông tin của môn học

---

Nội dung của môn học trong 12 tuần bao gồm:

- Quy trình xử lý số liệu thống kê;
- A/B testing;
- Hồi quy tuyến tính và tiên đoán;
- Statistical machine learning;
- Unsupervised learning;
- Imputation data;
- Phân tích sống sót và ứng dụng trong khoa học dữ liệu.

Thực hành trên phần mềm R/Rstudio, với các thư viện: tidyverse, ggplot2, xgboost, randomForest, rpart, FNN, glm, splines, mgcv, survival, pROC.

## Thông tin của môn học

### Số tín chỉ

|             | Tín chỉ | Số giờ học |
|-------------|---------|------------|
| Lý thuyết   | 2       | 30         |
| Thực hành R | 1       | 30         |
| Tổng cộng   | 3       | 60         |

### Lịch học

- Tất cả các bài giảng lý thuyết, thực hành và bài tập được tổ chức tại cơ sở 2 của trường Đại Học Khoa Học Tự Nhiên, Linh Trung, Thủ Đức.
- Bắt đầu từ 26/02/2024 tới 20/05/2024. Ngoại trừ ngày 22/04/2024 (thi giữa kỳ)
- Buổi lý thuyết: thứ 2 (hàng tuần) từ tiết 1 tới 3 (07:30 - 09h50) tại phòng E106
- Buổi thực hành R: thứ 2 (hàng tuần) từ tiết 4 tới 5 (10:00 - 12:00) và thứ 5 (hàng tuần) từ tiết 1 - 2.5 (7h30 - 9h30) và từ tiết 2.5 tới 5 (9h45 - 11h45) tại phòng C204, bắt đầu từ tuần thứ 1.

Xem chi tiết lịch học tại trang quản lý môn học.

## Thông tin của môn học

### *Cấu trúc điểm:*

- Điểm quá trình thực hành: 20%
- Điểm thi giữa kỳ: 20%
- Điểm báo cáo nhóm: 10%
- Điểm thi cuối kỳ: 50%

### *Nhóm:*

Sinh viên được chia thành các nhóm nhỏ, mỗi nhóm gồm từ 4-6 sinh viên.

### *Hình thức thi*

- Thi giữa kỳ: viết tự luận trong thời gian 60 phút.
- Thi cuối kỳ: làm đề tài/bài tập lớn theo nhóm.





**Chú ý:** Sinh viên cần phải tham gia ít nhất 80% số tiết học.

## Tài liệu học tập và tài liệu tham khảo

Slide bài giảng được cập nhật tại trang của môn học:

<https://courses.hcmus.edu.vn/course/view.php?id=5579>


Các tài liệu tham khảo







## Xử lý số liệu?







## Xử lý số liệu?

---

Việc xử lý dữ liệu xảy ra trong cuộc sống hàng ngày của chúng ta cho dù chúng ta có nhận thức được hay không. Dưới đây là một số ví dụ thực tế về xử lý dữ liệu:

- Phần mềm giao dịch chứng khoán chuyển đổi hàng triệu dữ liệu chứng khoán thành biểu đồ đơn giản.
- Một công ty thương mại điện tử sử dụng lịch sử tìm kiếm của khách hàng để giới thiệu các sản phẩm tương tự.
- Một công ty tiếp thị kỹ thuật số sử dụng dữ liệu nhân khẩu học của mọi người để lập chiến lược cho các chiến dịch theo vị trí cụ thể.
- Xe tự lái sử dụng dữ liệu thời gian thực từ các cảm biến để phát hiện xem có người đi bộ và các xe khác trên đường hay không.


## Xử lý số liệu?

---

|    | symbol | date       | open   | high   | low    | close  | volume    |
|----|--------|------------|--------|--------|--------|--------|-----------|
| 1  | AMZN   | 2024-02-15 | 170.58 | 171.17 | 167.59 | 169.80 | 49815300  |
| 2  | AMZN   | 2024-02-14 | 169.21 | 171.21 | 168.28 | 170.98 | 42815500  |
| 3  | AMZN   | 2024-02-13 | 167.73 | 170.95 | 165.75 | 168.64 | 56345100  |
| 4  | AMZN   | 2024-02-12 | 174.80 | 175.39 | 171.54 | 172.34 | 51050400  |
| 5  | AMZN   | 2024-02-09 | 170.90 | 175.00 | 170.58 | 174.45 | 56986000  |
| 6  | AMZN   | 2024-02-08 | 169.65 | 171.43 | 168.88 | 169.84 | 42316500  |
| 7  | AMZN   | 2024-02-07 | 169.48 | 170.88 | 168.94 | 170.53 | 47174100  |
| 8  | AMZN   | 2024-02-06 | 169.39 | 170.71 | 167.65 | 169.15 | 42505500  |
| 9  | AMZN   | 2024-02-05 | 170.20 | 170.55 | 167.70 | 170.31 | 55081300  |
| 10 | AMZN   | 2024-02-02 | 169.19 | 172.50 | 167.33 | 171.81 | 117154900 |
| 11 | AMZN   | 2024-02-01 | 155.87 | 159.76 | 155.62 | 159.28 | 76542400  |



## Data Analysts - Data Engineer - Data scientists



## Data Analysts - Data Engineer - Data scientists

*Data analysts* - hay **nhà phân tích dữ liệu** là người có trách nhiệm phân tích dữ liệu lịch sử, thiết kế hệ thống lưu trữ dữ liệu và sử dụng các công cụ khác nhau để phân tích dữ liệu.

*Data engineer* - hay **kỹ sư dữ liệu** là người được giao nhiệm vụ phát triển, xây dựng và quản lý hệ thống dữ liệu. Họ đảm bảo rằng dữ liệu có sẵn đã sẵn sàng để xử lý và phân tích ở định dạng có thể dễ dàng phân tích.

*Data scientists* - hay **nhà khoa học dữ liệu** là người sử dụng dữ liệu để trả lời các câu hỏi về công ty. Họ sử dụng dữ liệu để phát triển các tính năng sản phẩm mới. Họ sẽ dành một lượng thời gian đáng kể để làm sạch dữ liệu để đảm bảo rằng dữ liệu đó phù hợp với mô hình và kỹ thuật phân tích, xử lý số liệu của họ.



## Công việc của Data scientists

---




## *Case study 1: So sánh độ hiệu quả của hai dòng tiêu đề của trang web*

---



## Case study 2: Dự đoán lượng thuê xe đạp công cộng<sup>1</sup>



<sup>1</sup><https://www.kaggle.com/datasets/yasserh/bike-sharing-dataset>

## Case study 3: Phân tích tỷ lệ khách hàng từ bỏ dịch vụ



## *Statistical learning vs Machine learning*

---

**Thống kê (Statistics)** là một ngành khoa học của việc:

- **thu thập** dữ liệu
- **biểu diễn** dữ liệu
- **phân tích** dữ liệu
- **giải thích** kết quả


nhằm tìm ra các bằng chứng để củng cố hoặc bác bỏ các giả thuyết khoa học hoặc câu hỏi nghiên cứu.

## Statistical learning vs Machine learning

**Thống kê (Statistics)** là một ngành khoa học của việc:

- **thu thập** dữ liệu
- **biểu diễn** dữ liệu
- **phân tích** dữ liệu
- **giải thích** kết quả

nhằm tìm ra các bằng chứng để củng cố hoặc bác bỏ các giả thuyết khoa học hoặc câu hỏi nghiên cứu.




## *Statistical learning vs Machine learning*

---

**Statistical learning/Machine learning** là sự áp dụng của các phương pháp thống kê (chủ yếu là hồi quy) để tạo ra sự tiên đoán về các dữ liệu chưa nhìn thấy.

## Statistical learning vs Machine learning

**Statistical learning/Machine learning** là sự áp dụng của các phương pháp thống kê (chủ yếu là hồi quy) để tạo ra sự tiên đoán về các dữ liệu chưa nhìn thấy.





## *Statistical learning vs Machine learning*

---

Statistical learning tập trung vào phát triển và phân tích các mô hình có thể đưa ra dự đoán hoặc suy luận dựa trên dữ liệu:

- so sánh;
- mối tương quan;
- sự ảnh hưởng.

Ví dụ:

- so sánh số lượng click của hai thiết kế tiêu đề trang web;
- sự ảnh hưởng của thời tiết tới số lượng thuê xe đạp;
- nguyên nhân nào tác động tới tỷ lệ từ bỏ dịch vụ của khách hàng.

Statistical learning hoạt động dựa trên các giả định cho dữ liệu:

- phân phối chuẩn;
- độc lập của các quan sát;
- đồng nhất phương sai.

## *Statistical learning vs Machine learning*

---

Machine learning tập trung vào việc trích xuất kiến thức từ dữ liệu, bao gồm:


- các kỹ thuật hình thành khái niệm;
- phát hiện mẫu;
- các phương pháp lựa chọn tính năng tự động

Machine learning không phụ thuộc vào các giả định và trong hầu hết các trường hợp đều bỏ qua chúng.

Các mô hình machine learning được thiết kế để đưa ra dự đoán chính xác nhất có thể.

## *Statistical learning vs Machine learning*

---









## 1 Thông tin của học phần

## 2 Mở đầu

### 3 Dữ liệu





## Dữ liệu?


---

### Dữ liệu


Dữ liệu là một hoặc nhiều thông tin mô tả **tính chất của các đối tượng nghiên cứu**.

Dữ liệu có thể tới từ nhiều nguồn:

- cảm biến (sensor);
- sự kiện;
- văn bản (text);
- hình ảnh (images);
- âm thanh;
- video.



## Dữ liệu có cấu trúc - Structured data





## Dữ liệu có cấu trúc - Structured data

Ví dụ:

- số liên tục: tốc độ gió, doanh thu, khoảng thời gian, chi phí, ...
- số rời rạc: số lượng lượt truy cập web, số lượng khách hàng trong một ngày, ...
- đa định danh: thể loại màn hình TV: plasma, LCD, LED, ...
- thứ bậc: điểm đánh giá sản phẩm, thăng hài lòng về chất lượng dịch vụ, ...
- nhị phân: có/không, đúng/sai, ...



*Ví dụ: Dự đoán doanh số bán hàng*

Chi phí quảng cáo trên các nền tảng:

- truyền hình (TV)
- đài phát thanh (radio)
- nhật báo in (newspaper)

và doanh thu bán sản phẩm của công ty đều là các dữ liệu dạng số liên tục.

|    | A  | B     | C     | D         | E     |
|----|----|-------|-------|-----------|-------|
| 1  |    | TV    | radio | newspaper | sales |
| 2  | 1  | 230.1 | 37.8  | 69.2      | 22.1  |
| 3  | 2  | 44.5  | 39.3  | 45.1      | 10.4  |
| 4  | 3  | 17.2  | 45.9  | 69.3      | 9.3   |
| 5  | 4  | 151.5 | 41.3  | 58.5      | 18.5  |
| 6  | 5  | 180.8 | 10.8  | 58.4      | 12.9  |
| 7  | 6  | 8.7   | 48.9  | 75        | 7.2   |
| 8  | 7  | 57.5  | 32.8  | 23.5      | 11.8  |
| 9  | 8  | 120.2 | 19.6  | 11.6      | 13.2  |
| 10 | 9  | 8.6   | 2.1   | 1         | 4.8   |
| 11 | 10 | 199.8 | 2.6   | 21.2      | 10.6  |
| 12 | 11 | 66.1  | 5.8   | 24.2      | 8.6   |



## Ví dụ: Web Stickiness

### *Mục tiêu*

Một công ty bán một dịch vụ có giá trị cao, muốn kiểm tra xem trang web A hoặc B giúp công ty thực hiện công việc bán hàng tốt hơn.

### Các bước xác định mẫu:

Bán hàng tốt hơn  $\iff$  doanh số bán hàng của dịch vụ từ hai trang web có sự khác biệt lớn.

$\hookrightarrow$  ta cần thu thập tổng doanh số bán hàng của hai trang web.







## Ví dụ: Web Stickiness

### *Biến đại diện - Proxy variable*

**Biến đại diện (Proxy variable)** là biến đại diện cho biến được quan tâm thực sự, có thể không có sẵn, quá tốn kém hoặc quá tốn thời gian để đo lường.

- hàm lượng oxy trong lõi băng cổ đại: đại diện cho nhiệt độ;
- body mass index (BMI): đại diện cho % mỡ cơ thể;
- số năm được giáo dục/điểm GPA: đại diện cho khả năng nhận thức;
- ảnh vệ tinh màu sắc bề mặt đại dương: đại diện cho độ sâu mà ánh sáng xuyên qua đại dương trên diện rộng;
- sự thay đổi chiều cao trong một thời gian cố định: đại diện cho nồng độ hormone trong máu.

## *Ví dụ: Web Stickiness*

---

Một biến đại diện tiềm năng cho tổng doanh số bán hàng trên web là  
**số lần nhấp chuột vào trang đích chi tiết**

Như tại sao?







## *Rectangular Data*

---

Tuy nhiên, dữ liệu mà ta làm việc, không phải lúc nào cũng ở sẵn dạng rectangular data.

- dữ liệu phi cấu trúc: phải được xử lý và thao tác để có thể biểu diễn dưới dạng tập hợp các tính năng;
- dữ liệu trong cơ sở dữ liệu phải được trích xuất và đưa vào một bảng duy nhất cho hầu hết các nhiệm vụ phân tích và lập mô hình dữ liệu.



## *Non-rectangular Data*

---

Một số dạng dữ liệu sau không phải rectangular data:

- dữ liệu dạng danh sách: trong đó, mỗi danh sách là một rectangular data (cross-sectional data, panel data);
- dữ liệu chuỗi thời gian (time series data): ghi lại các phép đo liên tiếp của cùng một biến (feature);
- dữ liệu không gian (spatial data): được sử dụng trong phân tích bản đồ và vị trí;
- dữ liệu đồ thị hoặc mạng lưới (graph, network data): được sử dụng để thể hiện các mối quan hệ vật lý, xã hội và trừu tượng.