

Bài giảng 6: Bài toán Phân Loại - Classification - I

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Học phần: Xử lý Số liệu Thống kê

Nội dung buổi học

1 *Bài toán phân loại*

2 *Naive Bayes*

3 *Discriminant Analysis*

4 *Hồi quy logistic*

1 *Bài toán phân loại*

2 *Naive Bayes*

3 *Discriminant Analysis*

4 *Hồi quy logistic*


Giới thiệu

Phân loại (Classification) là một kỹ thuật được dùng để xử lý dữ liệu thành một số nhóm (lớp) nhất định.

Mục tiêu chính: xác định danh mục hoặc nhóm mà dữ liệu mới sẽ thuộc vào, dựa trên thông tin của một số biến giải thích độc lập:

- Một người đến phòng cấp cứu với một loạt các triệu chứng có thể do một trong ba tình trạng bệnh lý. Bác sĩ cần xác định/dự đoán bệnh trạng nào của bệnh nhân dựa trên thông tin của người đó?
- Dịch vụ ngân hàng trực tuyến phải có khả năng xác định liệu một giao dịch đang được thực hiện trên trang web là gian lận, dựa trên địa chỉ IP của người dùng, lịch sử giao dịch trong quá khứ, v.v.
- Trên cơ sở dữ liệu trình tự DNA của một số bệnh nhân mắc và không mắc một căn bệnh nhất định, một nhà sinh vật học muốn tìm ra đột biến DNA nào là có hại (gây bệnh) và đột biến nào thì không.
- Gmail lọc hộp thư đến của bạn thành “chính”, “xã hội”, “quảng cáo” hoặc “diễn đàn”.

Giới thiệu



Giới thiệu

Có nhiều phương pháp/kỹ thuật phân loại khác nhau đã được phát triển:

- Naive Bayes
- phân tích phân biệt - discriminant analysis
- hồi quy logistic - logistic regression
- hồi quy multinomial logistic - multinomial logistic regression
- phương pháp K-lân cận - K-nearest neighbors
- Cây quyết định - Decision Tree
- Random Forest
- Support Vector Machine

Phân loại nhị phân

Trong bộ dữ liệu, ta có:

- biến phản hồi $Y = 0$ hoặc 1 (đại diện cho hai nhóm cần phân loại);
- $X_1, X_2, \dots, X_p$ là p biến giải thích, độc lập nhau, cùng có mối liên hệ với biến phản hồi Y .

Câu hỏi

Dựa vào các giá trị của các biến giải thích $X_1, X_2, \dots, X_p$ của một đối tượng, một cách nào để phân đối tượng đó vào nhóm $Y = 1$ hoặc nhóm $Y = 0$?

Câu trả lời


Để phân một đối tượng vào nhóm $Y = 1$, ta có thể tiếp cận theo hướng xác suất, tức là:

$$p(x) = \Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)$$

với $x = (x_1, x_2, \dots, x_p)$.

- nếu $p(x)$ là lớn (tối đa 1), ta có thể chỉ định Y là 1;
- ngược lại, nếu $p(x)$ là nhỏ (tối thiểu 0), ta có thể chỉ định Y là 0.

Phân loại nhị phân



Phân loại 1 người có thể bị phá sản tín dụng (Default) dựa trên thông tin

- dư nợ tín dụng (Balance);
- thu nhập hàng tháng (Income).

Phân loại đa nhóm

Trong bộ dữ liệu, ta có:

- biến phản hồi $Y = j$ với $j = 1, \dots, K$ (đại diện cho K nhóm cần phân loại);
- $X_1, X_2, \dots, X_p$ là p biến giải thích, độc lập nhau, cùng có mối liên hệ với biến phản hồi Y .

Câu hỏi

Dựa vào các giá trị của các biến giải thích $X_1, X_2, \dots, X_p$ của một đối tượng, một cách nào để phân đối tượng đó vào nhóm $Y = 1$ hoặc nhóm $Y = j$?

Câu trả lời


Để phân một đối tượng vào nhóm $Y = j$, ta có thể tiếp cận theo hướng xác suất, tức là:

$$p_j(x) = \Pr(Y = j | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)$$

với $x = (x_1, x_2, \dots, x_p)$.

- nếu $p_j(x)$ là lớn (tối đa 1), ta có thể chỉ định Y là j ;
- ngược lại, nếu $p_j(x)$ là nhỏ (tối thiểu 0), ta có thể chỉ định Y là 0.

Phân loại đa nhóm



Phân loại 1 bông hoa vào 1 trong 3 loài hoa Iris dựa trên thông tin

- chiều dài lá đài (Sepal Length);
- chiều rộng lá đài (Sepal Width).

1 Bài toán phân loại

2 Naive Bayes

3 Discriminant Analysis

4 Hồi quy logistic

Công thức Bayes

Công thức Bayes cổ điển

Công thức xác suất Bayes - được đề xuất bởi nhà thống kê học người Anh, Thomas Bayes (1702 - 1761).

Cho không gian mẫu Ω , xét dãy các biến cố $B_1, B_2, \dots, B_k$ xung khắc nhau từng đôi một, và $B_1 \cup B_2 \cup \dots \cup B_k = \Omega$ (tức là hệ đầy đủ). Khi đó, xác suất điều kiện của biến cố B_j khi biết một biến cố A bất kỳ, được xác định bởi:

$$P(B_j|A) = \frac{P(A|B_j)P(B_j)}{\sum_{i=1}^k P(A|B_i)P(B_i)}$$

với j là một số bất kỳ trong $1, 2, \dots, k$.

Phân loại Bayes - Bayes classifier

Trong bộ dữ liệu, ta có:

- biến phản hồi $Y = j$ với $j = 1, \dots, K$ (đại diện cho K nhóm cần phân loại);
- $X_1, X_2, \dots, X_p$ là p biến giải thích, độc lập nhau, cùng có mối liên hệ với biến phản hồi Y .

Xác suất phân một đối tượng vào nhóm $Y = j$:

$$p_j(x) = \Pr(Y = j | X_1 = x_1, \dots, X_p = x_p) = \frac{f_j(x)\pi_j}{\sum_{i=1}^k f_i(x)\pi_i}$$

với $x = (x_1, \dots, x_p)$. Ta gọi

- $f_j(x)$ là mật độ xác suất đồng thời của $X_1, \dots, X_p$ trên nhóm j .
- $\pi_j = \Pr(Y = j)$ là xác suất tiên nghiệm (prior probability);
- $p(x) = \Pr(Y = j | X_1 = x_1, \dots, X_p = x_p)$ là xác suất hậu nghiệm (posterior probability).

Phân loại Bayes - Bayes classifier

Dựa vào dữ liệu, ta định nghĩa ước lượng $\hat{p}(x)$

$$\hat{p}_j(x) = \frac{\hat{f}_j(x)\hat{\pi}_j}{\sum_{i=1}^k \hat{f}_i(x)\hat{\pi}_i},$$

với

- $\hat{f}_j(x)$ là ước lượng mật độ xác suất đồng thời của $X_1, \dots, X_p$ trên nhóm j .
- $\hat{\pi}_j$ là ước lượng xác suất tiên nghiệm

$$\hat{\pi}_j = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(Y_i = j).$$

Vấn đề: ước lượng $\hat{f}_j(x) = \hat{f}_j(x_1, x_2, \dots, x_p)$?

Hàm mật độ p -chiều (của p biến $X_1, \dots, X_p$), tính toán phức tạp.

Phương pháp Naive Bayes

Giả sử $X_1, \dots, X_p$ là độc lập nhau, trong nhóm j , khi đó hàm mật độ p -chiều

$$f_j(\mathbf{x}) = f_{j1}(x_1) \times f_{j2}(x_2) \times \dots \times f_{jp}(x_p)$$

và do đó

$$\hat{f}_j(\mathbf{x}) = \hat{f}_{j1}(x_1) \times \hat{f}_{j2}(x_2) \times \dots \times \hat{f}_{jp}(x_p).$$

$\hookrightarrow$ ta cần ước lượng từng hàm mật độ thành phần $f_{jl}(x_l)$ trên nhóm j .

Xác suất hậu nghiệm

$$\hat{p}_{j,NB}(\mathbf{x}) = \frac{\hat{f}_{j1}(x_1) \times \hat{f}_{j2}(x_2) \times \dots \times \hat{f}_{jp}(x_p) \times \hat{\pi}_j}{\sum_{i=1}^k \hat{f}_{i1}(x_1) \times \hat{f}_{i2}(x_2) \times \dots \times \hat{f}_{ip}(x_p) \times \hat{\pi}_i}$$

Các phương pháp ước lượng

- tham số (parametric estimation): $X_l|Y=j \sim \mathcal{N}(\mu_{jl}, \sigma_{jl}^2)$ - phân phối chuẩn;
- ước lượng histogram;
- ước lượng kernel;
- ước lượng tỷ lệ (khi X_l là biến định tính).

Phương pháp Naive Bayes

Dựa trên ước lượng xác suất hậu nghiệm $\hat{p}_{j,NB}(x)$, ta có ước lượng nhóm như sau:

- $K = 2$

$$\hat{Y}(x) = \begin{cases} 1 & \text{nếu } \hat{p}_{1,NB}(x) > p_0, \\ 0 & \text{nếu } \hat{p}_{1,NB}(x) \leq p_0, \end{cases}$$

chú ý, $\hat{p}_{0,NB}(x) = 1 - \hat{p}_{1,NB}(x)$

- $K \geq 3$

$$\hat{Y}(x) = \arg \max_{j=1,\dots,K} \hat{p}_{j,NB}(x),$$

tức là nhóm j có xác suất hậu nghiệm lớn nhất. Cách làm này được gọi tên là phương pháp MAP (maximum a posterior).

Ví dụ phân loại tín dụng

Phân loại 1 người có thể bị phá sản tín dụng (Default) dựa trên thông tin

- dư nợ tín dụng (Balance) - X_1 ;
- thu nhập hàng tháng (Income) - X_2 ;

biến đáp ứng $Y = 0$ (không phá sản), $Y = 1$ (phá sản).

Áp dụng phân loại Bayes

$$\hat{p}_{j,NB}(\mathbf{x}) = \frac{\hat{f}_{j1}(x_1) \times \hat{f}_{j2}(x_2) \times \hat{\pi}_j}{\sum_{i=1}^2 \hat{f}_{i1}(x_1) \times \hat{f}_{i2}(x_2) \times \hat{\pi}_i},$$

trong đó, $\hat{f}_{jl}(x_l)$ là ước lượng hàm mật độ của phân phối chuẩn $\mathcal{N}(\hat{\mu}_{jl}, \hat{\sigma}_{jl}^2)$



$$\hat{\mu}_{jl} = \frac{1}{n_j} \sum_{k=1}^{n_j} X_{jlk}$$

$$\hat{\sigma}_{jl}^2 = \frac{1}{n_j - 1} \sum_{k=1}^{n_j} (X_{jlk} - \hat{\mu}_{jl})^2$$

Ví dụ phân loại tín dụng

Kết quả của quá trình ước lượng cho ta:


- mặt ước lượng $\hat{p}_{1,NB}(x)$ (hình bên trái);
- đường đồng mức của $\hat{p}_{1,NB}(x)$ (hình bên phải).



Các đường đồng mức này, gợi ý tới ngưỡng đưa ra quyết định.

Ví dụ phân loại tín dụng

Ví dụ, chọn $p_0 = 0.5$



Ví dụ phân loại tín dụng

Thay đổi ngưỡng $p_0 \in (0, 1) \Rightarrow \hat{Y}$ sẽ thay đổi

Ví dụ phân loại loài hoa iris

Phân loại 1 bông hoa iris vào 1 trong 3 loài:

- Versicolor ($j = 1$);
- Setosa ($j = 2$);
- Virginica ($j = 3$).

dựa trên thông tin

- chiều dài lá đài (Sepal Length) - X_1 ;
- chiều rộng lá đài (Sepal Width) - X_2 .


Áp dụng phân loại Bayes

$$\hat{p}_{j,NB}(\mathbf{x}) = \frac{\hat{f}_{j1}(x_1) \times \hat{f}_{j2}(x_2) \times \hat{\pi}_j}{\sum_{i=1}^3 \hat{f}_{i1}(x_1) \times \hat{f}_{i2}(x_2) \times \hat{\pi}_i},$$

trong đó, $\hat{f}_{jl}(x_l)$ là ước lượng hàm mật độ của phân phối chuẩn $\mathcal{N}(\hat{\mu}_{jl}, \hat{\sigma}_{jl}^2)$.

Ví dụ phân loại loài hoa iris

Áp dụng quy tắc MAP, ta có kết quả ước lượng nhóm được minh họa bởi hình



Vấn đề của phương pháp Naive Bayes

Như đã trình bày trong lý thuyết, phương pháp Naive Bayes dựa trên giả định

$$f_j(\mathbf{x}) = f_{j1}(x_1) \times f_{j2}(x_2) \times \dots \times f_{jp}(x_p),$$

tức các $X_1, \dots, X_p$ là độc lập, trong nhóm j .

↪ nếu dữ liệu không ủng hộ cho giả thuyết này $\Rightarrow$ phương pháp Naive Bayes hoạt động tệ.

Ví dụ: xét bài toán phân loại loài hoa iris bằng hai đặc tính:

- chiều dài lá đài (Sepal Length) - X_1 ;
- chiều rộng lá đài (Sepal Width) - X_2 ;

hệ số tương quan của hai đặc tính này: -0.1176 .

phân loại loài hoa iris bằng hai đặc tính:

- chiều dài cánh hoa (Petal Length) - X_1 ;
- chiều rộng cánh hoa (Petal Width) - X_2 ;

hệ số tương quan của hai đặc tính này: 0.8718 .

1 Bài toán phân loại

2 Naive Bayes

3 Discriminant Analysis

4 Hồi quy logistic

Ý tưởng

Nhắc lại phân loại Bayes

$$p_j(\mathbf{x}) = \Pr(Y = j | X_1 = x_1, \dots, X_p = x_p) = \frac{f_j(\mathbf{x})\pi_j}{\sum_{i=1}^k f_i(\mathbf{x})\pi_i}.$$

Đối với phương pháp Naive Bayes, ta giả định rằng $X_1, \dots, X_p$ là độc lập trong nhóm j , khi đó

$$f_j(\mathbf{x}) = f_{j1}(x_1) \times f_{j2}(x_2) \times \dots \times f_{jp}(x_p),$$

$\hookrightarrow$ ước lượng $f_j(\mathbf{x})$ là tích của các mật độ thành phần $f_{jp}(x_p)$.

Tuy nhiên, giả định này thường bị vi phạm với dữ liệu thực tế.

$\hookrightarrow$ do đó, cần phải ước lượng hàm mật độ xác suất đồng thời $f_j(\mathbf{x})$ (biến nhiều chiều).

Ý tưởng

Phương pháp cho bài toán ước lượng hàm mật độ xác suất nhiều chiều:

- ước lượng tham số - phân phối chuẩn nhiều chiều (multivariate normal distribution)

$$f_j(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma_j|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^\top \Sigma_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \right),$$

với Σ_j là ma trận hiệp phương và $\boldsymbol{\mu}_j$ là vector trung bình của $X_1, \dots, X_p$ trong nhóm j ;

$$\Sigma_j = \begin{pmatrix} \sigma_{j1}^2 & \sigma_{j12} & \dots & \sigma_{j1p} \\ \sigma_{j12} & \sigma_{j2}^2 & \dots & \sigma_{j2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{j1p} & \sigma_{j2p} & \dots & \sigma_{jp}^2 \end{pmatrix}$$

với $\sigma_{j12} = \text{Cov}(X_1, X_2)$ trong nhóm j .

- ước lượng phi tham số - kernel nhiều chiều (multivariate kernel density estimation)

$$\hat{f}_{j,\mathbf{H}}(\mathbf{x}) = \frac{1}{n_j} \sum_{i=1}^{n_j} |\mathbf{H}|^{-1/2} K \left(\mathbf{H}^{-1/2} (\mathbf{x} - \mathbf{x}_{ji}) \right),$$

với $K(\cdot)$ là hàm Kernel nhiều chiều, ví dụ, multivariate Gaussian kernel.

Ý tưởng

Ước lượng tham số - phân phối chuẩn nhiều chiều

Ta cần ước lượng

- trung bình μ_j ;
- ma trận hiệp phương sai Σ_j .

Ước lượng phi tham số - kernel nhiều chiều

Ta cần xác định

- hàm kernel nhiều chiều;
- ma trận bandwidth $\mathbf{H}$.

Khó khăn



- việc xác định ma trận bandwidth nhiều chiều không đơn giản;
- hiệu quả và độ chính xác của ước lượng bị giảm xuống khi p tăng.

↪ sử dụng cách tiếp cận dựa trên phân phối chuẩn nhiều chiều.

Phân phối chuẩn nhiều chiều

Xét

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & -0.4 \\ -0.4 & 1 \end{pmatrix}\right)$$



Linear discriminant analysis - LDA

Nếu ta giả sử rằng $\Sigma_1 = \Sigma_2 = \dots = \Sigma_p$

$\hookrightarrow$ chỉ cần ước lượng một Σ chung cho tất cả p nhóm. Khi này,

$$f_j(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \right),$$

và phân phối hậu nghiệm

$$p_j(\mathbf{x}) = \frac{\frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \right) \pi_j}{\sum_{i=1}^k f_i(\mathbf{x}) \pi_i}.$$

Áp dụng MAP và lấy $\log()$ hai vế, ta xác định được quy tắc phân loại

$$\hat{Y}(\mathbf{x}) = \arg \max_{j=1, \dots, K} \delta_j(\mathbf{x}),$$


với

$$\delta_j(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_j - \frac{1}{2} \boldsymbol{\mu}_j^\top \Sigma^{-1} \boldsymbol{\mu}_j + \log(\pi_j)$$

tuyến tính theo $\mathbf{x} \Rightarrow$ Linear discriminant analysis (LDA).


Linear discriminant analysis - LDA

Ví dụ: phân loại 1 người có thể bị phá sản tín dụng




Linear discriminant analysis - LDA

Ví dụ: phân loại 1 bông hoa iris vào 1 trong 3 loài




Quadratic discriminant analysis - QDA

Ví dụ: phân loại 1 người có thể bị phá sản tín dụng



Quadratic discriminant analysis - QDA

Ví dụ: phân loại 1 bông hoa iris vào 1 trong 3 loài



1 Bài toán phân loại

2 Naive Bayes

3 Discriminant Analysis

4 Hồi quy logistic

Mô hình hồi quy logistic

Nhắc lại rằng, mục tiêu chính trong phân loại là xác định

$$p_j(x) = \Pr(Y = j | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)$$

Trong các phần trước, ta đã xét các phương pháp ước lượng dựa trên

- ý tưởng của công thức Bayes,
- và ước lượng hàm mật độ xác suất.

Theo quan điểm thống kê, có một cách khác để ước lượng (tiên đoán) đó là dự vào mô hình hồi quy.

Xét trường hợp $K = 2$, khi đó, xác suất phân loại mục tiêu là

$$p(x) = \Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)$$

Một cách tự nhiên (và đơn giản), ta thiết lập ngay mô hình hồi quy tuyến tính

$$p(x) = \Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p) = \beta_0 + \sum_{k=1}^p \beta_k x_k$$

Mô hình hồi quy logistic

Tuy nhiên, ước lượng này sẽ vượt ra khỏi khoảng $(0, 1) \Rightarrow$ không thỏa mãn tính chất xác suất.

Ta cần một hàm biến đổi $\beta_0 + \sum_{k=1}^p \beta_k x_k$ từ $\mathbb{R}$ vào trong $(0, 1)$.

■ hàm chỉ

$$\mathbb{I}(x) = \begin{cases} 0, & \text{nếu } x < 0 \\ x, & \text{nếu } 0 \leq x \leq 1 \\ 1, & \text{nếu } x > 1 \end{cases}$$


■ hàm logistic

$$g(x) = \frac{\exp(x)}{1 + \exp(x)}$$

■ hàm probit

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{s^2}{2}\right) ds$$

Mô hình hồi quy logistic



- Hàm chỉ $I(x)$ là hàm không trơn, do đó, không tồn tại đạo hàm.
- Hàm logistic và probit là các hàm trơn, liên tục tại mọi x .

Mô hình hồi quy logistic

Nếu ta lựa chọn

- hàm logistic, thì

$$p(x) = \Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p) = \frac{\exp(\beta_0 + \sum_{k=1}^p \beta_k x_k)}{1 + \exp(\beta_0 + \sum_{k=1}^p \beta_k x_k)}$$

khi đó, ta có mô hình **hồi quy logistic**. Hơn nữa, sử dụng biến đổi ta được

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \sum_{k=1}^p \beta_k x_k;$$

- hàm probit, thì

$$p(x) = \Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p) = \Phi \left(\beta_0 + \sum_{k=1}^p \beta_k x_k \right)$$

khi đó, ta có mô hình **hồi quy probit**. Hơn nữa, sử dụng biến đổi ta được

$$\Phi^{-1}(p(x)) = \beta_0 + \sum_{k=1}^p \beta_k x_k.$$

Mô hình hồi quy logistic

Như vậy, xác suất $p(x)$ có thể được ước lượng thông qua mô hình hồi quy logistic:

$$p(x) = \frac{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}{1 + \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}.$$

Sau khi xác định được các ước lượng $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ bằng phương pháp hợp lý cực đại, ta tính được

$$\hat{p}(x) = \frac{\exp(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p)}{1 + \exp(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p)}$$

Quy tắc phân loại nhị phân ($K = 2$):

$$\hat{Y}(x) = \begin{cases} 1 & \text{nếu } \hat{p}(x) > p_0, \\ 0 & \text{nếu } \hat{p}(x) \leq p_0, \end{cases}$$

Ví dụ

Xét ví dụ phân loại một người có khả năng bị phá sản tín dụng (Default) dựa trên mô hình


$$\log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \beta_1 \text{Balance} + \beta_2 \text{Income}$$

Ước lượng mô hình cho ta kết quả

	Estimate	Std. Error	Pr(> z)
(Intercept)	-8.414	0.5325	< 0.0001
balance	5.072×10^{-3}	2.990×10^{-4}	< 0.0001
income	1.614×10^{-5}	7.105×10^{-6}	0.0232

Ví dụ

Chọn $p_0 = 0.5$



Hồi quy multinomial logistic

Xét lại mô hình hồi quy logistic

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \sum_{k=1}^p \beta_k x_k;$$

Nhận xét rằng $1 - p(x) = \Pr(Y = 0 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)$. Từ đây, mô hình được biểu diễn theo

$$\log \left(\frac{\Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)}{\Pr(Y = 0 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)} \right) = \beta_0 + \sum_{k=1}^p \beta_k x_k;$$

Như vậy, hồi quy logistic là một mô hình miêu tả log tỷ lệ xác suất của hai nhóm.

Điều này giúp ta mở rộng được mô hình lên trường hợp $K \geq 3$.

Hồi quy multinomial logistic

Với $K \geq 3$, mở rộng ý tưởng của mô hình hồi quy logistic, ta sẽ mô hình log tỷ lệ của hai nhóm bất kỳ

$$\log \left(\frac{\Pr(Y = j | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)}{\Pr(Y = l | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)} \right)$$

$\Rightarrow$ cần C_K^2 mô hình!

Thay vì so sánh tất cả cặp nhóm, ta sẽ so sánh một nhóm bất kỳ với một nhóm tham chiếu (reference group)

$$\log \left(\frac{\Pr(Y = j | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)}{\Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)} \right),$$

với $j = 2, \dots, K$.

$\Rightarrow$ chỉ cần $K - 1$ mô hình.

Hồi quy multinomial logistic

Với cách làm này, ta có mô hình

$$\log \left(\frac{p_j(x)}{p_1(x)} \right) = \beta_{j0} + \sum_{k=1}^p \beta_{jk} x_{jk},$$

với $j = 2, \dots, K$. Từ đây ta thu được

$$p_j(x) = \frac{\exp \left(\beta_{j0} + \sum_{k=1}^p \beta_{jk} x_{jk} \right)}{1 + \sum_{l=2}^K \exp \left(\beta_{l0} + \sum_{k=1}^p \beta_{lk} x_{lk} \right)}$$

và

$$p_1(x) = \frac{1}{1 + \sum_{l=2}^K \exp \left(\beta_{l0} + \sum_{k=1}^p \beta_{lk} x_{lk} \right)}$$

Quy tắc phân loại

$$\hat{Y}(x) = \arg \max_{j=1, \dots, K} p_j(x),$$

Ví dụ

Xét bài toán phân loại loài hoa iris vào 1 trong 3 loài hoa

- versicolor (nhóm tham chiếu) - 1;
- setosa - 2;
- virginica - 3.


Mô hình

$$\log \left(\frac{p_j(x)}{p_1(x)} \right) = \beta_{j0} + \beta_{j1} \text{Sepal.L}_j + \beta_{j1} \text{Sepal.W}_j,$$

Ước lượng mô hình cho ta kết quả

	2 vs. 1		3 vs. 1	
	Estimate	Std. Error	Estimate	Std. Error
(Intercept)	104.1164	141.0653	-13.0477	3.0977
Sepal.L	-41.2011	55.0576	1.9025	0.5170
Sepal.W	37.2945	59.7691	0.4048	0.8628

Ví dụ



Các vấn đề đối với mô hình

Ưu điểm

- Không phụ thuộc vào giả định phân phối của các $X_1, \dots, X_p$ trong nhóm j .
- Giải thích được sự biến động của Y thông qua mô hình.
- Tìm được biến giải thích phù hợp (có ý nghĩa) thông qua mô hình.

Nhược điểm

- Yêu cầu $X_1, \dots, X_p$ là độc lập, hoặc có sự tương quan thấp.
- Cần một quy trình xây dựng mô hình (tương tự mô hình hồi quy tuyến tính).
- Hoạt động kém hiệu quả nếu mô hình thực sự không có dạng tuyến tính.