

Bài giảng 3: Hồi quy logistic

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Mô Hình Thống Kê Tuyển Tính Nâng Cao

Mục lục

1 Giới thiệu

2 Mô hình hồi quy logistic

3 Ước lượng hệ số mô hình

1 *Giới thiệu*

2 *Mô hình hồi quy logistic*

3 *Ước lượng hệ số mô hình*

Biến nhị phân

Biến phản hồi nhị phân

Xét biến định tính Y . Nếu Y chỉ có hai kết quả, ta nói Y là một biến nhị phân (binary hoặc dichotomous).

Ví dụ:

- Y là trạng thái bệnh: không bị bệnh (non-diseased)/bị bệnh (diseased)

$$Y = \begin{cases} 0 & \text{nếu không bị bệnh} \\ 1 & \text{nếu bị bệnh} \end{cases}$$

- Y là tình trạng hút thuốc: không hoặc có

$$Y = \begin{cases} 0 & \text{nếu không hút thuốc} \\ 1 & \text{nếu có hút thuốc} \end{cases}$$

Mô hình tuyến tính cho biến nhị phân

Ví dụ 1: Ung thư thực quản là một trong những loại ung thư nguy hiểm. Sau một giai đoạn phát triển, tế bào ung thư có thể di căn sang các hạch bạch huyết gần đó, rồi sau đó là gan hoặc phổi. Một câu hỏi nghiên cứu được đặt ra:

“Liệu rằng có thể dự đoán tế bào ung thư thực quản đã di căn tới hạch bạch huyết, nếu dựa vào kích cỡ của khối u?”

Để trả lời câu hỏi này, một nghiên cứu đã được thực hiện:

- 31 bệnh nhân ung thư thực quản được quan sát;
- kích cỡ của các khối u lớn nhất được ghi nhận lại, đơn vị cm;
- sự xuất hiện tế bào ung thư ở hạch bạch huyết cũng được kiểm tra bằng một xét nghiệm độc lập, và ghi chép lại kết quả: có hoặc không.

Dựa vào câu hỏi, ta cần xây dựng một mô hình dự đoán sự xuất hiện tế bào ung thư thực quản tại hạch bạch huyết dựa trên thông tin của kích cỡ khối u.

- Biến phản hồi Y : sự xuất hiện tế bào ung thư ở hạch bạch huyết, có hoặc không.
- Biến giải thích X : kích cỡ khối u lớn nhất, đơn vị cm.

Mô hình tuyến tính cho biến nhị phân

Bệnh nhân	Kích cỡ khối u (cm)	Sự di căn hạch bạch huyết
1	6.5	có
2	6.3	không
3	3.8	có
⋮	⋮	⋮
29	3.0	không
30	3.0	có
31	1.7	không


Ta cần chuyển đổi biến Y về dạng **giả biến**:

$$Y = \begin{cases} 0, & \text{nếu tế bào ung thư chưa di căn,} \\ 1, & \text{nếu tế bào ung thư đã di căn.} \end{cases}$$

Khi đó, mô hình hồi quy tuyến tính có thể là

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Mô hình tuyến tính cho biến nhị phân



Ta nhận thấy rằng:

- đường thẳng hồi quy không bị giới hạn, có thể vượt qua 0 và 1;
- với cỡ khối u là 4cm, từ mô hình tuyến tính, ta ước lượng được $\hat{Y} = 0.49$;
- cùng một giá trị của cỡ khối u, ta có thể quan sát được cả 0 và 1, tức là không di căn và di căn.

1 Giới thiệu

2 Mô hình hồi quy logistic

3 Ước lượng hệ số mô hình

Phân phối nhị thức và mô hình xác suất

Ở phần trước, ta thấy rằng việc sử dụng mô hình hồi quy tuyến tính cho biến nhị phân là không phù hợp.

Quan sát, với cách đặt

$$Y = \begin{cases} 0, & \text{nếu tế bào ung thư chưa di căn,} \\ 1, & \text{nếu tế bào ung thư đã di căn.} \end{cases}$$

thì Y là biến ngẫu nhiên $\mathcal{B}(1, p)$, với $p = \Pr(Y = 1)$, tức là xác suất một người có tế bào ung thư đã di căn sang hạch bạch huyết:

- $p = 0$ tương ứng $Y = 0$, chắc chắn;
- $p = 1$ tương ứng $Y = 1$, chắc chắn;
- p càng gần 1 thì khả năng $Y = 1$ càng cao, tức là nguy cơ cao rằng tế bào ung thư đã di căn.

Phân phối nhị thức và mô hình xác suất

Nhắc lại câu hỏi nghiên cứu:

“Liệu rằng có thể dự đoán tế bào ung thư thực quản đã di căn tới hạch bạch huyết, nếu dựa vào kích cỡ của khối u?”

Nếu kích cỡ khối u có liên quan tới việc di căn của tế bào ung thư thì

$\hookrightarrow$ xác suất $p = \Pr(Y = 1)$ sẽ thay đổi theo thông tin của X .

Khi đó, ta có thể mô hình hóa xác suất di căn của tế bào ung thư theo X :

$$P(Y = 1|X) = p(X)$$

tức là xác suất điều kiện của Y khi biết X .

Do đó, ta có phân phối điều kiện

$$Y|X \sim \mathcal{B}(1, p(X)).$$

Nhắc lại: nếu X và Y là độc lập thì $P(Y = 1|X) = P(Y = 1) = p$.

Phân phối nhị thức và mô hình xác suất

Ta có nhiều lựa chọn dạng hàm cho $p(X)$, tuy nhiên, lựa chọn hàm tuyến tính là đơn giản nhất:

$$p(X) = \beta_0 + \beta_1 X.$$

Nhưng, hàm này cho giá trị không thuộc $(0, 1)$.

Ta cần một phép biến đổi từ $\mathbb{R}$ vào trong $(0, 1)$.

■ hàm chỉ

$$\mathbb{I}(x) = \begin{cases} 0, & \text{nếu } x < 0 \\ x, & \text{nếu } 0 \leq x \leq 1 \\ 1, & \text{nếu } x > 1 \end{cases}$$


■ hàm logistic:

$$g(x) = \frac{\exp(x)}{1 + \exp(x)}$$

■ hàm xác suất tích lũy phân phối chuẩn:

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{s^2}{2}\right) ds$$

Phân phối nhị thức và mô hình xác suất



- Hàm chỉ $I(x)$ là hàm không trơn, do đó, không tồn tại đạo hàm tại mọi x .
- Hàm logistic và hàm phân phối chuẩn tích lũy là các hàm trơn, liên tục tại mọi x .

Phân phối nhị thức và mô hình xác suất

Nếu ta lựa chọn

- hàm logistic, thì

$$\Pr(Y = 1|X) = p(X) = \frac{\exp(\beta_0 + \beta_1 X)}{1 + \exp(\beta_0 + \beta_1 X)}$$

khi đó, ta có mô hình **hồi quy logistic**. Hơn nữa, sử dụng biến đổi ta được

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X;$$

- hàm phân phối chuẩn tích lũy, thì

$$\Pr(Y = 1|X) = p(X) = \Phi(\beta_0 + \beta_1 X)$$

khi đó, ta có mô hình **hồi quy probit**. Hơn nữa, sử dụng biến đổi ta được

$$\Phi^{-1}(p(X)) = \beta_0 + \beta_1 X.$$

Như vậy: mô hình hồi quy logistic và mô hình hồi quy probit là hai mô hình hồi quy tham số được dùng để tiên đoán xác suất xuất hiện của một biến nhị phân.

Mô hình hồi quy logistic

Giả sử ta có bộ dữ liệu ngẫu nhiên $(Y_i, X_{1i}, X_{2i}, \dots, X_{qi})$, với $i = 1, \dots, n$, trong đó:

- các quan sát thứ i là độc lập;
- Y_i là biến phản hồi nhị phân, nhận giá trị 0 hoặc 1 với xác suất $\Pr(Y_i = 1) = p_i$;
- $X_{1i}, \dots, X_{qi}$ là các biến giải thích có thể liên quan tới Y_i .

Mô hình tiên đoán xác suất $Y_i = 1$ khi biết $X_{1i}, X_{2i}, \dots, X_{qi}$:

$$\Pr(Y_i = 1 | X_{1i}, X_{2i}, \dots, X_{qi}) = \frac{\exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})}{1 + \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})},$$

được gọi là mô hình **hồi quy logistic**. Mô hình này tương đương với,

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

với $\pi_i = \Pr(Y_i = 1 | X_{1i}, X_{2i}, \dots, X_{qi})$.

Mô hình hồi quy logistic

Một số dạng mô hình logistic thường gặp, giả sử với $q = 2$:

- $\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i};$
- $\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 g(X_{1i}) + \beta_2 X_{2i},$ với $g(\cdot)$ là một hàm thực;
- $\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} X_{2i},$ trong đó thành phần $X_{1i} X_{2i}$ đại diện cho sự tương tác của X_1 và X_2 .

Diễn giải mô hình

Xét mô hình tổng quát:

$$\Pr(Y = 1|X_1, \dots, X_q) = \pi = \frac{\exp(\beta_0 + \beta_1 X_1 + \dots + \beta_q X_q)}{1 + \exp(\beta_0 + \beta_1 X_1 + \dots + \beta_q X_q)}.$$

Trường hợp $q = 1$:

- nếu $\beta > 0$, đường cong của π là một đường đơn điệu tăng khi X từ $-\infty$ tới ∞ , nằm trong giới hạn là $(0, 1)$;
- nếu $\beta < 0$, đường cong của π là một đường đơn điệu giảm, khi X từ $-\infty$ tới ∞ , nằm trong giới hạn là $(0, 1)$.

Trong trường hợp $q > 1$:

- π là hàm đơn điệu theo từng biến X_j tương ứng theo dấu của hệ số β_j ;
- tốc độ thay đổi của π , tăng hoặc giảm, là $|\beta_j|$.

Diễn giải mô hình

Tỷ lệ cược - odds

Nếu một sự kiện A có xác suất xảy ra là p , thì tỷ lệ cược (*odds*) cho sự xuất hiện của A được xác định bởi $\frac{p}{1-p}$, tức là tỷ lệ giữa xác suất mà A xuất hiện và xác suất mà A không xuất hiện.

Ví dụ: A là sự kiện một người bị di căn tế bào ung thư:

- xác suất A xuất hiện là $p = 0.7$;
- tỷ lệ cược cho một người bị di căn tế bào ung thư là $\frac{0.7}{1-0.7} = 2.33$

Điều này có nghĩa là: xác suất quan sát được một người bệnh bị di căn tế bào ung thư là cao hơn 2.33 lần so với xác suất không quan sát được sự di căn tế bào ung thư.

Diễn giải mô hình

Theo thiết lập mô hình logistic, ta có

$$\frac{\pi}{1-\pi} = \exp(\beta_0 + \beta_1 X_1 + \dots + \beta_q X_q);$$

như vậy, ta có được biểu diễn của tỷ lệ cược theo $X_1, X_2, \dots, X_q$. Hay dạng biểu diễn tuyến tính của log-odds

$$\log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_q X_q.$$

Từ dạng biểu diễn tuyến tính này, ta có quy tắc sau:

- nếu $\beta_j > 0$, thì khi giá trị X_j tăng một đơn vị thì log-odds tăng β_j đơn vị;
- nếu $\beta_j < 0$, thì khi giá trị X_j tăng một đơn vị thì log-odds giảm $|\beta_j|$ đơn vị.

Quy tắc này cũng tương đương với

- nếu $\beta_j > 0$, thì khi giá trị X_j tăng một đơn vị thì tỷ lệ cược tăng $\exp(\beta_j)$ lần;
- nếu $\beta_j < 0$, thì khi giá trị X_j tăng một đơn vị thì tỷ lệ cược giảm $\exp(\beta_j)$ lần.

1 *Giới thiệu*

2 *Mô hình hồi quy logistic*

3 *Ước lượng hệ số mô hình*

Ước lượng mô hình

Xét mô hình hồi quy logistic:

$$\pi_i = \frac{\exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})}{1 + \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})},$$

với $\pi_i = \Pr(Y_i = 1 | X_{1i}, X_{2i}, \dots, X_{qi})$.

Ta cần ước lượng các tham số β_j với $j = 0, 1, \dots, q$.

Theo các thiết lập mô hình, ta có $Y_i | X_{1i}, X_{2i}, \dots, X_{qi} \sim \mathcal{B}(1, \pi_i)$, tức là $X_{1i}, X_{2i}, \dots, X_{qi}$ được coi như cố định.

Do đó, ta xây dựng được hàm hợp lý:

$$L(\beta_0, \beta_1, \dots, \beta_q) = \prod_{i=1}^n \pi_i^{Y_i} (1 - \pi_i)^{1-Y_i}.$$

Ước lượng mô hình

Từ đây ta suy ra được hàm log-likelihood:

$$\ell(\beta_0, \beta_1, \dots, \beta_q) = \sum_{i=1}^n \left\{ Y_i \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) - \log \left(1 + \exp \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) \right) \right\}.$$

Ta có hàm score cho từng tham số β_j là:

$$\begin{aligned} U(\beta_0) &= \sum_{i=1}^n \left\{ Y_i - \frac{\exp \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right)}{1 + \exp \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right)} \right\} \\ U(\beta_j) &= \sum_{i=1}^n X_{ji} \left\{ Y_i - \frac{\exp \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right)}{1 + \exp \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right)} \right\} \end{aligned}$$

Bằng cách đặt $Z_i = (1, X_{1i}, \dots, X_{qi})^\top$, ta có

$$U(\beta) = \sum_{i=1}^n Z_i \{ Y_i - \pi_i \}$$

Ước lượng mô hình

Từ công thức của $U(\beta)$, ta tính được ma trận thông tin Fisher:

$$\mathcal{I}(\beta) = \sum_{i=1}^n \mathbf{Z}_i \mathbf{Z}_i^\top \pi_i (1 - \pi_i).$$

Đặt

$$\mathbf{Z} = \begin{pmatrix} 1 & X_{11} & \dots & X_{q1} \\ 1 & X_{12} & \dots & X_{q2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \dots & X_{qn} \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \boldsymbol{\pi} = \begin{pmatrix} \pi_1 \\ \pi_2 \\ \vdots \\ \pi_n \end{pmatrix}$$
$$\mathbf{V} = \begin{pmatrix} \pi_1(1 - \pi_1) & 0 & \dots & 0 \\ 0 & \pi_2(1 - \pi_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \pi_n(1 - \pi_n) \end{pmatrix}$$

Khi này, ta có

$$U(\beta) = \mathbf{Z}^\top (\mathbf{Y} - \boldsymbol{\pi}), \quad \mathcal{I}(\beta) = \mathbf{Z}^\top \mathbf{V} \mathbf{Z}.$$

Ước lượng mô hình

Áp dụng thuật toán Fisher scoring, ta có

$$\hat{\beta} = \beta^{\dagger} + \mathcal{I}^{-1}(\beta^{\dagger}) U(\beta^{\dagger}),$$

hay tương đương với

$$\hat{\beta} = \beta^{\dagger} + (\mathbf{Z}^{\top} \mathbf{V}^{\dagger} \mathbf{Z})^{-1} \mathbf{Z}^{\top} (\mathbf{Y} - \boldsymbol{\pi}^{\dagger}).$$

Từ đây, ta có thuật toán ước lượng như sau:

- 1 Chọn một giá trị bắt đầu $\beta^{(0)}$
- 2 Với bước lặp $t = 0$, ta tính

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{Z}^{\top} \mathbf{V}^{(t)} \mathbf{Z})^{-1} \mathbf{Z}^{\top} (\mathbf{Y} - \boldsymbol{\pi}^{(t)}),$$

- 3 Đặt $t = t + 1$, lặp lại bước 2 cho tới khi nào thuật toán hội tụ, có thể là

$$\|\beta^{(t+1)} - \beta^{(t)}\| < \varepsilon.$$

- 4 ước lượng hợp lý cực đại $\hat{\beta} = \beta^{(t+1)}$.

Ví dụ

Xét lại ví dụ về dữ liệu ung thư thực quản di căn:

- $n = 31$ quan sát (bệnh nhân);
- biến phản hồi là trạng thái di căn của tế bào ung thư:

$$Y_i = \begin{cases} 0, & \text{tế bào ung thư chưa di căn} \\ 1, & \text{tế bào ung thư đã di căn} \end{cases}$$

- biến giải thích X_{1i} là kích cỡ khối u (cm).

Câu hỏi nghiên cứu: dự đoán khả năng di căn của tế bào ung thư thực quản dựa trên thông tin của khối u.

Mô hình hồi quy logistic:

$$\Pr(Y_i = 1|X_{1i}) = \pi_i = \frac{\exp(\beta_0 + \beta_1 X_{1i})}{1 + \exp(\beta_0 + \beta_1 X_{1i})}$$

Ví dụ

Chọn điểm bắt đầu $\beta^{(0)} = (\beta_0^{(0)}, \beta_1^{(0)}) = (-3, 0.2)$.

Giá trị của $\beta^{(t)}$ trong bước lặp thứ t , cũng như sai số:


Lần lặp t	$\beta_0^{(t)}$	$\beta_1^{(t)}$	Sai số
0	-3.0000	0.2000	0
1	0.8983	0.2795	3.8991
2	-3.6946	0.5401	4.6003
3	-0.3697	0.2420	3.3383
4	-2.0255	0.4946	1.6750
5	-2.0845	0.5113	6.1283×10^{-2}
6	-2.0858	0.5117	1.3533×10^{-3}
7	-2.0858	0.5117	5.0879×10^{-7}
8	-2.0858	0.5117	6.7885×10^{-14}
9	-2.0858	0.5117	4.4409×10^{-16}
10	-2.0858	0.5117	4.4409×10^{-16}
11	-2.0858	0.5117	4.4409×10^{-16}

Ví dụ

Ví dụ

Ta thu được ước lượng mô hình logistic:

$$\hat{\Pr}(Y = 1|X = x) = \frac{\exp(-2.0858 + 0.5117x)}{1 + \exp(-2.0858 + 0.5117x)}$$



Diễn giải mô hình

Với mô hình logistic được ước lượng

$$\hat{\Pr}(Y = 1|X = x) = \frac{\exp(-2.0858 + 0.5117x)}{1 + \exp(-2.0858 + 0.5117x)}$$

cho trước một giá trị của X ta dự đoán xác suất di căn của tế bào ung thư.

Ví dụ, với khối u có kích cỡ 6cm, xác suất di căn dự đoán là

$$\hat{\Pr}(Y = 1|X = 6) = \frac{\exp(-2.0858 + 0.5117 \times 6)}{1 + \exp(-2.0858 + 0.5117 \times 6)} = 0.7279$$

Ví dụ, với khối u có kích cỡ 3cm, xác suất di căn dự đoán là

$$\hat{\Pr}(Y = 1|X = 3) = \frac{\exp(-2.0858 + 0.5117 \times 3)}{1 + \exp(-2.0858 + 0.5117 \times 3)} = 0.3657$$

Diễn giải mô hình

Ước lượng $\hat{\beta}_1 > 0$, do đó, khi kích cỡ của khối u tăng thì xác suất tế bào ung thư di căn cũng tăng lên (minh họa bởi đường ước lượng trong hình).

Hệ số chặn $\hat{\beta}_0$ được hiểu là một hệ số cơ sở (hay tham chiếu) cho xác suất, khi biến giải thích có giá trị bằng 0:

$$\frac{\exp(-2.0858)}{1 + \exp(-2.0858)} = 0.1105$$

Diễn giải mô hình

Từ kết quả ước lượng hệ số mô hình, ta có thể biểu diễn tỷ lệ cược:

- nếu kích cỡ của khối u tăng 6cm thì tỷ lệ cược cho việc tế bào ung thư di căn là

$$\exp(-2.0858 + 0.5117 \times 6) = 2.6762$$

tức là, với khối u có kích thước 6cm, thì xác suất quan sát được một người bệnh có sự di căn tế bào ung thư là cao hơn 2.6762 lần so với xác suất không quan sát được sự di căn;

- nếu kích cỡ của khối u tăng 3cm thì tỷ lệ cược cho việc tế bào ung thư di căn là

$$\exp(-2.0858 + 0.5117 \times 3) = 0.5766$$

tức là, với khối u có kích thước 3cm, thì xác suất quan sát được một người bệnh có sự di căn tế bào ung thư là thấp hơn 0.5766 lần so với xác suất không quan sát được sự di căn;

- nếu kích cỡ của khối u tăng 1cm thì tỷ lệ cược cho việc tế bào ung thư di căn tăng lên $\exp(0.5117) = 1.6681$ lần, hay tương đương với mức tăng 66.81%.

Diễn giải mô hình

