

Bài giảng 4: Hồi quy logistic - Thống kê suy luận

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Mô Hình Thống Kê Tuyến Tính Nâng Cao

Mục lục

1 *Phân phối tiệm cận*

2 *Khoảng tin cậy*

3 *Thống kê kiểm định*

1 *Phân phối tiệm cận*

2 *Khoảng tin cậy*

3 *Thống kê kiểm định*

Mô hình hồi quy logistic

Trong bài học trước, ta đã làm quen với mô hình hồi quy logistic

$$\Pr(Y = 1|X_1, \dots, X_q) = \pi = \frac{\exp(\beta_0 + \beta_1 X_1 + \dots + \beta_q X_q)}{1 + \exp(\beta_0 + \beta_1 X_1 + \dots + \beta_q X_q)},$$

với $X_1, \dots, X_q$ là q biến hồi quy độc lập, và Y là biến phản hồi nhị phân.

Với n quan sát độc lập, $(Y_i, X_{1i}, \dots, X_{qi})$, với $i = 1, \dots, n$,

khi đó, ước lượng hợp lý cực đại (MLE) cho $\beta = (\beta_0, \beta_1, \dots, \beta_q)^\top$ được xác định bởi thuật toán Fisher Scoring:

$$\hat{\beta} = \beta^\dagger + (\mathbf{Z}^\top \mathbf{V}^\dagger \mathbf{Z})^{-1} \mathbf{Z}^\top (\mathbf{Y} - \boldsymbol{\pi}^\dagger),$$

với

$$\mathbf{V} = \begin{pmatrix} \pi_1(1 - \pi_1) & 0 & \dots & 0 \\ 0 & \pi_2(1 - \pi_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \pi_n(1 - \pi_n) \end{pmatrix},$$

và $\mathbf{Z}$ là ma trận thiết kế của mô hình.

Tính tiệm cận của hệ số

Nhắc lại rằng, ta có hàm log-likelihood cho β là:

$$\ell(\beta) = \sum_{i=1}^n \left\{ Y_i \mathbf{Z}_i^\top \beta - \log \left(1 + \exp \left(\mathbf{Z}_i^\top \beta \right) \right) \right\},$$

ma trận thông tin Fisher là

$$\mathcal{I}(\beta) = \mathbf{Z}^\top \mathbf{V} \mathbf{Z}.$$

Bởi vì $\hat{\beta}$ là ước lượng MLE, tức là:

$$\hat{\beta} = \arg \max_{\beta \in \Theta \subset \mathbb{R}^{q+1}} \ell(\beta).$$

Khi đó, $\hat{\beta}$ có đầy đủ tính chất tiệm cận của một ước lượng MLE, nếu các điều kiện chính quy của mô hình được thỏa mãn.

Tính tiệm cận của hệ số

Điều kiện chính quy:

- (A1) Giá trị chính xác (*the true value*) β_0 của β là tồn tại và phải nằm trong không gian tham số $\Theta \subset \mathbb{R}^{q+1}$.
- (A2) Với hai giá trị khác nhau β_1 và β_2 , hàm log-likelihood được định nghĩa bởi hai tham số này sẽ khác nhau, tức là $\ell(\beta_1) \neq \ell(\beta_2)$.
- (A3) Tồn tại một lân cận $\mathcal{N}$ của θ_0 sao cho, các đạo hàm $\frac{\partial \ell}{\partial \beta}$, $\frac{\partial^2 \ell}{\partial \beta \partial \beta^\top}$ và $\frac{\partial^3 \ell}{\partial \beta \partial \beta^\top \partial \beta}$ tồn tại hầu chắc chắn trong lân cận này. Hơn nữa, $\frac{1}{n} \mathbb{E} \left\{ \left\| \frac{\partial^3 \ell}{\partial \beta \partial \beta^\top \partial \beta} \right\| \right\}$ bị chặn đều với $\beta \in \mathcal{N}$.
- (A4) Ma trận thông tin Fisher $\mathcal{I}(\beta)$ là hữu hạn và xác định dương, với $\beta \in \mathcal{N}$.

Tính tiệm cận của hệ số

Ta có các kết quả sau:

- $\hat{\beta}$ là ước lượng vững của β tức là $\hat{\beta} \xrightarrow{p} \beta_0$, khi $n \rightarrow \infty$.
- Ước lượng $\hat{\beta}$ là xấp xỉ phân phối chuẩn $q + 1$ -chiều với vectơ trung bình là β_0 và ma trận hiệp phương sai $\mathcal{I}^{-1}(\beta_0)$, tức là

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$.

- Ước lượng ma trận hiệp phương sai của $\hat{\beta}$ là

$$\widehat{\text{Var}}(\hat{\beta}) = \left(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z} \right)^{-1},$$

với

$$\hat{\mathbf{V}} = \begin{pmatrix} \hat{\pi}_1(1 - \hat{\pi}_1) & 0 & \dots & 0 \\ 0 & \hat{\pi}_2(1 - \hat{\pi}_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{\pi}_n(1 - \hat{\pi}_n) \end{pmatrix},$$

Tính tiệm cận của thành phần tuyến tính

Delta method

Xét dãy biến ngẫu nhiên $T_{1n}, \dots, T_{pn}$, sao cho

$$\sqrt{n}(\mathbf{T}_n - \boldsymbol{\theta}) \xrightarrow{d} \mathcal{N}_p(0, \Sigma),$$

khi $n \rightarrow +\infty$, với $\mathbf{T}_n = (T_{1n}, \dots, T_{pn})^\top$ và $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)^\top$. Khi đó, với một hàm h liên tục, khả vi với đạo hàm khác 0, từ $\mathbb{R}^p \mapsto \mathbb{R}^q$, thì ta có

$$\sqrt{n}(h(\mathbf{T}_n) - h(\boldsymbol{\theta})) \xrightarrow{d} \mathcal{N}_q\left(0, \frac{\partial h}{\partial \boldsymbol{\theta}}^\top \Sigma \frac{\partial h}{\partial \boldsymbol{\theta}}\right),$$

khi $n \rightarrow +\infty$.

Tính tiệm cận của thành phần tuyến tính

Đặt $\eta = \mathbf{z}^\top \beta$, với $\mathbf{z} = (1, x_1, \dots, x_q)$, giá trị cho trước của các biến $X_1, \dots, X_q$.

Dễ thấy η là hàm liên tục của β , từ $\mathbb{R}^{q+1} \mapsto \mathbb{R}$.

Từ kết quả

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$, áp dụng Delta method, ta có

$$\hat{\eta} \xrightarrow{d} \mathcal{N} \left(\eta_0, \mathbf{z}^\top (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \mathbf{z} \right),$$

và ước lượng phương sai của $\hat{\eta}$ là

$$\widehat{\text{Var}}(\hat{\eta}) = \mathbf{z}^\top \left(\mathbf{Z}^\top \widehat{\mathbf{V}} \mathbf{Z} \right)^{-1} \mathbf{z}.$$

1 *Phân phối tiệm cận*

2 *Khoảng tin cậy*

3 *Thống kê kiểm định*

Vùng tin cậy đồng thời của hệ số

Từ kết quả xấp xỉ tiệm cận phân phối chuẩn của ước lượng hệ số

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$, ta có

$$\left(\hat{\beta} - \beta_0 \right)^\top (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z}) \left(\hat{\beta} - \beta_0 \right) \xrightarrow{d} \chi_{q+1}^2$$

Thay thế $\mathbf{V}_0$ bởi $\hat{\mathbf{V}}$, và β_0 bằng β (tổng quát), ta được

$$\left(\hat{\beta} - \beta \right)^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z}) \left(\hat{\beta} - \beta \right) \xrightarrow{d} \chi_{q+1}^2.$$

Vùng tin cậy đồng thời của hệ số

Đặt $W \sim \chi_k^2$, do tính chất không đối xứng của phân phối, nên ta có

$$\Pr(W \leq \chi_{k,1-\alpha}^2) = 1 - \alpha,$$

trong đó, $\chi_{k,1-\alpha}^2$ là phân vị thứ $(1 - \alpha)$ của phân phối χ_k^2 .

Theo đó, ta có

$$\Pr\left(\left(\hat{\beta} - \beta\right)^\top \left(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z}\right) \left(\hat{\beta} - \beta\right) \leq \chi_{q+1,1-\alpha}^2\right) = 1 - \alpha.$$

Biểu thức này dẫn tới vùng tin cậy đồng thời cho β :

$$\mathcal{R}_\beta = \left\{ \beta \in \Theta \subset \mathbb{R}^{q+1} : \left(\hat{\beta} - \beta\right)^\top \left(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z}\right) \left(\hat{\beta} - \beta\right) \leq \chi_{q+1,1-\alpha}^2 \right\}.$$

Khoảng tin cậy này có thể được biểu diễn bằng hình trong trường hợp $q = 1$ hoặc 2.

Với số chiều lớn hơn, nó không thực sự hữu ích.

Ví dụ

Xét ví dụ về ước lượng xác suất di căn của ung thư thực quản dựa vào kích thước khối u.

Bệnh nhân	Kích cỡ khối u (cm)	Sự di căn hạch bạch huyết
1	6.5	có
2	6.3	không
3	3.8	có
⋮	⋮	⋮
29	3.0	không
30	3.0	có
31	1.7	không

Biến phản hồi Y :

$$Y = \begin{cases} 0, & \text{nếu tế bào ung thư chưa di căn,} \\ 1, & \text{nếu tế bào ung thư đã di căn.} \end{cases}$$

Biến giải thích X là kích cỡ khối u (cm).

Ví dụ

Mô hình hồi quy logistic ước đoán xác suất di căn:

$$\Pr(Y_i = 1|X_i) = \pi_i = \frac{\exp(\beta_0 + \beta_1 X_i)}{1 + \exp(\beta_0 + \beta_1 X_i)}$$

Áp dụng thuật toán Fisher Scoring, ta ước lượng được

$$\blacksquare \hat{\beta}_0 = -2.0858$$

$$\blacksquare \hat{\beta}_1 = 0.5117$$


Ta thu được ước lượng mô hình logistic:

$$\hat{\pi}_i = \frac{\exp(-2.0858 + 0.5117X_i)}{1 + \exp(-2.0858 + 0.5117X_i)}$$

Ma trận hiệp phương sai của ước lượng

$$\begin{pmatrix} 1.5022 & -0.2971 \\ -0.2971 & 0.0656 \end{pmatrix}$$

Ví dụ



Khoảng tin cậy cho từng hệ số

Từ kết quả xấp xỉ tiệm cận phân phối chuẩn của ước lượng hệ số

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$, ta có

$$\frac{\hat{\beta}_j - \beta_{0j}}{\sqrt{v_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1),$$

với v_{jj} là thành phần trên đường chéo của ma trận $(\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1}$. Kết quả này có được do tính chất của phân phối chuẩn nhiều chiều.

Thay thế $\mathbf{V}_0$ bởi $\hat{\mathbf{V}}$, và β_0 bằng β (tổng quát), ta được

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{v}_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Từ đây, ta có khoảng tin cậy cho β_j là

$$\left(\hat{\beta}_j - z_{1-\alpha/2} \sqrt{\hat{v}_{jj}}, \hat{\beta}_j + z_{1-\alpha/2} \sqrt{\hat{v}_{jj}} \right)$$

Khoảng tin cậy cho từng hệ số

Ví dụ: xét lại ví dụ về ung thư thực quản, ta ước lượng

■ $\hat{\beta}_0 = -2.0858$

■ $\hat{\beta}_1 = 0.5117$

■ ma trận hiệp phương sai của ước lượng

$$\begin{pmatrix} 1.5022 & -0.2971 \\ -0.2971 & 0.0656 \end{pmatrix}$$

■ $\sqrt{\hat{v}_{11}} = 1.225643$

■ $\sqrt{\hat{v}_{22}} = 0.256125$

Khoảng tin cậy 95% cho β_0 là

$$(-4.4881, 0.3165)$$

và cho β_1 là

$$(0.0097, 1.0137)$$

Khoảng tin cậy cho π

Giả sử ta có bộ giá trị $\mathbf{z} = (1, x_1, \dots, x_q)$, lúc này ta tính được

$$\hat{\eta} = \mathbf{z}^\top \hat{\beta}$$

và ta tính được xác suất

$$\hat{\pi} = \widehat{\Pr}(Y = 1 | X_1 = x_1, \dots, X_q = x_q) = \frac{\exp(\hat{\eta})}{1 + \exp(\hat{\eta})}.$$

Xác suất này là ước lượng của xác suất

$$\pi = \Pr(Y = 1 | X_1 = x_1, \dots, X_q = x_q) = \frac{\exp(\eta)}{1 + \exp(\eta)},$$

với $\eta = \mathbf{z}^\top \beta$.

Ta mong muốn xác định khoảng tin cậy cho π .

Khoảng tin cậy cho π

Từ kết quả Delta method, ta có

$$\hat{\eta} \xrightarrow{d} \mathcal{N} \left(\eta_0, \mathbf{z}^\top (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \mathbf{z} \right),$$

Từ đây, ta suy ra rằng

$$\frac{\hat{\eta} - \eta}{\sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Do đó, ta xây dựng được khoảng tin cậy cho η

$$(\eta_L, \eta_U) = \left(\hat{\eta} - z_{1-\alpha/2} \sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}}, \hat{\eta} + z_{1-\alpha/2} \sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}} \right).$$

Áp dụng công thức tính π theo η , cho hai điểm giới hạn, ta thu được khoảng tin cậy cho π :

$$(\pi_L, \pi_U) = \left(\frac{\exp(\eta_L)}{1 + \exp(\eta_L)}, \frac{\exp(\eta_U)}{1 + \exp(\eta_U)} \right).$$

Khoảng tin cậy cho π

Ví dụ: xét lại ví dụ về ung thư thực quản, ta ước lượng

■ $\hat{\beta}_0 = -2.0858$

■ $\hat{\beta}_1 = 0.5117$

■ ma trận hiệp phương sai của ước lượng

$$\begin{pmatrix} 1.5022 & -0.2971 \\ -0.2971 & 0.0656 \end{pmatrix}$$

Giả sử ta có thông tin một người có khối u cỡ 5.2cm $\implies \mathbf{z} = (1, 5.2)$. Ta tính được

■ $\hat{\eta} = 0.5750$

■ $\hat{\pi} = 0.6399$

■ $SE(\hat{\eta}) = 0.4313$

Suy ra, ta tính được khoảng tin cậy 95% cho η là

$$(-0.2703, 1.4203)$$


và do đó, khoảng tin cậy 95% cho π là

$$(0.4328, 0.8054)$$

Khoảng tin cậy cho π

Với kích cỡ mẫu n thay đổi từ 0 tới 10 cm, ta ước lượng

- xác suất di căn - đường nét liền màu đen,
- dải tin cậy 95% (confidence band) - đường nét đứt màu xanh, như trong hình.



1 *Phân phối tiệm cận*

2 *Khoảng tin cậy*

3 *Thống kê kiểm định*

Kiểm định giả thuyết từng hệ số

Trong mô hình hồi quy logistic, ta quan tâm tới câu hỏi:

“Biến X_j có thực sự cần thiết cho mô hình để tiên đoán xác suất của Y ?”

Câu hỏi này tương đương với giả thuyết

$$\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$$

Nếu H_0 là đúng thì ta nói “ X_j không có nghĩa trong mô hình hồi quy logistics, và có thể bị loại bỏ mà không gây ảnh hưởng tới kết quả ước lượng của mô hình.”

Kiểm định giả thuyết từng hệ số

Nhắc lại rằng, ta có kết quả

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{v}_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1),$$

với $\hat{v}_{jj}$ là thành phần trên đường chéo của ma trận $(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1}$.

Dưới giả định H_0 , ta có

$$Z = \frac{\hat{\beta}_j}{\sqrt{\hat{v}_{jj}}} \sim \mathcal{N}(0, 1).$$

Từ đây, ta xác định được

$$p\text{-value} = 2(1 - \Phi(|z|)),$$

ta bác bỏ giả thuyết H_0 khi p -value nhỏ hơn một mức ý nghĩa α được xác định trước.

Kiểm định giả thuyết từng hệ số

Với ví dụ đang xét, ta có bảng kết quả tổng hợp sau:

	Estimate	Standard error	z-statistic	p-value
β_0 - Intercept	-2.0858	1.2256	-1.702	0.0888
β_1 - Cỡ khối u	0.5117	0.2561	1.998	0.0457

Như vậy, ta có thể kết luận rằng:

- cỡ khối u là cần thiết để dự đoán xác suất tế bào ung thư di căn tới hạch bạch huyết, tại mức ý nghĩa 5%;
- hệ số chặn không có ý nghĩa thống kê tại mức 5%.

So sánh mô hình lồng nhau

Giả sử rằng, ta có hai mô hình hồi quy logistic A và B như sau:

$$\text{MH A: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_{q_A} X_{q_A}$$

$$\text{MH B: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_{q_A} X_{q_A} + \dots + \beta_{q_B} X_{q_B}$$

Nhận thấy rằng MH A là một trường hợp rút gọn của MH B, với số biến $p_A < p_B$.

Ta nói rằng MH A bị lồng vào (nested) MH B.

Lúc này, câu hỏi cần giải đáp là

“Mô hình A đơn giản hơn, liệu có đủ tốt để mô hình hóa dữ liệu?”

Câu hỏi này tương đương với giả thuyết

$$\begin{cases} H_0 : \beta_{q_A+1} = \beta_{q_A+2} = \dots = \beta_{q_B} = 0 \\ H_1 : \text{không phải } H_0 \end{cases}$$

So sánh mô hình lồng nhau

Từ hai mô hình, ta có hàm likelihood tương ứng là:

$$\text{MH A: } L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}),$$

$$\text{MH B: } L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B}).$$

Nếu giả thuyết H_0 là đúng (tức là mô hình A đủ tốt để mô hình hóa dữ liệu), khi đó tỷ số

$$\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B})} \approx 1$$

hay

$$\log \left(\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B})} \right) \approx 0.$$

Mặt khác, ta chứng minh được rằng

$$W = -2 \log \left(\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B})} \right) \sim \chi^2_{q_B - q_A},$$

thống kê W này được gọi là log-likelihood ratio.

So sánh mô hình lồng nhau

Giá trị p -value được định nghĩa bởi

$$p\text{-value} = \Pr(W > w),$$

với w được tính từ kết quả ước lượng mô hình, và $W \sim \chi^2_{q_B - q_A}$.

Ta bác bỏ giả thuyết H_0 khi p -value nhỏ hơn một mức ý nghĩa α được xác định trước.

So sánh mô hình lồng nhau

Ví dụ: tiếp tục với dữ liệu ung thư thực quản. Ta có hai mô hình như sau:

$$\text{MH A: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0$$

$$\text{MH B: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X$$

Mô hình A có nghĩa là xác suất di căn của tế bào ung thư là hằng số, không phụ thuộc vào kích cỡ khối u (X).

Kết quả phân tích cho kết quả

- $W \sim \chi_1^2$;
- $w = 5.1632$;
- $p\text{-value} = 0.0231$

Như vậy, ta bác bỏ giả thuyết H_0 tại mức ý nghĩa 5%.

Vậy, kích cỡ của khối u là có ý nghĩa trong mô hình dự đoán xác suất di căn của tế bào ung thư thực quản.