

Bài giảng 5: Hồi quy logistic - Đánh giá, Mô hình cho tỷ lệ

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Mô Hình Thống Kê Tuyển Tính Nâng Cao

Mục lục

1 Đánh giá mô hình

2 Mô hình cho tỷ lệ

3 Chuẩn đoán mô hình

1 *Đánh giá mô hình*

2 *Mô hình cho tỷ lệ*

3 *Chuẩn đoán mô hình*

Một số tiêu chuẩn đánh giá

Đối với mô hình hồi quy, hai chỉ số thường được dùng để đánh giá là:

- **root mean square error** - căn bậc hai trung bình bình phương sai số:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$

RMSE đo lường độ chính xác tổng thể của mô hình và là cơ sở để so sánh với các mô hình khác.

- tương tự với RMSE là **residual standard error** - sai số chuẩn thặng dư:

$$\text{RSE} = \sqrt{\frac{1}{n - p - 1} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2},$$

với $\hat{Y}_i$ là giá trị ước lượng từ mô hình.

Về mặt ý tưởng, mô hình tốt, mô tả khớp với dữ liệu, là mô hình có RMSE và RSE nhỏ.

Một số tiêu chuẩn đánh giá

Đối với mô hình hồi quy logistic:

$$\pi_i = \frac{\exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})}{1 + \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})},$$

Do đó, ta có

- giá trị quan sát: $Y_i = 0$ hoặc 1 ;
- giá trị ước lượng: $\hat{\pi}_i \in (0, 1)$.

Từ đây, áp dụng tiêu chuẩn RMSE cho hồi quy logistic là

$$\text{RMSE} = \sqrt{\frac{1}{n} \left(\sum_{Y_i=0} \hat{\pi}_i^2 + \sum_{Y_i=1} (1 - \hat{\pi}_i)^2 \right)}$$

Chỉ số này chỉ phụ thuộc vào $\hat{\pi}_i$.

↪ không thể dùng để đánh giá sai số giữa ước lượng và giá trị quan sát.

So sánh nhị phân

Bởi vì quan sát Y_i là biến nhị phân, do đó, để tiện so sánh với ước lượng của mô hình, $\hat{\pi}_i$, ta cần chuyển đổi ước lượng này về dạng nhị phân.

Nhắc lại rằng

$$\hat{\pi}_i = \widehat{\Pr}(Y_i = 1 | X_{1i}, X_{2i}, \dots, X_{pi})$$

tức là ước lượng của xác suất $Y_i = 1$ khi biết giá trị $X_{1i}, X_{2i}, \dots, X_{pi}$.

Áp dụng nguyên lý xác suất, ta có thể đặt

- $\hat{Y}_i = 0$ nếu $\hat{\pi}_i \leq p_0$
- $\hat{Y}_i = 1$ nếu $\hat{\pi}_i > p_0$

với p_0 là một ngưỡng xác suất cho trước.

Thông thường, ta chọn $p_0 = 0.5$.

So sánh nhị phân

Khi đó, với p_0 cho trước, mỗi giá trị quan sát Y_i và giá trị ước lượng $\hat{Y}_i$, ta quan sát:

$$Z_i = \begin{cases} 0, & \text{nếu } (Y_i = 0, \hat{Y}_i = 1) \text{ hoặc } (Y_i = 1, \hat{Y}_i = 0) \\ 1, & \text{nếu } (Y_i = 0, \hat{Y}_i = 0) \text{ hoặc } (Y_i = 1, \hat{Y}_i = 1) \end{cases}$$

Tổng hợp tất cả các giá trị của Z_i , ta có bảng sau:

		Quan sát	
		$Y = 0$	$Y = 1$
Ước lượng	$\hat{Y}_i = 0$	n_{00}	n_{01}
	$\hat{Y}_i = 1$	n_{10}	n_{11}

với $n_{00} + n_{10} = n_0$ (số lượng quan sát $Y = 0$), $n_{01} + n_{11} = n_1$ (số lượng quan sát $Y = 1$). Trong đó,

- n_{00} và n_{11} là hai giá trị cho thấy số lượng ước lượng khớp của mô hình;
- n_{01} và n_{10} là hai giá trị cho thấy số lượng ước lượng sai của mô hình.

↪ n_{00} càng gần n_0 và n_{11} càng gần n_1 , thì mô hình là dự đoán tốt.

So sánh nhị phân

Ví dụ: xét mô hình hồi quy logistic ước đoán xác suất di căn

$$\Pr(Y_i = 1|X_i) = \pi_i = \frac{\exp(\beta_0 + \beta_1 X_i)}{1 + \exp(\beta_0 + \beta_1 X_i)},$$

với X là kích thước khối u.

Áp dụng thuật toán Fisher Scoring, ta ước lượng được

$$\hat{\pi}_i = \frac{\exp(-2.0858 + 0.5117X_i)}{1 + \exp(-2.0858 + 0.5117X_i)}.$$

Với $p_0 = 0.5$, ta tính được

		Quan sát	
		$Y = 0$	$Y = 1$
Ước lượng	$\hat{Y}_i = 0$	10	4
	$\hat{Y}_i = 1$	3	14

Tổng số người không bị ung thư di căn là 13, bị di căn là 18.

So sánh nhị phân

Với $p_0 = 0.35$, ta tính được

		Quan sát	
		$Y = 0$	$Y = 1$
Ước lượng	$\hat{Y}_i = 0$	3	0
	$\hat{Y}_i = 1$	10	18

Với $p_0 = 0.75$, ta tính được

		Quan sát	
		$Y = 0$	$Y = 1$
Ước lượng	$\hat{Y}_i = 0$	11	12
	$\hat{Y}_i = 1$	2	6

↪ kết quả so sánh hoàn toàn phụ thuộc vào ngưỡng xác suất p_0 .

Tỷ lệ dự đoán

Từ bảng kết quả so sánh nhị phân với một ngưỡng p_0 , ta định nghĩa được

- tỷ lệ dự đoán đúng “0”, được gọi là **Specificity** - Sp:

$$\text{Sp}(p_0) = \frac{n_{00}}{n_0} = \frac{1}{n_0} \sum_{i=1}^n I(Y_i = 0, \hat{\pi}_i \leq p_0)$$

- tỷ lệ dự đoán đúng “1”, được gọi là **Sensitivity** - Se:

$$\text{Se}(p_0) = \frac{n_{11}}{n_1} = \frac{1}{n_1} \sum_{i=1}^n I(Y_i = 1, \hat{\pi}_i > p_0)$$

- tỷ lệ dự đoán sai “0”, được gọi là **False Negative** - FN:

$$\text{FN}(p_0) = \frac{n_{01}}{n_1} = \frac{1}{n_1} \sum_{i=1}^n I(Y_i = 1, \hat{\pi}_i \leq p_0) = 1 - \text{Se}(p_0)$$

- tỷ lệ dự đoán sai “1”, được gọi là **False Positive** - FP:

$$\text{FP}(p_0) = \frac{n_{10}}{n_0} = \frac{1}{n_0} \sum_{i=1}^n I(Y_i = 0, \hat{\pi}_i > p_0) = 1 - \text{Sp}(p_0).$$

Tỷ lệ dự đoán

Với $p_0 = 0.5$, ta tính được

		Quan sát	
		$Y = 0$	$Y = 1$
Ước lượng	$\hat{Y}_i = 0$	10	4
	$\hat{Y}_i = 1$	3	14

Theo đó,

- tỷ lệ dự đoán đúng “0”

$$Sp(0.5) = \frac{10}{13} \approx 0.7692$$

- tỷ lệ dự đoán đúng “1”

$$Se(0.5) = \frac{14}{18} \approx 0.7778$$

Tỷ lệ dự đoán

Với $p_0 = 0.35$, ta tính được

		Quan sát	
		$Y = 0$	$Y = 1$
Ước lượng	$\hat{Y}_i = 0$	3	0
	$\hat{Y}_i = 1$	10	18

Theo đó,

- tỷ lệ dự đoán đúng “0”


$$Sp(0.35) = \frac{3}{13} \approx 0.2308$$

- tỷ lệ dự đoán đúng “1”

$$Se(0.35) = \frac{18}{18} = 1$$

Tỷ lệ dự đoán

Thay đổi ngưỡng xác suất p_0 từ 0 tới 1, ta thu được biểu đồ sau:



Phân tích đường cong ROC

- Qua hai ví dụ trên, ta thấy rằng specificity và sensitivity chỉ đo lường hiệu suất của sự dự đoán liên quan đến một ngưỡng cụ thể p_0 .
- Bằng cách thay đổi p_0 , ta sẽ có các giá trị khác nhau của specificity và sensitivity, và do đó, hiệu suất cũng khác nhau!

⇒ Chúng ta cần đánh giá specificity và sensitivity ở tất cả các ngưỡng p_0 có thể có để tổng hợp độ chính xác của mô hình.

Receiver Operating Characteristic (ROC) curve

Một đường cong ROC (receiver operating characteristic) là đường cong mô tả tất cả các cặp điểm $(1 - \text{Sp}(p_0), \text{Se}(p_0))$ với tất cả ngưỡng $p_0 \in (0, 1)$ có thể:

$$\text{ROC} = \{(1 - \text{Sp}(p_0), \text{Se}(p_0)), p_0 \in (0, 1)\}$$

Đường cong ROC được biểu diễn trên đồ thị giới hạn bởi hình vuông đơn vị


Diện tích dưới đường cong (AUC)

Diện tích dưới đường cong ROC (AUC) là một độ đo tổng hợp cho độ chính xác của phép phân loại.

Phân tích đường cong ROC

Thông thường, đường cong ROC của mô hình logistic nằm phía trên đường tham chiếu, tức là đường chéo $y = x$.

- Sự cân bằng giữa sensitivity và specificity được hiển thị trên đường cong ROC.
- Nếu đường cong ROC trùng với đường tham chiếu thì $AUC = 0.5$, chúng ta có thể nói rằng việc phân loại dựa trên mô hình logistic là **sự đoán ngẫu nhiên**.
- Nếu đường cong ROC trùng góc trên bên trái thì $AUC = 1$, điều đó có nghĩa là việc phân loại dựa trên mô hình logistic có hiệu suất **hoàn hảo**.



Giá trị hợp lý của AUC thay đổi từ 0.5 đến 1. AUC càng cao thì khả năng dự đoán của mô hình càng tốt.

Phân tích đường cong ROC

Đường cong ROC có thể được biểu diễn là $\text{ROC}(p)$, tức là hàm của p với $p \in (0, 1)$ - tức là $1 - \text{Sp}$.

Do đó, diện tích dưới đường cong ROC (AUC) được định nghĩa bởi

$$\text{AUC} = \int_0^1 \text{ROC}(p) \, dp$$

AUC có thể được ước lượng bằng **trapezoidal rule** (quy tắc hình thang):

$$\int_a^b f(x) \, dx = \sum_{k=1}^{N-1} \frac{f(x_{k+1}) + f(x_k)}{2} (x_{k+1} - x_k).$$


Áp dụng với đường cong ROC:

$$\widehat{\text{AUC}} = \sum_{k=1}^{N-1} \frac{\text{Se}(p_{0,k+1}) + \text{Se}(p_{0,k})}{2} (\text{Sp}(p_{0,k+1}) - \text{Sp}(p_{0,k})).$$

Khoảng tin cậy cho AUC có thể được xây dựng bằng phương pháp Delong hoặc phương pháp bootstrap.

Phân tích đường cong ROC

Đối với ví dụ về sự di căn của tế bào ung thư, đường cong ROC ước lượng được biểu diễn như sau:



Giá trị AUC ước lượng: 0.7329, 95% khoảng tin cậy: (0.5432, 0.9226).

Phân tích đường cong ROC

Quy tắc đánh giá dự trên AUC

Chúng ta có thể sử dụng quy tắc sau để đánh giá tính chính xác của mô hình logistic (hoặc một sự phân loại):

AUC	Tính chính xác
0.5	sự đoán ngẫu nhiên
(0.5, 0.65]	thiếu chính xác
(0.65, 0.8]	chấp nhận được
(0.8, 0.95]	tốt
(0.95, 1)	rất tốt
1	hoàn hảo

Trong ví dụ của chúng ta, AUC ước tính là 0.7329, 95% khoảng tin cậy cho AUC (0.5432, 0.9226), do đó mô hình logistic có độ chính xác chấp nhận được để dự đoán khả năng di căn của tế bào ung thư thực quản dựa trên kích thước khối u.

1 *Đánh giá mô hình*

2 *Mô hình cho tỷ lệ*

3 *Chuẩn đoán mô hình*

Giới thiệu bài toán

Trong phần trước, ta đã xây dựng và ước lượng mô hình logistic cho trường hợp Y là biến nhị phân (0 hoặc 1).

Trong thực tế, biến Y có thể được báo cáo dưới dạng là tổng số lần xuất hiện của 1 sự kiện cho 1 đối tượng quan sát:

- số tubin bị nứt của một tổ hợp máy, sau một khoảng thời gian làm việc;
- số lượng trứng cá hồi sống sót trong 1 hộp, sau một khoảng thời gian;
- số lượng trứng rùa nở ra con đực trong một ổ trứng rùa biển.

Trong các ví dụ trên, các sự kiện được quan tâm là

- tubin bị nứt
- trứng cá hồi sống sót
- trứng rùa nở ra con đực

chúng đều là các sự kiện dạng nhị phân (có/không).

Và biến Y có dạng là tổng của một dãy độc lập các biến nhị phân.

Giới thiệu bài toán

Nhắc lại: Cho $Z_1, Z_2, \dots, Z_m$ là một dãy biến ngẫu nhiên, độc lập, cùng phân phối, sao cho $Z_j \sim \mathcal{B}(1, p)$ với $j = 1, \dots, m$. Khi đó $Y = \sum_{j=1}^m Z_j$ là một biến ngẫu nhiên nhị thức, $Y \sim \mathcal{B}(m, p)$, với hàm trọng lượng xác suất

$$\Pr(Y = y) = C_m^y p^y (1 - p)^{m-y}$$

Do đó, biến Y trong các ví dụ:

- số tuabin bị nứt của một tổ hợp máy, sau một khoảng thời gian làm việc;
- số lượng trứng cá hồi sống sót trong 1 hộp, sau một khoảng thời gian;
- số lượng trứng rùa nở ra con đực trong một ổ trứng rùa biển.

là các biến nhị thức.

Giới thiệu bài toán


Ví dụ 1: Để nghiên cứu giới hạn chịu đựng của tuabin khi làm việc liên tục trong một khoảng thời gian dài. Một thí nghiệm được thực hiện trên 11 trường hợp với số lượng tuabin khác nhau trong mỗi trường hợp. Trong trường hợp thứ i , các tuabin m_i được chạy trong cùng một khoảng thời gian t_i (đơn vị: giờ). Dữ liệu quan sát ghi lại tổng số bánh xe của mi tuabin bị nứt.

Trường hợp	Giờ	Số tuabin	Số lượng tubin bị nứt
1	400	39	0
2	1000	53	4
3	1400	33	2
⋮	⋮	⋮	⋮
9	3800	34	22
10	4200	40	21
11	4600	36	21

Với trường hợp thứ i , biến đáp ứng Y_i biểu thị tổng số lượng bánh xe tuabin bị nứt là một biến nhị thức, $Y_i \sim \mathcal{B}(m_i, \pi_i)$.

Ta mong muốn ước lượng xác suất pi dựa trên thời gian hoạt động t_i .

Giới thiệu bài toán



Xây dựng mô hình

Giả sử ta có bộ dữ liệu ngẫu nhiên $(Y_i, X_{1i}, X_{2i}, \dots, X_{qi})$, với $i = 1, \dots, n$, trong đó:

- các quan sát thứ i là độc lập;
- Y_i là biến phản hồi nhị thức, $Y_i \sim \mathcal{B}(m_i, \pi_i)$;
- $X_{1i}, \dots, X_{qi}$ là các biến giải thích có thể liên quan tới Y_i , và do đó, có thể liên quan tới π_i (tỷ lệ xảy ra Y_i).

Tương tự như trong trường hợp nhị phân, ở đây ta cũng mô hình hóa tỷ lệ π_i bởi:

$$\pi_i = \frac{\exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})}{1 + \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})},$$

hay tương đương với,

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi}.$$

Ước lượng mô hình

Theo các thiết lập mô hình, ta có $Y_i | X_{1i}, X_{2i}, \dots, X_{qi} \sim \mathcal{B}(m_i, \pi_i)$, tức là $X_{1i}, X_{2i}, \dots, X_{qi}$ được coi như cố định.

Do đó, ta xây dựng được hàm hợp lý:

$$L(\beta_0, \beta_1, \dots, \beta_q) = \prod_{i=1}^n C_{m_i}^{Y_i} \pi_i^{Y_i} (1 - \pi_i)^{m_i - Y_i}.$$

Từ đây ta suy ra được hàm log-likelihood:

$$\ell(\beta) = \sum_{i=1}^n \left\{ Y_i \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) - m_i \log \left(1 + \exp \left(\beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) \right) \right\}.$$

Ước lượng mô hình

Ta có hàm score cho từng tham số β_j là:

$$U(\beta_0) = \sum_{i=1}^n \left\{ Y_i - m_i \frac{\exp(\beta_0 + \sum_{j=1}^q \beta_j X_{ji})}{1 + \exp(\beta_0 + \sum_{j=1}^q \beta_j X_{ji})} \right\}$$
$$U(\beta_j) = \sum_{i=1}^n X_{ji} \left\{ Y_i - m_i \frac{\exp(\beta_0 + \sum_{j=1}^q \beta_j X_{ji})}{1 + \exp(\beta_0 + \sum_{j=1}^q \beta_j X_{ji})} \right\}$$

Bằng cách đặt $Z_i = (1, X_{1i}, \dots, X_{qi})^\top$, ta có

$$U(\beta) = \sum_{i=1}^n Z_i \{Y_i - m_i \pi_i\}$$

Ước lượng mô hình

Từ công thức của $U(\beta)$, ta tính được ma trận thông tin Fisher:

$$\mathcal{I}(\beta) = \sum_{i=1}^n \mathbf{Z}_i \mathbf{Z}_i^\top m_i \pi_i (1 - \pi_i).$$

Đặt

$$\mathbf{Z} = \begin{pmatrix} 1 & X_{11} & \dots & X_{q1} \\ 1 & X_{12} & \dots & X_{q2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \dots & X_{qn} \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \boldsymbol{\pi} = \begin{pmatrix} m_1 \pi_1 \\ m_2 \pi_2 \\ \vdots \\ m_n \pi_n \end{pmatrix}$$
$$\mathbf{V} = \begin{pmatrix} m_1 \pi_1 (1 - \pi_1) & 0 & \dots & 0 \\ 0 & m_2 \pi_2 (1 - \pi_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & m_n \pi_n (1 - \pi_n) \end{pmatrix}$$

Khi này, ta có

$$U(\beta) = \mathbf{Z}^\top (\mathbf{Y} - \boldsymbol{\pi}), \quad \mathcal{I}(\beta) = \mathbf{Z}^\top \mathbf{V} \mathbf{Z}.$$

Ước lượng mô hình

Áp dụng thuật toán Fisher scoring, ta có

$$\hat{\beta} = \beta^{\dagger} + \mathcal{I}^{-1}(\beta^{\dagger}) U(\beta^{\dagger}),$$

hay tương đương với

$$\hat{\beta} = \beta^{\dagger} + (\mathbf{Z}^{\top} \mathbf{V}^{\dagger} \mathbf{Z})^{-1} \mathbf{Z}^{\top} (\mathbf{Y} - \boldsymbol{\pi}^{\dagger}).$$

Từ đây, ta có thuật toán ước lượng như sau:

- 1 Chọn một giá trị bắt đầu $\beta^{(0)}$
- 2 Với bước lặp $t = 0$, ta tính

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{Z}^{\top} \mathbf{V}^{(t)} \mathbf{Z})^{-1} \mathbf{Z}^{\top} (\mathbf{Y} - \boldsymbol{\pi}^{(t)}),$$

- 3 Đặt $t = t + 1$, lặp lại bước 2 cho tới khi nào thuật toán hội tụ, có thể là

$$\|\beta^{(t+1)} - \beta^{(t)}\| < \varepsilon.$$


- 4 ước lượng hợp lý cực đại $\hat{\beta} = \beta^{(t+1)}$.

Ước lượng mô hình

Ước lượng

■ $\hat{\beta}_0 = -3.923$

■ $\hat{\beta}_1 = 0.0010$



Tính tiệm cận của ước lượng

Ta chứng minh được rằng

- $\hat{\beta}$ là ước lượng vững của β tức là $\hat{\beta} \xrightarrow{p} \beta_0$, khi $n \rightarrow \infty$.
- Ước lượng $\hat{\beta}$ là xấp xỉ phân phối chuẩn $q + 1$ -chiều với vectơ trung bình là β_0 và ma trận hiệp phương sai $\mathcal{I}^{-1}(\beta_0)$, tức là

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$.

- Ước lượng ma trận hiệp phương sai của $\hat{\beta}$ là

$$\widehat{\mathbb{V}\text{ar}}(\hat{\beta}) = (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1},$$

với

$$\hat{\mathbf{V}} = \begin{pmatrix} m_1 \hat{\pi}_1 (1 - \hat{\pi}_1) & 0 & \dots & 0 \\ 0 & m_2 \hat{\pi}_2 (1 - \hat{\pi}_2) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & m_n \hat{\pi}_n (1 - \hat{\pi}_n) \end{pmatrix},$$

Tính tiệm cận của ước lượng

Đặt $\eta = \mathbf{z}^\top \beta$, với $\mathbf{z} = (1, x_1, \dots, x_q)$, giá trị cho trước của các biến $X_1, \dots, X_q$.

Dễ thấy η là hàm liên tục của β , từ $\mathbb{R}^{q+1} \mapsto \mathbb{R}$.

Từ kết quả

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$, áp dụng Delta method, ta có

$$\hat{\eta} \xrightarrow{d} \mathcal{N} \left(\eta_0, \mathbf{z}^\top (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \mathbf{z} \right),$$

và ước lượng phương sai của $\hat{\eta}$ là

$$\widehat{\text{Var}}(\hat{\eta}) = \mathbf{z}^\top \left(\mathbf{Z}^\top \widehat{\mathbf{V}} \mathbf{Z} \right)^{-1} \mathbf{z}.$$

Khoảng tin cậy cho π

Giả sử ta có bộ giá trị $\mathbf{z} = (1, x_1, \dots, x_q)$, lúc này ta tính được

$$\hat{\eta} = \mathbf{z}^\top \hat{\beta}$$

và ta tính được xác suất

$$\hat{\pi} = \frac{\exp(\hat{\eta})}{1 + \exp(\hat{\eta})}.$$

Xác suất này là ước lượng của xác suất

$$\pi = \frac{\exp(\eta)}{1 + \exp(\eta)},$$

với $\eta = \mathbf{z}^\top \beta$.

Ta mong muốn xác định khoảng tin cậy cho π .

Khoảng tin cậy cho π

Từ kết quả Delta method, ta có

$$\hat{\eta} \xrightarrow{d} \mathcal{N} \left(\eta_0, \mathbf{z}^\top (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \mathbf{z} \right),$$

Từ đây, ta suy ra rằng

$$\frac{\hat{\eta} - \eta}{\sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Do đó, ta xây dựng được khoảng tin cậy cho η

$$(\eta_L, \eta_U) = \left(\hat{\eta} - z_{1-\alpha/2} \sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}}, \hat{\eta} + z_{1-\alpha/2} \sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}} \right).$$

Áp dụng công thức tính π theo η , cho hai điểm giới hạn, ta thu được khoảng tin cậy cho π :

$$(\pi_L, \pi_U) = \left(\frac{\exp(\eta_L)}{1 + \exp(\eta_L)}, \frac{\exp(\eta_U)}{1 + \exp(\eta_U)} \right).$$

Khoảng tin cậy cho π

Ví dụ: xét lại ví dụ về thời gian vận hành turbin, ta ước lượng

■ $\hat{\beta}_0 = -3.9236$

■ $\hat{\beta}_1 = 0.0010$

■ ma trận hiệp phương sai của ước lượng

$$\begin{pmatrix} 0.1429 & -4.0597 \times 10^{-5} \\ -4.0597 \times 10^{-5} & 1.3030 \times 10^{-8} \end{pmatrix}$$

Giả sử ta có thông tin một tổ hợp máy hoạt động liên tục trong 3500 giờ $\Rightarrow$
 $z = (1, 3500)$. Ta tính được

■ $\hat{\eta} = -0.4263$

■ $\hat{\pi} = 0.395$

■ $SE(\hat{\eta}) = 0.1353$

Suy ra, ta tính được khoảng tin cậy 95% cho η là

$$(-0.6915, -0.1611)$$

và do đó, khoảng tin cậy 95% cho π là


$$(0.3337, 0.4598)$$

Khoảng tin cậy cho π

Với số giờ hoạt động thay đổi từ 400 tới 4600 cm, ta ước lượng

- xác suất bị nứt turbin - đường nét liền màu đen,
- dải tin cậy 95% (confidence band) - đường nét đứt màu xanh, như trong hình.

như trong hình.



Kiểm định giả thuyết từng hệ số

Xét giả thuyết

$$\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$$

Nhắc lại rằng

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{v}_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1),$$

với $\hat{v}_{jj}$ là thành phần trên đường chéo của ma trận $(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1}$.

Dưới giả định H_0 , ta có

$$Z = \frac{\hat{\beta}_j}{\sqrt{\hat{v}_{jj}}} \sim \mathcal{N}(0, 1).$$

Từ đây, ta xác định được

$$p\text{-value} = 2(1 - \Phi(|z|)),$$

ta bác bỏ giả thuyết H_0 khi p -value nhỏ hơn một mức ý nghĩa α được xác định trước.

Kiểm định giả thuyết từng hệ số

Với ví dụ đang xét, ta có bảng kết quả tổng hợp sau:

	Estimate	Standard error	z-statistic	p-value
β_0 - Intercept	-3.9236	0.3780	-10.381	< 0.0001
β_1 - Giờ làm việc	0.0010	0.0001	8.754	< 0.0001

Như vậy, ta có một số nhận xét sau:

- Sau 500 giờ làm việc liên tục, khả năng turbine bị nứt tăng lên khoảng $\exp(500 \times 0.0010) = 1.648$ lần, hay khoảng 64.8%.
- Số giờ làm việc liên tục là cần thiết để dự đoán xác suất bị nứt của turbine, tại mức ý nghĩa 5%.
- Hệ số chặn có ý nghĩa thống kê tại mức 5%.

So sánh mô hình lồng nhau

Giả sử rằng, ta có hai mô hình hồi quy nhị thức A và B như sau:

$$\text{MH A: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_{q_A} X_{q_A}$$

$$\text{MH B: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_{q_A} X_{q_A} + \dots + \beta_{q_B} X_{q_B}$$

MH A là một trường hợp rút gọn của MH B, với số biến $p_A < p_B$.

Ta nói rằng MH A bị lồng vào (nested) MH B.

Lúc này, câu hỏi cần giải đáp là

“Mô hình A đơn giản hơn, liệu có đủ tốt để mô hình hóa dữ liệu?”

Câu hỏi này tương đương với giả thuyết

$$\begin{cases} H_0 : \beta_{q_A+1} = \beta_{q_A+2} = \dots = \beta_{q_B} = 0 \\ H_1 : \text{không phải } H_0 \end{cases}$$

So sánh mô hình lồng nhau

Từ hai mô hình, ta có hàm likelihood tương ứng là:

$$\text{MH A: } L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}),$$

$$\text{MH B: } L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1}, \dots, \hat{\beta}_{q_B}).$$

Nếu giả thuyết H_0 là đúng, thống kê log-likelihood ratio

$$W = -2 \log \left(\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1}, \dots, \hat{\beta}_{q_B})} \right) \sim \chi^2_{q_B - q_A}.$$

Giá trị p -value được định nghĩa bởi

$$p\text{-value} = \Pr(W > w),$$

với w được tính từ kết quả ước lượng mô hình.

Ta bác bỏ giả thuyết H_0 khi $p\text{-value} < \alpha$ (một mức ý nghĩa cho trước).

So sánh mô hình lồng nhau

Ví dụ: tiếp tục với dữ liệu vận hành turbine. Ta có hai mô hình như sau:

$$\text{MH A: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0$$

$$\text{MH B: } \log\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 X$$

Mô hình A có nghĩa là xác suất turbine bị nứt là hằng số, không phụ thuộc vào số giờ vận hành liên tục (X).

Kết quả phân tích cho kết quả

- $W \sim \chi_1^2$;
- $w = 102.34$;
- $p\text{-value} < 0.0001$

Như vậy, ta bác bỏ giả thuyết H_0 tại mức ý nghĩa 5%.

Vậy, số giờ hoạt động liên tục là có ý nghĩa trong mô hình dự đoán xác suất bị nứt của các turbines trong một tổ hợp máy.

Goodness-of-fit test

Với dữ liệu nhị thức, về mặt lý thuyết ta có n xác suất $\pi_1, \dots, \pi_n$.

Thông qua mô hình, ta có:

$$\pi_i = \frac{\exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})}{1 + \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi})},$$

với $i = 1, \dots, n$.

Giả sử, ta có n giá trị chính xác $\pi_{10}, \pi_{20}, \dots, \pi_{n0}$.

Nếu mô hình là hợp lý thì $\pi_i = \pi_{i0}$, với mọi $i = 1, 2, \dots, n$.

Điều này dẫn tới bài toán kiểm định giả thuyết:

$$H_0 : \pi_1 = \pi_{10}, \pi_2 = \pi_{20}, \dots, \pi_n = \pi_{n0}$$

Nếu kết quả kiểm định là bác bỏ giả thuyết H_0 , thì ta nói “mô hình không phù hợp với dữ liệu” (**lack of fit**).

Kiểm định giả thuyết H_0 tương đương với bài toán kiểm định nhiều tỷ lệ.

Goodness-of-fit test

Trong bài toán kiểm định n tỷ lệ, ta sử dụng thống kê χ^2 (Chi-bình phương):

$$\chi^2 = \sum_{i=1}^n \frac{(O_i - E_i)^2}{E_i}$$

trong đó,

- O_i là giá trị quan sát;
- E_i là giá trị kỳ vọng.

Đối với mô hình nhị thức, $Y_i \sim \mathcal{B}(m_i, \pi_i)$, ta xét hai trường hợp

- | | |
|-------------------------|-------------------------------|
| ■ phép thử thành công: | ■ phép thử thất bại: |
| $O_i = Y_i$ | $O_i = m_i - Y_i$ |
| $E_i = m_i \hat{\pi}_i$ | $E_i = m_i (1 - \hat{\pi}_i)$ |

Khi đó, thống kê χ^2 được xác định là

$$\chi^2 = \sum_{i=1}^n \frac{(Y_i - m_i \hat{\pi}_i)^2}{m_i \hat{\pi}_i (1 - \hat{\pi}_i)}.$$

Goodness-of-fit test

Ta chứng minh được rằng, dưới giả định H_0 :

$$\chi^2 = \sum_{i=1}^n \frac{(Y_i - m_i \hat{\pi}_i)^2}{m_i \hat{\pi}_i (1 - \hat{\pi}_i)} \xrightarrow{d} \chi_{n-p-1}^2,$$

trong đó, p là số biến hồi quy được dùng trong mô hình.

Thống kê χ^2 được gọi là χ^2 **thống kê Pearson (Pearson's χ^2 -statistic)**.

Giá trị p -value được định nghĩa bởi

$$p\text{-value} = \Pr(\chi^2 > w),$$

với w được tính từ kết quả ước lượng mô hình.

Ta bác bỏ giả thuyết H_0 khi $p\text{-value} < \alpha$ (một mức ý nghĩa cho trước).

Goodness-of-fit test

Ví dụ: tiếp tục với dữ liệu vận hành turbine. Ta có mô hình ước lượng:

$$\hat{\pi}_i = \frac{\exp(-3.9236 + 0.0010 \times \text{hours})}{1 + \exp(-3.9236 + 0.0010 \times \text{hours})}$$

Dữ liệu cung cấp:

- Y_i số lượng turbine bị vỡ;
- m_i số lượng turbine có trong một tổ hợp máy;
- số lượng tổ hợp máy được quan sát $n = 11$.

Ta tính được

$$w = \sum_{i=1}^{11} \frac{(Y_i - m_i \hat{\pi}_i)^2}{m_i \hat{\pi}_i (1 - \hat{\pi}_i)} = 9.2508$$

Bậc tự do $11 - 1 - 1 = 9$. Giá trị p -value là 0.5856.

↪ ta không bác bỏ giả thuyết H_0 , tức là mô hình dự đoán phù hợp với dữ liệu.

1 Đánh giá mô hình

2 Mô hình cho tỷ lệ

3 Chuẩn đoán mô hình

Chuẩn đoán mô hình

Chuẩn đoán mô hình bao gồm các công việc:

- sự độc lập của dữ liệu
- sự tuyến tính của mô hình
- sự đa cộng tuyến
- tác động của các giá trị ngoại lai

Các chuẩn đoán này xuất phát từ giả định khi ta xây dựng, ước lượng và thực hiện thống kê suy luận cho mô hình:

- Các quan sát là độc lập nhau.
- Tồn tại quan hệ tuyến tính giữa các biến hồi quy và trung bình của biến phản hồi.
- Các biến hồi quy là độc lập nhau.
- Các giá trị ngoại lai ít xuất hiện.

Phân tích thặng dư

Phân tích thặng dư mô hình giúp ta đưa ra các nhận định:

- tính tuyến tính của mô hình;
- tính tuyến tính của từng biến hồi quy với trung bình của biến phản hồi;
- có sự xuất hiện của giá trị ngoại lai.

Đối với mô hình hồi quy logistic (nhị phân và nhị thức), ta có các loại thặng dư sau:

- thặng dư thô (raw residuals)

$$e_i = Y_i - m_i \hat{\pi}_i,$$

- thặng dư deviance (deviance residuals)

$$d_i = \text{sign}(Y_i - m_i \hat{\pi}_i) \sqrt{2 \left\{ Y_i \log \left(\frac{Y_i}{m_i \hat{\pi}_i} \right) + (m_i - Y_i) \log \left(\frac{m_i - Y_i}{m_i - m_i \hat{\pi}_i} \right) \right\}},$$

- thặng dư Pearson (Pearson's residuals)

$$p_i = \frac{Y_i - m_i \hat{\pi}_i}{\sqrt{m_i \hat{\pi}_i (1 - \hat{\pi}_i)}}.$$

Phân tích thặng dư mô hình nhị phân

Khi biến Y_i là nhị phân thì $m_i = 1$, do đó, ta có

- thặng dư thô (raw residuals)

$$e_i = Y_i - \hat{\pi}_i,$$

- thặng dư deviance (deviance residuals)

$$d_i = \text{sign}(Y_i - \hat{\pi}_i) \sqrt{2 \left\{ Y_i \log \left(\frac{Y_i}{\hat{\pi}_i} \right) + (1 - Y_i) \log \left(\frac{1 - Y_i}{1 - \hat{\pi}_i} \right) \right\}},$$

- thặng dư Pearson (Pearson's residuals)


$$p_i = \frac{Y_i - \hat{\pi}_i}{\sqrt{\hat{\pi}_i(1 - \hat{\pi}_i)}}.$$

Do $Y_i = 0$ hoặc 1, nên đồ thị của thặng dư sẽ bị tách thành hai phần.

Phân tích thặng dư mô hình nhị phân

Ví dụ: xét mô hình logistic dự đoán khả năng di căn của tế bào ung thư thực quản:

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 \times \text{tumor_size}$$



Phân tích thặng dư mô hình nhị phân

Đồ thị thặng dư của mô hình logistic nhị phân bị chia thành 2 phần.

↪ không thực sự hữu dụng để đưa ra nhận xét.



Thay vào đó, ta dùng biểu đồ thặng dư khoảng:

- chia vùng giá trị của biến hồi quy X thành các khoảng (bins);
- tính giá trị trung bình của thặng dư trong từng khoảng;
- tính giá trị trung bình của X trong từng khoảng.

Ta biểu diễn giá trị của


- trung bình của X trong các khoảng tại trục x ;
- trung bình của thặng dư trong các khoảng tại trục y .

Phân tích thặng dư mô hình nhị phân



- X được chia theo các khoảng dựa vào phân vị.
- Hình bên trái biểu diễn thặng dư deviance.
- Hình bên phải biểu diễn thặng dư deviance sau khi chia khoảng của X.

Phân tích thặng dư mô hình nhị phân





- Các điểm thặng dư không còn bị phân thành 2 đường.
- Tuy nhiên, số lượng điểm là khá ít, nên nhận xét cũng không khó nhận xét về xu hướng của thặng dư.

Phân tích thặng dư mô hình nhị phân

Ví dụ: phân tích thặng dư cho mô hình dự đoán xác suất bị bệnh tim mạch vành thông qua chiều cao và số lượng thuốc lá hút trong ngày:

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 \times \text{heights} + \beta_2 \times \text{cigs}$$



Phân tích thặng dư mô hình nhị phân


- Hình bên trái biểu diễn thặng dư deviance theo giá trị của thành phần tuyến tính.
- Hình bên phải biểu diễn thặng dư deviance sau khi chia khoảng của thành phần tuyến tính.

Nhận xét:


- Phần thặng dư không bị ràng buộc ở phải có trung bình bằng 0 nên mức trung bình trong biểu đồ không được quan tâm.
- Ta thấy một sự thay đổi đồng đều của thặng dư khi thành phần tuyến tính thay đổi nên biểu đồ này cho thấy không có sự thiếu sót trong mô hình: tính tuyến tính là hợp lý.
- Các giá trị thặng dư là nhỏ, và không có giá trị nào vượt quá ± 3 , nên không có giá trị ngoại lai.

Phân tích thặng dư mô hình nhị thức

- Thặng dư deviance và Pearson thường được dùng phổ biến trong phân tích thặng dư của mô hình nhị thức.
- Biểu đồ thặng dư của mô hình nhị thức không bị phân thành hai phần.
- Nếu phần thặng dư được phân bố ngẫu nhiên (khá đối xứng) xung quanh đường nằm ngang tương ứng với phần thặng dư = 0.
→ tính tuyến tính được thỏa mãn. (xem Hình a)
- Sự hiện diện của một xu hướng nào đó (một loại độ cong nào đó) có thể chỉ ra vấn đề với một số khía cạnh của mô hình tuyến tính.
→ tính tuyến tính không được thỏa mãn. (xem Hình b)



(a)




(b)

Phân tích thặng dư mô hình nhị thức

Ví dụ: xét mô hình ước lượng xác suất turbine bị nứt sau một thời gian làm việc liên tục:

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 \times \text{Hours}$$



Biểu đồ cho thấy tính tuyến tính là được thỏa mãn $\Rightarrow$ mô hình hợp lý.



Thặng dư từng phần

- Thặng dư từng phần rất hữu ích cho việc đánh giá tính tuyến tính của từng biến hồi quy trong mô hình đa biến.
- Nếu tính tuyến tính của một biến là không hợp lý
 $\hookrightarrow$ ta cần sử dụng biến đổi cho biến đó ($x^2, \log(x), \sqrt{x}$)
- Đối với quan sát thứ i , thặng dư từng phần của biến hồi quy thứ j là

$$r_{ij} = X_{ji}\hat{\beta}_j + \frac{Y_i - m_i\hat{\pi}_i}{m_i\hat{\pi}_i(1 - \hat{\pi}_i)}$$

- Đối với trường hợp biến nhị phân, ta cần áp dụng thặng dư khoảng cho thặng dư từng phần.

Thặng dư từng phần



- Đối với biến `height`, hầu hết các điểm thặng dư đều ủng hộ cho tính tuyến tính của mô hình.
- Đối với biến `cigs`, các điểm có giá trị thặng dư lớn, là những điểm có số lượng quan sát ít, do đó, ảnh hưởng tới ước lượng của mô hình là không đáng kể.

Hiệu ứng của giá trị ngoại lai

Ta định nghĩa ma trận $\mathbf{H}$ như sau:

$$\mathbf{H} = \hat{\mathbf{V}}^{1/2} \mathbf{Z} \left(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z} \right)^{-1} \mathbf{Z}^\top \hat{\mathbf{V}}^{1/2},$$

khi đó giá trị h_{ii} trên đường chéo của $\mathbf{H}$ được gọi là giá trị đòn bẩy (leverage):

- giá trị h_{ii} lớn gần 1, thì Y_i có ảnh hưởng lớn tới $\hat{\pi}_i$.
- giá trị h_{ii} nhỏ gần 0, thì $\hat{\pi}_i$ là được dựa trên đóng góp của nhiều quan sát, và Y_i không có ảnh hưởng lớn tới $\hat{\pi}_i$.

Như vậy, những điểm Y_i có giá trị đòn bẩy h_{ii} lớn, thì được coi là những điểm ảnh hưởng tới mô hình (influential observations).

Hiệu ứng của giá trị ngoại lai

Dựa vào thặng dư Pearson và giá trị đòn bẩy h_{ii} , ta định nghĩa thặng dư chuẩn hóa (standardized residuals):

$$r_i = \frac{p_i}{\sqrt{1 - h_{ii}}} = \frac{Y_i - m_i \hat{\pi}_i}{\sqrt{m_i \hat{\pi}_i (1 - \hat{\pi}_i) (1 - h_{ii})}}.$$

- Với phân phối nhị thức, thặng dư chuẩn hóa sẽ xấp xỉ phân phối $\mathcal{N}(0, 1)$ khi mô hình đúng, và m_i lớn.
- Giá trị tuyệt đối, $|r_i|$ vượt quá 2 hoặc 3, thì điểm Y_i tương ứng là điểm ảnh hưởng tới mô hình (influential observations).
- Khi có nhiều điểm $|r_i|$ vượt quá 2 hoặc 3, mô hình hiện tại là không phù hợp với dữ liệu.

Hiệu ứng của giá trị ngoại lai

Để phát hiện giá trị ngoại lai trong mô hình, ta có thể dùng khoảng cách Cook (Cook's distance):


$$D_i = r_i^2 \frac{h_{ii}}{(p+1)(1-h_{ii})}.$$

- Những quan sát có giá trị khoảng cách Cook, D_i , lớn (thường là lớn hơn 0.5 - 1), là những điểm ngoại lai hoặc cực kỳ ngoại lai.
- Nếu những điểm đó là tương ứng với các giá trị lớn của r_i và h_{ii}
 - ↪ những quan sát đó là các điểm ngoại lai có ảnh hưởng lớn trong mô hình.
 - ↪ kết quả hồi quy sẽ bị thay đổi nếu chúng ta loại trừ những quan sát này.


Ta có thể tích hợp khoảng cách Cook vào trong biểu đồ của thặng dư chính hóa và giá trị đòn bẩy, trong đó, khoảng cách Cook biểu thị kích cỡ của các điểm quan sát:

- điểm có kích cỡ nhỏ tương ứng khoảng cách Cook nhỏ;
- điểm có kích cỡ lớn tương ứng khoảng cách Cook lớn.

Hiệu ứng của giá trị ngoại lai



(a)



(b)

- Hình (a) - mô hình tiên đoán xác suất tế bào ung thư di căn.
- Hình (b) - mô hình tiên đoán tỷ lệ turbine bị nứt.