

Bài giảng 7: Hồi quy cho dữ liệu đếm

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Mô Hình Thống Kê Tuyến Tính Nâng Cao

Mục lục

1 *Giới thiệu*

2 *Mô hình hồi quy Poisson*

3 *Ước lượng hệ số mô hình*

4 *Thống kê suy luận cho mô hình*

1 *Giới thiệu*

2 *Mô hình hồi quy Poisson*

3 *Ước lượng hệ số mô hình*

4 *Thống kê suy luận cho mô hình*

Biến số đếm - Count variable

Biến phản hồi dạng số đếm

Xét biến định lượng Y miêu tả số lần một sự kiện A xuất hiện ngẫu nhiên trong

- một khung thời gian;
- một địa điểm/khu vực;
- một nhóm quần thể đối tượng;

với một tỷ lệ cụ thể.

Khi đó, Y cho kết quả là số đếm: 0, 1, 2, 3, ...

Ví dụ:

- Y là lượng thuê xe đạp trong 24h (1 ngày) tại một thành phố;
- Y là số lượng loài cây trong một hòn đảo;
- Y là số lượng khách hàng mua sản phẩm tại một cửa hàng trong một ngày;
- Y là số lượng người bị chết vì một căn bệnh tại một thành phố trong 1 năm.

Mô hình tuyến tính cho biến số đếm

Ví dụ 1: Quần đảo Galápagos là một nhóm gồm khoảng 30 đảo nằm ở Thái Bình Dương, cách bờ biển Ecuador khoảng 900km. Trên đảo có những loài động thực vật đặc hữu, không tồn tại ở những nơi khác. Những loài này có những đặc biệt tiến hóa khác thường, và là nguồn gốc ý tưởng cho nghiên cứu về thuyết tiến hóa của Darwin.

Năm 1973 một nghiên cứu thu thập về các loài thực vật tồn tại trên 30 đảo thuộc quần đảo Galápagos được thực hiện bởi M. P. Johnson và P. H. Raven.¹

Islands	species	endemics	area	elevation	nearest	scrub	adjacent
Baltra	58	23	25.09	346	0.6	0.6	1.84
Bartolome	31	21	1.24	109	0.6	26.3	572.33
Caldwell	3	3	0.21	114	2.8	58.7	0.78
Champion	25	9	0.10	46	1.9	47.4	0.18
Coamo	2	1	0.05	77	1.9	1.9	903.82
Daphne Major	18	11	0.34	119	8.0	8.0	1.84
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

¹<https://www.science.org/doi/abs/10.1126/science.179.4076.893>

Mô hình tuyến tính cho biến số đếm

Các biến được thu thập trong dữ liệu:

- **species**: số loài thực vật trên đảo
- **endemics**: số loài đặc hữu trên đảo
- **area**: diện tích của đảo (đơn vị: km^2)
- **elevation**: độ cao cao nhất của đảo (đơn vị: m)
- **nearest**: khoảng cách tới đảo gần nhất (đơn vị: km)
- **scruc**: khoảng cách tới đảo chính Santa Cruz (đơn vị: km)
- **adjacent**: diện tích của đảo gần kề (đơn vị: km^2)



Câu hỏi nghiên cứu được quan tâm:

“Mối quan hệ giữa số lượng loài thực vật và một số biến số địa lý.”

Khi đó, mô hình hồi quy tuyến tính có thể là

$$\begin{aligned}\text{species} = & \beta_0 + \beta_1 \times \text{area} + \beta_2 \times \text{elevation} + \beta_3 \times \text{nearest} \\ & + \beta_4 \times \text{scruc} + \beta_5 \times \text{adjacent} + \varepsilon\end{aligned}$$

Mô hình tuyến tính cho biến số đếm



Ta nhận thấy rằng:

- giá trị tiên đoán của số lượng < 0 ;
- biểu đồ Residuals vs. Fitted cho thấy xu hướng hình phiễu $\Rightarrow$ phương sai không đồng nhất.

1 *Giới thiệu*

2 *Mô hình hồi quy Poisson*

3 *Ước lượng hệ số mô hình*

4 *Thống kê suy luận cho mô hình*

Phân phối Poisson và mô hình Poisson

Ở phần trước, ta thấy rằng việc sử dụng mô hình hồi quy tuyến tính cho biến đếm là không phù hợp.

Nhắc lại rằng Y là số lần một sự kiện xuất hiện ngẫu nhiên trong một

- khoảng thời gian
- không gian

với một tỷ lệ cụ thể.

⇒ Y có thể là kết quả của một quá trình Poisson (Poisson process).

⇒ Y là biến ngẫu nhiên Poisson, $\mathcal{P}(\lambda)$, với $\lambda > 0$,

$$\Pr(Y = y) = \frac{\lambda^y \exp(-\lambda)}{y!},$$

và $\mathbb{E}(Y) = \mathbb{V}\text{ar}(Y) = \lambda$.

Phân phối Poisson và mô hình Poisson

Ví dụ: xét bộ dữ liệu về số loài thực vật trên đảo Galápagos.

- Các loài thực vật trên đảo xuất hiện và biến mất liên tục theo thời gian.
- Số lượng loài thực vật trên đảo xuất hiện ngẫu nhiên.
- Y là số lượng loài cây trên đảo được quan sát vào 1973
 $\Rightarrow Y \sim \mathcal{P}(\lambda)$.

Nhắc lại câu hỏi nghiên cứu:

“Số lượng loài thực vật có thay đổi theo một số biến số địa lý hay không??”

Nếu số lượng loài thực vật là thay đổi theo một số biến số địa lý X

$\hookrightarrow$ trung bình λ sẽ thay đổi theo thông tin của X .

Khi đó, ta có thể mô hình hóa trung bình số lượng loài cây theo X :

$$\mathbb{E}(Y|X) = \lambda(X)$$

tức là kỳ vọng điều kiện của Y khi biết X .

Nhắc lại: nếu X và Y là độc lập thì $\mathbb{E}(Y|X) = \mathbb{E}(Y) = \lambda$.

Phân phối Poisson và mô hình Poisson

Ta có nhiều lựa chọn dạng hàm cho $\lambda(X)$, tuy nhiên, lựa chọn hàm tuyến tính là đơn giản nhất:

$$\lambda(X) = \beta_0 + \beta_1 X.$$

Nhưng, hàm này cho giá trị không thuộc $(0, +\infty)$.


Ta cần một phép biến đổi từ $\mathbb{R}$ vào trong $(0, +\infty)$.

- hàm chỉ

$$\mathbb{I}(x) = \begin{cases} 0, & \text{nếu } x \leq 0 \\ x, & \text{nếu } 0 < x \end{cases}$$

- hàm bình phương x^2 ;
- hàm mũ $\exp(x)$.

Phân phối Poisson và mô hình Poisson



- Hàm chỉ $\mathbb{I}(x)$ là hàm không trơn, do đó, không tồn tại đạo hàm tại mọi x .
- Hàm $\exp(\cdot)$ và hàm bình phương là các hàm trơn, liên tục tại mọi x .

Phân phối Poisson và mô hình Poisson

Nếu ta lựa chọn

- hàm mũ, thì

$$\mathbb{E}(Y|X) = \lambda(X) = \exp(\beta_0 + \beta_1 X)$$

khi đó, ta có mô hình **Poisson log-linear**. Hơn nữa, sử dụng biến đổi ta được

$$\log(\lambda(X)) = \beta_0 + \beta_1 X;$$

- hàm bình phương, thì

$$\mathbb{E}(Y|X) = \lambda(X) = (\beta_0 + \beta_1 X)^2$$

khi đó, ta có mô hình **Poisson squared**. Hơn nữa, sử dụng biến đổi ta được

$$\sqrt{\lambda(X)} = \beta_0 + \beta_1 X.$$

Như vậy: mô hình Poisson log-linear và mô hình Poisson squared là hai mô hình hồi quy tham số được dùng để tiên đoán trung bình của một biến số đếm.

Trong áp dụng, mô hình Poisson log-linear được dùng phổ biến.

Mô hình Poisson log-linear

Giả sử ta có bộ dữ liệu ngẫu nhiên $(Y_i, X_{1i}, X_{2i}, \dots, X_{qi})$, với $i = 1, \dots, n$, trong đó:

- các quan sát thứ i là độc lập;
- Y_i là biến phản hồi dạng số đếm (Poisson), nhận giá trị $0, 1, 2, \dots$; với kỳ vọng $\mathbb{E}(Y_i) = \lambda_i$;
- $X_{1i}, \dots, X_{qi}$ là các biến giải thích có thể liên quan tới Y_i .

Mô hình tiên đoán trung bình của Y_i khi biết $X_{1i}, X_{2i}, \dots, X_{qi}$:

$$\mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi}) = \exp(\beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi}),$$

được gọi là mô hình **Poisson log-linear**. Mô hình này tương đương với,

$$\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

với $\mu_i = \mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi})$.

Mô hình Poisson log-linear

Một số dạng mô hình Poisson log-linear thường gặp, giả sử với $q = 2$:

- $\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i}$;
- $\log(\mu_i) = \beta_0 + \beta_1 g(X_{1i}) + \beta_2 X_{2i}$, với $g(\cdot)$ là một hàm thực;
- $\log(\mu_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} X_{2i}$, trong đó thành phần $X_{1i} X_{2i}$ đại diện cho sự tương tác của X_1 và X_2 .

Trong một số trường hợp, giá trị đếm Y_i là tỷ lệ với một chỉ số t_i , với

- t_i là một lượng thời gian;
- t_i là kích cỡ quần thể;
- t_i là diện tích một khu vực không gian.

Khi đó, tỷ lệ mẫu Y_i/t_i tương ứng với kỳ vọng λ_i/t_i . Điều này dẫn tới mô hình

$$\log\left(\frac{\mu_i}{t_i}\right) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

hay tương đương,

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

thành phần $\log(t_i)$ được gọi là **offset**.

Diễn giải mô hình

Xét mô hình tổng quát (có thành phần offset):

$$\mathbb{E}(Y|X_1, \dots, X_q) = \mu = \exp(\log(t) + \beta_0 + \beta_1 X_1 + \dots + \beta_q X_q).$$

Khảo sát đạo hàm tại điểm X_j , ta có

$$\frac{\partial \mu}{\partial X_j} = \beta_j \mu.$$

Trường hợp $q = 1$:

- nếu $\beta > 0$, đường cong của μ là một đường đơn điệu tăng khi X từ $-\infty$ tới ∞ , nằm trong giới hạn là $(0, +\infty)$;
- nếu $\beta < 0$, đường cong của μ là một đường đơn điệu giảm, khi X từ $-\infty$ tới ∞ , nằm trong giới hạn là $(0, +\infty)$.

Trong trường hợp $q > 1$:

- μ là hàm đơn điệu theo từng biến X_j tương ứng theo dấu của hệ số β_j ;
- tốc độ thay đổi của μ , tăng hoặc giảm, là $|\beta_j|$.

Diễn giải mô hình

Theo thiết lập mô hình, ta có

$$\log(\mu) = \log(t) + \beta_0 + \beta_1 X_1 + \dots + \beta_q X_q.$$

Từ dạng biểu diễn tuyến tính này, ta có quy tắc sau:

- nếu $\beta_j > 0$, thì khi giá trị X_j tăng một đơn vị thì $\log(\mu)$ tăng β_j đơn vị;
 - nếu $\beta_j < 0$, thì khi giá trị X_j tăng một đơn vị thì $\log(\mu)$ giảm $|\beta_j|$ đơn vị,
- khi các biến khác, $X_k, k \neq j$ được giữ là hằng số.

Quy tắc này cũng tương đương với

- nếu $\beta_j > 0$, thì khi giá trị X_j tăng một đơn vị thì μ tăng $\exp(\beta_j)$ lần;
 - nếu $\beta_j < 0$, thì khi giá trị X_j tăng một đơn vị thì μ giảm $\exp(\beta_j)$ lần,
- khi các biến khác, $X_k, k \neq j$ được giữ là hằng số.

1 *Giới thiệu*

2 *Mô hình hồi quy Poisson*

3 *Ước lượng hệ số mô hình*

4 *Thống kê suy luận cho mô hình*

Ước lượng mô hình

Xét mô hình hồi quy Poisson log-linear:

$$\mu_i = \exp(\log(t_i) + \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi}),$$

với $\mu_i = \mathbb{E}(Y_i | X_{1i}, X_{2i}, \dots, X_{qi})$.

Ta cần ước lượng các tham số β_j với $j = 0, 1, \dots, q$.

Theo các thiết lập mô hình, ta có $Y_i | X_{1i}, X_{2i}, \dots, X_{qi} \sim \mathcal{P}(\mu_i)$, tức là $X_{1i}, X_{2i}, \dots, X_{qi}$ được coi như cố định.

Do đó, ta xây dựng được hàm hợp lý:

$$L(\beta_0, \beta_1, \dots, \beta_q) = \prod_{i=1}^n \mu_i^{Y_i} \exp(-\mu_i) \frac{1}{Y_i!}.$$

Ước lượng mô hình

Từ đây ta suy ra được hàm log-likelihood:

$$\begin{aligned}\ell(\beta_0, \beta_1, \dots, \beta_q) &= \sum_{i=1}^n \left\{ Y_i \left(\log(t_i) + \beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) \right. \\ &\quad \left. - \exp \left(\log(t_i) + \beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) \right\}.\end{aligned}$$

Ta có hàm score cho từng tham số β_j là:

$$\begin{aligned}U(\beta_0) &= \sum_{i=1}^n \left\{ Y_i - \exp \left(\log(t_i) + \beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) \right\} \\ U(\beta_j) &= \sum_{i=1}^n X_{ji} \left\{ Y_i - \exp \left(\log(t_i) + \beta_0 + \sum_{j=1}^q \beta_j X_{ji} \right) \right\}\end{aligned}$$

Bằng cách đặt $Z_i = (1, X_{1i}, \dots, X_{qi})^\top$, ta có

$$U(\beta) = \sum_{i=1}^n Z_i \{Y_i - \mu_i\}$$

Ước lượng mô hình

Từ công thức của $U(\beta)$, ta tính được ma trận thông tin Fisher:

$$\mathcal{I}(\beta) = \sum_{i=1}^n Z_i Z_i^\top \mu_i.$$

Đặt

$$\mathbf{Z} = \begin{pmatrix} 1 & X_{11} & \dots & X_{q1} \\ 1 & X_{12} & \dots & X_{q2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \dots & X_{qn} \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix}$$
$$\mathbf{V} = \begin{pmatrix} \mu_1 & 0 & \dots & 0 \\ 0 & \mu_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \mu_n \end{pmatrix}$$

Khi này, ta có

$$U(\beta) = \mathbf{Z}^\top (\mathbf{Y} - \boldsymbol{\mu}), \quad \mathcal{I}(\beta) = \mathbf{Z}^\top \mathbf{V} \mathbf{Z}.$$

Ước lượng mô hình

Áp dụng thuật toán Fisher scoring, ta có

$$\hat{\beta} = \beta^{\dagger} + \mathcal{I}^{-1}(\beta^{\dagger}) U(\beta^{\dagger}),$$

hay tương đương với

$$\hat{\beta} = \beta^{\dagger} + (\mathbf{Z}^{\top} \mathbf{V}^{\dagger} \mathbf{Z})^{-1} \mathbf{Z}^{\top} (\mathbf{Y} - \boldsymbol{\mu}^{\dagger}).$$

Từ đây, ta có thuật toán ước lượng như sau:

- 1 Chọn một giá trị bắt đầu $\beta^{(0)}$
- 2 Với bước lặp $t = 0$, ta tính

$$\beta^{(t+1)} = \beta^{(t)} + (\mathbf{Z}^{\top} \mathbf{V}^{(t)} \mathbf{Z})^{-1} \mathbf{Z}^{\top} (\mathbf{Y} - \boldsymbol{\mu}^{(t)}),$$

- 3 Đặt $t = t + 1$, lặp lại bước 2 cho tới khi nào thuật toán hội tụ, có thể là

$$\|\beta^{(t+1)} - \beta^{(t)}\| < \varepsilon.$$

- 4 ước lượng hợp lý cực đại $\hat{\beta} = \beta^{(t+1)}$.

Tính tiệm cận của ước lượng

Ta chứng minh được rằng

- $\hat{\beta}$ là ước lượng vững của β tức là $\hat{\beta} \xrightarrow{P} \beta_0$, khi $n \rightarrow \infty$.
- Ước lượng $\hat{\beta}$ là xấp xỉ phân phối chuẩn $(q+1)$ -chiều với vectơ trung bình là β_0 và ma trận hiệp phương sai $\mathcal{I}^{-1}(\beta_0)$, tức là

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1}(\beta_0, \mathcal{I}^{-1}(\beta_0)),$$

khi $n \rightarrow +\infty$.

- Ước lượng ma trận hiệp phương sai của $\hat{\beta}$ là

$$\widehat{\text{Var}}(\hat{\beta}) = \mathcal{I}^{-1}(\hat{\beta}).$$

- Theo tính chất của phân phối chuẩn nhiều chiều, ta có kết quả

$$\hat{\beta}_j \xrightarrow{d} \mathcal{N}(\beta_{j0}, v_{jj}),$$

với v_{jj} là thành phần thứ j trên đường chéo của ma trận $\mathcal{I}^{-1}(\beta_0)$.

Tính tiệm cận của ước lượng

Đặt $\eta = \mathbf{z}^\top \beta$, với $\mathbf{z} = (1, x_1, \dots, x_q)$, giá trị cho trước của $X_1, \dots, X_q$.

Dễ thấy η là hàm liên tục của β , từ $\mathbb{R}^{q+1} \mapsto \mathbb{R}$.

Từ kết quả

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1}(\beta_0, \mathcal{I}^{-1}(\beta_0)),$$

khi $n \rightarrow +\infty$, áp dụng Delta method, ta có

$$\hat{\eta} \xrightarrow{d} \mathcal{N}(\eta_0, \mathbf{z}^\top \mathcal{I}^{-1}(\beta_0) \mathbf{z}),$$

và ước lượng phương sai của $\hat{\eta}$ là

$$\widehat{\text{Var}}(\hat{\eta}) = \mathbf{z}^\top \mathcal{I}^{-1}(\hat{\beta}) \mathbf{z}.$$

Ví dụ: số lượng loài thực vật trên quần đảo Galápagos

Xét lại ví dụ về dữ liệu số lượng loài thực vật trên quần đảo Galápagos:

- $n = 30$ quan sát (số lượng đảo);
- biến phản hồi là số lượng loài thực vật: $Y_i = 0, 1, 2, \dots$
- biến giải thích $X_{1i}, X_{2i}, X_{3i}, X_{4i}, X_{5i}$ là các biến phản hồi:

$$X_{1i} = \text{area}_i$$

$$X_{2i} = \text{elevation}_i$$

$$X_{3i} = \text{nearest}_i$$

$$X_{4i} = \text{scruz}_i$$

$$X_{5i} = \text{adjacent}_i$$

Câu hỏi nghiên cứu: dự đoán trung bình số lượng loài thực vật của một đảo dựa trên thông tin địa lý của đảo đó.

Mô hình Poisson log-linear:

$$\mathbb{E}(Y_i | X_{1i}, X_{2i}, X_{3i}, X_{4i}, X_{5i}) = \mu_i = \exp \left(\beta_0 + \sum_{k=1}^5 \beta_k X_{ki} \right)$$

Ví dụ: số lượng loài thực vật trên quần đảo Galápagos

Kết quả ước lượng mô hình

	Estimate	Std. Error
(Intercept)	3.155	5.175×10^{-2}
area	-5.799×10^{-4}	2.627×10^{-5}
elevation	3.541×10^{-3}	8.741×10^{-5}
nearest	8.826×10^{-3}	1.821×10^{-3}
scruz	-5.709×10^{-3}	6.256×10^{-4}
adjacent	-6.630×10^{-4}	2.933×10^{-5}

Ví dụ: số lượng loài thực vật trên quần đảo Galápagos

- trung bình số lượng loài thực vật giảm dần khi diện tích của đảo - area tăng lên (một kết luận có vẻ lạ lùng!);
- trung bình số lượng loài thực vật tăng lên khi chiều cao của đảo - elevation tăng lên (tức là thực vật phát triển theo chiều cao);
- khi diện tích của đảo - area tăng 10 km^2 , thì số lượng loài thực vật sẽ giảm đi $\exp(-5.799 \times 10^{-4} \times 10) = 0.9942$ lần, hay 0.58%;
- khi chiều cao tối đa của đảo - elevation tăng lên 50m, thì số lượng loài thực vật trên đảo đó sẽ cao gấp $\exp(3.541 \times 10^{-3} \times 50) = 1.1937$ lần, hay tương đương với 19.37%.

Ví dụ 2: Bức xạ gamma và lượng nhiễm sắc thể đột biến

Bức xạ gamma có thể gây đột biến ở nhiễm sắc thể của sinh vật sống.

Vào năm 1976, Purott R. và Reeder E.¹ thực hiện một nghiên cứu về sự ảnh hưởng của nồng độ của bức xạ gamma tới số lượng đột biến ở nhiễm sắc thể trên tổng số tế bào.

id	cells	ca	doseamt	doserate
1	478	25	1	0.10
2	1907	102	1	0.25
3	2258	149	1	0.50
4	2329	160	1	1.00
5	1238	75	1	1.50
6	1491	100	1	2.00
⋮	⋮	⋮	⋮	⋮

¹[https://doi.org/10.1016/0027-5107\(76\)90206-2](https://doi.org/10.1016/0027-5107(76)90206-2)

Ví dụ 2: Bức xạ gamma và lượng nhiễm sắc thể đột biến

Các biến được thu thập trong dữ liệu:

- cells: số lượng tế bào (đơn vị: ngàn)
- ca: số lượng nhiễm sắc thể bị đột biến (đơn vị: cái)
- doseamt: lượng liều trong Grays
- doserate: tỷ lệ liều tính bằng Grays/giờ


Câu hỏi nghiên cứu được quan tâm:

“Trung bình số lượng nhiễm sắc thể bị đột biến trong tế bào có bị thay đổi theo nồng độ và tỷ lệ liều theo giờ?”

Nhân thấy rằng:

- biến phản hồi Y là số lượng nhiễm sắc thể bị đột biến - ca; được quan sát trong thời gian thực hiện thí nghiệm; được đếm trong nhiều tế bào của một đối tượng;
- biến cells là số lượng tế bào (chứa các tế bào) của một đối tượng.

Ví dụ 2: Bức xạ gamma và lượng nhiễm sắc thể đột biến



Ví dụ 2: Bức xạ gamma và lượng nhiễm sắc thể đột biến

Khi đó, mô hình Poisson log-linear có thể là

$$\begin{aligned}\log(\mu_i) = & \log(\text{cells}_i) + \beta_0 + \beta_1 \times \text{doseamt}_i + \beta_2 \times \text{doserate}_i \\ & + \beta_3 \times \text{doserate}_i : \text{doseamt}_i\end{aligned}$$

Kết quả ước lượng mô hình

	Estimate	Std. Error
(Intercept)	-2.1875	0.0563
doseamt2.5	1.4426	0.0829
doseamt5	2.4996	0.0426
doserate	0.0482	0.0281
doseamt2.5:doserate	0.1156	0.0389
doseamt5:doserate	0.1557	0.0343

1 *Giới thiệu*

2 *Mô hình hồi quy Poisson*

3 *Ước lượng hệ số mô hình*

4 *Thống kê suy luận cho mô hình*

Khoảng tin cậy cho từng hệ số

Từ kết quả xấp xỉ tiệm cận phân phối chuẩn của ước lượng hệ số

$$\hat{\beta} \xrightarrow{d} \mathcal{N}_{q+1} \left(\beta_0, (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \right),$$

khi $n \rightarrow +\infty$, ta có

$$\frac{\hat{\beta}_j - \beta_{0j}}{\sqrt{v_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1),$$

với v_{jj} là thành phần trên đường chéo của ma trận $(\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1}$. Kết quả này có được do tính chất của phân phối chuẩn nhiều chiều.

Thay thế $\mathbf{V}_0$ bởi $\hat{\mathbf{V}}$, và β_0 bằng β (tổng quát), ta được

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{v}_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Từ đây, ta có khoảng tin cậy cho β_j là

$$\left(\hat{\beta}_j - z_{1-\alpha/2} \sqrt{\hat{v}_{jj}}, \hat{\beta}_j + z_{1-\alpha/2} \sqrt{\hat{v}_{jj}} \right)$$

Khoảng tin cậy cho từng hệ số

Khi ta thực hiện lấy $\exp(\cdot)$ cho hai điểm giới hạn, ta thu được khoảng tin cậy cho mức tăng/giảm của trung bình khi biến X_j tăng/giảm một đơn vị:

$$\left(\exp \left(\hat{\beta}_j - z_{1-\alpha/2} \sqrt{\hat{v}_{jj}} \right), \exp \left(\hat{\beta}_j + z_{1-\alpha/2} \sqrt{\hat{v}_{jj}} \right) \right)$$

Ví dụ: xét lại ví dụ về số lượng loài thực vật tại quần đảo Galápagos, khoảng tin cậy 95% cho hệ số và mức tăng/giảm lần lượt là

	KTC cho β	KTC cho mức tăng/giảm
area	(−0.0006, −0.0005)	(0.9994, 0.9995)
elevation	(0.0034, 0.0037)	(1.0034, 1.0037)
nearest	(0.0053, 0.0124)	(1.0053, 1.0125)
scruz	(−0.0069, −0.0044)	(0.9931, 0.9955)
adjacent	(−0.0007, −0.0006)	(0.9993, 0.9994)

Khoảng tin cậy cho μ

Giả sử ta có bộ giá trị $\mathbf{z} = (1, x_1, \dots, x_q)$, lúc này ta tính được

$$\hat{\eta} = \mathbf{z}^\top \hat{\beta}$$

và ta tính được trung bình

$$\hat{\mu} = \hat{\mathbb{E}}(Y | X_1 = x_1, \dots, X_q = x_q) = \exp(\hat{\eta}).$$

Trung bình này là ước lượng của kỳ vọng điều kiện

$$\mu = \mathbb{E}(Y | X_1 = x_1, \dots, X_q = x_q) = \exp(\eta),$$

với $\eta = \mathbf{z}^\top \beta$.

Ta mong muốn xác định khoảng tin cậy cho μ .

Khoảng tin cậy cho μ

Từ kết quả Delta method, ta có

$$\hat{\eta} \xrightarrow{d} \mathcal{N} \left(\eta_0, \mathbf{z}^\top (\mathbf{Z}^\top \mathbf{V}_0 \mathbf{Z})^{-1} \mathbf{z} \right),$$

Từ đây, ta suy ra rằng

$$\frac{\hat{\eta} - \eta}{\sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Do đó, ta xây dựng được khoảng tin cậy cho η

$$(\eta_L, \eta_U) = \left(\hat{\eta} - z_{1-\alpha/2} \sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}}, \hat{\eta} + z_{1-\alpha/2} \sqrt{\mathbf{z}^\top (\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1} \mathbf{z}} \right).$$

Áp dụng công thức tính μ theo η , cho hai điểm giới hạn, ta thu được khoảng tin cậy cho μ :

$$(\mu_L, \mu_U) = (\exp(\eta_L), \exp(\eta_U)).$$

Khoảng tin cậy cho μ

Ví dụ: ta muốn ước tính trung bình và khoảng tin cậy cho trung bình số lượng loài thực vật có trên đảo Espanola, với các thông tin địa lý là:

- area: 58.27 km²
- elevation: 198 m
- nearest: 1.1 km
- scruez: 88.3 km
- adjacent: 0.57 km²

Ta tính được

- $\hat{\eta} = 3.3272$
- $\hat{\mu} = 27.8614$
- $SE(\hat{\eta}) = 0.0551$

Suy ra, ta tính được khoảng tin cậy 95% cho η là

$$(3.2193, 3.4352)$$

và do đó, khoảng tin cậy 95% cho μ là

$$(25.0095, 31.0384)$$

Kiểm định giả thuyết từng hệ số

Trong mô hình Poisson log-linear, ta quan tâm tới câu hỏi:

“Biến X_j có thực sự cần thiết cho mô hình để tiên đoán trung bình của Y ?”

Câu hỏi này tương đương với giả thuyết

$$\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$$

Nếu H_0 là đúng thì ta nói “ X_j không có nghĩa trong mô hình, và có thể bị loại bỏ mà không gây ảnh hưởng tới kết quả ước lượng của mô hình.”

Kiểm định giả thuyết từng hệ số

Nhắc lại rằng, ta có kết quả

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{v}_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1),$$

với $\hat{v}_{jj}$ là thành phần trên đường chéo của ma trận $(\mathbf{Z}^\top \hat{\mathbf{V}} \mathbf{Z})^{-1}$.

Dưới giả định H_0 , ta có

$$Z = \frac{\hat{\beta}_j}{\sqrt{\hat{v}_{jj}}} \sim \mathcal{N}(0, 1).$$

Từ đây, ta xác định được

$$p\text{-value} = 2(1 - \Phi(|z|)),$$

ta bác bỏ giả thuyết H_0 khi p -value nhỏ hơn một mức ý nghĩa α được xác định trước.

Kiểm định giả thuyết từng hệ số

Với ví dụ về số lượng loài thực vật trên các đảo thuộc quần đảo Galápagos, ta có bảng kết quả tổng hợp sau:

	Estimate	Std. Error	z-statistic	p-value
(Intercept)	3.155	5.175×10^{-2}	60.963	< 0.001
area	-5.799×10^{-4}	2.627×10^{-5}	-22.074	< 0.001
elevation	3.541×10^{-3}	8.741×10^{-5}	40.507	< 0.001
nearest	8.826×10^{-3}	1.821×10^{-3}	4.846	< 0.001
scruz	-5.709×10^{-3}	6.256×10^{-4}	-9.126	< 0.001
adjacent	-6.630×10^{-4}	2.933×10^{-5}	-22.608	< 0.001

Như vậy, ta có thể kết luận rằng:

- tất cả các biến là cần thiết cho mô hình dự đoán trung bình số lượng loài thực vật, tại mức ý nghĩa 5%.

So sánh mô hình lồng nhau

Giả sử rằng, ta có hai mô hình Poisson log-linear A và B như sau:

$$\text{MH A: } \log(\mu) = \log(t) + \beta_0 + \beta_1 X_1 + \dots + \beta_{q_A} X_{q_A}$$

$$\text{MH B: } \log(\mu) = \log(t) + \beta_0 + \beta_1 X_1 + \dots + \beta_{q_A} X_{q_A} + \dots + \beta_{q_B} X_{q_B}$$

Nhận thấy rằng MH A là một trường hợp rút gọn của MH B, với số biến $p_A < p_B$.

Ta nói rằng MH A bị lồng vào (nested) MH B.

Lúc này, câu hỏi cần giải đáp là

“Mô hình A đơn giản hơn, liệu có đủ tốt để mô hình hóa dữ liệu?”

Câu hỏi này tương đương với giả thuyết

$$\begin{cases} H_0 : \beta_{q_A+1} = \beta_{q_A+2} = \dots = \beta_{q_B} = 0 \\ H_1 : \text{không phải } H_0 \end{cases}$$

So sánh mô hình lồng nhau

Từ hai mô hình, ta có hàm likelihood tương ứng là:

$$\text{MH A: } L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}),$$

$$\text{MH B: } L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B}).$$

Nếu giả thuyết H_0 là đúng (tức là mô hình A đủ tốt để mô hình hóa dữ liệu), khi đó tỷ số

$$\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B})} \approx 1$$

hay

$$\log \left(\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B})} \right) \approx 0.$$

Mặt khác, ta chứng minh được rằng

$$W = -2 \log \left(\frac{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A})}{L(\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_{q_A}, \hat{\beta}_{q_A+1} \dots, \hat{\beta}_{q_B})} \right) \sim \chi^2_{q_B - q_A},$$

thống kê W này được gọi là log-likelihood ratio.

So sánh mô hình lồng nhau

Giá trị p -value được định nghĩa bởi

$$p\text{-value} = \Pr(W > w),$$

với w được tính từ kết quả ước lượng mô hình, và $W \sim \chi^2_{q_B - q_A}$.

Ta bác bỏ giả thuyết H_0 khi p -value nhỏ hơn một mức ý nghĩa α được xác định trước.

So sánh mô hình lồng nhau

Ví dụ: ta xét lại ví dụ về ảnh hưởng của mức độ bức xạ gamma tới số lượng nhiễm sắc thể bị đột biến. Ta có hai mô hình như sau:

$$\text{MH A: } \log(\mu) = \log(\text{cells}) + \beta_0 + \beta_1 \times \text{doseamt} + \beta_2 \times \text{doserate}$$

$$\text{MH B: } \log(\mu) =$$

$$\log(\text{cells}) + \beta_0 + \beta_1 \times \text{doseamt} + \beta_2 \times \text{doserate} + \beta_3 \times \text{doseamt} \times \text{doserate}$$

Mô hình A là mô hình không xét tới sự tương tác giữa hai biến doseamt và doserate.

Kết quả phân tích cho kết quả

- $W \sim \chi^2_2$;
- $w = 21.165$;
- $p\text{-value} < 0.001$

Như vậy, ta bác bỏ giả thuyết H_0 tại mức ý nghĩa 5%.

Vậy, mô hình có thành phần tương tác giữa hai biến doseamt và doserate là phù hợp hơn với dữ liệu.

Ước lượng bị quá phân tán

Trong mô hình Poisson log-linear, dưới giả định biến phản hồi $Y|X \sim \mathcal{P}(\mu)$, do đó,

$$\mathbb{E}(Y|X) = \text{Var}(Y|X) = \mu$$

Tuy nhiên, trong thực tế, mô hình ước lượng Poisson log-linear thường không đảm bảo được điều kiện này, tức là

$$\widehat{\mathbb{E}}(Y|X) \neq \widehat{\text{Var}}(Y|X).$$

Điều này sẽ khiến cho

- ước lượng sai số chuẩn của hệ số β_j ;
- thống kê suy luận của các hệ số, cũng như μ


sẽ bị sai.

Nếu

- $\widehat{\mathbb{E}}(Y|X) < \widehat{\text{Var}}(Y|X)$: over-dispersion - mô hình ước lượng quá phân tán
- $\widehat{\mathbb{E}}(Y|X) > \widehat{\text{Var}}(Y|X)$: under-dispersion - mô hình ước lượng quá chụm (dữ liệu tập trung lại một khu vực, ít phân tán).

Ước lượng bị quá phân tán

Để kiểm chứng điều này, ta sẽ vẽ biểu đồ so sánh $\hat{\mu}_i$ và $(Y_i - \hat{\mu}_i)^2$, với đường tiêu chuẩn $x = y$.



Từ biểu đồ ta có $\widehat{\mathbb{E}}(Y|X) < \widehat{\text{Var}}(Y|X)$.

Ước lượng bị quá phân tán

Để hiệu chỉnh vấn đề này, ta có thể sử dụng hai mô hình:

- quasi-Poisson (chương 8.1, sách Foundations of Linear and Generalized Linear Models);
- Negative binomial (chương 7.3, sách Foundations of Linear and Generalized Linear Models).

Áp dụng mô hình quasi-Poisson, ta thu được kết quả như sau:

	Estimate	Std. Error	t-value	p-value
(Intercept)	3.1548	0.2916	10.819	< 0.001
area	-0.0006	0.0002	-3.918	< 0.001
elevation	0.0035	0.0005	7.189	< 0.001
nearest	0.0088	0.0103	0.860	0.3983
scruz	-0.0057	0.0035	-1.620	0.1184
adjacent	-0.0007	0.0002	-4.012	< 0.001