

Bài giảng R, số 2

-Hồi quy logistic-

TS.Tô Đức Khánh

19/03/2024

1 Thao tác cơ bản

Mô hình hồi quy logistic:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Trong R, để ước lượng mô hình hồi quy logistic, ta sử dụng hàm `glm()` như sau:

```
glm(formula = y ~ x1 + x2 + ..., data = ..., family = binomial, ...)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng, `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `...` là các đối thêm, được sử dụng trong các trường hợp cụ thể.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `exp(coef())`: ước lượng tỷ lệ cược - odds ratios;
- `confint.default()`: xác định khoảng tin cậy cho hệ số trong mô hình;
- `exp(confint.default())`: khoảng tin cậy cho tỷ lệ cược - odds ratios;
- `predict()`: tiên đoán giá trị của biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến đáp ứng.

Ví dụ 1: Để xác định xem liệu kích cỡ khối u có ảnh hưởng tới khả năng di căn tới hạch bạch huyết của tế bào ung thư thực quản, một nghiên cứu được tiến hành trên 31 bệnh nhân bị ung thư thực quản đã bị hoặc chưa bị di căn. Dữ liệu được lưu trong file `Esophageal_cancer.csv`

```
esoph_cancer <- read_csv(file = "datasets/Esophageal_cancer.csv")
```

```
## Rows: 31 Columns: 3
## -- Column specification -----
## Delimiter: ","
## dbl (3): Patient, TumorSize, LymphMetastasis
##
```

```
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
esoph_cancer <- esoph_cancer |> janitor::clean_names()
```

Các biến trong dữ liệu bao gồm:

- `patient`: số thứ tự của các bệnh nhân
- `tumor_size`: kích cỡ khối u
- `lymph_metastasis`: trạng thái di căn của tế bào ung thư (1 - đã di căn; 0 - chưa di căn).

Ta xem xét mô hình hồi quy sau:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{tumor_size}$$

Mô hình được ước lượng như sau:

```
out_md_cancer <- glm(formula = lymph_metastasis ~ tumor_size,
                     data = esoph_cancer, family = binomial)
```

Kết quả tổng hợp như sau:

```
summary(out_md_cancer)

##
## Call:
## glm(formula = lymph_metastasis ~ tumor_size, family = binomial,
##      data = esoph_cancer)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -2.0858      1.2256  -1.702   0.0888 .
## tumor_size    0.5117      0.2561   1.998   0.0457 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 42.165  on 30  degrees of freedom
## Residual deviance: 37.002  on 29  degrees of freedom
## AIC: 41.002
##
## Number of Fisher Scoring iterations: 4
```

Một vài nhận xét từ kết quả tổng hợp

- Ước tính $\hat{\beta}_1$ là dương, vì vậy, nếu một người bị ung thư có `tumor_size` (cỡ của khối u) lớn, thì khả năng tế bào ung thư di căn tới hạch bạch huyết tăng lên.
- Ta thấy p -value của `tumor_size` là nhỏ hơn $\alpha = 0.05$, điều đó có nghĩa là kích cỡ khối u có ý nghĩa thống kê đối với mô hình logistic, và nó hữu dụng trong việc dự đoán xác suất tế bào ung thư di căn.

Để tính tỷ lệ cược - odds cho tất cả mọi biến, ta thực hiện:

```
exp(coef(out_md_cancer))

## (Intercept)  tumor_size
##    0.1242095    1.6680481
```

Kết quả cho thấy tỷ lệ chênh lệch của `tumor_size` là 1.668, nghĩa là: nếu kích cỡ khối u tăng 1 cm thì khả năng di căn tế bào ung thư của người đó tăng lên khoảng 1.668 lần (tức là 66.8%).

Để xác định 95% khoảng tin cậy cho tỷ lệ cược odds, ta thực hiện như sau:

```
exp(confint.default(out_md_cancer, level = 0.95))
```

```
##                2.5 %    97.5 %
## (Intercept) 0.01124312 1.372216
## tumor_size  1.00972180 2.755595
```

Nếu kích cỡ khối u tăng 1 cm thì khả năng di căn tế bào ung thư của người đó tăng lên từ 1.372 tới 2.756 lần (tức là từ 37.2% tới 175.6%).

Giả sử ta có một bệnh nhân có khối u 5.3cm, khi đó, xác suất dự đoán người đó đã bị di căn được tính bởi

```
predict(out_md_cancer, newdata = data.frame(tumor_size = 5.3),
        type = "response")
```

```
##          1
## 0.6515777
```

Chú ý, trong `newdata = data.frame(...)` ta cần nhập đúng tên của biến X được sử dụng trong mô hình (không cần nhập biến phản hồi). Đối số `type = "response"` để yêu cầu tính giá trị xác suất dự đoán.

Để tìm khoảng tin cậy cho $\pi = \Pr(Y = 1|X = 5.3)$, ta sẽ tìm khoảng tin cậy cho $\eta = \mathbf{z}^\top \beta$, sau đó áp dụng chuyển đổi $\frac{\exp(x)}{1 + \exp(x)}$ cho hai điểm chặn dưới và trên của khoảng tin cậy.

```
pi_53 <- predict(out_md_cancer, newdata = data.frame(tumor_size = 5.3),
                type = "link", se.fit = TRUE)
```

```
pi_53
```

```
## $fit
##          1
## 0.6259812
##
## $se.fit
## [1] 0.442168
##
## $residual.scale
## [1] 1
```

Ở đây, đối số `type = "link"` để yêu cầu tính ước lượng $\hat{\eta}$ (được lưu tại `fit`), đồng thời với `se.fit = TRUE` ta sẽ thu được sai số chuẩn của $\hat{\eta}$ (được lưu tại `se.fit`). Khoảng tin cậy 95% cho η được tính bởi

```
ci_pi_53 <- pi_53$fit + c(-1, 1)*qnorm(1 - 0.05/2)*pi_53$se.fit
ci_pi_53
```

```
## [1] -0.2406521  1.4926145
```

Khoảng tin 95% cho $\pi = \Pr(Y = 1|X = 5.3)$:

```
exp(ci_pi_53)/(1 + exp(ci_pi_53))
```

```
## [1] 0.4401257 0.8164704
```

Mở rộng, ta có thể tính xác suất dự đoán với nhiều giá trị cho trước của X , và sẽ chúng để tạo thành đường cong ước lượng.

```
tumor_x <- seq(0, 10, by = 0.01)
pi_est <- predict(out_md_cancer, newdata = data.frame(tumor_size = tumor_x),
```

```

      type = "response")
data_pi_esoph <- data.frame(tumor_size = tumor_x, pi_est = pi_est)


```

Sử dụng `ggplot()` và `geom_line()` để vẽ đường cong ước lượng:

```

ggplot(data = data_pi_esoph,
      mapping = aes(x = tumor_size, y = pi_est)) +
  geom_line() +
  ylim(0, 1) +
  theme_bw()

```



Và ta xác định confidence band như sau:

```

out_eta_est <- predict(out_md_cancer, newdata = data.frame(tumor_size = tumor_x),
      type = "link", se.fit = TRUE)
eta_ci_095 <- mapply(function(x, y, ci_level){
  x + c(-1, 1)*qnorm((1 + ci_level)/2)*y
}, x = out_eta_est$fit, y = out_eta_est$se.fit, ci_level = 0.95)
pi_ci_095 <- apply(eta_ci_095, 1, function(x){
  exp(x)/(1 + exp(x))
})
data_pi_esoph <- data.frame(data_pi_esoph, pi_ci_095_l = pi_ci_095[, 1],
      pi_ci_095_u = pi_ci_095[, 2])


```

Sau đó ta vẽ hình như sau:

```

ggplot(data = data_pi_esoph,
      mapping = aes(x = tumor_size, y = pi_est)) +
  geom_line() +
  geom_line(aes(y = pi_ci_095_l), color = "blue", linetype = "dashed") +
  geom_line(aes(y = pi_ci_095_u), color = "blue", linetype = "dashed") +
  ylim(0, 1) +
  theme_bw()

```



Để so sánh 2 mô hình lồng nhau, ta dùng log-likelihood Chi-square test:

```
anova(object_1, object_2, test = "Chisq")
```

trong đó, `object_1` và `object_2` là kết quả của 2 mô hình cần so sánh. Ví dụ, ta so sánh mô hình

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0$$

với mô hình đã được xét:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{tumor_size}$$

```
out_md_cancer_0 <- glm(formula = lymph_metastasis ~ 1,
                        data = esoph_cancer, family = binomial)
anova(out_md_cancer_0, out_md_cancer, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: lymph_metastasis ~ 1
## Model 2: lymph_metastasis ~ tumor_size
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       30    42.165
## 2       29    37.002  1   5.1632  0.02307 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Kết quả p -value cho thấy mô hình số 2 là tốt hơn mô hình số 1 (chỉ có hệ số chặn).

Ví dụ 2: Để xác định các yếu tố làm tăng nguy cơ bị bệnh tim mạch vành với những đối tượng không mắc bệnh, một nghiên cứu trên 462 nam giới đã được thực hiện ở Western Cape, Nam Phi. Trong quá trình nghiên cứu, một số biến được thu thập:

- trạng thái bệnh tim mạch vành (`chd`): 1 (bị bệnh) hoặc 0 (không bị)
- huyết áp tâm thu (`sbp`)
- lượng thuốc lá tích lũy (`tobacco`)

- lượng cholesterol lipoprotein mật độ thấp (ldl)
- tiền sử gia đình về bệnh tim mạch vành (famhist): Absent hoặc Present
- tuổi (age)
- mức tiêu thụ rượu hiện tại (alcohol)
- và một số biến khác ...

Toàn bộ dữ liệu được cung cấp trong tệp `SAheart.csv`.

Với thông tin của một người đàn ông về huyết áp tâm thu, lượng cholesterol lipoprotein mật độ thấp, lượng thuốc lá tích lũy và tiền sử gia đình mắc bệnh tim mạch vành, làm thế nào chúng ta có thể dự đoán khả năng bị bệnh tim mạch vành của anh ta?

```
SAheart <- read_csv(file = "datasets/SAheart.csv")

## Rows: 462 Columns: 10
## -- Column specification -----
## Delimiter: ","
## chr (1): famhist
## dbl (9): sbp, tobacco, ldl, adiposity, typea, obesity, alcohol, age, chd
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.

SAheart <- SAheart |>
  mutate(famhist = factor(famhist, levels = c("Absent", "Present")),
         chd = factor(chd))
```

Ta xem xét mô hình hồi quy sau:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{sbp} + \beta_2 \text{tobacco} + \beta_3 \text{ldl} + \beta_4 \text{famhist}$$

Mô hình được ước lượng như sau:

```
out_md <- glm(formula = chd ~ sbp + tobacco + ldl + famhist, data = SAheart,
              family = binomial)
```

Kết quả tổng hợp như sau:

```
summary(out_md)

##
## Call:
## glm(formula = chd ~ sbp + tobacco + ldl + famhist, family = binomial,
##      data = SAheart)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -4.252750   0.778578  -5.462 4.70e-08 ***
## sbp           0.011982   0.005317   2.253 0.024234 *
## tobacco      0.118880   0.024727   4.808 1.53e-06 ***
## ldl          0.203350   0.053841   3.777 0.000159 ***
## famhistPresent 1.050498   0.218629   4.805 1.55e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 596.11 on 461 degrees of freedom
## Residual deviance: 502.17 on 457 degrees of freedom
## AIC: 512.17
##
## Number of Fisher Scoring iterations: 4
```

Một vài nhận xét từ kết quả tổng hợp

- Tất cả các ước tính $\hat{\beta}_j$ (với $j = 1, 2, 3$) đều dương, vì vậy, nếu một người đàn ông có **sbp** (huyết áp tâm thu) lớn, thì thay đổi mắc bệnh tim mạch vành tăng lên.
- $\hat{\beta}_4 > 0$, nghĩa là nếu thành viên gia đình của một người đàn ông mắc bệnh tim mạch vành thì khả năng người đó mắc bệnh tim là cao.
- Ta thấy tất cả các giá trị p đều nhỏ hơn $\alpha = 0.05$, điều đó có nghĩa là tất cả các biến đều có ý nghĩa thống kê đối với mô hình logistic. Và chúng rất hữu ích trong việc phân loại các đối tượng mắc bệnh tim mạch vành.

Tỷ lệ cược - odds cho tất cả mọi biến:

```
exp(coef(out_md))
```

```
## (Intercept)          sbp      tobacco          ldl famhistPresent
##  0.01422505    1.01205446    1.12623450    1.22550147    2.85907330
```

Kết quả cho thấy tỷ lệ chênh lệch của **famhistPresent** là 2.859, nghĩa là: nếu biết thành viên trong gia đình của một người đàn ông, là mắc bệnh tim mạch vành, thì khả năng người đàn ông đó mắc bệnh tim mạch vành tăng lên khoảng 2.859 lần (tức là 185.9%), so với khi không có lịch sử bệnh tim mạch gia đình.

Để xác định 95% khoảng tin cậy cho tỷ lệ cược odds, ta thực hiện như sau:

```
exp(confint.default(out_md, level = 0.95))
```

```
##              2.5 %      97.5 %
## (Intercept)  0.003092626 0.06543055
## sbp         1.001561536 1.02265732
## tobacco     1.072954984 1.18215971
## ldl         1.102767465 1.36189532
## famhistPresent 1.862634646 4.38856872
```

Bây giờ, giả sử chúng ta có một số thông tin về 4 người đàn ông và chúng ta muốn dự đoán xác suất họ mắc bệnh tim mạch vành. Thông tin được đưa ra như dưới đây

	id	sbp	tobacco	ldl	famhist
	1	115		1	Absent
	2	145		8	Absent
	3	125		2	Present
	4	135		5	Present

```
new_data <- tibble(sbp = c(115, 145, 125, 135),
                  tobacco = c(1, 8, 2, 5),
                  ldl = c(3, 9, 6, 8),
                  famhist = factor(c("Absent", "Absent", "Present", "Present"),
                                levels = c("Absent", "Present")))
predict(out_md, newdata = new_data, type = "response")
```

```
##          1          2          3          4
## 0.1047200 0.5660823 0.4386619 0.6539774
```

Ta có thể kiểm tra sự có nghĩa của các biến bằng log-likelihood Chi-square test:

```
anova(out_md, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model: binomial, link: logit
##
## Response: chd
##
## Terms added sequentially (first to last)
##
##
##          Df Deviance Resid. Df Resid. Dev  Pr(>Chi)
## NULL                461      596.11
## sbp          1   16.786      460   579.32 4.184e-05 ***
## tobacco      1   33.461      459   545.86 7.272e-09 ***
## ldl           1   20.120      458   525.74 7.273e-06 ***
## famhist      1   23.575      457   502.17 1.202e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Mỗi một dòng trong bảng kết quả, tương ứng với việc thêm biến tương ứng vào trong mô hình logistic. Ví dụ, dòng 1, NULL có nghĩa là mô hình 0

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0$$

dòng thứ hai, sbp tương ứng mô hình 1

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{sbp}$$

dòng thứ ba, tobacco tương ứng mô hình 2

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{sbp} + \beta_2 \text{tobacco}$$

tương tự cho tới dòng cuối cùng. Kết quả p -value cho thấy các biến được thêm vào đều có nghĩa, và giúp cho mô hình dự đoán xác suất tốt hơn.

Bây giờ, ta quan tâm tới mô hình mới

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{sbp} + \beta_2 \text{tobacco} + \beta_3 \text{ldl} + \beta_4 \text{famhist} + \beta_5 \text{age} + \beta_6 \text{famhist} : \text{age},$$

trong đó, thành phần `famhist:age` miêu tả sự tương tác giữa `famhist` và `age`. Ta so sánh mô hình này với mô hình trước đó:

```
out_md_2 <- glm(formula = chd ~ sbp + tobacco + ldl + famhist + age + famhist:age,
                data = SAheart, family = binomial)
anova(out_md, out_md_2, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: chd ~ sbp + tobacco + ldl + famhist
## Model 2: chd ~ sbp + tobacco + ldl + famhist + age + famhist:age
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1         457      502.17
## 2         455      483.24  2   18.927 7.761e-05 ***
```



```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Kết quả phân tích cho thấy, mô hình mới này tốt hơn mô hình cũ. Bây giờ, ta sẽ in ra kết quả ước lượng tổng hợp của mô hình mới:

```
summary(out_md_2)
```

```
##
## Call:
## glm(formula = chd ~ sbp + tobacco + ldl + famhist + age + famhist:age,
##      family = binomial, data = SAheart)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -4.403585    0.852105  -5.168 2.37e-07 ***
## sbp             0.005326    0.005560   0.958  0.33818
## tobacco        0.083308    0.025895   3.217  0.00129 **
## ldl             0.167300    0.054444   3.073  0.00212 **
## famhistPresent -0.113767    0.920628  -0.124  0.90165
## age            0.031888    0.012800   2.491  0.01273 *
## famhistPresent:age 0.022105    0.018909   1.169  0.24240
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 596.11  on 461  degrees of freedom
## Residual deviance: 483.24  on 455  degrees of freedom
## AIC: 497.24
##
## Number of Fisher Scoring iterations: 4
```

Ta nhận ra rằng, kết quả p -value của `sbp` và `famhist` là không còn ý nghĩa thống kê. Đối với `famhist`, nguyên nhân có thể là do sự có mặt của thành phần tương tác `famhist:age`. Ta có thể kiểm chứng thông qua việc sử dụng log-likelihood Chi-square test:

```
anova(out_md_2, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model: binomial, link: logit
##
## Response: chd
##
## Terms added sequentially (first to last)
##
##
```

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
## NULL			461	596.11	
## sbp	1	16.786	460	579.32	4.184e-05 ***
## tobacco	1	33.461	459	545.86	7.272e-09 ***
## ldl	1	20.120	458	525.74	7.273e-06 ***
## famhist	1	23.575	457	502.17	1.202e-06 ***
## age	1	17.539	456	484.63	2.815e-05 ***
## famhist:age	1	1.389	455	483.24	0.2386

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Như vậy, ta có thể bỏ đi thành phần tương tác `famhist:age` trong mô hình mới.

Thực hành: Cố định mức `tobacco` và `ldl` lần lượt là 6 và 8. Hãy vẽ đường ước lượng của mô hình 1 khi `sbp` thay đổi, tương ứng với 2 điều kiện khác nhau của `famhist`.

2 Bài tập

Bài tập 1: (Mô phỏng Monte Carlo)

Thực hiện mô phỏng cho mô hình $Y|X = x \sim \mathcal{B}(1, p(x))$, trong đó

$$p(x) = \frac{\exp(1 + 2x)}{1 + \exp(1 + 2x)},$$

theo các bước như sau:

1. Tạo ngẫu nhiên một mẫu cỡ n cho X từ phân phối $\mathcal{U}(-2, 2)$.
2. Xác định $p(X_i)$ với $i = 1, \dots, n$, sau đó, tạo ngẫu nhiên một mẫu n quan sát cho Y theo phân phối của mô hình.
3. Ước lượng hệ số của mô hình hồi quy logistic

$$p(x) = \frac{\exp(\beta_0 + \beta_1 x)}{1 + \exp(\beta_0 + \beta_1 x)},$$

dựa trên mẫu (X_i, Y_i) , với $i = 1, \dots, n$ được tạo ngẫu nhiên ở bước 1 và 2.

4. Lưu kết quả ước lượng của hệ số và sai số chuẩn của ước lượng.
5. Lặp lại các bước 1 từ 4 trong M lần (tối thiểu 1000 lần).

Yêu cầu

- (a) Thực hiện các bước mô tả ở trên với các cỡ mẫu n lần lượt là 20, 40, 80, 100, 150, 200.
- (b) Vẽ histogram của ước lượng $\hat{\beta}_0$ và $\hat{\beta}_1$ theo các trường hợp của cỡ mẫu.
- (c) Tính giá trị trung bình của M giá trị ước lượng $\hat{\beta}_0$ và $\hat{\beta}_1$, theo từng cỡ mẫu, so sánh với giá trị chính xác và nhận xét.
- (d) Tính giá trị trung bình của M giá trị sai số chuẩn của $\hat{\beta}_0$ và $\hat{\beta}_1$, theo từng cỡ mẫu, so sánh với độ lệch chuẩn mẫu của M giá trị ước lượng $\hat{\beta}_0$ và $\hat{\beta}_1$ và nhận xét.

Bài tập 2: Tập dữ liệu `bmd.csv` chứa ghi chép về mật độ xương (đo mật độ khoáng xương) của 169 bệnh nhân. Các biến sau đây đã được ghi nhận:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của bệnh nhân
- `sex`: giới tính của bệnh nhân (M - nam/F - nữ)
- `fracture`: đã bị gãy xương hông (1 - có/0 - không)
- `weight_kg`: cân nặng, đơn vị kg
- `height_cm`: chiều cao, đơn vị cm

- **waiting_time**: thời gian bệnh nhân phải đợi đo mật độ xương, đơn vị phút
- **bmd**: đo mật độ khoáng xương ở hông
- **medication**: tình trạng chăm sóc y tế (No medication / Glucocorticoids / Anticonvulsant)

Mục đích nghiên cứu là xây dựng mô hình dự đoán khả năng sẽ bị gãy xương của bệnh nhân. Điều này có thể giúp y tá hoặc bác sĩ chăm sóc bệnh nhân tốt hơn.

- Xây dựng và ước lượng mô hình hồi quy logistic để dự đoán khả năng bị gãy xương của bệnh nhân, sử dụng các biến: **bmd**, **sex**, **age** và **weight_kg**.
- Đưa ra một số nhận xét có giá trị dựa trên kết quả.
- Giả sử chúng ta có một số thông tin của 4 bệnh nhân:

id	age	sex	weight_kg	bmd
1	45	M	50	0.8
2	45	F	50	0.8
3	45	M	50	0.72
4	45	F	50	0.72

Xác định xác suất bị gãy xương của bệnh nhân, và khoảng tin cậy 95% tương ứng.

- Thực hiện kiểm định xem các mô hình con có hữu ích hơn mô hình đầy đủ.
- Giả sử ta có một nhóm bệnh nhân với độ tuổi 40, gồm cả nam lẫn nữ, với ba mức cân nặng 50, 55 và 60. Hãy vẽ đường ước lượng xác suất bị gãy xương của nhóm này, tương ứng với khoảng thay đổi của **bmd**.

Bài tập 3: Dữ liệu **SBI.csv** chứa thông tin của hơn 2349 trẻ em đến các dịch vụ cấp cứu vì bị sốt và được xét nghiệm nhiễm vi khuẩn nghiêm trọng. Kết quả **sbi2** có 2 loại: 0 - Không áp dụng (không nhiễm trùng) và 1 (bị nhiễm: UTI / Pneum / Bact). Các biến sau đây cũng được bao gồm:

- **id**: số thứ tự của bệnh nhân
- **age**: tuổi của trẻ
- **fever_hours**: thời gian sốt tính bằng giờ
- **sex**: giới tính của trẻ (M/F)
- **wcc**: số lượng tế bào bạch cầu
- **prevAB**: có sử dụng kháng sinh trước đó (Yes/No)
- **pct**: procalcitonin
- **crp**: protein phản ứng c (c-reactive protein)

Mục đích của nghiên cứu là xây dựng mô hình dự đoán tình trạng nhiễm trùng của trẻ. Điều này có thể giúp bác sĩ đưa ra quyết định nhanh chóng và chăm sóc trẻ tốt hơn.

- Xây dựng và ước lượng mô hình hồi quy logistic để dự đoán khả năng trẻ bị nhiễm trùng (**sbi2**), dựa vào các biến: **wcc**, **age**, **prevAB**, **pct** và **crp**.
- Đưa ra một số nhận xét có giá trị dựa trên kết quả.
- Giả sử chúng ta có một số thông tin của 6 trẻ em:

id	age	wcc	prevAB	pct	crp
1	1	5	No	4	15
2	1	20	No	4	25
3	2	10	Yes	5	50
4	0.5	20	Yes	5	70
5	1.5	30	No	1	120
6	1.5	30	No	1	12

Xác định xác suất bị nhiễm khuẩn của các bệnh nhi, và khoảng tin cậy 95% tương ứng.

- (d) Thực hiện kiểm định xem các mô hình con có hữu ích hơn mô hình đầy đủ.
- (e) Giả sử bác sĩ quan tâm tới nhóm trẻ 2 tuổi, gồm cả những trẻ đã sử dụng hoặc chưa sử dụng kháng sinh, có mức **crp** là 60, **pct** ở ba mức 3, 4, và 5. Hãy vẽ đường ước lượng xác suất bị nhiễm khuẩn của nhóm này, tương ứng với khoảng thay đổi của **wcc**.