

Bài giảng R, số 3

-Hồi quy logistic cho biến nhị thức-

TS.Tô Đức Khánh

09/04/2024

1 Thao tác cơ bản

Nhắc lại, mô hình hồi quy cho biến nhị thức được phát biểu như sau:

$$Y_i \sim \mathcal{B}(m_i, \mu_i),$$
$$\log\left(\frac{\mu_i}{1 - \mu_i}\right) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi},$$

với $i = 1, \dots, n$, $x_{1i}, x_{2i}, \dots, x_{pi}$ là các giá trị quan sát của các biến giải thích $X_1, X_2, \dots, X_p$. Mục tiêu của mô hình là để ước lượng/tiên đoán xác suất μ_i dựa vào giá trị cho trước của các biến giải thích $X_1, X_2, \dots, X_p$.

Trong R, để ước lượng mô hình hồi quy tuyến tính cho biến nhị thức, ta sử dụng hàm `glm()`, cụ thể như sau:

```
glm(y/m ~ x1 + x2, family = binomial, data = ..., weights = m, ...)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng, `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `weights` là trọng số của mô hình, tương ứng là số lượng phép thử;
- `...` là các đối thêm, được sử dụng trong các trường hợp cụ thể.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `exp(coef())`: ước lượng tỷ lệ cực - odds ratios;
- `confint.default()`: xác định khoảng tin cậy cho hệ số trong mô hình;
- `exp(confint.default())`: khoảng tin cậy cho tỷ lệ cực - odds ratios;
- `predict()`: tiên đoán giá trị của biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến đáp ứng.

Ví dụ 1: Dữ liệu `germ` trong thư viện `GLMsData` cung cấp dữ liệu về số hạt cây nảy mầm trong một nghiên cứu về tỷ lệ nảy mầm của hai loại hạt OA73 và OA75 khi được ghép với hai loại gốc ghép là cây đậu và cây dưa chuột.

```
data(germ, package = "GLMsData")
germ <- germ |> janitor::clean_names()
glimpse(germ)
```

```
## Rows: 21
## Columns: 4
## $ germ    <int> 10, 23, 23, 26, 17, 5, 53, 55, 32, 46, 10, 8, 10, 8, 23, 0, 3, 22, ~
## $ total   <int> 39, 62, 81, 51, 39, 6, 74, 72, 51, 79, 13, 16, 30, 28, 45, 4, 12, 4~
## $ extract <fct> Bean, Bean, Bean, Bean, Bean, Cucumber, Cucumber, Cucumber, Cucumbe~
## $ seeds   <fct> OA75, OA75, OA75, OA75, OA75, OA75, OA75, OA75, OA75, OA75, OA~
```

Trong dữ liệu này, biến *Germ* là số hạt nảy mầm thành công, *total* là tổng số hạt được gieo, *extract* là loại gốc cây được sử dụng (với hai loại: đậu - Bean, và dưa chuột - Cucumber), *seeds* là loại được gieo (OA73 và OA75). Ta cần xây dựng một mô hình tuyến tính để ước lượng tỷ lệ (xác suất) nảy mầm dựa vào thông tin của loại gốc cây và loại hạt được gieo.

Mô hình ta cần ước lượng sẽ có dạng

$$\begin{aligned} \text{germ}_i &\sim \mathcal{B}(\text{total}_i, \mu_i), \\ \log\left(\frac{\mu_i}{1 - \mu_i}\right) &= \beta_0 + \beta_1 \text{seeds}_i + \beta_2 \text{extract}_i, \end{aligned}$$

với $i = 1, 2, \dots, 21$.

Sử dụng `glm()` với hàm liên kết logit, ta tiến hành ước lượng mô hình như sau:

```
out_seeds <- glm(germ/total ~ seeds + extract, family = binomial,
                data = germ, weights = total)
```

Nhận xét rằng, trong thành phần công thức của hàm `glm()`, ta nhập thành phần biến đáp ứng là `germ/total`, điều này là do các thiết lập mô hình lý thuyết cho biến nhị thức, đồng thời ta cũng cần nhập thành phần trọng số `weights` là `total`. Kết quả ước lượng hệ số của mô hình là

```
coef(out_seeds)
```

```
##      (Intercept)      seedsOA75 extractCucumber
##      -0.7004832      0.2704511      1.0647498
```

```
summary(out_seeds)
```

```
##
## Call:
## glm(formula = germ/total ~ seeds + extract, family = binomial,
##      data = germ, weights = total)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.7005     0.1507  -4.648 3.36e-06 ***
## seedsOA75      0.2705     0.1547   1.748  0.0804 .
## extractCucumber 1.0647     0.1442   7.383 1.55e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 98.719  on 20  degrees of freedom
## Residual deviance: 39.686  on 18  degrees of freedom
## AIC: 122.28
```

```
##
## Number of Fisher Scoring iterations: 4
```

Chú ý: trong mô hình ta đang làm việc, hai biến giải thích **Seeds** và **Extract** là biến nhân tố, với các mức độ (hay thể loại) lần lượt là

```
levels(germ$seeds)
```

```
## [1] "OA73" "OA75"
```

và

```
levels(germ$extract)
```

```
## [1] "Bean"      "Cucumber"
```

Từ kết quả ước lượng, ta nhận thấy rằng:

- Hệ số chặn $\hat{\beta}_0$ là âm, cho thấy, nếu ta gieo hạt OA73 và sử dụng loại gốc là đậu (Bean), thì xác suất nảy mầm sẽ thấp hơn so với khi gieo loại hạt OA75 và dùng loại gốc Cucumber (dưa chuột);
- Hệ số $\hat{\beta}_1$ là dương, ám chỉ rằng, tỷ lệ nảy mầm OA75 là cao hơn so với loại hạt OA73, bất kể ta dùng loại gốc nào (đậu hoặc dưa chuột);
- Hệ số $\hat{\beta}_2$ là dương, cho thấy rằng tỷ lệ mầm của hai loại hạt sẽ cao hơn khi ta sử dụng loại gốc là dưa chuột, thay vì gốc là đậu.
- Từ kết quả p -value bằng 0.0804, lớn hơn mức ý nghĩa $\alpha = 0.05$, ta có được kết luận rằng, hệ số β_1 của biến giải thích **seed** có thể bằng 0, hay nói cách khác, biến giải thích **seed** (loại hạt) là có thể không cần thiết cho mô hình (mức ý nghĩa $\alpha = 0.05$).
- Mặt khác, p -value của hệ số β_2 là rất nhỏ, do đó, ta bác bỏ giả thuyết $H_0 : \beta_2 = 0$. Tức là, hệ số β_2 sẽ khác 0, và do đó, biến giải thích **extract** (loại gốc ghép) là cần thiết cho mô hình.

Hàm `glm()` sẽ tự động sử dụng mức độ đầu tiên của mỗi biến nhân tố làm mức độ (thể loại) tham chiếu, và do đó, ước lượng hệ số $\hat{\beta}_1$ và $\hat{\beta}_2$ tương ứng với hai mức độ OA75 và Cucumber.

Cụ thể hơn, ta có thể giải thích tỷ lệ nảy mầm của hạt dựa vào tỷ số chênh lệch (odds ratio):

```
exp(coef(out_seeds))
```

```
##      (Intercept)      seedsOA75 extractCucumber
##      0.4963454      1.3105554      2.9001133
```

Câu hỏi: Dựa vào kết quả của tỷ số chênh lệch được tính ở trên, hãy giải thích các kết quả nhận được.

Khoảng tin cậy 95% cho các hệ số của mô hình được xác định như sau:

```
confint.default(out_seeds, level = 0.95)
```

```
##              2.5 %      97.5 %
## (Intercept) -0.99589171 -0.4050747
## seedsOA75   -0.03276639  0.5736685
## extractCucumber 0.78209522 1.3474044
```

Ta tính khoảng tin cậy 95% cho tỷ số chênh lệch như sau:

```
exp(confint.default(out_seeds, level = 0.95))
```

```
##              2.5 %      97.5 %
## (Intercept)  0.3693939 0.666927
## seedsOA75    0.9677646 1.774766
## extractCucumber 2.1860477 3.847426
```

Câu hỏi: Ta có thể đưa ra được nhận xét gì, từ kết quả của các khoảng tin cậy 95% thu được ở trên?

Ta có thể sử dụng hàm `predict()` để ước lượng xác suất nảy mầm của hạt khi biết thông tin của biến giải thích. Ví dụ, ta xét 4 trường hợp kết hợp của loại hạt và loại gốc như sau

```
new_x <- data.frame(seeds = c("OA73", "OA73", "OA75", "OA75"),
                    extract = c("Bean", "Cucumber", "Bean", "Cucumber"))
new_x
```

```
##   seeds  extract
## 1  OA73    Bean
## 2  OA73 Cucumber
## 3  OA75    Bean
## 4  OA75 Cucumber
```

Xác suất ước lượng tương ứng như sau:

```
predict(out_seeds, newdata = new_x, type = "response")
```

```
##           1           2           3           4
## 0.3317051 0.5900729 0.3941186 0.6535584
```

Để tiện cho việc báo cáo kết quả, ta có thể tổng hợp các kết quả thành một bảng như sau:

```
new_prob <- predict(out_seeds, newdata = new_x, type = "response")
print(cbind(new_x, new_prob))
```

```
##   seeds  extract  new_prob
## 1  OA73    Bean 0.3317051
## 2  OA73 Cucumber 0.5900729
## 3  OA75    Bean 0.3941186
## 4  OA75 Cucumber 0.6535584
```

Từ đây, ta thấy rằng, việc dùng loại hạt OA75 kết hợp với gốc dưa chuột, sẽ cho xác suất nảy mầm cao nhất, với xác suất ước lượng là xấp xỉ 65%.

Để tìm khoảng tin cậy cho xác suất nảy mầm, ta sẽ tìm khoảng tin cậy cho $\eta = \mathbf{z}^T \beta$, sau đó áp dụng chuyển đổi $\frac{\exp(x)}{1 + \exp(x)}$ cho hai điểm chặn dưới và trên của khoảng tin cậy.

```
pi_est <- predict(out_seeds, newdata = new_x, type = "link", se.fit = TRUE)
pi_est
```

```
## $fit
##           1           2           3           4
## -0.7004832 0.3642666 -0.4300322 0.6347176
##
## $se.fit
##           1           2           3           4
## 0.1507214 0.1428253 0.1137382 0.1124518
##
## $residual.scale
## [1] 1
```

Ở đây, đối số `type = "link"` để yêu cầu tính ước lượng $\hat{\eta}$ (được lưu tại `fit`), đồng thời với `se.fit = TRUE` ta sẽ thu được sai số chuẩn của $\hat{\eta}$ (được lưu tại `se.fit`). Khoảng tin cậy 95% cho η được tính bởi

```
ci_pi_est <- mapply(FUN = function(x, y) {
  x + c(-1, 1)*qnorm((1 + 0.95)/2)*y
}, x = pi_est$fit, y = pi_est$se.fit)
ci_pi_est
```

```
##           1           2           3           4
## [1,] -0.9958917  0.08433404 -0.6529550  0.4143161
## [2,] -0.4050747  0.64419909 -0.2071093  0.8551191
```

Khoảng tin 95% cho xác suất nảy mầm:

```
exp(ci_pi_est)/(1 + exp(ci_pi_est))
```

```
##           1           2           3           4
## [1,] 0.2697499  0.5210710  0.3423239  0.6021223
## [2,] 0.4000937  0.6557021  0.4484070  0.7016399
```

Kết quả cho thấy rằng, nếu gieo hạt OA75 kết hợp với gốc dừa chuột, 95% khả năng xác suất nảy mầm sẽ giao động từ 60% tới 70%, tức là nếu ta gieo 20 hạt OA75 kết hợp với gốc dừa chuột, ta sẽ có được khoảng từ 12 tới 14 cây mầm. Trong khi nếu dùng hạt OA75 kết hợp với gốc đậu, 95% khả năng ta chỉ thu được khoảng từ 7 tới 9 cây mầm.

Chú ý: ở đây, ta dùng hàm `mapply()` để áp dụng hàm tính khoảng tin cậy cho từng phần tử của ước lượng hệ số và sai số chuẩn của ước lượng hệ số.

1.1 Bài tập

Bài tập 1: Sau vụ nổ của tàu con thoi Challenger vào ngày 28/01/1986, một nghiên cứu đã được tiến hành để xác định xem dữ liệu được thu thập trước đó về nhiệt độ không khí xung quanh tại thời điểm phóng có thể được sử dụng để dự đoán các vấn đề tiềm ẩn với phóng tàu vũ trụ, dữ liệu được lưu trong file `shuttles`, trong thư viện `GLMsData`).

```
data(shuttles, package = "GLMsData")
head(shuttles)
```

```
##   Temp Damaged
## 1    53       2
## 2    57       1
## 3    58       1
## 4    63       1
## 5    66       0
## 6    67       0
```

Dữ liệu chứa 2 cột với dữ liệu của 23 tàu vũ trụ được phóng trước ngày 28/01/1986, trong đó, cột 1 thể hiện nhiệt độ (thang đo độ F), cột 2 là số lượng vòng chính chữ O (primary O-rings) bị hỏng của mỗi tàu vũ trụ. Mỗi tàu vũ trụ có tổng cộng 6 vòng chính chữ O.

(a) Hãy vẽ biểu đồ mô tả tỷ lệ vòng chính chữ O bị hỏng, tương ứng với dữ liệu của nhiệt độ. Ta có thể đưa ra nhận xét gì? Gợi ý, tạo một vectơ `m0` chứa tổng số vòng chính chữ O của tàu vũ trụ, chẳng hạn

```
m0 <- rep(6, 23)
```

(b) Hãy xây dựng và ước lượng mô hình tuyến tính cho xác suất vòng chính chữ O bị hỏng do nhiệt độ.

(c) Giải thích kết quả xác định từ mô hình ước lượng.

(d) Xác định khoảng tin cậy 95

(e) Vào ngày phóng tàu Challenger, nhiệt độ dự báo là 31°F. Xác suất dự đoán xảy ra hỏng vòng chữ O là bao nhiêu? Xác định khoảng tin cậy 95% cho xác suất.

Bài tập 2: Dữ liệu `serum` trong thư viện `GLMsData` báo cáo số lượng chuột (thí nghiệm) sống sót sau khi được tiêm huyết thanh kháng phế cầu khuẩn (*pneumococcus*), với 5 liều khác nhau (đơn vị: cc).

```
data(serum, package = "GLMsData")
head(serum)
```

```
##      Dose Survivors Number
## 1 0.000625         7      40
## 2 0.001250        18      40
## 3 0.002500        32      40
## 4 0.005000        35      40
## 5 0.010000        38      40
```

- Hãy vẽ biểu đồ mô tả tỷ lệ sống sót của chuột tương ứng với liều của huyết thanh.
- Hãy xây dựng và ước lượng mô hình tuyến tính cho xác suất sống của chuột dưới tác động của liều huyết thanh.
- Giải thích kết quả xác định từ mô hình ước lượng.
- Xác định khoảng tin cậy 95
- Xác suất dự đoán chuột sống sót khi được tiêm một liều 0.0015cc là bao nhiêu? Xác định khoảng tin cậy 95% cho xác suất này.
- Lặp lại câu hỏi (b) - (e), với mô hình sử dụng $\log(\text{Dose})$ làm biến giải thích, thay vì Dose.

Bài tập 3: Phản ứng của sâu ăn nụ thuốc lá *Heliothis virescens* đối với liều thuốc trừ sâu trans-cypermethrin đã được ghi lại trong bộ dữ liệu `budworm` (thư viện `GLMsData`), từ một thí nghiệm nhỏ. Hai mươi con bướm đêm đực và hai mươi con bướm đêm cái đã được tiếp xúc với mỗi sáu liều pyrethroid, và số con chết đã được ghi lại.

```
data(budworm, package = "GLMsData")
head(budworm)
```

```
##      Killed Number Dose Gender
## 1         1      20      1      M
## 2         4      20      2      M
## 3         9      20      4      M
## 4        13      20      8      M
## 5        18      20     16      M
## 6        20      20     32      M
```

- Hãy vẽ biểu đồ mô tả tỷ lệ chết của bướm đêm tương ứng với liều của thuốc trừ sâu, và giới tính.
- Hãy xây dựng và ước lượng mô hình tuyến tính cho xác suất chết của bướm đêm dưới tác động của liều thuốc trừ sâu.
- Giải thích kết quả xác định từ mô hình ước lượng.
- Xác định khoảng tin cậy 95
- Xác suất dự đoán bướm đêm chết, phân biệt con đực và con cái, khi bị tiếp xúc một liều 15 là bao nhiêu? Xác định khoảng tin cậy 95% cho xác suất này.
- Lặp lại câu hỏi (b) - (e), với mô hình sử dụng $\log_2(\text{Dose})$ làm biến giải thích, thay vì Dose.

2 Thống kê kiểm định cho mô hình

2.1 log-likelihood Chi-square test

Sau khi ước lượng mô hình, ta thường quan tâm tới câu hỏi rằng, liệu rằng các biến giải thích có thực sự cần thiết cho mô hình trong thực tế. Câu hỏi này tương đương:

1. H_0 : Mô hình với chỉ hệ số chặn, $\log\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0$
2. H_A : Thêm biến giải thích X_j vào mô hình là phù hợp.

Ta kiểm chứng thông qua việc sử dụng log-likelihood Chi-square test:

```
anova(out_seeds, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model: binomial, link: logit
##
## Response: germ/total
##
## Terms added sequentially (first to last)
##
##
##          Df Deviance Resid. Df Resid. Dev Pr(>Chi)
## NULL                20      98.719
## seeds      1      2.544      19      96.175  0.1107
## extract   1     56.489      18     39.686 5.65e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Kết quả cho thấy biến giải thích **seeds** (loại hạt) là không cần thiết cho mô hình.

Chú ý: khi thực hiện kiểm định hệ số cho mô hình, ta nên thực hiện cả hai phương pháp kiểm định Wald cũng như kiểm định tỷ lệ hợp lý, để có thể đưa ra nhận xét tốt nhất. Trong một số trường hợp đặc biệt, kiểm định Wald có thể đưa ra kết quả sai, trong khi kiểm định tỷ lệ hợp lý vẫn chính xác. Do đó, ta thường ưu tiên sử dụng kiểm định tỷ lệ hợp lý hơn.

2.2 Goodness-of-fit test

Goodness-of-fit test được dùng để đánh giá khả năng dự đoán của mô hình đối với dữ liệu. Điều này dẫn tới bài toán kiểm định giả thuyết:

$$H_0 : \pi_1 = \pi_{10}, \pi_2 = \pi_{20}, \dots, \pi_n = \pi_{n0}$$

Nếu kết quả kiểm định là bác bỏ giả thuyết H_0 , thì ta nói “mô hình không phù hợp với dữ liệu” (**lack of fit**). Ta chứng minh được rằng, dưới giả định H_0 :

$$\chi^2 = \sum_{i=1}^n \frac{(Y_i - m_i \hat{\pi}_i)^2}{m_i \hat{\pi}_i (1 - \hat{\pi}_i)} = \sum_{i=1}^n p_i^2 \xrightarrow{d} \chi_{n-q-1}^2,$$

trong đó, q là số biến hồi quy được dùng trong mô hình, và p_i là thặng dư Pearson. Thống kê χ^2 được gọi là **χ^2 thống kê Pearson (Pearson's χ^2 -statistic)**. Giá trị p -value được định nghĩa bởi

$$p\text{-value} = \Pr(\chi^2 > w),$$

với w được tính từ kết quả ước lượng mô hình. Ta bác bỏ giả thuyết H_0 khi $p\text{-value} < \alpha$ (một mức ý nghĩa cho trước).

Áp dụng Goodness-of-fit test cho mô hình ta đang xét:

```
resid_chi_seeds <- residuals(out_seeds, type = "pearson")
chi_sq_seeds <- sum(resid_chi_seeds^2)
chi_sq_seeds
```

```
## [1] 38.31062
```

Giá trị $w = 38.31$, và p -value là

```
pchisq(chi_sq_seeds, df = nrow(germ) - 2 - 1)
```

```
## [1] 0.9964772
```

Kết quả này cho thấy mô hình này ước đoán tỷ lệ nảy mầm khớp với dữ liệu. Tuy nhiên, cần chú ý rằng, biến **seeds** là không có nghĩa trong mô hình. Do đó, ta có thể loại bỏ biến này, và áp dụng Goodness-of-fit test cho mô hình mới.

2.3 Bài tập

Bài tập 1: Phản ứng của sâu ăn nụ thuốc lá *Heliothis virescens* đối với liều thuốc trừ sâu trans-cypermethrin đã được ghi lại trong bộ dữ liệu **budworm** (thư viện **GLMsData**), từ một thí nghiệm nhỏ. Hai mươi con bướm đêm đực và hai mươi con bướm đêm cái đã được tiếp xúc với mỗi sáu liều pyrethroid, và số con chết đã được ghi lại.

```
data(budworm, package = "GLMsData")
head(budworm)
```

```
##      Killed Number Dose Gender
## 1          1      20      1      M
## 2          4      20      2      M
## 3          9      20      4      M
## 4         13      20      8      M
## 5         18      20     16      M
## 6         20      20     32      M
```

- Hãy xây dựng và ước lượng mô hình tuyến tính cho xác suất chết của bướm đêm dưới tác động của liều thuốc trừ sâu.
- Một mô hình ước lượng khác là sử dụng thành phần tuyến tính có thành phần biểu thị sự tương tác giữa liều thuốc trừ sâu (**Dose**) và giới tính của bướm (**Gender**). Hãy ước lượng mô hình này. (Gợi ý, công thức hồi quy tương ứng sẽ là: $1 + \text{Dose} * \text{Gender}$; ghi nhớ rằng dấu $*$ trong công thức hồi quy sẽ biểu thị cho sự tương tác giữa hai biến giải thích.)
- Sử dụng các kiểm định Wald cũng như kiểm định tỷ lệ hợp lý, kiểm tra xem liệu sự tương tác giữa liều thuốc trừ sâu và giới tính của bướm là có ý nghĩa thống kê.
- Trong trường hợp, sự tương tác là không có ý nghĩa thống kê, hãy ước lượng lại mô hình mới, trong đó thành phần tiên đoán là liều thuốc trừ sâu và giới tính của bướm (không chứa thành phần tương tác).
- Xác định tỷ số chênh lệch (odds ratio) cho việc một con bướm đực bị chết bởi thuốc trừ sâu so với một con cái. (tức là tỷ số giữa tỷ lệ cược - odds, cho việc một con đực bị chết, và tỷ lệ cược cho việc một con cái bị chết, bởi thuốc trừ sâu).
- Lập lại các câu hỏi từ (a) tới (e), với mô hình sử dụng $\log_2(\text{Dose})$ và **Gender**.
- Sử dụng Goodness-of-fit test kiểm tra độ chính xác của các mô hình đã ước lượng.

Bài tập 2: Tờ báo *Independent* của Anh đã thống kê giới tính của các ứng viên trong cuộc bầu cử quốc hội Anh năm 1992. Dữ liệu được tổng hợp trong bộ dữ liệu **belection** thuộc thư viện **GLMsData**

```
data(belection, package = "GLMsData")
head(belection)
```

```
##      Region Party Females Males
## 1  SouthEast  Cons         8    101
## 2  SouthWest  Cons         3     45
## 3 GreaterLondon Cons         8     76
```



```
## 4      EastAnglia  Cons      1    19
## 5  EastMidlands  Cons      3    39
## 6         Wales  Cons      2    36
```

Trong dữ liệu `belection`, ta có các biến được quan sát là:

- **Region**: khu vực bỏ phiếu
- **Party**: đảng tương ứng của ứng viên tranh cử.
- **Females**: số lượng nữ ứng viên tham gia tranh cử.
- **Males**: số lượng nam ứng viên tham gia tranh cử.

- Hãy vẽ biểu đồ mô tả tỷ lệ nữ ứng viên theo khu vực bầu cử, và nhận xét.
- Hãy vẽ biểu đồ mô tả tỷ lệ nữ ứng viên theo đảng, và nhận xét.
- Hãy xây dựng các mô hình tuyến tính có thể để ước lượng tỷ lệ nữ ứng viên tham gia tranh cử, sử dụng các biến giải thích **Region** và **Party**.
- Sử dụng các kiểm định Wald cũng như kiểm định tỷ lệ hợp lý, kiểm tra xem liệu các thành phần trong mô hình có ý nghĩa thống kê.
- Hãy giải thích kết quả của mô hình.
- Ước lượng và giải thích kết quả của tỷ lệ cược (odds) rằng ứng viên tham gia tranh cử của đảng Conservative (**Cons**) là một ứng viên nữ.
- Ước lượng và giải thích kết quả của tỷ lệ cược (odds) rằng ứng viên tham gia tranh cử của đảng Labour (**Labour**) là một ứng viên nữ.
- Hãy tính tỷ lệ chênh lệch (odds ratio) của ứng viên nữ giữa đảng Conservative (**Cons**) và đảng Labour (**Labour**). (Gợi ý, sử dụng kết quả về tỷ lệ cược ở câu (f) và (g)).
- Sử dụng Goodness-of-fit test kiểm tra độ chính xác của mô hình đã ước lượng.

Bài tập 3: Một nghiên cứu trên bệnh nhân được điều trị sarcoma không di căn (nonmetastatic sarcoma) đã thu được dữ liệu về giới tính (gender) của bệnh nhân, sự hiện diện của thâm nhiễm tế bào lympho (lymphocytic infiltration) và bất kỳ bệnh lý xương (osteoid pathology). Điều trị được coi là thành công nếu bệnh nhân không mắc bệnh trong 3 năm. Ở đây, hãy xem xét ảnh hưởng của thâm nhiễm tế bào lympho đến tỷ lệ thành công.

Bảng 1: Bảng dữ liệu sarcoma không di căn

lymphocytic infiltration	gender	osteoid pathology	cỡ nhóm	số lượng thành công
Absent	Female	Absent	3	3
Absent	Female	Present	2	2
Absent	Male	Absent	4	4
Absent	Male	Present	1	1
Present	Female	Absent	5	5
Present	Female	Present	5	3
Present	Male	Absent	9	5
Present	Male	Present	17	6

- Nhập bảng dữ liệu này vào trong R.
- Hãy vẽ biểu đồ mô tả tỷ lệ điều trị thành công theo giới tính, và nhận xét.
- Hãy vẽ biểu đồ mô tả tỷ lệ điều trị thành công theo trạng thái của lymphocytic infiltration, và nhận xét.

- (d) Hãy xây dựng các mô hình tuyến tính có thể để ước lượng tỷ lệ điều trị thành công, sử dụng các thông tin về giới tính và trạng thái của lymphocytic infiltration.
- (e) Sử dụng các kiểm định Wald cho mô hình, nhận xét về kết quả.
- (f) Sử dụng kiểm định tỷ lệ hợp lý, kiểm tra xem liệu trạng thái của lymphocytic infiltration có ý nghĩa thống kê.
- (g) Hãy giải thích kết quả của mô hình.
- (h) Sử dụng Goodness-of-fit test kiểm tra độ chính xác của mô hình đã ước lượng.