

Bài giảng R, số 4

-Phân tích ROC cho hồi quy logistic cho biến nhị phân-

TS.Tô Đức Khánh

09/04/2024

1 Phân tích đường cong ROC

1.1 Ước lượng đường cong ROC

Để đánh giá khả năng dự đoán (hay phân loại) của mô hình hồi quy logistic cho biến nhị phân, ta sử dụng phân tích đường cong ROC (receiver operating characteristic). Cụ thể, ý tưởng của phân tích là đánh giá độ chính xác của mô hình khi quyết định $\hat{Y}_i = 0$ hay 1 dựa trên so sánh $\hat{\pi}_i(\mathbf{x})$ với một ngưỡng xác suất p_0 trong khoảng $(0, 1)$:

- $\text{Sp}(p_0)$ là specificity hay độ đặc hiệu của mô hình tại ngưỡng p_0 , tức là, xác suất một đối tượng có $Y = 0$ được phân loại chính xác $Y = 0$:

$$\text{Sp}(p_0) = \Pr(\hat{\pi}(\mathbf{x}) \leq p_0 | Y = 0);$$

- $\text{Se}(p_0)$ là sensitivity hay độ nhạy của mô hình tại ngưỡng p_0 , tức là, xác suất một đối tượng có $Y = 1$ được phân loại chính xác $Y = 1$:

$$\text{Se}(p_0) = \Pr(\hat{\pi}(\mathbf{x}) > p_0 | Y = 1);$$

với p_0 thay đổi trong khoảng $(0, 1)$.

Đường cong ROC, là đường cong biểu diễn các cặp giá trị $(1 - \text{Sp}(p_0), \text{Se}(p_0))$.

Trong R, để ước lượng đường cong ROC, ta cần ước lượng $\text{Sp}(p_0)$ và $\text{Se}(p_0)$:

$$\begin{aligned}\widehat{\text{Sp}}(p_0) &= \frac{1}{n_0} \sum_{i=1}^{n_0} \mathbf{I}(\hat{\pi}_i(\mathbf{x}_i) \leq p_0) \\ \widehat{\text{Se}}(p_0) &= \frac{1}{n_1} \sum_{i=1}^{n_1} \mathbf{I}(\hat{\pi}_i(\mathbf{x}_i) > p_0)\end{aligned}$$

với n_0 và n_1 lần lượt là số lượng quan sát $Y = 0$ và $Y = 1$ có trong mẫu. Sau khi ước lượng, $\widehat{\text{Sp}}(p_0)$ và $\widehat{\text{Se}}(p_0)$ tại mọi điểm $p_0 \in (0, 1)$, ta sẽ vẽ các cặp điểm $(1 - \widehat{\text{Sp}}(p_0), \widehat{\text{Se}}(p_0))$ trên trục tọa độ hai chiều, và do đó, xác định được ước lượng của đường cong ROC.

Ví dụ 1: Ta xét lại mô hình dự đoán xác suất tế bào ung thư thực quản di căn dựa trên thông tin về kích cỡ khối u. Dữ liệu được lưu trong file `Esophageal_cancer.csv`

```
esoph_cancer <- read_csv(file = "datasets/Esophageal_cancer.csv")
```

```
## Rows: 31 Columns: 3
```

```
## -- Column specification -----
```

```
## Delimiter: ","
```

```
## dbl (3): Patient, TumorSize, LymphMetastasis
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
esoph_cancer <- esoph_cancer |> janitor::clean_names()
```

Mô hình hồi quy logistic:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{tumor_size}$$

Mô hình được ước lượng bởi:

```
out_md_cancer <- glm(formula = lymph_metastasis ~ tumor_size,
                     data = esoph_cancer, family = binomial)
```

Kết quả tổng hợp:

```
summary(out_md_cancer)

##
## Call:
## glm(formula = lymph_metastasis ~ tumor_size, family = binomial,
##      data = esoph_cancer)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -2.0858      1.2256  -1.702   0.0888 .
## tumor_size    0.5117      0.2561   1.998   0.0457 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 42.165  on 30  degrees of freedom
## Residual deviance: 37.002  on 29  degrees of freedom
## AIC: 41.002
##
## Number of Fisher Scoring iterations: 4
```

Ta muốn đánh giá độ chính xác của mô hình bằng phân tích đường cong ROC.

Bước 1 ta cần ước lượng được xác suất $\pi(\mathbf{x})$ tại mọi điểm dữ liệu $\pi_i(\mathbf{x}_i)$:

```
p_eso_est <- predict(out_md_cancer, type = "response")
p_eso_est
```

```
##           1           2           3           4           5           6           7           8
## 0.7755581 0.7572452 0.4646839 0.8521571 0.5539536 0.4267811 0.4902090 0.4519821
##           9          10          11          12          13          14          15          16
## 0.7572452 0.5157852 0.8815768 0.6398737 0.6159717 0.3086047 0.8169462 0.6515777
##          17          18          19          20          21          22          23          24
## 0.7477164 0.2568363 0.9254701 0.4902090 0.3656734 0.7279287 0.4902090 0.4902090
##          25          26          27          28          29          30          31
## 0.4902090 0.6159717 0.9254701 0.5539536 0.3656734 0.3656734 0.2286458
```

Chú ý: trong hàm `predict()` ta không nhập đối số `newdata`, bởi vì ta đang ước tính xác suất dựa trên dữ liệu được quan sát.

Bước 2 cho trước một $p_0 \in (0, 1)$, ước tính $\widehat{Sp}(p_0)$ và $\widehat{Se}(p_0)$ dựa vào công thức. Ví dụ với $p_0 = 0.5$, ta thực hiện như sau: tách kết quả ước lượng xác suất thành hai nhóm tương ứng với `lymph_metastasis = 0` hoặc `lymph_metastasis = 1`

```
p_eso_est_grp <- split(x = p_eso_est, f = esoph_cancer$lymph_metastasis)
p_eso_est_grp

## $`0`
##           2           7           8          11          14          16          18          20
## 0.7572452 0.4902090 0.4519821 0.8815768 0.3086047 0.6515777 0.2568363 0.4902090
##          23          24          25          29          31
## 0.4902090 0.4902090 0.4902090 0.3656734 0.2286458
##
## $`1`
##           1           3           4           5           6           9          10          12
## 0.7755581 0.4646839 0.8521571 0.5539536 0.4267811 0.7572452 0.5157852 0.6398737
##          13          15          17          19          21          22          26          27
## 0.6159717 0.8169462 0.7477164 0.9254701 0.3656734 0.7279287 0.6159717 0.9254701
##          28          30
## 0.5539536 0.3656734
```

ở đây, ta sử dụng hàm `split()`; sau đó, ta áp dụng công thức tính lên trên từng nhóm đã được phân tách

```
sp_05 <- mean(p_eso_est_grp[[1]] <= 0.5)
sp_05
```

```
## [1] 0.7692308
```

```
se_05 <- mean(p_eso_est_grp[[2]] > 0.5)
se_05
```


```
## [1] 0.7777778
```

Bây giờ ta sẽ thực hiện ước lượng sensitivity và specificity tại mọi điểm p_0 :

```
p_0 <- seq(0, 1, by = 0.01)
sp_lymph <- sapply(p_0, function(x) mean(p_eso_est_grp[[1]] <= x))
se_lymph <- sapply(p_0, function(x) mean(p_eso_est_grp[[2]] > x))
```

trong đó, hàm `seq()` dùng để tạo một dãy số cách đều; hàm `sapply()` dùng để áp dụng một hàm tính toán lên từng phần của một vectơ.

```
data_sp_se_lymph <- data.frame(se = se_lymph, sp = sp_lymph)
ggplot(data = data_sp_se_lymph,
       mapping = aes(x = rev(1 - sp_lymph), y = rev(se_lymph))) +
  xlab("1 - Specificity") + ylab("Sensitivity") +
  geom_line() +
  theme_bw()
```



Ở đây, ta sử dụng `rev()` để tạo phiên bản sắp xếp ngược của vectơ, do ta đang có `1 - sp_lymph` và `se_lymph` có thứ tự giảm dần.

Thực hành 1: Hãy vẽ lại ước lượng đường cong ROC và vẽ thêm đường thẳng $y = x$ vào trong hình vẽ.

1.2 Diện tích dưới đường cong

Diện tích dưới đường cong ROC (AUC) được định nghĩa bởi

$$\text{AUC} = \int_0^1 \text{ROC}(p) dp$$

AUC có thể được ước lượng bằng **trapezoidal rule** (quy tắc hình thang):

$$\widehat{\text{AUC}} = \sum_{k=1}^{N-1} \frac{\text{Se}(p_{0,k+1}) + \text{Se}(p_{0,k})}{2} (\text{Sp}(p_{0,k+1}) - \text{Sp}(p_{0,k})).$$

Trong đó, N là số điểm được chia của ngưỡng xác suất p_0 . Áp dụng công thức vào trong hàm `trap_rule()`:

```
trap_rule <- function(x, y){
  n <- length(x)
  res <- 0
  for(i in 1:(n - 1)){
    res <- res + 0.5*(y[i + 1] + y[i])*(x[i + 1] - x[i])
  }
  return(res)
}
auc_lymph <- trap_rule(x = sp_lymph, y = se_lymph)
auc_lymph
```

```
## [1] 0.732906
```

Thuật toán này cũng đã được áp dụng trong hàm `trapz()` của thư viện `caTools`.

Thực hành 2: Sử dụng hàm `trapz()` và so sánh với kết quả từ hàm `trap_rule()`.

Khoảng tin cậy của AUC có thể được xác định bởi phương pháp lặp lại mẫu bootstrap.

1. Tách dữ liệu thành hai bộ dữ liệu nhỏ, tương ứng với $Y = 0$ và $Y = 1$.
2. Lấy mẫu lặp lại trong từng bộ dữ liệu nhỏ.
3. Gộp hai mẫu được lấy ngẫu nhiên ở bước 2, thành một, và ước lượng mô hình logistic
4. Ước tính $Sp(p_0)$, $Se(p_0)$ và AUC của mô hình được ước lượng trong bước 3.
5. Lặp lại các bước 2 tới 4, trong R lần, và ghi lại kết quả ước lượng AUC trong R lần.
6. Xác định giá trị ở vị trí thứ $\lfloor R \times \alpha/2 \rfloor$ và ở vị trí thứ $\lfloor R \times (1 - \alpha/2) \rfloor$ làm hai giá trị giới hạn của khoảng tin cậy $(1 - \alpha)\%$ cho AUC.

Phương pháp xác định khoảng tin cậy này được gọi là bootstrap percentile confidence interval.

Ta áp dụng thuật toán vào trong đoạn code như sau:

Bước 1: tách dữ liệu thành nhóm theo tình trạng của biến Y

```
esoph_cancer_ls <- split(x = esoph_cancer, f = esoph_cancer$lymph_metastasis)
esoph_cancer_ls
```

```
## $`0`
## # A tibble: 13 x 3
##   patient tumor_size lymph_metastasis
##   <dbl>     <dbl>         <dbl>
## 1      2         6.3             0
## 2      7         4             0
## 3      8         3.7            0
## 4     11         8             0
## 5     14         2.5            0
## # i 8 more rows
##
## $`1`
## # A tibble: 18 x 3
##   patient tumor_size lymph_metastasis
##   <dbl>     <dbl>         <dbl>
## 1      1         6.5             1
## 2      3         3.8             1
## 3      4         7.5             1
## 4      5         4.5             1
## 5      6         3.5             1
## # i 13 more rows
```

```
esoph_cancer_0 <- esoph_cancer_ls[[1]]
esoph_cancer_1 <- esoph_cancer_ls[[2]]
```

Bước 2: lấy mẫu lặp lại với hàm `sample()`:

```
n0 <- nrow(esoph_cancer_0)
n1 <- nrow(esoph_cancer_1)
id_esoph_0 <- sample(1:n0, size = n0, replace = TRUE)
esoph_cancer_0b <- esoph_cancer_0[id_esoph_0, ]
id_esoph_1 <- sample(1:n1, size = n1, replace = TRUE)
esoph_cancer_1b <- esoph_cancer_1[id_esoph_1, ]
```

Bước 3: gộp thành mẫu chung và ước lượng mô hình cho mẫu bootstrap

```
esoph_cancer_b <- rbind(esoph_cancer_0b, esoph_cancer_1b)
out_md_cancer_b <- glm(formula = lymph_metastasis ~ tumor_size,
                        data = esoph_cancer_b, family = binomial)
```

Bước 4: ước lượng sensitivity, specificity và AUC của mô hình tương ứng mẫu bootstrap

```
p_eso_est_b <- predict(out_md_cancer_b, type = "response")
p_eso_est_grp_b <- split(x = p_eso_est_b, f = esoph_cancer_b$lymph_metastasis)
sp_lymph_b <- sapply(p_0, function(x) mean(p_eso_est_grp_b[[1]] <= x))
se_lymph_b <- sapply(p_0, function(x) mean(p_eso_est_grp_b[[2]] > x))
auc_lymph_b <- trap_rule(sp_lymph_b, se_lymph_b)
auc_lymph_b
```


```
## [1] 0.8653846
```

Bước 5: lặp quá trình bootstrap trong 1000 lần.

```
auc_lymph_bt <- numeric(1000)
for(i in 1:1000){
  id_esoph_0 <- sample(1:n0, size = n0, replace = TRUE)
  esoph_cancer_0b <- esoph_cancer_0[id_esoph_0,]
  id_esoph_1 <- sample(1:n1, size = n1, replace = TRUE)
  esoph_cancer_1b <- esoph_cancer_1[id_esoph_1,]
  esoph_cancer_b <- rbind(esoph_cancer_0b, esoph_cancer_1b)
  out_md_cancer_b <- glm(formula = lymph_metastasis ~ tumor_size,
                        data = esoph_cancer_b, family = binomial)
  p_eso_est_b0 <- predict(out_md_cancer_b, newdata = esoph_cancer_0b,
                        type = "response")
  p_eso_est_b1 <- predict(out_md_cancer_b, newdata = esoph_cancer_1b,
                        type = "response")
  sp_lymph_b <- sapply(p_0, function(x) mean(p_eso_est_b0 <= x))
  se_lymph_b <- sapply(p_0, function(x) mean(p_eso_est_b1 > x))
  auc_lymph_bt[i] <- trap_rule(sp_lymph_b, se_lymph_b)
}
```

Sau khi kết thúc quá trình bootstrap, ta có thể vẽ histogram của 1000 bootstrap ước lượng AUC.

```
ggplot(data = data.frame(auc_est = auc_lymph_bt),
      mapping = aes(x = auc_est)) +
  geom_histogram(fill = "white", color = "black", bins = 10) +
  geom_vline(xintercept = auc_lymph, linetype = "dashed", color = "blue") +
  theme_bw()
```



Bước 6: Khoảng tin cậy 95% cho AUC được xác định bởi

```
quantile(auc_lymph_bt, probs = c(0.025, 0.975))
```

```
##      2.5%      97.5%
## 0.5404915 0.8996261
```

Chú ý: Khi so sánh nhiều mô hình hồi quy logistic (cho cùng 1 biến phản hồi nhị phân), AUC của mô hình càng cao thì độ chính xác của mô hình càng cao, do đó, mô hình đó sẽ được ưu tiên sử dụng.

2 Bài tập

Bài tập 1: Tập dữ liệu `bmd.csv` chứa ghi chép về mật độ xương (đo mật độ khoáng xương) của 169 bệnh nhân. Các biến sau đây đã được ghi nhận:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của bệnh nhân
- `sex`: giới tính của bệnh nhân (M - nam/F - nữ)
- `fracture`: đã bị gãy xương hông (1 - có/0 - không)
- `weight_kg`: cân nặng, đơn vị kg
- `height_cm`: chiều cao, đơn vị cm
- `waiting_time`: thời gian bệnh nhân phải đợi đo mật độ xương, đơn vị phút
- `bmd`: đo mật độ khoáng xương ở hông
- `medication`: tình trạng chăm sóc y tế (No medication / Glucocorticoids / Anticonvulsant)

Mục đích nghiên cứu là xây dựng mô hình dự đoán khả năng sẽ bị gãy xương của bệnh nhân. Điều này có thể giúp y tá hoặc bác sĩ chăm sóc bệnh nhân tốt hơn.

- Xây dựng và ước lượng các mô hình hồi quy logistic để dự đoán khả năng bị gãy xương của bệnh nhân, sử dụng các biến giải thích khác nhau.
- Sử dụng phân tích đường cong ROC để đánh giá và so sánh độ chính xác của các mô hình được đề xuất ở câu trên.

Bài tập 2: Dữ liệu `SBI.csv` chứa thông tin của hơn 2349 trẻ em đến các dịch vụ cấp cứu vì bị sốt và được xét nghiệm nhiễm vi khuẩn nghiêm trọng. Kết quả `sbi2` có 2 loại: 0 - Không áp dụng (không nhiễm trùng) và 1 (bị nhiễm: UTI / Pneum / Bact). Các biến sau đây cũng được bao gồm:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của trẻ
- `fever_hours`: thời gian sốt tính bằng giờ
- `sex`: giới tính của trẻ (M/F)
- `wcc`: số lượng tế bào bạch cầu
- `prevAB`: có sử dụng kháng sinh trước đó (Yes/No)
- `pct`: procalcitonin
- `crp`: protein phản ứng c (c-reactive protein)

Mục đích của nghiên cứu là xây dựng mô hình dự đoán tình trạng nhiễm trùng của trẻ. Điều này có thể giúp bác sĩ đưa ra quyết định nhanh chóng và chăm sóc trẻ tốt hơn.

- (a) Xây dựng và ước lượng các mô hình hồi quy logistic để dự đoán khả năng trẻ bị nhiễm trùng (`sbi2`), dựa vào các biến dự đoán khác nhau.
- (b) Sử dụng phân tích đường cong ROC để đánh giá và so sánh độ chính xác của các mô hình được đề xuất ở câu trên.

Bài tập 3: hãy viết một hàm để thực hiện quá trình bootstrap cho AUC với giá trị đầu vào bao gồm

- `data_0`: dữ liệu tương ứng nhóm $Y = 0$;
- `data_1`: dữ liệu tương ứng nhóm $Y = 1$;
- `formula`: công thức của mô hình hồi quy;
- `p_0`: vector chứa ngưỡng xác suất;
- `R`: số lần lặp bootstrap.

Giá trị trả về là vector chứa giá trị ước lượng bootstrap của AUC trong `R` lần lặp.