

Bài giảng R, số 5

-Phân tích thặng dư cho hồi quy logistic-

TS.Tô Đức Khánh

17/04/2024

Phân tích thặng dư của mô hình logistic giúp ta kiểm tra:

- giả định về tính tuyến tính của mô hình là hợp lý;
- không có điểm ngoại lai ảnh hưởng tới ước lượng của mô hình.

Trong R, ta sử dụng hàm

```
residuals(object, type = c("deviance", "pearson", "response", "partial"))
```

để ước tính thặng dư của mô hình, trong đó,

- `object` là kết quả ước lượng của mô hình logistic;
- `type` là dạng thặng dư mà ta muốn tính, "deviance" là thặng dư deviance, "pearson" là thặng dư Pearson, "response" là thặng dư thô, "partial" là thặng dư từng phần.

1 Phân tích thặng dư mô hình logistic cho biến nhị phân

Như đã giới thiệu trong phần lý thuyết, đối với mô hình logistic cho biến nhị phân ($Y = 0$ hoặc $Y = 1$), ta nên dùng biểu đồ thặng dư khoảng (bin residuals) để tránh bị kết quả thặng dư phân thành hai nhánh.

Để vẽ được đồ thị thặng dư khoảng, ta thực hiện các bước sau:

- xác định thặng dư của mô hình logistic, thông thường, ta sử dụng thặng dư deviance;
- chia vùng giá trị của biến hồi quy X hoặc thành phần tuyến tính $\hat{\eta} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_q X_q$, thành các khoảng (bins);
- tính giá trị trung bình của thặng dư trong từng khoảng;
- tính giá trị trung bình của X hoặc $\hat{\eta}$ trong từng khoảng;
- biểu diễn các cặp điểm trung bình của X (hoặc $\hat{\eta}$) và của thặng dư trên trục tọa độ 2 chiều.

Ví dụ 1: Ta xét lại mô hình dự đoán xác suất tế bào ung thư thực quản di căn dựa trên thông tin về kích cỡ khối u. Dữ liệu được lưu trong file `Esophageal_cancer.csv`

```
esoph_cancer <- read_csv(file = "datasets/Esophageal_cancer.csv")
esoph_cancer <- esoph_cancer |> janitor::clean_names()
```

Mô hình hồi quy logistic:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{tumor_size}$$

Mô hình được ước lượng bởi:

```
out_md_cancer <- glm(formula = lymph_metastasis ~ tumor_size,
                     data = esoph_cancer, family = binomial)
```

Kết quả tổng hợp:

```
summary(out_md_cancer)
```

```
##
## Call:
## glm(formula = lymph_metastasis ~ tumor_size, family = binomial,
##      data = esoph_cancer)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -2.0858      1.2256  -1.702   0.0888 .
## tumor_size    0.5117      0.2561   1.998   0.0457 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 42.165  on 30  degrees of freedom
## Residual deviance: 37.002  on 29  degrees of freedom
## AIC: 41.002
##
## Number of Fisher Scoring iterations: 4
```

Ta muốn phân tích thẳng dư của mô hình.

Bước 1 ta xác định thẳng dư deviance của mô hình

```
resid_md_cancer <- residuals(object = out_md_cancer, type = "deviance")
resid_md_cancer
```

```
##           1           2           3           4           5           6           7
## 0.7129829 -1.6826785  1.2380613  0.5656579  1.0868987  1.3049781 -1.1608224
##           8           9          10          11          12          13          14
## -1.0967655  0.7457454  1.1507084 -2.0656673  0.9449704  0.9844330 -0.8591200
##          15          16          17          18          19          20          21
##  0.6358962 -1.4521294  0.7625372 -0.7705049  0.3935821 -1.1608224  1.4184602
##          22          23          24          25          26          27          28
##  0.7969343 -1.1608224 -1.1608224 -1.1608224  0.9844330  0.3935821  1.0868987
##          29          30          31
## -0.9541397  1.4184602 -0.7205658
```

Bước 2 ta tính $\hat{\eta}$

```
linear_pred_md_cancer <- predict(object = out_md_cancer, type = "link")
linear_pred_md_cancer
```

```
##           1           2           3           4           5           6           7
## 1.23996621  1.13763537 -0.14150004  1.75162037  0.21665788 -0.29499629 -0.03916920
##           8           9          10          11          12          13          14
## -0.19266545  1.13763537  0.06316163  2.00744745  0.57481579  0.47248496 -0.80665045
##          15          16          17          18          19          20          21
##  1.49579329  0.62598121  1.08646996 -1.06247753  2.51910162 -0.03916920 -0.55082337
##          22          23          24          25          26          27          28
```

```
## 0.98413913 -0.03916920 -0.03916920 -0.03916920 0.47248496 2.51910162 0.21665788
##          29          30          31
## -0.55082337 -0.55082337 -1.21597378
```

Bước 3 chia `linear_pred_md_cancer` thành các khoảng. Để làm việc này, ta sử dụng hàm

```
cut(x, break)
```

trong đó, `x` là vector mà ta muốn chia khoảng, `break` là vector chứa các điểm nút của các khoảng chia. cụ thể

```
bin_fitted <- cut(linear_pred_md_cancer,
                  breaks = unique(quantile(linear_pred_md_cancer,
                                           probs = (0:10)/10)),
                  include.lowest = TRUE)
bin_fitted

## [1] (1.14,1.75]      (0.984,1.14]      (-0.295,-0.0392] (1.14,1.75]
## [5] (-0.0392,0.217]   (-0.551,-0.295]   (-0.295,-0.0392] (-0.295,-0.0392]
## [9] (0.984,1.14]      (-0.0392,0.217]   (1.75,2.52]      (0.472,0.984]
## [13] (0.217,0.472]     [-1.22,-0.551]    (1.14,1.75]      (0.472,0.984]
## [17] (0.984,1.14]      [-1.22,-0.551]    (1.75,2.52]      (-0.295,-0.0392]
## [21] [-1.22,-0.551]    (0.472,0.984]     (-0.295,-0.0392] (-0.295,-0.0392]
## [25] (-0.295,-0.0392] (0.217,0.472]     (1.75,2.52]      (-0.0392,0.217]
## [29] [-1.22,-0.551]   [-1.22,-0.551]    [-1.22,-0.551]
## 9 Levels: [-1.22,-0.551] (-0.551,-0.295] (-0.295,-0.0392] ... (1.75,2.52]
```

ở đây, ta sử dụng các 10 điểm nút là các phân vị của mẫu, được tính thông qua hàm `quantile()`. Kết quả của `bin_fitted` là khoảng mà một giá trị của vector thuộc vào.

Sau đó, ta ghép `bin_fitted`, `linear_pred_md_cancer` và `resid_md_cancer` thành một tệp dữ liệu, để thuận tiện làm việc.

```
esoph_cancer_md_resid <- data.frame(bin_fitted = bin_fitted,
                                     linear_pred = linear_pred_md_cancer,
                                     resid = resid_md_cancer)
```

Bước 4 xác định trung bình của thặng dư và fitted (tức là $\hat{\eta}$) theo các khoảng chia


```
esoph_cancer_md_resid_bin <- esoph_cancer_md_resid |>
  group_by(bin_fitted) |>
  summarise(bin_resid = mean(resids), mean_x = mean(linear_pred), n = n())
esoph_cancer_md_resid_bin
```

```
## # A tibble: 9 x 4
##   bin_fitted      bin_resid    mean_x     n
##   <fct>          <dbl>      <dbl> <int>
## 1 [-1.22,-0.551] -0.0779017 -0.789595     6
## 2 (-0.551,-0.295] 1.30498    -0.294996     1
## 3 (-0.295,-0.0392] -0.808974  -0.0757159     7
## 4 (-0.0392,0.217] 1.10817     0.165492     3
## 5 (0.217,0.472] 0.984433    0.472485     2
## # i 4 more rows
```

Bước 5 biểu diễn kết quả để thu được biểu đồ thặng dư khoảng

```
ggplot(data = esoph_cancer_md_resid_bin,
       mapping = aes(x = mean_x, y = bin_resid)) +
  geom_point() +
  labs(x = "Linear predictor", y = "Residuals") +
```

```
theme_bw()
```



Thực hành 1. Xét mô hình hồi quy logistic

$$\log\left(\frac{\pi(\mathbf{x})}{1-\pi(\mathbf{x})}\right) = \beta_0 + \beta_1\text{sbp} + \beta_2\text{tobacco} + \beta_3\text{ldl} + \beta_4\text{famhist}$$

dự đoán xác suất bị bệnh tim mạch vành của nam giới ở Western Cape, Nam Phi. Các biến của mô hình được cung cấp thông tin cho dữ liệu `SAheart.csv`:

- trạng thái bệnh tim mạch vành (`chd`): 1 (bị bệnh) hoặc 0 (không bị)
- huyết áp tâm thu (`sbp`)
- lượng thuốc lá tích lũy (`tobacco`)
- lượng cholesterol lipoprotein mật độ thấp (`ldl`)
- tiền sử gia đình về bệnh tim mạch vành (`famhist`): `Absent` hoặc `Present`
- tuổi (`age`)
- mức tiêu thụ rượu hiện tại (`alcohol`)
- và một số biến khác ...

Hãy ước lượng mô hình trên và vẽ biểu đồ thặng dư khoảng cho mô hình ước lượng.

Thực hành 2. Xét mô hình hồi quy logistic

$$\log\left(\frac{\pi(\mathbf{x})}{1-\pi(\mathbf{x})}\right) = \beta_0 + \beta_1\text{sbp} + \beta_2\text{tobacco} + \beta_3\text{ldl} + \beta_4\text{famhist} + \beta_5\text{age}$$

với dữ liệu `SAheart.csv` như trong Thực hành 1. Hãy ước lượng mô hình trên và vẽ biểu đồ thặng dư khoảng cho mô hình ước lượng.

2 Phân tích thặng dư mô hình logistic cho biến nhị thức

Tương tự, như trong trường hợp mô hình logistic cho biến nhị phân, ở đây, ta cũng dùng biểu đồ miêu tả thặng dư và $\hat{\eta}$ (linear predictor), điểm khác là ta không cần chia khoảng.

Ví dụ 2: Xét dữ liệu turbines (được cung cấp trong thư viện GLMsData).

```
data(turbines, package = "GLMsData")
turbines <- turbines |> janitor::clean_names()
glimpse(turbines)
```

```
## Rows: 11
## Columns: 3
## $ hours    <int> 400, 1000, 1400, 1800, 2200, 2600, 3000, 3400, 3800, 4200, 4600
## $ turbines <int> 39, 53, 33, 73, 30, 39, 42, 13, 34, 40, 36
## $ fissures <int> 0, 4, 2, 7, 5, 9, 9, 6, 22, 21, 21
```

Dữ liệu này ghi chép lại thông tin về số lượng turbine bị nứt trong mỗi tổ hợp máy sau một số giờ làm việc liên tục. Ta xây dựng mô hình logistic dự đoán tỷ lệ turbine bị nứt của một tổ hợp máy, theo thông tin về số giờ làm việc liên tục:

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{hours}$$

Mô hình được ước lượng bởi:

```
out_md_turbine <- glm(formula = fissures/turbines ~ hours,
                      data = turbines, family = binomial, weights = turbines)
```

Kết quả tổng hợp:

```
summary(out_md_turbine)
```

```
##
## Call:
## glm(formula = fissures/turbines ~ hours, family = binomial, data = turbines,
##      weights = turbines)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -3.9235966  0.3779589 -10.381  <2e-16 ***
## hours        0.0009992  0.0001142   8.754  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 112.670  on 10  degrees of freedom
## Residual deviance:  10.331  on 9   degrees of freedom
## AIC: 49.808
##
## Number of Fisher Scoring iterations: 4
```

Ta phân tích thặng dư của mô hình như sau. Xác định giá trị của linear predictor, và thặng dư deviance:


```
linear_pred_md_turbine <- predict(out_md_turbine, type = "link")
resid_md_turbine <- residuals(out_md_turbine, type = "deviance")
```

Ghép thành hai vector này thành 1 bộ dữ liệu

```
data_md_turbine_resid <- data.frame(linear_pred = linear_pred_md_turbine,
                                   resids = resid_md_turbine)
```

và vẽ biểu đồ

```
ggplot(data = data_md_turbine_resid,
       mapping = aes(x = linear_pred, y = resid_md_turbine)) +
  geom_point() +
  labs(x = "Linear predictor", y = "Residuals") +
  theme_bw()
```



Thực hành 3. Xét dữ liệu `shuttles` (được cung cấp trong thư viện `GLMsData`).

```
data(shuttles, package = "GLMsData")
shuttles <- shuttles |> janitor::clean_names()
glimpse(shuttles)
```

```
## Rows: 23
## Columns: 2
## $ temp    <int> 53, 57, 58, 63, 66, 67, 67, 67, 68, 69, 70, 70, 70, 70, 72, 73, 75, ~
## $ damaged <int> 2, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 2, 0, 0, 0, 0
```

Dữ liệu chứa 2 cột với dữ liệu của 23 tàu vũ trụ được phóng trước ngày 28/01/1986, trong đó, cột 1 thể hiện nhiệt độ (thang đo độ F), cột 2 là số lượng vòng chính chữ O (primary O-rings) bị hỏng của mỗi tàu vũ trụ. Mỗi tàu vũ trụ có tổng cộng 6 vòng chính chữ O.

Hãy xây dựng và ước lượng mô hình tuyến tính cho xác suất vòng chính chữ O bị hỏng do nhiệt độ, và vẽ biểu đồ thặng dư cho mô hình ước lượng.

3 Phân tích thặng dư từng phần mô hình logistic

Thặng dư từng phần được sử dụng trong trường hợp ta muốn kiểm tra tính tuyến tính của từng biến hồi quy trong mô hình tuyến tính đa biến.

Ví dụ 3: Xét mô hình hồi quy logistic

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{sbp} + \beta_2 \text{tobacco} + \beta_3 \text{ldl} + \beta_4 \text{famhist}$$

dự đoán xác suất bị bệnh tim mạch vành của nam giới ở Western Cape, Nam Phi. Các biến của mô hình được cung cấp thông tin cho dữ liệu `SAheart.csv`

```
SAheart <- read_csv(file = "datasets/SAheart.csv")
SAheart <- SAheart |>
  mutate(famhist = factor(famhist, levels = c("Absent", "Present")),
         chd = factor(chd))
```

Mô hình được ước lượng bởi:

```
out_md_heart <- glm(formula = chd ~ sbp + tobacco + ldl + famhist,
                    data = SAheart, family = binomial)
summary(out_md_heart)
```

```
##
## Call:
## glm(formula = chd ~ sbp + tobacco + ldl + famhist, family = binomial,
##      data = SAheart)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -4.252750   0.778578  -5.462 4.70e-08 ***
## sbp           0.011982   0.005317   2.253 0.024234 *
## tobacco      0.118880   0.024727   4.808 1.53e-06 ***
## ldl          0.203350   0.053841   3.777 0.000159 ***
## famhistPresent 1.050498   0.218629   4.805 1.55e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 596.11  on 461  degrees of freedom
## Residual deviance: 502.17  on 457  degrees of freedom
## AIC: 512.17
##
## Number of Fisher Scoring iterations: 4
```

Thặng dư từng phần của mô hình được xác định bởi

```
resid_md_heart_part <- residuals(out_md_heart, type = "partial")
head(resid_md_heart_part)
```

```
##      sbp  tobacco    ldl  famhist
## 1  1.530413  2.265069  1.471967  1.8846439
## 2  6.168405  5.669410  6.033255  5.6638563
## 3 -1.586174 -1.765305 -1.598897 -0.7286828
## 4  1.736589  1.816463  1.696598  1.9709966
## 5  1.429159  2.665565  1.228785  2.0949325
## 6 -2.616380 -2.235719 -2.188839 -1.9266418
```

Kết quả cho thấy, ta có 4 cột cung cấp giá trị thặng dư từng phần tương ứng cho 4 biến hồi quy (tức 4 thành phần trong linear predictor).

Ta sử dụng thặng dư khoảng, do ta đang làm việc với mô hình hồi quy logistic cho biến nhị phân. Do là thặng dư từng phần, nên ta sẽ chia khoảng dựa trên biến hồi quy mà ta quan tâm. Ở đây, ta thực hiện phân tích thặng dư từng phần cho biến `sbp`.

```
bin_sbp_md <- cut(SAheart$sbp,
                  breaks = unique(quantile(SAheart$sbp, probs = (0:40)/40)))
```


Tạo dữ liệu cần dùng cho việc vẽ biểu đồ, và

```
data_md_resid_sbp <- data.frame(bin_fitted = bin_sbp_md,
                                sbp = SAheart$sbp,
                                resid = resid_md_heart_part[, "sbp"])
data_md_resid_bin_sbp <- data_md_resid_sbp |>
  group_by(bin_fitted) |>
  summarise(bin_resid = mean(resids), mean_x = mean(sbp), n = n())
data_md_resid_bin_sbp
```

```
## # A tibble: 30 x 4
##   bin_fitted bin_resid mean_x    n
##   <fct>      <dbl>   <dbl> <int>
## 1 (101,108]  2.56979  106.583  12
## 2 (108,112]  0.0846968 111.083  12
## 3 (112,114] -0.915823  114      12
## 4 (114,118] -0.392926  117.433  30
## 5 (118,120] -1.17421   120     14
## # i 25 more rows
```

Biểu đồ được vẽ như sau:

```
ggplot(data = data_md_resid_bin_sbp,
       mapping = aes(x = mean_x, y = bin_resid)) +
  geom_point() +
  labs(x = "SBP", y = "Residuals") +
  theme_bw()
```



Thực hành 4. Vẽ biểu đồ thặng dư từng phần cho các biến tobacco, ldl, famhist.

4 Phân tích điểm ngoại lai

Trong phân tích điểm ngoại lai với R, ta cần một số hàm sau:

```
hatvalues(model)
```

để tính giá trị đòn bẩy (leverage);


```
rstandard(model, type = "pearson")
```

để tính thặng dư chuẩn hóa (standardized residuals);

```
cooks.distance(model)
```

để tính khoảng cách Cook (Cook's distance).

Ví dụ 4: Ta xét lại mô hình logistic

$$\log\left(\frac{\pi(\mathbf{x})}{1 - \pi(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{tumor_size}$$

trong Ví dụ 1, `out_md_cancer`. Ta tính giá trị leverage

```
leverage_md_cancer <- hatvalues(out_md_cancer)
```

thặng dư chuẩn hóa của mô hình

```
std_resid_md_cancer <- rstandard(out_md_cancer, type = "pearson")
```

và khoảng cách Cook


```
cook_md_cancer <- cooks.distance(out_md_cancer)
```

Ta tạo một dữ liệu chứa các vector vừa tính phía trên

```
data_leverage_md_cancer <- data.frame(leverage = leverage_md_cancer,  
                                       std_resid = std_resid_md_cancer,  
                                       cooks = cook_md_cancer)
```

Biểu đồ của thặng dư chuẩn hóa và giá trị đòn bẩy, kết hợp khoảng cách Cook (trong đó, giá trị của khoảng cách Cook được dùng làm kích cỡ của điểm)

```
ggplot(data_leverage_md_cancer, aes(x = leverage, y = std_resid)) +  
  geom_point(aes(size = cooks)) +  
  xlab("Leverage") + ylab("Standardized Residuals") +  
  scale_size_continuous("Cook's Distance", range = c(1, 6)) +  
  theme_bw() +  
  theme(legend.position = "bottom")
```



Thực hành 5. Xác định điểm có giá trị thặng dư chuẩn hóa lớn (giá trị tuyệt đối lớn hơn 2 hoặc 3), và cung cấp thông tin về giá trị leverage và khoảng cách Cook của điểm đó.

Thực hành 6. Vẽ biểu đồ của thặng dư chuẩn hóa và giá trị đòn bẩy, kết hợp khoảng cách Cook cho các mô hình logistic được ước lượng trong các ví dụ và thực hành.