

Bài giảng R, số 6

-Mô hình hồi quy multinomial logistic-

TS.Tô Đức Khánh

20/05/2024

1 Thao tác cơ bản

1.1 Ước lượng mô hình

Mô hình hồi quy multinomial logistic:

$$\log \left(\frac{\pi_j(\mathbf{x})}{\pi_1(\mathbf{x})} \right) = \beta_{j0} + \beta_{j1}x_1 + \beta_{j2}x_2 + \dots + \beta_{jp}x_p$$

Trong R, để ước lượng mô hình hồi quy multinomial logistic, ta sử dụng hàm `multinom()` được cung cấp bởi thư viện `nnet`:

```
multinom(y ~ x1 + x2 + ..., data = ..., Hess = TRUE, weights, maxit = 100)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng (gồm 2 hoặc nhiều nhóm), `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `Hess` là lựa chọn xuất ra ma trận Hessian (ma trận thông tin Fisher) của mô hình, `TRUE` tức là có, `FALSE` có nghĩa không;
- `maxit` là số lần lặp tối đa của thuật toán;
- `weights` là trọng số dùng trong ước lượng mô hình.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `exp(coef())`: ước lượng tỷ số rủi ro tương đối - relative risk ratio;
- `confint.default()`: xác định khoảng tin cậy cho hệ số trong mô hình;
- `exp(confint.default())`: khoảng tin cậy cho tỷ số rủi ro tương đối - relative risk ratio;
- `predict(x, newdata, type = "probs")`: tiên đoán giá trị xác suất của biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến đáp ứng.

Ví dụ 1: Ta phân tích bộ dữ liệu `nes90` trong thư viện `faraway` về việc bỏ phiếu trong cuộc bầu cử tổng thống Mỹ năm 1996.

```
data(nes96, package = "faraway")
nes96 <- nes96 |> janitor::clean_names()
glimpse(nes96)
```

```
## Rows: 944
## Columns: 10
## $ popul <int> 0, 190, 31, 83, 640, 110, 100, 31, 180, 2800, 1600, 330, 190, 100, ~
## $ t_vnews <int> 7, 1, 7, 4, 7, 3, 7, 1, 7, 0, 0, 5, 2, 7, 7, 7, 7, 5, 7, 2, 7, 0, 3~
## $ self_lr <ord> extCon, sliLib, Lib, sliLib, sliCon, sliLib, sliCon, sliCon, Mod, s~
## $ clin_lr <ord> extLib, sliLib, Lib, Mod, Con, Mod, Con, Mod, Con, sliLib, Lib, sli~
## $ dole_lr <ord> Con, sliCon, Con, sliCon, Mod, Con, Mod, sliCon, sliLib, extCon, Mo~
## $ pid <ord> strRep, weakDem, weakDem, weakDem, strDem, weakDem, weakDem, indRep~
## $ age <int> 36, 20, 24, 28, 68, 21, 77, 21, 31, 39, 26, 31, 22, 42, 74, 62, 58, ~
## $ educ <ord> HS, Coll, BAdeg, BAdeg, BAdeg, Coll, Coll, Coll, Coll, HS, HSdrop, ~
## $ income <ord> $3Kminus, $3Kminus, $3Kminus, $3Kminus, $3Kminus, $3Kminus, $3Kminu~
## $ vote <fct> Dole, Clinton, Clinton, Clinton, Clinton, Clinton, Clinton, Clinton~
```

Ta muốn tìm ra một mô hình dự đoán tỷ lệ đảng viên thuộc 1 trong 3 đảng: Democrat, Independent or Republican, thông qua một số thông tin: trình độ giáo dục (educ), tuổi (age), lương (income).

Thành phần đảng viên của người bỏ phiếu được ghi trong biến pid với 7 nhóm:

```
with(nes96, table(pid))
```

```
## pid
## strDem weakDem indDem indind indRep weakRep strRep
## 200 180 108 37 94 150 175
```

Do đó, trước khi phân tích, ta cần nhóm các loại này thành 3 nhóm đảng chính:

```
nes96 <- nes96 |> mutate(party = factor(pid, ordered = FALSE))
levels(nes96$party) <- list("Democrat" = c("strDem", "weakDem"),
                           "Independent" = c("indDem", "indind", "indRep"),
                           "Republican" = c("weakRep", "strRep"))
```

Ở đây, hàm levels() được dùng để tạo ra 3 nhóm, với mỗi nhóm gồm các lớp thành phần của pid.

Nhận thấy rằng, biến income không phải là dạng số, mà là dạng thể loại miêu tả khoảng tiền thu nhập của người bỏ phiếu:

```
with(nes96, table(income))
```

```
## income
## $3Kminus $3K-$5K $5K-$7K $7K-$9K $9K-$10K $10K-$11K $11K-$12K
## 19 12 17 19 18 13 11
## $12K-$13K $13K-$14K $14K-$15K $15K-$17K $17K-$20K $20K-$22K $22K-$25K
## 17 10 15 23 35 26 39
## $25K-$30K $30K-$35K $35K-$40K $40K-$45K $45K-$50K $50K-$60K $60K-$75K
## 68 70 62 48 51 100 103
## $75K-$90K $90K-$105K $105Kplus
## 53 47 68
```

Để thuận tiện cho việc phân tích, ta chuyển đổi chúng về dạng số, với giá trị được xác định là giá trị trung bình của khoảng thu nhập, đồng thời ta cũng chia lại theo 7 khoảng giá trị để tiện cho việc vẽ biểu đồ:

```
inca <- c(1.5, 4, 6, 8, 9.5, 10.5, 11.5, 12.5, 13.5, 14.5, 16, 18.5, 21, 23.5,
         27.5, 32.5, 37.5, 42.5, 47.5, 55, 67.5, 82.5, 97.5, 115)
nes96 <- nes96 |> mutate(income2 = inca[unclass(income)],
                        income_gps = cut_number(income2, n = 7))
```

Sử dụng khoảng tiền lương mới được tạo `income_gps`, ta tính tỷ lệ đảng viên trong các khoảng tương ứng

```
nes96_props_income <- nes96 |> group_by(income_gps, party) |>
  summarise(count = n()) |> group_by(income_gps) |>
  mutate(etotal = sum(count), props = count/etotal)
```


kết quả thu được

```
nes96_props_income
```

```
## # A tibble: 21 x 5
## # Groups:   income_gps [7]
##   income_gps party      count etotal  props
##   <fct>      <fct>      <int> <int>  <dbl>
## 1 [1.5,13.5] Democrat        69    136 0.507353
## 2 [1.5,13.5] Independent    36    136 0.264706
## 3 [1.5,13.5] Republican    31    136 0.227941
## 4 (13.5,23.5] Democrat        75    138 0.543478
## 5 (13.5,23.5] Independent    30    138 0.217391
## # i 16 more rows
```

Từ kết quả này, ta có biểu đồ như sau:

```
ggplot(data = nes96_props_income,
  mapping = aes(x = income_gps, y = props, group = party)) +
  geom_line(mapping = aes(linetype = party)) +
  theme_bw() +
  theme(axis.text.x = element_text(angle = 90), legend.position = "bottom")
```



Thông qua biểu đồ này, ta nhận thấy rằng, tỷ lệ đảng viên đảng Democrat (Dân chủ) giảm theo thu nhập, trong khi đó, tỷ lệ đảng viên Republican (Cộng hòa) tỷ lệ thuận với thu nhập.

Bây giờ, ta sẽ xây dựng mô hình dựa trên thông tin này. Do biến **party** có ba nhóm (không có thứ tự), do đó, ta sử dụng mô hình multinomial logistic. Chú ý, ở đây, nhóm **Democrat** là nhóm đầu tiên, và được mặc định là nhóm tham chiếu, vì vậy ta có mô hình multinomial logistic như sau:

$$\begin{aligned}\log\left(\frac{\pi_2(\mathbf{x})}{\pi_1(\mathbf{x})}\right) &= \beta_{20} + \beta_{21}\text{income2} \\ \log\left(\frac{\pi_3(\mathbf{x})}{\pi_1(\mathbf{x})}\right) &= \beta_{30} + \beta_{31}\text{income2}\end{aligned}$$

Trong đó,

- $\pi_1(\mathbf{x})$ là tỷ lệ đảng viên đảng Democrat;
- $\pi_2(\mathbf{x})$ là tỷ lệ đảng viên đảng Independent;
- $\pi_3(\mathbf{x})$ là tỷ lệ đảng viên đảng Republican.

Mô hình ước lượng như sau

```
library(nnet)
out_md_party_1 <- multinom(party ~ income2, data = nes96, Hess = TRUE)

## # weights: 9 (4 variable)
## initial value 1037.090001
## final value 992.712152
## converged
```

Thuật toán hội tụ nhanh (dưới 10 lần lặp). Kết quả tổng hợp mô hình

```
summary(out_md_party_1)

## Call:
## multinom(formula = party ~ income2, data = nes96, Hess = TRUE)
##
## Coefficients:
##           (Intercept)      income2
## Independent  -1.1749331  0.01608683
## Republican   -0.9503591  0.01766457
##
## Std. Errors:
##           (Intercept)      income2
## Independent    0.1536103  0.002849738
## Republican     0.1416859  0.002652532
##
## Residual Deviance: 1985.424
## AIC: 1993.424
```

Để hiểu rõ hơn về ý nghĩa của các hệ số, ta tính $\exp()$ của các ước lượng hệ số, cũng chính là tỷ số rủi ro tương đối - relative risk ratio của từng biến:

```
exp(coef(out_md_party_1))

##           (Intercept)      income2
## Independent    0.3088396  1.016217
## Republican     0.3866022  1.017822
```

Kết quả cho thấy, khi tiền lương tăng khoảng 1 đơn vị (1000\$), tỷ lệ đảng viên đảng **Independent** hoặc **Republican** là cao hơn so với tỷ lệ đảng viên đảng **Democrat**, khoảng 1.016 lần (1.6%) và 1.017 lần (1.7%).

Thực hành 1: Thực hiện ước lượng các mô hình khác nhau với các biến khác nhau, và nhận xét về tỷ lệ rủi ro tương đối trong mỗi mô hình.

Thực hành 2: Hàm

```
relevel(x, ref)
```

được dùng để tạo một biến mới có nhóm tham chiếu được thay đổi so với biến định tính (nhân tố) ban đầu, trong đó, `x` là vector của biến định tính, `ref` là tên của nhóm được dùng làm nhóm tham chiếu. Ví dụ:

```
party2 <- relevel(party, ref = "Independent")
```

tạo ra biến mới `party2` là bản sao của `party` nhưng với nhóm tham chiếu là "Independent".

Thực hiện ước lượng các mô hình multinomial logistic với nhóm tham chiếu lần lượt là "Independent" và "Republican".

1.2 Kiểm định từng hệ số

Tiếp theo, ta thực hiện kiểm định cho từng hệ số

$$\begin{cases} H_0 : \beta_{jk} = 0 \\ H_1 : \beta_{jk} \neq 0 \end{cases}$$

Vì hàm `summary()` không xuất ra p -value cho kiểm định này (không thực hiện), do đó, ta sẽ cần phải áp dụng công thức lý thuyết:

```
res_coef_md_party_1 <- coef(out_md_party_1)
z_md_party_1 <- res_coef_md_party_1 / summary(out_md_party_1)$standard.errors
p_md_party_1 <- (1 - pnorm(abs(z_md_party_1), 0, 1)) * 2
print(p_md_party_1, 4L)
```

```
##           (Intercept)    income2
## Independent  2.021e-14  1.652e-08
## Republican   1.980e-11  2.747e-11
```

Kết quả cho thấy p -value của các hệ số là rất nhỏ, đồng nghĩa với việc giá trị thực sự của chúng khác 0. Điều này dẫn tới tỷ số rủi ro tương đối là thực sự khác 1, hay sự cao hơn của tỷ lệ đảng viên Independent hoặc Republican so với tỷ lệ đảng viên đảng Democrat là có ý nghĩa thống kê.

Thực hành 3: Thực hiện kiểm định hệ số cho mỗi mô hình được xây dựng trong phần thực hành 1.

1.3 Tiên đoán và minh họa

Tiếp theo, ta sẽ minh họa tỷ lệ ước lượng theo các giá trị tăng dần của tiền lương `income2`. Trước tiên, ta tạo một dữ liệu mới với các giá trị mới của tiền lương, tăng dần từ 0 tới 115, và tiên giá trị tỷ lệ tương ứng:

```
inclevels <- seq(0, 115, by = 1)
probs_party_md_1 <- predict(out_md_party_1,
                             newdata = data.frame(income2 = inclevels),
                             type = "probs")
head(probs_party_md_1)
```

```
##      Democrat Independent Republican
## 1 0.5898168   0.1821588   0.2280244
## 2 0.5857064   0.1838228   0.2304708
## 3 0.5815839   0.1854890   0.2329271
```

```
## 4 0.5774498 0.1871572 0.2353929
## 5 0.5733047 0.1888271 0.2378682
## 6 0.5691492 0.1904984 0.2403524
```


Kết quả thu được là tỷ lệ đảng viên của ba đảng, được ước lượng thông qua mô hình. Tiếp theo ta thiết lập bảng dữ liệu để vẽ biểu đồ:

```
preds_md_1 <- data.frame(income2 = inclevels, probs_party_md_1)
lpred_md_1 <- gather(preds_md_1, party, probability, -income2)
head(lpred_md_1)
```

```
##   income2   party probability
## 1      0 Democrat  0.5898168
## 2      1 Democrat  0.5857064
## 3      2 Democrat  0.5815839
## 4      3 Democrat  0.5774498
## 5      4 Democrat  0.5733047
## 6      5 Democrat  0.5691492
```

Tỷ lệ đảng viên của 3 đảng được miêu tả như sau:

```
ggplot(lpred_md_1, aes(x = income2, y = probability, group = party,
                        linetype = party)) +
  geom_line() +
  theme_bw() +
  theme(legend.position = "bottom")
```



Để xác định khoảng tin cậy cho tỷ lệ của các nhóm ta tiến hành như sau. Đầu tiên, xác định ma trận hiệp phương sai của ước lượng hệ số (tức là nghịch đảo của ma trận thông tin Fisher - Hessian):

```
out_var_md_party_1 <- solve(out_md_party_1$Hessian)
```

kết quả là

```
out_var_md_party_1
```

```
##               Independent:(Intercept) Independent:income2
## Independent:(Intercept)           0.0235961379          -3.649339e-04
## Independent:income2              -0.0003649339           8.121008e-06
## Republican:(Intercept)           0.0086299233          -1.564411e-04
## Republican:income2              -0.0001561773           4.084232e-06
##               Republican:(Intercept) Republican:income2
## Independent:(Intercept)           0.0086299233          -1.561773e-04
## Independent:income2              -0.0001564411           4.084232e-06
## Republican:(Intercept)           0.0200748999          -3.134693e-04
## Republican:income2              -0.0003134693           7.035928e-06
```

nếu ta lấy căn bậc hai của các phần tử trên đường chéo, ta thu được sai số chuẩn của các hệ số (như kết quả ở trong hàm `summary()`).

Tiếp theo, ta áp dụng công thức Delta method để xác định phương sai của $\eta_j(\mathbf{x})$. Giả sử rằng, ta có `income2` = 30,000\$, khi đó,

```
z_md_1_30 <- c(1, 30)
eta_est_md_1_30 <- z_md_1_30 %>% t(res_coef_md_party_1)
```

Kết quả là

```
eta_est_md_1_30
```

```
##      Independent Republican
## [1,] -0.6923281 -0.4204218
```

phương sai của chúng được xác định bởi

```
var_eta_2_md_1_30 <- as.numeric(
  z_md_1_30 %>% out_var_md_party_1[1:2, 1:2] %>% z_md_1_30
)
var_eta_3_md_1_30 <- as.numeric(
  z_md_1_30 %>% out_var_md_party_1[3:4, 3:4] %>% z_md_1_30
)
```

Khoảng tin cậy 95% cho $\eta_j(\mathbf{x})$ là

```
ci_eta_2_md_1_30 <- eta_est_md_1_30[1] + c(-1, 1)*
  qnorm((1 + 0.95)/2)*sqrt(var_eta_2_md_1_30)
ci_eta_3_md_1_30 <- eta_est_md_1_30[2] + c(-1, 1)*
  qnorm((1 + 0.95)/2)*sqrt(var_eta_3_md_1_30)
```

kết quả lần lượt là

```
ci_eta_2_md_1_30
```

```
## [1] -0.8783597 -0.5062966
```

và

```
ci_eta_3_md_1_30
```

```
## [1] -0.5912771 -0.2495665
```

Từ đây ta tính được khoảng tính được khoảng tin cậy 95% cho các tỷ lệ của các nhóm như sau

```

ci_pi_2_md_1 <- c(exp(ci_eta_2_md_1_30[1]) /
  (1 + exp(ci_eta_2_md_1_30[1]) + exp(ci_eta_3_md_1_30[1])),
  exp(ci_eta_2_md_1_30[2]) /
  (1 + exp(ci_eta_2_md_1_30[2]) + exp(ci_eta_3_md_1_30[2])))
ci_pi_3_md_1 <- c(exp(ci_eta_3_md_1_30[1]) /
  (1 + exp(ci_eta_2_md_1_30[1]) + exp(ci_eta_3_md_1_30[1])),
  exp(ci_eta_3_md_1_30[2]) /
  (1 + exp(ci_eta_2_md_1_30[2]) + exp(ci_eta_3_md_1_30[2])))
ci_pi_1_md_1 <- 1 - (ci_pi_2_md_1 + ci_pi_3_md_1)

```

kết quả lần lượt là, cho đảng Democrat

```
rev(ci_pi_1_md_1)
```

```
## [1] 0.4198396 0.5078505
```

cho đảng Independent

```
ci_pi_2_md_1
```

```
## [1] 0.2109935 0.2530472
```

cho đảng Republican

```
ci_pi_3_md_1
```

```
## [1] 0.2811561 0.3271132
```

Thực hành 4: Xác định khoảng tin cậy 95% cho các hệ số β_{j1} , từ đó xác định khoảng tin cậy cho tỷ số rủi ro tương đối trong các nhóm.

Thực hành 5: Thực hiện tiên đoán tỷ lệ và khoảng tin cậy 95% cho tỷ lệ trong các trường hợp `income2 = 6,000 $, 65,000$ và 95,000$`.

Thực hành 6: Thực hiện tiên đoán tỷ lệ và khoảng tin cậy 95% cho tỷ lệ trong các trường hợp khác nhau của biến tiên đoán, tương ứng các mô hình được xây dựng trong thực hành 1.

1.4 Độ chính xác trong tiên đoán nhóm

Sau khi ước lượng được tỷ lệ của mỗi nhóm, ta sẽ có thể tiên đoán được nhóm của một người cụ thể, thông qua quy tắc sau

$$\hat{Y}(\mathbf{x}) = \arg \max_{j=1,\dots,K} \hat{\pi}_j(\mathbf{x}),$$

tức là nhóm có tỷ lệ (xác suất) cao nhất. Việc tiên đoán nhóm được thực hiện dễ dàng thông qua hàm

```
predict(x, newdata, type = "class")
```

Với dữ liệu và mô hình ta đang phân tích, các nhóm được tiên đoán như sau:

```
pred_party_md_1 <- predict(out_md_party_1, type = "class")
```

Với kết quả này, ta có thể so sánh với nhóm đảng viên thực tế:

```
conf_mat_md_1 <- xtabs( ~ pred_party_md_1 + nes96$party)
conf_mat_md_1
```

```
##               nes96$party
## pred_party_md_1 Democrat Independent Republican
##      Democrat      284      123      166
```

##	Independent	0	0	0
##	Republican	96	116	159

Kết quả cho thấy,

- không có người nào thuộc đảng **Independent** được tiên đoán chính xác là thành viên của đảng, thay vào đó, những người này được tiên đoán như là thành viên của đảng **Democrat** hoặc **Republican**;
- mô hình chỉ có thể tiên đoán được hai nhóm đảng **Democrat** và **Republican**.

Tỷ lệ tiên đoán (phân loại) chính xác của mô hình là

```
(284 + 0 + 159) / nrow(nes96)
```

```
## [1] 0.4692797
```

khoảng 46.93%, quá thấp để có thể tin tưởng.

Thực hành 7: Thực hiện đánh giá khả năng tiên đoán của các mô hình được xây dựng trong thực hành 1.

2 Bài tập

Bài tập 1: Dữ liệu **hsb** trong thư viện **faraway** được thu thập như một phần của nghiên cứu High School and Beyond, được thực hiện bởi chương trình National Education Longitudinal Studies của National Center for Education Statistics. Các biến bao gồm:

- **gender**: giới tính (**male**/ **female**);
- **race**: chủng tộc (**african-amer**, **asian**, **hispanic**, **white**);
- **ses**: trạng thái kinh tế xã hội - socioeconomic status;
- **schttyp**: kiểu trường công lập hay trường tư;
- **prog**: loại chương trình học cấp ba (**academic** - học thuật, **vocation** - nghề nghiệp; hoặc **general** - chung);
- **read**: điểm thi đọc;
- **write**: điểm thi viết;
- **math**: điểm thi toán;
- **science**: điểm thi các môn khoa học;
- **socst**: điểm thi môn khoa học xã hội.

Mục tiêu là xác định những yếu tố nào liên quan đến việc lựa chọn loại chương trình học **prog** mà học sinh theo đuổi trong trường trung học. Phản hồi là đa định danh với ba nhóm.

```
data(hsb, package = "faraway")
head(hsb)
```

##	id	gender	race	ses	schttyp	prog	read	write	math	science	socst
## 1	70	male	white	low	public	general	57	52	41	47	57
## 2	121	female	white	middle	public	vocation	68	59	53	63	61
## 3	86	male	white	high	public	general	44	33	54	58	31
## 4	141	male	white	high	public	vocation	63	44	47	53	56
## 5	172	male	white	middle	public	academic	47	52	57	53	61
## 6	113	male	white	middle	public	academic	44	52	51	63	61

Làm các yêu cầu/câu hỏi dưới đây:

- (a) Lập bảng thể hiện tỷ lệ nam và nữ chọn ba chương trình khác nhau. Bình luận về sự khác biệt. Lập lại sự so sánh này nhưng đối với **ses** chứ không phải **gender**.
- (b) Xây dựng một biểu đồ thể hiện mối quan hệ giữa lựa chọn chương trình và điểm đọc. Nhận xét về kết quả. Lập lại môn toán thay cho bài đọc.
- (c) Tính ma trận tương quan cho điểm thi của 5 môn.
- (d) Ước lượng mô hình multinomial logistic cho việc lựa chọn chương trình và điểm thi của 5 môn. Trong 5 môn này, có một môn cho hệ số ngoài kỳ vọng. Xác định môn thi này và đề xuất một giải thích phù hợp.
- (e) Xây dựng một biến mới là tổng của năm điểm môn thi. Ước lượng mô hình multinomial logistic như trước nhưng sử dụng biến tổng này thay cho điểm năm môn thi riêng biệt. So sánh hai mô hình để quyết định nên ưu tiên mô hình nào.
- (f) Xây dựng biểu đồ xác suất dự đoán từ mô hình ban đầu trong đó điểm toán thay đổi trong phạm vi quan sát được. Các yếu tố dự đoán khác nên được đặt ở mức phổ biến nhất hoặc giá trị trung bình nếu phù hợp. Nhận xét về mối quan hệ.
- (g) Tính bảng xác suất dự đoán được phân loại chéo theo **ses** và **schtyp**. Cố định các yếu tố dự đoán khác ở giá trị trung bình của chúng. Nhận xét về mối liên hệ giữa **ses** và **schtyp** tới sự lựa chọn.
- (h) Tính kết quả dự đoán cho học sinh có ID 99. Thực tế học sinh này đã chọn gì?
- (i) Xây dựng một bảng gồm các kết quả dự đoán có khả năng xảy ra nhất và các kết quả quan sát được. Trong trường hợp nào thì kết quả được dự đoán và quan sát giống nhau?