

Bài giảng R, số 8

-Mô hình hồi quy Poisson-

TS.Tô Đức Khánh

16/06/2024

1 Thao tác cơ bản

1.1 Ước lượng mô hình

Mô hình Poisson (log-linear model, rate models):

$$\log\left(\frac{\mu_i}{t_i}\right) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

hay tương đương,

$$\log(\mu_i) = \log(t_i) + \beta_0 + \beta_1 X_{1i} + \dots + \beta_q X_{qi},$$

thành phần $\log(t_i)$ được gọi là **offset**. Thành phần offset có thể bằng 0 trong trường hợp không cần thiết.

Trong R, để ước lượng mô hình hồi quy logistic, ta sử dụng hàm `glm()` như sau:

```
glm(formula = y ~ x1 + x2 + ..., data = ..., family = poisson(link = "log"),
    offset = ..., ...)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng, `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `offset` là tên của biến được chỉ định là thành phần offset trong công thức;
- `...` là các đối số thêm, được sử dụng trong các trường hợp cụ thể.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `exp(coef())`: ước lượng tỷ số tăng/giảm của trung bình khi một biến thay đổi 1 đơn vị, và các biến còn lại được giữ là hằng số;
- `confint.default()`: xác định khoảng tin cậy cho hệ số trong mô hình;
- `exp(confint.default())`: khoảng tin cậy cho tỷ số tăng/giảm của trung bình khi một biến thay đổi 1 đơn vị, và các biến còn lại được giữ là hằng số;
- `predict(x, newdata, type = "response")`: tiên đoán giá trị trung bình biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến hồi quy;
- `predict(x, newdata, type = "link")`: tiên đoán giá trị của thành phần tuyến tính dựa vào một hoặc nhiều giá trị được cho trước của các biến hồi quy.

Ví dụ 1: Ta phân tích bộ dữ liệu `gala` được cung cấp trong thư viện `faraway`. Dữ liệu được thu thập trong một nghiên cứu về tính đa dạng sinh học của các đảo thuộc quần đảo Galápagos, Ecuador.

```
data(gala, package = "faraway")
gala <- gala |> janitor::clean_names()
glimpse(gala)
```


```
## Rows: 30
## Columns: 7
## $ species    <dbl> 58, 31, 3, 25, 2, 18, 24, 10, 8, 2, 97, 93, 58, 5, 40, 347, 51, 2~
## $ endemics   <dbl> 23, 21, 3, 9, 1, 11, 0, 7, 4, 2, 26, 35, 17, 4, 19, 89, 23, 2, 37~
## $ area       <dbl> 25.09, 1.24, 0.21, 0.10, 0.05, 0.34, 0.08, 2.33, 0.03, 0.18, 58.2~
## $ elevation  <dbl> 346, 109, 114, 46, 77, 119, 93, 168, 71, 112, 198, 1494, 49, 227, ~
## $ nearest    <dbl> 0.6, 0.6, 2.8, 1.9, 1.9, 8.0, 6.0, 34.1, 0.4, 2.6, 1.1, 4.3, 1.1, ~
## $ scruc      <dbl> 0.6, 26.3, 58.7, 47.4, 1.9, 8.0, 12.0, 290.2, 0.4, 50.2, 88.3, 95~
## $ adjacent   <dbl> 1.84, 572.33, 0.78, 0.18, 903.82, 1.84, 0.34, 2.85, 17.95, 0.10, ~
```

Ta muốn tìm ra một mô hình dựa đoán trung bình số loài thực vật ở trên 30 đảo dựa vào:

- diện tích (`area`), đơn vị km^2 ;
- chiều cao tối đa của đảo (`elevation`), đơn vị m;
- khoảng cách tới đảo gần nhất (`nearest`), đơn vị km;
- khoảng cách tới đảo Santa Cruz (`scruc`), đơn vị km;
- diện tích của đảo liền kề (`adjacent`), đơn vị km^2 .

Để dễ hình dung sự liên hệ giữa số lượng loài thực vật và diện tích (`area`) của đảo cũng như chiều cao `elevation` của đảo, ta vẽ biểu đồ phân tán.

```
ggplot(data = gala, mapping = aes(x = area, y = species, group = elevation)) +
  geom_point(mapping = aes(size = elevation)) +
  scale_radius(name = "Elevation") +
  labs(x = "Area", y = "Number of plant species") +
  theme_bw() +
  theme(legend.position = "bottom")
```



Thông qua biểu đồ ta thấy xu hướng chung rằng diện tích lớn thì số lượng loài thực vật cũng tăng theo, và với chiều cao của đảo thì ta cũng có xu hướng tương tự.

Bây giờ, ta sẽ xây dựng mô hình dựa trên thông tin này và có thêm các biến còn lại vào mô hình:

$$\log(\mu_i) = \beta_0 + \beta_1 \text{area} + \beta_2 \text{elevation} + \beta_3 \text{nearest} + \beta_4 \text{scrutz} + \beta_5 \text{adjacent}.$$

Mô hình ước lượng như sau:

```
out_gala_pois <- glm(species ~ area + elevation + nearest + scrutz + adjacent,
                     family = poisson(link = "log"), data = gala)
```

Kết quả ước lượng mô hình

```
out_gala_pois
```

```
##
## Call:  glm(formula = species ~ area + elevation + nearest + scrutz +
##       adjacent, family = poisson(link = "log"), data = gala)
##
## Coefficients:
## (Intercept)      area      elevation      nearest      scrutz      adjacent
##  3.1548079    -0.0005799    0.0035406    0.0088256   -0.0057094   -0.0006630
##
## Degrees of Freedom: 29 Total (i.e. Null);  24 Residual
## Null Deviance:      3511
## Residual Deviance: 716.8    AIC: 889.7
```

Để hiểu rõ hơn về ý nghĩa của các hệ số, ta tính $\exp()$ của các ước lượng hệ số, cũng chính là số lần tăng/giảm của trung bình theo từng biến khi biến đó tăng lên 1 đơn vị và các biến còn lại được giữ là hằng số:

```
exp(coef(out_gala_pois))
```

```
## (Intercept)      area      elevation      nearest      scrutz      adjacent
## 23.4485317    0.9994202    1.0035469    1.0088646    0.9943068    0.9993372
```

Kết quả cho ta một số nhận xét sau:

- trung bình số lượng loài thực vật giảm dần khi diện tích của đảo - **area** tăng lên (một kết luận có vẻ lạ lùng!);
- trung bình số lượng loài thực vật tăng lên khi chiều cao của đảo - **elevation** tăng lên (tức là thực vật phát triển theo chiều cao);
- khi diện tích của đảo - **area** tăng 10km², thì số lượng loài thực vật sẽ giảm đi $\exp(-5.799 \times 10^{-4} \times 10) = 0.9942$ lần, hay 0.58%;
- khi chiều cao tối đa của đảo - **elevation** tăng lên 50m, thì số lượng loài thực vật trên đảo đó sẽ cao gấp $\exp(3.541 \times 10^{-3} \times 50) = 1.1937$ lần, hay tương đương với 19.37%;
- nếu khoảng cách tới đảo gần nhất tăng lên thì số loài thực vật cũng tăng lên; chẳng hạn, nếu khoảng cách này tăng lên 20km thì trung bình số loài thực vật trên đảo sẽ tăng lên khoảng $\exp(0.0088256 \times 20) = 1.1931$ lần, hay 19.31%.

Mã trận hiệp phương sai của các ước lượng hệ số được truy xuất bởi hàm `vcov()`:

```
vcov(out_gala_pois)
```

```
##              (Intercept)      area      elevation      nearest      scrutz
## (Intercept)  2.678012e-03  6.967361e-07 -3.541266e-06 -2.942660e-06 -8.541145e-06
## area        6.967361e-07  6.902694e-10 -1.974574e-09  6.683931e-09  6.107465e-10
## elevation   -3.541266e-06 -1.974574e-09  7.639990e-09 -1.300429e-08  6.194387e-10
```

```
## nearest      -2.942660e-06  6.683931e-09 -1.300429e-08  3.316988e-06 -7.288453e-07
## scruez       -8.541145e-06  6.107465e-10  6.194387e-10 -7.288453e-07  3.914004e-07
## adjacent     5.854186e-07  2.700065e-10 -1.288214e-09  1.582451e-08 -6.043617e-09
##              adjacent
## (Intercept)  5.854186e-07
## area         2.700065e-10
## elevation    -1.288214e-09
## nearest      1.582451e-08
## scruez       -6.043617e-09
## adjacent     8.601045e-10
```

Từ đây, ta suy ra được, sai số chuẩn (standard error) của các ước lượng hệ số:

```
sqrt(diag(vcov(out_gala_pois)))
```

```
## (Intercept)      area      elevation      nearest      scruez      adjacent
## 5.174952e-02 2.627298e-05 8.740704e-05 1.821260e-03 6.256200e-04 2.932754e-05
```

Thực hành 1: xét mô hình với biến đổi $\log(\text{area})$:

- (a) vẽ biểu đồ mô tả sự thay đổi của trung bình số loài thực vật trên đảo theo $\log(\text{area})$ và elevation ;
- (b) ước lượng mô hình với $\log(\text{area})$ và các biến còn lại.

1.2 Kiểm định từng hệ số

Tiếp theo, ta thực hiện kiểm định cho từng hệ số

$$\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$$

Kết quả kiểm định được trả về bởi hàm `summary()`

```
summary(out_gala_pois)
```

```
##
## Call:
## glm(formula = species ~ area + elevation + nearest + scruez +
##      adjacent, family = poisson(link = "log"), data = gala)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  3.155e+00  5.175e-02  60.963 < 2e-16 ***
## area        -5.799e-04  2.627e-05 -22.074 < 2e-16 ***
## elevation    3.541e-03  8.741e-05  40.507 < 2e-16 ***
## nearest      8.826e-03  1.821e-03   4.846 1.26e-06 ***
## scruez       -5.709e-03  6.256e-04  -9.126 < 2e-16 ***
## adjacent    -6.630e-04  2.933e-05 -22.608 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 3510.73  on 29  degrees of freedom
## Residual deviance:  716.85  on 24  degrees of freedom
## AIC: 889.68
```

```
##
## Number of Fisher Scoring iterations: 5
```

Kết quả cho thấy, tại mức ý nghĩa 5%, tất cả các biến đều có ý nghĩa trong việc ước lượng mô hình.

Thực hành 2: Thực hiện kiểm định hệ số cho mô hình được xây dựng trong phần thực hành 1. Nhận xét và so sánh kết quả.

1.3 Khoảng tin cậy cho hệ số và tỷ số cược chênh lệch

Khoảng tin cậy cho hệ số được xây dựng dựa trên xấp xỉ chuẩn, thu được bởi hàm `confint.default`, ví dụ khoảng tin cậy 95% cho các hệ số của mô hình Poisson log-linear:

```
confint.default(out_gala_pois, level = 0.95)
```

```
##                2.5 %        97.5 %
## (Intercept)  3.053380689  3.2562350672
## area        -0.000631437 -0.0005284488
## elevation    0.003369279  0.0037119087
## nearest      0.005255968  0.0123951759
## scruez       -0.006935615 -0.0044832296
## adjacent     -0.000720512 -0.0006055501
```

Từ đây, ta thu được khoảng tin cậy cho số lần tăng/giảm của trung bình theo từng biến khi biến đó tăng lên 1 đơn vị và các biến còn lại được giữ là hằng số, thông qua lấy `exp()` cho các điểm giới hạn của khoảng tin cậy cho hệ số mô hình.

```
exp(confint.default(out_gala_pois, level = 0.95))
```

```
##                2.5 %        97.5 %
## (Intercept) 21.1868496 25.9516468
## area         0.9993688  0.9994717
## elevation    1.0033750  1.0037188
## nearest      1.0052698  1.0124723
## scruez       0.9930884  0.9955268
## adjacent     0.9992797  0.9993946
```

Tất nhiên, ta chỉ quan tâm tới khoảng tin cậy cho các hệ số của các biến hồi quy.

Thực hành 3: Xác định khoảng tin cậy 95% cho số lần tăng/giảm của trung bình trong các trường hợp sau:

- (a) diện tích đảo tăng lên 10km²;
- (b) chiều cao tối đa của đảo tăng 50m.

Thực hành 4: Lập lại thao tác trong thực hành 3 đối với mô hình trong thực hành 2.

1.4 Tiên đoán và minh họa

Giả sử ta có thông tin của đảo Espanola

```
gala["Espanola",]
```

```
##      species endemics  area elevation nearest scruez adjacent
## Espanola      97      26 58.27      198      1.1  88.3      0.57
```

và ta mong muốn tiên đoán số lượng loài thực vật trên đảo này, dựa vào mô hình Poisson log-linear:

```
predict(out_gala_pois, newdata = gala["Espanola", ], type = "response")
```

```
## Espanola  
## 27.86135
```

kết quả cho thấy mô hình ta đã xây dựng ước lượng thấp trung bình số loài thực vật trên đảo Espanola (thực tế là 97 loài).

Khoảng tin cậy cho trung bình ước lượng từ mô hình Poisson log-linear được xây dựng như sau. Đầu tiên, ta ước tính $\hat{\eta}(\mathbf{x})$ kèm theo sai số chuẩn (được tính dựa theo Delta method):

```
out_fit_1 <- predict(out_gala_pois, newdata = gala["Espanola", ],  
                    type = "link", se.fit = TRUE)  
out_fit_1
```

```
## $fit  
## Espanola  
## 3.32724  
##  
## $se.fit  
## [1] 0.05509451  
##  
## $residual.scale  
## [1] 1
```

Từ kết quả này, ta tính được khoảng tin cậy 95% cho $\eta(\mathbf{x})$:

```
ci_out_fit_1 <- out_fit_1$fit + c(-1, 1)*out_fit_1$se.fit*qnorm((1 + 0.95)/2)  
ci_out_fit_1
```

```
## [1] 3.219257 3.435224
```

Thực hiện lấy $\exp(\cdot)$ cho hai điểm giới hạn, ta thu được khoảng tin cậy 95% cho trung bình số loài thực vật trên đảo Espanola

```
exp(ci_out_fit_1)
```

```
## [1] 25.00954 31.03835
```

Một lần nữa kết quả này cho thấy mô hình được xây dựng ước lượng thấp trung bình số loài thực vật.

Thực hành 5: Hãy xác định giá trị tiên đoán và khoảng tin cậy cho trung bình số loài thực vật trên đảo Espanola, dựa trên mô hình Poisson log-linear được xây dựng trong Thực hành 2. So sánh với kết quả trước đó.

Thực hành 6: Sử dụng hai mô hình đã được xây dựng, hãy xác định giá trị tiên đoán và khoảng tin cậy cho trung bình số loài thực vật trên một số đảo được chọn ngẫu nhiên. So sánh kết quả thu được theo hai mô hình.

1.5 So sánh mô hình lồng nhau

Sau khi ước lượng mô hình, ta thường quan tâm tới câu hỏi rằng, liệu rằng các biến giải thích có thực sự cần thiết cho mô hình trong thực tế. Câu hỏi này tương đương:

1. H_0 : Mô hình với chỉ hệ số chặn, $\log(\mu_i) = \beta_0$
2. H_1 : Thêm biến giải thích X_j vào mô hình là phù hợp.

Ta kiểm chứng thông qua việc sử dụng log-likelihood Chi-square test:

```
anova(out_gala_pois, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model: poisson, link: log
##
## Response: species
##
## Terms added sequentially (first to last)
##
##
```

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			29	3510.7	
area	1	895.14	28	2615.6	< 2.2e-16 ***
elevation	1	802.05	27	1813.5	< 2.2e-16 ***
nearest	1	15.71	26	1797.8	7.378e-05 ***
scrutz	1	456.37	25	1341.5	< 2.2e-16 ***
adjacent	1	624.61	24	716.8	< 2.2e-16 ***

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Kết quả cho thấy các biến giải thích là cần thiết cho mô hình.

```
out_gala_pois_2 <- glm(species ~ area + elevation + nearest,
                        family = poisson(link = "log"), data = gala)
summary(out_gala_pois_2)
```

```
##
## Call:
## glm(formula = species ~ area + elevation + nearest, family = poisson(link = "log"),
##      data = gala)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  3.548e+00  3.933e-02  90.211  < 2e-16 ***
## area        -5.529e-05  1.890e-05  -2.925  0.00344 **
## elevation    1.588e-03  5.040e-05  31.502  < 2e-16 ***
## nearest      5.921e-03  1.466e-03   4.039  5.38e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##      Null deviance: 3510.7  on 29  degrees of freedom
## Residual deviance: 1797.8  on 26  degrees of freedom
## AIC: 1966.7
##
## Number of Fisher Scoring iterations: 5
```

```
anova(out_gala_pois_2, out_gala_pois)
```

```
## Analysis of Deviance Table
##
## Model 1: species ~ area + elevation + nearest
## Model 2: species ~ area + elevation + nearest + scrutz + adjacent
##      Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
```

```
## 1      26    1797.83
## 2      24     716.85  2    1081 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```