

Chương 6: Hồi quy tuyến tính

Hoàng Văn Hà
University of Science, VNU - HCM
hvha@hcmus.edu.vn

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Giới thiệu về hồi quy

- **Hồi quy (Regression)** là quá trình đi tìm mối liên hệ giữa các tập dữ liệu đầu vào (input data) $\{x_1, \dots, x_n\}$ và tập dữ liệu đầu ra (output data) $\{y_1, \dots, y_n\}$.

Giới thiệu về hồi quy

- **Hồi quy (Regression)** là quá trình đi tìm mối liên hệ giữa các tập dữ liệu đầu vào (input data) $\{x_1, \dots, x_n\}$ và tập dữ liệu đầu ra (output data) $\{y_1, \dots, y_n\}$.
- Ta gọi tập các cặp dữ liệu vào - ra $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ này là **tập dữ liệu huấn luyện (training data)**.

Giới thiệu về hồi quy

- **Hồi quy (Regression)** là quá trình đi tìm mối liên hệ giữa các tập dữ liệu đầu vào (input data) $\{x_1, \dots, x_n\}$ và tập dữ liệu đầu ra (output data) $\{y_1, \dots, y_n\}$.
- Ta gọi tập các cặp dữ liệu vào - ra $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ này là **tập dữ liệu huấn luyện (training data)**.
- Ta có thể mô tả mối quan hệ chưa biết này như một hàm $f(\cdot)$ với

$$y_i = f(x_i).$$

Giới thiệu về hồi quy


- **Hồi quy (Regression)** là quá trình đi tìm mối liên hệ giữa các tập dữ liệu đầu vào (input data) $\{x_1, \dots, x_n\}$ và tập dữ liệu đầu ra (output data) $\{y_1, \dots, y_n\}$.
- Ta gọi tập các cặp dữ liệu vào - ra $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ này là **tập dữ liệu huấn luyện (training data)**.
- Ta có thể mô tả mối quan hệ chưa biết này như một hàm $f(\cdot)$ với

$$y_i = f(x_i).$$

Giới thiệu về hồi quy

- **Hồi quy (Regression)** là quá trình đi tìm mối liên hệ giữa các tập dữ liệu đầu vào (input data) $\{x_1, \dots, x_n\}$ và tập dữ liệu đầu ra (output data) $\{y_1, \dots, y_n\}$.
- Ta gọi tập các cặp dữ liệu vào - ra $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ này là **tập dữ liệu huấn luyện (training data)**.
- Ta có thể mô tả mối quan hệ chưa biết này như một hàm $f(\cdot)$ với

$$y_i = f(x_i).$$



Hình ảnh: Introduction to Probability for Data Science, Stanley H. Chan.

Giới thiệu về hồi quy

- Vì f không biết, việc tìm nó từ một tập hữu hạn các điểm dữ liệu $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ là không thể, vì ta có rất nhiều cách để làm cho $y_i = f(x_i)$, $i = 1, \dots, n$.

Giới thiệu về hồi quy

- Vì f không biết, việc tìm nó từ một tập hữu hạn các điểm dữ liệu $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ là không thể, vì ta có rất nhiều cách để làm cho $y_i = f(x_i)$, $i = 1, \dots, n$.
- Ý tưởng của hồi quy là ta thêm một cấu trúc (structure) vào bài toán. Chẳng hạn, thay vì đi tìm f ta tìm một hàm ủy nhiệm g_θ với θ là một véc-tơ tham số.

Giới thiệu về hồi quy

- Vì f không biết, việc tìm nó từ một tập hữu hạn các điểm dữ liệu $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$ là không thể, vì ta có rất nhiều cách để làm cho $y_i = f(x_i)$, $i = 1, \dots, n$.
- Ý tưởng của hồi quy là ta thêm một cấu trúc (structure) vào bài toán. Chẳng hạn, thay vì đi tìm f ta tìm một hàm ủy nhiệm g_θ với θ là một véc-tơ tham số.
- Trong trường hợp g_θ có dạng tham số, ta có mối quan hệ tuyến tính

$$g_\theta(x_i) = \theta_0 + \theta_1 x_i, \quad i = 1, \dots, n.$$

Ta gọi $\theta = [\theta_0, \theta_1]$ là **tham số (parameter)** của mô hình $f(\cdot)$, và hàm g_θ được **tham số hóa (parameterized)** bởi θ .

Giới thiệu về hồi quy

- Hàm g_{θ} mà ta chọn ở đây chỉ là một dự đoán của mô hình $f(\cdot)$. Luôn luôn tồn tại một sai số e_i được định nghĩa bởi

$$e_i = y_i - g_{\theta}(x_i), \quad i = 1, \dots, n.$$

Giới thiệu về hồi quy

- Hàm g_{θ} mà ta chọn ở đây chỉ là một dự đoán của mô hình $f(\cdot)$. Luôn luôn tồn tại một sai số e_i được định nghĩa bởi

$$e_i = y_i - g_{\theta}(x_i), \quad i = 1, \dots, n.$$

- Mục đích của hồi quy là đi tìm θ tốt nhất để sai số này là nhỏ nhất. Chẳng hạn, ta có thể xét sự cực tiểu hóa sử dụng tổng bình phương sai số:

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^d} \sum_{i=1}^n (y_i - g_{\theta}(x_i))^2.$$

Giới thiệu về hồi quy

- Hàm g_θ mà ta chọn ở đây chỉ là một dự đoán của mô hình $f(\cdot)$. Luôn luôn tồn tại một sai số e_i được định nghĩa bởi


$$e_i = y_i - g_\theta(x_i), \quad i = 1, \dots, n.$$

- Mục đích của hồi quy là đi tìm θ tốt nhất để sai số này là nhỏ nhất. Chẳng hạn, ta có thể xét sự cực tiểu hóa sử dụng tổng bình phương sai số:

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^d} \sum_{i=1}^n (y_i - g_\theta(x_i))^2.$$

- Ta gọi tổng bình phương sai số là **Tổn thất huấn luyện (Training loss)**. Với một tập dữ liệu cho trước $\mathcal{D} := \{(x_1, y_1), \dots, (x_n, y_n)\}$, hồi quy tìm một hàm g_θ sao cho tổn thất huấn luyện đạt cực tiểu. Biến tối ưu ở đây chính là véc-tơ tham số θ . Nếu g_θ là hàm tuyến tính của θ , ta gọi hồi quy này là **hồi quy tuyến tính (linear regression)**.

Minh họa về bài toán hồi quy:



Hình ảnh: Introduction to Probability for Data Science, Stanley H. Chan.

Hồi quy là gì


Cho trước các điểm dữ liệu $(x_1, y_1), \dots, (x_n, y_n)$, hồi quy là quá trình đi tìm tham số θ của hàm $g_\theta(\cdot)$ sao cho tổn thất huấn luyện đạt cực tiểu:

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^d} \sum_{i=1}^n \mathcal{L}(y_i, g_\theta(x_i)),$$

với $\mathcal{L}(\cdot, \cdot)$ là hàm tổn thất giữa một giá trị quan trắc thực y_i và giá trị dự đoán $\hat{y}_i := g_\theta(x_i)$. Một lựa chọn phổ biến của $\mathcal{L}$ là $\mathcal{L}(x, y) = (x - y)^2$.

Ví dụ 1

Cho các điểm dữ liệu $(x_1, y_1), \dots, (x_n, y_n)$ mô tả bởi đồ thị phân tán




Ta cần tìm một đường cong mà mô tả tốt nhất cho tập dữ liệu. Ta có thể chọn một hàm đa thức bậc p như sau

$$g_{\theta}(x_i) = \theta_0 + \theta_1 x_1 + \theta_2 x_2^2 + \dots + \theta_p x_p^p.$$

Các hệ số $\theta = [\theta_0, \theta_1, \dots, \theta_p]$ được gọi là các **Hệ số hồi quy (regression coefficients)**.


Ví dụ 1



Các hệ số hồi quy $\theta = [\theta_0, \theta_1, \dots, \theta_p]$ được tìm bởi việc giải bài toán tối ưu sau

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^p} \sum_{i=1}^n \left(y_i - (\theta_0 + \theta_1 x_1 + \theta_2 x_2^2 + \dots + \theta_p x_p^p) \right)^2.$$

Ví dụ 1



Các hệ số hồi quy $\theta = [\theta_0, \theta_1, \dots, \theta_p]$ được tìm bởi việc giải bài toán tối ưu sau

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^p} \sum_{i=1}^n \left(y_i - (\theta_0 + \theta_1 x_1 + \theta_2 x_2^2 + \dots + \theta_p x_p^p) \right)^2.$$

Đường cong ướm (fitted curve) trong hình trên được tìm bởi việc lựa chọn một đa thức bậc 4.

Ví dụ 2: Dự đoán thị trường cổ phiếu

- **Bài toán:** giả sử rằng ta đã mua một số cổ phiếu trên thị trường chứng khoán. Dựa vào các dữ liệu quá khứ, ta muốn dự đoán xem giá của cổ phiếu trong một vài ngày tới sẽ như thế nào. Giả sử rằng ta có một tập dữ liệu về giá cổ phiếu được quan trắc theo thời gian $\{x_1, x_2, \dots, x_n\}$.

Ví dụ 2: Dự đoán thị trường cổ phiếu

- **Bài toán:** giả sử rằng ta đã mua một số cổ phiếu trên thị trường chứng khoán. Dựa vào các dữ liệu quá khứ, ta muốn dự đoán xem giá của cổ phiếu trong một vài ngày tới sẽ như thế nào. Giả sử rằng ta có một tập dữ liệu về giá cổ phiếu được quan trắc theo thời gian $\{x_1, x_2, \dots, x_n\}$.
- Một mô hình đơn giản được đề nghị là

$$x_n \approx ax_{n-1} + bx_{n-2}.$$

Mô hình này được gọi là **mô hình tự hồi quy (autoregression model)**.

Ví dụ 2: Dự đoán thị trường cổ phiếu

- **Bài toán:** giả sử rằng ta đã mua một số cổ phiếu trên thị trường chứng khoán. Dựa vào các dữ liệu quá khứ, ta muốn dự đoán xem giá của cổ phiếu trong một vài ngày tới sẽ như thế nào. Giả sử rằng ta có một tập dữ liệu về giá cổ phiếu được quan trắc theo thời gian $\{x_1, x_2, \dots, x_n\}$.
- Một mô hình đơn giản được đề nghị là

$$x_n \approx ax_{n-1} + bx_{n-2}.$$

Mô hình này được gọi là **mô hình tự hồi quy (autoregression model)**.

- Mô hình này giả sử giá của hôm nay có thể được dự đoán bởi một tổ hợp tuyến tính của giá ngày hôm qua và hôm kia.

Ví dụ 2: Dự đoán thị trường cổ phiếu

- **Bài toán:** giả sử rằng ta đã mua một số cổ phiếu trên thị trường chứng khoán. Dựa vào các dữ liệu quá khứ, ta muốn dự đoán xem giá của cổ phiếu trong một vài ngày tới sẽ như thế nào. Giả sử rằng ta có một tập dữ liệu về giá cổ phiếu được quan trắc theo thời gian $\{x_1, x_2, \dots, x_n\}$.
- Một mô hình đơn giản được đề nghị là

$$x_n \approx ax_{n-1} + bx_{n-2}.$$


Mô hình này được gọi là **mô hình tự hồi quy (autoregression model)**.

- Mô hình này giả sử giá của hôm nay có thể được dự đoán bởi một tổ hợp tuyến tính của giá ngày hôm qua và hôm kia.
- Véc-tơ tham số cần tìm là $\theta = (a, b)$. Nghiệm tối ưu $(\hat{a}, \hat{b})$ thỏa

$$(\hat{a}, \hat{b}) = \operatorname{argmin}_{a, b} \sum_{i=1}^n (x_i - (ax_{i-1} + bx_{i-2}))^2,$$

với $x_0 = x_{-1} = 0$.

Ví dụ 2: Dự đoán thị trường cổ phiếu



Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Các nguyên lý của hồi quy

Cho trước các điểm dữ liệu $(x_1, y_1), \dots, (x_n, y_n)$, hồi quy là quá trình đi tìm tham số $\theta = (\theta_1, \dots, \theta_d)$ của hàm $g_\theta(\cdot)$ sao cho tổng thất huấn luyện đạt cực tiểu:

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^d} \sum_{i=1}^n \mathcal{L}(y_i, g_\theta(x_i)).$$

Các nguyên lý của hồi quy

Cho trước các điểm dữ liệu $(x_1, y_1), \dots, (x_n, y_n)$, hồi quy là quá trình đi tìm tham số $\theta = (\theta_1, \dots, \theta_d)$ của hàm $g_\theta(\cdot)$ sao cho tổn thất huấn luyện đạt cực tiểu:

$$\hat{\theta} = \operatorname{argmin}_{\theta \in \mathbb{R}^d} \sum_{i=1}^n \mathcal{L}(y_i, g_\theta(x_i)).$$

Trong bài toán hồi quy, ta cần thực hiện hai sự lựa chọn:

- **Hàm hồi quy $g(\cdot)$:** họ các hàm số mà ta muốn sử dụng là gì? Đây có thể là đường thẳng, một đa thức, hay một tập hợp các hàm cơ sở.
- **Hàm tổn thất $\mathcal{L}(\cdot, \cdot)$:** làm thế nào để đo độ gần nhau giữa y_i và $g(x_i)$? Ta có sử dụng bình phương sai số $(y_i - g(x_i))^2$? hay sai số tuyệt đối $|y_i - g(x_i)|$? hay một dạng khác?

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Hồi quy tuyến tính đơn

- Xét tập dữ liệu $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, mục tiêu của hồi quy tuyến tính là tìm một đường thẳng có thể ước vừa nhất tập dữ liệu, phương trình đường thẳng cần tìm có dạng


$$g(x) = \theta_0 + \theta_1 x,$$

trong đó θ_0 là hệ số chặn (intercept) và θ_1 là hệ số góc (slope) của đường thẳng.

- Dựa trên dữ liệu đã cho, ta cần tìm $\theta = (\theta_0, \theta_1)$ để có được đường thẳng ước tốt nhất cho dữ liệu.

Hồi quy tuyến tính đơn

- Hình vẽ bên dưới mô tả đồ thị phân tán của một tập dữ liệu và các đường thẳng ướm (fitted line) cho mô hình



Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:

Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:
 - ▶ **Tổn thất tổng bình phương:** $\sum_{i=1}^n (y_i - g(x_i))^2$.

Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:
 - ▶ **Tổn thất tổng bình phương:** $\sum_{i=1}^n (y_i - g(x_i))^2$.
 - ▶ **Tổn thất tổng sai số tuyệt đối:** $\sum_{i=1}^n |y_i - g(x_i)|$.

Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:
 - ▶ **Tổn thất tổng bình phương:** $\sum_{i=1}^n (y_i - g(x_i))^2$.
 - ▶ **Tổn thất tổng sai số tuyệt đối:** $\sum_{i=1}^n |y_i - g(x_i)|$.
 - ▶ **Tổn thất Cross-entropy:** $-\sum_{i=1}^n (y_i \log(g(x_i)) + (1 - y_i) \log(1 - g(x_i)))$.

Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:
 - ▶ **Tổn thất tổng bình phương:** $\sum_{i=1}^n (y_i - g(x_i))^2$.
 - ▶ **Tổn thất tổng sai số tuyệt đối:** $\sum_{i=1}^n |y_i - g(x_i)|$.
 - ▶ **Tổn thất Cross-entropy:** $-\sum_{i=1}^n (y_i \log(g(x_i)) + (1 - y_i) \log(1 - g(x_i)))$.
 - ▶ **Tổn thất perceptual:** $\sum_{i=1}^n \max(-y_i g(x_i), 0)$, được dùng khi y_i và $g(x_i)$ nhận các giá trị nhị phân ± 1 . Tổn thất này thường được dùng để đo tổng tất các các cặp không khớp nhau.

Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:
 - ▶ **Tổn thất tổng bình phương:** $\sum_{i=1}^n (y_i - g(x_i))^2$.
 - ▶ **Tổn thất tổng sai số tuyệt đối:** $\sum_{i=1}^n |y_i - g(x_i)|$.
 - ▶ **Tổn thất Cross-entropy:** $-\sum_{i=1}^n (y_i \log(g(x_i)) + (1 - y_i) \log(1 - g(x_i)))$.
 - ▶ **Tổn thất perceptual:** $\sum_{i=1}^n \max(-y_i g(x_i), 0)$, được dùng khi y_i và $g(x_i)$ nhận các giá trị nhị phân ± 1 . Tổn thất này thường được dùng để đo tổng tất các các cặp không khớp nhau.
- Tổn thất tổng bình sai số thường được sử dụng nhất vì nó là hàm lồi (convex) và khả vi. Điều này sẽ làm cho việc tìm nghiệm tối ưu trở nên dễ dàng.

Hồi quy tuyến tính đơn

- Với hàm $g(x) = \theta_0 + \theta_1 x$ đã chọn, ta cần đo tổn thất huấn luyện. Tổn thất huấn luyện có thể được tính theo nhiều hàm tổn thất khác nhau, ví dụ:
 - Tổn thất tổng bình phương: $\sum_{i=1}^n (y_i - g(x_i))^2$.
 - Tổn thất tổng sai số tuyệt đối: $\sum_{i=1}^n |y_i - g(x_i)|$.
 - Tổn thất Cross-entropy: $-\sum_{i=1}^n (y_i \log(g(x_i)) + (1 - y_i) \log(1 - g(x_i)))$.
 - Tổn thất perceptual: $\sum_{i=1}^n \max(-y_i g(x_i), 0)$, được dùng khi y_i và $g(x_i)$ nhận các giá trị nhị phân ± 1 . Tổn thất này thường được dùng để đo tổng tất các các cặp không khớp nhau.
- Tổn thất tổng bình sai số thường được sử dụng nhất vì nó là hàm lồi (convex) và khả vi. Điều này sẽ làm cho việc tìm nghiệm tối ưu trở nên dễ dàng.
- Bài toán hồi quy tuyến tính sử dụng tổn thất tổng bình phương sai số là:

$$(\hat{\theta}_0, \hat{\theta}_1) = \underset{(\theta_0, \theta_1)}{\operatorname{argmin}} \sum_{i=1}^n (y_i - (\theta_0 + \theta_1 x_i))^2 = \underset{(\theta_0, \theta_1)}{\operatorname{argmin}} \epsilon_{\text{train}}(\theta).$$

Hồi quy tuyến tính đơn

Định lý

Nghiệm của bài toán

$$(\hat{\theta}_0, \hat{\theta}_1) = \underset{(\theta_0, \theta_1)}{\operatorname{argmin}} \sum_{i=1}^n (y_i - (\theta_0 + \theta_1 x_i))^2,$$

thỏa mãn phương trình

$$\begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} \begin{bmatrix} \hat{\theta}_0 \\ \hat{\theta}_1 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{bmatrix}.$$

Dạng ma trận của hồi quy tuyến tính đơn

Mô hình hồi quy có thể được biểu diễn dưới dạng

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \end{bmatrix} + \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix}$$
$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

Tổn thất huấn luyện $\epsilon_{\text{train}}(\boldsymbol{\theta})$ có thể được viết dưới dạng

$$\epsilon_{\text{train}}(\boldsymbol{\theta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2 = \sum_{i=1}^n (y_i - (\theta_0 + \theta_1 x_i))^2.$$

Lấy gradient theo $\boldsymbol{\theta}$, ta thu được

$$\nabla_{\boldsymbol{\theta}} \epsilon_{\text{train}}(\boldsymbol{\theta}) = -2\mathbf{X}^T(\mathbf{y} - \mathbf{X}\boldsymbol{\theta}).$$

Cho gradient bằng 0, suy ra

$$\mathbf{X}^T \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^T \mathbf{y}.$$

Phương trình trên được gọi là **phương trình chuẩn (normal equation)**.

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- **Hồi quy đa thức**
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Hồi quy đa thức

- Bên cạnh việc sử dụng đường thẳng tuyến tính, ta có thể xét mô hình hồi quy tổng quát như sau

$$g_{\theta}(x_i) = \sum_{k=0}^{d-1} \theta_k \phi_k(x_i),$$

với $\{\phi_k\}_{k=0}^{d-1}$ một tập các hàm cơ sở. Nếu ta chọn $\phi_k(x) = x^k$, ta thu được mô hình hồi quy đa thức.

- Ta có thể biểu diễn mô hình tổng quát dưới dạng một hệ phương trình tuyến tính

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} \phi_0(x_1) & \phi_1(x_1) & \cdots & \phi_{d-1}(x_1) \\ \phi_0(x_2) & \phi_1(x_2) & \cdots & \phi_{d-1}(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(x_n) & \phi_1(x_n) & \cdots & \phi_{d-1}(x_n) \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_{d-1} \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix}.$$

Ví dụ: hồi quy với đa thức toàn phương

Xét bài toán hồi quy tuyến tính sử dụng phương trình toàn phương (quadratic):

$$y_i = a_0 + a_1x_i + a_2x_i^2, \quad i = 1, \dots, n.$$

Dạng ma trận của bài toán là

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix},$$
$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e},$$

với $\boldsymbol{\theta} = (a_0, a_1, a_2)$.

Hồi quy đa thức

- Đối với hồi quy đa thức, các hàm $\{1, x, x^2, \dots, x^k\}$ không trực giao. Do vậy, khi k lớn, tập hợp các hàm $\{1, x, x^2, \dots, x^k\}$ sẽ trở nên dư thừa và có khả năng cho kết quả là ma trận **X** không khả nghịch.

Hồi quy đa thức

- Đối với hồi quy đa thức, các hàm $\{1, x, x^2, \dots, x^k\}$ không trực giao. Do vậy, khi k lớn, tập hợp các hàm $\{1, x, x^2, \dots, x^k\}$ sẽ trở nên dư thừa và có khả năng cho kết quả là ma trận **X** không khả nghịch.
- Để khắc phục vấn đề này, ta có thể chọn $\{\phi_k\}_{k=0}^d$ là một cơ sở trực giao (orthogonal basis). Chẳng hạn ta có thể chọn $\phi_k(x)$ là đa thức Legendre bậc k , kí hiệu bởi $L_k(x)$, ta có $L_0(x) = 1$, $L_1(x) = x$, $L_2(x) = \frac{1}{2}(3x^2 - 1)$, $L_3(x) = \frac{1}{2}(5x^3 - 3x)$, ...

Hồi quy đa thức

- Đối với hồi quy đa thức, các hàm $\{1, x, x^2, \dots, x^k\}$ không trực giao. Do vậy, khi k lớn, tập hợp các hàm $\{1, x, x^2, \dots, x^k\}$ sẽ trở nên dư thừa và có khả năng cho kết quả là ma trận **X** không khả nghịch.
- Để khắc phục vấn đề này, ta có thể chọn $\{\phi_k\}_{k=0}^d$ là một cơ sở trực giao (orthogonal basis). Chẳng hạn ta có thể chọn $\phi_k(x)$ là đa thức Legendre bậc k , kí hiệu bởi $L_k(x)$, ta có $L_0(x) = 1$, $L_1(x) = x$, $L_2(x) = \frac{1}{2}(3x^2 - 1)$, $L_3(x) = \frac{1}{2}(5x^3 - 3x)$, ...
- Một số cơ sở khác ta có thể chọn như: cơ sở Fourier, cơ sở Sinusoid, cơ sở Gaussian.

Hồi quy đa thức

- Đối với hồi quy đa thức, các hàm $\{1, x, x^2, \dots, x^k\}$ không trực giao. Do vậy, khi k lớn, tập hợp các hàm $\{1, x, x^2, \dots, x^k\}$ sẽ trở nên dư thừa và có khả năng cho kết quả là ma trận **X** không khả nghịch.
- Để khắc phục vấn đề này, ta có thể chọn $\{\phi_k\}_{k=0}^d$ là một cơ sở trực giao (orthogonal basis). Chẳng hạn ta có thể chọn $\phi_k(x)$ là đa thức Legendre bậc k , kí hiệu bởi $L_k(x)$, ta có $L_0(x) = 1$, $L_1(x) = x$, $L_2(x) = \frac{1}{2}(3x^2 - 1)$, $L_3(x) = \frac{1}{2}(5x^3 - 3x)$, ...
- Một số cơ sở khác ta có thể chọn như: cơ sở Fourier, cơ sở Sinusoid, cơ sở Gaussian.
- Việc lựa chọn cơ sở nào là phù hợp phụ thuộc vào nhiều yếu tố và không có câu trả lời xác định, nó có thể phụ thuộc vào phương pháp thống kê được chọn, kinh nghiệm, hoặc kiến thức chuyên ngành, ...

Ví dụ: mô hình tự hồi quy

Xét mô hình tự hồi quy 2 bước

$$y_n = ay_{n-1} + by_{n-2}, \quad n = 1, 2, \dots, N,$$

với giả sử $y_0 = y_{-1} = 0$.

Dạng ma trận của mô hình này có dạng

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} y_0 & y_{-1} \\ y_1 & y_0 \\ \vdots & \vdots \\ y_{N-1} & y_{N-2} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{bmatrix},$$
$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}.$$

Ví dụ: mô hình tự hồi quy

Mô hình tổng quát

$$y_n = \sum_{\ell=1}^L \theta_{\ell} y_{n-\ell}, \quad n = 1, 2, \dots, N,$$

với $\boldsymbol{\theta} = (\theta_1, \dots, \theta_L)$ là véc-tơ các hệ số hồi quy.

Ví dụ: mô hình tự hồi quy

Mô hình tổng quát

$$y_n = \sum_{\ell=1}^L \theta_{\ell} y_{n-\ell}, \quad n = 1, 2, \dots, N,$$

với $\theta = (\theta_1, \dots, \theta_L)$ là véc-tơ các hệ số hồi quy. Dạng ma trận của mô hình này có dạng

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} y_0 & y_{-1} & y_{-2} & \cdots & y_{1-L} \\ y_1 & y_0 & y_{-1} & \cdots & y_{2-L} \\ y_2 & y_1 & y_0 & \cdots & y_{3-L} \\ y_3 & y_2 & y_1 & \cdots & y_{4-L} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ y_{N-1} & y_{N-2} & y_{N-3} & \vdots & y_{N-L} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \\ \vdots \\ \theta_L \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ \vdots \\ e_N \end{bmatrix},$$

$$\mathbf{y} = \mathbf{X}\theta + \epsilon.$$

Ví dụ: mô hình tự hồi quy

Mô hình tổng quát

$$y_n = \sum_{\ell=1}^L \theta_{\ell} y_{n-\ell}, \quad n = 1, 2, \dots, N,$$

với $\theta = (\theta_1, \dots, \theta_L)$ là véc-tơ các hệ số hồi quy. Dạng ma trận của mô hình này có dạng

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} y_0 & y_{-1} & y_{-2} & \cdots & y_{1-L} \\ y_1 & y_0 & y_{-1} & \cdots & y_{2-L} \\ y_2 & y_1 & y_0 & \cdots & y_{3-L} \\ y_3 & y_2 & y_1 & \cdots & y_{4-L} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ y_{N-1} & y_{N-2} & y_{N-3} & \vdots & y_{N-L} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \\ \vdots \\ \theta_L \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ \vdots \\ e_N \end{bmatrix},$$

$$\mathbf{y} = \mathbf{X}\theta + \epsilon.$$

Đối với ma trận $\mathbf{X}$, mỗi cột của nó được thu được bởi dịch chuyển cột phía trước đi 1 phần tử. Ma trận này được gọi là ma trận *Toeplitz*.

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- **Dạng ma trận tổng quát của mô hình hồi quy tuyến tính**
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Mô hình tuyến tính tổng quát

- Tập dữ liệu $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ với $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ được biểu diễn dưới dạng ma trận như sau:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{bmatrix} = \mathbf{X}\boldsymbol{\theta}.$$

Mô hình tuyến tính tổng quát

- Tập dữ liệu $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ với $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ được biểu diễn dưới dạng ma trận như sau:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{bmatrix} = \mathbf{X}\boldsymbol{\theta}.$$

- Ma trận $\mathbf{X} \in \mathbb{R}^{N \times p}$ được gọi là **ma trận thiết kế (design matrix)**.

Mô hình tuyến tính tổng quát

- Tập dữ liệu $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ với $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ được biểu diễn dưới dạng ma trận như sau:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{bmatrix} = \mathbf{X}\boldsymbol{\theta}.$$

- Ma trận $\mathbf{X} \in \mathbb{R}^{N \times p}$ được gọi là **ma trận thiết kế (design matrix)**.
- Véc-tơ $\boldsymbol{\theta} \in \mathbb{R}^p$ chứa các hệ số hồi quy.

Mô hình tuyến tính tổng quát

- Tập dữ liệu $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ với $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ được biểu diễn dưới dạng ma trận như sau:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{bmatrix} = \mathbf{X}\boldsymbol{\theta}.$$

- Ma trận $\mathbf{X} \in \mathbb{R}^{N \times p}$ được gọi là **ma trận thiết kế (design matrix)**.
- Véc-tơ $\boldsymbol{\theta} \in \mathbb{R}^p$ chứa các hệ số hồi quy.
- Khi $N > p$, hệ phương trình tuyến tính được gọi là **overdetermined**.

Mô hình tuyến tính tổng quát

- Tập dữ liệu $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ với $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})$ được biểu diễn dưới dạng ma trận như sau:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \cdots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{Np} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_p \end{bmatrix} = \mathbf{X}\boldsymbol{\theta}.$$

- Ma trận $\mathbf{X} \in \mathbb{R}^{N \times p}$ được gọi là **ma trận thiết kế (design matrix)**.
- Véc-tơ $\boldsymbol{\theta} \in \mathbb{R}^p$ chứa các hệ số hồi quy.
- Khi $N > p$, hệ phương trình tuyến tính được gọi là **overdetermined**.
- Khi $N < p$, hệ phương trình tuyến tính được gọi là **underdetermined**.

Mô hình tuyến tính tổng quát

- Trong thực tế, dữ liệu luôn bị ảnh hưởng bởi nhiễu (noise), ta có

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

Mô hình tuyến tính tổng quát

- Trong thực tế, dữ liệu luôn bị ảnh hưởng bởi nhiễu (noise), ta có

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

- Sử dụng tổn thất tổng bình phương sai số, nghiệm tối ưu $\hat{\boldsymbol{\theta}}$ cho bởi

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta} \in \mathbb{R}^p}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2.$$

Mô hình tuyến tính tổng quát

- Trong thực tế, dữ liệu luôn bị ảnh hưởng bởi nhiễu (noise), ta có

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

- Sử dụng tổn thất tổng bình phương sai số, nghiệm tối ưu $\hat{\boldsymbol{\theta}}$ cho bởi

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta} \in \mathbb{R}^p}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2.$$

- Cho gradient của $\|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2$ bằng 0 ta thu được **phương trình chuẩn**:

$$\mathbf{X}^T \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^T \mathbf{y}.$$

Mô hình tuyến tính tổng quát

- Trong thực tế, dữ liệu luôn bị ảnh hưởng bởi nhiễu (noise), ta có

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

- Sử dụng tổn thất tổng bình phương sai số, nghiệm tối ưu $\hat{\boldsymbol{\theta}}$ cho bởi

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta} \in \mathbb{R}^p}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2.$$

- Cho gradient của $\|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2$ bằng 0 ta thu được **phương trình chuẩn**:

$$\mathbf{X}^T \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^T \mathbf{y}.$$

- Nếu $N \geq p$ (hệ overdetermined) và $\operatorname{rank}(\mathbf{X}) = p$ thì nghiệm của hệ là

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

$\hat{\boldsymbol{\theta}}$ còn được gọi là ước lượng bình phương bé nhất.

Tính chất của ước lượng bình phương bé nhất

- **Các giả định:**

- ▶ Dữ liệu sinh bởi mô hình $\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}$.
- ▶ $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$.
- ▶ Biến hồi quy $\mathbf{X}$ là xác định (deterministic).
- ▶ Ước lượng BPBN cho bởi $\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta} \in \mathbb{R}^p}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\theta}\|^2$.

- Ta có các tính chất sau:

- ▶ $\hat{\boldsymbol{\theta}}$ là ước lượng không chệch của $\boldsymbol{\theta}$, tức là $\mathbb{E}[\hat{\boldsymbol{\theta}}] = \boldsymbol{\theta}$.
- ▶ Ma trận hiệp phương sai của $\hat{\boldsymbol{\theta}}$ cho bởi

$$\operatorname{Cov}(\hat{\boldsymbol{\theta}}) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\Sigma} \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}.$$

Tính chất BLUE

- Các giả định:

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$.

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$.
- ▶ $\hat{\theta}_{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$.

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$.
- ▶ $\hat{\theta}_{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$.

- **BLUE - Best Linear Unbiased Estimator:** $\hat{\theta}_{LS}$ là ước lượng BPBN không chệch tuyến tính tốt nhất trong số tất cả các ước lượng tuyến tính $\hat{\theta} = \mathbf{B}\mathbf{y}$ của θ , theo nghĩa có phương sai bé nhất.

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$.
- ▶ $\hat{\theta}_{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$.

- **BLUE - Best Linear Unbiased Estimator:** $\hat{\theta}_{LS}$ là ước lượng BPBN không chệch tuyến tính tốt nhất trong số tất cả các ước lượng tuyến tính $\hat{\theta} = \mathbf{B}\mathbf{y}$ của θ , theo nghĩa có phương sai bé nhất.
- Tính chất BLUE còn được biết như là định lý Gauss - Markov.

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$.
- ▶ $\hat{\theta}_{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$.

- **BLUE - Best Linear Unbiased Estimator:** $\hat{\theta}_{LS}$ là ước lượng BPBN không chệch tuyến tính tốt nhất trong số tất cả các ước lượng tuyến tính $\hat{\theta} = \mathbf{B}\mathbf{y}$ của θ , theo nghĩa có phương sai bé nhất.
- Tính chất BLUE còn được biết như là định lý Gauss - Markov.
- Giả định $\text{Cov}(\epsilon) = \sigma^2 I$ tương đương với

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$.
- ▶ $\hat{\theta}_{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$.

- **BLUE - Best Linear Unbiased Estimator:** $\hat{\theta}_{LS}$ là ước lượng BPBN không chệch tuyến tính tốt nhất trong số tất cả các ước lượng tuyến tính $\hat{\theta} = \mathbf{B}\mathbf{y}$ của θ , theo nghĩa có phương sai bé nhất.

- Tính chất BLUE còn được biết như là định lý Gauss - Markov.

- Giả định $\text{Cov}(\epsilon) = \sigma^2 I$ tương đương với

- ▶ $\text{Var}(\epsilon_i) = \sigma^2$ với mọi i : phương sai là hằng số không đổi (tính đồng nhất - homoskedasticity)

Tính chất BLUE

- **Các giả định:**

- ▶ $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$.
- ▶ $\hat{\theta}_{LS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$.

- **BLUE - Best Linear Unbiased Estimator:** $\hat{\theta}_{LS}$ là ước lượng BPBN không chệch tuyến tính tốt nhất trong số tất cả các ước lượng tuyến tính $\hat{\theta} = \mathbf{B}\mathbf{y}$ của θ , theo nghĩa có phương sai bé nhất.

- Tính chất BLUE còn được biết như là định lý Gauss - Markov.

- Giả định $\text{Cov}(\epsilon) = \sigma^2 I$ tương đương với

- ▶ $\text{Var}(\epsilon_i) = \sigma^2$ với mọi i : phương sai là hằng số không đổi (tính đồng nhất - homoskedasticity)
- ▶ $\text{Cov}(\epsilon_i, \epsilon_j) = 0$ với mọi $i \neq j$: các thành phần sai số không có tương quan với nhau.

Tính chất của ước lượng của sai số

- Giả sử $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ và định nghĩa

$$\hat{\epsilon} = \mathbf{y} - \mathbf{X}\hat{\theta}, \quad \text{SSE} = \sum_{i=1}^N \hat{\epsilon}_i^2, \quad \hat{\sigma}^2 = \frac{\text{SSE}}{N-p} = \frac{\|\hat{\epsilon}\|^2}{N-p}.$$

- Ta có:

- $\hat{\sigma}^2$ là một ước lượng không chệch cho σ^2 .
- $\frac{(N-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(N-p)$.
- Ước lượng của phương sai và sai số chuẩn của $\hat{\theta}$ là

$$\text{Var}(\hat{\theta}) = \hat{\sigma}^2(\mathbf{X}^T\mathbf{X})^{-1}, \quad \text{SE}(\hat{\theta}_k) = \sqrt{\text{Var}(\hat{\theta})_{kk}}.$$

Độ chính xác của mô hình

Gọi:

- SST: Tổng bình phương toàn phần (Total Sum of Squares),

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2.$$

- SSR: Tổng bình phương hồi quy (Regression Sum of Squares),

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

- SSE: Tổng bình phương sai số (Error Sum of Squares),

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$


Độ chính xác của mô hình

- SST: đo sự biến thiên của các giá trị y_i xung quanh giá trị trung tâm của dữ liệu $\bar{y}$,
- SSR: giải thích sự biến thiên liên quan đến mối quan hệ tuyến tính của X và Y ,
- SSE: giải thích sự biến thiên của các yếu tố khác (không liên quan đến mối quan hệ tuyến tính của X và Y).

Ta chứng tỏ được:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2, \quad (1)$$
$$\text{SST} = \text{SSE} + \text{SSR}.$$

Độ chính xác của mô hình



Hệ số xác định

Định nghĩa

Hệ số xác định (Coefficient of Determination) là tỷ lệ của tổng sự biến thiên trong biến phụ thuộc gây ra bởi sự biến thiên của các biến độc lập (biến giải thích) so với tổng sự biến thiên toàn phần.

Hệ số xác định thường được gọi là R - bình phương (R -squared), ký hiệu là R^2 .

Công thức tính:

$$R^2 = \frac{SSR}{SST} = \frac{SSR}{SSR + SSE}. \quad (2)$$

Chú ý: $0 \leq R^2 \leq 1$.

Hệ số xác định

Định nghĩa

Hệ số xác định (Coefficient of Determination) là tỷ lệ của tổng sự biến thiên trong biến phụ thuộc gây ra bởi sự biến thiên của các biến độc lập (biến giải thích) so với tổng sự biến thiên toàn phần.

Hệ số xác định thường được gọi là R - bình phương (R -squared), ký hiệu là R^2 .

Công thức tính:

$$R^2 = \frac{SSR}{SST} = \frac{SSR}{SSR + SSE}. \quad (2)$$

Chú ý: $0 \leq R^2 \leq 1$.

Hệ số xác định của một mô hình hồi quy cho phép ta đánh giá mô hình tìm được có giải thích tốt cho mối liên hệ giữa biến phụ thuộc Y và biến phụ thuộc X hay không.

Kiểm định giả thuyết cho các hệ số hồi quy

- Giả thuyết $H_0 : \theta_k = 0$ vs $H_1 : \theta_k \neq 0$, với $k = 1, \dots, p$.
- Thống kê kiểm định t cho bởi

$$T = \frac{\hat{\theta}_k}{\text{SE}(\hat{\theta}_k)} = \frac{\hat{\theta}_k}{\sqrt{\hat{\sigma}^2 [(\mathbf{X}^T \mathbf{X})^{-1}]_{kk}}} \sim t_{N-p}.$$

- p -giá trị được tính bởi

$$\text{p-val} = \Pr(T_{N-p} \geq |T|).$$

Ta bác bỏ H_0 nếu $\text{p-val} < \alpha$.

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.
- Các giả định của mô hình:

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.
- Các giả định của mô hình:

① **Tuyến tính:** mối quan hệ giữa X và Y là tuyến tính, tức là

$$\mathbb{E}[Y|\mathbf{X} = \mathbf{x}] = \mathbf{x}^T \boldsymbol{\theta}.$$

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.
- Các giả định của mô hình:

- ➊ **Tuyến tính:** mối quan hệ giữa X và Y là tuyến tính, tức là

$$\mathbb{E}[Y|\mathbf{X} = \mathbf{x}] = \mathbf{x}^T \boldsymbol{\theta}.$$

- ➋ **Phương sai bằng nhau:** phương sai của biến đáp ứng (biến phụ thuộc) Y là hằng số với mọi giá trị của biến độc lập X , tức là $\mathbb{V}ar(Y|\mathbf{X} = \mathbf{x}) = \sigma^2$.

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.
- Các giả định của mô hình:

- ➊ **Tuyến tính:** mối quan hệ giữa X và Y là tuyến tính, tức là

$$\mathbb{E}[Y|\mathbf{X} = \mathbf{x}] = \mathbf{x}^T \boldsymbol{\theta}.$$

- ➋ **Phương sai bằng nhau:** phương sai của biến đáp ứng (biến phụ thuộc) Y là hằng số với mọi giá trị của biến độc lập X , tức là $\mathbb{V}ar(Y|\mathbf{X} = \mathbf{x}) = \sigma^2$.
- ➌ **Độc lập:** các quan trắc của biến đáp ứng Y độc lập với nhau.

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.
- Các giả định của mô hình:

- ➊ **Tuyến tính:** mối quan hệ giữa X và Y là tuyến tính, tức là

$$\mathbb{E}[Y|\mathbf{X} = \mathbf{x}] = \mathbf{x}^T \boldsymbol{\theta}.$$

- ➋ **Phương sai bằng nhau:** phương sai của biến đáp ứng (biến phụ thuộc) Y là hằng số với mọi giá trị của biến độc lập X , tức là $\text{Var}(Y|\mathbf{X} = \mathbf{x}) = \sigma^2$.
- ➌ **Độc lập:** các quan trắc của biến đáp ứng Y độc lập với nhau.
- ➍ **Phân phối chuẩn:** với mỗi giá trị của biến độc lập, phân phối có điều kiện (cho trước giá trị $\mathbf{x}$) của biến đáp ứng là phân phối chuẩn, $Y|\mathbf{X} = \mathbf{x} \sim \mathcal{N}(\mathbf{x}^T \boldsymbol{\theta}, \sigma^2)$.

Phân tích thặng dư

- **Phân tích thặng dư (Residual Analysis)** được sử dụng để kiểm tra các giả định của mô hình hồi quy tuyến tính.
- Các giả định của mô hình:

- ① **Tuyến tính:** mối quan hệ giữa X và Y là tuyến tính, tức là

$$\mathbb{E}[Y|\mathbf{X} = \mathbf{x}] = \mathbf{x}^T \boldsymbol{\theta}.$$

- ② **Phương sai bằng nhau:** phương sai của biến đáp ứng (biến phụ thuộc) Y là hằng số với mọi giá trị của biến độc lập X , tức là $\text{Var}(Y|\mathbf{X} = \mathbf{x}) = \sigma^2$.

- ③ **Độc lập:** các quan trắc của biến đáp ứng Y độc lập với nhau.

- ④ **Phân phối chuẩn:** với mỗi giá trị của biến độc lập, phân phối có điều kiện (cho trước giá trị $\mathbf{x}$) của biến đáp ứng là phân phối chuẩn, $Y|\mathbf{X} = \mathbf{x} \sim \mathcal{N}(\mathbf{x}^T \boldsymbol{\theta}, \sigma^2)$.

- Việc kiểm tra các giả định trên thông thường sẽ được thực hiện thông qua các giá trị thặng dư, cho bởi

$$e_i = y_i - \hat{y}_i, \quad i = 1, \dots, n,$$

$$\text{với } \hat{y}_i = \mathbf{x}_i^T \boldsymbol{\theta}.$$

Phân tích thặng dư

- Đồ thị các giá trị thặng dư: các cặp $(\hat{y}_i, e_i)$, $i = 1, \dots, n$. (Hoặc ta vẽ các giá trị e_i tương ứng với các giá trị của biến độc lập x_i).

Phân tích thặng dư

- Đồ thị các giá trị thặng dư: các cặp $(\hat{y}_i, e_i)$, $i = 1, \dots, n$. (Hoặc ta vẽ các giá trị e_i tương ứng với các giá trị của biến độc lập x_i).
- Nếu các giả định về 1, 2 và 3 thỏa thì ta sẽ nhận thấy đồ thị thặng dư gồm các điểm phân tán đều trên mặt phẳng Oxy và phân tán đều xung quanh đường thẳng $y = 0$.

Phân tích thặng dư

- Đồ thị các giá trị thặng dư: các cặp $(\hat{y}_i, e_i)$, $i = 1, \dots, n$. (Hoặc ta vẽ các giá trị e_i tương ứng với các giá trị của biến độc lập x_i).
- Nếu các giả định về 1, 2 và 3 thỏa thì ta sẽ nhận thấy đồ thị thặng dư gồm các điểm phân tán đều trên mặt phẳng Oxy và phân tán đều xung quanh đường thẳng $y = 0$.
- Trường hợp một trong các giả định trên bị vi phạm, chẳng hạn như phương sai thay đổi, mối quan hệ giữa các biến không tuyến tính, ta sẽ thấy các điểm trên đồ thị thặng dư sẽ phân bố theo một hình dạng cụ thể nào đó.


Phân tích thặng dư

- Đồ thị các giá trị thặng dư: các cặp $(\hat{y}_i, e_i)$, $i = 1, \dots, n$. (Hoặc ta vẽ các giá trị e_i tương ứng với các giá trị của biến độc lập x_i).
- Nếu các giả định về 1, 2 và 3 thỏa thì ta sẽ nhận thấy đồ thị thặng dư gồm các điểm phân tán đều trên mặt phẳng Oxy và phân tán đều xung quanh đường thẳng $y = 0$.
- Trường hợp một trong các giả định trên bị vi phạm, chẳng hạn như phương sai thay đổi, mối quan hệ giữa các biến không tuyến tính, ta sẽ thấy các điểm trên đồ thị thặng dư sẽ phân bố theo một hình dạng cụ thể nào đó.
- Đồ thị thặng dư cũng giúp cho ta xác định được sự tồn tại của các điểm **outlier**.


Phân tích thặng dư

- Đồ thị các giá trị thặng dư: các cặp $(\hat{y}_i, e_i)$, $i = 1, \dots, n$. (Hoặc ta vẽ các giá trị e_i tương ứng với các giá trị của biến độc lập x_i).
- Nếu các giả định về 1, 2 và 3 thỏa thì ta sẽ nhận thấy đồ thị thặng dư gồm các điểm phân tán đều trên mặt phẳng Oxy và phân tán đều xung quanh đường thẳng $y = 0$.
- Trường hợp một trong các giả định trên bị vi phạm, chẳng hạn như phương sai thay đổi, mối quan hệ giữa các biến không tuyến tính, ta sẽ thấy các điểm trên đồ thị thặng dư sẽ phân bố theo một hình dạng cụ thể nào đó.
- Đồ thị thặng dư cũng giúp cho ta xác định được sự tồn tại của các điểm **outlier**.
- Để kiểm tra giả định về phân phối chuẩn (giả định 4), ta thường dùng đồ thị **Normal Q-Q Plot**.


Phân tích thặng dư




(a)



(b)




(c)




(d)

- (a): các giả định của mô hình được thỏa mãn.


Phân tích thặng dư




(a)



(b)




(c)




(d)

- (a): các giả định của mô hình được thỏa mãn.
- (b): phương sai tăng dần theo thời gian hoặc theo biên độ của x_i hay y_i .
- (c): phương sai không bằng nhau.


Phân tích thặng dư




(a)



(b)



(c)




(d)


- (a): các giả định của mô hình được thỏa mãn.
- (b): phương sai tăng dần theo thời gian hoặc theo biên độ của x_i hay y_i .
- (c): phương sai không bằng nhau.
- (d): mối quan hệ giữa X và Y là phi tuyến tính.

Phân tích thặng dư

- Kiểm tra phân phối chuẩn sử dụng đồ thị **Normal Q-Q Plot**.



Dữ liệu tuân theo phân phối chuẩn



Dữ liệu không tuân theo phân phối chuẩn

Mục lục

1 Giới thiệu

2 Hồi quy tuyến tính

- Hồi quy tuyến tính đơn
- Hồi quy đa thức
- Dạng ma trận tổng quát của mô hình hồi quy tuyến tính
- Phân tích thặng dư cho hồi quy tuyến tính

3 Hồi quy tuyến tính mạnh (Robust linear regression)

Hạn chế của OLS

- Việc xây dựng ước lượng cho các hệ số trong mô hình hồi quy tuyến tính đã xét dựa trên tiêu chuẩn **bình phương sai số (squared error)**.


Hạn chế của OLS

- Việc xây dựng ước lượng cho các hệ số trong mô hình hồi quy tuyến tính đã xét dựa trên tiêu chuẩn **bình phương sai số (squared error)**.
- Hàm bình phương sai số được sử dụng vì 2 tính chất: lồi và khả vi. Tính khả vi cho phép ta lấy đạo hàm và xác định giá trị cực tiểu. Tính lồi cho phép ta khẳng định đây là cực tiểu toàn cục (và duy nhất nếu hàm mục tiêu lồi ngặt (strictly convex)).

Hạn chế của OLS


- Việc xây dựng ước lượng cho các hệ số trong mô hình hồi quy tuyến tính đã xét dựa trên tiêu chuẩn **bình phương sai số (squared error)**.
- Hàm bình phương sai số được sử dụng vì 2 tính chất: lồi và khả vi. Tính khả vi cho phép ta lấy đạo hàm và xác định giá trị cực tiểu. Tính lồi cho phép ta khẳng định đây là cực tiểu toàn cục (và duy nhất nếu hàm mục tiêu lồi ngặt (strictly convex)).
- Tuy nhiên, tiêu chí này có một hạn chế: bị ảnh hưởng bởi các điểm **ngoại lai (outliers)**.

Ảnh hưởng của outliers lên ước lượng OLS




Trái: Đường cong ướm (fitted curve) khi không có outliers. Phải: Đường cong ướm khi xuất hiện outliers.

Ảnh hưởng của outliers lên ước lượng OLS




Ảnh hưởng của outliers lên ước lượng OLS



- **Ảnh hưởng của outliers:** các ước lượng OLS có thể bị chệch và bị kéo về phía các điểm outliers.

Ảnh hưởng của outliers lên ước lượng OLS



- **Ảnh hưởng của outliers:** các ước lượng OLS có thể bị chệch và bị kéo về phía các điểm outliers.
- **Giải pháp:** sử dụng hồi quy tuyến tính mạnh (Robust linear regression).

Xác định các điểm outliers

Dùng Phân tích thặng dư (residual analysis):

Xét mô hình $\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}$ với giả sử $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$, $i = 1, \dots, n$.

- Với $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\theta}}$, tính thặng dư $\mathbf{r} = \mathbf{y} - \hat{\mathbf{y}}$.
- MSE: $s^2 = \hat{\sigma}^2 = \|\mathbf{r}\|^2 / (N - p)$ (ước lượng không chệch của σ^2).

Phân tích thặng dư: tính

- Thặng dư chuẩn hóa (standardized residual): $z_i = r_i / s$,
- Studentized residual:

$$t_i = \frac{r_i}{\sqrt{\text{MSE}_{(-i)}(1 - h_{ii})}},$$

trong đó

- $\text{MSE}_{(-i)}$ là MSE của mô hình ước lượng mà bỏ đi quan trắc thứ i .
- h_{ii} : phần tử trên đường chéo chính của ma trận $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$.
- Những điểm outliers tiềm năng là **những quan trắc có z_i hay t_i lớn hơn 3**.

Xác định các điểm outliers

Sử dụng khoảng cách của Cook (Cook's distance):

Cook's distance: là khoảng cách dùng để đo xem $\hat{\theta}$ di chuyển bao xa khi loại bỏ điểm (x_i, y_i) , định nghĩa bởi:

$$D_i = \frac{(\hat{\mathbf{y}} - \hat{\mathbf{y}}^{(-i)})^T (\hat{\mathbf{y}} - \hat{\mathbf{y}}^{(-i)})}{n\hat{\sigma}^2} = \frac{(\hat{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}^{(-i)})^T (\mathbf{X}^T \mathbf{X}) (\hat{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}^{(-i)})}{n\hat{\sigma}^2}$$

với

- $\hat{\mathbf{y}}, \hat{\mathbf{y}}^{(-i)}$ lần lượt là các giá trị dự đoán với toàn bộ dữ liệu và dữ liệu đã bỏ đi quan trắc thứ i .
- $\hat{\boldsymbol{\theta}}^{(-i)}$ là ước lượng OLS trên dữ liệu đã bỏ đi quan trắc thứ i .
- D_i đo ảnh hưởng của quan trắc thứ i trên véc-tơ giá trị dự đoán và các hệ số hồi quy.

Xác định các điểm outliers

Sử dụng khoảng cách của Cook (Cook's distance):

Cook's distance: là khoảng cách dùng để đo xem $\hat{\theta}$ di chuyển bao xa khi loại bỏ điểm (x_i, y_i) , định nghĩa bởi:

$$D_i = \frac{(\hat{\mathbf{y}} - \hat{\mathbf{y}}^{(-i)})^T (\hat{\mathbf{y}} - \hat{\mathbf{y}}^{(-i)})}{n\hat{\sigma}^2} = \frac{(\hat{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}^{(-i)})^T (\mathbf{X}^T \mathbf{X}) (\hat{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}^{(-i)})}{n\hat{\sigma}^2}$$


với

- $\hat{\mathbf{y}}, \hat{\mathbf{y}}^{(-i)}$ lần lượt là các giá trị dự đoán với toàn bộ dữ liệu và dữ liệu đã bỏ đi quan trắc thứ i .
- $\hat{\boldsymbol{\theta}}^{(-i)}$ là ước lượng OLS trên dữ liệu đã bỏ đi quan trắc thứ i .
- D_i đo ảnh hưởng của quan trắc thứ i trên véc-tơ giá trị dự đoán và các hệ số hồi quy.

→ bất kỳ quan trắc thứ i nào có D_i tương đối cao thì cần phải được xem xét kỹ hơn (thông thường chọn ngưỡng là $3\bar{D}$).

Xác định các điểm outliers

Sử dụng khoảng cách của Cook (Cook's distance):



Phương pháp Bình phương bé nhất có trọng số

- Cho trước $\mathbf{W}$ là một ma trận xác định dương (positive definite) mà có thể phân tích thành $\mathbf{W} = \mathbf{L}^T \mathbf{L}$.

Phương pháp Bình phương bé nhất có trọng số

- Cho trước $\mathbf{W}$ là một ma trận xác định dương (positive definite) mà có thể phân tích thành $\mathbf{W} = \mathbf{L}^T \mathbf{L}$.
- Bài toán Bình phương bé nhất có trọng số (Weighted Least-Squares - WLS) đi cực tiểu hóa

$$(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^T \mathbf{W} (\mathbf{X}\boldsymbol{\theta} - \mathbf{y}) = \|\mathbf{L}(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})\|^2.$$

Phương pháp Bình phương bé nhất có trọng số

- Cho trước $\mathbf{W}$ là một ma trận xác định dương (positive definite) mà có thể phân tích thành $\mathbf{W} = \mathbf{L}^T \mathbf{L}$.
- Bài toán Bình phương bé nhất có trọng số (Weighted Least-Squares - WLS) đi cực tiểu hóa

$$(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^T \mathbf{W}(\mathbf{X}\boldsymbol{\theta} - \mathbf{y}) = \|\mathbf{L}(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})\|^2.$$

- Ta thu được phương trình chuẩn (hiệu chỉnh) dưới dạng

$$\mathbf{X}^T \mathbf{W} \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^T \mathbf{W} \mathbf{y}.$$

Phương pháp Bình phương bé nhất có trọng số

- Cho trước $\mathbf{W}$ là một ma trận xác định dương (positive definite) mà có thể phân tích thành $\mathbf{W} = \mathbf{L}^T \mathbf{L}$.
- Bài toán Bình phương bé nhất có trọng số (Weighted Least-Squares - WLS) đi cực tiểu hóa

$$(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^T \mathbf{W}(\mathbf{X}\boldsymbol{\theta} - \mathbf{y}) = \|\mathbf{L}(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})\|^2.$$


- Ta thu được phương trình chuẩn (hiệu chỉnh) dưới dạng

$$\mathbf{X}^T \mathbf{W} \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^T \mathbf{W} \mathbf{y}.$$

- Nếu $\mathbf{X}$ có hạng đầy đủ (full rank), thì ước lượng WLS cho bởi


$$\hat{\boldsymbol{\theta}}_{WLS} = (\mathbf{X}^T \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W} \mathbf{y}.$$

Phương pháp Bình phương bé nhất có trọng số




- Giả sử tập dữ liệu cỡ n có các điểm outliers ở vị trí 3, 9 và 10.

Phương pháp Bình phương bé nhất có trọng số



- Giả sử tập dữ liệu cỡ n có các điểm outliers ở vị trí 3, 9 và 10.
- Chọn $\mathbf{W} = \text{diag}(w_1, w_2, \dots, w_n)$, ta có hàm mục tiêu WLS là $\sum_{i=1}^n w_i (y_i - \mathbf{x}_i^T \boldsymbol{\theta})^2$.
Ta có thể chọn các giá trị w_3, w_9, w_{10} tương đối nhỏ để phạt ít đi trên các điểm mẫu này.

Phương pháp Bình phương bé nhất có trọng số



- Giả sử tập dữ liệu cỡ n có các điểm outliers ở vị trí 3, 9 và 10.
- Chọn $\mathbf{W} = \text{diag}(w_1, w_2, \dots, w_n)$, ta có hàm mục tiêu WLS là $\sum_{i=1}^n w_i (y_i - \mathbf{x}_i^T \boldsymbol{\theta})^2$.
Ta có thể chọn các giá trị w_3, w_9, w_{10} tương đối nhỏ để phạt ít đi trên các điểm mẫu này.
- WLS còn được sử dụng khi phương sai của nhiễu không đồng nhất (heteroskedasticity). Ta có thể chọn $w_i = 1/\sigma_i^2$.

Hàm tổn thất cho hồi quy mạnh

- Ngoài việc sử dụng WLS, ta có thể thay thế sai số bình phương bằng **sai số tuyệt đối (absolute error)** để hạn chế ảnh hưởng của các điểm outliers, ta chọn

$$\epsilon_{\text{train}}(\theta) = \sum_{i=1}^n |y_i - \mathbf{x}_i^T \theta|.$$

- Bởi vì hàm tổn thất là sai số tuyệt đối, nên ta không thể lấy đạo hàm và tìm lời giải tối ưu. Tuy nhiên ta có thể sử dụng **Phương pháp đơn hình (simplex method)** trong quy hoạch tuyến tính để thực hiện việc này.
- Như vậy, ta giải bài toán tối ưu sau

$$\underset{\theta \in \mathbb{R}^d, \mathbf{u} \in \mathbb{R}^n}{\text{minimize}} \quad \sum_{i=1}^n u_i$$

$$\text{với ràng buộc } u_i = |y_i - \mathbf{x}_i^T \theta|, \quad i = 1, \dots, n.$$