

Principal Components Analysis

Nguyễn Phú Thành - Lê Hoàng Đức

Faculty of Mathematics and Computer Science
University of Science

Ngày 1 tháng 6 năm 2021

Table of Contents

- 1 Introduction
- 2 Phép phân tích thành phần chính của tổng thể
- 3 Mô tả phương sai mẫu bằng các vectơ thành phần chính
- 4 Biểu diễn các vectơ thành phần chính

Table of Contents

- 1 Introduction
- 2 Phép phân tích thành phần chính của tổng thể
- 3 Mô tả phương sai mẫu bằng các vectơ thành phần chính
- 4 Biểu diễn các vectơ thành phần chính

PCA là gì?

- Principal Components Analysis (PCA) - phương pháp thống kê giúp phân tích và diễn giải các dữ liệu phi cấu trúc.

PCA là gì?

- Principal Components Analysis (PCA) - phương pháp thống kê giúp phân tích và diễn giải các dữ liệu phi cấu trúc.
- PCA đi tìm một hệ cơ sở trực chuẩn thông qua các phép biến đổi tuyến tính sao cho phương sai của các quan sát ở hệ này cực đại trên một số chiều, và đối với một số chiều còn lại là đủ nhỏ để có thể bỏ qua (*trình bày chi tiết ở các phần sau*).

PCA là gì?

- Principal Components Analysis (PCA) - phương pháp thống kê giúp phân tích và diễn giải các dữ liệu phi cấu trúc.
- PCA đi tìm một hệ cơ sở trực chuẩn thông qua các phép biến đổi tuyến tính sao cho phương sai của các quan sát ở hệ này cực đại trên một số chiều, và đối với một số chiều còn lại là đủ nhỏ để có thể bỏ qua (*trình bày chi tiết ở các phần sau*).
- Hệ cơ sở mới còn được gọi là các *thành phần chính* - *PCs* (*principal components*).

Một số ứng dụng của PCA

- Giảm chiều dữ liệu (Dimension Reduction).
 - » Giảm chi phí tính toán trên không gian có số chiều lớn.
- Trực quan hóa dữ liệu (Data visualization).
 - » Các dữ liệu ở số chiều lớn được giảm xuống 3 hoặc 2 chiều (đảm bảo tính thông tin) để dàng cho việc trực quan.
- Nén ảnh (Image Compression).
 - » Đảm bảo tính thông tin khi nén và truyền tải dữ liệu không bị mất quá nhiều.

...

Table of Contents

1 Introduction

2 Phép phân tích thành phần chính của tổng thể

3 Mô tả phương sai mẫu bằng các vectơ thành phần chính

4 Biểu diễn các vectơ thành phần chính

Phép phân tích thành phần chính của tổng thể

Cho vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ với các trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$

Xét các tổ hợp tuyến tính sau:

Phép phân tích thành phần chính của tổng thể

Cho vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ với các trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$

Xét các tổ hợp tuyến tính sau:

$$Y_1 = \mathbf{a}_1^T \mathbf{X} = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p$$

$$Y_2 = \mathbf{a}_2^T \mathbf{X} = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p$$

$$\vdots$$

$$Y_p = \mathbf{a}_p^T \mathbf{X} = a_{p1}X_1 + a_{p2}X_2 + \dots + a_{pp}X_p$$

Phép phân tích thành phần chính của tổng thể

Cho vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ với các trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$

Xét các tổ hợp tuyến tính sau:

$$\begin{aligned} Y_1 &= \mathbf{a}_1^T \mathbf{X} = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p \\ Y_2 &= \mathbf{a}_2^T \mathbf{X} = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p \\ &\vdots \\ Y_p &= \mathbf{a}_p^T \mathbf{X} = a_{p1}X_1 + a_{p2}X_2 + \dots + a_{pp}X_p \end{aligned}$$

Khi đó, ta có: (**Kết quả 2-43**)

$$\begin{aligned} \text{Var}(Y_i) &= \mathbf{a}_i^T \Sigma \mathbf{a}_i, \quad i = 1, 2, \dots, p \\ \text{Cov}(Y_i, Y_k) &= \mathbf{a}_i^T \Sigma \mathbf{a}_k, \quad i, k = 1, 2, \dots, p \end{aligned}$$

Phép phân tích thành phần chính của tổng thể

Các thành phần chính $Y_1, Y_2, \dots, Y_p$ là các tổ hợp tuyến tính *không tương quan* sao cho mỗi phương sai Y_i là lớn nhất có thể

Phép phân tích thành phần chính của tổng thể

Các thành phần chính $Y_1, Y_2, \dots, Y_p$ là các tổ hợp tuyến tính *không tương quan* sao cho mỗi phương sai Y_i là lớn nhất có thể

Như vậy, thành phần chính thứ nhất là tổ hợp tuyến tính với phương sai đạt giá trị lớn nhất, tức:

Phép phân tích thành phần chính của tổng thể

Các thành phần chính $Y_1, Y_2, \dots, Y_p$ là các tổ hợp tuyến tính *không tương quan* sao cho mỗi phương sai Y_i là lớn nhất có thể

Như vậy, thành phần chính thứ nhất là tổ hợp tuyến tính với phương sai đạt giá trị lớn nhất, tức:

$$\max_{\mathbf{a}_1 \in \mathbb{R}^p} \text{Var}(Y_1) = \max_{\mathbf{a}_1 \in \mathbb{R}^p} \mathbf{a}_1^T \Sigma \mathbf{a}_1$$

Phép phân tích thành phần chính của tổng thể

Các thành phần chính $Y_1, Y_2, \dots, Y_p$ là các tổ hợp tuyến tính *không tương quan* sao cho mỗi phương sai Y_i là lớn nhất có thể

Như vậy, thành phần chính thứ nhất là tổ hợp tuyến tính với phương sai đạt giá trị lớn nhất, tức:

$$\max_{\mathbf{a}_1 \in \mathbb{R}^p} \text{Var}(Y_1) = \max_{\mathbf{a}_1 \in \mathbb{R}^p} \mathbf{a}_1^T \Sigma \mathbf{a}_1$$

Nhận thấy rằng ta có thể tăng $\text{Var}(Y_1) = \mathbf{a}_1^T \Sigma \mathbf{a}_1$ bằng cách nhân $\mathbf{a}_1$ bởi 1 hằng số $c \in \mathbb{R}, c \neq 0$ bất kì.

Phép phân tích thành phần chính của tổng thể

Các thành phần chính $Y_1, Y_2, \dots, Y_p$ là các tổ hợp tuyến tính *không tương quan* sao cho mỗi phương sai Y_i là lớn nhất có thể

Như vậy, thành phần chính thứ nhất là tổ hợp tuyến tính với phương sai đạt giá trị lớn nhất, tức:

$$\max_{\mathbf{a}_1 \in \mathbb{R}^p} \text{Var}(Y_1) = \max_{\mathbf{a}_1 \in \mathbb{R}^p} \mathbf{a}_1^T \Sigma \mathbf{a}_1$$

Nhận thấy rằng ta có thể tăng $\text{Var}(Y_1) = \mathbf{a}_1^T \Sigma \mathbf{a}_1$ bằng cách nhân $\mathbf{a}_1$ bởi 1 hằng số $c \in \mathbb{R}, c \neq 0$ bất kì.

Tức, trừ khi $\Sigma = 0$, ta có thể chọn $\mathbf{a}_1 \in \mathbb{R}^p$ sao cho $\mathbf{a}_1^T \Sigma \mathbf{a}_1 > 0$. Cố định $\mathbf{a}_1$ đó thì:

$$\lim_{c \rightarrow \infty} (c\mathbf{a}_1)^T \Sigma (c\mathbf{a}_1) = \lim_{c \rightarrow \infty} c^2 \mathbf{a}_1^T \Sigma \mathbf{a}_1 = +\infty$$

Do đó có thể xảy ra trường hợp $\max_{\mathbf{a}_1 \in \mathbb{R}^p} \text{Var}(Y_1) = +\infty$

Phép phân tích thành phần chính của tổng thể

Như vậy để tránh trường hợp này, ta sẽ đặt thêm điều kiện cho $\mathbf{a}_i$ và thông thường ta chọn $\mathbf{a}_i$ là vectơ đơn vị

Phép phân tích thành phần chính của tổng thể

Như vậy để tránh trường hợp này, ta sẽ đặt thêm điều kiện cho $\mathbf{a}_i$ và thông thường ta chọn $\mathbf{a}_i$ là vectơ đơn vị

Khi đó ta định nghĩa:

Thành phần chính thứ nhất = Tổ hợp tuyến tính $\mathbf{a}_1^T \mathbf{X}$
sao cho cực đại $\text{Var}(\mathbf{a}_1^T \mathbf{X})$
với điều kiện $\mathbf{a}_1^T \mathbf{a}_1 = 1$

Thành phần chính thứ hai = Tổ hợp tuyến tính $\mathbf{a}_2^T \mathbf{X}$
sao cho cực đại $\text{Var}(\mathbf{a}_2^T \mathbf{X})$
với điều kiện $\mathbf{a}_2^T \mathbf{a}_2 = 1$
và $\text{Cov}(\mathbf{a}_1^T \mathbf{X}, \mathbf{a}_2^T \mathbf{X}) = 0$

Phép phân tích thành phần chính của tổng thể

Tổng quát,

Thành phần chính thứ i = Tổ hợp tuyến tính $\mathbf{a}_i^T \mathbf{X}$
sao cho cực đại $\text{Var}(\mathbf{a}_i^T \mathbf{X})$
với điều kiện $\mathbf{a}_i^T \mathbf{a}_i = 1$
và $\text{Cov}(\mathbf{a}_i^T \mathbf{X}, \mathbf{a}_k^T \mathbf{X}) = 0 \ \forall k < i$

Phép phân tích thành phần chính của tổng thể

Kết quả 8.1

Cho Σ là ma trận hiệp phương sai của vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, \dots, X_p]$. Gọi $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ là các cặp trị riêng, vectơ riêng của ma trận Σ , với $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Khi đó, thành phần chính thứ i được cho bởi:

$$Y_i = \mathbf{e}_i^T \mathbf{X} = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p, \quad i = 1, 2, \dots, p$$

Khi đó:

$$\begin{aligned} \text{Var}(Y_i) &= \mathbf{e}_i^T \Sigma \mathbf{e}_i = \lambda_i \\ \text{Cov}(Y_i, Y_k) &= \mathbf{e}_i^T \Sigma \mathbf{e}_k = 0, \quad i \neq k \end{aligned}$$

Chứng minh kết quả 8.1

Nhắc lại **Kết quả 2-51** và **Kết quả 2-52**

Chứng minh kết quả 8.1

Nhắc lại **Kết quả 2-51** và **Kết quả 2-52**

Kết quả 2-51, 52

Cho $\mathbf{B}$ là ma trận $p \times p$, đối xứng và xác định dương với các trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ ứng với các trị riêng trực chuẩn $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p$. Khi đó:

$$\max_{\mathbf{x} \neq 0} \frac{\mathbf{x}^T \mathbf{B} \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \lambda_1 \text{ (đạt được khi } \mathbf{x} = \mathbf{e}_1)$$

$$\min_{\mathbf{x} \neq 0} \frac{\mathbf{x}^T \mathbf{B} \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \lambda_p \text{ (đạt được khi } \mathbf{x} = \mathbf{e}_p)$$

$$\max_{\mathbf{x} \perp \mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k} \frac{\mathbf{x}^T \mathbf{B} \mathbf{x}}{\mathbf{x}^T \mathbf{x}} = \lambda_{k+1} \text{ (đạt được khi } \mathbf{x} = \mathbf{e}_{k+1})$$

Chứng minh kết quả 8.1

Do Σ là ma trận đối xứng thực nên ta tìm được một cơ sở trực chuẩn $(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p)$ tức:

$$\begin{aligned}\mathbf{e}_i^T \mathbf{e}_i &= 1 \\ \mathbf{e}_i^T \mathbf{e}_k &= 0 \quad \forall i \neq k\end{aligned}$$

Chứng minh kết quả 8.1

Do Σ là ma trận đối xứng thực nên ta tìm được một cơ sở trực chuẩn $(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p)$ tức:

$$\begin{aligned}\mathbf{e}_i^T \mathbf{e}_i &= 1 \\ \mathbf{e}_i^T \mathbf{e}_k &= 0 \quad \forall i \neq k\end{aligned}$$

Áp dụng **kết quả 2-51**, ta được:

$$\max_{\mathbf{a} \neq 0} \frac{\mathbf{a}^T \Sigma \mathbf{a}}{\mathbf{a}^T \mathbf{a}} = \lambda_1, \text{ đạt được khi } \mathbf{a} = \mathbf{e}_1$$

Do $\mathbf{e}_1^T \mathbf{e}_1 = 1$ nên:

$$\max_{\mathbf{a} \neq 0} \frac{\mathbf{a}^T \Sigma \mathbf{a}}{\mathbf{a}^T \mathbf{a}} = \lambda_1 = \frac{\mathbf{e}_1^T \Sigma \mathbf{e}_1}{\mathbf{e}_1^T \mathbf{e}_1} = \mathbf{e}_1^T \Sigma \mathbf{e}_1 = \text{Var}(Y_1)$$

Chứng minh kết quả 8.1

Tương tự, sử dụng **Kết quả 2-52** ta được:

$$\max_{\mathbf{a} \perp \mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k} \frac{\mathbf{a}^T \Sigma \mathbf{a}}{\mathbf{a}^T \mathbf{a}} = \lambda_{k+1}, k = 1, 2, \dots, p-1$$

đạt được khi $\mathbf{a} = \mathbf{e}_{k+1}$

Khi đó:

$$\max_{\mathbf{a} \perp \mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k} \frac{\mathbf{a}^T \Sigma \mathbf{a}}{\mathbf{a}^T \mathbf{a}} = \lambda_{k+1} = \frac{\mathbf{e}_{k+1}^T \Sigma \mathbf{e}_{k+1}}{\mathbf{e}_{k+1}^T \mathbf{e}_{k+1}} = \mathbf{e}_{k+1}^T \Sigma \mathbf{e}_{k+1} = \text{Var}(Y_{k+1})$$

Cuối cùng, $\forall i \neq k$, ta có:

$$\begin{aligned} \text{Cov}(Y_i, Y_k) &= \mathbf{e}_i^T \Sigma \mathbf{e}_k \\ &= \mathbf{e}_i^T (\Sigma \mathbf{e}_k) \\ &= \mathbf{e}_i^T \lambda_k \mathbf{e}_k \\ &= \lambda_k \mathbf{e}_i^T \mathbf{e}_k = 0 \end{aligned}$$

Ta có đpcm

Phép phân tích thành phần chính của tổng thể

Nhận xét: Từ **Kết quả 8.1**, các thành phần chính không tương quan lẫn nhau và có phương sai là trị riêng của ma trận hiệp phương sai Σ

Phép phân tích thành phần chính của tổng thể

Nhận xét: Từ **Kết quả 8.1**, các thành phần chính không tương quan lẫn nhau và có phương sai là trị riêng của ma trận hiệp phương sai Σ

Kết quả 8.2

Cho vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ với các cặp trị riêng vectơ riêng $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ trong đó $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Đặt $Y_i = \mathbf{e}_i^T \mathbf{X}$, $i = 1, \dots, p$ là các thành phần chính. Khi đó:

$$\begin{aligned}\sigma_{11} + \sigma_{22} + \dots + \sigma_{pp} &= \sum_{i=1}^p \text{Var}(X_i) \\ &= \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p \text{Var}(Y_i)\end{aligned}$$

Chứng minh kết quả 8.2

Do Σ là ma trận đối xứng thực nên tồn tại ma trận trực giao P sao cho:

$$\Sigma = P^T D P$$

với D là ma trận đường chéo chỉ chứa các trị riêng của Σ

Khi đó:

$$\begin{aligned} \sum_{i=1}^p \text{Var}(X_i) &= \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} \\ &= \text{tr}(\Sigma) = \text{tr}(P^T D P) = \text{tr} \left[P^T (D P) \right] = \text{tr} \left[(D P) P^T \right] \\ &= \text{tr} \left(D P P^T \right) = \text{tr}(D I) \text{ (do } P \text{ là ma trận trực giao)} \\ &= \text{tr}(D) = \lambda_1 + \lambda_2 + \cdots + \lambda_p \\ &= \sum_{j=1}^p \text{Var}(Y_j) \text{ (theo Kết quả 8.2)} \end{aligned}$$

Ta có đpcm

Phép phân tích thành phần chính của tổng thể

Nhận xét: Kết quả 8.2 nói rằng:

$$\begin{aligned}\text{Tổng phương sai tổng thể} &= \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} \\ &= \lambda_1 + \lambda_2 + \cdots + \lambda_p\end{aligned}$$

và do đó, phần trăm của tổng phương sai được giải thích bởi thành phần chính thứ k là:

$$\frac{\lambda_k}{\lambda_1 + \lambda_2 + \cdots + \lambda_p} \quad k = 1, 2, \dots, p$$

Phép phân tích thành phần chính của tổng thể

Nhận xét: Kết quả 8.2 nói rằng:

$$\begin{aligned}\text{Tổng phương sai tổng thể} &= \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} \\ &= \lambda_1 + \lambda_2 + \cdots + \lambda_p\end{aligned}$$

và do đó, phần trăm của tổng phương sai được giải thích bởi thành phần chính thứ k là:

$$\frac{\lambda_k}{\lambda_1 + \lambda_2 + \cdots + \lambda_p} \quad k = 1, 2, \dots, p$$

Như vậy, nếu đa số phương sai tổng thể (80%, 90% chẳng hạn) được giải thích bởi một, hai hoặc ba thành phần chính thì ta có thể 'thay thế' vectơ p biến ban đầu bởi các thành phần chính này mà không mất quá nhiều thông tin

Phép phân tích thành phần chính của tổng thể

Mỗi hệ số của vectơ $\mathbf{e}_i^T = [e_{i1}, e_{i2}, \dots, e_{ip}]$ cũng nên xem xét. Độ lớn của e_{ik} đánh giá độ quan trọng của biến thứ k với thành phần chính thứ i độc lập với các biến khác

Phép phân tích thành phần chính của tổng thể

Mỗi hệ số của vectơ $\mathbf{e}_i^T = [e_{i1}, e_{i2}, \dots, e_{ip}]$ cũng nên xem xét. Độ lớn của e_{ik} đánh giá độ quan trọng của biến thứ k với thành phần chính thứ i độc lập với các biến khác

Kết quả 8.3

Nếu $Y_1 = \mathbf{e}_1^T \mathbf{X}$, $Y_2 = \mathbf{e}_2^T \mathbf{X}$, $\dots$, $Y_p = \mathbf{e}_p^T \mathbf{X}$ là các thành phần chính từ ma trận hiệp phương sai Σ . Khi đó:

$$\rho_{Y_i, X_k} = \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}, i, k = 1, 2, \dots, p$$

là hệ số tương quan giữa thành phần Y_i và biến X_k , với e_{ik} là hệ số thứ k của vectơ $\mathbf{e}_i$

Nhắc lại, ở đây, $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ là các cặp trị riêng, vectơ riêng của Σ và $\mathbf{X}^T = [X_1, X_2, \dots, X_k, \dots, X_p]$

Chứng minh kết quả 8.3

Đặt $\mathbf{a}_k^T = [0, \dots, 0, 1, 0, \dots, 0]$. Khi đó $X_k = \mathbf{a}_k^T \mathbf{X}$. Ta có:

$$\begin{aligned}\text{Cov}(Y_i, X_k) &= \text{Cov}(\mathbf{e}_i^T \mathbf{X}, \mathbf{a}_k^T \mathbf{X}) = \mathbf{e}_i^T \Sigma \mathbf{a}_k \\ &= (\Sigma \mathbf{e}_i)^T \mathbf{a}_k = (\lambda_i \mathbf{e}_i)^T \mathbf{a}_k \\ &= \lambda_i \mathbf{e}_i^T \mathbf{a}_k = \lambda_i e_{ik}\end{aligned}$$

Khi đó:

$$\begin{aligned}\rho_{Y_i, X_k} &= \frac{\text{Cov}(Y_i, X_k)}{\sqrt{\text{Var}(Y_i)} \sqrt{\text{Var}(X_k)}} = \frac{\lambda_i e_{ik}}{\sqrt{\lambda_i} \sqrt{\sigma_{kk}}} \\ &= \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}\end{aligned}$$

Ta có đpcm

Phép phân tích thành phần chính của tổng thể

Kết quả 8.3 thường được sử dụng để giải thích các thành phần chính. Khi đó, ta đang đánh giá mức độ quan trọng của biến X_k đối với thành phần chính Y_i mà không quan tâm đến sự hiện diện của các biến khác

¹Rencherm A.C, "Interpretation of Canonical Discriminant Functions, Canonical Variates and Principle Components", *The American Statistician*

Phép phân tích thành phần chính của tổng thể

Kết quả 8.3 thường được sử dụng để giải thích các thành phần chính. Khi đó, ta đang đánh giá mức độ quan trọng của biến X_k đối với thành phần chính Y_i mà không quan tâm đến sự hiện diện của các biến khác. Vì thế, một vài nhà thống kê (chẳng hạn, Rencher ¹) đề xuất sử dụng hệ số e_{ik} để giải thích các thành phần chính. Điều này sẽ được thể hiện trong

Ví dụ 8.1

¹Rencher A.C, "Interpretation of Canonical Discriminant Functions, Canonical Variates and Principle Components", *The American Statistician*

Phép phân tích thành phần chính của tổng thể

Ví dụ 8.1 Cho vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, X_3]$ có ma trận hiệp phương sai:

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

Phép phân tích thành phần chính của tổng thể

Ví dụ 8.1 Cho vectơ ngẫu nhiên $\mathbf{X}^T = [X_1, X_2, X_3]$ có ma trận hiệp phương sai:

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

Đa thức đặc trưng $P_{\Sigma}(\lambda) = |\Sigma - \lambda \mathbf{I}_3| = (\lambda - 2)(\lambda^2 - 6\lambda + 1)$

Ví dụ 8.1

Các trị riêng, vectơ riêng (sắp xếp theo chiều giảm dần các trị riêng):

$$\lambda_1 = 3 + 2\sqrt{2}, \quad \mathbf{a}_1^T = [1 - \sqrt{2}, 1, 0]$$

$$\lambda_2 = 2, \quad \mathbf{a}_2^T = [0, 0, 1]$$

$$\lambda_3 = 3 - 2\sqrt{2}, \quad \mathbf{a}_3^T = [1 + \sqrt{2}, 1, 0]$$

Ví dụ 8.1

Các trị riêng, vectơ riêng (sắp xếp theo chiều giảm dần các trị riêng):

$$\lambda_1 = 3 + 2\sqrt{2}, \quad \mathbf{a}_1^T = [1 - \sqrt{2}, 1, 0]$$

$$\lambda_2 = 2, \quad \mathbf{a}_2^T = [0, 0, 1]$$

$$\lambda_3 = 3 - 2\sqrt{2}, \quad \mathbf{a}_3^T = [1 + \sqrt{2}, 1, 0]$$

Trực chuẩn hóa bằng thuật toán Gram-Schmidt ta được:

$$\lambda_1 = 3 + 2\sqrt{2}, \quad \mathbf{e}_1^T = \frac{1}{\sqrt{4 - 2\sqrt{2}}}[\sqrt{2} - 1, -1, 0]$$

$$\lambda_2 = 2, \quad \mathbf{e}_2^T = [0, 0, 1]$$

$$\lambda_3 = 3 - 2\sqrt{2}, \quad \mathbf{e}_3^T = \frac{1}{\sqrt{4 + 2\sqrt{2}}}[1 + \sqrt{2}, 1, 0]$$

Ví dụ 8.1

Khi đó, các thành phần chính được xác định bởi:

$$Y_1 = \mathbf{e}_1^T \mathbf{X} \approx 0.383X_1 - 0.924X_2$$

$$Y_2 = \mathbf{e}_2^T \mathbf{X} = X_3$$

$$Y_3 = \mathbf{e}_3^T \mathbf{X} \approx 0.924X_1 + 0.383X_2$$

Ví dụ 8.1

Nhận xét: Biến X_3 là một thành phần chính do nó độc lập với các biến còn lại

- Kiểm chứng **Kết quả 8.1**

$$\begin{aligned}\text{Var}(Y_1) &= \text{Var}(0.383X_1 - 0.924X_2) \\ &= (0.383)^2\text{Var}(X_1) + (-0.924)^2\text{Var}(X_2) \\ &\quad + 2(0.383)(-0.924)\text{Cov}(X_1, X_2) \\ &= (0.383)^2 + 5(-0.924)^2 + 2(0.383)(-0.924)(-2) \\ &= 5.831 \approx \lambda_1\end{aligned}$$

$$\begin{aligned}\text{Cov}(Y_1, Y_2) &= \text{Cov}(0.383X_1 - 0.924X_2, X_3) \\ &= 0.383\text{Cov}(X_1, X_3) - 0.924\text{Cov}(X_2, X_3) \\ &= (-0.383)(0) + (-0.924)(0) = 0\end{aligned}$$

Ví dụ 8.1

- Kiểm chứng **Kết quả 8.2**

$$\sigma_{11} + \sigma_{22} + \sigma_{33} = 1 + 5 + 2 = 8$$

$$\lambda_1 + \lambda_2 + \lambda_3 = (3 + 2\sqrt{2}) + 2 + (3 - 2\sqrt{2}) = 8$$

Vậy: $\sigma_{11} + \sigma_{22} + \sigma_{33} = \lambda_1 + \lambda_2 + \lambda_3$

Ví dụ 8.1

- Kiểm chứng **Kết quả 8.2**

$$\sigma_{11} + \sigma_{22} + \sigma_{33} = 1 + 5 + 2 = 8$$

$$\lambda_1 + \lambda_2 + \lambda_3 = (3 + 2\sqrt{2}) + 2 + (3 - 2\sqrt{2}) = 8$$

Vậy: $\sigma_{11} + \sigma_{22} + \sigma_{33} = \lambda_1 + \lambda_2 + \lambda_3$

Nhận xét:

Ví dụ 8.1

- Kiểm chứng **Kết quả 8.2**

$$\sigma_{11} + \sigma_{22} + \sigma_{33} = 1 + 5 + 2 = 8$$

$$\lambda_1 + \lambda_2 + \lambda_3 = (3 + 2\sqrt{2}) + 2 + (3 - 2\sqrt{2}) = 8$$

Vậy: $\sigma_{11} + \sigma_{22} + \sigma_{33} = \lambda_1 + \lambda_2 + \lambda_3$

Nhận xét:

- Phần trăm tổng phương sai được giải thích bởi thành phần chính thứ nhất $= \frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3} \approx 0.729$. Hơn nữa phần trăm tổng phương sai được

giải thích bởi hai thành phần chính đầu tiên $= \frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} \approx 0.979$

Như vậy, trong trường hợp này ta có thể thay thế ba biến ban đầu bởi hai thành phần chính mà không bị mất quá nhiều thông tin

Ví dụ 8.1

- Sử dụng **Kết quả 8.3** với $Y_1 \approx 0.383X_1 - 0.924X_2$, ta có:

$$\begin{aligned}\rho_{Y_1, X_1} &= \frac{e_{11}\sqrt{\lambda_1}}{\sigma_{11}} \approx 0.924 \\ \rho_{Y_1, X_2} &= \frac{e_{12}\sqrt{\lambda_1}}{\sqrt{\sigma_{22}}} \approx -0.997\end{aligned}$$

Nhận thấy X_2 có trọng số lớn nhất trong Y_1 , -0.924 và đồng thời có tương quan lớn nhất (theo nghĩa trị tuyệt đối)

Hệ số tương quan của X_1 với Y_1 gần bằng với X_2 (theo nghĩa trị tuyệt đối), cho thấy 2 biến X_1 và X_2 có độ quan trọng như nhau với thành phần chính thứ nhất Y_1 . Tuy nhiên, độ lớn tương đối giữa trọng số của X_1 và X_2 lại cho thấy biến X_2 đóng góp nhiều hơn trong Y_1 so với biến X_1

Phép phân tích thành phần chính từ các biến được chuẩn hóa

Các thành phần chính có thể tìm được với các biến được chuẩn hóa:

$$\begin{aligned}Z_1 &= \frac{X_1 - \mu_1}{\sqrt{\sigma_{11}}} \\Z_2 &= \frac{X_2 - \mu_2}{\sqrt{\sigma_{22}}} \\&\vdots \\Z_p &= \frac{X_p - \mu_p}{\sqrt{\sigma_{pp}}}\end{aligned}$$

hay:

$$\mathbf{Z} = (\mathbf{V}^{1/2})^{-1} (\mathbf{X} - \boldsymbol{\mu})$$

Phép phân tích thành phần chính từ các biến được chuẩn hóa

trong đó: $\mathbf{V}^{1/2} = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{\sigma_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix}$

Dễ thấy $\mathbb{E}(\mathbf{Z}) = 0$ và:

$$\text{Cov}(\mathbf{Z}) = (\mathbf{V}^{1/2})^{-1} \Sigma (\mathbf{V}^{1/2})^{-1} = \boldsymbol{\rho}$$

Khi đó các thành phần chính của $\mathbf{Z}$ được xây dựng từ các trị riêng, vectơ riêng của ma trận tương quan $\boldsymbol{\rho}$ của $\mathbf{X}$

Phép phân tích thành phần chính từ các biến được chuẩn hóa

trong đó: $\mathbf{V}^{1/2} = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{\sigma_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix}$

Dễ thấy $\mathbb{E}(\mathbf{Z}) = 0$ và:

$$\text{Cov}(\mathbf{Z}) = (\mathbf{V}^{1/2})^{-1} \Sigma (\mathbf{V}^{1/2})^{-1} = \rho$$

Khi đó các thành phần chính của $\mathbf{Z}$ được xây dựng từ các trị riêng, vectơ riêng của ma trận tương quan ρ của $\mathbf{X}$

Lưu ý rằng *nói một cách tổng quát, các cặp trị riêng, vectơ riêng từ Σ không giống với các cặp trị riêng, vectơ riêng từ ρ*

Các kết quả 8.1, 8.2, 8.3 vẫn được áp dụng và tóm tắt trong **Kết quả 8.4** dưới đây

Phép phân tích thành phần chính từ các biến được chuẩn hóa

Kết quả 8.4

Thành phần chính thứ i của biến ngẫu nhiên được chuẩn hóa

$\mathbf{Z}^T = [Z_1, Z_2, \dots, Z_p]$, với $\text{Cov}(\mathbf{Z}) = \boldsymbol{\rho}$, cho bởi:

$$Y_i = \mathbf{e}_i^T \mathbf{Z} = \mathbf{e}_i^T (\mathbf{V}^{1/2})^{-1} (\mathbf{X} - \boldsymbol{\mu}), \quad i = 1, 2, \dots, p$$

Hơn nữa:

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var} Z_i = p$$

và

$$\rho_{Y_i, Z_k} = e_{ik} \sqrt{\lambda_i}, \quad i = 1, 2, \dots, p$$

Phép phân tích thành phần chính từ các biến được chuẩn hóa

Trong đó, $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ là các cặp trị riêng, vectơ riêng của $\boldsymbol{\rho}$ với $\lambda_1 \geq \lambda_2 \geq \lambda_p \geq 0$ và $(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p)$ là 1 cơ sở trực chuẩn

Phép phân tích thành phần chính từ các biến được chuẩn hóa

Trong đó, $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \dots, (\lambda_p, \mathbf{e}_p)$ là các cặp trị riêng, vectơ riêng của ρ với $\lambda_1 \geq \lambda_2 \geq \lambda_p \geq 0$ và $(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p)$ là 1 cơ sở trực chuẩn

Nhận xét: Từ kết quả trên, phần trăm của tổng phương sai của tổng thể (đã được chuẩn hóa) giải thích bởi thành phần chính thứ k là $\frac{\lambda_k}{p}$

Phép phân tích thành phần chính từ các biến được chuẩn hóa

Ví dụ 8.2 Xét ma trận hiệp phương sai:

$$\Sigma = \begin{bmatrix} 1 & 4 \\ 4 & 100 \end{bmatrix}$$

Khi đó ta tính được ma trận tương quan:

$$\rho = \begin{bmatrix} 1 & 0.4 \\ 0.4 & 1 \end{bmatrix}$$

Ví dụ 8.2

Cặp trị riêng - vectơ riêng của Σ là:

$$\begin{aligned}\lambda_{1,\Sigma} &\approx 100.16, & \mathbf{e}_1^T &= [0.040, 0.999] \\ \lambda_{2,\Sigma} &\approx 0.84, & \mathbf{e}_2^T &= [0.999, -0.040]\end{aligned}$$

và các thành phần chính tương ứng:

$$\begin{aligned}Y_{1,\Sigma} &= 0.040X_1 + 0.999X_2 \\ Y_{2,\Sigma} &= 0.999X_1 - 0.040X_2\end{aligned}$$

Ví dụ 8.2

Tương tự, cặp trị riêng - vectơ riêng của ρ là:

$$\begin{aligned}\lambda_{1,\rho} &= 1.4, & \mathbf{e}_1^T &= [0.707, 0.707] \\ \lambda_{2,\rho} &= 0.6, & \mathbf{e}_2^T &= [0.707, -0.707]\end{aligned}$$

và các thành phần chính tương ứng:

$$\begin{aligned}Y_{1,\rho} &= 0.707 \left(\frac{X_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) + 0.707 \left(\frac{X_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \\ &= 0.707(X_1 - \mu_1) + 0.707(X_2 - \mu_2) \\ Y_{2,\rho} &= 0.707 \left(\frac{X_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) - 0.707 \left(\frac{X_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \\ &= 0.707(X_1 - \mu_1) - 0.707(X_2 - \mu_2)\end{aligned}$$

Phép phân tích thành phần chính với ma trận hiệp phương sai có cấu trúc đặc biệt

Có những cấu trúc của ma trận hiệp phương sai/ ma trận tương quan mà ở đó các thành phần chính của nó có thể viết dưới dạng đơn giản. Ở đây ta sẽ xét hai cấu trúc đặc biệt sau

Phép phân tích thành phần chính với ma trận hiệp phương sai có cấu trúc đặc biệt: Cấu trúc thứ nhất

Ma trận đường chéo

$$\Sigma = \begin{bmatrix} \sigma_{11} & 0 & \cdots & 0 \\ 0 & \sigma_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{pp} \end{bmatrix}$$

Phép phân tích thành phần chính với ma trận hiệp phương sai có cấu trúc đặc biệt: Cấu trúc thứ nhất

Ma trận đường chéo

$$\Sigma = \begin{bmatrix} \sigma_{11} & 0 & \cdots & 0 \\ 0 & \sigma_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{pp} \end{bmatrix}$$

Bằng cách đặt $\mathbf{e}_i^T = [0, \dots, 0, 1, 0, \dots, 0]$ với số 1 nằm ở vị trí thứ $i = 1, 2, \dots, p$. Dễ dàng chỉ ra được:

$$\Sigma \mathbf{e}_i = \sigma_{ii} \mathbf{e}_i \quad \forall i = 1, 2, \dots, p$$

tức cặp trị riêng - vectơ riêng của Σ là $(\sigma_{ii}, \mathbf{e}_i), i = 1, 2, \dots, p$

Hơn nữa, do $\mathbf{e}_i^T \mathbf{X} = X_i$ nên các thành phần chính cũng chính là các biến X_i ban đầu

Phép phân tích thành phần chính với ma trận hiệp phương sai có cấu trúc đặc biệt: Cấu trúc thứ hai

Ma trận:

$$\Sigma = \begin{bmatrix} \sigma^2 & \rho\sigma^2 & \cdots & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 & \cdots & \rho\sigma^2 \\ \vdots & \vdots & \ddots & \vdots \\ \rho\sigma^2 & \rho\sigma^2 & \cdots & \sigma^2 \end{bmatrix}$$

cùng với ma trận tương quan:

$$\rho = \begin{bmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{bmatrix}$$

Phép phân tích thành phần chính với ma trận hiệp phương sai có cấu trúc đặc biệt: Cấu trúc thứ hai

Có thể chỉ ra được cặp trị riêng vectơ riêng của ma trận ρ là:

$$\begin{aligned}\lambda_1 = 1 + (p-1)\rho, \mathbf{e}_1^T &= \left[\frac{1}{\sqrt{p}}, \frac{1}{\sqrt{p}}, \dots, \frac{1}{\sqrt{p}} \right] \\ \lambda_i = 1 - \rho, \mathbf{e}_i^T &= \left[\frac{1}{\sqrt{(i-1)i}}, \dots, \frac{1}{\sqrt{(i-1)i}}, \frac{-(i-1)}{\sqrt{(i-1)i}}, 0, \dots, 0 \right]\end{aligned}$$

$$\forall i = 2, 3, \dots, p$$

Table of Contents

- 1 Introduction
- 2 Phép phân tích thành phần chính của tổng thể
- 3 Mô tả phương sai mẫu bằng các vectơ thành phần chính
- 4 Biểu diễn các vectơ thành phần chính

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Cho mẫu quan sát $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ tương ứng với mẫu ngẫu nhiên $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ lấy từ tổng thể có p chiều với kì vọng $\boldsymbol{\mu}$ và ma trận hiệp phương sai $\boldsymbol{\Sigma}$

Từ các quan sát này, ta tính được vectơ trung bình mẫu $\bar{\mathbf{x}}$, ma trận hiệp phương sai mẫu $\mathbf{S}$ và ma trận tương quan $\mathbf{R}$

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Nhắc lại rằng, nếu từng quan trắc trong mẫu quan sát đều cùng qua một phép biến đổi tuyến tính dưới dạng

$$\mathbf{a}_1^T \mathbf{x}_j = a_{11}x_{j1} + a_{12}x_{j2} + \cdots + a_{1p}x_{jp} \quad j = 1, 2, \dots, n$$

thì mẫu quan sát khi đó có trung bình và phương sai mẫu tương ứng là $\mathbf{a}_1^T \bar{\mathbf{x}}$ và $\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$.

Mặt khác, hai mẫu quan sát chứa từng cặp giá trị $(\mathbf{a}_1^T \mathbf{x}_j, \mathbf{a}_2^T \mathbf{x}_j)$ thì có hiệp phương sai hai mẫu là $\mathbf{a}_1^T \mathbf{S} \mathbf{a}_2$ (3-36)

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Giả sử vector thành phần chính thứ nhất cực đại $\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$, tương đương:

$$\frac{\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1}{\mathbf{a}_1^T \mathbf{a}_1}$$

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Giả sử vector thành phần chính thứ nhất cực đại $\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$, tương đương:

$$\frac{\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1}{\mathbf{a}_1^T \mathbf{a}_1}$$

Trị riêng lớn nhất $\hat{\lambda}_1$ có được khi chọn $\mathbf{a}_1 =$ vector riêng $\hat{\mathbf{e}}_1$ của ma trận covariance $\mathbf{S}$. (Kết quả 2.51)

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Giả sử vector thành phần chính thứ nhất cực đại $\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$, tương đương:

$$\frac{\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1}{\mathbf{a}_1^T \mathbf{a}_1}$$

Trị riêng lớn nhất $\hat{\lambda}_1$ có được khi chọn $\mathbf{a}_1 =$ vector riêng $\hat{\mathbf{e}}_1$ của ma trận covariance $\mathbf{S}$. (Kết quả 2.51)

Các vector thành phần chính còn lại được chọn sao cho $0 = \mathbf{a}_i^T \mathbf{S} \hat{\mathbf{e}}_k = \mathbf{a}_i^T \hat{\lambda}_k \hat{\mathbf{e}}_k$, hoặc nói cách khác $\mathbf{a}_i$ vuông góc với $\hat{\mathbf{e}}_k$. (với $i \neq k$)

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Cho ma trận hiệp phương sai mẫu $\mathbf{S} = \{s_{ik}\} \in \mathbb{M}_{p \times p}(\mathbb{R})$ với các cặp trị riêng - vector riêng tương ứng $(\hat{\lambda}_1, \hat{\mathbf{e}}_1), (\hat{\lambda}_2, \hat{\mathbf{e}}_2), \dots, (\hat{\lambda}_p, \hat{\mathbf{e}}_p)$. Thành phần chính thứ i được định nghĩa bởi

$$\hat{y}_i = \hat{\mathbf{e}}_i^T \mathbf{x} = \hat{e}_{i1}x_1 + \hat{e}_{i2}x_2 + \dots + \hat{e}_{ip}x_p, \quad i = 1, 2, \dots, p$$

sao cho $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0$ và $\mathbf{x}$ là một quan sát bất kỳ.

Mô tả phương sai mẫu bằng các vectơ thành phần chính

$$\begin{aligned}\text{Var}(\hat{y}_k) &= \hat{\lambda}_k, \quad k = 1, 2, \dots, p \\ \text{Cov}(\hat{y}_i, \hat{y}_k) &= 0, \quad i \neq k\end{aligned}$$

Mô tả phương sai mẫu bằng các vectơ thành phần chính

$$\begin{aligned}\text{Var}(\hat{y}_k) &= \hat{\lambda}_k, \quad k = 1, 2, \dots, p \\ \text{Cov}(\hat{y}_i, \hat{y}_k) &= 0, \quad i \neq k\end{aligned}$$

Thêm vào đó,

$$\text{Tổng phương sai mẫu} = \sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \hat{\lambda}_p$$

Mô tả phương sai mẫu bằng các vectơ thành phần chính

Chuẩn hóa các điểm dữ liệu $\mathbf{x}_j$ bằng cách trừ cho trung bình $\bar{\mathbf{x}}$. Thành phần chính thứ i th được định nghĩa bởi:

$$\hat{y}_i = \hat{\mathbf{e}}_i^T (\mathbf{x} - \bar{\mathbf{x}}), \quad i = 1, 2, \dots, p$$

Với $\mathbf{x}$ là một quan sát bất kỳ.

Xét các giá trị trên/của thành phần chính thứ i th

$$\hat{y}_{ji} = \hat{\mathbf{e}}_i^T (\mathbf{x}_j - \bar{\mathbf{x}}), \quad j = 1, 2, \dots, n$$

Khi đó,

$$\bar{\hat{y}}_i = \frac{1}{n} \sum_{j=1}^n \hat{\mathbf{e}}_i^T (\mathbf{x}_j - \bar{\mathbf{x}}) = \frac{1}{n} \hat{\mathbf{e}}_i^T \left(\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) \right) = \frac{1}{n} \hat{\mathbf{e}}_i^T \mathbf{0} = 0$$

Ví dụ 8.3

Số lượng thành phần chính

Q: Cần bao nhiêu vector thành phần chính ?

Số lượng thành phần chính

Q: Cần bao nhiêu vector thành phần chính ?

A: Như trình bày phía trước, phương sai của dữ liệu được biểu diễn thông qua giá trị riêng. Do vậy việc lựa chọn vector thành phần chính sẽ phụ thuộc rất nhiều vào điều này.

Số lượng thành phần chính




Figure 8.2 A scree plot.

Hình: Johnson-Wichern - Applied Multivariate Statistical Analysis

Ví dụ 8.4

Sự diễn giải cho các vector thành phần chính

Giả sử, $\mathbf{X}$ xấp xỉ phân phối chuẩn $\mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Khi đó, từ các giá trị quan sát $\mathbf{x}_j$, ta có thể xấp xỉ $\boldsymbol{\mu}$ bằng $\bar{\mathbf{x}}$ và $\boldsymbol{\Sigma}$ bằng $\mathbf{S}$. Nếu $\mathbf{S}$ là ma trận xác định dương, đường mức chứa các vector $\mathbf{x} \in \mathbb{R}^{p \times 1}$ nằm bên trong thỏa:

$$(\mathbf{x} - \bar{\mathbf{x}})^T \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}) = c^2 \quad (8-4)$$

là một ước lượng của "the constant density contour" $(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$

Sự diễn giải cho các vector thành phần chính

Ta có thể trích xuất các vector riêng và trị riêng từ ma trận hiệp phương sai mẫu $\mathbf{S}$. Từ đó, ta được các vector thành phần chính của mẫu.

Sự diễn giải cho các vector thành phần chính

Ta có thể trích xuất các vector riêng và trị riêng từ ma trận hiệp phương sai mẫu $\mathbf{S}$. Từ đó, ta được các vector thành phần chính của mẫu.

Hay nói cách khác, một hệ cơ sở mới cho dữ liệu sẽ được lấy từ các trục của đường mức là một ellipsoid (8-4). Từ đây định nghĩa một hyperellipsoid có tâm là $\bar{\mathbf{x}}$ và các trục là các vector riêng của $\mathbf{S}^{-1}$ hoặc $\mathbf{S}$. Độ lớn của các trục được xác định bởi $\sqrt{\hat{\lambda}_i}$, $i = 1, 2, \dots, p$ sao cho $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0$ là các trị riêng của $\mathbf{S}$.

Sự diễn giải cho các vector thành phần chính




Figure 8.4 Sample principal components and ellipses of constant distance.

Hình: Johnson-Wichern - Applied Multivariate Statistical Analysis

Sự diễn giải cho các vector thành phần chính

PCA dưới góc nhìn giảm chiều dữ liệu:

Giả sử sắp xếp các trị riêng theo chiều giảm dần. Nếu các trị riêng λ_i ở thứ tự cuối sao cho phương sai của các vector riêng $\mathbf{e}_i$ tương ứng là đủ nhỏ, thì các vector này có thể bỏ đi. Khi đó, thông tin của dữ liệu ban đầu có thể *xấp xỉ* thông qua các thành phần chính còn lại.

Chuẩn hóa các thành phần chính của mẫu

Đặt $\mathbf{D}$ là ma trận đường chéo $p \times p$ với các phần tử trên đường chéo chính là $s_{ii} \in \mathbf{S}, i = 1, \dots, p$. Dạng chuẩn hóa của mỗi quan sát:

$$\mathbf{z}_j = \mathbf{D}^{-1/2}(\mathbf{x}_j - \bar{\mathbf{x}}) = \begin{bmatrix} \frac{x_{j1} - \bar{x}_1}{\sqrt{s_{11}}} \\ \frac{x_{j2} - \bar{x}_2}{\sqrt{s_{22}}} \\ \vdots \\ \frac{x_{jp} - \bar{x}_p}{\sqrt{s_{pp}}} \end{bmatrix} \quad j = 1, 2, \dots, n \quad (8-25)$$

Chuẩn hóa các thành phần chính của mẫu

Ma trận chuẩn hóa $n \times p$ của các quan sát:

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1^T \\ \mathbf{z}_2^T \\ \vdots \\ \mathbf{z}_n^T \end{bmatrix} = \begin{bmatrix} z_{11} & z_{12} & \cdots & z_{1p} \\ z_{21} & z_{22} & \cdots & z_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ z_{n1} & z_{n2} & \cdots & z_{np} \end{bmatrix} = \begin{bmatrix} \frac{x_{11} - \bar{x}_1}{\sqrt{s_{11}}} & \frac{x_{12} - \bar{x}_1}{\sqrt{s_{22}}} & \cdots & \frac{x_{1p} - \bar{x}_p}{\sqrt{s_{pp}}} \\ \frac{x_{21} - \bar{x}_1}{\sqrt{s_{11}}} & \frac{x_{22} - \bar{x}_2}{\sqrt{s_{22}}} & \cdots & \frac{x_{2p} - \bar{x}_p}{\sqrt{s_{pp}}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{x_{n1} - \bar{x}_1}{\sqrt{s_{11}}} & \frac{x_{n2} - \bar{x}_2}{\sqrt{s_{22}}} & \cdots & \frac{x_{np} - \bar{x}_p}{\sqrt{s_{pp}}} \end{bmatrix}$$

Chuẩn hóa các thành phần chính của mẫu

Vector trung bình mẫu:

$$\bar{\mathbf{z}} = \frac{1}{n}(\mathbf{I}^T \mathbf{Z})^T = \frac{1}{n} \mathbf{Z}^T \mathbf{I} = \frac{1}{n} \begin{bmatrix} \sum_{j=1}^n \frac{x_{j1} - \bar{x}_1}{\sqrt{s_{11}}} \\ \sum_{j=1}^n \frac{x_{j2} - \bar{x}_2}{\sqrt{s_{22}}} \\ \vdots \\ \sum_{j=1}^n \frac{x_{jp} - \bar{x}_p}{\sqrt{s_{pp}}} \end{bmatrix} = \mathbf{0}$$

Chuẩn hóa các thành phần chính của mẫu

Ma trận hiệp phương sai mẫu

$$\mathbf{S}_z = \frac{1}{n-1} \begin{bmatrix} (n-1)s_{11} & (n-1)s_{12} & \dots & (n-1)s_{1p} \\ s_{11} & \sqrt{s_{11}}\sqrt{s_{22}} & \dots & \sqrt{s_{11}}\sqrt{s_{pp}} \\ (n-1)s_{12} & (n-1)s_{22} & \dots & (n-1)s_{2p} \\ \sqrt{s_{11}}\sqrt{s_{22}} & s_{22} & \dots & \sqrt{s_{22}}\sqrt{s_{pp}} \\ \vdots & \vdots & \ddots & \vdots \\ (n-1)s_{1p} & (n-1)s_{2p} & \dots & (n-1)s_{pp} \\ \sqrt{s_{11}}\sqrt{s_{pp}} & \sqrt{s_{22}}\sqrt{s_{pp}} & \dots & s_{pp} \end{bmatrix} = \mathbf{R}$$

Chuẩn hóa các thành phần chính của mẫu

Thành phần chính thứ i :

$$\hat{y}_i = \hat{\mathbf{e}}_i \mathbf{z} = \hat{e}_{i1} z_1 + \hat{e}_{i2} z_2 + \cdots + \hat{e}_{ip} z_p, \quad i = 1, \dots, p$$

Từ đó,

$$\text{Var}(\hat{y}_i) = \hat{\lambda}_i \quad i = 1, 2, \dots, p$$

$$\text{Cov}(\hat{y}_i, \hat{y}_k) = 0 \quad i \neq k$$

Hơn nữa,
$$\sum_{j=1}^n \text{Var}(z_j) = \text{tr}(\mathbf{R}) = p = \hat{\lambda}_1 + \hat{\lambda}_2 + \cdots + \hat{\lambda}_p$$

Tỉ lệ phương sai mẫu so với phương sai thành phần chính thứ $i = \frac{\hat{\lambda}_i}{p}$.

Table of Contents

- 1 Introduction
- 2 Phép phân tích thành phần chính của tổng thể
- 3 Mô tả phương sai mẫu bằng các vectơ thành phần chính
- 4 Biểu diễn các vectơ thành phần chính

Biểu diễn các vector thành phần chính

Trực quan các vector thành phần chính, có tác dụng:

- Phát hiện các dữ liệu ngoại lai.
- Kiểm định giả thuyết về phân phối chuẩn của dữ liệu

Biểu diễn các vector thành phần chính

Trực quan các vector thành phần chính, có tác dụng:

- Phát hiện các dữ liệu ngoại lai.
 - » Các thành phần chính cuối cùng có thể giúp xác định các điểm dữ liệu ngoại lai. Các quan sát được biểu diễn dưới dạng tổ hợp tuyến tính:

$$\begin{aligned}\mathbf{x}_j &= (\mathbf{x}_j^T \hat{\mathbf{e}}_1) \hat{\mathbf{e}}_1 + (\mathbf{x}_j^T \hat{\mathbf{e}}_2) \hat{\mathbf{e}}_2 + \cdots + (\mathbf{x}_j^T \hat{\mathbf{e}}_p) \hat{\mathbf{e}}_p \\ &= \hat{y}_{j1} \hat{\mathbf{e}}_1 + \hat{y}_{j2} \hat{\mathbf{e}}_2 + \cdots + \hat{y}_{jp} \hat{\mathbf{e}}_p\end{aligned}$$

- » Giá trị ngoại lai thường có ít nhất một trong các thành phần $\hat{y}_{jq}, \dots, \hat{y}_{jp}$ sao cho tổng bình phương của chúng là lớn, với $\overline{p}, \overline{q}$ là các chỉ số của vector thành phần chính cuối cùng đóng vai trò ít quan trọng.

Biểu diễn các vector thành phần chính

Trực quan các vector thành phần chính, có tác dụng:

- Phát hiện các dữ liệu ngoại lai.
 - » Các thành phần chính cuối cùng có thể giúp xác định các điểm dữ liệu ngoại lai. Các quan sát được biểu diễn dưới dạng tổ hợp tuyến tính:

$$\begin{aligned}\mathbf{x}_j &= (\mathbf{x}_j^T \hat{\mathbf{e}}_1) \hat{\mathbf{e}}_1 + (\mathbf{x}_j^T \hat{\mathbf{e}}_2) \hat{\mathbf{e}}_2 + \cdots + (\mathbf{x}_j^T \hat{\mathbf{e}}_p) \hat{\mathbf{e}}_p \\ &= \hat{y}_{j1} \hat{\mathbf{e}}_1 + \hat{y}_{j2} \hat{\mathbf{e}}_2 + \cdots + \hat{y}_{jp} \hat{\mathbf{e}}_p\end{aligned}$$

- » Giá trị ngoại lai thường có ít nhất một trong các thành phần $\hat{y}_{jq}, \dots, \hat{y}_{jp}$ sao cho tổng bình phương của chúng là lớn, với $\overline{p}, \overline{q}$ là các chỉ số của vector thành phần chính cuối cùng đóng vai trò ít quan trọng.
- Kiểm định giả thuyết về phân phối chuẩn của dữ liệu
 - » Vì các vector thành phần chính là tổ hợp tuyến tính của các quan sát ban đầu.
 - » Kiểm tra tính xấp xỉ phân phối chuẩn của các vector thành phần chính đầu tiên.

Example 8.7 (Plotting the principal components for the turtle data) We illustrate the plotting of principal components for the data on male turtles discussed in Example 8.4. The three sample principal components are

$$\hat{y}_1 = .683(x_1 - 4.725) + .510(x_2 - 4.478) + .523(x_3 - 3.703)$$

$$\hat{y}_2 = -.159(x_1 - 4.725) - .594(x_2 - 4.478) + .788(x_3 - 3.703)$$

$$\hat{y}_3 = -.713(x_1 - 4.725) + .622(x_2 - 4.478) + .324(x_3 - 3.703)$$

where $x_1 = \ln(\text{length})$, $x_2 = \ln(\text{width})$, and $x_3 = \ln(\text{height})$, respectively.

Hình: Johnson-Wichern - Applied Multivariate Statistical Analysis

-  Richard A. Johnson, and Dean W. Wichern, Applied Multivariate Statistical Analysis. *Sixth Edition*, 2007.
-  PCA and ICA, Julie Nutini
https://www.cs.ubc.ca/~jnutini/documents/mlrg_pca.pdf
-  C. M. Bishop. Pattern Recognition and Machine Learning, Springer, 2006.
-  Sebastian Raschka: Python Machine Learning, Second Edition
-  Principal Components Analysis
<https://machinelearningcoban.com/2017/06/15/pca/>
-  Scikit-learn Decomposition Module
<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

Cảm ơn cô và các bạn đã theo dõi phần trình bày!