



ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Thông kê nhiều chiều Tiểu luận kết thúc môn

Võ Thành Đạt

Ngày 13 tháng 2 năm 2023

Mục lục

1 Phần lý thuyết và ứng dụng	1
Câu 1 (Lý thuyết)	1
Câu 2 (Ứng dụng)	10
2 Phần bài tập	21
Câu 1	21
Câu 2	24
Câu 3	29
Câu 4	42

1 Phần lý thuyết và ứng dụng

Câu 1

Học viên trình bày lý thuyết về một trong hai chủ đề sau:

- Phương pháp phân tích thành phần chính,
- Phương pháp phân tích nhân tố.

Yêu cầu

- Trình bày đầy đủ, chi tiết và rõ ràng.
- Nội dung trình bày bằng tiếng Việt.

Bài làm.

PHÂN TÍCH THÀNH PHẦN CHÍNH

1 Giới thiệu

- Phương pháp thành phần chính (Principal Component Analysis - PCA) là phương pháp được dùng để giảm số chiều của một bộ dữ liệu mà trong đó có một số lượng lớn các biến có tương quan với nhau, trong khi vẫn giữ được lượng thông tin nhiều nhất có thể của bộ dữ liệu gốc.

- Việc giảm số chiều được thực hiện bởi việc biến đổi tập hợp các biến gốc sang một tập hợp các biến mới, gọi là các "thành phần chính" (principal component). Các thành phần mới này không tương quan với nhau và có thứ tự sao cho một vài thành phần đầu tiên giữ lại được nhiều nhất thông tin có thể của bộ dữ liệu.

Hai cách tiếp cận PCA

- Đại số: các thành phần chính là các tổ hợp tuyến tính của p biến gốc $X_1, \dots, X_p$ sao cho các thành phần chính có phương sai lớn nhất có thể và trực giao với nhau.
- Hình học: Thực hiện phép xoay để chuyển về một hệ trục tọa độ mới có khả năng biểu diễn dữ liệu tốt hơn, cho phép khám phá được những liên kết tiềm ẩn trong bộ dữ liệu cũ mà ta không thể thấy rõ trên hệ trục tọa độ cũ. Các trục tọa độ mới phải được đảm bảo là luôn trực giao đôi một với nhau.

2 Các thành phần chính của tổng thể (Population PCA)

Cho vector ngẫu nhiên $\mathbf{X}' = [X_1, X_2, \dots, X_p]$ có ma trận hiệp phương sai Σ với các trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$. Xét các tổ hợp tuyến tính

$$\begin{aligned} Y_1 &= \mathbf{a}_1' \mathbf{X} = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p \\ Y_2 &= \mathbf{a}_2' \mathbf{X} = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p \\ &\vdots \\ Y_p &= \mathbf{a}_p' \mathbf{X} = a_{p1}X_1 + a_{p2}X_2 + \dots + a_{pp}X_p \end{aligned}$$

Ta có

$$\begin{aligned} \text{Var}(Y_i) &= \mathbf{a}_i' \Sigma \mathbf{a}_i \quad i = 1, 2, \dots, p \\ \text{Cov}(Y_i, Y_k) &= \mathbf{a}_i' \Sigma \mathbf{a}_k \quad i, k = 1, 2, \dots, p \end{aligned}$$

Ta gọi các thành phần chính là các tổ hợp tuyến tính $Y_1, Y_2, \dots, Y_p$ sao cho các tổ hợp tuyến tính này *không tương quan* và có phương sai càng lớn càng tốt.

Ta định nghĩa

- Thành phần chính thứ nhất là tổ hợp tuyến tính $\mathbf{a}_1' \mathbf{X}$ làm cực đại $\text{Var}(\mathbf{a}_1' \mathbf{X})$ với $\mathbf{a}_1' \mathbf{a}_1 = 1$,
- Thành phần chính thứ hai là tổ hợp tuyến tính $\mathbf{a}_2' \mathbf{X}$ làm cực đại $\text{Var}(\mathbf{a}_2' \mathbf{X})$ với $\mathbf{a}_2' \mathbf{a}_2 = 1$ và $\text{Cov}(\mathbf{a}_1' \mathbf{X}, \mathbf{a}_2' \mathbf{X}) = 0$,
- $\vdots$
- Thành phần chính thứ i là tổ hợp tuyến tính $\mathbf{a}_i' \mathbf{X}$ làm cực đại $\text{Var}(\mathbf{a}_i' \mathbf{X})$ với $\mathbf{a}_i' \mathbf{a}_i = 1$ và $\text{Cov}(\mathbf{a}_i' \mathbf{X}, \mathbf{a}_k' \mathbf{X}) = 0, \quad k < i$.

Ta có kết quả sau:

Kết quả 1. Xét Σ là ma trận hiệp phương sai ứng với vector ngẫu nhiên $\mathbf{X}' = [X_1, X_2, \dots, X_p]$. Σ có các cặp trị riêng và vector riêng $(\lambda_1 \mathbf{e}_1), \dots, (\lambda_p, \mathbf{e}_p)$ với $\lambda_1 \geq \dots \geq \lambda_p \geq 0$. Khi đó, thành phần chính thứ i được xác định bởi

$$Y_i = \mathbf{e}_i' \mathbf{X} = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p, \quad i = 1, 2, \dots, p.$$

Ta có

$$\begin{aligned} \text{Var}(Y_i) &= \mathbf{e}_i' \Sigma \mathbf{e}_i = \lambda_i, \quad i = 1, 2, \dots, p, \\ \text{Cov}(Y_i, Y_k) &= \mathbf{e}_i' \Sigma \mathbf{e}_k = 0, \quad i \neq k. \end{aligned}$$

Như vậy, ta thấy rằng các thành phần chính không tương quan và có phương sai bằng với trị riêng của Σ .

Kết quả 2. Xét Σ là ma trận hiệp phương sai ứng với vector ngẫu nhiên $\mathbf{X}' = [X_1, X_2, \dots, X_p]$. Σ có các cặp trị riêng và vector riêng $(\lambda_1 \mathbf{e}_1), \dots, (\lambda_p, \mathbf{e}_p)$ với $\lambda_1 \geq \dots \geq \lambda_p \geq 0$. Xét các thành phần chính $Y_1 = \mathbf{e}_1' \mathbf{X}, Y_2 = \mathbf{e}_2' \mathbf{X}, \dots, Y_p = \mathbf{e}_p' \mathbf{X}$. Khi đó

$$\sigma_{11} + \sigma_{22} + \dots + \sigma_{pp} = \sum_{i=1}^p \text{Var}(X_i) = \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p \text{Var}(Y_i).$$

Do đó, phương sai tổng thể toàn phần bằng tổng các trị riêng. Dẫn tới, tỷ lệ phương sai tổng thể toàn phần (total population variance) được giải thích bởi thành phần chính thứ k là

$$0 < \frac{\lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p} < 1, \quad k = 1, \dots, p.$$

- Nếu hầu hết (80% - 90%) phương sai tổng thể toàn phần (với p lớn) có thể được quy cho một, hai hoặc ba thành phần chính đầu tiên thì các thành phần này có thể thay thế cho p biến ban đầu mà không làm mất nhiều thông tin.
- Độ lớn của e_{ik} đo tầm quan trọng của biến X_k đối với thành phần chính thứ i . Đặc biệt, e_{ik} tỷ lệ thuận với hệ số tương quan giữa Y_i và X_k .

Kết quả 3. Xét $Y_1 = \mathbf{e}_1' \mathbf{X}, Y_2 = \mathbf{e}_2' \mathbf{X}, \dots, Y_p = \mathbf{e}_p' \mathbf{X}$ là các thành phần chính từ ma trận hiệp phương sai Σ . Khi đó

$$\rho_{Y_i, X_k} = \frac{e_{ki} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}$$

là hệ số tương quan giữa thành phần Y_i và biến X_k và ρ là ma trận tương quan.

Các thành phần chính từ các biến được chuẩn hóa

Các thành phần chính cũng có thể thu được từ các biến được chuẩn hóa $\mathbf{Z}' = [Z_1, Z_2, \dots, Z_p]$, trong đó

$$Z_i = \frac{X_i - \mu_i}{\sqrt{\sigma_{ii}}}.$$

Viết dưới dạng ma trận sẽ là:

$$\mathbf{Z} = (\mathbf{V}^{1/2})^{-1} (\mathbf{X} - \boldsymbol{\mu}),$$

trong đó $\mathbf{V}^{1/2}$ là ma trận đường chéo độ lệch chuẩn, được định nghĩa là:

$$\mathbf{V}^{1/2} = \begin{pmatrix} \sqrt{\sigma_{11}} & & & \\ & \ddots & & \\ & & \ddots & \\ & & & \sqrt{\sigma_{pp}} \end{pmatrix}$$

Dễ thấy

$$E(\mathbf{Z}) = \mathbf{0} \text{ và } \text{Cov}(\mathbf{Z}) = \boldsymbol{\rho}.$$

Các thành phần chính của $\mathbf{Z}$ có thể thu được từ các vector riêng của ma trận tương quan $\boldsymbol{\rho}$. Tất cả các kết quả trước cũng đúng khi các biến được chuẩn hóa. Ta cũng sử dụng ký hiệu Y_i để chỉ thành phần chính thứ i và $(\lambda_i, \mathbf{e}_i)$ để chỉ cặp trị riêng - vector riêng của $\boldsymbol{\rho}$ hoặc $\boldsymbol{\Sigma}$. Tuy nhiên, $(\lambda_i, \mathbf{e}_i)$ của $\boldsymbol{\Sigma}$ nói chung không giống với $(\lambda_i, \mathbf{e}_i)$ của $\boldsymbol{\rho}$.

Kết quả 4. Thành phần chính thứ i của biến được chuẩn hoá $\mathbf{Z}' = [Z_1, Z_2, \dots, Z_p]$ với $\text{Cov}(\mathbf{Z}) = \boldsymbol{\rho}$ được biểu diễn dưới dạng

$$Y_i = \mathbf{e}_i' \mathbf{Z} = \mathbf{e}_i' (\mathbf{V}^{1/2})^{-1} (\mathbf{X} - \boldsymbol{\mu}), \quad i = 1, 2, \dots, p,$$

Ngoài ra,

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var}(Z_i) = p.$$

và

$$\rho_{Y_i, Z_k} = e_{ik} \sqrt{\lambda_i} \quad i, k = 1, 2, \dots, p.$$

Từ kết quả trên ta thấy tỷ lệ được giải thích bởi thành phần chính thứ k là

$$\frac{\lambda_k}{p}.$$

Các thành phần chính từ ma trận hiệp phương sai có cấu trúc đặc biệt

Xét ma trận chéo

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & 0 & \cdots & 0 \\ 0 & \sigma_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{pp} \end{bmatrix} \quad (1)$$

Đặt $\mathbf{e}_i' = [0, \dots, 0, 1, 0, \dots, 0]$ (1 ở vị trí i), ta có

$$\begin{bmatrix} \sigma_{11} & 0 & \cdots & 0 \\ 0 & \sigma_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{pp} \end{bmatrix} \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1\sigma_{ii} \\ 0 \\ \vdots \\ 0 \end{bmatrix} \text{ hay } \boldsymbol{\Sigma} \mathbf{e}_i = \sigma_{ii} \mathbf{e}_i.$$

Như vậy, $(\sigma_{ii}, \mathbf{e}_i)$ là cặp trị riêng - vector riêng thứ i . Mà $\mathbf{e}_i' \mathbf{X} = X_i$ nên tập các thành phần chính có thể coi là tập gốc của các biến ngẫu nhiên không tương quan.

Một ví dụ khác như sau. Xét ma trận hiệp phương sai liên quan tới sinh học (chẳng hạn, kích thước sinh vật) có dạng

$$\Sigma = \begin{bmatrix} \sigma^2 & \rho\sigma^2 & \cdots & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 & \cdots & \rho\sigma^2 \\ \vdots & \vdots & \ddots & \vdots \\ \rho\sigma^2 & \rho\sigma^2 & \cdots & \sigma^2 \end{bmatrix} \quad (2)$$

Ta tính được ma trận tương quan là

$$\rho = \begin{bmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{bmatrix} \quad (3)$$

và ma trận tương quan này chính là ma trận hiệp phương sai có biến chuẩn hoá. Ma trận (3) có p trị riêng có thể được chia thành 2 nhóm. Khi p dương, trị riêng lớn nhất là

$$\lambda_1 = 1 + (p - 1)\rho$$

với vector riêng tương ứng

$$\mathbf{e}'_1 = \left[\frac{1}{\sqrt{p}}, \frac{1}{\sqrt{p}}, \dots, \frac{1}{\sqrt{p}} \right].$$

Bây giờ ta còn lại $p - 1$ trị riêng

$$\lambda_2 = \lambda_3 = \cdots = \lambda_p = 1 - \rho.$$

Một cách để chọn các vector riêng ứng với các trị riêng này là

$$\begin{aligned} \mathbf{e}'_2 &= \left[\frac{1}{\sqrt{1 \times 2}}, \frac{-1}{\sqrt{1 \times 2}}, 0, \dots, 0 \right] \\ \mathbf{e}'_3 &= \left[\frac{1}{\sqrt{2 \times 3}}, \frac{1}{\sqrt{2 \times 3}}, \frac{-2}{\sqrt{2 \times 3}}, 0, \dots, 0 \right] \\ &\vdots \\ \mathbf{e}'_i &= \left[\frac{1}{\sqrt{(i-1)i}}, \dots, \frac{1}{\sqrt{(i-1)i}}, \frac{-(i-1)}{\sqrt{(i-1)i}}, 0, \dots, 0 \right] \\ &\vdots \\ \mathbf{e}'_p &= \left[\frac{1}{\sqrt{(p-1)p}}, \dots, \frac{1}{\sqrt{(p-1)p}}, \frac{-(p-1)}{\sqrt{(p-1)p}} \right] \end{aligned}$$

Khi đó, thành phần chính thứ nhất là

$$Y_1 = \mathbf{e}'_1 \mathbf{Z} = \frac{1}{\sqrt{p}} \sum_{i=1}^p Z_i$$

tỉ lệ với tổng của p biến chuẩn hoá khác. Thành phần chính này chiếm tỉ lệ

$$\frac{\lambda_1}{p} = \frac{1 + (p-1)\rho}{p} = \rho + \frac{1-\rho}{p}.$$

3 Sự biến thiên của mẫu (sample) bởi các thành phần chính

Xét bộ dữ liệu $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ từ không gian p chiều có trung bình μ và ma trận hiệp phương sai Σ . Bộ dữ liệu này sẽ có vector trung bình $\bar{\mathbf{x}}$, ma trận hiệp phương sai $\mathbf{S}$ và ma trận tương quan $\mathbf{R}$.

Cho $\mathbf{S}_{(p \times p)} = \{s_{ik}\}$ là ma trận hiệp phương sai mẫu với các cặp trị riêng - vector riêng $(\hat{\lambda}_1, \hat{\mathbf{e}}_1), (\hat{\lambda}_2, \hat{\mathbf{e}}_2), \dots, (\hat{\lambda}_p, \hat{\mathbf{e}}_p)$. Khi đó, thành phần chính thứ i là

$$\hat{y}_i = \hat{\mathbf{e}}_i' \mathbf{x} = \hat{e}_{i1}x_1 + \hat{e}_{i2}x_2 + \dots + \hat{e}_{ip}x_p, \quad i = 1, 2, \dots, p$$

với $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0$ và $\mathbf{x}$ là quan trắc của các biến $X_1, X_2, \dots, X_p$.

Hơn nữa,

$$\text{Phương sai mẫu } (\hat{y}_k) = \hat{\lambda}_k, \quad k = 1, 2, \dots, p$$

$$\text{Hiệp phương sai mẫu } (\hat{y}_i, \hat{y}_k) = 0, \quad i \neq k$$

$$\text{Phương sai mẫu toàn phần} = \sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \hat{\lambda}_p$$

Ngoài ra

$$r_{\hat{y}_i, x_k} = \frac{\hat{e}_{ik} \sqrt{\hat{\lambda}_i}}{\sqrt{s_{kk}}}, \quad i, k = 1, 2, \dots, p.$$

Số lượng thành phần chính

Câu hỏi ta quan tâm là cần bao nhiêu thành phần chính để có thể mô tả được gần như toàn bộ sự biến thiên của dữ liệu. Thông thường, các tiêu chuẩn sau dùng để xác định số thành phần chính cần giữ lại:

1) Tỷ lệ phương sai mẫu toàn phần được giải thích bởi q thành phần chính đầu tiên:

$$\frac{\sum_{j=1}^q \lambda_j}{\sum_{j=1}^p \lambda_j}, \quad q < p.$$

Ta sẽ chọn q sao cho q thành phần chính đầu tiên có thể giải thích được một lượng lớn sự biến thiên của dữ liệu (khoảng từ 70% – 80%).

2) Nếu PCA được thực hiện với dữ liệu chuẩn hóa, ta giữ lại q thành phần chính đầu tiên thỏa điều kiện $\lambda_q > 1$, tức là phương sai của các thành phần chính được giữ lại đều lớn hơn 1.

3) Sử dụng đồ thị Scree-plot: mô tả lượng phương sai được giải thích bởi từng thành phần chính, ta tìm kiếm một “điểm gãy/khuỷ tay” (elbow).

4) Quy tắc Kaiser: giữ lại q thành phần chính đầu tiên thỏa

$$\lambda_q > \bar{\lambda} = \frac{1}{p} \sum_{j=1}^p \lambda_j.$$

Chuẩn hoá thành phần chính của mẫu

$$\mathbf{Z} = \begin{bmatrix} \frac{x_{11} - \bar{x}_1}{\sqrt{s_{11}}} & \frac{x_{12} - \bar{x}_2}{\sqrt{s_{22}}} & \dots & \frac{x_{1p} - \bar{x}_p}{\sqrt{s_{pp}}} \\ \frac{x_{21} - \bar{x}_1}{\sqrt{s_{11}}} & \frac{x_{22} - \bar{x}_2}{\sqrt{s_{22}}} & \dots & \frac{x_{2p} - \bar{x}_p}{\sqrt{s_{pp}}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{x_{n1} - \bar{x}_1}{\sqrt{s_{11}}} & \frac{x_{n2} - \bar{x}_2}{\sqrt{s_{22}}} & \dots & \frac{x_{np} - \bar{x}_p}{\sqrt{s_{pp}}} \end{bmatrix}$$

Ta tính được vector trung bình mẫu

$$\bar{\mathbf{z}} = \frac{1}{n}(\mathbf{1}'\mathbf{Z})' = \frac{1}{n}\mathbf{Z}'\mathbf{1} = \frac{1}{n} \left[\sum_{j=1}^n \frac{x_{j1} - \bar{x}_1}{\sqrt{s_{11}}}, \sum_{j=1}^n \frac{x_{j2} - \bar{x}_2}{\sqrt{s_{22}}}, \dots, \sum_{j=1}^n \frac{x_{jp} - \bar{x}_p}{\sqrt{s_{pp}}} \right]' = \mathbf{0}$$

và ma trận hiệp phương sai mẫu

$$\begin{aligned} \mathbf{S}_z &= \frac{1}{n-1} \left(\mathbf{Z} - \frac{1}{n}\mathbf{1}\mathbf{1}'\mathbf{Z} \right)' \left(\mathbf{Z} - \frac{1}{n}\mathbf{1}\mathbf{1}'\mathbf{Z} \right) = \frac{1}{n-1} (\mathbf{Z} - \mathbf{1}\bar{\mathbf{z}}')' (\mathbf{Z} - \mathbf{1}\bar{\mathbf{z}}') \\ &= \frac{1}{n-1} \mathbf{Z}'\mathbf{Z} = \frac{1}{n-1} \begin{bmatrix} (n-1)s_{11} & (n-1)s_{12} & \dots & (n-1)s_{1p} \\ s_{11} & \sqrt{s_{11}}\sqrt{s_{22}} & \dots & \sqrt{s_{11}}\sqrt{s_{pp}} \\ (n-1)s_{12} & (n-1)s_{22} & \dots & (n-1)s_{2p} \\ \sqrt{s_{11}}\sqrt{s_{22}} & s_{22} & \dots & \sqrt{s_{22}}\sqrt{s_{pp}} \\ \vdots & \vdots & \ddots & \vdots \\ (n-1)s_{1p} & (n-1)s_{2p} & \dots & (n-1)s_{pp} \\ \sqrt{s_{11}}\sqrt{s_{pp}} & \sqrt{s_{22}}\sqrt{s_{pp}} & \dots & s_{pp} \end{bmatrix} := \mathbf{R} \end{aligned}$$

Như vậy, với $\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n$ là các quan trắc được chuẩn hoá với ma trận hiệp phương sai $\mathbf{R}$, thành phần chính thứ i của mẫu là

$$\hat{y}_i = \hat{\mathbf{e}}_i' \mathbf{z} = \hat{e}_{i1}z_1 + \hat{e}_{i2}z_2 + \dots + \hat{e}_{ip}z_p, \quad i = 1, 2, \dots, p$$

với $(\hat{\lambda}_i, \hat{\mathbf{e}}_i)$ là cặp trị riêng - vector riêng thứ i của $\mathbf{R}$ với $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0$. Ta cũng có

$$\begin{aligned} \text{Phương sai mẫu } (\hat{y}_i) &= \hat{\lambda}_i, \quad i = 1, 2, \dots, p \\ \text{Hiệp phương sai mẫu } (\hat{y}_i, \hat{y}_k) &= 0, \quad i \neq k. \end{aligned}$$

Ngoài ra,

$$\text{Phương sai mẫu toàn phần (chuẩn hoá)} = \text{tr}(\mathbf{R}) = p = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \hat{\lambda}_p$$

và

$$\text{Hệ số tương quan mẫu} = r_{\hat{y}_i \hat{y}_k} = \hat{e}_{ik} \sqrt{\hat{\lambda}_i}, \quad i, k = 1, 2, \dots, p.$$

Tỉ lệ giữa thành phần chính thứ i của mẫu so với phương sai mẫu toàn phần là

$$\frac{\hat{\lambda}_i}{p}, \quad i = 1, 2, \dots, p.$$

Mặc dù có thể dùng công thức này để xác định phần nào số lượng thành phần chính cần dùng, cách hay nhất vẫn là vẽ scree plot để có cái nhìn trực quan hơn.

4 Suy luận thống kê cho mẫu lớn

Tính chất của $\hat{\lambda}_i$ và $\hat{\mathbf{e}}_i$

Giả sử $X_1, X_2, \dots, X_n$ là một mẫu ngẫu nhiên có phân phối chuẩn. Các trị riêng của Σ là $\lambda_1 > \dots > \lambda_p > 0$.

1) Với $\Lambda = \text{diag}\{\lambda_i\}$ thì $\sqrt{n} \begin{pmatrix} \hat{\lambda}_1 - \lambda_1 \\ \vdots \\ \hat{\lambda}_p - \lambda_p \end{pmatrix}$ xấp xỉ phân phối $N_p(\mathbf{0}, 2\Lambda^2)$

2) Với $\mathbf{E}_i = \lambda_i \sum_{\substack{k=1 \\ k \neq i}}^p \frac{\lambda_k}{(\lambda_k - \lambda_i)^2} \mathbf{e}_k \mathbf{e}_k'$ thì $\sqrt{n} \begin{pmatrix} \hat{\mathbf{e}}_1 - \mathbf{e}_1 \\ \vdots \\ \hat{\mathbf{e}}_p - \mathbf{e}_p \end{pmatrix}$ xấp xỉ phân phối $N_p(\mathbf{0}, \mathbf{E}_i)$

3) $\hat{\lambda}_i$ có phân phối độc lập với $\hat{\mathbf{e}}_i$

Tính chất 1 cho ta thấy với n lớn thì các $\hat{\lambda}_i$ sẽ có phân phối độc lập. Hơn nữa, khi đó $\hat{\lambda}_i \rightarrow N\left(\lambda_i, \frac{2\lambda_i^2}{n}\right)$ và khoảng tin cậy $100(1 - \alpha)\%$ của λ_i là

$$\frac{\hat{\lambda}_i}{1 + z_{\alpha/2} \sqrt{\frac{2}{n}}} \leq \lambda_i \leq \frac{\hat{\lambda}_i}{1 - z_{\alpha/2} \sqrt{\frac{2}{n}}}.$$

Tính chất 2 cho ta thấy với n lớn thì các $\hat{\mathbf{e}}_i$ sẽ có phân phối chuẩn. Ngoài ra, các sai số chuẩn $se(\hat{e}_{ik})$ sẽ xấp xỉ với căn bậc hai của các phần tử trên đường chéo của ma trận $(1/n) \hat{\mathbf{E}}_i$ (trong $\mathbf{E}_i$ thay λ_i bằng $\hat{\lambda}_i$ và $\mathbf{e}_i$ bằng $\hat{\mathbf{e}}_i$ thì ta được $\hat{\mathbf{E}}_i$).

Chú ý. Nếu tìm khoảng tin cậy đồng thời cho m thành phần chính thì ta thay $z_{\alpha/2}$ bằng $z_{\alpha/2m}$.

Kiểm định cho cấu trúc tương quan

Cấu trúc tương quan đặc biệt $\text{Cov}(X_i, X_k) = \sqrt{\sigma_{ii}\sigma_{kk}}\rho$ hoặc $\text{Corr}(X_i, X_k) = \rho$ với mọi $i \neq k$ là một cấu trúc quan trọng mà trong đó các trị riêng của Σ không phân biệt.

Cho $\mathbf{R}$ là ma trận tương quan mẫu. Xét kiểm định sau :

$$H_0 : \boldsymbol{\rho} = \underset{(p \times p)}{\boldsymbol{\rho}_0} = \begin{bmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{bmatrix}$$

$$H_1 : \boldsymbol{\rho} \neq \boldsymbol{\rho}_0$$

Thống kê của kiểm định:

$$T = \frac{(n-1)}{(1-\bar{r})^2} \left[\sum_{k=1}^p \sum_{\substack{i=1 \\ i < k}}^p (r_{ik} - \bar{r})^2 - \hat{\gamma} \sum_{k=1}^p (\bar{r}_k - \bar{r})^2 \right],$$

trong đó

$$\bar{r}_k = \frac{1}{p-1} \sum_{\substack{i=1 \\ i \neq k}}^p r_{ik} \quad k = 1, 2, \dots, p;$$

$$\bar{r} = \frac{2}{p(p-1)} \sum_{k=1}^p \sum_{\substack{i=1 \\ i < k}}^p r_{ik}$$

$$\hat{\gamma} = \frac{(p-1)^2 [1 - (1 - \bar{r})^2]}{p - (p-2)(1 - \bar{r})^2}$$

Bác bỏ H_0 nếu

$$T > \chi_{(p+1)(p-2)/2}^2(\alpha).$$

5 Ứng dụng của PCA

- Dùng để nghiên cứu cấu trúc phương sai - hiệp phương sai của dữ liệu, dựa trên việc phân tích ma trận hiệp phương sai mẫu $\mathbf{S}$ hoặc ma trận hệ số tương quan $\mathbf{R}$.
- Tạo ra một tập hợp biến mới (với một số lượng nhỏ hơn và không có tương quan với nhau). Tập hợp các biến mới này được sử dụng cho mô hình hồi quy (hồi quy trên thành phần chính) nhằm khắc phục hiện tượng đa cộng tuyến - multicollinearity).
- Phát hiện các điểm outliers hay phân cụm dữ liệu (cluster analysis).
- Kiểm tra giả định về phân phối chuẩn nhiều chiều (được sử dụng cho các phân tích thống kê nhiều chiều khác).
- Sử dụng trong các mô hình hồi quy logistic để giải quyết các bài toán phân loại.
- Khử nhiễu (denoising)
- Nén dữ liệu/ảnh (data compression)

Câu 2

Học viên tự chọn hai bộ dữ liệu (đề tài tự do) để tìm hiểu “nghiên cứu” nhằm áp dụng vào phân lý thuyết với hai chủ đề trên.

Yêu cầu

- Tên “đề tài”, nguồn gốc của dữ liệu, giới thiệu các biến,...
- Xử lý số liệu (kiểm tra dữ liệu khuyết, dữ liệu ngoại lai,...),
- Chọn phương pháp phân tích phù hợp,
- Diễn giải kết quả và nhận xét,
- Đưa ra những phương pháp/phân tích khác có thể cho kết quả tốt hơn nếu có thể,
- Kết luận.

Bộ dữ liệu 1

Nguồn: <https://www.kaggle.com/datasets/sdhilip/nutrient-analysis-of-pizzas>

Tập dữ liệu “Pizza.csv” chứa các quan trắc về các thành phần dinh dưỡng của một chiếc bánh pizza. Các biến trong tập dữ liệu là:

- brand: Thương hiệu bánh pizza (gồm 10 thương hiệu, gán nhãn A - J)
- id: Sample analysed
- mois: Lượng nước trên 100 gam mẫu
- prot: Lượng protein trên 100 gam mẫu
- fat: Lượng chất béo trên 100 gam mẫu
- ash: Lượng tro trên 100 gam mẫu
- sodium: Lượng natri trên 100 gam mẫu
- carb: Lượng carbohydrate trên 100 gam mẫu
- cal: Lượng calo trên 100 gam mẫu

Bài làm.

Đọc dữ liệu

```
1 > pizza = read.csv("Pizza.csv")
2 > dim(pizza)
3 [1] 300 9
4 > head(pizza)
5   brand    id  mois  prot  fat  ash sodium carb  cal
6 1     A 14069 27.82 21.43 44.87 5.11  1.77 0.77 4.93
7 2     A 14053 28.49 21.26 43.89 5.34  1.79 1.02 4.84
8 3     A 14025 28.35 19.99 45.78 5.08  1.63 0.80 4.95
9 4     A 14016 30.55 20.15 43.13 4.79  1.61 1.38 4.74
```

```

10 5      A 14005 30.49 21.28 41.65 4.82 1.64 1.76 4.67
11 6      A 14075 31.14 20.23 42.31 4.92 1.65 1.40 4.67
12 > str(pizza)
13 'data.frame': 300 obs. of 9 variables:
14 $ brand : chr "A" "A" "A" "A" ...
15 $ id : int 14069 14053 14025 14016 14005 14075 14082 14097 14117 14133
16 $ mois : num 27.8 28.5 28.4 30.6 30.5 ...
17 $ prot : num 21.4 21.3 20 20.1 21.3 ...
18 $ fat : num 44.9 43.9 45.8 43.1 41.6 ...
19 $ ash : num 5.11 5.34 5.08 4.79 4.82 4.92 4.71 5.28 5.02 5.16 ...
20 $ sodium: num 1.77 1.79 1.63 1.61 1.64 1.65 1.58 1.75 1.71 1.66 ...
21 $ carb : num 0.77 1.02 0.8 1.38 1.76 1.4 1.77 2.95 1.18 0.64 ...
22 $ cal : num 4.93 4.84 4.95 4.74 4.67 4.67 4.63 4.72 4.93 4.95 ...

```

Dữ liệu gồm 9 biến và 300 quan trắc, trong đó:

- 2 biến định tính là *brand* và *id*.
- 7 biến định lượng là *mois*, *prot*, *fat*, *ash*, *sodium*, *carb*, *cal*.

Thống kê số lượng bánh pizza của 10 thương hiệu trong mẫu:

```

1 > table(pizza$brand)
2
3  A  B  C  D  E  F  G  H  I  J
4 29 31 27 32 28 30 29 33 29 32

```

Kiểm tra dữ liệu khuyết

```

1 > sum(is.na(pizza))
2 [1] 0

```

Ta thấy bộ dữ liệu không có dữ liệu khuyết.

Thống kê mô tả

Ta tạo một data.frame mới gồm 7 cột cuối của data.frame *pizza* (gồm các biến định lượng) để thực hiện thống kê mô tả

```

1 > dat_pizza = pizza[, 3:9]

```

Tính trung bình mẫu của các biến:

```

1 > apply(dat_pizza, 2, mean)
2      mois      prot      fat      ash      sodium      carb      cal
3 40.903067 13.373567 20.229533 2.633233 0.669400 22.864767 3.271000

```

Tính phương sai mẫu của các biến:

```

1 > apply(dat_pizza, 2, var)
2      mois      prot      fat      ash      sodium
3 91.2595538 41.4014050 80.5624419  1.6121979  0.1371649
4      carb      cal
5 325.0708919  0.3844425


```

Kiểm tra dữ liệu ngoại lai:

```

1 > boxplot(dat_pizza)

```



Từ đồ thị ta thấy các biến *fat*, *sodium* và *cal* có các ngoại lai.

Tính phạm vi biến thiên của các biến:

```

1 > apply(dat_pizza, 2, range)
2      mois      prot      fat      ash      sodium      carb      cal
3 [1,] 25.00   6.98   4.38   1.17   0.25   0.51   2.18
4 [2,] 57.22  28.48  47.20   5.43   1.79  48.64   5.08


```

Từ boxplot và kết quả tính phạm vi biến thiên ở trên, ta thấy rằng đơn vị và phương sai của các biến rất khác biệt nhau. Do đó ta cần thực hiện chuẩn hóa dữ liệu trước khi xử lý.

```


1 > sc_pizza = as.data.frame(scale(dat_pizza))
2 > boxplot(sc_pizza)

```



Đồ thị tương quan giữa các biến:

```
1 > pairs.panels(sc_pizza)
```



Từ đồ thị ta thấy các biến *fat*, *ash*, *sodium* có mối tương quan cao.

Phân tích các thành phần chính (PCA)

Ta thực hiện PCA với bộ dữ liệu đã được chuẩn hóa *sc_pizza*

```

1 > pca_pizza = princomp(sc_pizza)
2 > summary(pca_pizza)
3 Importance of components:
4
5      Comp.1      Comp.2      Comp.3      Comp.4
6 Standard deviation  2.0390870  1.5109012  0.64279115  0.30798860
7 Proportion of Variance  0.5959688  0.3272082  0.05922319  0.01359632
8 Cumulative Proportion  0.5959688  0.9231770  0.98240023  0.99599655
9
10     Comp.5      Comp.6      Comp.7
11 Standard deviation  0.16608661  1.834350e-02  3.080106e-03
12 Proportion of Variance  0.00395386  4.822991e-05  1.359826e-06
13 Cumulative Proportion  0.99995041  9.999986e-01  1.000000e+00


```

Xác định số thành phần chính cần giữ lại: vẽ scree plot

```

1 > screeplot(pca_pizza, type = "lines", main = "Scree plot")

```



Từ scree plot ta thấy “điểm gãy” nằm ở PC3, do đó ta quyết định chọn hai thành phần chính đầu tiên (giải thích 92% phương sai toàn phần) để phân tích.

Diễn giải các thành phần chính:

```

1 > pca_pizza$loadings
2
3 Loadings:
4   Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7
5 mois      0.628  0.422  0.221      0.446  0.419
6 prot      0.379  0.270 -0.746      0.388  0.277
7 fat       0.447 -0.234  0.199  0.507 -0.173 -0.525  0.378
8 ash       0.472  0.111      -0.552 -0.671
9 sodium    0.436 -0.202  0.455 -0.446  0.603
10 carb     -0.425 -0.320      -0.334      0.776
11 cal       0.244 -0.567 -0.113  0.279      0.722
12
13   Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7
14 SS loadings  1.000  1.000  1.000  1.000  1.000  1.000  1.000
15 Proportion Var 0.143  0.143  0.143  0.143  0.143  0.143  0.143
16 Cumulative Var 0.143  0.286  0.429  0.571  0.714  0.857  1.000
    
```

Từ hệ số e_{ik} của các biến với 2 thành phần chính đầu tiên, ta thấy

- Với Y_1 : trừ biến *mois* ra thì các biến còn lại đều có ảnh hưởng lên Y_1 như nhau.
- Với Y_2 : mô tả sự khác biệt giữa *mois* + *prot* với *carb* + *cal* + *sodium*.

Xác định cụm (clusters) bằng PCA:

```

1 > autoplot(pca_pizza, loadings = TRUE, loadings.colour = 'blue',
2 +           loadings.label = TRUE, loadings.label.size = 3,
3 +           colour = "brand", data = pizza)

```



Bộ dữ liệu 2

Nguồn: <https://www.kaggle.com/datasets/aungpyaeap/fish-market>

Tập dữ liệu "Fish.csv" ghi lại các số liệu về 7 loài cá khác nhau phổ biến ở chợ. Các biến trong tập dữ liệu là:

- Species: Loại cá
- Weight: Trọng lượng của cá (tính bằng gam)
- Length1: Chiều dài dọc của cá (tính bằng cm)
- Length2: Chiều dài đường chéo của cá (tính bằng cm)
- Length3: Chiều dài chéo của cá (tính bằng cm)
- Height: Chiều cao của cá (tính bằng cm)
- Width: Chiều rộng theo đường chéo của cá (tính bằng cm)

Bài làm.

Đọc dữ liệu

```

1 > fish = read.csv("Fish.csv")
2 > dim(fish)
3 [1] 159 7
4 > head(fish)
5   Species Weight Length1 Length2 Length3 Height Width
6 1   Bream   242    23.2    25.4    30.0 11.5200 4.0200
7 2   Bream   290    24.0    26.3    31.2 12.4800 4.3056
8 3   Bream   340    23.9    26.5    31.1 12.3778 4.6961
9 4   Bream   363    26.3    29.0    33.5 12.7300 4.4555
10 5   Bream   430    26.5    29.0    34.0 12.4440 5.1340
11 6   Bream   450    26.8    29.7    34.7 13.6024 4.9274
12 > str(fish)
13 'data.frame': 159 obs. of 7 variables:
14 $ Species: chr  "Bream" "Bream" "Bream" "Bream" ...
15 $ Weight : num  242 290 340 363 430 450 500 390 450 500 ...
16 $ Length1: num  23.2 24 23.9 26.3 26.5 26.8 26.8 27.6 27.6 28.5 ...
17 $ Length2: num  25.4 26.3 26.5 29 29 29.7 29.7 30 30 30.7 ...
18 $ Length3: num  30 31.2 31.1 33.5 34 34.7 34.5 35 35.1 36.2 ...
19 $ Height : num  11.5 12.5 12.4 12.7 12.4 ...
20 $ Width : num  4.02 4.31 4.7 4.46 5.13 ...

```

Dữ liệu gồm 7 biến và 159 quan trắc, trong đó:

- 1 biến định tính là *Species*.
- 7 biến định lượng là *Weight*, *Length1*, *Length2*, *Length3*, *Height*, *Width*.

Thống kê số lượng cá của 7 loại cá trong mẫu:

```

1 > table(fish$Species)
2
3   Bream   Parkki   Perch   Pike   Roach   Smelt Whitefish
4    35      11     56    17    20     14      6

```

Kiểm tra dữ liệu khuyết

```

1 > sum(is.na(fish))
2 [1] 0

```

Ta thấy bộ dữ liệu không có dữ liệu khuyết.

Thống kê mô tả

Ta tạo một data.frame mới gồm 6 cột cuối của data.frame *fish* (gồm các biến định lượng) để thực hiện thống kê mô tả

```

1 > dat_fish = fish[, 2:7]

```

Tính trung bình mẫu của các biến:

```

1 > apply(dat_fish, 2, mean)
2   Weight   Length1   Length2   Length3   Height   Width
3 398.326415  26.247170  28.415723  31.227044   8.970994   4.417486

```

Tính phương sai mẫu của các biến:

```

1   Weight   Length1   Length2   Length3   Height
2   Width
3 1.281485e+05 9.992884e+01 1.148397e+02 1.347978e+02 1.837158e+01 2.841935e+00


```

Kiểm tra dữ liệu ngoại lai:

```

1 > boxplot(dat_fish)

```



Từ đồ thị ta thấy các biến *Weight*, *Length1*, *Length2* và *Length3* có các ngoại lai.

Tính phạm vi biến thiên của các biến:

```

1 > apply(dat_fish, 2, range)
2   Weight Length1 Length2 Length3 Height Width
3 [1,]    0      7.5     8.4     8.8  1.7284 1.0476
4 [2,]  1650    59.0    63.4    68.0 18.9570 8.1420


```

Từ boxplot và kết quả tính phạm vi biến thiên ở trên, ta thấy rằng đơn vị và phương sai của các biến rất khác biệt nhau. Do đó ta cần thực hiện chuẩn hóa dữ liệu trước khi xử lý.

```


1 > sc_pizza = as.data.frame(scale(dat_pizza))
2 > boxplot(sc_pizza)

```



Đồ thị tương quan giữa các biến:

```
1 > pairs.panels(sc_pizza)
```



Từ đồ thị ta thấy tất cả các biến đều có mối tương quan rất cao.

Phân tích các thành phần chính (PCA)

Ta thực hiện PCA với bộ dữ liệu đã được chuẩn hóa *sc_fish*

```
1 > pca_fish = princomp(sc_fish)
2 > summary(pca_fish)
3 Importance of components:
4
5 Comp.1      Comp.2      Comp.3      Comp.4
6 Standard deviation  2.2883754  0.71225144  0.34575410  0.31130972
7 Proportion of Variance 0.8783009  0.08508548  0.02005042  0.01625452
```

```

7 Cumulative Proportion 0.8783009 0.96338637 0.98343679 0.99969131
8                               Comp.5      Comp.6
9 Standard deviation    0.0395564370 1.660591e-02
10 Proportion of Variance 0.0002624358 4.625027e-05
11 Cumulative Proportion 0.9999537497 1.000000e+00


```

Xác định số thành phần chính cần giữ lại: vẽ scree plot

```

1 > screeplot(pca_fish, type = "lines", main = "Scree plot")

```



Từ scree plot ta thấy “điểm gãy” nằm ở PC2, do đó ta quyết định chọn một thành phần chính đầu tiên (giải thích 87.83% phương sai toàn phần) để phân tích.

Diễn giải các thành phần chính:

```


1 > pca_fish$loadings
2
3 Loadings:
4      Comp.1  Comp.2  Comp.3  Comp.4  Comp.5  Comp.6
5 Weight    0.417      0.218  0.881
6 Length1   0.422  0.335 -0.166 -0.160 -0.472 -0.659
7 Length2   0.423  0.309 -0.172 -0.166 -0.331  0.748
8 Length3   0.428  0.197 -0.332 -0.149  0.800
9 Height    0.343 -0.843 -0.389      -0.142
10 Width     0.411 -0.204  0.796 -0.384
11
12      Comp.1  Comp.2  Comp.3  Comp.4  Comp.5  Comp.6
13 SS loadings  1.000  1.000  1.000  1.000  1.000  1.000
14 Proportion Var 0.167  0.167  0.167  0.167  0.167  0.167
15 Cumulative Var 0.167  0.333  0.500  0.667  0.833  1.000

```

Từ hệ số e_{ik} của các biến với thành phần chính đầu tiên, ta thấy tất cả các biến đều có ảnh hưởng lên Y_1 như nhau. Sở dĩ như vậy là vì các biến này đều cùng mô tả kích thước của con cá.

Xác định cụm (clusters) bằng PCA:

```
1 > autoplot(pca_fish, loadings = TRUE, loadings.colour = 'blue',
2 +         loadings.label = TRUE, loadings.label.size = 3,
3 +         colour = "Species", data = fish)
```



2 Phần bài tập

Câu 1

Bài 4.13. Cho $\mathbf{X}$ có phân phối $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ với $|\boldsymbol{\Sigma}| \neq 0$.

(a) Chứng minh rằng

$$|\boldsymbol{\Sigma}| = |\boldsymbol{\Sigma}_{22}| \left| \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} \right|.$$

(b) Chứng minh rằng

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) &= \left[\mathbf{x}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2) \right]' \left(\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} \right)^{-1} \\ &\quad \times \left[\mathbf{x}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2) \right] + (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2). \end{aligned}$$

(c) Dựa vào kết quả câu (a) và câu (b), xác định phân phối lề của $\mathbf{X}_2$ và phân phối có điều kiện của $\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$.

Lời giải.

(a) **Nhận xét.**

$$1) \begin{vmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0}' & \mathbf{B} \end{vmatrix} = |\mathbf{A}| |\mathbf{B}|.$$

$$2) \begin{vmatrix} \mathbf{A} & \mathbf{C} \\ \mathbf{0}' & \mathbf{B} \end{vmatrix} = |\mathbf{A}| |\mathbf{B}| \text{ với } |\mathbf{A}| \neq 0.$$

Chứng minh.

$$1) \begin{vmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0}' & \mathbf{B} \end{vmatrix} = \begin{vmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0}' & \mathbf{I} \end{vmatrix} \begin{vmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{0}' & \mathbf{B} \end{vmatrix} = |\mathbf{A}| |\mathbf{B}|.$$

$$2) \begin{vmatrix} \mathbf{A} & \mathbf{C} \\ \mathbf{0}' & \mathbf{B} \end{vmatrix} = \begin{vmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0}' & \mathbf{B} \end{vmatrix} \begin{vmatrix} \mathbf{I} & \mathbf{A}^{-1}\mathbf{C} \\ \mathbf{0}' & \mathbf{I} \end{vmatrix} = |\mathbf{A}| |\mathbf{B}| \cdot 1 = |\mathbf{A}| |\mathbf{B}|$$

□

Trở lại bài toán, ta có

$$\begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} = \begin{bmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{bmatrix}.$$

Suy ra

$$\begin{vmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{vmatrix} \begin{vmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{vmatrix} \begin{vmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{vmatrix} = \begin{vmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{vmatrix}$$

Mặt khác, áp dụng hai nhận xét trên, ta được

$$\begin{vmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{vmatrix} = \begin{vmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{vmatrix} = |\mathbf{I}| |\mathbf{I}| = 1;$$

$$\begin{vmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{vmatrix} = |\Sigma_{22}| |\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}|.$$

Suy ra

$$\begin{vmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{vmatrix} = |\Sigma_{22}| |\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}|.$$

Mà

$$\begin{vmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{vmatrix} = |\Sigma|.$$

Do đó

$$|\Sigma| = |\Sigma_{22}| |\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}|.$$

(b) Ta có

$$\begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} = \begin{bmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{bmatrix}.$$

Suy ra

$$\begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} = \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix}^{-1},$$

hay

$$\Sigma = \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix}^{-1} \begin{bmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix}^{-1}.$$

Do đó

$$\Sigma^{-1} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix},$$

hay

$$\Sigma^{-1} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} \begin{bmatrix} (\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})^{-1} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix}$$

Suy ra

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) &= \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}' \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} \begin{bmatrix} (\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})^{-1} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22}^{-1} \end{bmatrix} \\ &\quad \times \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}. \end{aligned}$$

Ta lại có

$$\begin{aligned} \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}' & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix} &= \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}; \\ \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}' \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} &= \begin{bmatrix} (\mathbf{x}_1 - \boldsymbol{\mu}_1)' - (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \Sigma_{22}^{-1}\Sigma_{21} \\ (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \end{bmatrix}'. \end{aligned}$$

Mà

$$\begin{aligned} (\mathbf{x}_1 - \boldsymbol{\mu}_1)' - (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \Sigma_{22}^{-1}\Sigma_{21} &= (\mathbf{x}_1 - \boldsymbol{\mu}_1)' - (\mathbf{x}_2 - \boldsymbol{\mu}_2)' (\Sigma_{22}^{-1})' (\Sigma_{12})' \\ &= \left[\mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \right]'. \end{aligned}$$

Cho nên

$$\begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}' \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{I} \end{bmatrix} = \left[\begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \end{bmatrix} \right]'. \quad \square$$

Do đó

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) &= \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \end{bmatrix}' \begin{bmatrix} (\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})^{-1} & \mathbf{0} \\ \mathbf{0}' & \Sigma_{22}^{-1} \end{bmatrix} \\ &\quad \times \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \Sigma_{22}^{-1} \end{bmatrix}' \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix} \\ &= \left[\mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \right]' (\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})^{-1} \left[\mathbf{x}_1 - \boldsymbol{\mu}_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2) \right] \end{aligned}$$

$$+ (\mathbf{x}_2 - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2).$$

(c) Ta có

- $\mathbf{X}_2 \sim \mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$.
- $\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim \mathcal{N}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21})$.

□

Bài 4.21. Cho $\mathbf{X}_1, \dots, \mathbf{X}_{60} \sim \mathcal{N}_4(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

- (a) Tìm phân phối của $\bar{\mathbf{X}}$.
- (b) Tìm phân phối của $(\mathbf{X}_1 - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X}_1 - \boldsymbol{\mu})$.
- (c) Tìm phân phối của $n(\bar{\mathbf{X}} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu})$.
- (d) Tìm phân phối xấp xỉ của $n(\bar{\mathbf{X}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu})$.

Lời giải.

- a) $\bar{\mathbf{X}} \sim \mathcal{N}_4(\boldsymbol{\mu}, \frac{1}{60} \boldsymbol{\Sigma})$.
- b) $(\mathbf{X}_1 - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X}_1 - \boldsymbol{\mu}) \sim \chi_4^2$.
- c) $n(\bar{\mathbf{X}} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim \chi_4^2$.
- d) $n(\bar{\mathbf{X}} - \boldsymbol{\mu})' \mathbf{S}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu})$ xấp xỉ phân phối χ_4^2 (vì $60 \gg 4$).

□

Câu 2

7.24. Cho số liệu về đặc điểm của các con bò đực được bán đấu giá trong Bảng 1.10:

Bảng 1.10 Số liệu của các con bò đực								
Breed	SalePr	YrHgt	FtFrBody	PrctFFB	Frame	BkFat	SaleHt	SaleWt
1	2200	51.0	1128	70.9	7	.25	54.8	1720
1	2250	51.9	1108	72.1	7	.25	55.3	1575
1	1625	49.9	1011	71.6	6	.15	53.1	1410
1	4600	53.1	993	68.9	8	.35	56.4	1595
1	2150	51.2	996	68.6	7	.25	55.0	1488
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
8	1450	51.4	997	73.4	7	.10	55.2	1454
8	1200	49.8	991	70.8	6	.15	54.6	1475
8	1425	50.0	928	70.8	6	.10	53.9	1375
8	1250	50.1	990	71.0	6	.10	54.9	1564
8	1500	51.7	992	70.6	7	.15	55.1	1458

(a) Hồi quy $Y_1 = \text{SaleHt}$ theo $Z_1 = \text{YrHgt}$ và $Z_2 = \text{FtFrBody}$.

(i) Tìm một mô hình phù hợp và phân tích phần dư.

- (ii) Tìm khoảng dự đoán 95% cho SaleHt ứng với $z_1 = 50.5$ và $z_2 = 970$.
- (b) Hồi quy (nhiều chiều) $Y_1 = \text{SaleHt}$ và $Y_2 = \text{SaleWt}$ theo $Z_1 = \text{YrHgt}$ và $Z_2 = \text{FtFrBody}$.
- (i) Tìm một mô hình (nhiều chiều) phù hợp và phân tích phần dư.
- (ii) Tìm ellipse dự đoán 95% cho SaleHt và SaleWt ứng với $z_1 = 50.5$ và $z_2 = 970$. So sánh ellipse này với khoảng dự đoán ở câu (i). Đưa ra nhận xét.

Lời giải. Đọc dữ liệu

```

1 > data = read.table("http://users.stat.umn.edu/~sandy/courses/8053/Data/
  Wichern_data/T1-10.dat")
2 > colnames(data) = c("Breed", "SalePr", "YrHgt", "FtFrBody", "PrctFFB",
3 + "Frame", "BkFat", "SaleHt", "SaleWt")
4 > head(data)
5   Breed SalePr YrHgt FtFrBody PrctFFB Frame BkFat SaleHt SaleWt
6 1      1  2200  51.0   1128    70.9     7  0.25   54.8  1720
7 2      1  2250  51.9   1108    72.1     7  0.25   55.3  1575
8 3      1  1625  49.9   1011    71.6     6  0.15   53.1  1410
9 4      1  4600  53.1    993    68.9     8  0.35   56.4  1595
10 5      1  2150  51.2    996    68.6     7  0.25   55.0  1488
11 6      1  1225  49.2    985    71.4     6  0.15   51.4  1500

```

(a)

```

1 > Y1 = data$SaleHt
2 > Z1 = data$YrHgt
3 > Z2 = data$FtFrBody

```

(i) Lập mô hình

```

1 > model_a = lm(Y1 ~ Z1 + Z2, data = data)
2 > summary(model_a)
3
4 Call:
5 lm(formula = Y1 ~ Z1 + Z2, data = data)
6
7 Residuals:
8      Min       1Q   Median       3Q      Max
9 -2.64443  -0.52691   0.02509   0.71522   2.47628
10
11 Coefficients:
12             Estimate Std. Error t value Pr(>|t|)
13 (Intercept)  7.846281   3.362213   2.334 0.022370 *
14 Z1           0.802235   0.080886   9.918 3.61e-15 ***
15 Z2           0.005773   0.001511   3.821 0.000277 ***
16 ---
17 Signif. codes:  0   ***    0.001   **    0.01   *    0.05   .    0.1
18
19 Residual standard error: 0.948 on 73 degrees of freedom
20 Multiple R-squared:  0.7823, Adjusted R-squared:  0.7763
21 F-statistic: 131.2 on 2 and 73 DF, p-value: < 2.2e-16


```

Ta thấy các hệ số trong mô hình đều có ý nghĩa và mô hình giải thích được 78% sự biến thiên của $Y_1 = SaleHt$. Vậy mô hình ta chọn là:

$$\widehat{SaleHt} = 7.846281 + 0.802235 \times YrHgt + 0.005771 \times FtFrBody.$$

Phân tích phần dư

```
1 > par(mfrow = c(2, 2))
2 > plot(model_a)
```



(ii)

```
1 > data1 = data.frame(Z1 = 50.5, Z2 = 970)
2 > predict(model_a, data1, interval = "prediction", level = 0.95)
3      fit      lwr      upr
4 1 53.95859 52.05537 55.8618
```

Vậy khoảng dự đoán 95% cho $SaleHt$ ứng với $z_1 = 50.5$ và $z_2 = 970$ là

(52.06, 55.86)

(b)

```
1 > Y2 = data$SaleWt
```

(i) Lập mô hình

```
1 > model_b = lm(cbind(Y1,Y2) ~ Z1 + Z2, data = data)
2 > summary(model_b)
3 Response Y1 :
4
5 Call:
6 lm(formula = Y1 ~ Z1 + Z2, data = data)
7
8 Residuals:
9      Min       1Q   Median       3Q      Max
10 -2.64443  -0.52691   0.02509   0.71522   2.47628
11
12 Coefficients:
13             Estimate Std. Error t value Pr(>|t|)
14 (Intercept)  7.846281    3.362213   2.334 0.022370 *
15 Z1           0.802235    0.080886   9.918 3.61e-15 ***
16 Z2           0.005773    0.001511   3.821 0.000277 ***
17 ---
18 Signif. codes:  0   ***    0.001   **    0.01   *    0.05   .    0.1
19                  1
20 Residual standard error: 0.948 on 73 degrees of freedom
21 Multiple R-squared:  0.7823, Adjusted R-squared:  0.7763
22 F-statistic: 131.2 on 2 and 73 DF, p-value: < 2.2e-16
23
24
25 Response Y2 :
26
27 Call:
28 lm(formula = Y2 ~ Z1 + Z2, data = data)
29
30 Residuals:
31      Min       1Q   Median       3Q      Max
32 -186.36  -73.33  -14.15   55.66  304.84
33
34 Coefficients:
35             Estimate Std. Error t value Pr(>|t|)
36 (Intercept)  675.3168   387.9350   1.741  0.0859 .
37 Z1           2.7193    9.3327   0.291  0.7716
38 Z2           0.7456    0.1743   4.278 5.65e-05 ***
39 ---
40 Signif. codes:  0   ***    0.001   **    0.01   *    0.05   .    0.1
41                  1
42 Residual standard error: 109.4 on 73 degrees of freedom
43 Multiple R-squared:  0.309, Adjusted R-squared:  0.29
44 F-statistic: 16.32 on 2 and 73 DF, p-value: 1.387e-06
```

Manova

```
1 > manova = Anova(model_b)
2 > summary(manova)
```

```

3
4 Type II MANOVA Tests:
5
6 Sum of squares and products for error:
7           Y1           Y2
8 Y1      65.60204      3171.979
9 Y2 3171.97867 873342.995
10
11 -----
12
13 Term: Z1
14
15 Sum of squares and products for the hypothesis:
16           Y1           Y2
17 Y1      88.40056      299.6459
18 Y2 299.64586 1015.6909
19
20 Multivariate Tests: Z1
21           Df test stat approx F num Df den Df      Pr(>F)
22 Pillai          1 0.6147543  57.44686      2      72 1.2206e-15 ***
23 Wilks           1 0.3852457  57.44686      2      72 1.2206e-15 ***
24 Hotelling-Lawley 1 1.5957462  57.44686      2      72 1.2206e-15 ***
25 Roy             1 1.5957462  57.44686      2      72 1.2206e-15 ***
26 ---
27 Signif. codes:  0      ***      0.001      **      0.01      *      0.05      .      0.1
28                   1
29 -----
30
31 Term: Z2
32
33 Sum of squares and products for the hypothesis:
34           Y1           Y2
35 Y1      13.12123      1694.78
36 Y2 1694.78000 218903.17
37
38 Multivariate Tests: Z2
39           Df test stat approx F num Df den Df      Pr(>F)
40 Pillai          1 0.2418660  11.48501      2      72 4.6866e-05 ***
41 Wilks           1 0.7581340  11.48501      2      72 4.6866e-05 ***
42 Hotelling-Lawley 1 0.3190281  11.48501      2      72 4.6866e-05 ***
43 Roy             1 0.3190281  11.48501      2      72 4.6866e-05 ***
44 ---
45 Signif. codes:  0      ***      0.001      **      0.01      *      0.05      .      0.1
46                   1

```

(ii)

```

1 > predict(model_b, data1 , interval = "prediction" , level = 0.95)
2           Y1           Y2
3 1 53.95859 1535.882

```

□

Câu 3

8.22. Xét dữ liệu về các con bò đực trong Bảng 1.10. Sử dụng 7 biến YrHgt, FtFrBody, PrctFFB, Frame, BkFat, SaleHt và SaleWt, thực hiện phân tích thành phần chính bằng cách sử dụng ma trận hiệp phương sai **S** và ma trận tương quan **R**.

- Xác định số lượng thành phần thích hợp để tóm tắt hiệu quả độ biến thiên của mẫu. Vẽ scree plot để minh họa.
- Diễn giải các thành phần chính của mẫu.
- Có thể phát triển chỉ số “kích thước cơ thể” hoặc “cấu hình cơ thể” từ dữ liệu của 7 biến trên không? Giải thích.
- Sử dụng các giá trị từ hai thành phần chính đầu tiên, vẽ biểu đồ dữ liệu trong không gian hai chiều với y_1 dọc theo trục tung và y_2 dọc theo trục hoành. Ta có thể phân biệt các nhóm đại diện cho ba giống gia súc hay không? Có điểm ngoại lai nào không?
- Vẽ biểu đồ Q – Q bằng cách sử dụng thành phần chính đầu tiên. Diễn giải biểu đồ.

Lời giải. Đọc dữ liệu

```
1 > vars = strsplit("YrHgt FtFrBody PrctFFB Frame BkFat SaleHt SaleWt", " ")
  [[1]]
2 > data = read.table("http://users.stat.umn.edu/~sandy/courses/8053/Data/
  Wichern_data/T1-10.dat",
3 +               col.names=c("Breed", "SalePr", vars))
4 > head(data)
5   Breed SalePr YrHgt FtFrBody PrctFFB Frame BkFat SaleHt SaleWt
6 1      1  2200  51.0    1128    70.9    7  0.25   54.8  1720
7 2      1  2250  51.9    1108    72.1    7  0.25   55.3  1575
8 3      1  1625  49.9    1011    71.6    6  0.15   53.1  1410
9 4      1  4600  53.1     993    68.9    8  0.35   56.4  1595
10 5      1  2150  51.2     996    68.6    7  0.25   55.0  1488
11 6      1  1225  49.2     985    71.4    6  0.15   51.4  1500
```

Sử dụng ma trận S để phân tích

```
1 > (S = cov(data[, vars]))
2               YrHgt    FtFrBody    PrctFFB    Frame
3 YrHgt      2.99802632  100.130526  2.9600175  1.50884211
4 FtFrBody  100.13052632 8594.343860 209.5043509 51.95017544
5 PrctFFB    2.96001754 209.504351 10.6916561  1.45922807
6 Frame      1.50884211  51.950175  1.4592281  0.85894737
7 BkFat     -0.05339211  -1.398175 -0.1429947 -0.02161404
8 SaleHt     2.98313684 129.940070  3.4142246  1.48757895
9 SaleWt     82.81077193 6680.308772 83.9254035 44.32070175
10              BkFat    SaleHt    SaleWt
11 YrHgt     -0.053392105  2.98313684  82.810772
12 FtFrBody  -1.398175439 129.94007018 6680.308772
13 PrctFFB   -0.142994737  3.41422456  83.925404
14 Frame     -0.021614035  1.48757895  44.320702
15 BkFat      0.008022368  -0.05064561  2.412965
16 SaleHt    -0.050645614  4.01796491 147.289614
17 SaleWt     2.412964912 147.28961404 16850.661754
```

(a) Phân tích thành phần chính:

```

1 > pca = princomp(data[, vars])
2 > summary(pca)
3 Importance of components:
4
5      Comp.1      Comp.2      Comp.3      Comp.4
6 Standard deviation 142.5090460 69.3580156 2.3146777818 1.8090529826
7 Proportion of Variance 0.8081979 0.1914371 0.0002132131 0.0001302373
8 Cumulative Proportion 0.8081979 0.9996351 0.9998482652 0.9999785025
9
10     Comp.5      Comp.6      Comp.7
11 Standard deviation 6.801921e-01 2.703318e-01 6.678305e-02
12 Proportion of Variance 1.841179e-05 2.908220e-06 1.774865e-07
13 Cumulative Proportion 9.999969e-01 9.999998e-01 1.000000e+00

```


Ta thấy hai thành phần chính đầu tiên giải thích 99.96% phương sai mẫu nên số lượng thành phần thích hợp để tóm tắt hiệu quả độ biến thiên của mẫu là hai.

Vẽ scree plot minh họa:

```

1 > library(latex2exp)
2 > plot(1:ncol(S), eigen(S)$values/10^3, type="o", pch=19, xlab="i", ylab=
    TeX("$\\lambda_i\\times 10^3$"))

```



(b) Diễn giải các thành phần chính của mẫu.

```
1 > pca$loadings
2
3 Loadings:
4      Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7
5 YrHgt           0.286  0.609  0.536  0.510
6 FtFrBody  0.487  0.873
7 PrctFFB           0.904 -0.425
8 Frame           0.133  0.311  0.391 -0.855
9 BkFat                               0.999
10 SaleHt           0.284  0.593 -0.749
11 SaleWt  0.873 -0.487
12
13      Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7
14 SS loadings  1.000  1.000  1.000  1.000  1.000  1.000  1.000
15 Proportion Var  0.143  0.143  0.143  0.143  0.143  0.143  0.143
16 Cumulative Var  0.143  0.286  0.429  0.571  0.714  0.857  1.000
```


Từ hệ số e_{ik} của các biến với 2 thành phần chính đầu tiên, ta thấy biến thứ 7 (SaleWt) và biến thứ 2 (FtFrBody) có ảnh hưởng lên Y_1 và Y_2 . Sở dĩ như vậy là vì 2 biến này có các giá trị rất lớn so với các giá trị của các biến còn lại.

- (c) Có thể phát triển chỉ số “kích thước cơ thể” hoặc “cấu hình cơ thể” từ dữ liệu của bảy biến trên không? Giải thích.
- (d) Tính giá trị 2 thành phần chính Y_1, Y_2 cho dữ liệu

```
1 > Y1 = as.matrix(data[, vars]) > Y2 = as.matrix(data[, vars])
```

Vẽ đồ thị phân tán Y_1 theo Y_2 của các điểm dữ liệu với nhãn là Breed (giống bò) tương ứng.


```
1 > plot(Y2, Y1, type="n")
2 > text(Y2, Y1, data[, "Breed"], cex=0.8)
```



Từ đồ thị ta thấy 3 giống bò (nhãn 1, 5, 8) trộn lẫn vào nhau chứ không tách riêng ra theo cụm. Ngoài ra, ta cũng thấy có 2 điểm ngoại lai ở góc trái dưới (nhãn 8).

(e) Vẽ biểu đồ Q – Q bằng cách sử dụng thành phần chính đầu tiên:

```
1 > qqnorm(Y1, ylab="Y1")
2 > qqline(Y1, col="red")
```



Ta thấy các điểm dữ liệu phân bố gần như trên đường thẳng. Như vậy, Y_1 có phân phối xấp xỉ phân phối chuẩn. Ta cũng thấy 1 điểm ngoại lai trên biểu đồ.

Sử dụng ma trận R để phân tích

```
1 > (R = cor(data[, vars]))
2
3 YrHgt      1.0000000  0.6237958  0.5228223  0.9402488 -0.3442770
4 FtFrBody   0.6237958  1.0000000  0.6911371  0.6046407 -0.1683852
5 PrctFFB    0.5228223  0.6911371  1.0000000  0.4815234 -0.4882545
6 Frame      0.9402488  0.6046407  0.4815234  1.0000000 -0.2603762
7 BkFat      -0.3442770 -0.1683852 -0.4882545 -0.2603762  1.0000000
```

8	SaleHt	0.8595129	0.6992519	0.5209146	0.8007440	-0.2820899
9	SaleWt	0.3684348	0.5551134	0.1977254	0.3683960	0.2075349
10		SaleHt	SaleWt			
11	YrHgt	0.8595129	0.3684348			
12	FtFrBody	0.6992519	0.5551134			
13	PrctFFB	0.5209146	0.1977254			
14	Frame	0.8007440	0.3683960			
15	BkFat	-0.2820899	0.2075349			
16	SaleHt	1.0000000	0.5660575			
17	SaleWt	0.5660575	1.0000000			

(a) Phân tích thành phần chính:

```

1 > pca=princomp(data[, vars], cor=T)
2 > summary(pca)
3 Importance of components:
4
5               Comp.1      Comp.2      Comp.3      Comp.4
6 Standard deviation  2.0299502  1.1563431  0.8610357  0.6491727
7 Proportion of Variance 0.5886711  0.1910185  0.1059118  0.0602036
8 Cumulative Proportion 0.5886711  0.7796896  0.8856014  0.9458050
9
10              Comp.5      Comp.6      Comp.7
11 Standard deviation  0.4310521  0.38275628  0.216925572
12 Proportion of Variance 0.0265437  0.02092891  0.006722386
13 Cumulative Proportion 0.9723487  0.99327761  1.000000000

```


Ta thấy hai thành phần chính đầu tiên giải thích 77.96% phương sai mẫu, còn ba thành phần chính đầu tiên giải thích 88.56% phương sai mẫu. Do đó số lượng thành phần thích hợp để tóm tắt hiệu quả độ biến thiên của mẫu là hai hoặc ba.

Vẽ scree plot minh họa:

```

1 > plot(1:ncol(R), eigen(R)$values, type="o", pch=19, xlab="i", ylab=TeX("$\\lambda_i$"))

```



(b) Diễn giải các thành phần chính của mẫu.

```

1 > (pca$loadings)
2 Loadings:
3           Comp.1  Comp.2  Comp.3  Comp.4  Comp.5  Comp.6  Comp.7
4 YrHgt          0.450          0.416  0.113          0.775
5 FtFrBody       0.412 -0.130 -0.450  0.247 -0.719  0.177
6 PrctFFB        0.356  0.316 -0.568  0.315  0.579 -0.128
7 Frame          0.434          0.452  0.243  0.143  0.434 -0.582
8 BkFat         -0.187 -0.715          0.618  0.160 -0.208
9 SaleHt         0.453 -0.101  0.177 -0.216 -0.110 -0.799 -0.237
10 SaleWt        0.270 -0.601 -0.253 -0.582  0.291  0.277

```

Vì dùng ma trận hệ số tương quan để phân tích nên 2 biến (SaleWt và FtFrBody) đã không còn ảnh hưởng nhiều lên các thành phần chính như kết quả phân tích trên ma


trận S. Các biến gần như đều có ảnh hưởng lên thành phần chính thứ nhất (biến BkFat và SaleWt có vai trò nhỏ hơn). Biến BkFat và SaleWt lại có vai trò lớn trên thành phần chính thứ 2 (biến PrctFFB cũng ảnh hưởng lên thành phần chính thứ 2).

- (c) Có thể phát triển chỉ số “kích thước cơ thể” hoặc “cấu hình cơ thể” từ dữ liệu của bảy biến trên không? Giải thích.
- (d) Tính giá trị 2 thành phần chính Y_1, Y_2 cho dữ liệu

```
1 > Y1 = as.matrix(data[, vars]) * as.matrix(eigen(R)$vectors[, 1])
2 > Y2 = as.matrix(data[, vars]) * as.matrix(eigen(R)$vectors[, 2])
```

Vẽ đồ thị phân tán Y_1 theo Y_2 của các điểm dữ liệu với nhãn là Breed (giống bò) tương ứng.


```
1 > plot(Y2, Y1, type="n")
2 > text(Y2, Y1, data[, "Breed"], cex=0.8)
```



Từ đồ thị ta thấy 3 giống bò (nhãn 1, 5, 8) vẫn trộn lẫn vào nhau chứ không tách riêng ra theo cụm. Ngoài ra, ta cũng thấy có 1 điểm ngoại lai ở góc trái dưới (nhãn 8).

(e) Vẽ biểu đồ Q – Q bằng cách sử dụng thành phần chính đầu tiên:

```
1 > qqnorm(Y1, ylab="Y1")
2 > qqline(Y1, col="red")
```



Ta thấy các điểm dữ liệu cũng phân bố gần như trên đường thẳng. Như vậy, Y_1 có phân phối xấp xỉ phân phối chuẩn. Ta cũng thấy 1 điểm ngoại lai trên biểu đồ.

□

8.28. Dữ liệu khảo sát được thu thập như một phần của nghiên cứu nhằm đánh giá các lựa chọn để tăng cường an ninh lương thực thông qua việc sử dụng các nguồn tài nguyên thiên nhiên ở vùng Sikasso của Mali (Tây Phi). Có $n = 76$ nông dân đã được khảo sát. Các quan trắc trên 9 biến

x_1 = Family (tổng số người trong hộ gia đình)

x_2 = DistRd (khoảng cách tính bằng km đến đường có thể đi qua gần nhất)

x_3 = Cotton (số ha bông được trồng vào năm 2000)

x_4 = Maize (số ha ngô được trồng vào năm 2000)

x_5 = Sorg (số ha cao lương được trồng vào năm 2000)

x_6 = Millet (số ha kê trồng năm 2000)

x_7 = Bull (tổng số bò đực hoặc động vật kéo)

x_8 = Cattle (total)

x_9 = Goats (total)

được ghi lại. Dữ liệu được liệt kê trong Bảng 8.7

Bảng 8.7 Dữ liệu về trang trại gia đình Mali								
Family	DistRD	Cotton	Maize	Sorg	Millet	Bull	Cattle	Goats
12	80	1.5	1.00	3.0	.25	2	0	1
54	8	6.0	4.00	0	1.00	6	32	5
11	13	.5	1.00	0	0	0	0	0
21	13	2.0	2.50	1.0	0	1	0	5
61	30	3.0	5.00	0	0	4	21	0
20	70	0	2.00	3.0	0	2	0	3
29	35	1.5	2.00	0	0	0	0	0
29	35	2.0	3.00	2.0	0	0	0	0
57	9	5.0	5.00	0	0	4	5	2
23	33	2.0	2.00	1.0	0	2	1	7
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
20	0	1.5	1.00	3.0	0	1	6	0
27	41	1.1	.25	1.5	1.50	0	3	1
18	500	2.0	1.00	1.5	.50	1	0	0
30	19	2.0	2.00	4.0	1.00	2	0	5
77	18	8.0	4.00	6.0	4.00	6	8	6
21	500	5.0	1.00	3.0	4.00	1	0	5
13	100	.5	.50	0	1.00	0	0	4
24	100	2.0	3.00	0	.50	3	14	10
29	90	2.0	1.50	1.5	1.50	2	0	2
57	90	10.0	7.00	0	1.50	7	8	7

- (a) Vẽ các biểu đồ phân tán hai chiều của Family so với DistRd và DistRd với Cattle. Loại bỏ các điểm ngoại lai rõ ràng khỏi tập dữ liệu.
- (b) Thực hiện phân tích thành phần chính bằng cách sử dụng ma trận tương quan. Xác định số lượng thành phần để tóm tắt hiệu quả sự biến thiên (sử dụng tỷ lệ giải thích phương sai và scree plot).
- (c) Giải thích 5 thành phần chính đầu tiên.

Lời giải. Đọc dữ liệu

```

1 > farm=read.table("http://users.stat.umn.edu/~sandy/courses/8053/Data/
    Wichern_data/T8-7.DAT",col.names=c("Family","DistRD","Cotton","Maize","
    Sorg","Millet","Bull","Cattle","Goats"))
2 > head(farm)
3   Family DistRD Cotton Maize Sorg Millet Bull Cattle Goats
4   1      12     80    1.5  1.0   3   0.25   2      0      1
5   2      54      8    6.0  4.0   0   1.00   6     32      5
6   3      11     13    0.5  1.0   0   0.00   0      0      0
7   4      21     13    2.0  2.5   1   0.00   1      0      5
8   5      61     30    3.0  5.0   0   0.00   4     21      0
9   6      20     70    0.0  2.0   3   0.00   2      0      3


```

(a) Biểu đồ phân tán hai chiều của Family so với DistRd:

```

1 > plot(farm$Family,farm$DistRD, xlab="Family", ylab="DistRD")

```




Biểu đồ phân tán hai chiều của DistRd so với Cattle:

```

1 > plot(farm$DistRD,farm$Cattle, xlab="DistRD", ylab="Cattle")

```



Loại bỏ các điểm ngoại lai:

```
1 farm1=farm[-c(25,34,69,72),]
```


(b) Phân tích thành phần chính

```
1 > pca = prcomp(farm1, center = TRUE, scale = TRUE)
2 > summary(pca)
3
4 Importance of components:
5
6      PC1      PC2      PC3      PC4      PC5      PC6
7 Standard deviation  2.046  1.1992  1.0414  0.88984  0.77738  0.60509
8 Proportion of Variance 0.465  0.1598  0.1205  0.08798  0.06715  0.04068
9 Cumulative Proportion 0.465  0.6248  0.7453  0.83328  0.90043  0.94111
10
11      PC7      PC8      PC9
12 Standard deviation  0.48992  0.41452  0.34374
13 Proportion of Variance 0.02667  0.01909  0.01313
14 Cumulative Proportion 0.96778  0.98687  1.00000
```

Ta thấy 5 thành phần chính đầu tiên giải thích 90% phương sai mẫu nên số lượng thành phần để tóm tắt hiệu quả sự biến thiên là 5 thành phần.

Vẽ biểu đồ scree plot:

```
1 > plot(1:length(pca$sdev),pca$sdev^2,type="o",pch=19,xlab="Number of PCs",
2       ylab="Variance explained")
```



(c) Giải thích 5 thành phần chính đầu tiên:

1	> pca\$rotation					
2		PC1	PC2	PC3	PC4	PC5
3	Family	0.433842713	-0.065088695	0.09840025	-0.17120143	0.01132705
4	DistRD	0.007587031	0.496670914	-0.56856059	-0.49561039	-0.37766811
5	Cotton	0.446140316	0.008917253	0.13211700	0.02733684	-0.21870789
6	Maize	0.352228405	0.352571495	0.38820350	-0.24020492	-0.07920345
7	Sorg	0.203622111	-0.603667416	-0.11149246	0.05854254	-0.64457738
8	Millet	0.240361102	-0.415159516	-0.11595977	-0.61632679	0.52696668
9	Bull	0.445273680	0.068042477	-0.03038787	0.14559178	-0.02829987
10	Cattle	0.355411548	0.284473439	0.01382636	0.37293370	0.21753184
11	Goats	0.254549533	-0.048668251	-0.68695528	0.35078804	0.24867109

Từ hệ số e_{ik} của các biến với các thành phần chính, ta thấy tất cả các biến trừ biến DistRD đều có ảnh hưởng gần như nhau đến thành phần chính thứ nhất. Do đó thành phần này có thể được gọi là thành phần “farm size”.

Thành phần thứ 2 mô tả khác biệt giữa DistRD + Maize + Cattle với Sorg + Millet.

Thành phần thứ 3 bị ảnh hưởng chủ yếu bởi hai biến DistRD và Goats. Do đó thành phần này có thể được gọi là thành phần “goats and distance to road”.

Thành phần thứ 4 mô tả khác biệt giữa DistRD + Millet với Cattle + Goats.

Thành phần thứ 5 mô tả khác biệt giữa Millet với Sorg.

□

Câu 4

9.34. Dữ liệu về đặc tính của giấy và bột giấy được đưa ra trong Bảng 7.7.

Bảng 7.7 Dữ liệu về đặc tính của giấy và bột giấy							
y_1 BL	y_2 EM	y_3 SF	y_4 BS	z_1 AFL	z_2 LFF	z_3 FFF	z_4 ZST
21.312	7.039	5.326	0.932	-0.030	35.239	36.991	1.057
21.206	6.979	5.237	0.871	0.015	35.713	36.851	1.064
20.709	6.779	5.060	0.742	0.025	39.220	30.586	1.053
19.542	6.601	4.479	0.513	0.030	39.756	21.072	1.050
20.449	6.795	4.912	0.577	-0.070	32.991	36.570	1.049
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
16.441	6.315	2.997	-0.400	-0.605	2.845	84.554	1.008
16.294	6.572	3.017	-0.478	-0.694	1.515	81.988	.998
20.289	7.719	4.866	0.239	-0.559	2.054	8.786	1.081
17.163	7.086	3.396	-0.236	-0.415	3.018	5.855	1.033
20.289	7.437	4.859	0.470	-0.324	17.639	28.934	1.070

Thực hiện phân tích nhân tố bằng cách sử dụng các quan trắc trên 4 biến thuộc tính trên giấy, BL , EM , SF , BS và ma trận tương quan mẫu $\mathbf{R}$. Thông tin trong những dữ liệu này có thể được tóm tắt bởi một nhân tố duy nhất không? Nếu có, hãy diễn giải các yếu tố. Hãy thử cả phương pháp phân tích thành phần chính và phương pháp hợp lí cực đại. Lập lại phân tích này với ma trận hiệp phương sai mẫu $\mathbf{S}$. Cách diễn giải về (các) nhân tố có thay đổi khi thay $\mathbf{R}$ bởi $\mathbf{S}$ không?

Lời giải. Đọc dữ liệu

```

1 > data = read.table("http://users.stat.umn.edu/~sandy/courses/8053/Data/
  Wichern_data/T7-7.dat")
2 > colnames(data) = c("BL", "EM", "SF", "BS", "AFL", "LFF", "FFF", "ZST")
3 > data = data[,c('BL', 'EM', 'SF', 'BS')]
4 > head(data)
5      BL      EM      SF      BS
6 1 21.312  7.039  5.326  0.932
7 2 21.206  6.979  5.237  0.871
8 3 20.709  6.779  5.060  0.742
9 4 19.542  6.601  4.479  0.513
10 5 20.449  6.795  4.912  0.577
11 6 20.841  6.919  5.108  0.784

```

Phân tích trên $\mathbf{R}$:

```

1 > (R = cor(data))
2      BL      EM      SF      BS
3 BL 1.0000000  0.9138256  0.9838790  0.9875554
4 EM 0.9138256  1.0000000  0.9422199  0.8746665
5 SF 0.9838790  0.9422199  1.0000000  0.9745114
6 BS 0.9875554  0.8746665  0.9745114  1.0000000
7 > ev = eigen(R)
8 > lambdas = ev$values
9 > cumsum(lambdas)/sum(lambdas)
10 [1] 0.9598764 0.9949524 0.9981034 1.0000000

```

Phân tích với $m = 1$ nhân tố:

- Ước lượng L bằng phương pháp thành phần chính

```
1 > #Principal Component Factor Analysis of R (m = 1)
2 > (L = cbind(sqrt(lambdas[1])*ev$vectors[, 1]))
3           [,1]
4 [1,] -0.9918199
5 [2,] -0.9513052
6 [3,] -0.9955425
7 [4,] -0.9796492
```

Nhân tố đầu tiên giải thích 96% phương sai. Tất cả các biến đều tải cao và gần bằng nhau. Nhân tố này có thể được gọi là “chỉ số thuộc tính giấy”.

- Ước lượng L bằng phương pháp hợp lí cực đại

```
1 > #Maximum Likelihood Factor Analysis of R (m = 1)
2 > ftmodel = factanal(covmat = R, factors = 1, rotate = "none")
3 > (L = ftmodel$loadings)
4
5 Loadings:
6     Factor1
7 BL 0.998
8 EM 0.916
9 SF 0.987
10 BS 0.989
11
12                Factor1
13 SS loadings      3.787
14 Proportion Var   0.947
```

Kết quả gần tương tự như kết quả của phương pháp thành phần chính (Phương pháp thành phần chính giải thích được 96%, nhiều hơn 95% của phương pháp hợp lí cực đại). Tương tự, nhân tố này cũng có thể được gọi là “chỉ số thuộc tính giấy”.

Phân tích trên S :

```
1 (S = cov(data))
2           BL           EM           SF           BS
3 BL 8.302871 1.8866363 4.1473181 1.9720562
4 EM 1.886636 0.5133593 0.9875851 0.4343071
5 SF 4.147318 0.9875851 2.1400458 0.9879663
6 BS 1.972056 0.4343071 0.9879663 0.4802721
7 > ev = eigen(S)
8 > lambdas = ev$values
9 > cumsum(lambdas)/sum(lambdas)
10 [1] 0.9876239 0.9966844 0.9994710 1.0000000
11 > #Principal Component Factor Analysis of S (m = 1)
12 > (L = cbind(sqrt(lambdas[1])*ev$vectors[, 1]))
13           [,1]
```

```

14 [1,] 2.8784542
15 [2,] 0.6640048
16 [3,] 1.4494165
17 [4,] 0.6839584
18 > #Maximum Likelihood Factor Analysis of S (m = 1)
19 > ftmodel = factanal(covmat = S, factors = 1, rotate = "none")
20 > (L = ftmodel$loadings)
21
22 Loadings:
23     Factor1
24 BL 0.998
25 EM 0.916
26 SF 0.987
27 BS 0.989
28
29              Factor1
30 SS loadings      3.787
31 Proportion Var   0.947

```

Đối với phương pháp hợp lí cực đại thì kết quả không có sự khác biệt. Đối với phương pháp thành chính thì nhấn mạnh ảnh hưởng của hai biến *BL* và *SF* hơn trong nhân tố.

Vậy tóm lại, ta có thể dùng một nhân tố để giải thích cho bộ dữ liệu gồm 4 biến *BL*, *EM*, *SF* và *BS*. □

9.35. Giải lại bài 9.34 bằng cách sử dụng các quan trắc trên các biến đặc tính của sợi bột giấy AFL, LFF, FFF và ZST. Những dữ liệu này có thể được tóm tắt bằng một yếu tố duy nhất không? Giải thích.

Lời giải. Đọc dữ liệu

```

1 > data = read.table("http://users.stat.umn.edu/~sandy/courses/8053/Data/
   Wichern_data/T7-7.dat")
2 > colnames(data) = c("BL", "EM", "SF", "BS", "AFL", "LFF", "FFF", "ZST")
3 > data = data[,c('AFL', 'LFF', 'FFF', 'ZST')]
4 > head(data)
5      AFL    LFF    FFF    ZST
6 1 -0.030 35.239 36.991 1.057
7 2  0.015 35.713 36.851 1.064
8 3  0.025 39.220 30.586 1.053
9 4  0.030 39.756 21.072 1.050
10 5 -0.070 32.991 36.570 1.049
11 6 -0.050 31.140 38.115 1.052

```

Phân tích trên R:

```

1 > #Sử dụng ma trận tương quan R
2 > (R = cor(data))
3      AFL      LFF      FFF      ZST
4 AFL  1.0000000  0.9055912 -0.7334321  0.7842212
5 LFF  0.9055912  1.0000000 -0.7109855  0.7927309
6 FFF -0.7334321 -0.7109855  1.0000000 -0.7845570
7 ZST  0.7842212  0.7927309 -0.7845570  1.0000000
8 > ev = eigen(R)
9 > lambdas = ev$values

```

```

10 > cumsum(lambdas)/sum(lambdas)
11 [1] 0.8394260 0.9267414 0.9768944 1.0000000

```

Phân tích với $m = 1$ nhân tố:

- Ước lượng L bằng phương pháp thành phần chính

```

1 > #Principal Component Factor Analysis of R (m = 1)
2 > (L = cbind(sqrt(lambdas[1])*ev$vector[, 1]))
3      [,1]
4 [1,] -0.9362775
5 [2,] -0.9326319
6 [3,]  0.8776623
7 [4,] -0.9170578

```

Nhân tố đầu tiên giải thích 84% tổng phương sai và thể hiện sự tương phản giữa *FFF* và nhóm *AFL*, *LFF* và *ZST*. Các biến *AFL* (chiều dài sợi trung bình), *LFF* (sợi dài) và *ZST* (sức căng) đều có thể liên quan đến độ bền (strength) giấy trong khi *FFF* (sợi mịn) có thể liên quan đến chất lượng (quality) giấy. Vậy ta có thể gọi nhân tố này là nhân tố “độ bền - chất lượng”.

- Ước lượng L bằng phương pháp hợp lí cực đại

```

1 > #Maximum Likelihood Factor Analysis of R (m = 1)
2 > ftmodel = factanal(covmat = R, factors = 1, rotate = "none")
3 > (L = ftmodel$loadings)
4
5 Loadings:
6      Factor1
7 AFL  0.949
8 LFF  0.945
9 FFF -0.784
10 ZST  0.846
11
12      Factor1
13 SS loadings  3.125
14 Proportion Var  0.781

```

Nhân tố đầu tiên giải thích 78% tổng phương sai. Tương tự, ta cũng có thể gán nhãn nhân tố này là nhân tố “độ bền - chất lượng”.

Vậy ta có thể dùng một nhân tố để giải thích cho bộ dữ liệu gồm 4 biến *AFF*, *LFF*, *FFF* và *ZST*.

Phân tích trên S :

```

1 > #Su dung ma tran tuong quan S
2 > (S = cov(data))
3
4      AFL      LFF      FFF      ZST
5 AFL  0.06226868  3.3598034 -3.2140442  0.0057713099
6 LFF  3.35980342 221.0516096 -185.6370704  0.3475951169

```

```

6 FFF -3.21404415 -185.6370704 308.3998916 -0.4063335029
7 ZST 0.00577131 0.3475951 -0.4063335 0.0008697652
8 > ev = eigen(S)
9 > lambdas = ev$values
10 > cumsum(lambdas)/sum(lambdas)
11 [1] 0.8601809 0.9999803 0.9999996 1.0000000
12 > #Principal Component Factor Analysis of S (m = 1)
13 > (L = cbind(sqrt(lambdas[1])*ev$vectors[, 1]))
14 [1,]
15 [1,] -0.21581692
16 [2,] -13.25040119
17 [3,] 16.72895767
18 [4,] -0.02503868
19 > #Maximum Likelihood Factor Analysis of S (m = 1)
20 > ftmodel = factanal(covmat = S, factors = 1, rotate = "none")
21 > (L = ftmodel$loadings)
22
23 Loadings:
24 Factor1
25 AFL 0.949
26 LFF 0.945
27 FFF -0.784
28 ZST 0.846
29
30 Factor1
31 SS loadings 3.125
32 Proportion Var 0.781

```

Ta thấy nếu dùng phương pháp hợp lý cực đại thì kết quả phân tích trên **S** cũng giống trên **R**. Tuy nhiên nếu dùng phương pháp thành phần chính thì kết quả phân tích trên **S** có nhiều sự khác biệt so với trên **R**. Cụ thể là hệ số của *LFF* và *FFF* có sự chênh lệch lớn so với hệ số của *AFL* và *ZST*.

Nói chung, phương pháp thành phần chính nhạy cảm với tỉ lệ và phụ thuộc mạnh vào đơn vị đo, vì vậy nếu ta dùng **S** thay cho **R** thì sẽ khó diễn giải nhân tố hơn. $\square$

Tài liệu

- [1] Richard A. Johnson and Dean W. Wichern, *Applied Multivariate Statistical Analysis*, 6nd edition, 2014.
- [2] V.H.Hoang, *Phương pháp phân tích thành phần chính (PCA) trong xử lý số liệu nhiều chiều và các ứng dụng*, Seminar Thống kê Ứng dụng 2021.