

Thống kê Phi tham số

Chương 4: Hồi quy phi tham số

Hoàng Văn Hà

hvha@hcmus.edu.vn

Faculty of Mathematics and Computer Science
University of Science, VNU - HCM

Nội dung

1 Giới thiệu

2 Ước lượng hàm hồi quy bởi histogram

3 Ước lượng Nadaraya-Watson

4 Ước lượng đa thức địa phương (local polynomial estimator)

5 Ước lượng hình chiếu

Mô hình hi quy tham s:- Linear Regression: $Y = BX$

Giới thiệu

- Xét cặp biến ngẫu nhiên (X, Y) với $\mathbb{E}[|Y|] < \infty$.
- $r: x \mapsto r(x) = \mathbb{E}[Y|X=x]$ hàm hồi quy của Y .
- Xét mẫu cỡ n $(X_1, Y_1), \dots, (X_n, Y_n)$ có cùng phân phối với (X, Y) .
- Ta muốn ước lượng hàm r bằng cách đặt ít nhất giả thuyết có thể, chỉ dùng duy nhất $r \in \mathcal{F}$ với $\mathcal{F}$ là một không gian hàm.
- Tập các biến ngẫu nhiên $(X_1, X_2, \dots, X_n)$ được gọi một *thiết kế (design)*. Chúng có thể xác định (deterministic) hoặc ngẫu nhiên (random). Trong trường hợp đầu tiên, ta gọi là "các hiệu ứng cố định" (hay thiết kế cố định), trong trường hợp thứ hai, ta gọi là "các hiệu ứng ngẫu nhiên".
- Ta ký hiệu $\xi = Y - \mathbb{E}[Y|X]$ là thặng dư (residual), với giả thiết $\mathbb{E}[\xi] = 0$. Ta có thể viết

$$Y_i = r(X_i) + \xi_i, \quad 1 \leq i \leq n.$$

$$\xi \sim N(0, \sigma^2)$$
- Các $\{\xi_i\}_{1 \leq i \leq n}$ đóng vai trò là nhiễu (noise). Ta giả sử rằng chúng có momen bậc 2 hữu hạn và kí hiệu $\sigma^2 = \mathbb{V}ar(\xi)$.

Regressogram

- Tương tự như ước lượng hàm mật độ, ta có thể sử dụng histogram để ước lượng hàm hồi quy phi tham số. Ta giả sử rằng hàm r xác định trên một khoảng đóng $[a, b] \subset \mathbb{R}$ và $r \in \mathbb{L}_2([a, b])$.


Định nghĩa 1

- Xét $I = (I_k)_{1 \leq k \leq D}$ là một phân hoạch của $[a, b]$ (tức là tập các khoảng rời nhau và hợp của chúng bằng $[a, b]$),
- Kí hiệu $n_k = \text{Card}\{i : X_i \in I_k\}$ số biến X trong khoảng I_k .
- Ước lượng regressogram của r được định nghĩa bởi

$$\hat{r}_{I,n}(x) = \sum_{i=1}^D \left[\sum_{i=1}^n \frac{Y_i}{n_k} \mathbb{1}_{X_i \in I_k} \right] \mathbb{1}_{I_k}(x). \quad (1)$$

- Trong mỗi khoảng I_k , ta tính một giá trị bằng trung bình của các quan trắc Y , được chuẩn hóa (renormalized) bởi số quan trắc X trong khoảng đó.

Minh họa



Hình: Regressogram với dữ liệu mcycle trong thư viện MASS của R.

Ghi chú

- **Nhược điểm:** cần phải chọn trước số khoảng.
- Việc lấy giá trị trung bình trong mỗi khoảng tương tự như kết quả của một cửa sổ trượt với hàm nhân tứ giác, do vậy việc sử dụng hàm nhân sẽ tốt hơn.

Xây dựng ước lượng Nadaraya-Watson

phổ biến

- Giả sử rằng (X, Y) có hàm mật độ đồng thời $f_{XY} : (x, y) \mapsto f_{XY}(x, y)$ thuộc $\mathbb{R}^2$ và $f_X(x) = \int f_{XY}(x, y) dy > 0$. Ta có

$$\forall x \in \mathbb{R}, r(x) = \mathbb{E}[Y|X = x] = \frac{\int y f_{XY}(x, y) dy}{f_X(x)}.$$

①

- Các hàm mật độ f_{XY} và f_X đều không biết, nhưng ta có thể ước lượng chúng bởi các hàm nhân

$$\forall (x, y) \in \mathbb{R}^2, \hat{f}_{n,XY}(x, y) = \frac{1}{n} \sum_{i=1}^n K_h(X_i - x) K_h(Y_i - y),$$

$$\hat{f}_{n,X}(x) = \frac{1}{n} \sum_{i=1}^n K_h(X_i - x).$$

- Ta xét ước lượng của hàm hồi quy

$$\hat{r}_n(x) = \frac{\int y \hat{f}_{n,XY}(x, y) dy}{\hat{f}_{n,X}(x)} \mathbb{1}_{\hat{f}_{n,X}(x) \neq 0}, \quad \forall x \in \mathbb{R}.$$

(2)

Ước lượng Nadaraya-Watson

Mệnh đề 1

Nếu K là một hàm nhân bậc 1, thì ước lượng định nghĩa bởi (2) thỏa


$$\hat{r}_n(x) = \frac{\sum_{i=1}^n Y_i K_h(X_i - x)}{\sum_{i=1}^n K_h(X_i - x)} \mathbb{1}_{\{\sum_{i=1}^n K_h(X_i - x) \neq 0\}}, \quad \forall x \in \mathbb{R}, \quad (3)$$

với $K_h(\cdot) = \frac{1}{h} K\left(\frac{\cdot}{h}\right)$.

Ước lượng này được gọi là ước lượng Nadaraya-Watson, ký hiệu r_n^{NW} .


Trong R, dùng hàm npreg trong gói np.

Minh họa



Hình: Ước lượng Nadaraya-Watson với hàm nhân tứ giác ($K(u) = \frac{1}{2}\mathbb{1}_{|u|\leq 1}(u)$) với một số giá trị khác nhau của h .

Minh họa



Hình: Ước lượng Nadaraya - Watson với dữ liệu mcycle trong thư viện MASS.

Ghi chú

- Ước lượng Nadaraya-Watson là một trung bình trọng số (weighted mean) của các quan trắc Y_i ,

$$\hat{r}_n^{NW}(x) = \sum_{i=1}^n Y_i W_{n,i}(x), \quad x \in \mathbb{R},$$

trong đó các trọng số $W_{n,i}(x)$ thỏa

$$W_{n,i}(x) = \frac{K_h(X_i - x)}{\sum_{j=1}^n K_h(X_j - x)} \mathbb{1}_{\{\sum_{j=1}^n K_h(X_j - x) \neq 0\}}.$$

- Các trọng số này chỉ phụ thuộc vào các giá trị $X_1, \dots, X_n$ và

$$\sum_{i=1}^n W_{n,i}(x) = 1.$$

- $\hat{r}_n^{NW}$ là một ước lượng tuyến tính (linear estimator) theo các quan trắc Y_i (đừng nhầm lẫn với hồi quy tuyến tính).

Biểu diễn dạng ma trận

hãy thử

- Giả sử ta quan trắc được n cặp điểm (x_i, y_i) , $1 \leq i \leq n$. Đặt $\hat{y}_i = \hat{f}_n^{NW}(x_i)$ và gọi $\mathbf{W}$ là ma trận cỡ n với các thành phần $w_{ij} = W_{n,i}(x_j)$. Ta thấy rằng

$$\begin{pmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_n \end{pmatrix} = \begin{pmatrix} w_{11} & \cdots & w_{1,n} \\ \vdots & w_{ij} & \vdots \\ w_{n1} & \cdots & w_{nn} \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix},$$

hay

$$\hat{\mathbf{y}} = \mathbf{W}\mathbf{y}.$$

Ghi chú

- Nếu ta biết hàm mật độ $f_X(x)$, ta có thể sử dụng $f_X(x)$ thay vì $\hat{f}_{n,X}$ trong biểu thức (2)

$$\hat{f}_n(x) = \frac{\int y \hat{f}_{XY}(x, y) dy}{f_X(x)} = \frac{\mathbb{1}_{\{f_X(x) \neq 0\}}}{n f_X(x)} \sum_{i=1}^n Y_i K_h(X_i - x).$$

- Cụ thể, nếu các biến $X_1, \dots, X_n$ có phân phối đều trên đoạn $[0, 1]$, ta thu được

$$\hat{f}_n(x) = \frac{1}{n} \sum_{i=1}^n Y_i K_h(X_i - x) \mathbb{1}_{[0,1]}(x). \quad (4)$$

- Trong trường hợp thiết kế cố định, tức là $X_i = i/n$, $1 \leq i \leq n$, ta không có hàm mật độ f_X . Tuy nhiên, ước lượng (4) vẫn đáp ứng rất tốt cho trường hợp này.
- Ước lượng Nadaraya-Watson là một trường hợp cụ thể của một lớp các ước lượng tổng quát hơn: các ước lượng đa thức địa phương. Ta sẽ khảo sát các ước lượng này trong phần tiếp theo.

Lựa chọn cửa sổ theo phương pháp kiểm tra chéo (Cross-Validation)

- Ta sử dụng LOO-CV (Leave-one-out Cross-Validation). Gọi $\hat{r}_h^{(-i)}$ là ước lượng thu được bởi việc rút ra cặp (X_i, Y_i) . Ta có

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \left(Y_i - \hat{r}_h^{(-i)}(X_i) \right)^2.$$

- Ta có thể chỉ ra rằng

$$CV(h) = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{r}_h(X_i)}{1 - \mathbf{W}_{ii}} \right)^2, \quad (5)$$

với $\mathbf{W}_{ii}$ là phần tử nằm trên đường chéo chính của ma trận $\mathbf{W}$.

- Ta chọn $\hat{h}$ thỏa

$$\hat{h} = \underset{h \in H}{\operatorname{argmin}} CV(h).$$

code R

- Nếu thay thế $\mathbf{W}_{ii}$ bởi giá trị trung bình $(1/n) \sum_{i=1}^n \mathbf{W}_{ii} = (1/n) \operatorname{tr}(\mathbf{W}) = \tau/n$, ta thu được phiên bản cải tiến của CV là

$$GCV(h) = \frac{1}{(1 - \frac{\tau}{n})^2} \sum_{i=1}^n (Y_i - \hat{r}_h(X_i))^2.$$

Xây dựng ước lượng đa thức địa phương

- Để ý rằng nếu K là một hàm nhân dương thì

$$\hat{f}_n^{NW}(x) = \operatorname{argmin}_{\theta \in \mathbb{R}} \sum_{i=1}^n K_h(X_i - x)(Y_i - \theta)^2, \quad x \in \mathbb{R}.$$

- Thật vậy, ta có

$$-2 \sum_{i=1}^n K_h(X_i - x)(Y_i - \theta) = 0 \quad : \text{đạo hàm}$$

$$\Leftrightarrow \theta = \frac{\sum_{i=1}^n Y_i K_h(X_i - x)}{\sum_{i=1}^n K_h(X_i - x)} \mathbb{1}_{\{\sum_{i=1}^n K_h(X_i - x) \neq 0\}},$$

và đây là một điểm cực tiểu nếu $K \geq 0$.

Xây dựng ước lượng đa thức địa phương

- Theo nghĩa bình phương bé nhất có trọng số (weighted least squares), ta xấp xỉ Y_i bởi một hằng số (theo x), gọi là θ .
- Tổng quát hơn, ta có thể xấp xỉ Y_i bởi một đa thức.
- Như vậy, hàm hồi quy r , xung quanh một lân cận của x có thể được xấp xỉ bởi một đa thức (địa phương), mà không chỉ là một hằng số θ .

Xây dựng ước lượng đa thức địa phương

- Nếu hàm r có đạo hàm ℓ lần xung quanh một lân cận của x , thì với u đủ gần với x , ta thể biểu diễn

$$r(u) = r(x) + r'(x)(u-x) + \cdots + \frac{r^{(\ell)}(x)}{\ell!}(u-x)^\ell. \quad \text{Taylor}$$

- Ta thêm vào biểu thức trên của số h ,

$$\begin{aligned} r(u) &= r(x) + r'(x)h \left(\frac{u-x}{h} \right) + \cdots + \frac{r^{(\ell)}(x)h^\ell}{\ell!} \left(\frac{u-x}{h} \right)^\ell \\ &= \theta^T(x) V_\ell \left(\frac{u-x}{h} \right), \end{aligned}$$

với $\theta(x) = (r(x), r'(x)h, \dots, r^{(\ell)}(x)h^\ell)^T$ là một véc-tơ chứa các giá trị của r và đạo hàm tại x và $V_\ell(z) = (1, z, z^2/2!, \dots, z^\ell/(\ell!))^T$.

$$z = \frac{u-x}{h}$$

Xây dựng ước lượng đa thức địa phương

Định nghĩa 2

Xét $K : \mathbb{R} \rightarrow \mathbb{R}^+$ là một hàm nhân dương, $h > 0$ là một cửa sổ và $\ell \geq 0$ một số nguyên. Một véc-tơ $\hat{\theta}_n(x) \in \mathbb{R}^{\ell+1}$ được định nghĩa bởi

$$\hat{\theta}_n(x) = \operatorname{argmin}_{\theta \in \mathbb{R}^{\ell+1}} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \left[Y_i - \theta^T V_\ell\left(\frac{X_i - x}{h}\right) \right]^2, \quad (6)$$

được gọi là một ước lượng đa thức địa phương bậc ℓ (local polynomial estimator of order ℓ) của $\theta(x)$, ký hiệu là $LP(\ell)$ của $\theta(x)$. Hơn nữa, thống kê

$$\hat{r}_n^{LP(\ell)}(x) = \hat{\theta}_n^T(x) V_\ell(0), \quad (7)$$

được gọi là ước lượng đa thức địa phương bậc ℓ của hàm hồi quy r .

Chú ý rằng trong định nghĩa trên, $\hat{r}_n^{LP(\ell)}(x)$ chính là tọa độ đầu tiên của véc-tơ $\hat{\theta}_n(x)$.

Biểu diễn dạng ma trận

- Ta quan trắc được tập hợp các điểm $(x_i, y_i)_{1 \leq i \leq n}$ (6) được mô tả theo dạng ma trận như sau

$$\min_{\theta \in \mathbb{R}^{\ell+1}} (\mathbf{y} - \mathbf{V}_\ell(x)\theta)^T \mathbf{W}(x) (\mathbf{y} - \mathbf{V}_\ell(x)\theta),$$

với $\mathbf{y} = (y_1, \dots, y_n)^T$, $\mathbf{W}(x) = \text{diag}(K_h(x_1 - x), \dots, K_h(x_n - x))$ và

$$\mathbf{V}_\ell(x) = \begin{pmatrix} 1 & (x_1 - x) & \cdots & (x_1 - x)^\ell \\ \vdots & & & \\ 1 & (x_n - x) & \cdots & (x_n - x)^\ell \end{pmatrix}.$$

- Lời giải được cho bởi

$$\hat{\theta}_n(x) = \left(\hat{r}_n(x), \dots, \frac{\hat{r}_n^{(\ell)}(x)}{\ell!} \right) = \left\{ \mathbf{V}_\ell(x)^T \mathbf{W}(x) \mathbf{V}_\ell(x) \right\}^{-1} \mathbf{V}_\ell(x)^T \mathbf{W}(x) \mathbf{y}.$$

Nhận xét

- Ta thấy rằng khi $\ell = 0$ thì ta có $\hat{r}_n^{\text{LP}(0)} = \hat{r}_n^{\text{NW}}$.
- $\hat{\theta}_n$ chứa nhiều hơn một ước lượng của hàm hồi quy r , bởi vì các tọa độ của nó là các ước lượng của các đạo hàm liên tiếp của r , cho đến bậc ℓ .
- Ta có thể chỉ ra rằng $\hat{r}_n^{\text{LP}(\ell)}$ là một ước lượng tuyến tính (theo các quan trắc) của hàm hồi quy.

Độ chệch và phương sai của ước lượng đa thức địa phương

- Trong phần này, ta chỉ khảo sát duy nhất mô hình hồi quy với thiết kế cố định trên $[0, 1]$, tức là

$$Y_i = r(x_i) + \xi_i, \quad 1 \leq i \leq n, \quad x_i \in [0, 1],$$

và ta quan tâm đến việc khảo sát rủi ro theo từng điểm (point-wise risk) tại $x \in [0, 1]$ cố định.

- Ký hiệu $\hat{r}_n$ là ước lượng đa thức địa phương bậc ℓ .
- Ta giả sử thiết kế là đủ đều và hàm nhân K có giá com-pắc.

Độ chệch và phương sai của ước lượng đa thức địa phương

- **Độ chệch:** Ta giả sử rằng $r \in \mathcal{H}(\beta, L)$ không gian Hölder trên $[0, 1]$, với β, L là các hằng số. Khi đó, tồn tại C sao cho

$$|b(x)| \leq \frac{CLh^\beta}{\ell!}.$$

- **Phương sai:** ta chứng tỏ được rằng

$$\sigma^2(x) \leq \frac{2\sigma^2 K_{\max}}{nh}.$$

Có thể
thi CM

Thỏa hiệp độ chệch - phương sai (bias-variance compromise)

- Ta có

$$\begin{aligned}\text{MSE}(x) &= \mathbb{E} \left[(\hat{r}_n(x) - r(x))^2 \right] = b^2(x) + \sigma^2(x) \\ &\leq C_1 h^{2\beta} + C_2 \times \frac{1}{nh}.\end{aligned}$$

- Ta chọn cửa sổ $h^* = cn^{-1/(2\beta+1)}$ với $c > 0$, thì tồn tại hằng số $C > 0$ sao cho

$$\limsup_{n \rightarrow \infty} \sup_{r \in \mathcal{H}(\beta, L)} \sup_{x \in [0, 1]} \mathbb{E} \left[n^{2\beta/(2\beta+1)} |\hat{r}^*(x) - r(x)|^2 \right] \leq C \leq \infty.$$

Ước lượng hình chiếu

- Ta vẫn xét mô hình hồi quy với thiết kế cố định thuộc $[0, 1]$.
- Giả sử rằng $r \in \mathbb{L}^2([0, 1])$.
- Với $\{\phi_j\}_{j \geq 1}$ là một cơ sở trực chuẩn (Orthonormal basis - ONB) của $\mathbb{L}^2([0, 1])$. Ta có

$$r(x) = \sum_{j=1}^{\infty} \theta_j \phi_j(x),$$

với $\theta_j = \langle r, \phi_j \rangle = \int r(x) \phi_j(x) dx$ là hình chiếu của r xuống tọa độ thứ j của cơ sở.

- Nếu $\{\hat{\theta}_j\}_{j \geq 1}$ là các ước lượng của $\{\theta_j\}_{j \geq 1}$ ta định nghĩa ước lượng hình chiếu của r bởi

$$\hat{r}_{n,D}(x) = \sum_{j=1}^D \hat{\theta}_j \phi_j(x).$$

- D đóng vai trò như cửa sổ h của ước lượng nhân.

Ước lượng hình chiều

Trường hợp thiết kế cố định đều trên $[0, 1]$:

- Mô hình

$$Y_i = r(i/n) + \xi_i, \quad 1 \leq i \leq n,$$

- Ta có

$$\theta_j = \int_0^1 r(x) \phi_j(x) \simeq \frac{1}{n} \sum_{i=1}^n r(i/n) \phi_j(i/n).$$

Tích phân
Riemann

- Do vậy, một ước lượng tự nhiên của θ_j là

$$\hat{\theta}_j = \frac{1}{n} \sum_{i=1}^n Y_i \phi_j\left(\frac{i}{n}\right).$$

VL ko chệch

- Vậy ước lượng hình chiều được cho bởi

$$\hat{r}_{n,D} = \frac{1}{n} \sum_{i=1}^n Y_i \left(\sum_{j=1}^D \phi_j(i/n) \phi_j(x) \right).$$

Chú ý rằng đây cũng là một ước lượng tuyến tính.

Ví dụ về các cơ sở của $\mathbb{L}^2$

- Cơ sở regressogram trên $[0,1]$: cố định $p \geq 1$ và

$$\phi_k(x) = c_k \mathbb{1}_{\left\{ \left[\frac{k-1}{2^p}, \frac{k}{2^p} \right] \right\}}, \quad 1 \leq k \leq 2^p,$$

với $c_k = 2^{p/2}$ là hằng số chuẩn hóa.

- Cơ sở lượng giác (Fourier): đặt $\phi_1(x) = 1$ và

$$\forall k \geq 1, \quad \phi_{2k}(x) = \sqrt{2} \cos(2\pi kx) \text{ và } \phi_{2k+1}(x) = \sqrt{2} \sin(2\pi kx).$$

- Cơ sở Wavelet: Xét $\psi : \mathbb{R} \rightarrow \mathbb{R}$ là một hàm đủ trơn. Ta định nghĩa

$$\psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k), \quad j, k \in \mathbb{Z}.$$

Dưới một số điều kiện nhất định, thì $\{\psi_{j,k}\}_{j,k \in \mathbb{Z}}$ tạo thành 1 ONB của $\mathbb{L}^2(\mathbb{R})$.