

Thống kê Phi tham số

Chương 5: Các phương pháp tái chọn mẫu (Resampling Methods)

Hoàng Văn Hà
hvha@hcmus.edu.vn

Faculty of Mathematics and Computer Science
University of Science, VNU - HCM

Nội dung

- 1 Giới thiệu
- 2 Phương pháp bootstrap
- 3 Ví dụ về các ước lượng bootstrap

Các kỹ thuật của việc tái chọn mẫu

- Các phương pháp thống kê dựa trên việc **tái chọn mẫu (resampling)** dùng để ước lượng phân phối của một biến ngẫu nhiên $T(\mathbf{X})$ từ một mẫu $\mathbf{X} = (X_1, \dots, X_n)$ các biến ngẫu nhiên độc lập và có cùng phân phối.
- Việc tái chọn mẫu là một khung (framework) cho phép ta đo đặc độ bất định và chất lượng của một quy trình (chẳng hạn như việc ước lượng một tham số nào đó).

Tham khảo:

- Phương pháp Jackknife [Quenouille 49, Quenouille 56, Tukey 58]
- Bootstrap [Efron 79]
- Kiểm tra chéo (Cross-Validation)
- Kiểm định hoán vị (Permutation test)
- ...

PP bootstrap - giới thiệu

- **Phương pháp bootstrap**, được giới thiệu lần đầu tiên bởi B. Efron (1979), là một phương pháp tái chọn mẫu thường được dùng để tìm
 - ▶ sai số chuẩn (standard error) cho các ước lượng,
 - ▶ các khoảng tin cậy đối với các tham số chưa biết,
 - ▶ p -giá trị cho các thống kê dưới giả thuyết H_0 .

PP bootstrap - giới thiệu

- **Phương pháp bootstrap**, được giới thiệu lần đầu tiên bởi B. Efron (1979), là một phương pháp tái chọn mẫu thường được dùng để tìm
 - ▶ sai số chuẩn (standard error) cho các ước lượng,
 - ▶ các khoảng tin cậy đối với các tham số chưa biết,
 - ▶ p -giá trị cho các thống kê dưới giả thuyết H_0 .

Ví dụ

Trong một thử nghiệm thuốc, người ta chọn một mẫu gồm 16 con chuột mang bệnh, trong số đó, chọn ngẫu nhiên ra 7 con chuột để được tiêm thuốc điều trị và số chuột còn lại thì được tiêm placebo. Bảng số liệu dưới đây đo thời gian sống sót của các con chuột sau khi được điều trị.

Nhóm điều trị	94, 38, 23, 197, 99, 16, 141
Nhóm đối chứng (placebo)	52, 10, 40, 104, 51, 27, 146, 30, 46

Ta tính được thời gian sống trung bình của hai nhóm là

$$\bar{x}_T = 86.86, \quad \bar{x}_P = 56.22,$$

suy ra $\bar{x}_T - \bar{x}_P = 30.62$. **Câu hỏi:** thuốc điều trị có hiệu quả?

Ví dụ

Các phương pháp phân tích:

- **t-test**: so sánh về trung bình giữa hai nhóm. Điều kiện: dữ liệu tuân theo phân phối chuẩn.
- **Kiểm định phi tham số**: kiểm định Kolmogorov-Smirnov (KS-test) hoặc kiểm định tổng hạng Wilcoxon: **có thể mất đi thông tin**.
- Đối với cách tiếp cận đơn giản: độ chính xác của các ước lượng như thế nào?
 - ▶ Đối với trung bình mẫu $\bar{X}$, ta ước lượng phương sai

$$\text{Var}(\bar{X}) = \frac{\text{Var}(X_1)}{n} \quad \text{bởi} \quad \frac{S^2}{n} = \frac{1}{n(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2.$$

- ▶ Ta thu được

$$\sqrt{\frac{s_T^2}{n_T}} = 25.24, \quad \sqrt{\frac{s_P^2}{n_P}} = 14.14,$$

và sai số chuẩn cho $\bar{x}_T - \bar{x}_P$ bằng $\sqrt{25.24^2 + 14.14^2} = 28.93$.

- ▶ Dưới giả thuyết rằng $\bar{X}_T - \bar{X}_P$ tuân theo phân phối chuẩn, ta kết luận rằng sự sai khác về thời gian sống sót trung bình giữa hai nhóm không có ý nghĩa.

Ví dụ

Trường hợp tổng quát:

- Làm thế nào nếu ta không có công thức để ước lượng sai số chuẩn của một ước lượng?
- Ví dụ: thay vì so sánh trung bình, ta muốn so sánh trung vị của thời gian sống sót, khi đó $\text{Med}(x_T) = 94$ và $\text{Med}(x_P) = 46$ và sai khác $\text{Med}(x_T) - \text{Med}(x_P) = 48$. Nhưng làm sao ta có thể ước lượng được phương sai của đại lượng này?
- Ví dụ khác: nếu ta quan tâm đến hệ số tương quan giữa hai biến, làm thế nào để ước lượng sự biến thiên của hệ số này?
- Bên cạnh phương sai, làm thế nào để xác định phân phối của một ước lượng?

PP bootstrap

- Nếu ta có nhiều mẫu có cùng phân phối $\mathbb{P}$, ta có thể trả lời các câu hỏi trên.
- Trong thống kê phi tham số, xấp xỉ tốt nhất cho $\mathbb{P}$ là phân phối thực nghiệm

$$\mathbb{P}_n = \frac{1}{n} \sum_{i=1}^n \delta_{X_i}.$$

- Khi ta không có các mẫu như vậy, ta có thể mô phỏng các mẫu đó từ phân phối thực nghiệm $\mathbb{P}_n$.

Mục tiêu bootstrap

- **Bối cảnh:**

- ▶ Ta có một mẫu ngẫu nhiên $\mathbf{X} = (X_1, \dots, X_n)$ các BNN i.i.d có phân phối $\mathbb{P}$ chưa biết.
- ▶ Ta quan tâm đến hàm $\phi(\mathbb{P})$ của phân phối $\mathbb{P}$.

- **Các vấn đề mong muốn khảo sát:**

- ▶ Ước lượng từng điểm (point-wise estimation) của $\phi(\mathbb{P})$ bởi $\hat{\phi}(\mathbb{P}) = T(\mathbf{X})$ và nghiên cứu độ chính xác của ước lượng này (độ chệch của $\hat{\phi}$, phương sai của $\hat{\phi}$, MSE của $\hat{\phi}$, ...)
- ▶ Xây dựng một miền tin cậy cho $\phi(\mathbb{P})$,
- ▶ Thực hiện kiểm định giả thuyết trên $\phi(\mathbb{P})$.

Nguyên lý tổng quát của bootstrap

Từ mẫu $\mathbf{X} = (X_1, \dots, X_n)$ các BNN i.i.d, ta xét

- $T(\mathbf{X})$ là một thống kê, được tính toán từ mẫu ban đầu,
- Với $1 \leq b \leq B$,
 - ▶ thực hiện **chọn mẫu có hoàn lại** n biến từ mẫu xuất phát, ký hiệu là $\mathbf{X}^b = (X_1^b, \dots, X_n^b)$. Ta gọi các mẫu này là các mẫu bootstrap.
 - ▶ ta tính toán giá trị của thống kê trên các mẫu bootstrap, ký hiệu là $T^b = T(\mathbf{X}^b)$.
- $\mathbf{T} = (T^1, \dots, T^B)$ là một mẫu bootstrap cỡ B của phân phối có điều kiện của T cho trước $\mathbf{X}$.
- Mẫu này có thể được sử dụng để ước lượng $\mathbb{E}[T|\mathbf{X}]$, $\text{Var}(T|\mathbf{X})$, các khoảng tin cậy cho $\mathbb{E}[T|\mathbf{X}]$, ... chẳng hạn,

$$\bar{T}_{boot} = \frac{1}{B} \sum_{b=1}^B T^b, \quad \widehat{\text{Var}}_{boot}(T) = \frac{1}{B-1} \sum_{b=1}^B (T^b - \bar{T}_{boot})^2.$$

- **Chú ý:** để xấp xỉ được tốt ta cần chọn B đủ lớn.

Nguyên lý tổng quát của bootstrap

- Bootstrap là một công cụ để đo lường sai số của ước lượng hoặc mức ý nghĩa của kiểm định giả thuyết.
- Một mẫu bootstrap là một mẫu được chọn từ mẫu ban đầu (có hoàn lại).
- Phương pháp này hoạt động khi biểu đồ histogram của mẫu có tính đại diện cho tổng thể.
- Nói cách khác, biểu đồ histogram của mẫu giống với hàm mật độ xác suất của biến ngẫu nhiên.
- Việc lấy mẫu từ biểu đồ tần số khi đó tương đương với việc lấy mẫu từ tổng thể
- Do đó, bootstrap cho ta ước lượng về phân phối mẫu của thống kê $T(\mathbf{X})$ hoặc ước lượng θ .

Lý thuyết cơ bản

- Xét $X_1, \dots, X_n$ các BNN i.i.d và $\mathbb{P}_n$ là phân phối thực nghiệm của mẫu cho bởi

$$\mathbb{P}_n(\cdot) = \frac{1}{n} \sum_{i=1}^n \delta_{X_i}(\cdot),$$

với δ_a là độ đo Dirac tại điểm a . Do vậy $\mathbb{P}_n$ là một ước lượng phi tham số của phân phối thực $\mathbb{P}$.

- **Mẫu bootstrap:**

- ▶ Một mẫu bootstrap là mẫu được chọn có hoàn lại trong số các biến $\{X_1, \dots, X_n\}$: mỗi biến được chọn một cách độc lập với xác suất $1/n$. Do vậy, đây là một mẫu với phân phối $\mathbb{P}_n$.
- ▶ Các lặp bootstrap $T^1, \dots, T^B$ có phân phối T cho biết $\mathbf{X}$.

Tương ứng giới thể giới thực và thể giới bootstrap

Thể giới thực	Thể giới bootstrap
Phân phối $\mathbb{P}$ không biết $\mathbf{X} = (X_1, \dots, X_n)$ mẫu xuất phát	Phân phối thực nghiệm $\mathbb{P}_n$ $\mathbf{X}^* = (X_1^*, \dots, X_n^*)$ mẫu bootstrap $\mathbb{P}(X_j^* = X_i \mathbf{X}) = n^{-1}, \forall i, j$
$\theta = \phi(\mathbb{P})$ tham số có phân phối $\mathbb{P}$ $\hat{\theta} = T(\mathbf{X})$ ước lượng của θ phân phối $\hat{\theta}$ (không biết) được xấp xỉ bởi phân phối $\hat{\theta} \mathbf{X}$	$\theta_n = \phi(\mathbb{P}_n)$ tham số thực nghiệm $\hat{\theta}^* = T(\mathbf{X}^*)$ lặp bootstrap Dùng xấp xỉ Monte-Carlo: $\mathbb{P}(\hat{\theta} \in A \mathbf{X}) \simeq \frac{1}{B} \sum_{b=1}^B \mathbb{1}_{\{\hat{\theta}^b \in A\}}$

- **Ví dụ :** $\mathbb{P} = \mathcal{N}(\theta, 1)$, $\theta = \int x d\mathbb{P}(x)$, $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i$, $\theta_n = \hat{\theta}$.
- **Ghi chú:** nếu $\hat{\theta}$ là một ước lượng thu được bởi sự thay thế, thì

$$\hat{\theta} = \phi(\mathbb{P}_n) = \theta_n.$$

Ước lượng độ chệch của một ước lượng

Bối cảnh:

- Xét $\mathbf{X} = (X_1, \dots, X_n)$ i.i.d có phân phối $\mathbb{P}$.
- $\theta = \phi(\mathbb{P})$ là một hàm của phân phối $\mathbb{P}$ và $\theta_n = \phi(\mathbb{P}_n)$.
- $\hat{\theta}$ là một ước lượng của θ (có thể là θ_n).
- $(\mathbf{X}^1, \dots, \mathbf{X}^B)$ là các lặp bootstrap từ mẫu xuất phát (có cỡ n) và $(\hat{\theta}^1, \dots, \hat{\theta}^B)$ là các ước lượng tương ứng.

Ước lượng độ chệch của $\hat{\theta}$:

$$\text{bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta,$$

$$\widehat{\text{bias}}_{\text{boot}}(\hat{\theta}) = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^b - \theta_n.$$

Áp dụng: giảm độ chệch của một ước lượng

- Từ một ước lượng $\hat{\theta}$ ban đầu, ta có thể xem xét

$$\hat{\theta}_{corrected} = \hat{\theta} - \widehat{\text{bias}}_{boot}(\hat{\theta}).$$

- Trường hợp cụ thể nếu $\hat{\theta} = \theta_n = \phi(\mathbb{P}_n)$, ta có

$$\hat{\theta}_{corrected} = 2\hat{\theta} - \frac{1}{B} \sum_{b=1}^B \hat{\theta}^b.$$

- **Chú ý:**

- ▶ Việc giảm độ chệch có thể làm tăng phương sai !!
- ▶ Trong thực hành, việc nghiên cứu độ chệch của một ước lượng chỉ hữu ích khi ước lượng phương sai của nó.

Ước lượng phương sai của một ước lượng

Bối cảnh:

- Xét $\mathbf{X} = (X_1, \dots, X_n)$ i.i.d có phân phối $\mathbb{P}$.
- $\theta = \phi(\mathbb{P})$ là một hàm của phân phối $\mathbb{P}$ và $\theta_n = \phi(\mathbb{P}_n)$.
- $\hat{\theta}$ là một ước lượng của θ .
- $(\mathbf{X}^1, \dots, \mathbf{X}^B)$ là các lặp bootstrap từ mẫu xuất phát (có cỡ n) và $(\hat{\theta}^1, \dots, \hat{\theta}^B)$ là các ước lượng tương ứng.

Ước lượng phương sai của $\hat{\theta}$:

$$\text{Var}(\hat{\theta}) = \mathbb{E} \left[\left(\hat{\theta} - \mathbb{E}[\hat{\theta}] \right)^2 \right],$$

$$\widehat{\text{Var}}_{boot}(\hat{\theta}) = \frac{1}{B-1} \sum_{b=1}^B \left(\hat{\theta}^b - \frac{1}{B} \sum_{b'=1}^B \hat{\theta}^{b'} \right)^2.$$

Áp dụng: sai số chuẩn của ước lượng thu được bởi thuật toán EM

Bối cảnh:

- Ta nghiên cứu mô hình với dữ liệu khuyết (missing data) hoặc mô hình với các biến ẩn (latent variables), như mô hình hỗn hợp (mixed model), HMM (Hidden Markov Model), ...
- Trong các mô hình này, ước lượng hợp lý cực đại (MLE) $\hat{\theta}^{MLE}$ của tham số θ không phải là một biểu thức tường minh đơn giản. Ta thường sử dụng thuật toán EM (Expectation - Maximization) để ước lượng θ , gọi là $\hat{\theta}^{EM}$.
- Thuật toán EM không cung cấp cho ta ước lượng của phương sai $\text{Var}(\hat{\theta}^{EM})$.

Sai số chuẩn của $\hat{\theta}^{EM}$:

- Với mỗi mẫu bootstrap $\mathbf{X}^b$, ta sử dụng thuật toán EM để xây dựng một ước lượng $\hat{\theta}^{EM,b}$.
- Ta ước lượng sai số của $\hat{\theta}^{EM}$ bởi

$$\widehat{\text{SE}}_{boot}(\hat{\theta}^{EM}) = \left\{ \frac{1}{B-1} \sum_{b=1}^B \left(\hat{\theta}^b - \frac{1}{B} \sum_{b'=1}^B \hat{\theta}^{b'} \right)^2 \right\}^{1/2}$$

Ước lượng rủi ro MSE của một ước lượng

Bối cảnh:

- Xét $\mathbf{X} = (X_1, \dots, X_n)$ i.i.d có phân phối $\mathbb{P}$.
- $\theta = \phi(\mathbb{P})$ là một hàm của phân phối $\mathbb{P}$ và $\hat{\theta}_n = \phi(\mathbb{P}_n)$.
- $\hat{\theta}$ là một ước lượng của θ .
- $(\mathbf{X}^1, \dots, \mathbf{X}^B)$ là các lặp bootstrap từ mẫu xuất phát (có cỡ n) và $(\hat{\theta}^1, \dots, \hat{\theta}^B)$ là các ước lượng tương ứng.

Ước lượng MSE (Mean Square Error) của $\hat{\theta}$:

$$\text{MSE}(\hat{\theta}) = \mathbb{E} \left[\left(\hat{\theta} - \theta \right)^2 \right],$$

$$\widehat{\text{MSE}}_{boot}(\hat{\theta}) = \frac{1}{B} \sum_{b=1}^B \left(\hat{\theta}^b - \hat{\theta}_n \right)^2.$$

Ước lượng bootstrap cho phân phối của một thống kê mẫu

Bối cảnh:

- Xét $\mathbf{X} = (X_1, \dots, X_n)$ i.i.d có phân phối $\mathbb{P}$.
- $\theta = \phi(\mathbb{P})$ là một hàm của phân phối $\mathbb{P}$ và $\theta_n = \phi(\mathbb{P}_n)$.
- $\hat{\theta}$ là một ước lượng của θ .
- $(\mathbf{X}^1, \dots, \mathbf{X}^B)$ là các lặp bootstrap từ mẫu xuất phát (có cỡ n) và $(\hat{\theta}^1, \dots, \hat{\theta}^B)$ là các ước lượng tương ứng.

Ước lượng phân phối của T : với $(T^1, \dots, T^B)$ là một mẫu của phân phối có điều kiện của T cho trước $\mathbf{X}$, ta có thể

- tính toán các phân vị thực nghiệm, để có thể thực hiện các kiểm định,
- ước lượng mật độ của T ,
- xây dựng khoảng tin cậy trên $\phi(\mathbb{P})$,
- ...

Áp dụng: kiểm định unimodal của phân phối

Bối cảnh:

- Xét $X_1, \dots, X_n \stackrel{i.i.d}{\sim} f$, f không biết.
- Ta muốn kiểm định H_0 : " f có một mode" với H_1 : " f có ít nhất 2 mode".
- Ta ước lượng f bởi một ước lượng nhân $\hat{f}_{n,h}$ với cửa sổ h .
- Khi h càng lớn, hàm ước lượng càng trơn và ta có ít mode cho $\hat{f}_{n,h}$.
- Đặt

$$h_{\min} = \min \left\{ h > 0, \forall h' < h : \hat{f}_{n,h'} \text{ có ít nhất 2 mode} \right\}.$$

Xây dựng kiểm định:

- Ta bác bỏ H_0 khi h lớn hơn một ngưỡng s .
- Đối với mức ý nghĩa của kiểm định, ta phải xác định phân phối của $h_{\min}$ dưới H_0 : sử dụng ước lượng bootstrap cho phân vị $q_{1-\alpha}$ của phân phối của $h_{\min}$.

Áp dụng: kiểm định unimodal của phân phối

Thực hành: với $1 \leq b \leq B$

- Chọn mẫu ngẫu nhiên có hoàn lại $\mathbf{X}^b$ từ các quan trắc ban đầu,
- Ta xác định, trên một lưới các giá trị của h , giá trị $h_{\min}^b$ với mỗi mẫu bootstrap,
- Ta thu được phân phối thực nghiệm $\hat{F}_B^*$ cho $h_{\min}$.
- Cuối cùng, ta ước lượng phân vị $q_{1-\alpha}$ của biến $h_{\min}$ bởi

$$\hat{q}_{1-\alpha} = (\hat{F}_B^*)^{-1}(1 - \alpha).$$

Ta cần một thống kê thứ tự của chỉ số $\lceil B(1 - \alpha) \rceil$ từ mẫu $\{h_{\min}^b\}_{1 \leq b \leq B}$.

Xây dựng khoảng tin cậy

Bối cảnh:

- $\mathbf{X} = (X_1, \dots, X_n)$ các BNN i.i.d có phân phối $\mathbb{P}$,
- $\theta = \phi(\mathbb{P}) \in \mathbb{R}$ là một tham số thực của phân phối $\mathbb{P}$, và $\theta_n = \phi(\mathbb{P}_n)$ tham số thực nghiệm.
- Một khoảng tin cậy (Confidence Interval - CI) $1 - \alpha$ là một khoảng ngẫu nhiên $[T_1(\mathbf{X}), T_2(\mathbf{X})]$ sao cho

$$\mathbb{P}(\theta \in [T_1(\mathbf{X}), T_2(\mathbf{X})]) \geq 1 - \alpha.$$

Pivotal CI:

- Tìm một hàm **pivot** $g(\mathbf{X}, \theta)$ mà phân phối của nó không phụ thuộc vào θ .
- Xác định các phân vị $q_{\alpha/2}$ và $q_{1-\alpha/2}$ của phân phối của $g(\mathbf{X}, \theta)$.
- Phương trình nghịch đảo:

$$g(\mathbf{X}, \theta) \in [q_{\alpha/2}, q_{1-\alpha/2}] \Leftrightarrow \theta \in [T_1(\mathbf{X}), T_2(\mathbf{X})].$$

Xây dựng khoảng tin cậy

Pivotal CI:

- Ta tạo B lặp bootstrap $g(\mathbf{X}^b, \theta)$ của hàm pivot, từ đó ta ước lượng các phân vị $\hat{q}_{\alpha/2}^*$ và $\hat{q}_{1-\alpha/2}^*$ là các thống kê thứ tự tương ứng với chỉ số $\lceil B\alpha/2 \rceil$ và $\lceil B(1 - \alpha/2) \rceil$ của mẫu bootstrap.
- **Ưu điểm:** không cần giả thuyết đối với phân phối của pivot (ví dụ về pp chuẩn hay Student).
- **Hạn chế:** cần thiết về sự tồn tại của một hàm pivot.

Ví dụ:

- θ là tham số vị trí, được ước lượng bởi $\hat{\theta}$.
- Dưới giả thuyết rằng

$$\frac{\hat{\theta} - \theta}{SE(\hat{\theta})}$$

là một phân phối (tiệm cận) độc lập với θ , ta có thể xây dựng một CI bootstrap cho θ .

Xây dựng khoảng tin cậy

Xây dựng bởi phân vị bootstrap:

- Ta tạo B lặp bootstrap của một ước lượng $\{\hat{\theta}^{*b}\}_{1 \leq b \leq B}$,
- Gọi $\hat{q}_{\alpha/2}^*$ và $\hat{q}_{1-\alpha/2}^*$ là các thống kê thứ tự tương ứng với chỉ số $\lceil B\alpha/2 \rceil$ và $\lceil B(1-\alpha/2) \rceil$ của mẫu bootstrap $\{\hat{\theta}^{*b}\}_{1 \leq b \leq B}$,
- Khoảng tin cậy $1 - \alpha$ cho θ là $[\hat{q}_{\alpha/2}^*, \hat{q}_{1-\alpha/2}^*]$.

Khoảng tin cậy chuẩn bootstrap:

- Giả thiết: $\frac{\hat{\theta} - \theta}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1)$, với $\sigma^2 = \text{Var}(\hat{\theta}_n)$.
 - ▶ Nếu ta biết σ , thì khoảng tin cậy $1 - \alpha$ của θ cho bởi $[\hat{\theta}_n \pm z_{\alpha/2}\sigma]$.
 - ▶ Nếu σ không biết, ta ước lượng nó bởi bootstrap. Và khoảng tin cậy chuẩn bootstrap cho bởi

$$\left[\hat{\theta}_n \pm z_{\alpha/2} \sqrt{\widehat{\text{Var}}_{boot}(\hat{\theta})} \right],$$

với

$$\widehat{\text{Var}}_{boot}(\hat{\theta}) = \frac{1}{B} \sum_{i=1}^B \left(\hat{\theta}^{*i} - \bar{\theta}^* \right)^2, \quad \bar{\theta}^* = \frac{1}{B} \sum_{i=1}^B \hat{\theta}^{*i}.$$

Ước lượng bootstrap cho sai số của dự đoán (supervised classification)

Bối cảnh:

- Xét $\mathcal{L} = \{(X_1, Y_1), \dots, (X_L, Y_L)\}$ các cặp biến i.i.d có phân phối $\mathbb{P}$ trên $\mathcal{X} \times \mathcal{Y}$ với $\mathcal{Y}$ hữu hạn. Ta gọi mẫu này là **learning sample**.
- $r : \mathcal{X} \rightarrow \mathcal{Y}$ là một **quy tắc phân loại** (ước lượng).
- Sai số của dự đoán theo quy tắc r là $\mathbb{P}(r(X) \neq Y)$. Ta ước lượng sai số này bởi sai số thực nghiệm của nó

$$\widehat{\text{Err}}(r) = \frac{1}{L} \sum_{i=1}^L \mathbb{1}_{\{r(X_i) \neq Y_i\}}.$$

- **Vấn đề:** nếu r được xây dựng từ learning sample và sai số của r cũng được ước lượng từ cùng một mẫu, ta có một ước lượng lạc quan (chệch) cho sai số.

Ước lượng bootstrap cho sai số của dự đoán (supervised classification)

Một số cách xử lý:

- Kiểm tra chéo (Cross-Validation).
- Dùng bootstrap để giảm độ chệch cho ước lượng của sai số: với mỗi $1 \leq b \leq B$, ta rút một mẫu bootstrap $\mathcal{L}^b = \{(X_1^b, Y_1^b), \dots, (X_L^b, Y_L^b)\}$, ta xây dựng r^b trên $\mathcal{L}^b$ và tính

- ▶ $\widehat{\text{Err}}_{\mathcal{L}^b}(r^b)$ là sai số thực nghiệm được tính trên $\mathcal{L}^b$,
- ▶ $\widehat{\text{Err}}_{\mathcal{L}}(r^b)$ là sai số thực nghiệm được tính trên $\mathcal{L}$,
- ▶ Ước lượng bootstrap của độ chệch

$$\widehat{\text{bias}}_{\text{boot}}(\text{Err}) = \frac{1}{B} \sum_{b=1}^B \left[\widehat{\text{Err}}_{\mathcal{L}^b}(r^b) - \widehat{\text{Err}}_{\mathcal{L}}(r^b) \right].$$

- ▶ Ước lượng bootstrap cho độ chệch đã giảm trừ

$$\widehat{\text{Err}}_{\text{boot}}(r) = \widehat{\text{Err}}(r) - \widehat{\text{bias}}_{\text{boot}}(\text{Err}).$$

- **Vấn đề:** ước lượng bootstrap cho độ chệch vẫn còn chệch (vì nó được tính trên learning sample).

Ước lượng bootstrap cho sai số của dự đoán (supervised classification)

Bootstrap 632 [Efron & Tibshirani (97)]:

- Với mỗi $1 \leq b \leq B$, ta rút một mẫu bootstrap $\mathcal{L}^b = \{(X_1^b, Y_1^b), \dots, (X_L^b, Y_L^b)\}$, ta xây dựng r^b trên $\mathcal{L}^b$ và tính sai số thực nghiệm $\widehat{\text{Err}}_{\mathcal{L} \setminus \mathcal{L}^b}(r^b)$ trên các biến của $\mathcal{L} \setminus \mathcal{L}^b$, sau đó

$$\epsilon_0 = \frac{1}{B} \sum_{b=1}^B \widehat{\text{Err}}_{\mathcal{L} \setminus \mathcal{L}^b}(r^b),$$

$$\widehat{\text{Err}}_{\text{boot.632}}(r) = 0.368 \widehat{\text{Err}}(r) + 0.632 \epsilon_0.$$

- Tại sao là bootstrap 0.632:** ta có $0.632 \simeq 1 - 1/e =$ xác suất (khi $L \rightarrow +\infty$) mà một cặp biến (X_i, Y_i) của mẫu ban đầu có mặt trong mẫu bootstrap $(\mathbf{X}^b, \mathbf{Y}^b)$.
- Phương pháp này cho kết quả tốt hơn kiểm tra chéo.

Tài liệu tham khảo

- ① [Efron 79] B. Efron. Bootstrap methods : Another look at the jackknife. *Ann. Stat.*, 7 :1-26, 1979.
- ② [Efron & Tibshirani 97] B. Efron & R. Tibshirani. Improvements on Cross-Validation: The .632+ Bootstrap Method. *Journal of the American Statistical Association*, 92(438) :548-560, 1997.
- ③ [Quenouille 49] M.H. Quenouille. Approximate tests of correlation in time series. *Journal of the Royal Statistical Society, Series B*, 11 :18-44, 1949.
- ④ [Quenouille 56] M.H. Quenouille. Notes on bias in estimation. *Biometrika*, 43 :353-360, 1956.
- ⑤ [Tukey 58] J.W. Tukey. Bias and confidence in not quite large samples. *Annals of Mathematical Statistics.*, 29 :614, 1958.