

Bài giảng 1: Giới thiệu về Thống kê sinh học

TS. Tô Đức Khánh

Khoa Toán-Tin Học, ĐH Khoa Học Tự Nhiên, Tp. HCM

Học phần: Thống Kê Trong Sinh Học

Nội dung buổi học

1 Một số thông tin của học phần

2 Mở đầu

3 Ôn lại một số kiến thức cơ bản

Thông tin của môn học

Giảng viên:

TS. Tô Đức Khánh (tôi)

Bộ môn Xác suất-Thống kê, khoa Toán-Tin học

Trường Đại Học Khoa Học Tự Nhiên, Tp. HCM

e-mail: tdkhanh@hcmus.edu.vn

Phòng F.012, Trường Đại Học Khoa Học Tự Nhiên, 227 Nguyễn Văn Cừ,
Quận 5, Tp. Hồ Chí Minh.

Thông tin của môn học

Nội dung của môn học trong 14 tuần bao gồm:

- Bài toán thống kê sinh học, các cách lấy mẫu thông dụng;
- Các bài toán về ước lượng khoảng tin cậy;
- Các bài toán về kiểm định thống kê;
- Áp dụng mô hình hồi quy tuyến tính;
- Phân tích rủi ro và phân tích ROC;
- Giới thiệu mô hình hồi quy logistic và ứng dụng;
- Phân tích sống sót

Thực hành trên phần mềm R/Rstudio, với các thư viện: tidyverse, ggplot2, glm, survival, pROC.

Thông tin của môn học

Cấu trúc điểm:

- Điểm quá trình thực hành: 20%
- Điểm thi giữa kỳ: 20%
- Điểm báo cáo nhóm: 10%
- Điểm thi cuối kỳ: 50%

Nhóm:

Sinh viên được chia thành các nhóm nhỏ, mỗi nhóm gồm từ 4-6 sinh viên.

Hình thức thi

- Thi giữa kỳ: viết tự luận trong thời gian 90 phút.
- Thi cuối kỳ: làm đề tài/bài tập lớn theo nhóm.

Chú ý: Sinh viên cần phải tham gia ít nhất 80% số tiết học.

Tài liệu học tập và tài liệu tham khảo

- Slide bài giảng được cập nhật tại trang của môn học:
<https://courses.hcmus.edu.vn/course/view.php?id=3398>
- Motulsky, H. (2014). Intuitive biostatistics: a nonmathematical guide to statistical thinking. *Oxford University Press, USA*. **Tài liệu tham khảo.**
- Julien, J., & Hoffman, I. E. (2019). Basic Biostatistics for Medical and Biomedical Practitioners. *Academic Press*. **Tài liệu tham khảo.**
- Samuels, M. L., Witmer, J., & Schaffner, A. (2016). Statistics for the Life Sciences. *Pearson Education*. **Tài liệu tham khảo.**
- Hadley, W., & Garrett, G. R. (2017). R for data science: import, tidy, transform, visualize, and model data. *O'Reilly Media Inc.,*. **Tài liệu tham khảo.**

1 Một số thông tin của học phần

2 Mở đầu


3 Ôn lại một số kiến thức cơ bản

Thống kê trong sinh học?



$$Z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{p-value} = \Pr(|T| \geq t)$$




$$S_x = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$



$$T = \frac{\bar{x} - \mu_0}{S_x/\sqrt{n}} \xrightarrow{d} t_{n-1}$$

$$\left(\bar{x} - \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}, \bar{x} + \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}} \right)$$




Thống kê trong sinh học?

Thống kê (statistics) là một ngành khoa học của việc thu thập, phân tích, biểu diễn và giải thích dữ liệu, nhằm tìm ra các bằng chứng để củng cố hoặc bác bỏ các giả thuyết khoa học.

Thống kê trong sinh học?

Thống kê (statistics) là một ngành khoa học của việc thu thập, phân tích, biểu diễn và giải thích dữ liệu, nhằm tìm ra các bằng chứng để củng cố hoặc bác bỏ các giả thuyết khoa học.



Thống kê trong sinh học?

Thống kê sinh học (biostatistics) là một nhánh của thống kê, mà ở đó nghiên cứu và vận dụng các phương pháp thống kê tới một loạt các chủ đề trong sinh học: sinh học phân tử, sinh học di truyền, y sinh, y tế, nhằm đưa ra các luận điểm/bằng chứng có **ý nghĩa thống kê** để củng cố hay bác bỏ các giả định khoa học chưa được kiểm định.

Câu hỏi:

- Câu hỏi nghiên cứu là gì?
- Lập kế hoạch cho một nghiên cứu thống kê là gì?
- Ý nghĩa thống kê là gì? và tại sao ta phải sử dụng các phương pháp thống kê trong các vấn đề của sinh học?

Câu hỏi nghiên cứu là gì?

Một câu hỏi nghiên cứu là “một câu hỏi mà một dự án nghiên cứu đặt ra để trả lời”. Trong sinh học, câu hỏi nghiên cứu có thể là:

- sự khác biệt về hình thái giữa cua cái và cua đực, hay cua xanh và cam là gì?
- tại sao mức độ hoạt động của MAO (monoammino oxidase) lại khác nhau giữa các nhóm bệnh nhân tâm thần phân liệt?
- làm thế nào để phân loại các loài hoa iris dựa trên đặc điểm của chúng?
- có sự khác biệt nào giữa 3 loài chim cánh cụt: Adelie, Chinstrap và Gentoo?
- tỷ lệ 3:1 liệu có luôn luôn đúng trong di truyền?
- và nhiều hơn nữa ...

Ví dụ 1: *Monoamine oxidase (MAO)*

Monoamine oxidase (MAO) v.s. bệnh tâm thần phân liệt (schizophrenia)

Monoamine oxidase (MAO) là một loại enzyme được cho là có vai trò trong việc điều chỉnh hành vi của não bộ, đặc biệt, nồng độ MAO có thể liên quan tới các tình trạng của bệnh tâm thần phân liệt (schizophrenia)¹.

- Câu hỏi nghiên cứu: MAO có liên quan tới tình trạng của bệnh nhân tâm thần phân liệt?
- Đối tượng nghiên cứu: bệnh nhân tâm thần phân liệt với các tình trạng khác nhau.
- Khoanh vùng đối tượng: Bệnh nhân tâm thần phân liệt tại một khu vực sinh sống nhất định.
- Biến cần quan sát:
 - nồng độ MAO của bệnh nhân tâm thần phân liệt;
 - tình trạng bệnh;
 - độ tuổi;
 - giới tính.
- Các thức lấy mẫu: quan sát thu thập dữ liệu thực tế.

¹[N Engl J Med 1978; 298:61-66]

Ví dụ 3: thằn lằn sừng

Chiều dài sừng của thằn lằn có giúp chúng thoát chết?




- Câu hỏi nghiên cứu: ???
- Đối tượng nghiên cứu: ???
- Khoanh vùng đối tượng: ???
- Biến cần quan sát: ???
- Các thức lấy mẫu: ???

Ý nghĩa thống kê?

So sánh sự khác biệt nồng độ của MAO trong tiểu cầu của 42 bệnh nhân mắc 3 loại bệnh tâm thần phân liệt:

- I - Tâm thần phân liệt không phân biệt mãn tính - chronic undifferentiated schizophrenia (18)
- II - Không phân biệt với các đặc điểm hoang tưởng - undifferentiated with paranoid features (16)
- III - Bệnh tâm thần phân liệt hoang tưởng - paranoid schizophrenia (8)



Ý nghĩa thống kê?


- Nồng độ MAO trong nhóm I, cao hơn rõ rệt (khoảng 50% số bệnh nhân trong nhóm I) so với nhóm II và III.
- Giữa nhóm II và III, sự khác biệt là không thực sự rõ ràng.
- Có vẻ như nồng độ thấp MAO có liên quan tới tình trạng bệnh II và III.

Vấn đề:

- Các kết luận trên có phải do **may mắn**???
- Mối liên hệ giữa MAO và tình trạng của bệnh tâm thần phân liệt có thực sự tồn tại thật???

Ý nghĩa thống kê?

Kết quả phân tích ANOVA và TukeyHSD (p -value).



Ý nghĩa thống kê?

Một cách *bản năng*, so sánh p -value với một mức ý nghĩa (*significance level*), chẳng hạn 0.05, ta dễ dàng đưa ra một số nhận định thống kê như sau:

- Một cách tổng thể, sự khác biệt nồng độ MAO trong ba nhóm bệnh là có **ý nghĩa thống kê**.
- Sự khác biệt về nồng độ MAO giữa nhóm I và II, và giữa nhóm I và III là có **ý nghĩa thống kê**.
- Không tìm thấy **ý nghĩa thống kê** trong so sánh nồng độ MAO giữa nhóm II và III.

1 Một số thông tin của học phần


2 Mở đầu

3 Ôn lại một số kiến thức cơ bản

Dữ liệu thống kê là gì?

- Một dữ liệu thống kê là một bộ *mẫu ngẫu nhiên* của các *đối tượng nghiên cứu*, nó bao gồm các thông tin mô tả *tính chất của các đối tượng nghiên cứu*.
- Một bộ dữ liệu thống kê có thể được thu được thông qua việc quan sát và thu mẫu thực tế (*observations*), hoặc thu mẫu các đối tượng trong phòng thí nghiệm *experiments*.
- Một quần thể (*population*) là bộ dữ liệu lớn bao gồm tất cả đối tượng nghiên cứu có thể được bao hàm trong câu hỏi nghiên cứu.
- Chú ý: một đối tượng nghiên cứu được coi là một đơn vị thống kê (*statistical unit*).

Dữ liệu thống kê là gì?



Dữ liệu thống kê là gì?

Characteristics of a iris flower

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa

Number of iris flowers




- Câu hỏi nghiên cứu: Làm thế nào phân loại 3 loài hoa diên vĩ (iris): setosa, versicolor và virginica, dựa vào các số đo của chiều dài đài hoa (sepal), chiều rộng đài hoa, chiều dài cánh hoa (petal) và chiều rộng cánh hoa?
- Đối tượng nghiên cứu: hoa diên vĩ thuộc 3 loài: setosa, versicolor, và virginica.
- Quần thể: Tất cả các hoa diên vĩ trên thế giới, với khoảng 310 loài đã được ghi nhận.
- Dữ liệu: một mẫu gồm 150 hoa diên vĩ của 3 loài: setosa, versicolor, and virginica.

Biến ngẫu nhiên là gì?

Biến ngẫu nhiên

Trong thống kê, một tính chất của đối tượng nghiên cứu thường được gán bởi một biến ngẫu nhiên (*random variable*).





Biến ngẫu nhiên là gì?

Câu hỏi: phân loại dạng biến ngẫu nhiên

- Các cách thức truyền nhiễm bệnh.
- Giới tính sinh học của một người.
- Chiều cao của một người.
- Độ tuổi chết của một người.
- Các nhóm tính trạng bệnh của bệnh ung thư phổi.
- Lượng thuốc lá tiêu thụ trong một ngày.

Kỹ thuật phân tích thống kê

Thống kê mô tả (*descriptive statistics*) là tổ hợp các kỹ thuật để tổ chức, mô tả, tổng hợp và trình bày dữ liệu hoặc thông tin của dữ liệu theo cách thuận tiện cho việc hiểu và sử dụng.



Kỹ thuật phân tích thống kê

Thống kê suy luận (inferential statistics) là tổ hợp các phương pháp thống kê dùng để đưa ra các kết luận và suy luận về tính chất của quần thể đối tượng dựa trên thông tin của dữ liệu.




- Khoảng tin cậy cho trung bình quần thể.
- Kiểm định giả thuyết.
- So sánh nhiều nhóm trong một quần thể.
- Dự đoán xu hướng.

Kỹ thuật phân tích thống kê

Mô hình thống kê (statistical model) là một dạng phân tích thống kê dựa trên một mô hình toán cụ thể cho dữ liệu. Mô hình thống kê thường được dùng để mô tả sự biến động của một (hoặc nhiều) biến dựa trên giá trị của một hay nhiều biến khác. Khi phân tích mô hình thống kê, ta thường phải sử dụng một số phương pháp thống kê mô tả và thống kê suy luận.


- Mô hình hồi quy tuyến tính.
- Mô hình hồi quy logistic.
- Mô hình hồi quy phân vị (quantile regression model).
- Mô hình chuỗi thời gian.
- Mô hình sống sót.

Kỹ thuật phân tích thống kê




Kỹ thuật lấy mẫu ngẫu nhiên

Lấy mẫu ngẫu nhiên đơn giản (*simple random sampling*) là một cách lấy mẫu ngẫu nhiên mà trong đó, ta chọn ngẫu nhiên n đối tượng từ quần thể sao cho mỗi đối tượng một lần với xác suất được chọn là như nhau, các đối tượng là độc lập nhau.




Kỹ thuật lấy mẫu ngẫu nhiên

Lấy mẫu ngẫu nhiên theo cụm (*random cluster sample*) là một cách lấy mẫu ngẫu nhiên mà trong đó, ta sẽ chọn ngẫu nhiên **toàn bộ** thành viên trong một nhóm thay vì chỉ định một thành viên duy nhất.



Kỹ thuật lấy mẫu ngẫu nhiên

Lấy mẫu ngẫu nhiên phân tầng (*stratified random sample*) một mẫu ngẫu nhiên phân tầng được chọn bằng cách trước tiên chia quần thể thành các tầng, tức là tập hợp các cá thể đồng nhất. Sau đó, nhiều mẫu ngẫu nhiên đơn giản được lấy - một mẫu trong mỗi tầng - và kết hợp lại để tạo thành mẫu.



Một số chủ đề thảo luận cho tuần sau:

- p -value là gì? sử dụng như thế nào cho hợp lý.
- Một số ví dụ cho các cách lấy mẫu ngẫu nhiên.