

Bài giảng 4: Kiểm định cho biến định tính

TS. Tô Đức Khánh

Khoa Toán-Tin Học, ĐH Khoa Học Tự Nhiên
Đại học Quốc Gia Tp. HCM

Học phần: Thống Kê Trong Sinh Học

1 Lý thuyết thống kê cho biến định tính

2 Kiểm định một tỷ lệ

3 Kiểm định nhiều tỷ lệ

4 Mối liên hệ giữa hai biến định tính

Biến định tính và chuyển đổi số

Biến định tính X là một biến miêu tả các đặc tính hoặc tính chất không thể cân-đong-đo-đếm của một đối tượng:

- giới tính,
- màu sắc,
- nhóm thể loại,
- trạng thái bệnh,
- tình trạng hút thuốc.

Thông thường, dữ liệu quan sát của biến định tính được ghi nhận dưới dạng chữ, thay vì số

	Pain	Treatment	Age	Gender	Duration
1	eased	Treated	76	M	36
2	notEased	Treated	52	M	22
3	notEased	NotTreated	80	F	33
4	notEased	Treated	77	M	33
5	notEased	Treated	73	F	17
6	notEased	NotTreated	82	F	84

Biến định tính và chuyển đổi số

Tổng quát, khi biến định tính X có k tính chất ($k > 2$), ta sẽ đặt một tính chất tương ứng là một biến Bernoulli:

X	D_1	D_2	$\dots$	D_{k-1}	D_k
tính chất 1	1	0	$\dots$	0	0
tính chất 2	0	1	$\dots$	0	0
$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\vdots$
tính chất $k - 1$	0	0	$\dots$	1	0
tính chất k	0	0	$\dots$	0	1

$\Rightarrow X$ tương đương một vectơ ngẫu nhiên Bernoulli k chiều, $(D_1, D_2, \dots, D_k)^\top$:

- vectơ xác suất thành công $(p_1, p_2, \dots, p_k)$,
- $p_1 + p_2 + \dots + p_k = 1$;
- vectơ $(D_1, D_2, \dots, D_k)^\top \sim \text{Multi}(1, (p_1, p_2, \dots, p_k))$, phân phối đa thức.

Biến định tính và chuyển đổi số

Giả sử rằng, ta có một mẫu ngẫu nhiên của X với n quan sát, $X_1, X_2, \dots, X_n$. Khi đó, ta có ma trận kết quả cỡ $n \times k$ tương ứng biểu diễn vectơ ngẫu nhiên Bernoulli k chiều:

$$\begin{pmatrix} D_{11} & D_{12} & \dots & D_{1k} \\ D_{21} & D_{22} & \dots & D_{2k} \\ \vdots & \vdots & \dots & \vdots \\ D_{n1} & D_{n2} & \dots & D_{nk} \end{pmatrix}$$

trong đó,

$$D_{ij} = \begin{cases} 1, & \text{tính chất } j, \\ 0, & \text{tính chất khác,} \end{cases}$$

với $i = 1, \dots, n$ và $j = 1, \dots, k$. Đặt $Y_j = \sum_{i=1}^n D_{ij}$, khi đó,

- Y_j là tổng số lượng đối tượng có tính chất j , và
- $Y_j \sim B(n, p_j)$ - phân phối nhị thức,
- $\sum Y_j = n$,
- vectơ $(Y_1, Y_2, \dots, Y_k)^\top \sim \text{Multi}(n, (p_1, p_2, \dots, p_k))$, phân phối đa thức.

Phân phối đa thức

Xét vectơ k chiều $Y = (Y_1, Y_2, \dots, Y_k)^T$ sao cho:

- $Y_j \sim B(n, p_j)$;
- $\sum p_j = 1$;
- $\sum Y_j = n$.

Khi đó, ta nói $Y \sim \text{Multi}(n, (p_1, p_2, \dots, p_k))$, hàm xác suất

$$f(y_1, y_2, \dots, y_k; n, p_1, p_2, \dots, p_k) = \frac{n!}{y_1! y_2! \dots y_k!} p_1^{y_1} p_2^{y_2} \dots p_k^{y_k}.$$

Tính chất:

- vectơ trung bình $\mathbb{E}(Y) = (np_1, np_2, \dots, np_k)^\top$;
- $\text{Var}(Y_j) = np_j(1 - p_j)$;
- $\text{Cov}(Y_j, Y_r) = -np_j p_r$;
- ma trận hiệp phương sai:

$$\Omega = \begin{pmatrix} np_1(1-p_1) & -np_1p_2 & \dots & -np_1p_k \\ -np_1p_2 & np_2(1-p_2) & \dots & -np_2p_k \\ \vdots & \vdots & \ddots & \vdots \\ -np_1p_k & -np_2p_k & \dots & np_k(1-p_k) \end{pmatrix}$$

Phân phối đa thức

Ví dụ: Xét kết quả xuất hiện khi gieo một con xúc xắc 6 mặt, 30 lần. Trong mỗi lần tung:

- số chấm xuất hiện ở mặt trên là kết quả được ghi nhận: 1, 2, 3, 4, 5, 6;
- chỉ 1 trong 6 kết quả (tính chất) có thể xuất hiện;
- xác suất 1 kết quả xuất hiện là $1/6$.

Kết quả trong 30 lần có thể là

Lần tung	Số chấm	D_1	D_2	D_3	D_4	D_5	D_6
1	1	1	0	0	0	0	0
2	3	0	0	1	0	0	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
29	4	0	0	0	1	0	0
30	6	0	0	0	0	0	1

Đặt $Y_j = \sum_{i=1}^{30} D_{ij}$ là tổng số lần mặt j xuất hiện trong 30 lần, khi đó

$$(Y_1, Y_2, Y_3, Y_4, Y_5, Y_6)^T \sim \text{Multi}(30, (1/6, 1/6, 1/6, 1/6, 1/6, 1/6))$$

Ước lượng p và phân phối tiệm cận

Xét trường hợp X có 2 tính chất, trong đó,

- tính chất 2 được quan tâm,
- xác suất xảy ra là p .

Khi đó, với một mẫu ngẫu nhiên $X_1, X_2, \dots, X_n$, độc lập cùng phân phối Bernoulli, $B(p)$, thì bằng phương pháp hợp lý cực đại, ta suy ra một ước lượng không chệch cho p là

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

Áp dụng định lý giới hạn trung tâm cho dãy biến ngẫu nhiên $X_1, X_2, \dots, X_n$:

$$\frac{\sum X_i - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1),$$


khi $n \rightarrow \infty$. Tương đương với

$$\sqrt{n} \left(\frac{Y}{n} - p \right) \xrightarrow{d} N(0, p(1-p)),$$

khi $n \rightarrow \infty$ (hay theo quy tắc thực nghiệm: $np \geq 5$ và $n(1 - p) \geq 5$).

Ước lượng p và phân phối tiệm cận

$$X_i \sim B(0.2)$$



Ước lượng p_i và phân phối tiệm cận

Xét trường hợp X có k tính chất với xác suất xảy ra p_k .

Giả sử rằng, ta có một mẫu ngẫu nhiên của X với n quan sát, $X_1, X_2, \dots, X_n$.

Đặt Y_j là tổng số lần tính chất j (với $j = 1, \dots, k$) xuất hiện trong n quan sát:

- $(Y_1, Y_2, \dots, Y_k)^\top \sim \text{Multi}(n, (p_1, p_2, \dots, p_k))$;
- $p_1 + p_2 + \dots + p_k = 1$.

Áp dụng phương pháp hợp lý cực đại và ràng buộc $p_1 + p_2 + \dots + p_k = 1$, ta tìm ước lượng cho p_i bằng phương pháp Lagrange:

- hàm log-hợp lý

$$\ell(p_1, p_2, \dots, p_k) = \log \left(\frac{n!}{y_1! y_2! \dots y_k!} \right) + \sum_{i=1}^k y_i \log(p_i)$$

- hàm mục tiêu Lagrange

$$L(p_1, p_2, \dots, p_k; \lambda) = \ell(p_1, p_2, \dots, p_k) + \lambda \left(1 - \sum_{j=1}^k p_j \right)$$

Ước lượng p_i và phân phối tiệm cận

Thực hiện lấy đạo hàm từng tham số, ta có phương trình đạo hàm

$$\frac{\partial L}{\partial p_j} = \frac{y_j}{p_j} - \lambda = 0,$$

$$\frac{\partial L}{\partial \lambda} = 1 - \sum_{j=1}^k p_j = 0.$$

Giải phương trình đầu, ta thu được $p_j = \frac{y_j}{\lambda}$. Thế vào phương trình thứ hai, ta có

$$1 - \sum_{j=1}^k \frac{y_j}{\lambda} = 0$$

suỵ ra $\lambda = n$. Do đó, ta có $\hat{p}_j = \frac{y_j}{n}$.

Tổng quát, ta có ước lượng

$$\hat{p}_j = \frac{Y_j}{n},$$

với $j = 1, 2, \dots, k$, và là ước lượng không chệch.

Ước lượng p_j và phân phối tiệm cận

Định lý giới hạn trung tâm (GHTT) nhiều chiều

Xét $X_n = (X_{n,1}, X_{n,2}, \dots, X_{n,k})^\top$ là một chuỗi của các vectơ độc lập cùng phân phối với vectơ trung bình $\mu = (\mu_1, \mu_2, \dots, \mu_k)^\top$ và ma trận hiệp phương sai Σ .

Đặt $S_{n,j} = \sum_{i=1}^n X_{i,j}$. Thì

$$\sqrt{n} \begin{pmatrix} \frac{S_{n,1}}{n} - \mu_1 \\ \vdots \\ \frac{S_{n,k}}{n} - \mu_k \end{pmatrix} \xrightarrow{d} N(0, \Sigma)$$

Ước lượng p_j và phân phối tiệm cận

Ta áp dụng định lý này cho dãy $D_n = (D_{n1}, D_{n2}, \dots, D_{nk})^\top$ độc lập cùng phân phối đa thức:

- $(D_{n1}, D_{n2}, \dots, D_{nk})^\top \sim \text{Multi}(1, (p_1, p_2, \dots, p_k));$
- vectơ trung bình $\mu = (p_1, p_2, \dots, p_k)^\top;$
- ma trận hiệp phương sai:

$$\Sigma = \begin{pmatrix} p_1(1-p_1) & -p_1p_2 & \dots & -p_1p_k \\ -p_1p_2 & p_2(1-p_2) & \dots & -p_2p_k \\ \vdots & \vdots & \ddots & \vdots \\ -p_1p_k & -p_2p_k & \dots & p_k(1-p_k) \end{pmatrix}$$

tuy nhiên, ma trận này có hạng $k-1$, do dòng cuối cùng là tổ hợp của $k-1$ dòng trên.

Do đó, ta áp dụng định lý GHTT nhiều chiều cho $(D_{n1}, D_{n2}, \dots, D_{nk-1})^\top$

Ước lượng p_j và phân phối tiệm cận

- vectơ trung bình $\mu = (p_1, p_2, \dots, p_{k-1})^\top$;
- ma trận hiệp phương sai:

$$\Sigma = \begin{pmatrix} p_1(1-p_1) & -p_1p_2 & \dots & -p_1p_{k-1} \\ -p_1p_2 & p_2(1-p_2) & \dots & -p_2p_{k-1} \\ \vdots & \vdots & \ddots & \vdots \\ -p_1p_{k-1} & -p_2p_{k-1} & \dots & p_{k-1}(1-p_{k-1}) \end{pmatrix}$$

Ta có kết quả

$$\sqrt{n} \begin{pmatrix} \frac{Y_1}{n} - p_1 \\ \vdots \\ \frac{Y_{k-1}}{n} - p_{k-1} \end{pmatrix} \xrightarrow{d} N(0, \Sigma)$$

Từ kết quả này, ta suy ra được

$$nV_n^\top \Sigma^{-1} V_n \xrightarrow{d} \chi_{k-1}^2$$

khi $n \rightarrow \infty$, trong đó $V_n = \left(\frac{Y_1}{n} - p_1, \dots, \frac{Y_{k-1}}{n} - p_{k-1} \right)^\top$.

Ước lượng p_j và phân phối tiệm cận

Ngoài ra, ta còn chứng minh được

$$\Sigma^{-1} = \begin{pmatrix} \frac{1}{p_1} + \frac{1}{p_k} & \frac{1}{p_k} & \cdots & \frac{1}{p_k} \\ \frac{1}{p_k} & \frac{1}{p_2} + \frac{1}{p_k} & \cdots & \frac{1}{p_k} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{p_k} & \frac{1}{p_k} & \cdots & \frac{1}{p_{k-1}} + \frac{1}{p_k} \end{pmatrix}$$

và

$$nV_n^\top \Sigma^{-1} V_n = \sum_{j=1}^k \frac{(Y_j - np_j)^2}{np_j}$$


Do đó,

$$\sum_{j=1}^k \frac{(Y_j - np_j)^2}{np_j} \xrightarrow{d} \chi_{k-1}^2$$

Kết quả này sẽ được dùng ở phần sau.

Ước lượng p_j và phân phối tiệm cận

- $(D_{i1}, D_{i2}, D_{i3}, D_{i4}, D_{i5})^\top \sim \text{Multi}(1, (0.2, 0.3, 0.2, 0.2, 0.1))$,
- so sánh với χ^2_4 .



Lý thuyết thống kê cho biến định tính
○○○○○

Kiểm định một tỷ lệ
●○○○

Kiểm định nhiều tỷ lệ
○○○○

Mối liên hệ giữa hai biến định tính
○○○○○○○

1 Lý thuyết thống kê cho biến định tính

2 Kiểm định một tỷ lệ

3 Kiểm định nhiều tỷ lệ

4 Mối liên hệ giữa hai biến định tính

Thí nghiệm của Mendel

Đặt

- G là ký hiệu cho gen trội, tạo hạt màu xanh lá,
- y là ký hiệu cho gen lặn, tạo hạt màu vàng.

Theo lý thuyết (tổ hợp), ta thu được

- 1 cặp gen di truyền F1: Gy
- 4 cặp gen di truyền F2: GG, Gy, Gy, yy

Như vậy, ở đời F2, tỷ lệ lý thuyết có hạt màu xanh lá là $p_0 = 0.75$.

Gọi Y là số cây có hạt màu xanh lá trong số n cây thế hệ F2, thì


$$Y \sim B(n, p)$$

với p là không biết trước.

Theo lý thuyết, p có thể là 0.75.


Tương ứng với dữ liệu, $n = 60$.

Thí nghiệm của Mendel



Điểm màu đỏ là giá trị quan sát được trong mẫu, 42 cây.

Thí nghiệm của Mendel



Nếu $p = 0.75$ thực sự là đúng, thì khi ta lặp lại thí nghiệm với số lượng cây 60, số cây có hạt màu xanh lá quan sát được là từ 37 tới 53 (xác suất khoảng 98.93%).

Tất nhiên, là ta không thể lặp lại nhiều thí nghiệm (yếu tố thời gian).

Thí nghiệm của Mendel

Ta sử dụng kết quả từ thí nghiệm này để tìm kiếm sự ủng hộ cho kết quả lý thuyết của Mendel.

- Từ dữ liệu, ta tính được

$$\hat{p} = \frac{42}{60} = 0.7$$


- Dễ thấy ước lượng này khác 0.75

Câu hỏi: Kết quả thí nghiệm có ủng hộ lý thuyết của Mendel?

Ta cần kiểm định giả thuyết


$$\begin{cases} H_0 : p = 0.75 \\ H_1 : p \neq 0.75 \end{cases}$$

Kiểm định nhị thức



Kiểm định nhị thức


■ xa hơn về phía phải: ???



Các điểm xa hơn về bên phải của $np_0 = 45$, so với giá trị quan sát $Y_{\text{obs}} = 42$ có thể là các giá trị bắt đầu từ:

- 47, hoặc
- 48, hay 50, ...

Kiểm định nhị thức




Kiểm định nhị thức

Như vậy, ta tính


$$p\text{-value} = \sum_{x \in B} C_n^x p_0^x (1 - p_0)^{n-x},$$

với $B = \{x : \Pr(Y = x) \leq \Pr(Y = Y_{\text{obs}})\}$, dưới giả định H_0 đúng.



Kiểm định nhị thức

- $n = 60$
- $p_0 = 0.75$
- $Y_{\text{obs}} = 38$



Kiểm định nhị thức

Từ kết quả này, ta có thể kết luận rằng:

Thí nghiệm không cung cấp đủ bằng chứng để có thể hoài nghi về tỷ lệ lý thuyết 3:1 của Mendel.

Ta có thể giải thích giá trị p -value như sau:

Nếu ta lặp lại thí nghiệm này 1000 lần, với cùng cỡ mẫu 60, thì sẽ có khoảng 372 mẫu có số lượng cây đậu hạt xanh lá là lớn hơn so với 49 hoặc bé hơn 42, với tỷ lệ lý thuyết của Mendel.

Hay:

Nếu ta lặp lại thí nghiệm này 1000 lần, với cùng cỡ mẫu 60, thì sẽ có khoảng 372 mẫu có số lượng cây đậu hạt xanh lá ủng hộ cho tỷ lệ lý thuyết 3:1 của Mendel.

Kiểm định nhị thức

Một số nhận xét:

- Kiểm định nhị thức - binomial test, được gọi là một kiểm định chính xác, *exact test*, bởi nó dựa trên phân phối chính xác của biến ngẫu nhiên, trong trường hợp này là phân phối nhị thức.
- Nếu kiểm định một phía bên trái, $H_0 : p = p_0$ v.s. $H_1 : p < p_0$, thì

$$p\text{-value} = \sum_{x=0}^{Y_{\text{obs}}} C_n^x p_0^x (1 - p_0)^{n-x}.$$

- Nếu kiểm định một phía bên phải, $H_0 : p = p_0$ v.s. $H_1 : p > p_0$, thì

$$p\text{-value} = \sum_{x=Y_{\text{obs}}}^n C_n^x p_0^x (1 - p_0)^{n-x}.$$

- Thay vì sử dụng kiểm định nhị thức, ta có thể sử dụng xấp xỉ phân phối chuẩn

$$\sqrt{n} \left(\frac{Y}{n} - p \right) \xrightarrow{d} N(0, p(1 - p)),$$

khi $n \rightarrow \infty$, để thực hiện một kiểm định z .

Tuy nhiên, xấp xỉ này chỉ tốt trong các trường hợp n lớn hoặc theo quy tắc thực nghiệm: $np_0 \geq 5$ và $n(1 - p_0) \geq 5$.

Kiểm định Chi-bình phương goodness-of-fit

Kết hợp kết quả quan sát và quan sát kỳ vọng, ta có bảng sau:

tính chất	quan sát	kỳ vọng
1	Y_1	E_1
2	Y_2	E_2
$\vdots$	$\vdots$	$\vdots$
k	Y_k	E_k

Nếu tỷ lệ lý thuyết $(p_{10}, p_{20}, \dots, p_{k0})^\top$ là hợp lý, tức là

$$H_0 : p_1 = p_{10}, p_2 = p_{20}, \dots, p_k = p_{k0}$$

là đúng, thì các giá trị quan sát Y_j sẽ gần bằng các giá trị kỳ vọng E_j .

Kiểm định goodness-of-fit

Việc thực hiện kiểm định so sánh các giá trị quan sát với các giá trị kỳ vọng (lý thuyết) được gọi là một kiểm định **goodness-of-fit** (*goodness-of-fit test*).

Kiểm định Chi-bình phương goodness-of-fit

Khi giả thuyết H_0 đúng, ta có

$$(Y_1, Y_2, \dots, Y_k)^T \sim \text{Multi}(n, (p_{10}, p_{20}, \dots, p_{k0}))$$

Khi đó, theo kết quả lý thuyết của vectơ ngẫu nhiên đa thức, ta có

$$Q = \sum_{j=1}^k \frac{(Y_j - E_j)^2}{E_j} = \sum_{j=1}^k \frac{(Y_j - np_{j0})^2}{np_{j0}} \xrightarrow{d} \chi_{k-1}^2,$$

khi $n \rightarrow \infty$.

Thống kê Q được gọi là thống kê Pearson (*Pearson's chi-squared test statistic*).

Khi H_0 đúng, giá trị quan sát w của Q sẽ nhỏ, và gần 0.

Kiểm định Chi-bình phương goodness-of-fit

Ví dụ 2: Các nhà di truyền học nghiên cứu mô hình di truyền của cây đậu đũa đã phân loại cây này trong một thí nghiệm tùy theo tính chất của lá của chúng. Dữ liệu theo sau¹:

Loại	I	II	III
Số lượng	179	44	23

Các loại I, II và III được tác giả xác định là *trifoliolate*, *trifoliolate orbicular* và *unifoliolate orbicular*.

Tỷ lệ lý thuyết cho mỗi loại lần lượt là 12/16, 3/16, và 1/16.

Giả thuyết H_0 là

$$H_0 : p_I = 12/16, p_{II} = 3/16, p_{III} = 1/16$$

Đối thuyết H_1 : không phải H_0 .

¹Fawole, (2001), <https://doi.org/10.1093/jhe000092.1.43>


Kiểm định Chi-bình phương goodness-of-fit

Dưới giả thuyết H_0 , ta tính được

Loại	I	II	III
Số lượng	179	44	23
Kỳ vọng	184.5	46.125	15.375

Do đó, ta xác định được:

$$\sum_{j=1}^3 \frac{(Y_j - E_j)^2}{E_j} = \frac{(179 - 184.5)^2}{184.5} + \frac{(44 - 46.125)^2}{46.125} + \frac{(23 - 15.375)^2}{15.375} = 4.0434$$



Kiểm định Chi-bình phương goodness-of-fit

Với dữ liệu được quan sát, chúng ta có thể thu được giá trị quan sát w của thống kê Q .

Nhắc lại định nghĩa p -value

p -value là xác suất thu được một kết quả thí nghiệm (dữ liệu) xa hoặc càng xa giả thuyết H_0 so với kết quả quan sát được, dưới giả định H_0 là đúng.

Nếu H_0 là đúng thì:

- $Y_{j,\text{obs}}$ gần bằng $E_j = np_0$, hay w sẽ gần bằng 0,
- $Q \sim \chi_{k-1}^2$.


↪ “xa hoặc càng xa giả thuyết H_0 ” có nghĩa là càng xa 0 về bên phải (do tính chất của phân phối χ^2).

Kiểm định Chi-bình phương goodness-of-fit

Như vậy, p -value của kiểm định Chi-bình phương goodness-of-fit:

$$p\text{-value} = \Pr(Q > w),$$

tức là xác suất ở đuôi bên phải của phân phối χ^2_{k-1} .



Bảng tổng hợp - Contingency table

Bảng tổng hợp - Contingency table

Bảng tổng hợp (contingency table hay two-way table) là bảng hai chiều tóm tắt tần suất quan sát được của hai biến định tính.

Ví dụ 3: Bảng tổng hợp dưới đây là một ví dụ về contingency table của màu tóc (X) và màu mắt (Y) của 6800 nam giới Đức.

		Màu tóc			
		Nâu	Đen	Vàng nhạt	Đỏ
Màu mắt	Nâu	438	288	115	16
	Xám hoặc Xanh lá	1387	746	946	53
	Xanh dương	807	189	1768	47

Bảng tổng hợp này được sắp xếp thành 3 dòng (số quan sát của màu mắt) và 4 cột (số quan sát của màu tóc).

Giao điểm của một hàng và một cột được gọi là **ô** và nó thể hiện số lượng đối tượng thuộc loại j của biến X (cột j) và loại k của biến Y (dòng k).

Bảng tổng hợp - Contingency table

Tiếp theo, ta sẽ cố định các dòng, khi đó các tần số được tô đậm là

		Màu tóc			
		Nâu	Đen	Vàng nhạt	Đỏ
Màu mắt	Nâu	438	288	115	16
	Xám hoặc Xanh lá	1387	746	946	53
	Xanh dương	807	189	1768	47


Ví dụ, xét hàng đầu tiên của màu mắt, tức là mắt nâu, ta có thể thấy số lượng người có tóc màu nâu là cao nhất, tiếp đến là tóc đen.

Ở dòng thứ hai, tức là màu xám hoặc xanh lá, ta thấy tóc màu nâu là màu phổ biến nhất, tiếp đến là tóc màu vàng nhạt.

Số người có tóc màu đỏ luôn luôn ít nhất trong mọi trường hợp của màu mắt.

Bảng tổng hợp - Contingency table

Khi ta cố định cột (màu tóc), khi đó ta có thể tính được tỷ lệ màu mắt (theo công thức xác suất điều kiện), và biểu diễn theo biểu đồ cột dưới đây.



Bảng tổng hợp - Contingency table

Dựa vào bảng tổng hợp, có thể nói rằng, đối với đàn ông Đức, màu tóc dường như gắn liền với màu mắt.

Đặc biệt, chúng ta có thể nói một số điều như:

- Đàn ông Đức tóc nâu có xu hướng sở hữu mắt màu xám hoặc xanh lá nhiều hơn.
- Đàn ông Đức mắt nâu thường để tóc màu nâu.
- Đàn ông Đức mắt xanh dương thường có mái tóc màu vàng nhạt.

Lưu ý rằng, với dữ liệu này, chúng ta chỉ có thể nói rằng “sự thay đổi của màu tóc **gắn liền với sự thay đổi** của màu mắt, hoặc ngược lại”.

Ta không thể nói rằng “sự thay đổi của màu tóc gây ra sự thay đổi của màu mắt”, bởi vì có một số yếu tố mà ta không thể kiểm soát nếu thu thập dữ liệu bằng cách quan sát.

Như vậy, nhìn chung, với nghiên cứu quan sát thực nghiệm, chúng ta chỉ có thể phát hiện được mối liên hệ giữa hai biến (định tính hoặc định lượng).

Kiểm định độc lập - Chi-square independent test

Kiểm định độc lập

Kiểm định độc lập (chi-square contingency test) (hay còn được gọi là also kiểm định độc lập - **chi-square independent test**) là kiểm định được sử dụng phổ biến nhất trong việc kiểm tra mối liên hệ giữa hai biến định tính.

Đối với kiểm định độc lập, các phát biểu về giả thuyết H_0 và đối thuyết H_1 có thể khác nhau tùy theo ngữ cảnh, nhưng chúng luôn có ý nghĩa sau:

H_0 : Hai biến định tính là độc lập (nghĩa là không có mối liên hệ nào giữa hai biến định tính).

H_1 : Hai biến định tính là **không** độc lập (nghĩa là có mối liên hệ giữa hai biến định tính là có ý nghĩa thống kê).

Đối với ví dụ 3, dữ liệu màu mắt và màu tóc của đàn ông Đức, ta có các giả thuyết như sau:

H_0 : Đàn ông Đức không có xu hướng nào trong màu tóc và màu mắt.

H_1 : Tồn tại một xu hướng nhất định trong màu tóc và màu mắt của đàn ông Đức.

Kiểm định độc lập - Chi-square independent test

Nhắc lại định nghĩa hai biến ngẫu nhiên độc lập

Ta biết rằng, hai biến cố A và B là độc lập khi và chỉ khi

$$\Pr(A \cap B) = \Pr(A) \Pr(B)$$

Hai biến ngẫu nhiên rời rạc X và Y được gọi là độc lập nếu và chỉ nếu

$$\Pr(X = i, Y = j) = \Pr(X = i) \Pr(Y = j),$$

với mọi i và j trong tập giá trị của X và Y , tương ứng.

Nhắc lại rằng hai biến định tính tương ứng là 2 biến đa thức thông qua phép đặt giả biến.

Kiểm định độc lập - Chi-square independent test

Theo bảng ta có

- trên mỗi cột, $\Pr(X = j) = \frac{c_j}{N}$,

- trên mỗi dòng, $\Pr(Y = i) = \frac{r_i}{N}$,

- $\Pr(X = j, Y = i) = \frac{n_{ij}}{N}$

Do đó, nếu H_0 là đúng thì:

$$\frac{n_{ij}}{N} \approx \frac{c_j}{N} \times \frac{r_i}{N}$$



Đặt

$$E_{ij} = \frac{r_i \times c_j}{N},$$

là tần số kỳ vọng của ô tương ứng dòng thứ i và cột thứ j trong bảng tổng hợp. Khi đó, nếu H_0 là đúng thì n_{ij} sẽ gần bằng E_{ij} .

Kiểm định độc lập - Chi-square independent test

Để hiểu hơn vì giả thuyết H_0 , ta so sánh biểu đồ của bảng quan sát và tần số kỳ vọng (dưới giả định H_0 là đúng).



Tỷ lệ màu mắt là không đổi trong các cột màu tóc.

Kiểm định độc lập - Chi-square independent test

Quay trở lại với ví dụ về màu mắt và màu tóc của đàn ông Đức.

- Ta tính được giá trị quan sát

$$w = \frac{(438 - 331.709)^2}{331.709} + \frac{(288 - 154.134)^2}{154.134} + \dots + \frac{(47 - 47.952)^2}{47.952} = 1073.5$$

- Thống kê Q_n tuân theo phân phối χ^2_6 (do $m = 3$ và $k = 4$).
- Giá trị p -value là rất nhỏ (nhỏ hơn 0.0001) $\Rightarrow$ ta bác bỏ H_0 tức là màu tóc của đàn ông Đức có liên quan đáng kể với sự thay đổi màu mắt của họ.

Một số chủ đề thêm

Kiểm định cho biến định tính chỉ là một phần nhỏ trong phân tích biến định tính (**Categorical Data Analysis**). Ta có một số chủ đề/bài toán khác:

- kiểm định goodness-of-fit khi dữ liệu thu thập trong khung thời gian/khoảng không gian ngẫu nhiên,
- mô hình log-linear cho bảng tần số,
- phân tích tương hợp (**correspondence analysis**),
- phân tích tỷ lệ rủi ro.