

Bài giảng 5: Phân tích sự tương quan của biến định lượng

TS. Tô Đức Khánh

Khoa Toán-Tin Học, ĐH Khoa Học Tự Nhiên
Đại học Quốc Gia Tp. HCM

Học phần: Thống Kê Trong Sinh Học

Nội dung buổi học

1 Mối quan hệ của biến định lượng

2 Hệ số tương quan tuyến tính

3 Hệ số tương quan hạng Spearman

1 Mối quan hệ của biến định lượng

2 Hệ số tương quan tuyến tính

3 Hệ số tương quan hạng Spearman

Mối quan hệ

Câu hỏi nghiên cứu về sự tương quan hay mối quan hệ giữa hai biến hay hai đặc tính của một đối tượng thường được quan tâm nhiều:

- màu tóc và màu mắt của đàn ông Đức có quan hệ với nhau?
- mức độ tiêu thụ thuốc lá liệu có ảnh hưởng tới khả năng mắc bệnh ung thư thực quản hay không?
- uống cà phê liệu có ảnh hưởng đến lưu lượng máu, đặc biệt là khi tập thể dục hay không?
- loại thức ăn khác nhau khiến trọng lượng của gà thay đổi như thế nào?
- nhịp tim có bị thay đổi theo giới tính và chế độ luyện tập thể dục hay không?

Mối quan hệ

Về mặt bản chất, khi xét mối quan hệ của hai biến, ta sẽ đặt:

- Y là biến được quan tâm chính, tức là biến phản hồi - *response variable*;
- X là biến được dùng để giải thích cho biến Y .

Khi đó, mối quan hệ của giữa X và Y nếu tồn tại, sẽ được giải thích là:

Sự thay đổi của X có quan hệ tới sự thay đổi của Y .

Ví dụ:

- **sự thay đổi** màu mắt của đàn ông Đức **có liên hệ với sự thay đổi** màu tóc của họ;
- mức độ tiêu thụ thuốc lá **có liên hệ tới** khả năng mắc bệnh ung thư thực quản;
- sự thay đổi nhịp tim **có quan hệ với** giới tính và chế độ luyện tập thể dục.

Mối quan hệ và sự độc lập

Nếu giữa X và Y không tồn tại bất kỳ mối quan hệ nào, thì có nghĩa là X và Y là độc lập nhau.

Sự không độc lập và mối quan hệ

Sự độc lập

Cho vectơ ngẫu nhiên (X, Y) xác định trên không gian $\mathcal{X} \times \mathcal{Y}$, với hàm phân phối tích lũy đồng thời F . Đặt F_X và F_Y lần lượt là hàm phân phối tích lũy lẻ của X và Y . Ta có hai kết quả sau.

- Hai biến ngẫu nhiên X và Y là độc lập nhau, nếu và chỉ nếu với mọi giá trị x, y :

$$F(x, y) = F_X(x)F_Y(y).$$

- Hai biến ngẫu nhiên X và Y là độc lập nhau, nếu và chỉ nếu với mọi hàm bị chặn $g_1 : \mathcal{X} \rightarrow \mathbb{R}$, và $g_2 : \mathcal{Y} \rightarrow \mathbb{R}$, sao cho

$$\mathbb{E}[g_1(X)g_2(Y)] = \mathbb{E}[g_1(X)]\mathbb{E}[g_2(Y)].$$

Sự không độc lập

Nếu X và Y là không độc lập, khi đó, với mọi x, y , ta có

$$F(x, y) = F_{Y|X}(y|x)F_X(x) = F_{X|Y}(x|y)F_Y(y).$$

Tức là, với một giá trị của X ta có thể suy ra luật phân phối cho Y (hoặc ngược lại). $\Rightarrow X$ và Y có quan hệ với nhau.

Sự không độc lập và mối quan hệ

Ta có một số loại phụ thuộc như sau:

- phụ thuộc tuyến tính;
- phụ thuộc phi tuyến tính;
- phụ thuộc nhân quả (causality);
- sự liên hệ.

Trong đó, phụ thuộc tuyến tính và phụ thuộc phi tuyến xuất hiện khi xét mối quan hệ giữa hai biến định lượng.

Đặc biệt, mối quan hệ giữa hai biến định lượng được gọi là **sự tương quan - correlation**.

Như vậy, sự tương quan là một dạng của sự phụ thuộc (hay mối quan hệ):

- tương quan tuyến tính;
- tương quan phi tuyến tính.


↪ ta có thể mô hình Y bởi $g(X)$, với g là một hàm tuyến tính hoặc phi tuyến.

Tương quan tuyến tính

Ví dụ 1: Quan sát biểu đồ phân tán miêu tả :

- trung bình trọng lượng cơ thể (kg) - trục x;
- trung bình trọng lượng não (g) - trục y


của 29 loài động vật.



Tương quan tuyến tính

Ví dụ 2: Quan sát biểu đồ phân tán miêu tả :

- hệ số ghép cặp cận huyết của sói - trục x ;
 - số lượng sói con sống sót qua mùa đông đầu tiên - trục y
- của 24 cặp sói quan sát tại Norway và Sweden, từ 1983 - 2002.



Tương quan tuyến tính

Ở ví dụ 1, ta nhận thấy:

- giá trị nhỏ của x tương ứng với giá trị nhỏ của y ;
- giá trị lớn của x tương ứng với giá trị lớn của y ;
- khi x tăng thì giá trị của y cũng có xu hướng tăng theo một đường thẳng.

Ở ví dụ 2, ta nhận thấy:

- giá trị nhỏ của x tương ứng với giá trị lớn của y ;
- giá trị lớn của x tương ứng với giá trị nhỏ của y ;
- khi x tăng thì giá trị của y cũng có xu hướng giảm theo một đường thẳng.

↪ sự tương quan như trong hai ví dụ trên được gọi là **tương quan tuyến tính** giữa hai biến định lượng.

Tương quan tuyến tính


Hai biến định lượng được gọi là có tương quan tuyến tính nếu các cặp giá trị quan sát của hai biến thể hiện một xu hướng tăng (hoặc giảm) tuyến tính, tức là theo một đường thẳng.

Tương quan phi tuyến

Ví dụ 3: Quan sát biểu đồ phân tán miêu tả :

- tỷ lệ bác sĩ trên 1000 dân - trục x ;
- tuổi thọ (năm) - trục y

của 175 quốc gia, tại thời điểm 2010.



Tương quan phi tuyến

Trong đồ thị của ví dụ 3, ta nhận thấy:

- giá trị nhỏ của x tương ứng với giá trị nhỏ của y ;
- giá trị lớn của x tương ứng với giá trị lớn của y ;
- khi x tăng thì giá trị của y cũng có xu hướng tăng theo một đường cong.


Tương quan phi tuyến tính

Hai biến định lượng được gọi là có tương quan phi tuyến tính nếu các cặp giá trị quan sát của hai biến thể hiện một xu hướng tăng (hoặc giảm) theo một hàm phi tuyến.

Về mặt toán học, ta có thể phân hàm phi tuyến ra làm hai loại:

- hàm đơn điệu (monotonic function) - ví dụ 3,
- hàm nghịch biến.

Tương quan phi tuyến



Do độ mạnh của tương quan

Sự tương quan giữa hai biến định lượng, có thể được đo độ mạnh trong một số trường hợp cụ thể:

- tương quan tuyến tính,
- tương quan phi tuyến đơn điệu.

Thăng đo độ mạnh của sự tương quan, được gọi là **hệ số tương quan - correlation coefficient**.

Có nhiều hệ số tương quan khác nhau đã được phát triển, mỗi loại tương ứng cho một trường hợp cụ thể:

- hệ số tương quan tuyến tính Pearson - **Pearson correlation coefficient**, dành cho tương quan tuyến tính,
- hệ số tương quan hạng Spearman - **Spearman's correlation coefficient**, dành cho tương quan phi tuyến đơn điệu.

1 Mối quan hệ của biến định lượng

2 Hệ số tương quan tuyến tính

3 Hệ số tương quan hạng Spearman

Hệ số tương quan tuyến tính Pearson

Hệ số tương quan tuyến tính Pearson




Hệ số tương quan tuyến tính Pearson - Pearson correlation coefficient là một hệ số dùng để đo độ mạnh của một tương quan tuyến tính giữa hai biến định lượng.

$$r = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.$$




Hệ số r có giá trị nằm trong $[-1, 1]$:

- nếu $-1 < r < 0$: tương quan tuyến tính giữa X và Y là tương quan nghịch, tức là X tăng thì Y giảm;
- nếu $0 < r < 1$: tương quan tuyến tính giữa X và Y là tương quan thuận, tức là X tăng thì Y tăng;
- nếu $r = 0$: tương quan tuyến tính giữa X và Y là không tồn tại;
- nếu $r = -1$: tương quan tuyến tính giữa X và Y là tương quan nghịch ngặt;
- nếu $r = 1$: tương quan tuyến tính giữa X và Y là tương quan thuận ngặt;




Hệ số tương quan tuyến tính Pearson



Hệ số tương quan tuyến tính Pearson




Hệ số tương quan tuyến tính Pearson




Cách hệ số tương quan tuyến tính hoạt động

Chú ý, phép đổi biến Z_X và Z_Y là tuyến tính, nên không thay đổi tính tương quan của X và Y .



Nếu X và Y có tương quan tuyến tính, các điểm dữ liệu z_x và z_y sẽ có xu hướng nằm thành 1 đường chéo đi qua gốc tọa độ (trung bình Z_X và Z_Y).

Cách hệ số tương quan tuyến tính hoạt động




Nếu đa phần các điểm nằm vào trong góc phần tư thứ I và thứ III, thì

$$Z_X Z_Y > 0,$$

với hầu hết dữ liệu quan sát, dẫn tới kết quả là $r > 0$. (Về mặt lý thuyết, ta có thể chứng minh bằng bổ đề Fatou - Fatou's Lemma)

Cách hệ số tương quan tuyến tính hoạt động



Nếu đa phần các điểm nằm vào trong góc phần tư thứ II và thứ IV, thì

$$Z_X Z_Y < 0,$$

với hầu hết dữ liệu quan sát, dẫn tới kết quả là $r < 0$.

Một số kết quả lý thuyết

Định lý sau cung cấp các kết quả quan trọng của hệ số tương quan tuyến tính. (Xem thêm chứng minh trong phụ lục đính kèm).

Định lý

Gọi X và Y là hai biến ngẫu nhiên, thỏa $\mathbb{E}(X^2) < \infty$ và $\mathbb{E}(Y^2) < \infty$. Giả sử rằng $\text{Var}(X) > 0$ và $\text{Var}(Y) > 0$. Khi đó,

- (i) r không thay đổi dưới phép biến đổi tỷ lệ của X và Y ;
(ii) $r^2 \leq 1$;
(iii) $r^2 = 1$ khi và chỉ khi tồn tại các hằng số thực a, b sao cho

$$\Pr(Y = aX + b) = 1.$$

- (iv) $r^2 = 0$ khi và chỉ khi, với bất kỳ hằng số thực a, b sao cho

$$\mathbb{E} \{ [Y - (aX + b)]^2 \} \geq \text{Var}(Y).$$

Từ (ii), ta có kết quả rằng, nếu $r^2 = 1$ thì chắc chắn rằng Y là một hàm tuyến tính của X .

Từ (iv), $r^2 = 0$ nếu và chỉ nếu hàm tuyến tính của X là tiên đoán tốt nhất cho Y theo nghĩa $\mathbb{E}\{[Y - (aX + b)]^2\}$ là hàm số với $a = 0$ và $b = \mathbb{E}(Y)$.

Một số kết quả lý thuyết

Tức là X sẽ không hữu ích trong việc tiên đoán Y , ít nhất khi ta cố áp đặt một hàm tuyến tính của X .

Ví dụ: Đặt X là một biến ngẫu nhiên theo phân phối Laplace với hàm mật độ

$$f(x) = \frac{1}{2} \exp(-|x|),$$

với $-\infty < x < \infty$. Khi đó, ta tính được $\mathbb{E}(X) = 0$, $\mathbb{E}(X^2) = 2$ và $\mathbb{E}(X^3) = 0$.

Đặt $Y = X^2$, khi đó, $\mathbb{E}(Y) = \mathbb{E}(X^2) = 2$ và

$$\text{Cov}(X, Y) = \mathbb{E}[X(Y - 2)] = \mathbb{E}[X^3 - 2X] = 0.$$

Suy ra, $r = 0$. Do đó, tất cả các hàm tuyến tính của X là không hữu ích cho việc tiên đoán Y (không có tương quan tuyến tính).

Tuy nhiên, thực tế thì X^2 tạo ra Y .

Ví dụ này cũng minh họa cho việc $r = 0$ chỉ suy ra **không có tương quan tuyến tính**, nhưng **không chắc chắn là không có tương quan** giữa X và Y , trong trường hợp tổng quát.

Một số kết quả lý thuyết

Phân phối chuẩn hai chiều

Ta xét trường hợp đặc biệt, khi (X, Y) tuân theo phân phối chuẩn hai chiều:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & r\sigma_X\sigma_Y \\ r\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix} \right)$$

Lúc này, phân phối lề của X và Y lần lượt là phân phối chuẩn tương ứng với trung bình μ_X, μ_Y và phương sai σ_X^2 và σ_Y^2 .

Ta tính được phân phối điều kiện của Y khi biết X là một phân phối chuẩn với trung bình

$$\mu_{Y|X} = \mu_Y + r \frac{\sigma_Y}{\sigma_X} (X - \mu_X)$$

và phương sai $\sigma_{Y|X}^2 = (1 - r^2)\sigma_Y^2$.

Từ kết quả trung bình điều kiện $\mu_{Y|X}$, ta thấy rằng nếu $r = 0$, thì $\mu_{Y|X} = \mu_Y$, tức là không phụ thuộc vào X , và khi đó, không có tương quan tuyến tính giữa X và Y .

Một số kết quả lý thuyết

Hơn nữa, khi $r = 0$, ta cũng có $\sigma_{Y|X}^2 = \sigma_Y^2$.

↪ Phân phối điều kiện của Y khi biết X chính là phân phối lề của Y .

Như vậy, ta có

$$F_{X,Y}(x, y) = F_X(x)F_{Y|X}(y|x) = F_X(x)F_Y(y)$$

tức là, X và Y là độc lập, hay không có tương quan giữa X và Y .

Trường hợp này cho ta hai kết luận:



- Nếu (X, Y) là vectơ ngẫu nhiên tuân theo phân phối chuẩn 2 chiều, thì tương quan giữa X và Y nếu tồn tại thì chỉ là tương quan tuyến tính.
- Nếu $r = 0$ thì nhận xét “không tồn tại tương quan giữa X và Y ” chỉ đúng trong trường hợp (X, Y) là vectơ ngẫu nhiên tuân theo phân phối chuẩn 2 chiều.

Kết luận thứ hai là bản lề cho kiểm định giả thuyết $r = 0$ mà ta sẽ xét trong phần sau.

Phân phối chuẩn hai chiều

Xét

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & -0.4 \\ -0.4 & 1 \end{pmatrix}\right)$$



Ước lượng hệ số tương quan tuyến tính

Xét quan sát ngẫu nhiên $(X_1, Y_1), \dots, (X_n, Y_n)$ của (X, Y) . Đặt

$$\blacksquare \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$\blacksquare \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i,$$

$$\blacksquare S_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\blacksquare S_Y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2}.$$

Khi đó, ước lượng $\hat{r}_n$ của r được xác định bởi

$$\hat{r}_n = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{S_X} \right) \left(\frac{Y_i - \bar{Y}}{S_Y} \right).$$

Và với dữ liệu quan sát $(x_1, y_1), \dots, (x_n, y_n)$, ta có hệ số tương quan mẫu:

$$\hat{r} = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right).$$

Ước lượng hệ số tương quan tuyến tính

Ví dụ 1: ta quan sát lại dữ liệu về cân nặng trung bình và trọng lượng não trung bình của 29 loài động vật. Đặt

- X là “trọng lượng cơ thể trung bình”,
- Y là “trọng lượng não trung bình”.

Ta tính được:

- $\bar{x} = 6544.7$, $s_x = 20269$
- $\bar{y} = 865.1$, $s_y = 2041$
- hệ số tương quan tuyến tính mẫu $\hat{r} = 0.459$.


Ước lượng hệ số tương quan tuyến tính

Ví dụ 2: ta quan sát lại dữ liệu về số lượng sói con sống sót so với chỉ số cận huyết của cặp sói bố mẹ. Đặt

- X là “chỉ số giao phối cận huyết của cặp sói bố mẹ”,
- Y là “số lượng sói con sống sót qua mùa đông đầu tiên”.

Ta tính được:

- $\bar{x} = 0.230$, $s_x = 0.100$
- $\bar{y} = 3.96$, $s_y = 1.88$
- hệ số tương quan tuyến tính mẫu $\hat{r} = -0.623$.




Ước lượng hệ số tương quan tuyến tính

Ví dụ 3: ta quan sát lại dữ liệu về tỷ lệ bác sĩ trên 1000 dân, và tuổi thọ trung bình của 175 quốc gia. Đặt

- X là “tỷ lệ bác sĩ trên 1000 dân”,
- Y là “tuổi thọ trung bình”.

Ta tính được:

- $\bar{x} = 1.786$, $s_x = 1.528$
- $\bar{y} = 70.661$, $s_y = 8.587$
- hệ số tương quan tuyến tính mẫu $\hat{r} = 0.695$.



Trong ví dụ này, rõ ràng tương quan là phi tuyến, nhưng $\hat{r} \neq 0$.

↪ nếu chỉ nhìn vào giá trị của $\hat{r}$, ta sẽ có một kết luận sai lầm về sự tương quan.

Khoảng tin cậy cho r


Xét (X, Y) tuân phân phối chuẩn hai chiều

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & r\sigma_X\sigma_Y \\ r\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix} \right)$$


Giả sử ta có quan sát ngẫu nhiên $(X_1, Y_1), \dots, (X_n, Y_n)$ của (X, Y) . Đặt $\hat{r}_n$ là ước lượng của r . Khi đó,

- phân phối mẫu của $\hat{r}_n$ không xấp xỉ một phân phối chuẩn;
- khi r gần ± 1 , thì phân phối của $\hat{r}_n$ bị lệch (không đối xứng).

Khoảng tin cậy cho r



Khoảng tin cậy cho r



Khoảng tin cậy cho r

Dựa vào kết quả xấp xỉ trên, ta có thể xây dựng khoảng tin cậy cho z và sau đó thực hiện biến đổi ngược:

$$r = \frac{\exp(2z) - 1}{\exp(2z) + 1}$$

để xác định khoảng tin cậy cho r .

Khoảng tin cậy $100(1 - \alpha)\%$ cho z có dạng là (z_L, z_U) , với

$$\blacksquare z_L = \hat{z} - z_{1-\alpha/2} \frac{1}{\sqrt{n-3}},$$

$$\blacksquare z_U = \hat{z} + z_{1-\alpha/2} \frac{1}{\sqrt{n-3}}.$$

Áp dụng công thức biến đổi ngược, ta có khoảng tin cậy $100(1 - \alpha)\%$ cho r là:

$$\left(\frac{\exp(2z_L) - 1}{\exp(2z_L) + 1}, \frac{\exp(2z_U) - 1}{\exp(2z_U) + 1} \right).$$

Khoảng tin cậy cho r

Ví dụ 2: ta quan sát lại dữ liệu về số lượng sói con sống sót so với chỉ số cận huyết của cặp sói bố mẹ. Đặt

- X là “chỉ số giao phối cận huyết của cặp sói bố mẹ”,
- Y là “số lượng sói con sống sót qua mùa đông đầu tiên”.

Ta tính được:

- $\bar{x} = 0.230, s_x = 0.100, \bar{y} = 3.96, s_y = 1.88$
- hệ số tương quan tuyến tính mẫu $\hat{r} = -0.623$.

Giả sử (X, Y) là tuân theo phân phối chuẩn 2 chiều.

Ta tính được

$$\hat{z} = \frac{1}{2} \log \left(\frac{1 + (-0.623)}{1 - (-0.623)} \right) = -0.7298.$$

Khoảng tin cậy 95% của z là $(-1.1575, -0.3021)$. Và do đó, khoảng tin cậy 95% cho r là

$$\left(\frac{\exp(2 \times (-1.1575)) - 1}{\exp(2 \times (-1.1575)) + 1}, \frac{\exp(2 \times (-0.3021)) - 1}{\exp(2 \times (-0.3021)) + 1} \right) = (-0.8202, -0.2932).$$

Kiểm định hệ số tương quan bằng 0

Xét (X, Y) tuân phân phối chuẩn hai chiều

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & r\sigma_X\sigma_Y \\ r\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix} \right).$$

Ta muốn kiểm tra xem liệu X và Y có độc lập hay không.

Nhắc lại rằng, trong trường hợp phân phối chuẩn hai chiều, X và Y có độc lập tương đương không có tương quan tuyến tính.

Ta cần kiểm định giả thuyết $H_0 : r = 0$, cụ thể

$$\begin{cases} H_0 : r = 0 \\ H_1 : r \neq 0 \end{cases} \quad \text{hoặc} \quad \begin{cases} H_0 : r = 0 \\ H_1 : r < 0 \end{cases} \quad \text{hoặc} \quad \begin{cases} H_0 : r = 0 \\ H_1 : r > 0 \end{cases}$$

Dưới giả định H_0 , tức là $r = 0$, thì

$$\hat{r}_n \sqrt{\frac{n-2}{1-\hat{r}_n^2}} \sim t_{n-2}.$$

Khi đó, ta sẽ thực hiện kiểm định với thống kê T tuân theo phân phối t_{n-2} .

Kiểm định hệ số tương quan bằng 0

Ví dụ 2: ta quan sát lại dữ liệu về số lượng sói con sống sót so với chỉ số cận huyết của cặp sói bố mẹ. Đặt

- X là “chỉ số giao phối cận huyết của cặp sói bố mẹ”,
- Y là “số lượng sói con sống sót qua mùa đông đầu tiên”.

Ta tính được:

- $\bar{x} = 0.230$, $s_x = 0.100$, $\bar{y} = 3.96$, $s_y = 1.88$
- hệ số tương quan tuyến tính mẫu $\hat{r} = -0.623$.

Giả sử (X, Y) là tuân theo phân phối chuẩn 2 chiều.

Ta muốn kiểm tra xem liệu có thực sự tồn tại tương quan tuyến tính của X và Y trong quần thể hay không.


Ta xét giả thuyết $H_0 : r = 0$ với đối thuyết $H_1 : r \neq 0$.

Ta tính được giá trị quan sát của thống kê T là

$$t_{\text{obs}} = (-0.623) \times \sqrt{\frac{24 - 2}{1 - (-0.623)^2}} = -3.736$$

Kết quả p -value là 0.00115. $\Rightarrow$ ta có thể bác bỏ giả thuyết H_0 .

Hệ số tương quan tuyến tính và vùng dữ liệu




Hệ số tương quan tuyến tính và vùng dữ liệu


- Mỗi tương quan giữa hai biến X và Y phụ thuộc vào khoảng giá trị mà dữ liệu được quan sát.
- Vì lý do này, ta phải thận trọng khi so sánh độ mạnh tương quan tuyến tính giữa các nghiên cứu sử dụng phạm vi dữ liệu khác nhau.

Hệ số tương quan và điểm ngoại lai


Hệ số tương quan rất nhạy cảm với các điểm cực trị.



(a) $r = 0.2$



(b) $r = 0.6$



(c) $r = -0.1$

Ba biểu đồ này minh họa cách một điểm có thể ảnh hưởng lớn đến độ lớn của hệ số tương quan tuyến tính.


→ Điều quan trọng là luôn vẽ biểu đồ dữ liệu trước khi sử dụng r (hoặc bất kỳ số liệu thống kê nào khác) để tóm tắt dữ liệu.

Thống kê thứ tự và hạng


Ta có một số kết quả lý thuyết sau:

- $(R_1, R_2, \dots, R_n)$ là có phân phối đều rời rạc (discrete uniform distribution) trên tập gồm tất cả các tổ hợp của $(1, 2, \dots, n)$, tức là xác suất xuất hiện là như nhau với mọi i .
- $\mathbb{E}(R_i) = \frac{n+1}{2}$.
- $\mathbb{E}(R_i^2) = \frac{(n+1)(2n+1)}{6}$.
- $\text{Var}(R_i) = \frac{n^2-1}{12}$.

Hệ số tương quan hạng Spearman



(a)



(b)

Xét hai biến X và Y . Đặt $R(X)$ và $R(Y)$ là hạng của X và Y :

- hình (a) miêu tả tương quan của X và Y ;
- hình (b) miêu tả tương quan giữa $R(X)$ và $R(Y)$.

Hệ số tương quan hạng Spearman

Hệ số tương quan hạng Spearman

Hệ số tương quan hạng Spearman - Spearman's rank correlation coefficient là một hệ số dùng để đo độ mạnh của một tương quan đơn điệu giữa hai biến định lượng.


$$r_S = \frac{\text{Cov}(R(X), R(Y))}{\sqrt{\text{Var}(R(X))\text{Var}(R(Y))}},$$

với $R(X)$ và $R(Y)$ lần lượt là hạng của X và Y .


Hệ số r_S có giá trị nằm trong $[-1, 1]$:

- nếu $-1 < r_S < 0$: tương quan giữa X và Y là tương quan đơn điệu giảm, tức là X tăng thì Y giảm;
- nếu $0 < r_S < 1$: tương quan giữa X và Y là tương quan đơn điệu tăng, tức là X tăng thì Y tăng;
- nếu $r_S = 0$: tương quan giữa X và Y là không phải đơn điệu;
- nếu $r_S = -1$: tương quan giữa X và Y là đơn điệu giảm ngặt;
- nếu $r_S = 1$: tương quan giữa X và Y là đơn điệu tăng ngặt;

Hệ số tương quan hạng Spearman




(a)




(b)

- Hình (a): X và Y có tương quan phi tuyến theo một hàm không đơn điệu.
- hình (b): $R(X)$ và $R(Y)$ không cho thấy sự tương quan.

Hệ số tương quan hạng Spearman



(a)



(b)

- Hình (a): X và Y không có tương quan (các điểm phân bố ngẫu nhiên).
- hình (b): $R(X)$ và $R(Y)$ không cho thấy sự tương quan.


Ước lượng hệ số tương quan hạng

Ví dụ 1: ta quan sát lại dữ liệu về cân nặng trung bình và trọng lượng não trung bình của 29 loài động vật.
Đặt

- X là “trọng lượng cơ thể trung bình”,
- Y là “trọng lượng não trung bình”.

Ta tính được:

- $\bar{x} = 6544.7$, $s_x = 20269$
- $\bar{y} = 865.1$, $s_y = 2041$
- hệ số tương quan tuyến tính mẫu $\hat{r} = 0.459$.
- hệ số tương quan hạng của mẫu $\hat{r}_S = 0.738$.



Quan sát hình vẽ với tỷ lệ gốc (không chỉnh tỷ lệ ở trục x và y), ta thấy có các điểm cực trị, do đó, giá trị của $\hat{r}$ có lẽ đã bị thay đổi.

Hầu hết các điểm có xu hướng tăng theo chiều tăng của trục x và y . Do đó, $\hat{r}_S$ là hợp lý.


Ước lượng hệ số tương quan hạng

Ví dụ 2: ta quan sát lại dữ liệu về số lượng sói con sống sót so với chỉ số cận huyết của cặp sói bố mẹ. Đặt

- X là “chỉ số giao phối cận huyết của cặp sói bố mẹ”,
- Y là “số lượng sói con sống sót qua mùa đông đầu tiên”.

Ta tính được:

- $\bar{x} = 0.230$, $s_x = 0.100$
- $\bar{y} = 3.96$, $s_y = 1.88$
- hệ số tương quan tuyến tính mẫu $\hat{r} = -0.623$.
- hệ số tương quan hạng của mẫu $\hat{r}_S = -0.693$.



Khi tương quan thực sự là tuyến tính, $\hat{r}_S$ sẽ gần bằng $\hat{r}$.


Ước lượng hệ số tương quan hạng

Ví dụ 3: ta quan sát lại dữ liệu về tỷ lệ bác sĩ trên 1000 dân, và tuổi thọ trung bình của 175 quốc gia. Đặt

- X là “tỷ lệ bác sĩ trên 1000 dân”,
- Y là “tuổi thọ trung bình”.

Ta tính được:

- $\bar{x} = 1.786$, $s_x = 1.528$
- $\bar{y} = 70.661$, $s_y = 8.587$
- hệ số tương quan tuyến tính mẫu $\hat{r} = 0.695$.
- hệ số tương quan hạng của mẫu $\hat{r}_S = 0.775$.



Trong ví dụ này, rõ ràng tương quan là phi tuyến và đơn điệu tăng, do đó, sử dụng $\hat{r}_S$ là hợp lý hơn $\hat{r}$.

Khoảng tin cậy cho hệ số tương quan hàng

Khoảng tin cậy $(1 - \alpha) \times 100\%$ của r_S có thể được xây dựng bằng hai phương pháp:

- phương pháp Jackknife empirical likelihood¹, cụ thể:

$$I_\alpha = \{ \theta : -2 \log L(\theta) \leq \chi_{1,\alpha}^2 \},$$

trong đó $\chi_{1,\alpha}^2$ là phân vị thứ α của phân phối χ_1^2 .

- phương pháp Jackknife Euclidean likelihood², cụ thể:

$$l_{\alpha} = \left\{ \theta : \frac{\left[\sum_{i=1}^n (Z_i - \theta) \right]^2}{\sum_{i=1}^n (Z_i - \theta)^2} \leq \chi_{1, \alpha}^2 \right\},$$

trong đó, Z_i là các giả quan sát jackknife (jackknife pseudo-values), và $\chi^2_{1,\alpha}$ là phân vị thứ α của phân phối χ^2_1 .

Cả hai phương pháp đều có thể thực hiện trong R với thư viện `spearmanCI`.

¹Wang and Peng, (2012)

²de Carvalho and Marques, (2012)

Khoảng tin cậy cho hệ số tương quan hạng

Ví dụ 2: xét lại ví dụ 2 về tương quan giữa chỉ số giao phối cận huyết của cặp sói bố mẹ và số lượng sói con sống sót.

- $\hat{r} = -0.623$;
- $\hat{r}_S = -0.693$;
- khoảng tin cậy 95% của hệ số tương quan Pearson là $(-0.8202, -0.2932)$;
- áp dụng phương pháp Jackknife Euclidean likelihood, khoảng tin cậy 95% cho hệ số tương quan hạng Spearman là $(-0.887, -0.493)$.


Ví dụ 3: xét lại ví dụ 3 về tương quan giữa tỷ lệ bác sĩ trên 1000 dân và tuổi thọ trung bình.

- $\hat{r}_S = 0.775$;
- áp dụng phương pháp Jackknife Euclidean likelihood, khoảng tin cậy 95% cho hệ số tương quan hạng Spearman là $(0.701, 0.849)$.

So sánh với hệ số tương quan Pearson

Hệ số tương quan hạng Spearman ít nhạy cảm với giá trị cực trị hơn so với hệ số tương quan Pearson.

Bởi vì hệ số tương quan hạng Spearman sử dụng hạng của quan sát, thay vì giá trị của chúng.



Ở hình trên

- hệ số tương quan tuyến tính $\hat{r} = 0.565$;
- hệ số tương quan hạng $\hat{r}_S = 0.770$;

Kết luận

Ta có một số kết luận như sau:

- Hệ số tương quan tuyến tính Pearson chỉ hiệu quả với trường hợp tương quan của mẫu là tuyến tính.
- Kiểm định giả thuyết $H_0 : r = 0$ và khoảng tin cậy cho r chỉ có thể thực hiện nếu giả định về phân phối chuẩn hai chiều được thỏa mãn, và tương quan được quan sát thấy có thiên hướng tuyến tính.
- Hệ số tương quan hạng Spearman tương thích với các trường hợp tương quan đơn điệu khác nhau, kể cả tuyến tính lẫn phi tuyến.
- Khoảng tin cậy cho tương quan hạng Spearman không yêu cầu giả định về phân phối chuẩn hai chiều.
- Nhất thiết phải quan sát đồ thị phân tán của hai biến trước khi tính toán hệ số tương quan.
- Khi $\hat{r} = 0$ hoặc $\hat{r}_S = 0$ có nghĩa là không tồn tại tương quan tuyến tính hoặc tương quan đơn điệu. Không kết luận là không có tương quan.

Kết luận

Thăng đo độ mạnh của tương quan (tuyến tính hoặc đơn điệu) giữa X và Y :

- $|\hat{r}_*| \in [0, 0.2)$: tương quan (tuyến tính hoặc đơn điệu) rất yếu;
- $|\hat{r}_*| \in [0.2, 0.4)$: tương quan (tuyến tính hoặc đơn điệu) yếu;
- $|\hat{r}_*| \in [0.4, 0.6)$: tương quan (tuyến tính hoặc đơn điệu) tương đối;
- $|\hat{r}_*| \in [0.6, 0.8)$: tương quan (tuyến tính hoặc đơn điệu) mạnh;
- $|\hat{r}_*| \in [0.8, 1]$: tương quan (tuyến tính hoặc đơn điệu) rất mạnh;