

## *Bài giảng 7: Mô hình hồi quy logistic và bài toán phân loại*

TS. Tô Đức Khánh

Khoa Toán-Tin Học, ĐH Khoa Học Tự Nhiên  
Đại học Quốc Gia Tp. HCM

**Học phần: Thống Kê Trong Sinh Học**

## *Nội dung buổi học*

---

**1** *Mô hình hồi quy logistic*

**2** *Bài toán phân loại*

## 1 Mô hình hồi quy logistic

## 2 Bài toán phân loại

## Mô hình hồi quy tuyến tính cho biến nhị phân

### Biến đáp ứng nhị phân

Xét biến định tính  $Y$ . Nếu  $Y$  chỉ có hai kết quả, ta nói  $Y$  là một biến nhị phân (binary hoặc dichotomous). Ví dụ:

- $Y$  là trạng thái bệnh: không bị bệnh (non-diseased)/bị bệnh (diseased)

$$Y = \begin{cases} 0 & \text{nếu không bị bệnh} \\ 1 & \text{nếu bị bệnh} \end{cases}$$

- $Y$  là tình trạng hút thuốc: không hoặc có

$$Y = \begin{cases} 0 & \text{nếu không hút thuốc} \\ 1 & \text{nếu có hút thuốc} \end{cases}$$

Trong phần trước, ta đã học về mô hình hồi quy tuyến tính:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_p X_p + \varepsilon,$$

để dự đoán giá trị của biến định lượng  $Y$  dựa vào  $X_1, X_2, \dots, X_p$ .

Nếu  $Y$  là biến nhị phân, thì mô hình hồi quy tuyến tính còn có thể sử dụng??

**Ví dụ 1:** Ung thư thực quản là một trong những loại ung thư nguy hiểm. Sau một giai đoạn phát triển, tế bào ung thư có thể di căn sang các hạch bạch huyết gần đó, rồi sau đó là gan hoặc phổi. Một câu hỏi nghiên cứu được đặt ra:

“Liệu rằng có thể dự đoán tế bào ung thư thực quản đã di căn sang hạch bạch huyết, nếu dựa vào kích cỡ của khối u?”

Để trả lời câu hỏi này, một nghiên cứu đã được thực hiện:


- 31 bệnh nhân ung thư thực quản được quan sát;
- kích cỡ của các khối u lớn nhất được ghi nhận lại, đơn vị cm;
- sự xuất hiện tế bào ung thư ở hạch bạch huyết cũng được kiểm tra bằng một xét nghiệm độc lập, và ghi chép lại kết quả: có hoặc không.

Dựa vào câu hỏi, ta cần xây dựng một mô hình dựa đoán sự xuất hiện tế bào ung thư thực quản tại hạch bạch huyết dựa trên thông tin của kích cỡ khối u.

- **Biến đáp ứng Y:** sự xuất hiện tế bào ung thư ở hạch bạch huyết, có hoặc không.
- **Biến giải thích X:** kích cỡ khối u lớn nhất, đơn vị cm.

[illegible]

## Mô hình hồi quy tuyến tính cho biến nhị phân



Ta nhận thấy rằng:

- đường thẳng hồi quy không bị giới hạn, có thể vượt qua 0 và 1;
- với cỡ khối u là 4cm, từ mô hình tuyến tính, ta ước lượng được  $\hat{Y} = 0.49$ ;
- cùng một giá trị của cỡ khối u, ta có thể quan sát được cả 0 và 1, tức là không di căn và di căn.

## Phân phối nhị thức và mô hình xác suất

Ở phần trước, ta thấy rằng việc sử dụng mô hình hồi quy tuyến tính cho biến nhị phân là không phù hợp.

Quan sát, với cách đặt

$$Y = \begin{cases} 0, & \text{nếu tế bào ung thư chưa di căn,} \\ 1, & \text{nếu tế bào ung thư đã di căn.} \end{cases}$$

thì  $Y$  là biến ngẫu nhiên  $\mathcal{B}(1, p)$ , với  $p = \Pr(Y = 1)$ , tức là xác suất tế bào di căn sang hạch bạch huyết:

- $p = 0$  tương ứng  $Y = 0$ , chắc chắn;
- $p = 1$  tương ứng  $Y = 1$ , chắc chắn;
- $p$  càng gần 1 thì khả năng  $Y = 1$  càng cao, tức là nguy cơ cao rằng tế bào ung thư đã di căn.



## Phân phối nhị thức và mô hình xác suất

Nhắc lại câu hỏi nghiên cứu:

“Liệu rằng có thể dự đoán tế bào ung thư thực quản đã di căn sang hạch bạch huyết, nếu dựa vào kích cỡ của khối u?”

Nếu kích cỡ khối u có liên quan tới việc di căn của tế bào ung thư thì

$\hookrightarrow$  xác suất  $p = \Pr(Y = 1)$  sẽ thay đổi theo thông tin của  $X$ .

Khi đó, ta có thể mô hình hóa xác suất di căn của tế bào ung thư theo  $X$ :

$$P(Y = 1|X) = p(X)$$

tức là xác suất điều kiện của  $Y$  khi biết  $X$ .

Do đó, ta có phân phối điều kiện

$$Y|X \sim \mathcal{B}(1, p(X)).$$

**Nhắc lại:** nếu  $X$  và  $Y$  là độc lập thì  $P(Y = 1|X) = P(Y = 1) = p$ .

Ta có nhiều lựa chọn dạng hàm cho  $p(X)$ , tuy nhiên, lựa chọn hàm tuyến tính là đơn giản nhất:

$$p(X) = \beta_0 + \beta_1 X.$$

Nhưng, hàm này cho giá trị không thuộc  $(0, 1)$ .

Ta cần một hàm biến đổi  $\beta_0 + \beta_1 X$  từ  $\mathbb{R}$  vào trong  $(0, 1)$ .

- hàm chỉ

$$\mathbb{I}(x) = \begin{cases} 0, & \text{nếu } x < 0 \\ x, & \text{nếu } 0 \leq x \leq 1 \\ 1, & \text{nếu } x > 1 \end{cases}$$


- hàm logistic

$$g(x) = \frac{\exp(x)}{1 + \exp(x)}$$

- hàm probit

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{s^2}{2}\right) ds$$

## Phân phối nhị thức và mô hình xác suất



- Hàm chỉ  $I(x)$  là hàm không trơn, do đó, không tồn tại đạo hàm.
- Hàm logistic và probit là các hàm trơn, liên tục tại mọi  $x$ .

## Phân phối nhị thức và mô hình xác suất

Nếu ta lựa chọn

- hàm logistic, thì

$$\Pr(Y = 1|X) = p(X) = \frac{\exp(\beta_0 + \beta_1 X)}{1 + \exp(\beta_0 + \beta_1 X)}$$

khi đó, ta có mô hình **hồi quy logistic**. Hơn nữa, sử dụng biến đổi ta được

$$\log \left( \frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X;$$

- hàm probit, thì

$$\Pr(Y = 1|X) = p(X) = \Phi(\beta_0 + \beta_1 X)$$

khi đó, ta có mô hình **hồi quy probit**. Hơn nữa, sử dụng biến đổi ta được

$$\Phi^{-1}(p(X)) = \beta_0 + \beta_1 X.$$

Như vậy: mô hình hồi quy logistic và mô hình hồi quy probit là hai mô hình hồi quy tham số được dùng để tiên đoán xác suất xuất hiện của một biến nhị phân.

Giả sử ta có bộ dữ liệu ngẫu nhiên gồm  $n$  cặp quan sát  $(X_i, Y_i)$ ,  $i = 1, \dots, n$ .

$$\Pr(Y_i = 1|X = X_i) = p(X_i) = \frac{\exp(\beta_0 + \beta_1 X_i)}{1 + \exp(\beta_0 + \beta_1 X_i)}$$

để thuận tiện, ta đặt  $p_i = p(X_i)$ .

Các tham số  $\beta_0$  và  $\beta_1$  là chưa biết và cần phải ước lượng.

Trong mô hình này,  $Y_i \sim \mathcal{B}(1, p_i)$ . Do đó, ta xây dựng được hợp lý:

$$L(\beta_0, \beta_1) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1 - Y_i}$$

Từ đây ta suy ra được hàm log-likelihood:

$$\ell(\beta_0, \beta_1) = \sum_{i=1}^n \{Y_i (\beta_0 + \beta_1 X_i) - \log(1 + \exp(\beta_0 + \beta_1 X_i))\}$$

## Ước lượng mô hình

Ước lượng của  $\beta_0$  và  $\beta_1$  được suy ra từ phương pháp hợp lý cực đại:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \max_{(\beta_0, \beta_1) \in \mathbb{R}^2} \ell(\beta_0, \beta_1)$$

Tức là ta đi giải hệ phương trình đạo hàm riêng phần:

$$\begin{cases} \frac{\partial}{\partial \beta_0} \ell(\beta_0, \beta_1) = 0 \\ \frac{\partial}{\partial \beta_1} \ell(\beta_0, \beta_1) = 0 \end{cases}$$


Tuy nhiên, nghiệm của hệ phương trình này không có dạng tường minh, do đó, ta cần phải giải lặp bằng phương giải số.

Trong giải tích ta có phương pháp giải lặp Newton-Raphson.

Áp dụng vào trong bài toán mô hình thống kê, ta có phương pháp có tên là **Fisher scoring**.

Nội dung của phương pháp này, sẽ được trình bày trong môn học “Mô hình thống kê tuyến tính nâng cao”.

## Ước lượng mô hình



## Ước lượng mô hình


Ta thu được ước lượng

■  $\hat{\beta}_0 = -2.0858$

■  $\hat{\beta}_1 = 0.5117$

Và ta có ước lượng mô hình logistic là:

$$\hat{\Pr}(Y = 1|X = x) = \frac{\exp(-2.0858 + 0.5117x)}{1 + \exp(-2.0858 + 0.5117x)}$$





## Diễn giải mô hình

Với mô hình logistic được ước lượng

$$\hat{\text{Pr}}(Y = 1|X = x) = \frac{\exp(-2.0858 + 0.5117x)}{1 + \exp(-2.0858 + 0.5117x)}$$

cho trước một giá trị của  $X$  ta dự đoán xác suất di căn của tế bào ung thư.

Ví dụ, với khối u có kích cỡ 6cm, xác suất di căn dự đoán là

$$\hat{\text{Pr}}(Y = 1|X = 6) = \frac{\exp(-2.0858 + 0.5117 \times 6)}{1 + \exp(-2.0858 + 0.5117 \times 6)} = 0.7279$$

Ví dụ, với khối u có kích cỡ 3cm, xác suất di căn dự đoán là

$$\hat{\text{Pr}}(Y = 1|X = 3) = \frac{\exp(-2.0858 + 0.5117 \times 3)}{1 + \exp(-2.0858 + 0.5117 \times 3)} = 0.3657$$

Giá trị và dấu của  $\hat{\beta}_1$  cho biết độ lớn của tác động của biến giải thích  $X$  tới xác suất  $\Pr(Y = 1|X = x)$ :

- $\hat{\beta}_1 > 0$ : tác động tích cực tới  $\hat{\Pr}(Y = 1|X = x)$ , tức là  $X$  tăng thì  $\hat{\Pr}(Y = 1|X = x)$  cũng tăng;
- $\hat{\beta}_1 < 0$ : tác động tiêu cực tới  $\hat{\Pr}(Y = 1|X = x)$ , tức là  $X$  tăng thì  $\hat{\Pr}(Y = 1|X = x)$  cũng giảm;

Đối với ví dụ mà ta đang xét, ước lượng  $\hat{\beta}_1$  là dương, do đó, khi kích cỡ của khối u tăng thì xác suất tế bào ung thư di căn cũng tăng lên (minh họa bởi đường ước lượng trong hình).

Hệ số chặn  $\hat{\beta}_0$  được hiểu là một hệ số cơ sở (hay tham chiếu) cho xác suất, khi biến giải thích có giá trị bằng 0.

Đối với ví dụ mà ta đang xét, giá trị xác suất tham chiếu sẽ là

$$\frac{\exp(-2.0858)}{1 + \exp(-2.0858)} = 0.1105$$

## Diễn giải mô hình

---

### Tỷ lệ cược - odds

Nếu một sự kiện A có xác suất xảy ra là  $p$ , thì tỷ lệ cược (*odds*) cho sự xuất hiện của A được xác định bởi  $\frac{p}{1-p}$ , tức là tỷ lệ giữa xác suất mà A xuất hiện và xác suất mà A không xuất hiện.

**Ví dụ:** A là sự kiện một người bị di căn tế bào ung thư:

- xác suất A xuất hiện là  $p = 0.7$ ;
- tỷ lệ cược cho một người bị di căn tế bào ung thư là  $\frac{0.7}{1-0.7} = 2.33$

Điều này có nghĩa là: xác suất quan sát được một người bệnh bị di căn tế bào ung thư là cao hơn 2.33 lần so với xác suất không quan sát được sự di căn tế bào ung thư.

## Diễn giải mô hình

Theo thiết lập mô hình logistic, ta có

$$\frac{p(X)}{1 - p(X)} = \exp(\beta_0 + \beta_1 X);$$

như vậy, ta có được biểu diễn của tỷ lệ cược theo giá trị của  $X$ . Hay dạng biểu diễn tuyến tính của log-odds

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X.$$

Từ dạng biểu diễn tuyến tính này, ta có quy tắc sau:

- nếu  $\hat{\beta}_1 > 0$ , thì khi giá trị  $x$  tăng một đơn vị thì log-odds tăng  $\hat{\beta}_1$  đơn vị;
- nếu  $\hat{\beta}_1 < 0$ , thì khi giá trị  $x$  tăng một đơn vị thì log-odds giảm  $|\hat{\beta}_1|$  đơn vị.

Quy tắc này cũng tương đương với

- nếu  $\hat{\beta}_1 > 0$ , thì khi giá trị  $x$  tăng một đơn vị thì tỷ lệ cược tăng  $\exp(\hat{\beta}_1)$  lần;
- nếu  $\hat{\beta}_1 < 0$ , thì khi giá trị  $x$  tăng một đơn vị thì tỷ lệ cược giảm  $\exp(\hat{\beta}_1)$  lần.

## Diễn giải mô hình

---

Đối với ví dụ mà ta đang xét, ước lượng  $\hat{\beta}_1 = 0.5117$ ,

- nếu kích cỡ của khối u tăng 6cm thì tỷ lệ cược cho việc tế bào ung thư di căn là

$$\exp(-2.0858 + 0.5117 \times 6) = 2.6762$$

tức là, với khối u có kích thước 6cm, thì xác suất quan sát được một người bệnh có sự di căn tế bào ung thư là cao hơn 2.6762 lần so với xác suất không quan sát được sự di căn;

- nếu kích cỡ của khối u tăng 3cm thì tỷ lệ cược cho việc tế bào ung thư di căn là


$$\exp(-2.0858 + 0.5117 \times 3) = 0.5766$$

tức là, với khối u có kích thước 3cm, thì xác suất quan sát được một người bệnh có sự di căn tế bào ung thư là thấp hơn 0.5766 lần so với xác suất không quan sát được sự di căn;

- nếu kích cỡ của khối u tăng 1cm thì tỷ lệ cược cho việc tế bào ung thư di căn tăng lên  $\exp(0.5117) = 1.6681$  lần, hay tương đương với mức tăng 66.81%.

## Diễn giải mô hình

---



## Thống kê suy luận cho mô hình

Sử dụng lý thuyết cho ước lượng hợp lý cực đại, ta chứng minh được:

- $\hat{\beta}_0, \hat{\beta}_1$  là bất biến, tức là với  $s(\beta_0, \beta_1)$  là một hàm song ánh của  $(\beta_0, \beta_1)$  thì  $s(\hat{\beta}_0, \hat{\beta}_1)$  là ước lượng hợp lý cực đại của  $s(\beta_0, \beta_1)$ ;
- $\hat{\beta}_0, \hat{\beta}_1$  là các ước lượng vững;
- $\hat{\beta}_0, \hat{\beta}_1$  là các ước lượng xấp xỉ không chệch;
- $\frac{\hat{\beta}_0 - \beta_0}{\widehat{SE}(\hat{\beta}_0)} \xrightarrow{d} N(0, 1)$ ;
- $\frac{\hat{\beta}_1 - \beta_1}{\widehat{SE}(\hat{\beta}_1)} \xrightarrow{d} N(0, 1)$ .

Từ kết quả này ta suy ra được:

- khoảng tin cậy cho hệ số  $\beta_0$  và cho  $\beta_1$ :

$$\left( \hat{\beta}_j - z_{(1+c)/2} \widehat{SE}(\hat{\beta}_j), \hat{\beta}_j + z_{(1+c)/2} \widehat{SE}(\hat{\beta}_j) \right)$$

- kiểm định giả thuyết  $H_0 : \beta_j = 0$ , dựa trên phân phối chuẩn.

## Thống kê suy luận cho mô hình

Với ví dụ đang xét, ta có bảng kết quả tổng hợp sau:

|                       | Estimate | Standard error | z-statistic | p-value |
|-----------------------|----------|----------------|-------------|---------|
| $\beta_0$ - Intercept | -2.0858  | 1.2256         | -1.702      | 0.0888  |
| $\beta_1$ - Cỡ khối u | 0.5117   | 0.2561         | 1.998       | 0.0457  |

Như vậy, ta có thể kết luận rằng:

- cỡ khối u là cần thiết để dự đoán xác suất tế bào ung thư di căn tới hạch bạch huyết, tại mức ý nghĩa 10%;
- hệ số chặn có ý nghĩa tại mức 10%.

Khoảng tin cậy 90% cho hệ số của mô hình là

- $\beta_0$  :  $(-4.3100, -0.2020)$
- $\beta_1$  :  $(0.1307, 0.9901)$



### Xét hàm tuyến tính

$$\eta = \beta_0 + \beta_1 x$$

là một hàm song ánh của  $(\beta_0, \beta_1)$ . Do đó

$$\hat{\eta} = \hat{\beta}_0 + \hat{\beta}_1 x$$

là một ước lượng hợp lý cực đại của  $\eta$ . Do đó, ta có các tính chất sau:

- $\hat{\eta}$  là ước lượng vững;
- $\hat{\eta}$  là ước lượng xấp xỉ không chệch;
- $\frac{\hat{\eta} - \eta}{\widehat{SE}(\hat{\eta})} \xrightarrow{d} N(0, 1)$ .


Từ đây, ta suy ra khoảng tin cậy cho  $\eta$  là:

$$\left(\widehat{\eta} - z_{(1+c)/2} \widehat{SE}(\widehat{\eta}), \widehat{\eta} + z_{(1+c)/2} \widehat{SE}(\widehat{\eta})\right)$$

Và do đó, ta có được khoảng tin cậy cho  $\Pr(Y = 1|X = x)$ :

$$\left( \frac{\exp\left(\widehat{\eta} - z_{(1+c)/2} \widehat{SE}(\widehat{\eta})\right)}{1 + \exp\left(\widehat{\eta} - z_{(1+c)/2} \widehat{SE}(\widehat{\eta})\right)}, \frac{\exp\left(\widehat{\eta} + z_{(1+c)/2} \widehat{SE}(\widehat{\eta})\right)}{1 + \exp\left(\widehat{\eta} + z_{(1+c)/2} \widehat{SE}(\widehat{\eta})\right)} \right)$$

## Thống kê suy luận cho mô hình



Mô hình hồi quy logistic có thể mở rộng cho các trường hợp:

- nhiều hơn một biến giải thích;
- biến giải thích là định tính;
- các dạng biến đổi của biến giải thích ( $x^2$ ,  $\sqrt{x}$ ,  $\sqrt[3]{x}$ ,  $\log(x)$ , ...);

mà quy trình ước lượng, các diễn giải mô hình, tính chất của ước lượng, cũng như quy trình thống kê suy luận là không đổi.

Mô hình hồi quy logistic tổng quát là:

$$\Pr(Y = 1|X_1, \dots, X_p) = \frac{\exp(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}{1 + \exp(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}$$

với  $X_1, \dots, X_p$  là  $p$  biến giải thích trong mô hình (có thể là biến đổi của biến giải thích).

## 1 Mô hình hồi quy logistic

## 2 Bài toán phân loại

## Giới thiệu


---

**Phân loại (Classification)** là một kỹ thuật được dùng để phân dữ liệu thành một số nhóm (lớp) nhất định. Mục tiêu chính của bài toán phân loại là xác định danh mục hoặc nhóm mà dữ liệu mới sẽ thuộc vào, dựa trên thông tin của một số biến giải thích được lập.

Bài toán phân loại là rất phổ biến trong nhiều lĩnh vực khác nhau:

- Một người đến phòng cấp cứu với một loạt các triệu chứng có thể do một trong ba tình trạng bệnh lý. Bác sĩ cần xác định/dự đoán bệnh trạng nào của bệnh nhân dựa trên thông tin của người đó?
- Dịch vụ ngân hàng trực tuyến phải có khả năng xác định liệu một giao dịch đang được thực hiện trên trang web là gian lận, dựa trên địa chỉ IP của người dùng, lịch sử giao dịch trong quá khứ, v.v.
- Trên cơ sở dữ liệu trình tự DNA của một số bệnh nhân mắc và không mắc một căn bệnh nhất định, một nhà sinh vật học muốn tìm ra đột biến DNA nào là có hại (gây bệnh) và đột biến nào thì không.

## Giới thiệu



## *Giới thiệu*

---

Có nhiều phương pháp/kỹ thuật phân loại khác nhau đã được phát triển:

- **hồi quy logistic - logistic regression**
- **phân tích phân biệt tuyến tính - linear discriminant analysis**
- **phương pháp K-lân cận - K-nearest neighbors**
- **Cây quyết định - Decision Tree**
- **Random Forest**
- **Support Vector Machine**

Trong bài giảng này chúng ta sẽ học về cách sử dụng hồi quy logistic trong bài toán phân loại.

## Phân loại nhị phân

- Xét  $X_1, X_2, \dots, X_p$  là  $p$  biến giải thích, độc lập nhau, cùng có mối liên hệ với biến đáp ứng  $Y$ .
- Gọi  $x_1, x_2, \dots, x_p$  là kết quả tương ứng của  $X_1, X_2, \dots, X_p$ .

*Câu hỏi nghiên cứu*

Dựa vào các giá trị của các biến giải thích  $X_1, X_2, \dots, X_p$  của một đối tượng, một cách nào để phân đối tượng đó vào nhóm  $Y = 1$  hoặc nhóm  $Y = 0$ ?

*Câu trả lời*

Đề phân một đối tượng vào nhóm  $Y = 1$ , ta có thể tiếp cận theo hướng xác suất, tức là:

$$p(x) = \Pr(Y = 1 | X_1 = x_1, X_2 = x_2, \dots, X_p = x_p)$$

với  $x = (x_1, x_2, \dots, x_p)$ .

- nếu  $p(x)$  là lớn (tối đa 1), ta có thể chỉ định  $Y$  là 1;
- ngược lại, nếu  $p(x)$  là nhỏ (tối thiểu 0), ta có thể chỉ định  $Y$  là 0.



Như đã học ở phần trước, xác suất  $p(x)$  có thể được ước lượng thông qua mô hình hồi quy logistic:

$$p(x) = \frac{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}{1 + \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)}.$$

Sau khi xác định được các ước lượng  $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$  bằng phương pháp hợp lý cực đại, ta tính được

$$\hat{p}(\mathbf{x}) = \frac{\exp(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p)}{1 + \exp(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p)}$$

## Phân loại nhị phân

---

**Ví dụ:** Bệnh tim mạch vành - Coronary heart disease

Để phân biệt bệnh tim mạch vành với những đối tượng không mắc bệnh, một nghiên cứu trên 462 nam giới đã được thực hiện ở Western Cape, Nam Phi. Trong quá trình nghiên cứu, một số biến được thu thập:

- trạng thái bệnh tim mạch vành (chd): 1 (bị bệnh) hoặc 0 (không bị)
- huyết áp tâm thu (sbp)
- lượng thuốc lá tích lũy (tobacco)
- lượng cholesterol lipoprotein mật độ thấp (ldl)
- tiền sử gia đình về bệnh tim mạch vành (famhist): Absent hoặc Present
- tuổi (age)
- mức tiêu thụ rượu hiện tại (alcohol)
- và một số biến khác ...

Với thông tin của một người đàn ông về huyết áp tâm thu, lượng cholesterol lipoprotein mật độ thấp, lượng thuốc lá tích lũy và tiền sử gia đình mắc bệnh tim mạch vành, làm thế nào chúng ta có thể phân loại anh ta vào nhóm bị bệnh tim mạch vành?

1. *Journal of the American Medical Association*, 1997; 277: 1039-1043.

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160 161 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179 180 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215 216 217 218 219 220 221 222 223 224 225 226 227 228 229 230 231 232 233 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 250 251 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268 269 270 271 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286 287 288 289 290 291 292 293 294 295 296 297 298 299 300 301 302 303 304 305 306 307 308 309 310 311 312 313 314 315 316 317 318 319 320 321 322 323 324 325 326 327 328 329 330 331 332 333 334 335 336 337 338 339 340 341 342 343 344 345 346 347 348 349 350 351 352 353 354 355 356 357 358 359 360 361 362 363 364 365 366 367 368 369 370 371 372 373 374 375 376 377 378 379 380 381 382 383 384 385 386 387 388 389 390 391 392 393 394 395 396 397 398 399 400 401 402 403 404 405 406 407 408 409 410 411 412 413 414 415 416 417 418 419 420 421 422 423 424 425 426 427 428 429 430 431 432 433 434 435 436 437 438 439 440 441 442 443 444 445 446 447 448 449 450 451 452 453 454 455 456 457 458 459 460 461 462 463 464 465 466 467 468 469 470 471 472 473 474 475 476 477 478 479 480 481 482 483 484 485 486 487 488 489 490 491 492 493 494 495 496 497 498 499 500 501 502 503 504 505 506 507 508 509 510 511 512 513 514 515 516 517 518 519 520 521 522 523 524 525 526 527 528 529 530 531 532 533 534 535 536 537 538 539 540 541 542 543 544 545 546 547 548 549 550 551 552 553 554 555 556 557 558 559 560 561 562 563 564 565 566 567 568 569 570 571 572 573 574 575 576 577 578 579 580 581 582 583 584 585 586 587 588 589 590 591 592 593 594 595 596 597 598 599 600 601 602 603 604 605 606 607 608 609 610 611 612 613 614 615 616 617 618 619 620 621 622 623 624 625 626 627 628 629 630 631 632 633 634 635 636 637 638 639 640 641 642 643 644 645 646 647 648 649 650 651 652 653 654 655 656 657 658 659 660 661 662 663 664 665 666 667 668 669 670 671 672 673 674 675 676 677 678 679 680 681 682 683 684 685 686 687 688 689 690 691 692 693 694 695 696 697 698 699 700 701 702 703 704 705 706 707 708 709 710 711 712 713 714 715 716 717 718 719 720 721 722 723 724 725 726 727 728 729 730 731 732 733 734 735 736 737 738 739 740 741 742 743 744 745 746 747 748 749 750 751 752 753 754 755 756 757 758 759 760 761 762 763 764 765 766 767 768 769 770 771 772 773 774 775 776 777 778 779 780 781 782 783 784 785 786 787 788 789 790 791 792 793 794 795 796 797 798 799 800 801 802 803 804 805 806 807 808 809 810 811 812 813 814 815 816 817 818 819 820 821 822 823 824 825 826 827 828 829 830 831 832 833 834 835 836 837 838 839 840 841 842 843 844 845 846 847 848 849 850 851 852 853 854 855 856 857 858 859 860 861 862 863 864 865 866 867 868 869 870 871 872 873 874 875 876 877 878 879 880 881 882 883 884 885 886 887 888 889 890 891 892 893 894 895 896 897 898 899 900 901 902 903 904 905 906 907 908 909 910 911 912 913 914 915 916 917 918 919 920 921 922 923 924 925 926 927 928 929 930 931 932 933 934 935 936 937 938 939 940 941 942 943 944 945 946 947 948 949 950 951 952 953 954 955 956 957 958 959 960 961 962 963 964 965 966 967 968 969 970 971 972 973 974 975 976 977 978 979 980 981 982 983 984 985 986 987 988 989 990 991 992 993 994 995 996 997 998 999 1000 1001 1002 1003 1004 1005 1006 1007 1008 1009 1010 1011 1012 1013 1014 1015 1016 1017 1018 1019 1020 1021 1022 1023 1024 1025 1026 1027 1028 1029 1030 1031 1032 1033 1034 1035 1036 1037 1038 1039 1040 1

- 190

- 1.0

## Phân loại nhị phân

Cho trước giá trị của biến giải thích của các đối tượng, ta ước lượng được xác suất thuộc vào nhóm tim mạch vành:

| đối tượng | $x$ |         |     |         | $\hat{p}(x)$ |
|-----------|-----|---------|-----|---------|--------------|
|           | sbp | tobacco | ldl | famhist |              |
| 1         | 115 | 1       | 3   | Absent  | 0.105        |
| 2         | 145 | 8       | 9   | Absent  | 0.566        |
| 3         | 125 | 2       | 6   | Present | 0.439        |
| 4         | 135 | 5       | 8   | Present | 0.654        |

Tuy nhiên, các xác suất của các đối tượng 2 tới 4 là không thực sự lớn (gần 1)

↪ làm thế nào để đưa ra quyết định phân loại.

## Thực hiện phân loại

---

- Sau khi ước lượng được hệ số của mô hình ta dễ dàng ước tính được xác suất  $\hat{p}(x)$ , tức là xác suất  $Y = 1$  khi biết thông tin của các biến giải thích.
- Đặt  $\hat{C}(x)$  là kết quả được dự đoán của  $Y$  dựa trên giá trị của  $x$ .

*Quy tắc phân loại - Classification rule*

Quy tắc phân loại cho biến đáp ứng nhị phân được định nghĩa là

$$\hat{C}(x) = \begin{cases} 0 & \text{nếu } \hat{p}(x) \leq c \\ 1 & \text{nếu } \hat{p}(x) > c, \end{cases}$$

với  $c$  là một ngưỡng xác suất phân loại (threshold hoặc cutoff),  $c \in (0, 1)$ .

- Một cách chọn thông thường cho  $c$  là đặt  $c = 0.5$ .
- Nhưng trong thực tế, ngưỡng  $c$  có thể được chọn theo một số tiêu chuẩn cụ thể.

Ví dụ, xét  $c = 0.5$ . Dựa trên mô hình đã ước lượng, xác suất dự đoán và loại dự đoán của bốn trường hợp mới được trình bày dưới đây:

| đối tượng | $x$ |         |     |         | $\hat{p}(x)$ | $\hat{C}(x)$ | nhóm dự đoán   |
|-----------|-----|---------|-----|---------|--------------|--------------|----------------|
|           | sbp | tobacco | ldl | famhist |              |              |                |
| 1         | 115 | 1       | 3   | Absent  | 0.105        | 0            | non-diseased   |
| 2         | 145 | 8       | 9   | Absent  | 0.566        | 1            | heart diseased |
| 3         | 125 | 2       | 6   | Present | 0.439        | 0            | non-diseased   |
| 4         | 135 | 5       | 8   | Present | 0.654        | 1            | heart diseased |

## Đánh giá sự phân loại

Như đã được giới thiệu ở phần trước:

- ước lượng mô hình hồi quy là tương đối dễ dàng;
- việc tính xác suất dự đoán rồi áp dụng quy tắc phân loại là không quá khó khăn.

Tuy nhiên, trước khi áp dụng mô hình logistic và phân loại tương ứng, có một số câu hỏi quan trọng mà chúng ta phải giải quyết:

1. Hiệu quả của việc phân loại dựa trên mô hình logistic như thế nào?
2. Làm thế nào để chọn ngưỡng  $c$  tốt?

↪ Để giải quyết những câu hỏi này, chúng ta cần thực hiện một nhiệm vụ đánh giá, ở đó, chúng ta đánh giá độ chính xác của một sự phân loại (chẳng hạn, mô hình logistic).

|   | U   | V   | X   | Y   |
|---|-----|-----|-----|-----|
| U | 1   | 0.5 | 0.5 | 0.5 |
| V | 0.5 | 1   | 0.5 | 0.5 |
| X | 0.5 | 0.5 | 1   | 0.5 |
| Y | 0.5 | 0.5 | 0.5 | 1   |

1. *Journal of the American Medical Association*, 2000; 283: 2689-2696.

1. 2. 3. 4. 5. 6. 7. 8. 9. 10. 11. 12. 13. 14. 15. 16. 17. 18. 19. 20. 21. 22. 23. 24. 25. 26. 27. 28. 29. 30. 31. 32. 33. 34. 35. 36. 37. 38. 39. 40. 41. 42. 43. 44. 45. 46. 47. 48. 49. 50. 51. 52. 53. 54. 55. 56. 57. 58. 59. 60. 61. 62. 63. 64. 65. 66. 67. 68. 69. 70. 71. 72. 73. 74. 75. 76. 77. 78. 79. 80. 81. 82. 83. 84. 85. 86. 87. 88. 89. 90. 91. 92. 93. 94. 95. 96. 97. 98. 99. 100. 101. 102. 103. 104. 105. 106. 107. 108. 109. 110. 111. 112. 113. 114. 115. 116. 117. 118. 119. 120. 121. 122. 123. 124. 125. 126. 127. 128. 129. 130. 131. 132. 133. 134. 135. 136. 137. 138. 139. 140. 141. 142. 143. 144. 145. 146. 147. 148. 149. 150. 151. 152. 153. 154. 155. 156. 157. 158. 159. 160. 161. 162. 163. 164. 165. 166. 167. 168. 169. 170. 171. 172. 173. 174. 175. 176. 177. 178. 179. 180. 181. 182. 183. 184. 185. 186. 187. 188. 189. 190. 191. 192. 193. 194. 195. 196. 197. 198. 199. 200. 201. 202. 203. 204. 205. 206. 207. 208. 209. 210. 211. 212. 213. 214. 215. 216. 217. 218. 219. 220. 221. 222. 223. 224. 225. 226. 227. 228. 229. 230. 231. 232. 233. 234. 235. 236. 237. 238. 239. 240. 241. 242. 243. 244. 245. 246. 247. 248. 249. 250. 251. 252. 253. 254. 255. 256. 257. 258. 259. 260. 261. 262. 263. 264. 265. 266. 267. 268. 269. 270. 271. 272. 273. 274. 275. 276. 277. 278. 279. 280. 281. 282. 283. 284. 285. 286. 287. 288. 289. 290. 291. 292. 293. 294. 295. 296. 297. 298. 299. 300. 301. 302. 303. 304. 305. 306. 307. 308. 309. 310. 311. 312. 313. 314. 315. 316. 317. 318. 319. 320. 321. 322. 323. 324. 325. 326. 327. 328. 329. 330. 331. 332. 333. 334. 335. 336. 337. 338. 339. 340. 341. 342. 343. 344. 345. 346. 347. 348. 349. 350. 351. 352. 353. 354. 355. 356. 357. 358. 359. 360. 361. 362. 363. 364. 365. 366. 367. 368. 369. 370. 371. 372. 373. 374. 375. 376. 377. 378. 379. 380. 381. 382. 383. 384. 385. 386. 387. 388. 389. 390. 391. 392. 393. 394. 395. 396. 397. 398. 399. 400. 401. 402. 403. 404. 405. 406. 407. 408. 409. 410. 411. 412. 413. 414. 415. 416. 417. 418. 419. 420. 421. 422. 423. 424. 425. 426. 427. 428. 429. 430. 431. 432. 433. 434. 435. 436. 437. 438. 439. 440. 441. 442. 443. 444. 445. 446. 447. 448. 449. 450. 451. 452. 453. 454. 455. 456. 457. 458. 459. 460. 461. 462. 463. 464. 465. 466. 467. 468. 469. 470. 471. 472. 473. 474. 475. 476. 477. 478. 479. 480. 481. 482. 483. 484. 485. 486. 487. 488. 489. 490. 491. 492. 493. 494. 495. 496. 497. 498. 499. 500. 501. 502. 503. 504. 505. 506. 507. 508. 509. 510. 511. 512. 513. 514. 515. 516. 517. 518. 519. 520. 521. 522. 523. 524. 525. 526. 527. 528. 529. 530. 531. 532. 533. 534. 535. 536. 537. 538. 539. 540. 541. 542. 543. 544. 545. 546. 547. 548. 549. 550. 551. 552. 553. 554. 555. 556. 557. 558. 559. 560. 561. 562. 563. 564. 565. 566. 567. 568. 569. 570. 571. 572. 573. 574. 575. 576. 577. 578. 579. 580. 581. 582. 583. 584. 585. 586. 587. 588. 589. 590. 591. 592. 593. 594. 595. 596. 597. 598. 599. 600. 601. 602. 603. 604. 605. 606. 607. 608. 609. 610. 611. 612. 613. 614. 615. 616. 617. 618. 619. 620. 621. 622. 623. 624. 625. 626. 627. 628. 629. 630. 631. 632. 633. 634. 635. 636. 637. 638. 639. 640. 641. 642. 643. 644. 645. 646. 647. 648. 649. 650. 651. 652. 653. 654. 655. 656. 657. 658. 659. 660. 661. 662. 663. 664. 665. 666. 667. 668. 669. 670. 671. 672. 673. 674. 675. 676. 677. 678. 679. 680. 681. 682. 683. 684. 685. 686. 687. 688. 689. 690. 691. 692. 693. 694. 695. 696. 697. 698. 699. 700. 701. 702. 703. 704. 705. 706. 707. 708. 709. 710. 711. 712. 713. 714. 715. 716. 717. 718. 719. 720. 721. 722. 723. 724. 725. 726. 727. 728. 729. 730. 731. 732. 733. 734. 735. 736. 737. 738. 739. 740. 741. 742. 743. 744. 745. 746. 747. 748. 749. 750. 751. 752. 753. 754. 755. 756. 757. 758. 759. 760. 761. 762. 763. 764. 765. 766. 767. 768. 769. 770. 771. 772. 773. 774. 775. 776. 777. 778. 779. 780. 781. 782. 783. 784. 785. 786. 787. 788. 789. 790. 791. 792. 793. 794. 795. 796. 797. 798. 799. 800. 801. 802. 803. 804. 805. 806. 807. 808. 809. 810. 811. 812. 813. 814. 815. 816. 817. 818. 819. 820. 821. 822. 823. 824. 825. 826. 827. 828. 829. 830. 831. 832. 833. 834. 835. 836. 837. 838. 839. 840. 84

- [illegible]

[illegible]

Downloaded from <http://ajphaphysocpharm.sagepub.com/> at 11:06 11 September 2014



## Đánh giá sự phân loại

Quay trở lại với ví dụ tìm mạch vành, tại ngưỡng  $c = 0.5$ , ta xác định được confusion matrix:

|         |               | Thực sự       |         |
|---------|---------------|---------------|---------|
|         |               | không bị bệnh | bị bệnh |
| Dự đoán | không bị bệnh | 265           | 83      |
|         | bị bệnh       | 37            | 77      |

Giá trị specificity và sensitivity là

$$Sp(0.5) = \frac{265}{265 + 37} = 0.877, \quad Se(0.5) = \frac{77}{83 + 77} = 0.481$$

Bằng cách sử dụng  $c = 0.5$ , mô hình logistic được đề xuất đã phân loại chính xác 87.7% (đúng) đối tượng không mắc bệnh, nhưng chỉ phân loại chính xác 48.1% đối tượng mắc bệnh.

Vì vậy, sử dụng  $c = 0.5$  là không tốt để phân loại đối tượng bị bệnh. Chúng ta nên thay đổi sang giá trị khác của ngưỡng  $c$ .

Bây giờ ta thay đổi ngưỡng  $c = 0.25$ , confusion matrix lúc này:

|           |               | Thực sự       |         |
|-----------|---------------|---------------|---------|
|           |               | không bị bệnh | bị bệnh |
| Predicted | không bị bệnh | 167           | 32      |
|           | bị bệnh       | 135           | 128     |

Giá trị specificity và sensitivity là

$$\text{Sp}(0.25) = \frac{167}{167 + 135} = 0.553, \quad \text{Se}(0.25) = \frac{128}{128 + 32} = 0.800$$

Sử dụng  $c = 0.25$  thay vì 0.5, mô hình logistic được đề xuất có giá trị sensitivity cao (0.8), nhưng giá trị specificity thấp (0.553).

Vì vậy, sự lựa chọn  $c = 0.25$  vẫn không tốt.

---

- © 2001 Blackwell Science Ltd

1 9 ( )


(c)            (d)            (e)

1 6 6 1

## Đánh giá sự phân loại

Thông thường, đường cong ROC của mô hình logistic nằm phía trên đường tham chiếu, tức là đường chéo  $y = x$ .


- Sự cân bằng giữa sensitivity và specificity được hiển thị trên đường cong ROC.
- Nếu đường cong ROC trùng với đường tham chiếu thì  $AUC = 0.5$ , chúng ta có thể nói rằng việc phân loại dựa trên mô hình logistic là **sự đoán ngẫu nhiên**.
- Nếu đường cong ROC trùng góc trên bên trái thì  $AUC = 1$ , điều đó có nghĩa là việc phân loại dựa trên mô hình logistic có hiệu suất **hoàn hảo**.



Giá trị hợp lý của AUC thay đổi từ 0.5 đến 1. AUC càng cao thì khả năng dự đoán của mô hình càng tốt.

## Đánh giá sự phân loại

Đối với ví dụ về bệnh tim mạch vành, đường cong ROC ước lượng được biểu diễn như sau:



Giá trị AUC ước lượng: 0.7589, 95% khoảng tin cậy cho AUC: (0.7128, 0.8050).

## Đánh giá sự phân loại

*The evaluation rule of based on AUC*

Chúng ta có thể sử dụng quy tắc sau để đánh giá tính chính xác của mô hình logistic (hoặc một sự phân loại):

| AUC         | Tính chính xác     |
|-------------|--------------------|
| 0.5         | sự đoán ngẫu nhiên |
| (0.5, 0.65) | thiếu chính xác    |
| (0.65, 0.8) | chấp nhận được     |
| (0.8, 0.95) | tốt                |
| (0.95, 1)   | rất tốt            |
| 1           | hoàn hảo           |

Trong ví dụ của chúng ta, AUC ước tính là 0.7589, 95% khoảng tin cậy cho AUC (0.7128, 0.8050), do đó mô hình logistic có độ chính xác chấp nhận được để phân loại các đối tượng mắc bệnh tim mạch vành.

|    | 1 | 1 | 3 | 3 |
|----|---|---|---|---|
| 1  | 1 | 1 | 1 | 1 |
| 2  | 1 | 1 | 1 | 1 |
| 3  | 1 | 1 | 1 | 1 |
| 4  | 1 | 1 | 1 | 1 |
| 5  | 1 | 1 | 1 | 1 |
| 6  | 1 | 1 | 1 | 1 |
| 7  | 1 | 1 | 1 | 1 |
| 8  | 1 | 1 | 1 | 1 |
| 9  | 1 | 1 | 1 | 1 |
| 10 | 1 | 1 | 1 | 1 |
| 11 | 1 | 1 | 1 | 1 |
| 12 | 1 | 1 | 1 | 1 |
| 13 | 1 | 1 | 1 | 1 |
| 14 | 1 | 1 | 1 | 1 |
| 15 | 1 | 1 | 1 | 1 |
| 16 | 1 | 1 | 1 | 1 |
| 17 | 1 | 1 | 1 | 1 |
| 18 | 1 | 1 | 1 | 1 |
| 19 | 1 | 1 | 1 | 1 |
| 20 | 1 | 1 | 1 | 1 |
| 21 | 1 | 1 | 1 | 1 |
| 22 | 1 | 1 | 1 | 1 |
| 23 | 1 | 1 | 1 | 1 |
| 24 | 1 | 1 | 1 | 1 |
| 25 | 1 | 1 | 1 | 1 |
| 26 | 1 | 1 | 1 | 1 |
| 27 | 1 | 1 | 1 | 1 |
| 28 | 1 | 1 | 1 | 1 |
| 29 | 1 | 1 | 1 | 1 |
| 30 | 1 | 1 | 1 | 1 |
| 31 | 1 | 1 | 1 | 1 |
| 32 | 1 | 1 | 1 | 1 |
| 33 | 1 | 1 | 1 | 1 |
| 34 | 1 | 1 | 1 | 1 |
| 35 | 1 | 1 | 1 | 1 |
| 36 | 1 | 1 | 1 | 1 |
| 37 | 1 | 1 | 1 | 1 |
| 38 | 1 | 1 | 1 | 1 |
| 39 | 1 | 1 | 1 | 1 |
| 40 | 1 | 1 | 1 | 1 |
| 41 | 1 | 1 | 1 | 1 |
| 42 | 1 | 1 | 1 | 1 |
| 43 | 1 | 1 | 1 | 1 |
| 44 | 1 | 1 | 1 | 1 |
| 45 | 1 | 1 | 1 | 1 |
| 46 | 1 | 1 | 1 | 1 |
| 47 | 1 | 1 | 1 | 1 |
| 48 | 1 | 1 | 1 | 1 |
| 49 | 1 | 1 | 1 | 1 |
| 50 | 1 | 1 | 1 | 1 |
| 51 | 1 | 1 | 1 | 1 |
| 52 | 1 | 1 | 1 | 1 |
| 53 | 1 | 1 | 1 | 1 |
| 54 | 1 | 1 | 1 | 1 |
| 55 | 1 | 1 | 1 | 1 |
| 56 | 1 | 1 | 1 | 1 |
| 57 | 1 | 1 | 1 | 1 |
| 58 | 1 | 1 | 1 | 1 |
| 59 | 1 | 1 | 1 | 1 |
| 60 | 1 | 1 | 1 | 1 |
| 61 | 1 | 1 | 1 | 1 |
| 62 | 1 | 1 | 1 | 1 |
| 63 | 1 | 1 | 1 | 1 |
| 64 | 1 | 1 | 1 | 1 |
| 65 | 1 | 1 | 1 | 1 |
| 66 | 1 | 1 | 1 | 1 |
| 67 | 1 | 1 | 1 | 1 |
| 68 | 1 | 1 | 1 | 1 |
| 69 | 1 | 1 | 1 | 1 |
| 70 | 1 | 1 | 1 | 1 |
| 71 | 1 | 1 | 1 | 1 |
| 72 | 1 | 1 | 1 | 1 |
| 73 | 1 | 1 | 1 | 1 |
| 74 | 1 | 1 | 1 | 1 |
| 75 | 1 | 1 | 1 | 1 |
| 76 | 1 | 1 | 1 | 1 |
| 77 | 1 | 1 | 1 | 1 |
| 78 | 1 | 1 | 1 | 1 |
| 79 | 1 | 1 | 1 | 1 |
| 80 | 1 | 1 | 1 | 1 |
| 81 | 1 | 1 | 1 | 1 |
| 82 | 1 | 1 | 1 | 1 |
| 83 | 1 | 1 | 1 | 1 |
| 84 | 1 | 1 | 1 | 1 |
| 85 | 1 | 1 | 1 | 1 |
| 86 | 1 | 1 | 1 | 1 |
| 87 | 1 | 1 | 1 | 1 |
| 88 | 1 | 1 | 1 | 1 |
| 89 | 1 | 1 | 1 | 1 |
| 90 | 1 | 1 | 1 | 1 |
| 91 | 1 | 1 | 1 | 1 |
| 92 | 1 | 1 | 1 | 1 |
| 93 | 1 | 1 | 1 | 1 |
| 94 | 1 | 1 | 1 | 1 |
| 95 |   |   |   |   |

- chúng ta có thể nghĩ đến việc áp dụng mô hình vào thực tế.

$$c^* = \arg \max_{c \in (0,1)} \{Se(c) + Sp(c)\}$$
$$c^* = \arg \min_{c \in (0,1)} \sqrt{(1 - \text{Se}(c))^2 + (1 - \text{Sp}(c))^2}$$

## Lựa chọn ngưỡng

Trong ví dụ đang xét, ngưỡng tối ưu  $c^*$ , giá trị specificity và sensitivity tương ứng là:

| Phương pháp      | $c^*$ | $Sp(c^*)$ | $Se(c^*)$ |
|------------------|-------|-----------|-----------|
| Youden index     | 0.350 | 0.702     | 0.700     |
| Closest top left | 0.350 | 0.702     | 0.700     |

Bây giờ ta áp dụng mô hình logistic và  $c^* = 0.35$  để phân loại bốn trường hợp mới được xem xét ở trên:

| đối tượng | $x$ |         |     |         | $\hat{p}(x)$ | $\hat{C}(x)$ | nhóm dự đoán   |
|-----------|-----|---------|-----|---------|--------------|--------------|----------------|
|           | sbp | tobacco | ldl | famhist |              |              |                |
| 1         | 115 | 1       | 3   | Absent  | 0.105        | 0            | non-diseased   |
| 2         | 145 | 8       | 9   | Absent  | 0.566        | 1            | heart diseased |
| 3         | 125 | 2       | 6   | Present | 0.439        | 1            | heart diseased |
| 4         | 135 | 5       | 8   | Present | 0.654        | 1            | heart diseased |

Hãy nhớ rằng, đối tượng thứ ba được phân loại là không mắc bệnh khi ta sử dụng  $c = 0.5$ .



## Một số nhận xét

---

- Việc sử dụng mô hình logistic rất đơn giản và cho phép chúng ta dễ dàng diễn giải kết quả.
- Mô hình này có thể được mở rộng để tính đến sự tương tác có thể có giữa các biến và cả các số hạng phi tuyến tính.
- Trong trường hợp các biến giải thích lớn, để có được mô hình logistic tốt, chúng ta cần sử dụng một số phương pháp **selection variable**.
- Mô hình logistic chỉ áp dụng cho trường hợp biến đáp ứng nhị phân.
- Trong trường hợp phân loại với nhiều nhóm, ta có thể sử dụng một trong các phương pháp sau:
  1. Multinomial logistic regression
  2. Linear discriminant analysis
  3. Decision tree
  4. K-nearest neighbors