

Bài giảng 1: Mô hình hồi quy tuyến tính

TS. Tô Đức Khánh¹

¹*Khoa Toán - Tin học, Trường Đại học Khoa Học Tự Nhiên, Đại Học Quốc Gia, Tp. Hồ Chí Minh*

Ngày 14 tháng 12 năm 2023

Mục lục

1	Mô hình hồi quy tuyến tính	2
1.1	Giới thiệu	2
1.2	Ước lượng tham số	5
1.3	Tính chất phân phối của ước lượng	7
1.4	Thống kê suy luận cho mô hình hồi quy	11
1.4.1	Thống kê suy luận cho β	11
1.4.2	Phân tích phương sai	12
1.5	Hệ số xác định R^2	15
1.6	Phân tích thặng dư	16
2	Biến đổi Box-Cox	19

Bài giảng này nhằm ôn tập lại các kiến thức cơ bản của mô hình hồi quy tuyến tính - Linear Regression Models. Các kiến thức sẽ bao gồm: định nghĩa mô hình hồi quy tuyến, các phương pháp ước lượng, các phương pháp suy luận và kiểm định mô hình. Hơn nữa, bài giảng cũng sẽ trình bày về pháp biến đổi Box-Cox trong trường hợp giả định về phân phối chuẩn của biến đáp ứng bị vi phạm.

1 Mô hình hồi quy tuyến tính

1.1 Giới thiệu

Mô hình hồi quy thường được sử dụng để miêu tả sự thay đổi hoặc ước đoán giá trị của một (hoặc nhiều) biến đáp ứng (response variable) dựa vào thông tin của một hay nhiều biến giải thích khác (explanatory variables hoặc covariates). Trong thực tế, có nhiều dạng mô hình hồi quy, trong đó, mô hình hồi quy tuyến tính là dạng đơn giản và thường được sử dụng. Bây giờ, ta sẽ đi vào phần thiết lập cho mô hình hồi quy tuyến tính.

Ký hiệu Y là biến đáp ứng, $X_1, \dots, X_p$ là p biến giải thích ($p \geq 2$). Giả định rằng ta có một bộ dữ liệu với n quan sát $(Y_i, x_{1i}, \dots, x_{pi})$ với $i = 1, \dots, n$, của các biến $Y, X_1, \dots, X_p$:

- biến đáp ứng Y_i được coi như là biến ngẫu nhiên;
- bộ biến giải thích $x_{1i}, \dots, x_{pi}$, thường được coi như là cố định và được biết trước;
- ta giả định $n > p$.

Biến đáp ứng Y thường là **biến định lượng (quantitative variable)** hoặc biến số học (numerical variable) có thể là liên tục (tuổi, chiều cao, nồng độ cồn trong máu, cân nặng, v.v.) hoặc là rời rạc (số tuần trong năm, số lượng khách hàng, v.v.). Trong khi đó, các biến giải thích X_p có thể là biến định lượng nhưng cũng có thể là **biến định tính (qualitative variable)** tức là các biến có dạng phân loại - categorical (giới tính, trạng mắc bệnh, v.v.) hoặc có dạng phân loại thứ tự - ordinal (bậc học, mức độ khó của môn học, v.v.).

Mô hình hồi quy **tuyến tính** mô tả mối liên hệ giữa Y_i và các giá trị của các biến giải thích $x_{1i}, \dots, x_{pi}$ được viết như sau:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + \varepsilon_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i \quad (1.1)$$

trong đó:

- $\beta_0, \beta_1, \dots, \beta_p$ là các hệ số hồi quy chưa biết, với β_0 là hệ số chặn (intercept), β_p là hệ số dốc (slope) của biến giải thích X_p ;
- ε_i là sai số (hay thặng dư) không được quan sát của mô hình, các sai số này nhằm tính toán sự khác biệt giữa các giá trị quan sát được Y_i với phần ước đoán $\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi}$.
- $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ là một vectơ cỡ $p + 1$ của các tham số chưa biết,
- $\mathbf{x}_i = (1, x_{1i}, x_{2i}, \dots, x_{pi})^\top$ là một vectơ cỡ $p + 1$ chứa các giá trị của biến giải thích tương ứng với quan sát thứ i .

Ta ký hiệu:

- $\mathbf{Y} = (Y_1, \dots, Y_n)^\top$ là một vectơ chứa n giá trị quan sát được của Y ,

- $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^\top$ là một vectơ cỡ n chứa các phần tử ε_i ,
- $\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)^\top$ là ma trận thiết kế của mô hình, có cỡ $n \times (p+1)$.

Khi đó, mô hình hồi quy tuyến tính (1.1) sẽ có thể được trình bày theo dạng ma trận (tuyến tính) như sau:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (1.2)$$

Trong mô hình tuyến tính (1.1), các tác động hay hiệu ứng của X_p là các hiệu ứng cộng (additive effect), và hiệu ứng của biến X_k là độc lập với hiệu ứng của biến X_j (với $k \neq j$). Tức là, nếu biến X_k tăng một đơn vị, thì giá trị của Y_i sẽ thay đổi β_k đơn vị, khi các biến giải thích còn lại được cố định.

Nếu ta chỉ có 1 biến giải thích, tức là $p = 1$, thì ta sẽ có mô hình hồi quy tuyến tính đường thẳng (hay hồi quy tuyến tính đơn), tức là

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

Mô hình (1.1) có thể được tùy chỉnh theo nhiều dạng khác nhau, miễn sao cho giữ được cấu trúc hàm tuyến tính theo các thành phần β_j (với $j = 0, 1, 2, \dots, p$). Ví dụ, ta có thể có mô hình tuyến tính dạng mũ (polynomial regression) với một biến giải thích:

$$Y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_p x_i^p + \varepsilon_i,$$

hoặc ta cũng có thể có một mô hình dạng hỗn hợp

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i}^2 + \beta_3 \log(x_{3i}) + \varepsilon_i.$$

Trong một số trường hợp, biến đáp ứng Y có thể được biến đổi trước khi ta thực hiện phân tích mô hình hồi quy tuyến tính, ví dụ

$$\log(Y_i) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + \varepsilon_i,$$

nếu $Y_i > 0$ với mọi $i = 1, \dots, n$. Ở các ví dụ trên, ta đang quan sát các mô hình mà ở đó các biến giải thích là các biến định lượng, khi này khi ước lượng mô hình ta chỉ cần dùng các giá trị quan sát của các biến. Tuy nhiên, khi trong mô hình có sự hiện diện của biến giải thích dạng phân loại, ta không thể sử dụng giá trị quan sát của chúng khi thực hiện các tính toán, do các giá trị quan sát này vốn dĩ không phải là dạng số học. Do đó, khi thiết lập mô hình ta cần phải tạo ra một giả biến (hay dummy variable) để mô tả hay chuyển đổi biến giải thích dạng phân loại sang dạng số học (giả số học). Ví dụ, nếu ta xây dựng một mô hình có sử dụng một biến giải thích tình trạng hút thuốc có hai trạng thái: hút thuốc và không hút thuốc. Khi này, ta có một giả biến D_i sao cho $D_i = 0$ nếu người thứ i không hút thuốc; và $D_i = 1$ nếu người thứ i hút thuốc. Lúc này, ta có thể viết mô hình hồi quy với dạng:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 \mathbb{I}_{(D_i=1)} + \varepsilon_i,$$

trong đó, $\mathbb{I}$ là hàm chỉ định (indicator function), $\mathbb{I}_{(D_i=1)} = 1$ nếu $D_i = 1$, và bằng 0 nếu ngược lại. Khi này, ta có thể hiểu:

$$Y_i = \begin{cases} \beta_0 + \beta_1 x_{1i} + \varepsilon_i & \text{nếu người thứ } i \text{ không hút thuốc,} \\ \beta_0 + \beta_1 x_{1i} + \beta_2 + \varepsilon_i & \text{nếu người thứ } i \text{ hút thuốc,} \end{cases}$$

theo đó, β_2 sẽ mô tả lượng thay đổi trong Y_i nếu người thứ i hút thuốc so với khi người này không hút thuốc. Tương tự, nếu biến giải thích phân loại có nhiều hơn 2 loại (hay cấp độ), ví dụ là 3, khi đó, mô hình hồi quy tuyến tính sẽ có thể được viết như sau:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 \mathbb{I}_{(D_i=2)} + \beta_3 \mathbb{I}_{(D_i=3)} + \varepsilon_i,$$

trong đó, $\mathbb{I}_{(D_i=j)} = 1$ nếu $D_i = j$ với $j = 2$ hoặc 3 , và bằng 0 nếu $D_i = 1$. Tham số β_2 sẽ mô tả lượng thay đổi trong Y_i giữa mức 2 và mức 1 của biến giải thích; tham số β_3 sẽ mô tả lượng thay đổi trong Y_i giữa mức 3 và mức 1 của biến giải thích.

Trong một số trường hợp, các biến giải thích có thể có ảnh hưởng qua lại với nhau, điều này dễ xảy ra khi ta có một biến giải thích định lượng và một biến giải thích phân loại. Khi này, bên cạnh thành phần mô tả tác động của hai biến giải thích, mô hình hồi quy sẽ có thêm thành mô tả tác động của sự tương tác (interaction) giữa hai biến giải thích, ví dụ:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 \mathbb{I}_{(D_i=1)} + \beta_3 \mathbb{I}_{(D_i=1)} x_{1i} + \varepsilon_i,$$

khi này, mô hình được mô tả như sau:

$$Y_i = \begin{cases} \beta_0 + \beta_1 x_{1i} + \varepsilon_i & \text{nếu } D_i = 0, \\ \beta_0 + \beta_2 + (\beta_1 + \beta_3) x_{1i} + \varepsilon_i & \text{nếu } D_i = 1, \end{cases}$$

với mô tả này, ta nhận thấy rằng hiệu ứng của X_1 sẽ thay đổi tùy thuộc vào giá trị của biến giải thích phân loại, tức là hiệu ứng sẽ bằng β_1 nếu biến giải thích phân loại có giá trị là 0 , và hiệu ứng sẽ bằng $\beta_1 + \beta_3$ nếu biến giải thích phân loại có giá trị là 1 . Thành phần $\mathbb{I}_{(D_i=1)} x_{1i}$ chính là thành phần mô tả sự tương tác giữa hai biến giải thích, và β_3 là hệ số của sự tương tác.

Để thực hiện được ước lượng hệ số β trong mô hình hồi quy tuyến tính ta chỉ cần các giá trị quan sát $Y_i, x_{1i}, \dots, x_{pi}$ là có dạng số và ma trận thiết kế $\mathbf{X}$ là ma trận có hạng đầy đủ $p + 1$. Tuy nhiên, để có thể thực hiện các suy luận thống kê cho mô hình, ta cần có các giả định sau:

- (A1) Ma trận thiết kế $\mathbf{X}$ là ma trận không ngẫu nhiên và có hạng đầy đủ $p + 1$, và $n > p + 1$.
- (A2) Các thành phần sai số ε_i là không tương quan (tức là độc lập nhau), có kỳ vọng 0 , và có chung phương sai σ^2 , tức là:

$$\mathbb{E}(\varepsilon_i) = 0, \quad \text{Var}(\varepsilon_i) = \sigma^2, \quad \text{Cov}(\varepsilon_i, \varepsilon_k) = 0 \text{ với } i \neq k.$$

- (A3) Thông thường, cho các công việc thống kê suy luận (ví dụ như ước lượng điểm, ước tính khoảng tin cậy, kiểm định các giả thuyết thống kê), ta cần giả định rằng ε_i tuân theo một phân phối chuẩn, tức là $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

Chú ý rằng, điều kiện (A2) về phương sai chung σ^2 còn được biết đến với tên gọi điều kiện phương sai đồng nhất (homoscedasticity). Từ giả định về phân phối chuẩn của sai số ε_i , kết hợp với tính chất tuyến tính của phân phối chuẩn, ta suy ra $Y_i \sim \mathcal{N}(\mu_i, \sigma^2)$ với

$$\mu_i = \mathbb{E}(Y_i) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} = \mathbf{x}_i^\top \beta$$

là một hàm tuyến tính theo các tham số β_j (với $j = 0, 1, \dots, p$). Mặt khác, kết hợp điều kiện (A2) và (A3), ta có $\varepsilon \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, với $\mathbf{I}_n$ là ma trận đơn vị cỡ $n \times n$. Do đó, ta có thể viết $\mathbf{Y} \sim \mathcal{N}_n(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n)$, với $\boldsymbol{\mu} = \mathbf{X}\beta$.

1.2 Ước lượng tham số

Phương pháp ước lượng thông dụng cho hệ số mô hình β là phương pháp bình phương nhỏ nhất (Least Squares - LS). Với phương pháp này, ta sẽ cực tiểu hóa tổng bình phương sai số (sum of squared errors - SSE), tức là:

$$\begin{aligned}\hat{\beta} &= \arg \min_{\beta} \left\{ \sum_{i=1}^n \varepsilon_i^2 \right\} \\ &= \arg \min_{\beta} \left\{ \sum_{i=1}^n \left(Y_i - \mathbf{x}_i^\top \beta \right)^2 \right\} = \arg \min_{\beta} \text{SSE}(\beta)\end{aligned}$$

Việc cực tiểu hóa tương đương với việc giải phương trình đạo hàm riêng của $\text{SSE}(\beta)$ bằng $\mathbf{0}$, tức là,

$$\frac{\partial}{\partial \beta} \text{SSE}(\beta) = \sum_{i=1}^n \frac{\partial}{\partial \beta} \left(Y_i - \mathbf{x}_i^\top \beta \right)^2 = \mathbf{0}$$

Kết quả cho ra ước lượng LS:

$$\hat{\beta}_{\text{LS}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Một phương pháp ước lượng khác có thể dùng, đó là phương pháp ước lượng hợp lý cực đại (Maximum Likelihood - ML). Với phương pháp này, ước lượng của hệ số mô hình, $\hat{\beta}$, là điểm cực đại hóa hàm log của hàm hợp lý:

$$\hat{\beta} = \arg \max_{\beta} \ell(\beta, \sigma^2 | \mathbf{Y}),$$

trong đó, hàm $\ell(\beta, \sigma^2 | \mathbf{Y})$ được xây dựng dựa trên phân phối chuẩn của Y_i , tức là $Y_i \sim \mathcal{N}(\mathbf{x}_i^\top \beta, \sigma^2)$:

$$\ell(\beta, \sigma^2 | \mathbf{Y}) = \sum_{i=1}^n \left\{ -\frac{1}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \left(Y_i - \mathbf{x}_i^\top \beta \right)^2 \right\}.$$

Việc cực đại hóa tương đương với việc giải phương trình đạo hàm riêng của $\ell(\beta, \sigma^2 | \mathbf{Y})$ bằng $\mathbf{0}$, tức là,

$$\frac{\partial}{\partial \beta} \ell(\beta, \sigma^2 | \mathbf{Y}) = \sum_{i=1}^n \frac{\partial}{\partial \beta} \left(Y_i - \mathbf{x}_i^\top \beta \right)^2 = \mathbf{0}.$$

Từ đây, ta có thể thấy rằng, phương pháp bình phương nhỏ nhất và phương pháp ước lượng hợp lý cực đại là tương đương nhau dưới giả định của phân phối chuẩn. Hệ quả, ước lượng ML cũng là

$$\hat{\beta}_{\text{ML}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Chú ý rằng, ước lượng hợp lý cực đại hoạt động dưới giả định về phân phối của dữ liệu (hoặc sai số), tức là công thức ước lượng $\hat{\beta}_{\text{ML}}$ sẽ thay đổi theo phân phối của dữ liệu. Trong khi, công thức ước lượng $\hat{\beta}_{\text{LS}}$ sẽ không bị ảnh hưởng bởi dạng phân phối của dữ liệu. Do đó, trong các phần mềm thống kê, phương pháp LS thường được áp dụng để ước lượng mô hình hồi quy tuyến tính. Từ đây trở về sau, nếu không có gì nhầm lẫn, ước lượng $\hat{\beta}$ sẽ được hiểu là ước lượng $\hat{\beta}_{\text{LS}}$.

Ghi nhớ 1.1. Trong thực tế, ma trận thiết kế $\mathbf{X}$ có thể không có hạng đầy đủ, tức là $\text{rank}(\mathbf{X}) < p+1$ nếu có ít nhất hai cột là phụ thuộc tuyến tính lẫn nhau (hay có nghĩa là có ít nhất hai biến giải thích là phụ thuộc tuyến tính lẫn nhau). Vì $\text{rank}(\mathbf{X}) = \text{rank}(\mathbf{X}^\top \mathbf{X})$, nên $\mathbf{X}^\top \mathbf{X}$ cũng có hạng không đầy đủ. Điều này dẫn tới $(\mathbf{X}^\top \mathbf{X})^{-1}$ là không tồn tại. Khi đó, ta có thể sử dụng ma trận nghịch đảo tổng quát¹ (generalized inverse matrix) $(\mathbf{X}^\top \mathbf{X})^-$ của $\mathbf{X}^\top \mathbf{X}$ để tính $\hat{\boldsymbol{\beta}}$. Tuy nhiên, ma trận nghịch đảo tổng quát luôn luôn tồn tại mà không duy nhất, điều này dẫn tới ước lượng $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^- \mathbf{X}^\top \mathbf{Y}$ là không duy nhất. Mặt khác, nếu $n < p+1$ thì ma trận $\mathbf{X}^\top \mathbf{X}$ là suy biến, và do đó, ước lượng $\hat{\boldsymbol{\beta}}$ cũng không thể được xác định duy nhất.

Sau khi có được ước lượng $\hat{\boldsymbol{\beta}}$, ta dễ dàng thu được giá trị ước lượng $\hat{y}_i$ của quan sát Y_i , là $\hat{y}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$. Sai số không được quan sát, $\varepsilon_i = Y_i - \mathbf{x}_i^\top \boldsymbol{\beta}$, được ước lượng bởi *thặng dư* thứ i , tức là

$$\hat{e}_i = Y_i - \hat{y}_i = Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}.$$

Khi đó, ta có vectơ $\hat{\mathbf{e}} = (\hat{e}_1, \dots, \hat{e}_n)$ và $\hat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$. Từ đây, ta có thể viết được công thức biểu diễn của $\hat{\mathbf{e}}$ theo dạng tổ hợp tuyến tính của $\boldsymbol{\varepsilon}$, tức là:

$$\hat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} = (\mathbf{I}_n - \mathbf{H})\mathbf{Y} = (\mathbf{I}_n - \mathbf{H})(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = (\mathbf{I}_n - \mathbf{H})\boldsymbol{\varepsilon},$$

với $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$, và được gọi là ma trận “hat”. Kết quả trên có được là do $(\mathbf{I}_n - \mathbf{H})\mathbf{X} = \mathbf{0}$. Nhắc lại, vì ta giả định rằng $\boldsymbol{\varepsilon}$ tuân theo phân phối chuẩn, nên $\hat{\mathbf{e}}$ cũng tuân theo phân phối chuẩn với kỳ vọng $\mathbb{E}(\hat{\mathbf{e}}) = \mathbf{0}$, và ma trận hiệp phương sai $\text{Var}(\hat{\mathbf{e}}) = \sigma^2(\mathbf{I}_n - \mathbf{H})$. Tính chất này rất quan trọng vì nó cho phép chúng ta có thể kiểm định giả thuyết về phân phối chuẩn của $\boldsymbol{\varepsilon}$ thông qua các ước lượng thặng dư $\hat{\mathbf{e}}$.

Phương sai σ^2 được ước lượng bởi công thức

$$\hat{\sigma}^2 = \frac{1}{n-p-1} \sum_{i=1}^n \left(Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}} \right)^2 = \frac{\hat{\mathbf{e}}^\top \hat{\mathbf{e}}}{n-p-1} = \frac{1}{n-p-1} \text{SSE}(\hat{\boldsymbol{\beta}}). \quad (1.3)$$

Ước lượng này là ước lượng không chệch (xem trong Agresti, 2015, Phần 2.4.1, trang 49-50). Ngoài ra, ta cũng có thể sử dụng phương pháp ước lượng hợp lý cực đại, khi đó, $\hat{\sigma}_{\text{ML}}^2$ sẽ là nghiệm của phương trình

$$\frac{\partial}{\partial \sigma^2} \ell(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y}) = -\frac{n}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n \left(Y_i - \mathbf{x}_i^\top \boldsymbol{\beta} \right)^2 = 0.$$

Giải phương trình trên và thay thế tham số chưa biết $\boldsymbol{\beta}$ bằng ước lượng $\hat{\boldsymbol{\beta}}$, ta thu được

$$\hat{\sigma}_{\text{ML}}^2 = \frac{1}{n} \sum_{i=1}^n \left(Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}} \right)^2 = \frac{1}{n} \text{SSE}(\hat{\boldsymbol{\beta}}).$$


Tuy nhiên, ước lượng này là một ước lượng chệch, khi mà $\mathbb{E}(\hat{\sigma}_{\text{ML}}^2) = \frac{n-p-1}{n} \sigma^2$.

¹Nhắc lại rằng, đối với một ma trận $\mathbf{A}$, một ma trận $\mathbf{B}$ được gọi là ma trận nghịch đảo tổng quát của $\mathbf{A}$, nếu và chỉ nếu, $\mathbf{ABA} = \mathbf{A}$

1.3 Tính chất phân phối của ước lượng

Ở phần trên, ta đã tìm được công thức ước lượng của hệ số β bằng các phương pháp LS và ML. Tuy nhiên, cần phải nhận xét rằng, quan sát của biến đáp ứng Y là ngẫu nhiên, tức là với mỗi lần thu thập dữ liệu khác nhau, ta sẽ có các bộ giá trị quan sát Y_i khác nhau. Điều này dẫn tới ước lượng $\hat{\beta}$ tương ứng từng bộ dữ liệu sẽ khác nhau, hay nói cách khác $\hat{\beta}$ là một đại lượng ngẫu nhiên, và do đó, nó sẽ có các tính chất phân phối.

Ví dụ 1.2. Ta tạo mô phỏng bộ dữ liệu với 25 quan sát cho cặp (X, Y) , trong đó, $X \sim \mathcal{U}(-1, 1)$ và $Y = 1 + 2X + \varepsilon$, với $\varepsilon \sim \mathcal{N}(0, 1)$. Ta lặp lại việc tạo mẫu 30 lần, trong mỗi lần đó, ta ước lượng hệ số $\beta = (\beta_0, \beta_1)^\top$ cho mô hình hồi quy $Y = \beta_0 + \beta_1 X + \varepsilon$. Kết quả được mô tả trong Hình 1.



Hình 1 – Dữ liệu (X, Y) được tạo mô phỏng trong 30 lần (màu xám) và đường thẳng hồi quy ước lượng (màu xám) cho mô hình $Y = \beta_0 + \beta_1 X + \varepsilon$. Đường thẳng màu xanh biểu diễn đường hồi quy chính xác $Y = 1 + 2X$. Bấm nút play bên phải để chạy hình chuyển động (chỉ có thể xem bằng phần mềm đọc file pdf - Adobe Acrobat Reader).

Bây giờ, ta sẽ tìm hiểu tính chất phân phối của $\hat{\beta}$. Từ công thức ước lượng của $\hat{\beta}$, ta chứng minh được rằng, $\hat{\beta}$ là một tổ hợp tuyến tính của ε , tức là:

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X} \beta + \varepsilon) \\ &= \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon.\end{aligned}$$

Nếu các giả định (A1) - (A3) là đúng, ta có các tính chất sau:

1. $\widehat{\beta}$ là ước lượng không chệch, tức là $\mathbb{E}(\widehat{\beta}) = \beta$;
2. $\text{Var}(\widehat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$;
3. $\widehat{\beta} \sim \mathcal{N}_{p+1}(\beta, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$;
4. $\frac{1}{\sigma^2} (\widehat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\widehat{\beta} - \beta) \sim \chi_{p+1}^2$ (phân phối chi-bình phương với $p+1$ bậc tự do).

Chứng minh. Nhắc lại rằng theo điều kiện (A2), vectơ ε sẽ có kỳ vọng $\mathbb{E}(\varepsilon) = \mathbf{0}$ và ma trận hiệp phương sai $\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}_n$. Từ biểu thức biến đổi của $\widehat{\beta}$, ta suy ra:

$$\begin{aligned} \mathbb{E}(\widehat{\beta}) &= \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}(\varepsilon) = \beta \\ \text{Var}(\widehat{\beta}) &= \text{Cov} \left(\beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon, \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon \right) \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Cov}(\varepsilon, \varepsilon) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \end{aligned}$$

Do đó, ta suy ra được các tính chất 1 và 2. Mặt khác, vì ε có phân phối chuẩn, nên dẫn tới $\widehat{\beta}$ cũng tuân theo phân phối chuẩn (theo tính chất tổ hợp tuyến tính của phân phối chuẩn), như vậy, ta có tính chất 3. Để chứng minh tính chất 4, trước hết, ta biến đổi:

$$\frac{1}{\sigma^2} (\widehat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\widehat{\beta} - \beta) = \mathbf{U}^\top \mathbf{U},$$

với $\mathbf{U} = \frac{1}{\sigma} (\mathbf{X}^\top \mathbf{X})^{1/2} (\widehat{\beta} - \beta)$, $\mathbb{E}(\mathbf{U}) = \mathbf{0}$ và

$$\text{Var}(\mathbf{U}) = \frac{1}{\sigma} (\mathbf{X}^\top \mathbf{X})^{1/2} \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \frac{1}{\sigma} (\mathbf{X}^\top \mathbf{X})^{1/2} = \mathbf{I}_{p+1}.$$


hay $\mathbf{U} \sim \mathcal{N}_{p+1}(\mathbf{0}, \mathbf{I}_{p+1})$. Ta có $\mathbf{U}^\top \mathbf{U} = \sum_{i=0}^p U_i^2 \sim \chi_{p+1}^2$, với U_i là độc lập và $U_i \sim \mathcal{N}(0, 1)$. ■

Bên cạnh các tính chất trên, ta cũng nhắc tới một tính chất quan trọng khác, đó là định lý Gauss-Markov.

Định lý 1.3. (*Gauss-Markov theorem*) Nếu các giả định (A1) và (A2) là đúng, tức là ma trận thiết kế $\mathbf{X}$ là ma trận không suy biến, $\mathbb{E}(\varepsilon_i) = 0$, $\text{Var}(\varepsilon_i) = \sigma^2$ và $\text{Cov}(\varepsilon_i, \varepsilon_k) = 0$, thì ước lượng LS $\widehat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ là ước lượng tuyến tính không chệch tốt nhất (*best linear unbiased estimator - BLUE*) của β , tức là $\widehat{\beta}$ có phương sai nhỏ nhất trong tất cả các ước lượng tuyến tính của β .

Chứng minh. Phần chứng minh của định lý Gauss-Markov có thể được tham khảo trong [Agresti \(2015, Phần 2.7, trang 67\)](#). ■

Về mặt thực nghiệm, tính phân phối chuẩn của $\widehat{\beta}$ được kiểm tra bằng mô phỏng Monte Carlo. Ví dụ, ta tạo biến X với phân phối $\mathcal{U}(-1, 1)$, và biến Y theo mô hình $Y = 1 + 2X + \varepsilon$ với $\varepsilon \sim \mathcal{N}(0, 1)$. Ta tạo mẫu với $n = 25$ quan sát, và lặp lại việc tạo mẫu 1,000 lần. Trong mỗi lần, ta ước lượng các hệ số β_0 và β_1 của mô hình $Y = \beta_0 + \beta_1 X + \varepsilon$. Tổng hợp lại, ta có một bộ kết quả gồm 1,000 ước lượng β_0 và 1,000 ước lượng β_1 . Ta sẽ quan sát biểu đồ tần số và biểu đồ phân vị xác suất để đánh giá tính phân phối chuẩn của các ước lượng. Kết quả thể hiện trong Hình 2 cho thấy các ước lượng




Hình 2 – Biểu đồ tần số và biểu đồ phân vị xác suất của mẫu gồm 1,000 ước lượng $\hat{\beta}_0$ - hình (a) và (b); và của mẫu gồm 1,000 ước lượng $\hat{\beta}_1$ - hình (c) và (d), của mô hình $Y = \beta_0 + \beta_1 X + \varepsilon$ với $\varepsilon \sim \mathcal{N}(0, 1)$.

$\hat{\beta}_0$ và $\hat{\beta}_1$ phân bố quanh giá trị chính xác (đường màu xanh dương trong Hình 2 (a) và (b)), tức là $\beta_0 = 1$ và $\beta_1 = 2$ (giá trị trung bình mẫu của 1,000 ước lượng $\hat{\beta}_0$ là 0.9956 và của 1,000 ước lượng $\hat{\beta}_1$ là 2.0055); đồng thời chúng tuân theo phân phối chuẩn.

Tuy nhiên, nếu giả định (A3) về tính phân phối chuẩn của sai số ε bị vi phạm, thì kết quả về tính phân phối chuẩn của ước lượng $\hat{\beta}$ cũng sẽ không còn chính xác. Chẳng hạn, ta thực hiện một mô phỏng Monte Carlo, trong đó, biến đáp ứng Y được tạo từ mô hình $Y = 1 + 2X + \varepsilon$ với $X \sim \mathcal{U}(-1, 1)$ và $\varepsilon \sim t_3$ (phân phối t -student với 3 bậc tự do). Trong mô phỏng này, ta sẽ thực hiện với 4 kích cỡ mẫu khác nhau, lần lượt là $n = 25, 50, 100$ và 200 ; ta sẽ lặp lại việc tạo mẫu trong 1,000 lần. Hình 3 biểu diễn biểu đồ phân vị của 1,000 ước lượng $\hat{\beta}_1$, tương ứng với 4 kích thước mẫu khác nhau. Ta nhận thấy rằng, khi cỡ mẫu là nhỏ $n = 25, 50$ thì phân phối của $\hat{\beta}_1$ không xấp xỉ phân phối chuẩn, tuy nhiên khi cỡ mẫu tương đối lớn $n = 100, 200$, $\hat{\beta}_1$ xấp xỉ tiệm cận phân phối chuẩn (*asymptotic distribution*). Về mặt tổng quát, sự xấp xỉ tiệm cận phân phối chuẩn của ước lượng $\hat{\beta}$ thường yêu cầu cỡ mẫu tương đối lớn (thường là lớn hơn 100) hoặc thậm chí rất lớn. Do đó, trong áp dụng, khi cỡ mẫu nhỏ, ta sẽ phải rất chú ý tới giả định (A3) về phân phối chuẩn của sai số ε .

Từ công thức ước lượng $\hat{\sigma}^2$ (1.3), ta nhận thấy rằng σ^2 là hàm của các đại lượng ngẫu nhiên Y_i và $\hat{\beta}$, do đó, σ^2 cũng sẽ là một đại lượng ngẫu nhiên. Nếu các giả định (A1) - (A3) là đúng, ta có các tính chất như sau:



Hình 3 – Biểu đồ phân vị xác suất của mẫu gồm 1,000 ước lượng $\hat{\beta}_1$, tương ứng 4 cỡ mẫu khác nhau, của mô hình $Y = \beta_0 + \beta_1 X + \varepsilon$ với $\varepsilon \sim t_3$.

1. $\hat{\sigma}^2$ độc lập với $\hat{\beta}$;
2. $(n - p - 1)\hat{\sigma}^2/\sigma^2 \sim \chi_{n-p-1}^2$ (phân phối chi-bình phương với $n - p - 1$ bậc tự do).

Chứng minh. Để chứng minh tính chất 1, trước hết ta nhận xét rằng $\hat{\beta}$ độc lập với $\hat{e}$:

$$\begin{aligned} \text{Cov}(\hat{\beta}, \hat{e}) &= \text{Cov}\left(\beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon, (\mathbf{I}_n - \mathbf{H})\varepsilon\right) \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Cov}(\varepsilon, \varepsilon)(\mathbf{I}_n - \mathbf{H})^\top \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \sigma^2 \mathbf{I}_n (\mathbf{I}_n - \mathbf{H})^\top = \mathbf{0}. \end{aligned}$$

Kết quả này dẫn tới kết luận về tính độc lập của $\hat{\sigma}^2$ và $\hat{\beta}$. Để chứng minh tính chất 2, trước hết ta phân tích

$$\begin{aligned} \varepsilon^\top \varepsilon &= (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta) \\ &= (\mathbf{Y} - \mathbf{X}\hat{\beta} + \mathbf{X}\hat{\beta} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\hat{\beta} + \mathbf{X}\hat{\beta} - \mathbf{X}\beta) \\ &= \{\hat{e} + \mathbf{X}(\hat{\beta} - \beta)\}^\top \{\hat{e} + \mathbf{X}(\hat{\beta} - \beta)\} \\ &= \hat{e}^\top \hat{e} + (\hat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta). \end{aligned} \tag{1.4}$$

Biểu thức (1.4) được suy ra bởi tính chất $\hat{\boldsymbol{\varepsilon}}^\top \mathbf{X} = \boldsymbol{\varepsilon}^\top (\mathbf{I}_n - \mathbf{H})\mathbf{X} = \mathbf{0}$. Từ đây, ta suy ra

$$\boldsymbol{\varepsilon}^\top \boldsymbol{\varepsilon} / \sigma^2 = \hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}} / \sigma^2 + \left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \right)^\top \mathbf{X}^\top \mathbf{X} \left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \right) / \sigma^2.$$

Ta nhận thấy rằng $\boldsymbol{\varepsilon}^\top \boldsymbol{\varepsilon} / \sigma^2 = \sum_{i=1}^n \varepsilon_i^2 / \sigma^2 \sim \chi_n^2$, bởi vì ε_i / σ^2 là độc lập cùng phân phối chuẩn $\mathcal{N}(0, 1)$.

Mặt khác ta cũng đã chứng minh ở phần trước đó rằng $\left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \right)^\top \mathbf{X}^\top \mathbf{X} \left(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \right) / \sigma^2 \sim \chi_{p+1}^2$. Do đó, áp dụng tính chất rằng $\hat{\boldsymbol{\varepsilon}}$ và $\hat{\boldsymbol{\beta}}$ là độc lập, ta tính hàm sinh mô-men² hai vế của (1.4):

$$(1 - 2t)^{-n/2} = \mathbb{E} \left(\exp \left(t \hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}} / \sigma^2 \right) \right) \times (1 - 2t)^{-(p+1)/2},$$

với $t < 1/2$. Từ đây, ta có được hàm sinh mô-men của $\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}} / \sigma^2$ là:

$$\mathbb{E} \left(\exp \left(t \hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}} / \sigma^2 \right) \right) = (1 - 2t)^{-(n-p-1)/2},$$

điều này chứng tỏ rằng $\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}} / \sigma^2 \sim \chi_{n-p-1}^2$. Nhắc lại rằng, $(n - p - 1)\hat{\sigma}^2 = \hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}$, do đó, ta có được tính chất 2, và $\mathbb{E}(\hat{\sigma}^2) = \sigma^2$ (tính không chệch của $\hat{\sigma}^2$). ■

1.4 Thống kê suy luận cho mô hình hồi quy

Trong phần trước, ta đã trình bày về các phương pháp ước lượng cho hệ số $\boldsymbol{\beta}$ và σ^2 . Nhưng nếu chỉ ước lượng thì là chưa thể hoàn thành một phân tích thống kê cho mô hình hồi quy tuyến tính. Thêm vào đó, ta cần phải làm một số suy luận thống kê cho $\boldsymbol{\beta}$ dựa trên kết quả ước lượng của $\hat{\boldsymbol{\beta}}$ và tính chất phân phối của $\hat{\boldsymbol{\beta}}$. Cũng như thống kê suy luận cho giá trị tiên đoán $\hat{y}$ từ mô hình ước lượng; hay là so sánh độ hiệu quả của nhiều mô hình với nhau.

1.4.1 Thống kê suy luận cho $\boldsymbol{\beta}$

Đối với $\boldsymbol{\beta}$, ta thường quan tâm tới hai vấn đề sau:

- khoảng tin cậy cho các thành phần β_j của $\boldsymbol{\beta}$, với $j = 0, 1, \dots, p$;
- kiểm định giả thuyết liên quan tới một biến tiên đoán X_j

$$H_0 : \beta_j = 0 \quad \text{đối trọng với đối thuyết} \quad H_A : \beta_j \neq 0.$$

Các vấn đề này sẽ được giải quyết dựa trên các phân phối của $\hat{\boldsymbol{\beta}}$ và $\hat{\sigma}^2$ mà ta đã trình bày ở phần trước đó. Nhắc lại rằng, $\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{p+1}(\boldsymbol{\beta}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$, nên với phân tử $\hat{\beta}_j$ (với $j = 0, 1, \dots, p$) của $\hat{\boldsymbol{\beta}}$, ta có $\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 v_{jj})$ với v_{jj} là thành phần thứ j của đường chéo của ma trận $(\mathbf{X}^\top \mathbf{X})^{-1}$. Suy ra,

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\sigma^2 v_{jj}}} \sim \mathcal{N}(0, 1).$$

²Cho X là một biến ngẫu nhiên, tuân theo phân phối F . Hàm sinh mô-men (*moment-generating function*) của X được xác định là $\mathbb{E}(\exp(tX))$, nếu kỳ vọng này tồn tại với t nằm trong lân cận 0.

Với tính chất này ta có thể xây dựng khoảng tin cậy cho β_j cũng như thực hiện được kiểm định thống kê cho giả thuyết $H_0 : \beta_j = 0$ dựa trên phân phối chuẩn $\mathcal{N}(0, 1)$, nếu σ^2 được biết trước. Tuy nhiên, trong thực tế, ta chỉ biết thông tin về ước lượng $\hat{\sigma}^2$, khi đó, ta buộc phải thay thế σ^2 bằng $\hat{\sigma}^2$, và sẽ có

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 v_{jj}}} \sim t_{n-p-1},$$

phân phối t -student với $n - p - 1$ bậc tự do. Kết quả này³ có được là do $(n - p - 1)\hat{\sigma}^2/\sigma^2 \sim \chi_{n-p-1}^2$ và $\hat{\beta}_j$ là độc lập với $\hat{\sigma}^2$. Một khoảng tin cậy $(1 - \alpha)\%$ của β_j là

$$\left(\hat{\beta}_j - \hat{\sigma} v_{jj}^{1/2} t_{n-p-1, 1-\alpha/2}, \hat{\beta}_j + \hat{\sigma} v_{jj}^{1/2} t_{n-p-1, 1-\alpha/2} \right),$$

với $t_{n-p-1, 1-\alpha/2}$ là phân vị thứ $1 - \alpha/2$ của phân phối t -student với bậc tự do $n - p - 1$. Để kiểm định giả thuyết $H_0 : \beta_j = 0$, ta sử dụng thông kê kiểm định t (t-test statistic) sau

$$t = \frac{\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 v_{jj}}}.$$

Khi này, ta có p -value là $2\Pr(T \geq |t|)$, với T là một biến ngẫu nhiên tuân theo phân phối t_{n-p-1} . So sánh p -value với một mức ý nghĩa α , nếu p -value $< \alpha$, ta sẽ kết luận rằng dữ liệu ủng hộ việc loại bỏ giả thuyết H_0 , tức là biến giải thích X_j là hiệu dụng trong mô hình hồi quy tuyến tính cho việc giải thích sự thay đổi của Y ; ngược lại, nếu p -value $> \alpha$ ám chỉ rằng X_j là không cần thiết cho mô hình.

1.4.2 Phân tích phương sai

Trong phân tích mô hình hồi quy, ta thường quan tâm tới một câu hỏi rằng liệu tất cả các biến giải thích có ảnh hưởng tới biến đáp ứng Y , hay sẽ có một vài biến giải thích không có ảnh hưởng đáng kể (theo nghĩa thống kê) tới Y . Câu hỏi này tương đương với việc ta thực hiện một kiểm định thống kê về giả thuyết rằng tồn tại một vài tập con của β với tất cả thành phần bằng 0.

Giả sử rằng, ta thiết lập một mô hình hồi quy đầy đủ với p biến giải thích, tuy nhiên, trong đó chỉ có r biến có sự ảnh hưởng tới Y , và $p - r$ biến giải thích còn lại không có ảnh hưởng có nghĩa thống kê, tức là có hệ số bằng 0. Khi này, giả thuyết H_0 sẽ là $\beta_{p-r} = \mathbf{0}$. Nếu giả thuyết H_0 là đúng, ta sẽ có một mô hình con có r biến giải thích ($r \leq p$)

$$\mathbf{Y} = \tilde{\mathbf{X}}\boldsymbol{\gamma} + \tilde{\boldsymbol{\varepsilon}}, \quad (1.5)$$

trong đó, $\tilde{\mathbf{X}}$ là ma trận thiết kế cỡ $n \times (r + 1)$ của mô hình con, $\boldsymbol{\gamma} = (\gamma_0, \gamma_1, \dots, \gamma_r)$. Mô hình này tuy có ít biến giải thích hơn mô hình đầy đủ, nhưng vẫn đảm bảo ước lượng và giải thích được sự thay đổi của biến đáp ứng Y . Để thực hiện kiểm định giả thuyết H_0 này, ta sẽ ước lượng mô hình hồi quy đầy đủ tất cả p biến giải thích, và mô hình con có r biến giải thích, sau đó thực hiện kiểm định trên tổng bình phương sai số của hai mô hình.

Nhắc lại rằng, đối với mô hình đầy đủ

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

³Nếu $z \sim \mathcal{N}(0, 1)$ và $s \sim \chi_k^2$, nếu z và s là độc lập, thì $\frac{z}{\sqrt{s/k}} \sim t_k$ (phân phối t -student với bậc tự do k).

ta có ước lượng LS cho β là $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$, và tổng bình phương sai số là

$$\text{SSE}(\hat{\beta}) = \sum_{i=1}^n \left(Y_i - \mathbf{x}_i^\top \hat{\beta} \right)^2.$$

Đối với mô hình con (1.5), ta có ước lượng LS của γ là $\hat{\gamma} = (\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^\top \mathbf{Y}$, và tổng bình phương sai số tương ứng là

$$\text{SSE}(\hat{\gamma}) = \sum_{i=1}^n \left(Y_i - \tilde{\mathbf{x}}_i^\top \hat{\gamma} \right)^2.$$

Đặt $\text{SSE}_{\text{diff}} = \text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta})$ là tổng bình phương sai số thay đổi giữa mô hình con và mô hình đầy đủ. Về mặt ý tưởng, ta quan sát tỷ số $\text{SSE}_{\text{diff}}/\text{SSE}(\hat{\beta})$, nếu tỷ số này lớn, đồng nghĩa với $\text{SSE}(\hat{\gamma})$ lớn hơn nhiều so với $\text{SSE}(\hat{\beta})$. Điều này ám chỉ rằng mô hình con là không đúng. Ngược lại nếu tỷ số này là nhỏ thì có thể mô hình con là hợp lý và rằng $\beta_{p-r} = \mathbf{0}$. Để thực hiện được kiểm định thống kê, ta sẽ tìm phân phối của tỷ số $\text{SSE}_{\text{diff}}/\text{SSE}(\hat{\beta})$.

Nhận xét rằng

$$\text{SSE}(\hat{\beta}) = \hat{\mathbf{e}}^\top \hat{\mathbf{e}},$$

do đó, ta có $\text{SSE}(\hat{\beta})/\sigma^2 \sim \chi_{n-p-1}^2$. Nếu H_0 là đúng, ta sẽ có $\text{SSE}(\hat{\gamma})/\sigma^2 \sim \chi_{n-r-1}^2$. Đặt $\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta}$ và $\tilde{\mathbf{Y}} = \tilde{\mathbf{X}}\hat{\gamma}$ lần lượt là các ước lượng của biến đáp ứng trong mô hình đầy đủ và mô hình con. Vector thặng dư của mô hình đầy đủ là

$$\mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{H})\mathbf{Y},$$

và vector thặng dư của mô hình con được biểu diễn dưới dạng như sau:

$$\mathbf{Y} - \tilde{\mathbf{Y}} = \mathbf{Y} - \tilde{\mathbf{X}}\hat{\gamma} = \mathbf{Y} - \tilde{\mathbf{X}}(\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^\top \mathbf{Y} = (\mathbf{I} - \tilde{\mathbf{H}})\mathbf{Y},$$

với $\tilde{\mathbf{H}} = \tilde{\mathbf{X}}(\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^\top$. Đồng thời, ta cũng có

$$\mathbf{Y} - \tilde{\mathbf{Y}} = (\mathbf{Y} - \hat{\mathbf{Y}}) + (\hat{\mathbf{Y}} - \tilde{\mathbf{Y}}).$$

Ta nhận thấy rằng, $(\mathbf{Y} - \hat{\mathbf{Y}})^\top (\hat{\mathbf{Y}} - \tilde{\mathbf{Y}}) = 0$, nên vector $\mathbf{Y} - \hat{\mathbf{Y}}$ và vector $\hat{\mathbf{Y}} - \tilde{\mathbf{Y}}$ là trực giao với nhau và do đó là độc lập nhau. Áp dụng định lý Pythagoras⁴ cho tích vô hướng ta có

$$(\mathbf{Y} - \tilde{\mathbf{Y}})^\top (\mathbf{Y} - \tilde{\mathbf{Y}}) = (\mathbf{Y} - \hat{\mathbf{Y}})^\top (\mathbf{Y} - \hat{\mathbf{Y}}) + (\hat{\mathbf{Y}} - \tilde{\mathbf{Y}})^\top (\hat{\mathbf{Y}} - \tilde{\mathbf{Y}}).$$

Vế trái của biểu thức trên chính là $\text{SSE}(\hat{\gamma})$, trong khi đó, hai thành phần của vế phải chính là $\text{SSE}(\hat{\beta})$ và $\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta})$. Do đó, ta có

$$\text{SSE}(\hat{\gamma})/\sigma^2 = \text{SSE}(\hat{\beta})/\sigma^2 + \left(\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta}) \right) / \sigma^2. \quad (1.6)$$

Hơn nữa, do $\mathbf{Y} - \hat{\mathbf{Y}}$ và vector $\hat{\mathbf{Y}} - \tilde{\mathbf{Y}}$ là độc lập nhau, nên tổ hợp tuyến tính của chúng cũng sẽ độc lập nhau, tức là $\text{SSE}(\hat{\beta})$ độc lập với $\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta})$. ta tính hàm sinh mô-men hai vế của (1.6):

$$(1 - 2t)^{-(n-r-1)/2} = \mathbb{E} \left(\exp \left(t \left(\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta}) \right) / \sigma^2 \right) \right) \times (1 - 2t)^{-(n-p-1)/2},$$

⁴Với một tích vô hướng, Định lý Pythagoras phát biểu rằng, với hai vector trực giao $\mathbf{w}$ và $\mathbf{v}$ bất kỳ, ta có, $(\mathbf{w} + \mathbf{v})^\top (\mathbf{w} + \mathbf{v}) = \mathbf{w}^\top \mathbf{w} + \mathbf{v}^\top \mathbf{v}$.

với $t < 1/2$. Từ đây, ta có được hàm sinh mô-men của $(\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta})) / \sigma^2$ là:

$$\mathbb{E} \left(\exp \left(t \left(\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta}) \right) / \sigma^2 \right) \right) = (1 - 2t)^{-(p-r)/2},$$

điều này chứng tỏ rằng $(\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta})) / \sigma^2 \sim \chi_{p-r}^2$. Khi đó, ta có⁵

$$F = \frac{(\text{SSE}(\hat{\gamma}) - \text{SSE}(\hat{\beta})) / (p - r)}{\text{SSE}(\hat{\beta}) / (n - p - 1)} \sim F_{p-r, n-p-1}, \quad (1.7)$$

ở đây, $F_{p-r, n-p-1}$ là ký hiệu của phân phối F với hai bậc tự do là $p - r$ và $n - p - 1$. Do đó, để kiểm định giả định $H_0 : \beta_{p-r} = \mathbf{0}$, ta sẽ sử dụng thống kê F (F -statistic) như được định nghĩa ở trên. Như ta đã nói ở phần ý tưởng, nếu giả thuyết H_0 là sai, tức là $\beta_{p-r} \neq \mathbf{0}$, khi đó, F sẽ có thể tương đối lớn so với phân phối $F_{p-r, n-p-1}$. Vì thế, ta có p -value $= \Pr(W > F)$, với W là một biến ngẫu nhiên tuân theo phân phối $F_{p-r, n-p-1}$. Và do đó, việc thực hiện kiểm định giả thuyết H_0 với thống kê F tương đương với việc thực hiện phân tích phương sai (ANOVA).

Ví dụ 1.4. Nếu $r = 0$, thì khi đó giả thuyết H_0 là $\beta_1 = \beta_2 = \dots = \beta_p = 0$, và đối thuyết H_A sẽ là “tồn tại ít nhất 1 $\beta_j \neq 0$, với $j = 1, \dots, p$ ”. Nếu giả thuyết H_0 là đúng, thì mô hình con sẽ chỉ có duy nhất hệ số chặn β_0 , lúc này ta tất cả các biến giải thích là không có ảnh hưởng tuyến tính tới biến đáp ứng Y . Thống kê F sẽ là

$$F = \frac{(\text{SSE}(\hat{\beta}_0) - \text{SSE}(\hat{\beta})) / p}{\text{SSE}(\hat{\beta}) / (n - p - 1)} \sim F_{p, n-p-1}.$$

Nếu ta không thể bác bỏ giả thuyết H_0 , có nghĩa là tất cả p biến giải thích là không liên quan tới sự thay đổi hoặc sự biến động của biến đáp ứng Y . ■

Ví dụ trên trình bày về một trong những kiểm định thường được tiến hành trong phân tích mô hình hồi quy tuyến tính. Tiếp theo, ta sẽ trình bày về một kiểm định khác tổng quát hơn, có thể được sử dụng khi ta có nhiều hơn mô hình có thể dùng.

Ví dụ 1.5. Giả sử rằng ta muốn so sánh hai mô hình hồi quy tuyến tính, được đặt tên lần lượt là mô hình 1 (MH1) và mô hình 2 (MH2); trong đó, MH2 có số biến ít hơn so với MH1 và có thể chứa một dạng biểu diễn tuyến tính hạn chế của các tham số trong MH1, ví dụ:

$$(\text{MH1}) : Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \varepsilon_i,$$

và

$$(\text{MH2}) : Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{1i} x_{2i} + \varepsilon_i.$$

Giả sử MH1 có $p + 1$ hệ số (bao gồm p hệ số tương ứng của p biến giải thích và hệ số chặn), và MH2 có $q + 1$ hệ số. Giả thuyết H_0 mà ta quan tâm là “Mô hình với số biến ít hơn là tốt hơn.”. Nếu giả thuyết H_0 là đúng, khi đó, ta có thống kê F sẽ là

$$F = \frac{(\text{SSE}_{\text{MH2}} - \text{SSE}_{\text{MH1}}) / (p - q)}{\text{SSE}_{\text{MH1}} / (n - p - 1)} \sim F_{p-q, n-p-1},$$

trong đó, SSE_{MH1} và SSE_{MH2} lần lượt là tổng bình phương sai số của MH1 và MH2. ■

⁵Nếu X và Y là biến độc lập, $X \sim \chi_m^2$ và $Y \sim \chi_n^2$ thì $\frac{X/m}{Y/n} \sim F_{m,n}$, phân phối F với hai bậc tự do là m và n .

Ta cũng có thể áp dụng thống kê F vào việc kiểm tra xem liệu thêm một hoặc nhiều biến giải thích trong mô hình hồi quy có giúp cải thiện hiệu quả của mô hình hay không. Giả sử, ta có dãy mô hình sau đây:

$$\begin{aligned}(\text{MH0}) : \mathbf{Y} &= \mathbf{1}_n \beta_0 + \varepsilon \\(\text{MH1}) : \mathbf{Y} &= \mathbf{1}_n \beta_0 + X_1 \beta_1 + \varepsilon \\(\text{MH2}) : \mathbf{Y} &= \mathbf{1}_n \beta_0 + X_1 \beta_1 + X_2 \beta_2 + \varepsilon \\&\vdots \\(\text{MH}m) : \mathbf{Y} &= \mathbf{1}_n \beta_0 + X_1 \beta_1 + X_2 \beta_2 + \dots + X_m \beta_m + \varepsilon\end{aligned}$$

trong đó, mô hình 0 (MH0) chỉ có hệ số chặn, mô hình 1 (MH1) được xác định bằng cách thêm thành phần giải thích X_1 vào mô hình 0 (MH0), mô hình 2 (MH2) là mô hình 1 (MH1) được thêm thành phần X_2 , cứ như thế tới mô hình m (MH m); thành phần hằng số $\mathbf{1}_n$ là vectơ cột với n số 1; $X_1, X_2, \dots, X_m$ là ký hiệu của các thành phần tuyến tính của mô hình, chúng có thể là vectơ bao gồm các quan sát của một biến giải thích, nhưng cũng có thể là một ma trận thiết kế bao gồm nhiều biến giải thích khác nhau. Trong MH1, nếu hiệu ứng của thành phần X_1 lên biến đáp ứng là có nghĩa, thì điều đó có nghĩa là việc thêm thành phần X_1 vào MH0 giúp cải thiện hiệu quả của mô hình, khi đó tổng bình phương sai số trong MH1 sẽ giảm so với trong MH0. Ta có lập luận tương tự cho việc thêm các thành phần $X_2, X_3, \dots, X_m$. Như vậy để kiểm định xem liệu việc thêm thành phần X_r vào mô hình có giúp cải thiện mô hình hay không, ta sẽ đánh giá tỷ số giữa sự thay đổi trong tổng bình phương sai số của mô hình sau khi thêm X_r , được ký hiệu là $\text{SSE}_{\text{MH}r-1} - \text{SSE}_{\text{MH}r}$, với tổng bình phương sai số $\text{SSE}_{\text{MH}m}$ của mô hình MH m với tất cả các thành phần $X_1, \dots, X_m$

$$\frac{\text{SSE}_{\text{MH}r-1} - \text{SSE}_{\text{MH}r}}{\text{SSE}_{\text{MH}m}}.$$

Nếu tỷ số này lớn thì có nghĩa là $\text{SSE}_{\text{MH}r-1} > \text{SSE}_{\text{MH}r}$, và do đó việc thêm thành phần X_r giúp cải thiện mô hình.

Một cách tổng quát, ta có giả thuyết H_0 là “Mô hình không được cải thiện khi thêm thành phần X_r vào mô hình đã có các thành phần hằng số $\mathbf{1}_n, X_1, \dots, X_{r-1}$.”. Dưới giả định H_0 ta có thể chứng minh rằng $\text{SSE}_{\text{MH}m}$ là độc lập với $\text{SSE}_{\text{MH}r-1} - \text{SSE}_{\text{MH}r}$, đồng thời, $\text{SSE}_{\text{MH}m} \sim \chi^2_{\nu_m}$ và $\text{SSE}_{\text{MH}r-1} - \text{SSE}_{\text{MH}r} \sim \chi^2_{\nu_{r-1}-\nu_r}$, với ν_m, ν_r và ν_{r-1} lần lượt là các bậc tự do của mô hình MH m , MH r và MH $r-1$ (xem [Davison, 2003](#), Phần 8.5, trang 380). Khi đó, ta có thống kê F sau

$$F_r = \frac{(\text{SSE}_{\text{MH}r-1} - \text{SSE}_{\text{MH}r}) / (\nu_{r-1} - \nu_r)}{\text{SSE}_{\text{MH}m} / \nu_m} \sim F_{\nu_{r-1}-\nu_r, \nu_m},$$

và $p\text{-value}_r = \Pr(W > F_r)$. Tổng hợp lại, ta có bảng phân tích phương sai như sau:

1.5 Hệ số xác định R^2

Hệ số xác định (*the coefficient of determination*), R^2 , là một chỉ số đo tỷ lệ phần trăm phương sai của biến đáp ứng Y được giải thích bởi mô hình hồi quy tuyến tính. Chỉ số R^2 được xác định bởi

$$R^2 = 1 - \frac{\sum_{i=1}^n \left(Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}} \right)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2},$$

Bảng 1 – Bảng phân tích phương sai của các thành phần trong mô hình hồi quy

Thành phần được thêm	Bậc tự do	Sự thay đổi trong tổng bình phương sai số	F	p-value
X_1	$n - 1 - \nu_1$	$SSE_{MH0} - SSE_{MH1}$	$\frac{(SSE_{MH0} - SSE_{MH1}) / (n - 1 - \nu_1)}{SSE_{MHm} / \nu_m}$	$\Pr(W > F_1)$
X_2	$\nu_1 - \nu_2$	$SSE_{MH1} - SSE_{MH2}$	$\frac{(SSE_{MH1} - SSE_{MH2}) / (\nu_1 - \nu_2)}{SSE_{MHm} / \nu_m}$	$\Pr(W > F_2)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
X_m	$\nu_{m-1} - \nu_m$	$SSE_{MHm-1} - SSE_{MHm}$	$\frac{(SSE_{MHm-1} - SSE_{MHm}) / (\nu_{m-1} - \nu_m)}{SSE_{MHm} / \nu_m}$	$\Pr(W > F_m)$
Tất cả thành phần	ν_m	SSE_{MHm}	$\frac{SSE_{MHm}}{\nu_m}$	

trong đó $\bar{Y} = (1/n) \sum_{i=1}^n Y_i$, là trung bình mẫu của n quan sát $Y_1, \dots, Y_n$. Ta chứng minh được rằng, R^2 luôn nằm trong khoảng $(0, 1)$. Chỉ số R^2 càng gần 0, chứng tỏ rằng mô hình không đem lại kết quả tốt cho việc giải thích sự biến động của biến đáp ứng Y (tức là sự biến động của Y là ngẫu nhiên và không thể được giải thích bởi mô hình tuyến tính hiện tại); trong khi đó, nếu R^2 càng gần 1 thì mô hình giải thích tốt sự biến động của biến Y .

Tuy nhiên, hệ số R^2 có một nhược điểm đó là giá trị của nó luôn tăng khi ta thêm biến giải thích vào mô hình, mặc cho tác động của biến đó lên Y có nghĩa thống kê hay không. Điều này dẫn tới hệ quả là một mô hình với nhiều biến sẽ có R^2 lớn nhưng lại không phải một mô hình tốt. Do đó, nếu ta dựa vào chỉ số R^2 để nhận định và lựa chọn một mô hình là tốt, thì sẽ dẫn tới những kết luận sai lầm. Để tránh điều này, ta sẽ dùng chỉ số R^2 -điều chỉnh (*the adjusted R^2*), ký hiệu là R_a^2 :

$$R_a^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}})^2 / (n - p)}{\sum_{i=1}^n (Y_i - \bar{Y})^2 / (n - 1)} = 1 - \frac{n - 1}{n - p} (1 - R^2).$$

Hệ số R_a^2 sẽ có thể không tăng giá trị khi ta cho thêm biến giải thích vào mô hình, thậm chí, nó còn có thể giảm nếu thành phần được thêm vào là không có tác động có nghĩa lên biến Y . Trong một vài trường hợp, R_a^2 cũng vẫn có thể gần bằng R^2 , tuy nhiên điều này sẽ chỉ xảy ra khi các biến được thêm vào là đều có tác động có nghĩa tới biến Y , và rằng chúng là cần thiết cho mô hình.

1.6 Phân tích thẳng dư

Trong thực tế, luôn có sự khác biệt giữa dữ liệu và mô hình hồi quy, sự khác biệt này có thể mang tính đơn lẻ hoặc mang tính hệ thống. Sự khác biệt đơn lẻ xuất hiện khi dữ liệu có các giá trị ngoại lai (outliers), tức là các quan sát tương đối bất thường so với phần còn lại của dữ liệu. Trong khi đó, sự khác biệt mang tính hệ thống thường phát sinh trong một vài trường hợp, ví dụ như khi ta cần áp dụng phép đổi biến cho biến đáp ứng hoặc biến giải thích; hay khi sai số của mô hình là


không độc lập, hoặc khi các thành phần giải thích bị loại bỏ không chính xác. Có nhiều kỹ thuật khác nhau được sử dụng để phát hiện các vấn đề này, trong số đó, phân tích thặng dư dựa trên đồ thị là kỹ thuật được sử dụng rộng rãi.

Một mô hình hồi quy được coi là phù hợp với dữ liệu nếu các giả định sau được thỏa mãn:

- *tính tuyến tính* — biến đáp ứng phụ thuộc tuyến tính vào các biến giải thích và sai số, và không phụ thuộc vào bất kỳ thành phần giải thích bị bỏ qua nào;
- *tính độc lập* — các sai số ε_i là độc lập nhau;
- *phương sai đồng nhất* — các sai số ε_i có phương sai đồng nhất;
- *tính phân phối chuẩn* — sai số ε_i tuân theo phân phối chuẩn.

Nếu một trong số các giả định trên không thỏa mãn thì các suy luận thống kê cho mô hình hồi quy, bao gồm: kiểm định t , khoảng tin cậy cho hệ số hồi quy, kiểm định F sẽ không chính xác. Nhắc lại rằng, ta có $\hat{\mathbf{e}} = (\hat{e}_1, \hat{e}_2, \dots, \hat{e}_n)^\top$, với $\hat{e}_i = Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Để kiểm tra giả định về tính tuyến tính, ta vẽ đồ thị so sánh thặng dư $\hat{e}_i$ với giá trị ước lượng $\hat{y}_i$ (được gọi là Residual v.s. Fitted plot). Nếu như tính tuyến tính là đúng, khi đó các điểm trong đồ thị sẽ phân tán một cách ngẫu nhiên, không theo bất kỳ một hình dạng nào nhất định (hình cong, đường thẳng tăng hoặc giảm theo trục tọa độ), xem Hình 4. Ngược lại, tính tuyến tính là không chính xác, và ta cần phải xem xét áp dụng một số biến đổi cho biến đáp ứng hoặc các biến giải thích, hoặc xem xét một mô hình phi tuyến.



Hình 4 — Minh họa đồ thị so sánh thặng dư và giá trị ước lượng của mô hình. Hình (a) cho thấy các điểm phân bố ngẫu nhiên trong một vùng đồng nhất. Hình (b) biểu thị một xu hướng phân bố theo đường cong của các điểm trong đồ thị.


Tính độc lập của các sai số ε_i thường được kiểm tra thông qua các bước thu thập dữ liệu. Vấn đề này thường xuất hiện khi ta áp dụng mô hình hồi quy tuyến tính cho dữ liệu chuỗi thời gian (time series data), hay khi các đối tượng quan sát có mối liên hệ với nhau theo một đặc trưng nào đó, ví dụ, các thành viên trong cùng một gia đình, cây trồng trong cùng một chậu.

Giả định về phương sai đồng nhất có thể được kiểm tra bằng đồ thị so sánh $\sqrt{|r_i|}$ với giá trị ước lượng $\hat{y}_i$ (được gọi là đồ thị tỷ lệ-vị trí hay Scale-Location plot), ở đây, r_i là thặng dư tiêu chuẩn

hóa (standardized residuals) được xác định bởi

$$r_i = \frac{\hat{e}_i}{\sqrt{\hat{\sigma}^2(1 - h_{ii})}},$$

với h_{ii} là phần tử trên đường chéo của ma trận $\mathbf{H}$, $\hat{\sigma}^2$ là ước lượng không chệch của σ^2 . Ta dễ dàng chứng minh được rằng, các thặng dư tiêu chuẩn hóa r_i có trung bình bằng 0 và phương sai xấp xỉ 1, và do đó, chúng có thể so sánh với các biến phân phối chuẩn tắc. Khi quan sát đồ thị, nếu ta nhận thấy các điểm phân phối theo một dạng đường cong hoặc đường thẳng tăng hoặc giảm theo trục tọa độ, thì khi đó giả định về phương sai đồng nhất là không hợp lý. Một số đồ thị được thể hiện trong hình 5, trong đó, hình (a) cho thấy giả định về phương sai đồng nhất là có thể chấp nhận; trong khi đó, các hình (b), (c) và (d) cho thấy các trường hợp mà giả định về phương sai đồng nhất là không thực tế.



Hình 5 – Một số ví dụ cho đồ thị so sánh $\sqrt{|r_i|}$ với giá trị ước lượng $\hat{y}_i$ hay đồ thị tỷ lệ-vị trí.

Để kiểm tra tính phân phối chuẩn của sai số, ta sẽ vẽ đồ thị so sánh phân vị xác suất (QQ probability plot), trong đó ta so sánh phân vị xác suất của r_i với phân vị xác suất của biến ngẫu nhiên phân phối chuẩn tắc. Nếu các điểm trên đồ thị phân bố theo một đường chéo (từ góc dưới bên trái tới góc trên bên phải) thì khi đó ta có thể tin tưởng rằng tính phân phối chuẩn là hợp lý. Ngược lại, nếu đồ thị cho thấy một đường cong, thì có nghĩa là phân phối của sai số là một phân phối lệch, mặt khác, nếu các điểm ở phần đuôi nằm xa đường chéo thì lúc này phân phối của sai số có đuôi dài (long-tail error). Thông thường khi điều kiện về phân phối chuẩn không thỏa mãn, ta cần phải sử dụng một số phép biến đổi dữ liệu để hiệu chỉnh lại.

2 Biến đổi Box-Cox

Trong thực tế, khi áp dụng mô hình hồi quy tuyến tính cho dữ liệu, ta có thể gặp một số vấn đề:

- mô hình dạng tuyến tính không chính xác, tức là $\mu_i \neq \mathbf{x}_i^\top \boldsymbol{\beta}$;
- phương sai của sai số không đồng nhất $\text{Var}(\varepsilon_i) \neq \text{Var}(\varepsilon_k)$;
- giả định phân phối chuẩn không được thỏa mãn, tức $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

Có những cách khắc phục khác nhau, phụ thuộc vào vấn đề nào mà ta gặp phải. Chẳng hạn, nếu mô hình dạng tuyến tính không đúng, ta có thể xây dựng mô hình dạng phi tuyến, ví dụ,

$$Y_i = g(\mathbf{x}_i^\top \boldsymbol{\beta}) + \varepsilon_i,$$

với $g(\cdot)$ là một hàm phi tuyến bất kỳ. Hay nếu ta gặp phải trường hợp không đồng nhất phương sai, khi này, ta có thể sử dụng ước lượng trọng số bình phương nhỏ nhất (Weighted Least Square - WLS), khi đó, ta vẫn sẽ ước lượng mô hình hồi quy tuyến tính, tức là $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, tuy nhiên, $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{W})$ với $\mathbf{W} = \text{diag}(w_1, w_2, \dots, w_n)$, w_i là các trọng số cho từng quan sát được xác định trước. Trong trường hợp, giả định về phân phối chuẩn không được thỏa mãn, một số phép biến đổi dữ liệu, ví dụ biến đổi logarithm, biến đổi căn bậc hai hoặc căn bậc ba, có thể được sử dụng lên biến đáp ứng Y_i để hiệu chỉnh tính phân phối chuẩn.

Trong một số trường hợp, cả ba vấn đề liệt kê trên xuất hiện cùng một lúc, khi đó, nếu ta sử dụng các phương pháp ước lượng hiệu chỉnh đơn lẻ, sẽ gây ra sự chồng chéo trong quá trình tính toán cũng như giải thích kết quả. Thay vào đó, ta có thể sử dụng biến đổi Box-Cox⁶ để giải quyết cùng lúc các vấn đề trên (xem trong [Box và Cox, 1964](#)).

Một biến đổi Box-Cox có dạng như sau:

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda} & \text{nếu } \lambda \neq 0, \\ \log(y) & \text{nếu } \lambda = 0, \end{cases}$$

trong đó, $y > 0$, λ được gọi là tham số Box-Cox. Trong một số trường hợp, khi λ được biết trước, ta có một số biến đổi cụ thể như sau:

- $\lambda = 0 \hookrightarrow$ biến đổi logarithm, $\log(y)$;
- $\lambda = 1/2 \hookrightarrow$ biến đổi căn bậc hai, $\sqrt{y}$;
- $\lambda = 1/3 \hookrightarrow$ biến đổi căn bậc ba, $\sqrt[3]{y}$;
- $\lambda = -1 \hookrightarrow$ biến đổi ngược, $1/y$;

⁶Biến đổi Box-Cox (Box-Cox transformation) được phát triển bởi hai nhà thống kê học George E. P. Box (1919 - 2013) và Sir David R. Cox (1924 - 2022).

đặc biệt, nếu $\lambda = 1$ thì có nghĩa là không cần phải sử dụng biến đổi Box-Cox.

Ý tưởng áp dụng biến đổi Box-Cox vào mô hình hồi quy tuyến tính là thay thế biến đáp ứng Y_i bằng phiên bản biến đổi $Y_i^{(\lambda)}$, trong khi các thành phần của công thức hồi quy được giữ nguyên:

$$Y_i^{(\lambda)} = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i.$$

Với một giá trị phù hợp của λ , tính phân phối chuẩn của sai số ε_i sẽ được đảm bảo. Tuy nhiên, chú ý rằng, các hệ số hồi quy $\boldsymbol{\beta}$ sẽ thay đổi do lúc này ra đang ước lượng mô hình dựa trên biến đáp ứng đã biến đổi $Y_i^{(\lambda)}$. Điều này dẫn đến việc ta phải giải thích sự tác động của các biến giải thích X_j tương ứng với biến đáp ứng đã biến đổi $Y^{(\lambda)}$, thay vì là biến đáp ứng gốc Y . Mặt khác, ta cần phải áp dụng biến đổi ngược cho ước lượng tiên đoán trước khi sử dụng

$$y = \begin{cases} (\lambda y^{(\lambda)} + 1)^{1/\lambda} & \text{nếu } \lambda \neq 0, \\ \exp(y^{(\lambda)}) & \text{nếu } \lambda = 0. \end{cases}$$

Về mặt tổng quát, một giá trị thích hợp của λ tương ứng với một dữ liệu là không được biết trước, thay vào đó, ta cần phải ước lượng dựa trên thông tin của dữ liệu. Để ước lượng λ , ta sẽ sử dụng ước lượng hợp lý cực đại (ML) dựa trên thông tin của hàm mật độ phân phối chuẩn. Thật vậy, dưới biến đổi Box-Cox, ta có $Y_i^{(\lambda)} \sim \mathcal{N}(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2)$ và hàm mật độ cho biến đáp ứng biến đổi $Y_i^{(\lambda)}$ là

$$f_\lambda(Y_i^{(\lambda)}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2} (Y_i^{(\lambda)} - \mathbf{x}_i^\top \boldsymbol{\beta})^2\right).$$

Áp dụng công thức đổi biến hàm mật độ xác suất⁷ ta có hàm mật độ của biến áp ứng Y_i sẽ là

$$f(Y_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2} (Y_i^{(\lambda)} - \mathbf{x}_i^\top \boldsymbol{\beta})^2\right) Y_i^{\lambda-1}.$$

Từ đây, ta có hàm log của hàm hợp lý

$$\ell(\boldsymbol{\beta}, \sigma^2, \lambda | \mathbf{Y}) = -\frac{n \log(\sigma^2)}{2} - \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i^{(\lambda)} - \mathbf{x}_i^\top \boldsymbol{\beta})^2 + (\lambda - 1) \sum_{i=1}^n \log(Y_i).$$

Khi cố định λ , ta dễ dàng chứng minh được rằng ước lượng ML của $\boldsymbol{\beta}$ và σ^2 lần lượt là

$$\hat{\boldsymbol{\beta}}_{\text{ML},\lambda} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}^{(\lambda)} \quad \text{và} \quad \hat{\sigma}_{\text{ML},\lambda}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i^{(\lambda)} - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{ML},\lambda})^2.$$

Thay thế hai giá trị ước lượng này vào hàm $\ell(\boldsymbol{\beta}, \sigma^2, \lambda | \mathbf{Y})$, ta sẽ có được hàm log của hàm hợp lý lẻ (*profile log likelihood*) cho λ , tức là

$$\ell_p(\lambda | \mathbf{Y}) = \ell(\hat{\boldsymbol{\beta}}_{\text{ML},\lambda}, \hat{\sigma}_{\text{ML},\lambda}^2, \lambda | \mathbf{Y}) = -\frac{n}{2} \log\left(\frac{1}{n} \sum_{i=1}^n (Y_i^{(\lambda)} - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{\text{ML},\lambda})^2\right) + (\lambda - 1) \sum_{i=1}^n \log(Y_i).$$


⁷Gọi X là một biến ngẫu nhiên có hàm mật độ xác suất liên tục $f_X(\cdot)$. Đặt $Y = g(X)$ là một biến đổi đồng biến của X . Khi đó, ta có hàm mật độ của Y được xác định bởi $f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$.

Một ước lượng $\hat{\lambda}$ sẽ được tìm bằng phương pháp tìm kiếm lưới (*grid search*), thông thường là trên đoạn $[-2, 2]$. Khoảng tin cậy $100(1 - \alpha)\%$ của λ được xác định bởi tập hợp $\mathcal{R}_\lambda$:

$$\mathcal{R}_\lambda = \left\{ \lambda : \ell_p(\lambda|\mathbf{Y}) \geq \ell_p(\hat{\lambda}|\mathbf{Y}) - 0.5\chi_{1,1-\alpha}^2 \right\},$$

với $\chi_{1,1-\alpha}^2$ là phân vị thứ $(1 - \alpha)$ của phân phối χ_1^2 . Khoảng tin cậy trên được xây dựng dựa vào kết quả về phân phối tiệm cận của tỷ lệ hợp lý (*likelihood ratio*), xem thêm trong Pawitan (2001, Chương 9.5, trang 243 - 244). Như vậy, ứng với mỗi giá trị $\hat{\lambda}$ ta sẽ có một bộ giá trị ước lượng của hệ số β cũng như phương sai σ^2 .

Ví dụ 2.1. Hình 6 mô tả hàm $\ell_p(\lambda|\mathbf{Y})$ và khoảng tin cậy 95% cho λ cho từng trường hợp dữ liệu và mô hình khác nhau.



Hình 6 – Hàm log của hàm hợp lý $\ell_p(\lambda|\mathbf{Y})$ (đường nét liền màu đen), $\ell_p(\hat{\lambda}|\mathbf{Y}) - 0.5\chi_{1,1-0.05}^2$ - đường ngang nét đứt, và khoảng tin cậy 95% cho tham số Box-Cox λ .

Trong trường hợp đầu tiên, Hình 6 (a), ước lượng $\hat{\lambda} = 0.95$, và khoảng tin cậy 95% chứa 1, điều này có nghĩa là ta có thể không cần sử dụng biến đổi Box-Cox trong trường hợp này. Trong trường hợp thứ 2, Hình 6 (b), ước lượng $\hat{\lambda} = 0.31$, và ta nhận thấy rằng giá trị $1/3$ thuộc vào khoảng tin cậy 95%. Do đó, ta có thể sử dụng một biến đổi Box-Cox với $\lambda = 1/3$ (biến đổi căn bậc ba). Đối với trường hợp thứ 3, Hình 6 (c), ta có thể sử dụng một biến đổi logarithm, với $\lambda = 0$, do giá trị này nằm trong khoảng tin cậy 95%. Với trường hợp cuối cùng, Hình 6 (d), ta có thể áp dụng biến đổi Box-Cox với $\lambda = -1$ (biến đổi nghịch đảo).

Qua ví dụ trên ta nhận thấy rằng, các giá trị ước lượng $\hat{\lambda}$ ít khi được áp dụng, thay vào đó ta thường dùng các giá trị khác nằm trong khoảng tin cậy của λ , để có thể dễ giải thích hơn. Ví dụ dưới đây sẽ cho thấy sự tác động của biến đổi Box-Cox lên kết quả của một mô hình hồi quy tuyến tính.

Ví dụ 2.2. Ta xét bộ dữ liệu thu được từ thiết kế thí nghiệm 2 nhân tố (được báo cáo trong nghiên cứu [Box và Cox, 1964](#)) về thời gian sống sót của 48 động vật trong vòng 10 giờ dưới sự tác động của 3 loại chất độc và 4 phương pháp trị liệu. Các động vật nghiên cứu được chia thành 12 nhóm, mỗi nhóm có 4 đối tượng. Mỗi nhóm sẽ được tiếp xúc với một trong số ba loại chất độc, và đồng thời là một phương pháp trị liệu (được đặt tên: A, B, C và D). Dữ liệu thời gian sống sót của các đối tượng được tổng hợp như bảng dưới đây.

Bảng 2 – Dữ liệu thời gian sống sót của 48 động vật dưới tác động của 3 chất độc và 4 phương pháp trị liệu.

Phương pháp	Chất độc 1	Chất độc 2	Chất độc 3
A	0.31, 0.45, 0.46, 0.43	0.36, 0.29, 0.40, 0.23	0.22, 0.21, 0.18, 0.23
B	0.82, 1.10, 0.88, 0.72	0.92, 0.61, 0.49, 1.24	0.30, 0.37, 0.38, 0.29
C	0.43, 0.45, 0.63, 0.76	0.44, 0.35, 0.31, 0.40	0.23, 0.25, 0.24, 0.22
D	0.45, 0.71, 0.66, 0.62	0.56, 1.02, 0.71, 0.38	0.30, 0.36, 0.31, 0.33

Ta xét mô hình hồi quy tuyến tính sau đây, để giải thích sự tác động của chất độc và phương pháp trị liệu tới thời gian sống sót của động vật:

$$y_{tpj} = \mu + \alpha_t + \beta_p + \varepsilon_{tpj}, \quad t = 1, 2, 3, 4; p = 1, 2, 3; j = 1, 2, 3, 4.$$

Các hệ số của mô hình được giải thích như sau:

- y_{tpj} là các giá trị thời gian sống sót của động vật;
- μ đại diện trung bình thời gian sống sót của động vật khi không tiếp xúc với chất độc hay phương pháp điều trị;
- α_t biểu thị hiệu ứng của phương pháp điều trị thứ t ;
- β_p là hiệu ứng của chất độc p ;
- ε_{tpj} là sai số của mô hình.

Kết quả ước lượng mô hình (thực hiện với phần mềm R) có kết quả như sau:

```


Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.45229    0.05592   8.088 4.22e-10 ***
treatB       0.36250    0.06458   5.614 1.43e-06 ***
treatC       0.07833    0.06458   1.213  0.23189
treatD       0.22000    0.06458   3.407  0.00146 **

```

```
poison2    -0.07313    0.05592   -1.308   0.19813
poison3    -0.34125    0.05592   -6.102  2.83e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.1582 on 42 degrees of freedom
Multiple R-squared:  0.6503, Adjusted R-squared:  0.6087
```

Dựa trên kết quả, một cách sơ bộ ta thấy rằng chất độc 3 có tác động tiêu cực nhất tới thời gian sống sót của động vật. Bây giờ, ta sẽ quan sát phân tích thặng dư của mô hình để xem liệu rằng các phân tích suy luận thống kê trên có vững chắc.



Hình 7 – Biểu đồ phân tích thặng dư của mô hình phân tích ảnh hưởng chất độc và phương pháp điều trị lên thời gian sống sót của động vật.

Như được hiển thị trong Hình 7 (a), ta thấy rằng thặng dư phân bố gần như một đường cong. Đặc biệt, các thặng dư tương ứng với giá trị lớn của $\hat{y}_{tpj}$ có xu hướng phân tán rộng hơn so với các điểm tương ứng với các giá trị nhỏ của $\hat{y}_{tpj}$. Điều này cho thấy dạng tuyến tính mà ta đã xét là không hợp lý. Hình 7 (b) chứng minh tính phân phối chuẩn của sai số là không được thỏa mãn. Hơn nữa, giả định về phương sai đồng nhất cũng không hợp lý, như được minh chứng trong Hình 7 (c). Sau đây, ta sẽ áp dụng biến đổi Box-Cox để xem liệu các vấn đề này có được khắc phục hay không.



Hình 8 – Ước lượng và khoảng tin cậy cho tham số Box-Cox λ , hình (a); phân tích thặng dư cho mô hình biến đổi Box-Cox với $\lambda = -1$, hình (b)-(d).

Hình 8 (a) cho thấy ta có thể dùng $\lambda = -1$ cho việc biến đổi. Khi đó, ta sẽ ước lượng mô hình dự đoán tác động của chất độc và phương pháp điều trị lên tốc độ chết của động vật, tức là $1/y$. Hình 8 (b)-(d) biểu thị cho kết quả phân tích thặng dư của mô hình sau khi sử dụng biến đổi Box-Cox với $\lambda = -1$. Kết quả cho thấy các giả định của mô hình lúc này dường như có thể chấp nhận. Mặt khác, kết quả ước lượng của mô hình cũng cho thấy sự cải thiện đáng kể khi so với mô hình ban đầu.

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.6977	0.1744	-9.737	2.47e-12 ***
treatB	1.6574	0.2013	8.233	2.66e-10 ***
treatC	0.5721	0.2013	2.842	0.00689 **
treatD	1.3583	0.2013	6.747	3.35e-08 ***
poison2	-0.4686	0.1744	-2.688	0.01026 *
poison3	-1.9964	0.1744	-11.451	1.69e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4931 on 42 degrees of freedom

Multiple R-squared: 0.8441, Adjusted R-squared: 0.8255

Tài liệu tham khảo

Agresti, A. (2015). *Foundations of linear and generalized linear models*. John Wiley & Sons.

Box, G. E. P., & Cox, D. R. (1964). An Analysis of Transformations (with discussion). *Journal of the Royal Statistical Society. Series B (Methodological)*, 26(2), 211-252.

Davison, A. C. (2003). *Statistical models*. Cambridge University Press.

Pawitan, Y. (2001). *In all likelihood: statistical modelling and inference using likelihood*. Oxford University Press.