

Bài giảng R, số 2

-Khoảng tin cậy cho trung bình và tỷ lệ-

TS.Tô Đức Khánh

02/10/2023

Trong bài này, ta sẽ học cách xây dựng và tính khoảng tin cậy cho trung bình của một biến định lượng, và cho tỷ lệ của một thể loại của biến định tính.

1 Khoảng tin cậy cho tỷ lệ

Tỷ lệ là một trong những tham số quan trọng thể hiện xu hướng của một hoặc một vài thể loại nhất định của một biến thể loại (biến định tính). Các bài toán liên quan tới ước tính tỷ lệ, hay ước lượng khoảng tin cậy cho tỷ lệ thường được bắt gặp trong các bài toán sinh học di truyền, hay sinh học quần thể, hoặc sinh thái học, nên mà các biến thể loại của đối tượng được quan tâm.

1.1 Nhắc lại lý thuyết

Giả sử ta có một biến định tính (biến phân loại) Y với K thể loại, khi đó, với mỗi thể loại ta sẽ có một tỷ lệ được ký hiệu là p_k , với $k = 1, \dots, K$. Ước lượng của tỷ lệ p_k là tỷ lệ mẫu $\hat{p}_k$, được tính bởi công thức:

$$\hat{p}_k = \frac{n_k}{n},$$

trong đó, n_k là số lượng quan sát trong nhóm thể loại k , và n là số lượng đối tượng được quan sát. Tổng của tất cả các ước lượng tỷ lệ sẽ bằng 1, tức là


$$\hat{p}_1 + \hat{p}_2 + \dots + \hat{p}_K = 1.$$

Nhắc lại rằng, một khoảng tin cậy có dạng (a, b) là một phạm vi giá trị hợp lý nhất của tham số, dựa trên dữ liệu. Đối với tỷ lệ p , khoảng tin cậy (a, b) sẽ không được phép lớn hơn $(0, 1)$. Một khoảng tin cậy là hiệu quả nếu xác suất phủ của nó xấp xỉ với mức tin cậy (ví dụ, 0.95).

Theo tính chất tiệm cận phân phối chuẩn của ước lượng tỷ lệ ta có, $\hat{p}_k \xrightarrow{d} \mathcal{N}\left(p_k, \frac{p_k(p_k-1)}{n}\right)$, n tiến tới ∞ . Áp dụng, kết quả này, ta có thể xây dựng khoảng tin cậy $(1 - \alpha) \times 100\%$ cho tỷ lệ p_k như sau:

$$\left(\hat{p}_k - z_{(1-\alpha)/2} \sqrt{\frac{\hat{p}_k(\hat{p}_k - 1)}{n}}, \hat{p}_k + z_{(1-\alpha)/2} \sqrt{\frac{\hat{p}_k(\hat{p}_k - 1)}{n}} \right).$$

Khoảng tin cậy này được đặt tên là khoảng tin cậy Wald. Tuy nhiên, khoảng tin cậy Wald chỉ độ chính xác cao khi cỡ mẫu n lớn, và khi tỷ lệ không gần 0 hoặc 1. Xem hình 1, minh họa kết quả mô phỏng cho xác suất phủ của khoảng tin cậy Wald 95% cho tỷ lệ p , xét trường hợp $Y \sim \mathcal{B}(1, p)$, với $p = 0.05, 0.1, \dots, 0.95$. Cỡ mẫu n thay đổi từ 5, 10, 15 và 30. Mỗi lần ta tạo ngẫu nhiên một mẫu ngẫu nhiên với cỡ mẫu n theo phân phối $\mathcal{B}(1, p)$, sau đó xác định ước lượng $\hat{p}$ và khoảng tin cậy 95% Wald của p , tiếp đó, xác định xem liệu p có nằm trong khoảng tin cậy Wald 95% hay không. Lặp lại 10,000 lần, rồi lấy trung bình số lần p có nằm trong khoảng tin cậy Wald 95%. Kết quả cuối cùng được biểu hiện trong Hình 1. Ta dễ dàng thấy rằng, độ phủ của khoảng tin cậy Wald không xấp xỉ mức tin cậy 0.95, trong hầu hết các trường hợp giá trị của p , đặc biệt là



Hình 1: Kết quả độ phủ của khoảng tin cậy Wald 95% cho tỷ lệ p thay đổi từ 0.05 tới 0.95. Đường nét đứt là mức tin cậy 0.95.

khi p gần hai biên 0 và 1. Khi cỡ mẫu n được tăng lên, độ chính xác bắt đầu được cải thiện, nhưng vẫn chậm ở phần biên của khoảng xác định tham số p .

Để khắc phục nhược điểm này, ta sử dụng phương pháp Agresti–Coull¹. Khoảng tin cậy Agresti–Coull $(1 - \alpha) \times 100\%$ cho tỷ lệ p_k được xác định bởi:

$$\left(\tilde{p}_k - z_{(1+\alpha)/2} \sqrt{\frac{\tilde{p}_k(1 - \tilde{p}_k)}{n + z_{(1+\alpha)/2}^2}}, \tilde{p}_k + z_{(1+\alpha)/2} \sqrt{\frac{\tilde{p}_k(1 - \tilde{p}_k)}{n + z_{(1+\alpha)/2}^2}} \right),$$

với

$$\tilde{p}_k = \frac{n\hat{p}_k + 0.5z_{(1+c)/2}^2}{n + z_{(1+c)/2}^2}.$$

Thực hiện lại mô phỏng như ở trên, nhưng áp dụng khoảng tin cậy Agresti–Coull 95% cho tỷ lệ p , ta có kết quả tổng hợp được minh họa trong Hình 2.

1.2 Tính toán trong R

Ta sử dụng hàm `binom.confint()` trong thư viện `binom`. Trước tiên, ta cần cài đặt thư viện (do nó không phải là thư viện được cài đặt sẵn):

```
install.packages("binom")
```

Sau khi cài đặt, ta cần tải thư viện này lên trên phiên làm việc R hiện thời:

```
library(binom)
```


Để sử dụng hàm `binom.confint()`, ta sử dụng cấu trúc như sau:

```
binom.confint(x, n, conf.level = ..., methods = "ac")
```

trong đó,

- **x** tên của biến chứa thông tin tần số (số lượng) của một hoặc nhiều thể loại;
- **n** tên của biến chứa thông tin về số lượng được quan sát (cỡ mẫu);

¹Agresti and Coull (1998), <https://doi.org/10.2307/2685469>



Hình 2: Kết quả độ phủ của khoảng tin cậy Agresti-Coull 95% cho tỷ lệ p thay đổi từ 0.05 tới 0.95. Đường nét đứt là mức tin cậy 0.95.

- `conf.level` mức tin cậy được sử dụng để xây dựng khoảng tin cậy;
- `methods` tên của phương pháp muốn sử dụng, với "ac" viết tắt cho phương pháp Agresti-Coull. Ngoài ra, ta còn có `methods = "asymptotic"` ám chỉ phương pháp Ward, và nhiều phương pháp khác, xem chi tiết trong trợ giúp của hàm `binom.confint()`, tức là `help("binom.confint")`.

Ví dụ 1.1: Trong một thí nghiệm với một đột biến nhất định ở ruồi giấm *Drosophila*, 100 cá thể đã được kiểm tra; trong số này, 20 người được phát hiện là đột biến. Hãy xây dựng khoảng tin cậy 95% cho các tỷ lệ của thí nghiệm này.

Gọi Y là trạng thái đột biến của ruồi giấm *Drosophila*. Vì vậy, Y là một biến phân loại nhị phân với hai loại có thể có: không đột biến và đột biến (*mutant*).

Bảng thí nghiệm, chúng ta có tổng số lượt quan sát là 100; tần số của hai loại là: 80 đối với không đột biến và 20 đối với đột biến. Khoảng tin cậy Agresti-Coull 95% được tính như sau:

```
freq_mut <- c(80, 20)
n_mut <- 100
binom.confint(x = freq_mut, n = n_mut, conf.level = 0.95, methods = "ac")
```

```
##           method x    n mean   lower   upper
## 1 agresti-coull 80 100  0.8 0.7104116 0.8673923
## 2 agresti-coull 20 100  0.2 0.1326077 0.2895884
```

Mỗi dòng đưa ra kết quả cho từng loại. Cột có tên `mean` hiển thị tỷ lệ mẫu $\hat{p}$ của các danh mục. Hai cột cuối cùng (có tên `low` và `upper`) đưa ra các điểm giới hạn của khoảng tin cậy. Ví dụ: dòng thứ hai cho chúng ta kết quả về đột biến:

- tỷ lệ mẫu $\hat{p}_{\text{mutant}} = 0.2$;
- khoảng tin cậy 95% cho tỷ lệ đột biến là $(0.1326077, 0.2895884)$ hoặc $(0.133, 0.290)$.

Ví dụ 1.2: Các nhà khoa học đã sử dụng chuột nhảy Mông Cổ (*Mongolian gerbils*) khi tiến hành nghiên cứu về thần kinh. Một giống chuột nhảy nhất định đã được lai tạo và sinh ra con cháu có màu sắc sau:

Màu sắc	đen	nâu	trắng
Số lượng	40	59	42

Khoảng tin cậy Agresti-Coull 95% cho tỷ lệ màu giống được tính như sau.

```
freq_colr <- c(40, 59, 42)
n_gerbils <- sum(freq_colr)
n_gerbils
```

```
## [1] 141
```

```
binom.confint(x = freq_colr, n = n_gerbils, conf.level = 0.95, methods = "ac")
```

```
##           method x    n    mean    lower    upper
## 1 agresti-coull 40 141 0.2836879 0.2155708 0.3632790
## 2 agresti-coull 59 141 0.4184397 0.3402084 0.5009973
## 3 agresti-coull 42 141 0.2978723 0.2283759 0.3780904
```

Bài tập 1.1: Trong một quần thể chuột tự nhiên (*Mus musculus*) gần Ann Arbor, Michigan, bộ lông của một số cá thể có đốm trắng ở bụng. Trong một mẫu gồm 580 con chuột từ quần thể, người ta phát hiện 28 cá thể có bụng có đốm trắng. Xây dựng khoảng tin cậy 95% cho tỷ lệ của đặc điểm này.

Bài tập 1.2: Để đánh giá chính sách tiêm vắc xin ho gà định kỳ cho trẻ sơ sinh, các phản ứng bất lợi đã được theo dõi ở 339 trẻ sơ sinh được tiêm vắc xin đầu tiên. Phản ứng đã được ghi nhận ở 69 trẻ sơ sinh.

- Xây dựng khoảng tin cậy 95% cho xác suất xảy ra phản ứng bất lợi với vắc xin.
- Giải thích khoảng tin cậy ở phần (a). Khoảng tin cậy nói gì về việc tiêm phòng bệnh ho gà?

Bài tập 1.3: Trong một nghiên cứu sinh thái của Carolina Junco, 53 con chim đã được bắt từ một quần thể nhất định; trong số này, 40 người là nam giới. Sử dụng những dữ liệu này để xây dựng khoảng tin cậy 90% cho tỷ lệ chim đực trong quần thể Carolina Junco.

Bài tập 1.4: Việc lai giữa bí mùa hè màu trắng và màu vàng đã cho thế hệ con cháu có màu sắc sau:

Màu	trắng	vàng	xanh lá
Tần số	155	40	10

- Xây dựng khoảng tin cậy 95% cho tỷ lệ màu sắc.
- Giải thích khoảng tin cậy ở phần (a).
- Nếu chúng ta lặp lại thí nghiệm với tổng số lần quan sát như nhau thì dự kiến sẽ thu được bao nhiêu màu trắng sau thí nghiệm.

2 Khoảng tin cậy cho trung bình

Nhắc lại rằng, một khoảng tin cậy $(100 \times c)\%$ cho trung bình của một biến dạng số là

$$\left(\bar{Y} - t_{(1+c)/2, n-1} \frac{s}{\sqrt{n}}, \bar{Y} + t_{(1+c)/2, n-1} \frac{s}{\sqrt{n}} \right),$$

trong đó, $\bar{Y}$ là trung bình mẫu; s là độ lệch chuẩn mẫu; n là cỡ mẫu hay số lượng quan sát; và $t_{(1+c)/2, n-1}$ là phân vị thứ $(1+c)/2$ của phân phối t -student với $n-1$ bậc tự do.

Trong R, để xác định khoảng tin cậy này, ta thực hiện các bước sau:

Bước 0. Kiểm tra xem phân phối của dữ liệu đã có xấp xỉ với phân phối chuẩn hay không, bằng cách sử dụng biểu đồ tần số (histogram) hoặc biểu đồ xác suất chuẩn (* normal probability plot - Normal Q-Q plot*). **Chú ý**: sau khi kiểm tra, nếu ta nhận thấy một trong các trường hợp sau:

- dữ liệu được lấy từ phân bố chuẩn;
- sự phân bố của dữ liệu “tương tự” với phân bố chuẩn và cỡ mẫu lớn (ít nhất là 30);
- dữ liệu không phải từ phân phối chuẩn mà là một phép biến đổi, ví dụ: logarit, căn bậc hai, có thể tạo ra dữ liệu tuân theo phân phối chuẩn;

thì ta có thể làm tiếp bước tiếp theo. Nếu không, ta không nên sử dụng khoảng tin cậy- t .

Bước 1. tính trung bình mẫu bằng hàm `mean()`.

Bước 2. tính độ lệch chuẩn mẫu bằng hàm `sd()`.

Bước 3. tính sai số chuẩn.

Bước 4. xác định điểm phân vị $t_{(1+c)/2, n-1}$, bằng hàm `qt((1 + c)/2, df = n - 1)`.


Bước 5. sử dụng tất cả các thành phần đã được ước tính để tính khoảng tin cậy.

Lưu ý rằng, nếu chúng ta áp dụng phép biến đổi cho dữ liệu thì khoảng tin cậy là cho trung bình của dữ liệu được biến đổi, ví dụ: nếu chúng ta lấy logarit thì chúng ta sẽ xây dựng khoảng tin cậy cho logarit của trung bình.

Bây giờ, hãy bắt đầu với một ví dụ đơn giản, để chỉ ra cách ...

Ví dụ 2.1:

Để nghiên cứu diện tích cánh của loài bướm, một nhóm các nhà nghiên cứu đã thu thập mẫu 14 con bướm Monarch được tại Công viên bang Oceano Dunes ở California. Dựa trên dữ liệu, họ báo cáo giá trị trung bình mẫu của diện tích cánh là 32.81 cm^2 và độ lệch chuẩn mẫu $s = 2.48 \text{ cm}^2$. Với những thông tin này, hãy xây dựng khoảng tin cậy 90% cho diện tích cánh trung bình của bướm Monarch.



Đối tượng nghiên cứu là bướm Monarch, biến Y là “diện tích cánh của bướm”. Vì ta không nhìn thấy dữ liệu nên ta không thể kiểm tra điều kiện phân phối chuẩn của dữ liệu. Với cỡ mẫu $n = 14$, ta hy vọng rằng nó có thể ổn. Các giá trị trung bình mẫu và độ lệch chuẩn mẫu được báo cáo, vì vậy trong ví dụ này chúng ta không cần tính toán các đại lượng này. Tuy nhiên, chúng ta cần nhập chúng vào R.

```
n_y <- 14
y_bar <- 32.81
y_sd <- 2.48
```

Ta tính toán sai số chuẩn của giá trị trung bình mẫu bằng cách sau

```
se_y_bar <- y_sd / sqrt(n_y)
```

(lưu ý: lệnh `sqrt()` dùng để tính căn bậc hai). Sau đó kết quả là

```
se_y_bar
```

```
## [1] 0.6628079
```

Yêu cầu là xây dựng khoảng tin cậy 90% cho giá trị trung bình, do đó chúng ta nhận được $c = 0.9$, và

```
ci_wa_90 <- y_bar + c(-1, 1) * qt((1 + 0.9) / 2, df = n_y - 1) * se_y_bar
```

Kết quả là

```
ci_wa_90
```

```
## [1] 31.63621 33.98379
```

Chúng ta có thể nói rằng “diện tích cánh trung bình của bướm Monarch nằm trong khoảng (31.636, 33.984), với độ tin cậy 90%”.

Thực hành: Bây giờ, bạn có thể thử tìm khoảng tin cậy 95% và 99% cho diện tích cánh trung bình của con bướm.

Thực hành: Hãy viết một đoạn hàm `function()` để tính khoảng tin cậy cho trung bình, với đầu vào là trung bình mẫu, độ lệch chuẩn mẫu, cỡ mẫu và độ tin cậy; giá trị trả ra là chặn trên và chặn dưới của khoảng tin cậy.

Sau đó, áp dụng cho Ví dụ 1.1

Ví dụ 2.2: Ta hãy xem xét lại Ví dụ 1.1. Bảng sau đây trình bày dữ liệu của 14 con bướm Monarch được tại Công viên bang Oceano Dunes ở California.

Bảng 1: Diện tích cánh (cm^2) của bướm Monarch được

Diện tích cánh (cm^2)				
33.9	33.0	30.6	36.6	36.5
34.0	36.1	32.0	28.0	32.0
32.2	32.2	32.3	30.0	

Hãy xây dựng khoảng tin cậy 95% cho diện tích cánh trung bình của bướm Monarch.

Bây giờ, ta có dữ liệu, vì vậy, ta có thể kiểm tra nhanh điều kiện phân phối chuẩn. Để bắt đầu, trước tiên chúng ta cần nhập dữ liệu vào R, theo dạng một bảng dữ liệu, để làm điều này, ta có thể dùng hàm `tibble()` trong thư viện `tibble`:


```
library(tibble)
data_monarch <- tibble(wa = c(33.9, 33.0, 30.6, 36.6, 36.5, 34.0, 36.1, 32.0,
                             28.0, 32.0, 32.2, 32.2, 32.3, 30.0))
data_monarch
```

```
## # A tibble: 14 x 1
##   wa
##   <dbl>
## 1  33.9
## 2   33
## 3  30.6
## 4  36.6
## 5  36.5
## # i 9 more rows
```

(lưu ý: chúng ta cần sử dụng lệnh `c()` để nhập các số, cách nhau bằng dấu phẩy “,”)


Bây giờ ta sẽ vẽ biểu đồ tần số (histogram) cho `wa`, bằng cách sử dụng `ggplot` trong thư viện `ggplot2`:

```
library(ggplot2)
ggplot(data = data_monarch, aes(x = wa)) +
  geom_histogram(fill = "gray80", color = "black", bins = 5) +
  xlab("Wing area (cm2)") +
  ylab("Frequency") +
  theme_classic()
```



Như thể hiện trong biểu đồ, sự phân bố diện tích cánh khá đối xứng với một mode ở giữa. Vì vậy, có lẽ, dữ liệu gần đúng với phân phối chuẩn. Để chắc chắn, ta cũng có thể tạo biểu đồ Normal Q-Q. Với thư viện `ggplot2`, ta có thể dùng `geom_qq()` để vẽ các điểm phân vị của phân phối chuẩn so với các điểm phân vị của phối mẫu; và hàm `geom_qq_line()` để vẽ đường tham chiếu. Ví dụ,

```
ggplot(data = data_monarch, aes(sample = wa)) +
  geom_qq() + geom_qq_line() +
  xlab("Quantile of Normal distribution") +
  ylab("Quantile of Sample distribution") +
  theme_classic()
```



Như được hiển thị trong biểu đồ Normal Q-Q, hầu hết các điểm đều nằm gần đường chéo, điều đó có nghĩa là dữ liệu có thể đến từ phân phối chuẩn. Vì vậy, ta có thể áp dụng cách tiếp cận khoảng tin cậy t để xây dựng khoảng tin cậy cho diện tích cánh trung bình của bướm Monarch.

Trong ví dụ này, ta cần tính trung bình mẫu

```
mu_wa <- mean(data_monarch$wa)
mu_wa
```

```
## [1] 32.81429
```

và độ lệch chuẩn mẫu:

```
sd_wa <- sd(data_monarch$wa)
sd_wa
```

```
## [1] 2.475684
```

Các kết quả về giá trị trung bình mẫu và độ lệch chuẩn mẫu này gần giống với kết quả được báo cáo trong Ví dụ 2.1. Và khi đó, sai số chuẩn là

```
se_mu_wa <- sd_wa / sqrt(length(data_monarch$wa))
se_mu_wa
```

```
## [1] 0.6616544
```

Lưu ý: lệnh `length()` dùng để lấy độ dài của vectơ, tức là kích thước mẫu trong trường hợp này. Yêu cầu là xây dựng khoảng tin cậy 95% cho giá trị trung bình, do đó ta nhận được $c = 0,95$, và

```
ci_wa_95 <- mu_wa + c(-1, 1) * qt((1 + 0.95) / 2,
                                   df = length(data_monarch$wa) - 1) * se_mu_wa
```

kết quả là

```
ci_wa_95
```

```
## [1] 31.38487 34.24370
```

Thực hành Viết một hàm `function()` với đầu vào là một vectơ của một biến định lượng, độ tin cậy; giá trị trả ra là chặn trên và chặn dưới của khoảng tin cậy.

Bài tập 2.1: Tích lũy trầm tích, là thước đo lượng trầm tích lơ lửng trong nước, là thước đo chất lượng nước của một con sông. Bảng sau đây báo cáo lượng trầm tích của các mẫu nước, tính bằng mg/l, từ Black River ở phía bắc Ohio trong 9 ngày:

Bảng 2: Lượng tích lũy trầm tích (mg/l) của mẫu nước trong 9 ngày

Lượng tích lũy trầm tích (mg/l)				
14	4	7	20	117
10	210	25	70	

- Nhập dữ liệu vào R.
- Sử dụng biểu đồ tần số hoặc biểu đồ Normal Q-Q để kiểm tra tính chất phân phối chuẩn của dữ liệu. Nhận xét có thể đưa ra là gì?
- sử dụng hàm `log()` để tính logarit của dữ liệu, và lưu kết quả đó vào một biến mới của dữ liệu.
- Sử dụng biểu đồ tần số hoặc biểu đồ Normal Q-Q để kiểm tra tính chất phân phối chuẩn của logarit của dữ liệu. Nhận xét có thể đưa ra là gì?
- Xây dựng khoảng tin cậy 95% cho trung bình logarit của lượng trầm tích ở Black River.

Bài tập 2.2: Xem xét dữ liệu về nồng độ MAO trong tiểu cầu của các bệnh nhân, được ghi lại trong tệp `MAO.csv`. Hãy xây dựng khoảng tin cậy 95% cho nồng độ MAO của các bệnh nhân theo các trường hợp sau:

- tất cả bệnh nhân, không phân biệt nhóm bệnh;
- phân theo các nhóm bệnh khác nhau.