

Bài giảng R, số 8

-Hồi quy tuyến tính-

TS.Tô Đức Khánh

02/10/2023

1 Ước lượng và kiểm định mô hình

Mô hình hồi quy tuyến tính được dùng để tiên đoán giá trị của biến phản hồi (response variable) Y dựa trên cơ sở của p biến giải thích khác nhau: $X_1, X_2, \dots, X_p$. Mô hình được phát biểu tổng quát như sau:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + \varepsilon_i,$$

trong đó, $x_{1i}, x_{2i}, \dots, x_{pi}$ là các giá trị quan sát của các biến giải thích $X_1, X_2, \dots, X_p$, Y_i là quan sát của biến Y , và ε_i là thành phần sai số, với $i = 1, 2, \dots, n$.

Trong R, để ước lượng mô hình hồi quy tuyến tính cho biến nhị thức, ta sử dụng hàm `lm()`, cụ thể như sau:

```
lm(formula = y ~ x1 + x2 + ..., data = ..., ...)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với y là tên của biến đáp ứng, $x1$ và $x2$ lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `...` là các đối thêm, được sử dụng trong các trường hợp cụ thể.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `confint()`: xác định khoảng tin cậy cho hệ số trong mô hình;
- `predict()`: tiên đoán giá trị của biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến đáp ứng;
- `residuals()`: truy xuất thẳng dư của mô hình;
- `rstandard()`: truy xuất thẳng dư chuẩn hóa của mô hình;
- `plot()`: tạo các biểu đồ để kiểm tra các giả định của mô hình, dựa trên thông tin của thẳng dư hoặc thẳng dư đã được chuẩn hóa.

Trong phần sau, chúng ta sẽ thực hành để biết cách ước lượng mô hình hồi quy tuyến tính đa biến trong R bằng hai ví dụ. Ví dụ đầu tiên xem xét mô hình tuyến tính với tất cả các biến giải thích liên tục, trong khi ví dụ thứ hai xem xét mô hình tuyến tính với một biến giải thích liên tục và một biến giải thích phân loại.


Ví dụ 1: Huyết áp tâm thu được đo cho 11 người ở các độ tuổi khác nhau. Cùng với trọng lượng của họ (đơn vị: pound) được thu thập. Dữ liệu được ghi lại trong tệp dữ liệu `blood_pressure.csv`. Một câu hỏi nghiên cứu là “huyết áp tâm thu có thể được dự đoán theo cân nặng và tuổi tác hay không?”

```
dt_pressure <- read_csv(file = "datasets/blood_pressure.csv")
```

```
## Rows: 11 Columns: 3
## -- Column specification -----
## Delimiter: ","
## dbl (3): blood_pressure, age, weight
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

Để thấy được mối tương quan giữa các biến: blood_pressure, age và weight; chúng ta có thể tạo một biểu đồ phân tán cho ba biến này bằng cách sử dụng plot().

```
plot(dt_pressure, pch = 16)
```



Từ biểu đồ, chúng ta thấy rằng cả tuổi tác và cân nặng đều liên quan đến huyết áp tâm thu. Vì vậy, ta có thể cố gắng áp dụng mô hình hồi quy tuyến tính đa biến để dự đoán huyết áp tâm thu dựa trên độ tuổi và cân nặng.

```
out_pressure <- lm(formula = blood_pressure ~ age + weight, data = dt_pressure)
```

This corresponding to the linear model:

$$\text{blood_pressure} = b_0 + b_1 \text{age} + b_2 \text{weight} + \varepsilon$$

```
summary(out_pressure)
```

```
##
## Call:
## lm(formula = blood_pressure ~ age + weight, data = dt_pressure)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4640 -1.1949 -0.4078  1.8511  2.6981
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  30.9941     11.9438   2.595  0.03186 *
## age          0.8614      0.2482   3.470  0.00844 **
## weight       0.3349      0.1307   2.563  0.03351 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.318 on 8 degrees of freedom
## Multiple R-squared:  0.9768, Adjusted R-squared:  0.9711
## F-statistic: 168.8 on 2 and 8 DF,  p-value: 2.874e-07
```

Một số nhận xét về kết quả:

- Ước lượng OLS là $\hat{b}_0 = 30.9941$, $\hat{b}_1 = 0.8614$ và $\hat{b}_2 = 0.3349$.
- Nếu một người già hơn một tuổi, cân nặng không thay đổi thì huyết áp tâm thu tăng 0.8614 đơn vị.
- Nếu một người tăng 1 pound cân nặng trong một khoảng thời gian nhất định trong năm thì huyết áp tâm thu của người đó tăng 0.3349 đơn vị.
- p -value của kiểm định $H_0 : b_j = 0$ ($j = 1, 2$) nhỏ hơn mức ý nghĩa $\alpha = 0.05$, vì vậy ta có thể bác bỏ H_0 . Vì vậy, chúng ta có thể tin rằng cả độ tuổi và cân nặng đều hữu ích để dự đoán huyết áp tâm thu.
- Hệ số xác định $R_a^2 = 0.9711$, có nghĩa là 97.11% độ biến thiên của huyết áp tâm thu có thể được giải thích bằng mô hình hồi quy tuyến tính với độ tuổi và cân nặng.

Bây giờ, giả sử chúng ta quan tâm đến việc dự đoán huyết áp tâm thu của một người 65 tuổi nặng 200 pound (khoảng 90.7185 kg). Dựa trên mô hình, chúng ta có huyết áp tâm thu dự đoán và khoảng dự đoán 95% là

```
predict(out_pressure, newdata = data.frame(age = 65, weight = 200),
        interval = "prediction", level = 0.95)
```

```
##          fit          lwr          upr
## 1 153.9579 148.353 159.5628
```

Vì vậy, chúng ta có thể nói rằng: dựa trên mô hình, chúng ta tin cậy 95% rằng huyết áp tâm thu của một người 65 tuổi nặng 200 pound dao động từ 148,353 đến 159,5628 mmHg. Trong khi đó, 95% khoảng tin cậy cho trung bình huyết áp tâm thu của một nhóm người với độ tuổi 65 và cùng cân nặng 200 pound được xác định là:

```
predict(out_pressure, newdata = data.frame(age = 65, weight = 200),
        interval = "confidence", level = 0.95)
```

```
##          fit          lwr          upr
## 1 153.9579 152.2735 155.6423
```

Giả sử ta có tuổi của ba người lần lượt là 45, 55 và 72; trọng lượng của họ là 210, 170 và 185 pounds. Dựa trên mô hình, huyết áp tâm thu của họ có thể được dự đoán như sau:

```
predict(out_pressure,
        newdata = data.frame(age = c(45, 55, 72), weight = c(210, 170, 185)),
        interval = "prediction", level = 0.95)
```

```
##           fit      lwr      upr
## 1 140.0782 124.6874 155.4690
## 2 135.2980 128.5667 142.0292
## 3 154.9649 144.9020 165.0279
```


Và 95% khoảng tin cậy cho trung bình huyết áp tâm thu của một nhóm người này là:

```
predict(out_pressure,
        newdata = data.frame(age = c(45, 55, 72), weight = c(210, 170, 185)),
        interval = "confidence", level = 0.95)
```

```
##           fit      lwr      upr
## 1 140.0782 125.6456 154.5108
## 2 135.2980 131.2075 139.3885
## 3 154.9649 146.4393 163.4905
```

Để kiểm tra giả định của mô hình, ta sẽ tạo các biểu đồ chuẩn đoán cho thặng dư của mô hình:

```
par(mfrow = c(2,2))
plot(out_pressure, pch = 16)
```



- Biểu đồ đầu tiên (trên cùng bên trái) thể hiện một xu hướng nhất định của các điểm. Trên thực tế, ta thấy đường liền nét không xấp xỉ nằm ngang ở mức 0. Nó gợi ý sử dụng một số biến đổi cho biến đáp ứng hoặc sử dụng mô hình có thành phần phi tuyến.
- Biểu đồ phía dưới bên trái cho thấy độ biến thiên (phương sai) của các điểm tăng dần theo giá trị của ước lượng của biến đáp ứng, cho thấy các phương sai không cố định trong các phần thập dư (hoặc độ không đồng nhất).
- Biểu đồ trên cùng bên phải cho thấy hầu hết các điểm đều nằm dọc theo đường tham chiếu này, do đó giả định về tính phân phối chuẩn là hợp lý (hoặc được thỏa mãn).
- Biểu đồ cuối cùng (dưới cùng bên phải) cho thấy quan sát thứ ba (# 7) là một ngoại lai và nó có thể ảnh hưởng đến các ước lượng. Tuy nhiên, mức độ ảnh hưởng không quá mạnh do khoảng cách của Cook tới điểm này không lớn hơn 1.

Looking the scatter plot, we see that the age and weight are correlated to each other. Thus, it could be a problematic of collinearity if we use both the age and the weight as predictors in the model. In order to check the collinearity problem, we compute VIF for each predictor by using function `vif()` in package `car` (so first, we need to load the package `car`).

```
library(car)
vif(out_pressure)
```

```
##      age    weight
## 9.525022 9.525022
```

The results indicate a strong collinearity problem. One solution is to use only the age or the weight in the linear model. For example, to use only the weight as predictor, we can make a new update which remove the age from the current model. In order to do this work, we use function `update()`.

```
out_pressure_2 <- update(out_pressure, formula = . ~ . - age)
summary(out_pressure_2)
```

```
##
## Call:
## lm(formula = blood_pressure ~ weight, data = dt_pressure)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.7440 -1.0412 -0.3124  2.2283  4.2560
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.14161    12.36447   0.092   0.928
## weight       0.76384     0.06318  12.090 7.23e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.459 on 9 degrees of freedom
## Multiple R-squared:  0.942, Adjusted R-squared:  0.9356
## F-statistic: 146.2 on 1 and 9 DF, p-value: 7.227e-07
```

Note: To use the function `update()`, we input the results of current model (in this case `out_pressure`), and then we give an update formula: the dot “.” means the unchanged terms, and “-” is used to remove one predictor from model (of course, for adding a new predictor, we can use “+”).

Example 2: The length of a species of fish is to be represented as a function of the age and water temperature. The fishes are kept in tanks at 25, 27, 29 and 31 degrees Celsius. After birth, a test specimen (44 fishes) is chosen at random every 14 days and its length measured. The data is available in the data file `fish_length.csv`.


```
dt_fish <- read_csv(file = "datasets/fish_length.csv")
```

```
## Rows: 44 Columns: 4
## -- Column specification -----
## Delimiter: ","
## dbl (4): Id, Age, Temp, Length
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
dt_fish <- dt_fish |> janitor::clean_names()
dt_fish <- dt_fish |> mutate(temp_ft = factor(temp))
```

First, we can make a scatter plot for Age, Temp and Length, in order to see the correlation between these variables.

```
plot(dt_fish[, c("age", "temp", "length")], pch = 16)
```



Note: We use `dt_fish[, c("age", "temp", "length")]` to specify the variables needed for making scatter plot. If we use `dt_fish`, the plot will be made for all variables including the uninterested ones.

From the plot, we see that both the age is related to the fish length, and the temperature is somehow related to the first length.

Note that: the researcher designed temperature condition of a tank to be constant and the data were obtained by an experimental study, so it could be better if we consider Temp as a factor with four fixed levels: 25, 27, 29 and 31, instead of a continuous variable.

Now we fit a linear model to predict the length of fish based on the age and also the temperature of water. Thus, `length` is response variable; `age` and `temp_ft` are predictors.

```
out_fish_1 <- lm(length ~ age + temp_ft, data = dt_fish)
```

This corresponding to the linear model:

$$\text{Length} = b_0 + b_1 \text{Age} + b_2 \text{Temp_ft}_2 + b_3 \text{Temp_ft}_3 + b_4 \text{Temp_ft}_4 + \varepsilon$$

where Temp_ft_j (with $j = 2, 3, 4$) is dummy variable, such that:

$$\text{Temp_ft}_j = \begin{cases} 0 & \text{is not level } j \text{ of Temp_ft} \\ 1 & \text{is level } j \text{ of Temp_ft} \end{cases}$$

Note that, the first level of Temp_ft is 25.

```
summary(out_fish_1)

##
## Call:
## lm(formula = length ~ age + temp_ft, data = dt_fish)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1100.0  -412.0   117.2   388.1   887.0
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1035.434    223.482   4.633 3.96e-05 ***
## age          26.241      1.845  14.221 < 2e-16 ***
## temp_ft27    106.364    229.716   0.463  0.64592
## temp_ft29    186.909    229.716   0.814  0.42078
## temp_ft31   -736.273    229.716  -3.205  0.00269 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 538.7 on 39 degrees of freedom
## Multiple R-squared:  0.851, Adjusted R-squared:  0.8357
## F-statistic: 55.67 on 4 and 39 DF, p-value: 1.333e-15
```

Some comments for results:

- The estimate of Temp_ft₃ (31°C) is -736.273 and statistically significant (p -value is 0.00269). This indicates that the reduction in fish length is statistically significant at 31°C. If we have two fishes with same age, but one fish lives in water with temperature as 25°C, and another one lives at 31°C. Then, the length of the first fish will be about 736.273 (unit) longer than the length of the second fish.
- In contrast, when the temperature increases from 25°C to 27°C or 29°C, the change in fish length is not statistically significant.
- Suppose that Age of i -th fish increases 1 day, we have the change in the length is 26.241.
- Adjusted $R^2 = 0.8357$, means that 83.57% of the variability in the fish length can be explained by the linear regression model.

Suppose that we have 3 groups of fish. The age of fish in each group are same 90 days. The groups live in water with temperature as 25°C, 27°C and 31°C, respectively. Based on the model, we can predict the mean length of 3 groups as follows:

```
predict(out_fish_1,
        newdata = data.frame(age = c(90, 90, 90),
                              temp_ft = factor(c(25, 27, 31),
                                                levels = c("25", "27", "29", "31"))),
        interval = "confidence", level = 0.95)

##           fit      lwr      upr
## 1 3397.096 3067.559 3726.632
## 2 3503.459 3173.922 3832.996
## 3 2660.823 2331.286 2990.360
```

Based on the results:

- The 95% confidence interval for the mean length of 90-day-old fish living at water temperature of

25°C is (3067.559, 3726.632). This means that, according to our model, a 90-day-old fish living at water temperature of 25°C has, on average, a length ranging between 3067.559 and 3726.632 units (with 95% of confidence).

- The 95% confidence interval for the mean length of 90-day-old fish living at water temperature of 27°C is (3173.922, 3832.996). This means that, according to our model, a 90-day-old fish living at water temperature of 27°C has, on average, a length ranging between 3173.922 and 3832.996 units (with 95% of confidence).
- The 95% confidence interval for the mean length of 90-day-old fish living at water temperature of 31°C is (2331.286, 2990.360). This means that, according to our model, a 90-day-old fish living at water temperature of 31°C has, on average, a length ranging between 2331.286 and 2990.360 units (with 95% of confidence).
- Comparing three confidence intervals, we see that the mean length of 90-day-old fishes living at water temperature of 31°C is statistically shorter than those of fishes living at water temperature of 27°C.


2 Multiple linear model with interaction terms

In this section, we practice the multiple linear model with interaction terms through an example.

Example 3: We consider again the fish length data. In Example 2, we constructed a linear model with `age` and `temp_ft` as predictors in order to predict the length of fish. In this example, we will use a multiple linear model with interaction between temperature and age, i.e., the effect of age on the fish length is changed as the temperature changes.

Before going to fit the multiple linear regression model, we make again a scatter plot of `Length` and `Age`, but we change point colors and shapes by levels of `Temp_ft`, in order to highlight the different trends.

```
ggplot(dt_fish, aes(x = age, y = length, color = temp_ft, shape = temp_ft)) +  
  geom_point() +  
  ylim(0, 5000) +  
  scale_color_discrete(name = "Temperature") +  
  scale_shape_discrete(name = "Temperature") +  
  xlab("Age") + ylab("Length") +  
  theme_classic()
```



As shown in the figure, when the fish is young (less than 80 days), the effect of water temperature on the length is nothing. However, when fish were older than 100 days, we found that fish living at water temperature of 31°C seemed to stop growing in length. Perhaps, interaction between age and temperature is reasonable.

```
out_fish_2 <- lm(length ~ age + temp_ft + temp_ft:age, data = dt_fish)
```

Note: in the formula, the term `Temp_ft:Age` means the interaction term (between `Temp_ft` and `Age`).

This corresponding to the linear model:

$$\begin{aligned} \text{Length} = & b_0 + b_1\text{Age} + b_2\text{Temp_ft}_2 + b_3\text{Temp_ft}_3 + b_4\text{Temp_ft}_4 \\ & + c_{22}\text{Temp_ft}_2\text{Age} + c_{23}\text{Temp_ft}_3\text{Age} + c_{24}\text{Temp_ft}_4\text{Age} + \varepsilon \end{aligned}$$

```
summary(out_fish_2)
```

```
##
## Call:
## lm(formula = length ~ age + temp_ft + temp_ft:age, data = dt_fish)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -838.02  -384.75   78.39   319.38   920.94
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   792.6795    327.0218   2.424   0.0205 *
## age           29.1590     3.4749   8.391  5.4e-10 ***
## temp_ft27      84.3391    462.4787   0.182   0.8563
## temp_ft29     230.8772    462.4787   0.499   0.6207
## temp_ft31     212.8026    462.4787   0.460   0.6482
## age:temp_ft27   0.2648     4.9143   0.054   0.9573
```

```
## age:temp_ft29 -0.5286      4.9143 -0.108  0.9149
## age:temp_ft31 -11.4096     4.9143 -2.322  0.0260 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 507.3 on 36 degrees of freedom
## Multiple R-squared:  0.878, Adjusted R-squared:  0.8543
## F-statistic: 37.02 on 7 and 36 DF,  p-value: 1.369e-14
```

Some comments for results:

- The estimate of interaction between Age and Temp at 31°C (Age:Temp_ft31) is -11.4096 and statistically significant (with p -value is 0.026). This confirms our review of the behavior of the older fish living at water temperature of 31°C.
- When the temperature increases from 25°C to 27°C or 29°C, the change in fish length is not statistically significant.

Suppose that Age of i -th fish increases 1 day.

- If this fish lives at water temperature of 27°C, we have the change in the length is $29.16 + 0.27 = 29.43$.
- If this fish lives at water temperature of 31°C, we have the change in the length is $29.16 - 11.41 = 17.75$.
- Adjusted $R^2 = 0.8543$, means that 85.43% of the variability in the fish length can be explained by the linear regression model.

Suppose that we have 4 groups of fish. The age of fish in each group are: 20, 120, 85 and 120 days, respectively. The groups live in water with temperature as 25°C, 27°C, 31°C and 31°C, respectively. Based on the model, we can predict the mean length of 4 groups as follows:


```
predict(out_fish_2,
        newdata = data.frame(age = c(20, 120, 85, 120),
                              temp_ft = factor(c(25, 27, 31, 31),
                                                levels = c("25", "27", "29", "31"))),
        interval = "confidence")
```

```
##          fit          lwr          upr
## 1 1375.860  833.1949 1918.526
## 2 4407.877 4003.4700 4812.284
## 3 2514.181 2203.7271 2824.634
## 4 3135.410 2731.0026 3539.817
```

Based on the results, we can see the mean length of fishes living at water temperature of 31°C is statistically shorter than those of fishes living at water temperature of 27°C even they are at same age, i.e., compare two 95% confidence intervals: (2731.0026, 3539.817) and (4003.4700, 4812.284).

To check the model assumption, we make the diagnostic plots of residuals as:

```
par(mfrow = c(2,2))
plot(out_fish_2, pch = 16)
```



- The first (top left) plot is shows a fitted pattern. In fact, we see the solid line is a curve and not approximately horizontal at zero. It suggests to use a nonlinear model.
- The bottom left plot shows that the variability (variances) of the residual points is related to the value of the fitted response variable, suggesting non-constant variances in the residuals errors (or heteroskedasticity).
- The top right plot shows that almost the points fall approximately along this reference line, so the normality assumption is reasonable (or satisfied).
- The last (bottom right) plot indicates that there is no outlier.


Based on the fitted model, we can make a plot to show 4 estimated regression lines corresponding to 4 levels of Temp.

```
coef_fish_2 <- coef(out_fish_2)
dt_fish_coef_2 <- tibble(
  a = c(coef_fish_2[1], coef_fish_2[1] + coef_fish_2[3],
        coef_fish_2[1] + coef_fish_2[4], coef_fish_2[1] + coef_fish_2[5]),
```

```

b = c(coef_fish_2[2], coef_fish_2[2] + coef_fish_2[6],
      coef_fish_2[2] + coef_fish_2[7], coef_fish_2[2] + coef_fish_2[8]),
temp_ft = factor(c(25, 27, 29, 31))
)
ggplot(dt_fish, aes(x = age, y = length, color = temp_ft, shape = temp_ft)) +
  geom_point() +
  ylim(0, 5000) +
  geom_abline(data = dt_fish_coef_2,
             mapping = aes(intercept = a, slope = b, color = temp_ft)) +
  scale_color_discrete(name = "Temperature") +
  scale_shape_discrete(name = "Temperature") +
  xlab("Age") + ylab("Length") +
  theme_classic()

```



Note: In the above codes:

- We use function `geom_abline()` to make a regression line, in which, we input two arguments: $a = \dots$ for the intercept and $b = \dots$ for the slope.
- The function `coef(out_fish_2)` is to extract all coefficients of a linear model, say `out_fish_2` in this case, and `coef(out_fish_2)[i]` gives the i -th coefficient, as the same order showed in the result. For example,

`coef(out_fish_2)[1]` gives $\hat{b}_0 = 792.6795 \longleftrightarrow$ (Intercept)

`coef(out_fish_2)[2]` gives $\hat{b}_1 = 29.1590 \longleftrightarrow$ Age

`coef(out_fish_2)[3]` gives $\hat{b}_2 = 84.3391 \longleftrightarrow$ Temp_ft27

- The formula of the intercepts and slopes are obtained by the mathematical forms of model:

$$\text{Length} = \begin{cases} b_0 + b_1 \text{Age} + \varepsilon & \text{if Temp_ft}_2 = \text{Temp_ft}_3 = \text{Temp_ft}_4 = 0 \\ b_0 + b_{22} + (b_1 + c_{22})\text{Age} + \varepsilon & \text{if Temp_ft}_2 = 1 \\ b_0 + b_{23} + (b_1 + c_{23})\text{Age} + \varepsilon & \text{if Temp_ft}_3 = 1 \\ b_0 + b_{24} + (b_1 + c_{24})\text{Age} + \varepsilon & \text{if Temp_ft}_4 = 1 \end{cases}$$

3 Multiple linear model with nonlinear terms

In this section, we practice the multiple linear model with nonlinear terms through an example.

Example 4: Consider again the fish length data. As in the previous example, where we consider a multiple linear model with interaction term. However, this model does not fit well the trend of data. In fact, based on the scatter plot, we can see the shape of data seems to be fitted with the shape of a root function (nonlinear).

Suppose that we use the cube root function, i.e., $\sqrt[3]{x}$, in order to recover the relationship between Length and Age. A suggested model with interaction term is

$$\begin{aligned} \text{Length} = & b_0 + b_1 \sqrt[3]{\text{Age}} + b_2 \text{Temp_ft}_2 + b_3 \text{Temp_ft}_3 + b_4 \text{Temp_ft}_4 \\ & + c_{22} \text{Temp_ft}_2 \sqrt[3]{\text{Age}} + c_{23} \text{Temp_ft}_3 \sqrt[3]{\text{Age}} + c_{24} \text{Temp_ft}_4 \sqrt[3]{\text{Age}} + \varepsilon \end{aligned}$$

or equivalent to

$$\text{Length} = \begin{cases} b_0 + b_1 \sqrt[3]{\text{Age}} + \varepsilon & \text{if Temp_ft}_2 = \text{Temp_ft}_3 = \text{Temp_ft}_4 = 0 \\ b_0 + b_{22} + (b_1 + c_{22}) \sqrt[3]{\text{Age}} + \varepsilon & \text{if Temp_ft}_2 = 1 \\ b_0 + b_{23} + (b_1 + c_{23}) \sqrt[3]{\text{Age}} + \varepsilon & \text{if Temp_ft}_3 = 1 \\ b_0 + b_{24} + (b_1 + c_{24}) \sqrt[3]{\text{Age}} + \varepsilon & \text{if Temp_ft}_4 = 1 \end{cases}$$

This model have a similar form as the previous one.

```
out_fish_3 <- lm(length ~ I(age^(1/3)) + temp_ft + temp_ft:I(age^(1/3)),
                 data = dt_fish)
summary(out_fish_3)
```

```
##
## Call:
## lm(formula = length ~ I(age^(1/3)) + temp_ft + temp_ft:I(age^(1/3)),
##     data = dt_fish)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -578.55 -162.77   4.03  138.72  647.80
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -3000.58    421.61  -7.117 2.31e-08 ***
## I(age^(1/3))     1484.17     98.42  15.081 < 2e-16 ***
## temp_ft27        -42.07    596.25  -0.071 0.944142
## temp_ft29        113.92    596.25   0.191 0.849548
## temp_ft31       1553.37    596.25   2.605 0.013265 *
## I(age^(1/3)):temp_ft27   35.42    139.18   0.255 0.800539
## I(age^(1/3)):temp_ft29   17.42    139.18   0.125 0.901097
## I(age^(1/3)):temp_ft31 -546.45    139.18  -3.926 0.000374 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 291.2 on 36 degrees of freedom
## Multiple R-squared:  0.9598, Adjusted R-squared:  0.952
## F-statistic: 122.8 on 7 and 36 DF,  p-value: < 2.2e-16
```

Note: In the formula, we use $I(\text{age}^{(1/3)})$ for the cube transformation of Age, i.e., $\sqrt[3]{\text{age}}$. In general, we could use $I()$ for a power transformation, for example, $I(x^2)$ for x^2 ; or $I(x^{(1/2)})$ for $\sqrt{x}$.

Example 5: Biologists studied the relationship between embryonic heart rate and egg mass for 20 species of birds. They found that heart rate, Y , has a linear relationship with the logarithm of egg mass, X . The data are given in the file `eggs.csv`.

```
dt_eggs <- read.csv(file = "datasets/eggs.csv", header = TRUE)
dt_eggs <- dt_eggs |> janitor::clean_names()
```

The suggested model is: $\text{HeartRate} = b_0 + b_1 \log(\text{EggMass}) + \varepsilon$. In R, we fit the model as

```
out_egg <- lm(formula = heart_rate ~ log(egg_mass), data = dt_eggs)
summary(out_egg)
```

```
##
## Call:
## lm(formula = heart_rate ~ log(egg_mass), data = dt_eggs)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -57.501 -21.043   3.646  21.339  40.816
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   368.057     10.839   33.955 < 2e-16 ***
## log(egg_mass)  -35.808       5.408   -6.621 3.24e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 29.58 on 18 degrees of freedom
## Multiple R-squared:  0.7089, Adjusted R-squared:  0.6927
## F-statistic: 43.84 on 1 and 18 DF,  p-value: 3.242e-06
```

4 Exercise

Exercise 1: *Blood Pressure and Platelet Calcium.* It is suspected that calcium in blood platelets may be related to blood pressure. A study of this relationship was conducted. The study included two groups of subjects: 38 volunteers with normal blood pressure, selected from hospital lab personnel and other non-patients, and 45 patients with a diagnosis of high blood pressure. The data are given in the file `blood_pressure_Ca.csv`, in which BP refers to the blood pressure; Ca refers to the platelet calcium; and Group refers to group of subjects: normal or high blood pressure. Based on the study, the researchers aim to build linear model to predict the platelet calcium based on the information of the blood pressure and disease status (normal or high blood pressure disease).

- Write down the linear model. Then, fit the model in R based on the data.
- Give some valuable comments based on the results.

- (c) Select one reasonable or interested value of two predictors and then compute the predicted mean of platelet calcium and a 95% confidence interval for this predicted mean.
- (d) What is the 95% predicted interval for platelet calcium with these value of predictors?
- (e) Verify the model assumptions.

Exercise 2: *Caterpillar Head Size.* Can diet affect the size of a caterpillar's head? Such an effect is plausible, because a caterpillar's chewing muscles occupy a large part of the head. To study the effect of diet, a biologist raised caterpillars (*Pseudaletia unipuncta*) on three different diets: diet 1, an artificial soft diet; diet 2, soft grasses; and diet 3, hard grasses. He measured the weight of the head and of the entire body in the final stage of larval development. The results are given in the file `diet.csv`.

- (a) Write down the linear model. Then, fit the model in R based on the data.
- (b) Give some valuable comments based on the results.
- (c) Select one reasonable or interested value of two predictors and then compute the predicted mean of head weight and a 95% confidence interval for this predicted mean.
- (d) What is the 95% predicted interval for head weight with these value of predictors?
- (e) Verify the model assumptions.

Exercise 3: Consider the data `eggs.csv` used in Example 5.

- (a) Fit a linear model with nonlinear term: $Y = b_0 + b_1X + b_2X^2 + \varepsilon$, where Y is heart rate and X is egg mass.
- (b) Give some valuable comments based on the results.
- (c) Select one reasonable or interested value of two predictors and then compute the predicted mean of head weight and a 95% confidence interval for this predicted mean.
- (d) What is the 95% predicted interval for head weight with these value of predictors?
- (e) Verify the model assumptions.
- (f) Compare this model to the one considered in Example 4.

Exercise 4: Consider the data `ToothGrowth.csv` used in Example 4 of R note 10. This data contains the results of a study on Guinea pigs in order to see the effect of vitamin C on tooth growth. The response is the length of odontoblasts (cells responsible for tooth growth) in 60 guinea pigs. Each animal received one of three dose levels of vitamin C (0.5, 1, and 2 mg/day) by one of two delivery methods, orange juice or ascorbic acid (a form of vitamin C and coded as VC).

- (a) Fit a linear model: $\text{len} = b_0 + b_1\text{dose} + b_2\text{supp} + \varepsilon$, where `supp` is treated as a dummy variable, `dose` is a numerical variable.
- (b) Give some valuable comments based on the results.
- (c) Fit other linear model: $\text{len} = b_0 + b_1\text{dose_ft} + b_2\text{supp} + \varepsilon$, where `dose_ft` is treated as factor variable with three levels: 0.5, 1, 2.
- (d) Give some valuable comments based on the results of second model.
- (e) Compare the two models.
- (f) Do you think that it could be reasonable to consider the interaction between `dose_ft` and `supp`? If yes, fit the new model with interaction term.
- (g) Select one reasonable or interested value of two predictors and then compute the predicted mean of length of odontoblasts and a 95% confidence interval for this predicted mean, based on the second model (and the third one if possible).

- (h) What is the 95% predicted interval for length of odontoblasts with these value of predictors, based on the second model (and the third one if possible)?
- (l) Verify the model assumptions for the models.