

Bài giảng R, số 9

-Hồi quy logistic và phân loại-

TS.Tô Đức Khánh

02/10/2023

Chúng ta sẽ học cách ước lượng và sử dụng mô hình hồi quy logistic cho bài toán phân loại các đối tượng vào hai nhóm (hoặc các lớp). Đầu tiên, ta tìm hiểu cách điều chỉnh mô hình logistic và dự đoán xác suất bằng một số hàm trong R. Thứ hai, ta nghiên cứu sự đánh giá mô hình logistic bằng phương pháp phân tích đường cong ROC. Cuối cùng, ta nghiên cứu cách xác định được ngưỡng tối ưu bằng phương pháp Youden index hoặc Closet top left.

1 Logistic model

Mô hình hồi quy logistic:

$$\log\left(\frac{p(\mathbf{x})}{1-p(\mathbf{x})}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Trong R, để ước lượng mô hình hồi quy logistic, ta sử dụng hàm `glm()` như sau:

```
glm(formula = y ~ x1 + x2 + ..., data = ..., family = binomial, ...)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng, `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `...` là các đối thêm, được sử dụng trong các trường hợp cụ thể.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `exp(coef())`: ước lượng tỷ lệ cực - odds ratios;
- `confint()`: xác định khoảng tin cậy cho hệ số trong mô hình;
- `exp(confint())`: khoảng tin cậy cho tỷ lệ cực - odds ratios;
- `predict()`: tiên đoán giá trị của biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến đáp ứng.

Sau khi tính xác suất dự đoán $\hat{p}(\mathbf{x})$, chúng ta có thể áp dụng quy tắc phân loại cho biến đáp ứng nhị phân để thu được nhóm dự đoán $\hat{C}(\mathbf{x})$:

$$\hat{C}(\mathbf{x}) = \begin{cases} 0 & \text{if } \hat{p}(\mathbf{x}) \leq c \\ 1 & \text{if } \hat{p}(\mathbf{x}) > c, \end{cases}$$

với c là ngưỡng hoặc xác suất giới hạn, $c \in (0, 1)$. Lựa chọn tiêu chuẩn cho c là đặt $c = 0.5$. Tác vụ này có thể được thực hiện bằng cách sử dụng hàm `ifelse(z > c, 1, 0)`, trong đó z là kết quả của $\hat{p}(\mathbf{x})$

Ví dụ 1: Để phân biệt bệnh tim mạch vành với những đối tượng không mắc bệnh, một nghiên cứu trên 462 nam giới đã được thực hiện ở Western Cape, Nam Phi. Trong quá trình nghiên cứu, một số biến được thu thập:

- trạng thái bệnh tim mạch vành (`chd`): 1 (bị bệnh) hoặc 0 (không bị)
- huyết áp tâm thu (`sbp`)
- lượng thuốc lá tích lũy (`tobacco`)
- lượng cholesterol lipoprotein mật độ thấp (`ldl`)
- tiền sử gia đình về bệnh tim mạch vành (`famhist`): `Absent` hoặc `Present`
- tuổi (`age`)
- mức tiêu thụ rượu hiện tại (`alcohol`)
- và một số biến khác ...

Toàn bộ dữ liệu được cung cấp trong tệp `SAheart.csv`.

Với thông tin của một người đàn ông về huyết áp tâm thu, lượng cholesterol lipoprotein mật độ thấp, lượng thuốc lá tích lũy và tiền sử gia đình mắc bệnh tim mạch vành, làm thế nào chúng ta có thể phân loại anh ta vào nhóm bị bệnh tim mạch vành?

```
SAheart <- read_csv(file = "datasets/SAheart.csv")

## Rows: 462 Columns: 10
## -- Column specification -----
## Delimiter: ","
## chr (1): famhist
## dbl (9): sbp, tobacco, ldl, adiposity, typea, obesity, alcohol, age, chd
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.

SAheart <- SAheart |>
  mutate(famhist = factor(famhist, levels = c("Absent", "Present")),
         chd = factor(chd))
```

Ta xem xét mô hình hồi quy sau:

$$\log \left(\frac{p(\mathbf{x})}{1 - p(\mathbf{x})} \right) = \beta_0 + \beta_1 \text{sbp} + \beta_2 \text{tobacco} + \beta_3 \text{ldl} + \beta_4 \text{famhist}$$

Mô hình được ước lượng như sau:

```
out_md <- glm(formula = chd ~ sbp + tobacco + ldl + famhist, data = SAheart,
              family = binomial)
```

Kết quả tổng hợp như sau:

```
summary(out_md)

##
## Call:
## glm(formula = chd ~ sbp + tobacco + ldl + famhist, family = binomial,
##      data = SAheart)
```

```
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) -4.252750   0.778578  -5.462 4.70e-08 ***
## sbp         0.011982   0.005317   2.253 0.024234 *
## tobacco     0.118880   0.024727   4.808 1.53e-06 ***
## ldl         0.203350   0.053841   3.777 0.000159 ***
## famhistPresent 1.050498   0.218629   4.805 1.55e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 596.11  on 461  degrees of freedom
## Residual deviance: 502.17  on 457  degrees of freedom
## AIC: 512.17
##
## Number of Fisher Scoring iterations: 4
```

Một vài nhận xét từ kết quả tổng hợp

- Tất cả các ước tính $\hat{\beta}_j$ (với $j = 1, 2, 3$) đều dương, vì vậy, nếu một người đàn ông có **sbp** (huyết áp tâm thu) lớn, thì thay đổi mắc bệnh tim mạch vành tăng lên.
- $\hat{\beta}_4 > 0$, nghĩa là nếu thành viên gia đình của một người đàn ông mắc bệnh tim mạch vành thì khả năng người đó mắc bệnh tim là cao.
- Ta thấy tất cả các giá trị p đều nhỏ hơn $\alpha = 0.05$, điều đó có nghĩa là tất cả các biến đều có ý nghĩa thống kê đối với mô hình logistic. Và chúng rất hữu ích trong việc phân loại các đối tượng mắc bệnh tim mạch vành.

Để tính tỷ lệ cược - odds cho tất cả mọi biến, ta thực hiện:

```
exp(coef(out_md))
```

```
##      (Intercept)          sbp          tobacco          ldl famhistPresent
##      0.01422505      1.01205446      1.12623450      1.22550147      2.85907330
```

Kết quả cho thấy tỷ lệ chênh lệch của **famhistPresent** là 2.859, nghĩa là: nếu biết thành viên trong gia đình của người đàn ông, là mắc bệnh tim mạch vành, thì khả năng người đàn ông đó được phân loại mắc bệnh tim mạch vành là cao khoảng 2.859 lần (tức là 185.9%), so với khi không có lịch sử bệnh tim mạch gia đình.

Để xác định 95% khoảng tin cậy cho tỷ lệ cược odds, ta thực hiện như sau:

```
exp(confint(out_md, level = 0.95))
```

```
## Waiting for profiling to be done...
##
##              2.5 %      97.5 %
## (Intercept)  0.00299985 0.06397203
## sbp         1.00156518 1.02274077
## tobacco     1.07443160 1.18414390
## ldl         1.10491162 1.36547965
## famhistPresent 1.86761437 4.40566624
```

Bây giờ, giả sử chúng ta có một số thông tin về 4 người đàn ông và chúng ta muốn dự đoán xác suất họ mắc bệnh tim mạch vành. Thông tin được đưa ra như dưới đây

	id	sbp	tobacco	ldl	famhist
	1	115	1	3	Absent
	2	145	8	9	Absent
	3	125	2	6	Present
	4	135	5	8	Present

```
new_data <- tibble(sbp = c(115, 145, 125, 135),
  tobacco = c(1, 8, 2, 5),
  ldl = c(3, 9, 6, 8),
  famhist = factor(c("Absent", "Absent", "Present", "Present"),
    levels = c("Absent", "Present")))
predict(out_md, newdata = new_data, type = "response")
```

```
##           1           2           3           4
## 0.1047200 0.5660823 0.4386619 0.6539774
```

Dựa trên xác suất dự đoán, chúng ta có thể phân loại 4 người đàn ông thành 2 nhóm: không mắc bệnh (hoặc 0) và bệnh (hoặc 1), bằng cách so sánh xác suất dự đoán với ngưỡng c . Ở đây, ta sử dụng $c = 0,5$.

```
pred_prob <- predict(out_md, newdata = new_data, type = "response")
ifelse(pred_prob > 0.5, "diseased", "non-diseased")
```

```
##           1           2           3           4
## "non-diseased" "diseased" "non-diseased" "diseased"
```

Thực hành: Cố định mức tobacco và ldl lần lượt là 6 và 8. Hãy vẽ đường ước lượng của mô hình khi sbp thay đổi, tương ứng với 2 điều kiện khác nhau của famhist.

2 Đánh giá mô hình

Để đánh giá độ chính xác của mô hình logistic, chúng ta sẽ sử dụng phân tích đường cong ROC và diện tích dưới đường cong (AUC). Công việc này sẽ được thực hiện dễ dàng bằng cách sử dụng các hàm trong gói pROC.

Để ước tính đường cong ROC và AUC, ta sử dụng hàm roc(). Đầu tiên, chúng ta cần tính toán xác suất dự đoán cho tất cả các quan sát trong dữ liệu.

```
prob_pred_dt <- predict(out_md, type = "response")
```

Để sử dụng roc(), chúng ta cần tải gói pROC:

```
library(pROC)
```

Sau đó, ta thực hiện

```
out_roc <- roc(SAheart$chd ~ prob_pred_dt)
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

Ước lượng AUC là

```
out_roc$auc
```

```
## Area under the curve: 0.7589
```


Để có được khoảng tin cậy 95% cho AUC, ta sử dụng hàm ci.auc():

```
ci.auc(out_roc, conf.level = 0.95)
```

```
## 95% CI: 0.7128-0.805 (DeLong)
```

Để vẽ đường cong ROC ước lượng, chúng ta sử dụng hàm `plot()` như sau:

```
plot(out_roc, legacy.axes = TRUE, asp = 0)
```



Để đạt được ngưỡng tối ưu dựa trên phương pháp Youden index hoặc phương pháp closest top left, chúng tôi sử dụng hàm `coords()`:

```
out_youd <- coords(out_roc, "best", ret = c("threshold", "specificity", "sensitivity"),
                  best.method = "youden")
print(out_youd)
```

```
## threshold specificity sensitivity
## 1 0.3498213 0.7019868 0.7
```

Mã này cho chúng ta kết quả của phương pháp chỉ mục Youden. Đối với phương pháp closest top left, chúng ta thực hiện như sau:

```
out_clost <- coords(out_roc, "best", ret = c("threshold", "specificity", "sensitivity"),
                  best.method = "closest.topleft")
print(out_clost)
```

```
## threshold specificity sensitivity
## 1 0.3498213 0.7019868 0.7
```

Cả hai phương pháp đều đưa ra ngưỡng tối ưu giống nhau là 0.35. Bây giờ, chúng tôi áp dụng ngưỡng này để phân loại 4 nam giới (mới) được trình bày ở trên:

```
ifelse(pred_prob > out_youd$threshold, "diseased", "non-diseased")
```

```
##           1           2           3           4
## "non-diseased" "diseased" "diseased" "diseased"
```

3 Bài tập

Bài tập 1: Tập dữ liệu `bmd.csv` chứa ghi chép về mật độ xương (đo mật độ khoáng xương) của 169 bệnh nhân. Các biến sau đây đã được ghi nhận:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của bệnh nhân
- `sex`: giới tính của bệnh nhân (M - nam/F - nữ)
- `fracture`: đã bị gãy xương hông (1 - có/0 - không)
- `weight_kg`: cân nặng, đơn vị kg
- `height_cm`: chiều cao, đơn vị cm
- `waiting_time`: thời gian bệnh nhân phải đợi đo mật độ xương, đơn vị phút
- `bmd`: đo mật độ khoáng xương ở hông
- `medication`: tình trạng chăm sóc y tế (No medication / Glucocorticoids / Anticonvulsant)

Mục đích nghiên cứu là xây dựng mô hình dự đoán khả năng sẽ bị gãy xương của bệnh nhân. Điều này có thể giúp y tá hoặc bác sĩ chăm sóc bệnh nhân tốt hơn.

- Xây dựng và ước lượng mô hình hồi quy logistic để dự đoán khả năng bị gãy xương của bệnh nhân, sử dụng các biến: `bmd`, `sex`, `age` và `weight_kg`.
- Đưa ra một số nhận xét có giá trị dựa trên kết quả.
- Đánh giá độ chính xác của mô hình được đề xuất.
- Xác định ngưỡng tối ưu bằng 2 phương pháp.
- Giả sử chúng ta có một số thông tin của 4 bệnh nhân:

id	age	sex	weight_kg	bmd
1	45	M	50	0.8
2	45	F	50	0.8
3	45	M	50	0.72
4	45	F	50	0.72

Sử dụng ngưỡng tối ưu để phân loại 4 bệnh nhân thành hai nhóm: gãy xương hoặc không gãy xương.

Bài tập 2: Dữ liệu `SBI.csv` chứa thông tin của hơn 2349 trẻ em đến các dịch vụ cấp cứu vì bị sốt và được xét nghiệm nhiễm vi khuẩn nghiêm trọng. Kết quả `sbi2` có 2 loại: 0 - Không áp dụng (không nhiễm trùng) và 1 (bị nhiễm: UTI / Pneum / Bact). Các biến sau đây cũng được bao gồm:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của trẻ
- `fever_hours`: thời gian sốt tính bằng giờ
- `sex`: giới tính của trẻ (M/F)
- `wcc`: số lượng tế bào bạch cầu
- `prevAB`: có sử dụng kháng sinh trước đó (Yes/No)
- `pct`: procalcitonin
- `crp`: protein phản ứng c (c-reactive protein)

Mục đích của nghiên cứu là xây dựng mô hình dự đoán tình trạng nhiễm trùng của trẻ. Điều này có thể giúp bác sĩ đưa ra quyết định nhanh chóng và chăm sóc trẻ tốt hơn.

- (a) xây dựng và ước lượng mô hình hồi quy logistic để dự đoán khả năng trẻ bị nhiễm trùng (**sbi2**), dựa vào các biến: **wcc**, **age**, **prevAB**, **pct** và **crp**.
- (b) Đưa ra một số nhận xét có giá trị dựa trên kết quả.
- (c) Đánh giá độ chính xác của mô hình được đề xuất.
- (d) Xác định ngưỡng tối ưu bằng 2 phương pháp.
- (e) Giả sử chúng ta có một số thông tin của 6 trẻ em:

id	age	wcc	prevAB	pct	crp
1	1	5	No	4	15
2	1	20	No	4	25
3	2	10	Yes	5	50
4	0.5	20	Yes	5	70
5	1.5	30	No	1	120
6	1.5	30	No	1	12

Sử dụng ngưỡng tối ưu để phân loại 6 trẻ này thành hai nhóm: nhiễm khuẩn hoặc không nhiễm khuẩn.