

Bài giảng 7: Bài toán Phân Loại - Classification - II

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Học phần: Xử lý Số liệu Thống kê

Nội dung buổi học

1 Đánh giá mô hình phân loại

2 Chiến lược với dữ liệu không cân bằng

1 Đánh giá mô hình phân loại

2 Chiến lược với dữ liệu không cân bằng

Các chỉ số đánh giá tổng quát

Độ chính xác của một mô hình phân loại nhị phân có thể được đánh giá thông qua:

- confusion matrix: một bảng 2×2 thể hiện số lượng phân loại đúng và sai của hai nhóm;
- accuracy: phần trăm phân loại chính xác của cả hai nhóm;
- sensitivity: phần trăm phân loại chính xác nhóm "1";
- specificity: phần trăm phân loại chính xác nhóm "0";
- precision: phần trăm dự đoán nhóm "1" mà thực chất là nhóm "1";
- ROC curve: đường cong thể hiện sensitivity và specificity khi thay đổi ngưỡng xác suất;
- AUC: diện tích dưới đường cong ROC.

Các chỉ số đánh giá tổng quát

Để đánh giá một mô hình phân loại, ta chia dữ liệu thành hai phần

- training set: dữ liệu dùng để xây dựng mô hình;
- test set: dữ liệu dùng để đánh giá mô hình.

Nhắc lại rằng, đối với một mô hình phân loại nhị phân:

- xác suất dự đoán $\hat{p}_1(x)$ được xác định dựa trên mô hình
- tiên đoán $\hat{Y}(x)$ được xác định bởi

$$\hat{Y}(x) = \begin{cases} 0 & \text{nếu } \hat{p}_1(x) \leq p_0 \\ 1 & \text{nếu } \hat{p}_1(x) > p_0 \end{cases}$$

với p_0 là một ngưỡng xác suất.

Việc đánh giá độ chính xác mô hình phân loại, dựa trên ý tưởng về việc so sánh

- số lượng đối tượng thuộc nhóm “1” được phân loại vào nhóm “1” / “0”;
- số lượng đối tượng thuộc nhóm “0” được phân loại vào nhóm “0” / “1”;

tại một ngưỡng xác suất p_0 .

Ma trận phân loại - Confusion matrix

Khi đó, với p_0 cho trước, mỗi giá trị quan sát Y_i và giá trị ước lượng $\hat{Y}_i$, ta quan sát:

$$Z_i = \begin{cases} 0, & \text{nếu } (Y_i = 0, \hat{Y}_i = 1) \text{ hoặc } (Y_i = 1, \hat{Y}_i = 0) \\ 1, & \text{nếu } (Y_i = 0, \hat{Y}_i = 0) \text{ hoặc } (Y_i = 1, \hat{Y}_i = 1) \end{cases}$$

Tổng hợp tất cả các giá trị của Z_i , ta có bảng sau:

		Ước lượng	
		$\hat{Y}_i = 0$	$\hat{Y}_i = 1$
Quan sát	$Y_i = 0$	n_{00}	n_{01}
	$Y_i = 1$	n_{10}	n_{11}

với $n_{00} + n_{10} = n_0$ (số lượng quan sát $Y = 0$), $n_{01} + n_{11} = n_1$ (số lượng quan sát $Y = 1$). Trong đó,

- n_{00} và n_{11} là hai giá trị cho thấy số lượng ước lượng khớp của mô hình;
- n_{01} và n_{10} là hai giá trị cho thấy số lượng ước lượng sai của mô hình.

↪ n_{00} càng gần n_0 và n_{11} càng gần n_1 , thì mô hình là dự đoán tốt.

Ma trận phân loại - Confusion matrix

- n_{00} là true negative (TN)
- n_{11} là true positive (TP)
- n_{01} là false positive (FP)
- n_{10} là false negative (FN)

Ví dụ: ma trận phân loại của mô hình Naive Bayes phân loại 1 người bị phá sản tín dụng,

- tại ngưỡng $p_0 = 0.5$ là

		Ước lượng	
		$\hat{Y}_i = 0$	$\hat{Y}_i = 1$
Quan sát	$Y_i = 0$	918	82
	$Y_i = 1$	80	253

- tại ngưỡng $p_0 = 0.3$ là

		Ước lượng	
		$\hat{Y}_i = 0$	$\hat{Y}_i = 1$
Quan sát	$Y_i = 0$	853	147
	$Y_i = 1$	43	290

Accuracy

Accuracy là tổng số lượng phân loại chính xác nhóm “1” và “0” của một mô hình phân loại tại một ngưỡng xác suất p_0 :

$$\text{Accuracy} = \frac{n_{00} + n_{11}}{n}.$$

Giá trị của Accuracy thay đổi từ 0 tới 1, trong đó,

- 0: mô hình phân loại hoàn toàn sai tại ngưỡng p_0 ;
- 1: mô hình phân loại hoàn toàn chính xác tại ngưỡng p_0 ;
- càng gần 1 thì có nghĩa mô hình càng phân loại đúng hai nhóm.

Ví dụ: Accuracy của mô hình Naive Bayes tại

- $p_0 = 0.5$:

$$\text{Accuracy}_{0.5} = \frac{918 + 253}{1333} = 0.8785;$$

- $p_0 = 0.3$:

$$\text{Accuracy}_{0.3} = \frac{853 + 290}{1333} = 0.8575.$$

Accuracy không cho biết góc nhìn về tỷ lệ phân loại sai.

Precision, Sensitivity và Specificity

Từ bảng kết quả so sánh nhị phân với một ngưỡng p_0 , ta định nghĩa được

- tỷ lệ dự đoán đúng “0”, được gọi là **Specificity** - Sp:

$$\text{Sp}(p_0) = \frac{n_{00}}{n_{00} + n_{01}} = \frac{1}{n_0} \sum_{i=1}^n \mathbb{I}(Y_i = 0, \hat{p}_i(x) \leq p_0)$$

- tỷ lệ dự đoán đúng “1”, được gọi là **Sensitivity** - Se:

$$\text{Se}(p_0) = \frac{n_{11}}{n_1} = \frac{1}{n_1} \sum_{i=1}^n \mathbb{I}(Y_i = 1, \hat{p}_i(x) > p_0)$$

Sensitivity còn được gọi là **Recall** - thường được dùng trong machine learning;

- tỷ lệ dự đoán “1” của mô hình, được gọi là **Precision**:

$$\text{Precision}(p_0) = \frac{n_{11}}{n_{01} + n_{11}}$$

Precision cho biết tỷ lệ dương tính thật (True positive) so với dương tính giả (False positive) của mô hình.

Precision càng cao $\Rightarrow$ tỷ lệ dương tính thật càng cao $\Rightarrow$ mô hình phân loại nhóm 1 tốt.

Precision, Sensitivity và Specificity

Với $p_0 = 0.5$, ta tính được

- tỷ lệ dự đoán đúng “0”

$$\text{Sp}(0.5) = \frac{918}{918 + 82} \approx 0.918$$

- tỷ lệ dự đoán đúng “1”

$$\text{Se}(0.5) = \frac{253}{253 + 80} \approx 0.760$$

- tỷ lệ dương tính thật trong nhóm được dự đoán “1”:

$$\text{Precision}(0.5) = \frac{253}{253 + 82} \approx 0.755$$

Precision, Sensitivity và Specificity

Với $p_0 = 0.3$, ta tính được

- tỷ lệ dự đoán đúng “0”

$$\text{Sp}(0.3) = \frac{853}{853 + 147} \approx 0.853$$

- tỷ lệ dự đoán đúng “1”


$$\text{Se}(0.3) = \frac{290}{290 + 43} \approx 0.871$$

- tỷ lệ dương tính thật trong nhóm được dự đoán “1”:

$$\text{Precision}(0.3) = \frac{290}{290 + 147} \approx 0.664$$

Precision, Sensitivity và Specificity

Thay đổi ngưỡng xác suất p_0 từ 0 tới 1, ta thu được biểu đồ sau:



Đường nét đứt màu xanh tại $p_0 = 0.317$ và $Sp(0.317) = Se(0.317) = 0.858$

Phân tích đường cong ROC

- Qua hai ví dụ trên, ta thấy rằng specificity và sensitivity chỉ đo lường hiệu suất của sự dự đoán liên quan đến một ngưỡng cụ thể p_0 .
- Bằng cách thay đổi p_0 , ta sẽ có các giá trị khác nhau của specificity và sensitivity, và do đó, hiệu suất cũng khác nhau!

⇒ Chúng ta cần đánh giá specificity và sensitivity ở tất cả các ngưỡng p_0 có thể có để tổng hợp độ chính xác của mô hình.

Receiver Operating Characteristic (ROC) curve

Một đường cong ROC (receiver operating characteristic) là đường cong mô tả tất cả các cặp điểm $(1 - \text{Sp}(p_0), \text{Se}(p_0))$ với tất cả ngưỡng $p_0 \in (0, 1)$ có thể:

$$\text{ROC} = \{(1 - \text{Sp}(p_0), \text{Se}(p_0)), p_0 \in (0, 1)\}$$

Đường cong ROC được biểu diễn trên đồ thị giới hạn bởi hình vuông đơn vị


Diện tích dưới đường cong (AUC)

Diện tích dưới đường cong ROC (AUC) là một độ đo tổng hợp cho độ chính xác của phép phân loại.

Phân tích đường cong ROC

Thông thường, đường cong ROC của mô hình logistic nằm phía trên đường tham chiếu, tức là đường chéo $y = x$.

- Sự cân bằng giữa sensitivity và specificity được hiển thị trên đường cong ROC.
- Nếu đường cong ROC trùng với đường tham chiếu thì $AUC = 0.5$, chúng ta có thể nói rằng việc phân loại dựa trên mô hình logistic là **sự đoán ngẫu nhiên**.
- Nếu đường cong ROC trùng góc trên bên trái thì $AUC = 1$, điều đó có nghĩa là việc phân loại dựa trên mô hình logistic có hiệu suất **hoàn hảo**.



Giá trị hợp lý của AUC thay đổi từ 0.5 đến 1. AUC càng cao thì khả năng dự đoán của mô hình càng tốt.

Phân tích đường cong ROC

Đường cong ROC có thể được biểu diễn là $\text{ROC}(p)$, tức là hàm của p với $p \in (0, 1)$ - tức là $1 - \text{Sp}$.

Do đó, diện tích dưới đường cong ROC (AUC) được định nghĩa bởi

$$\text{AUC} = \int_0^1 \text{ROC}(p) \, dp$$

AUC có thể được ước lượng bằng **trapezoidal rule** (quy tắc hình thang):

$$\int_a^b f(x) \, dx = \sum_{k=1}^{N-1} \frac{f(x_{k+1}) + f(x_k)}{2} (x_{k+1} - x_k).$$


Áp dụng với đường cong ROC:

$$\widehat{\text{AUC}} = \sum_{k=1}^{N-1} \frac{\text{Se}(p_{0,k+1}) + \text{Se}(p_{0,k})}{2} (\text{Sp}(p_{0,k+1}) - \text{Sp}(p_{0,k})).$$

Khoảng tin cậy cho AUC có thể được xây dựng bằng phương pháp Delong hoặc phương pháp bootstrap.

Phân tích đường cong ROC

Đối với ví dụ về dự đoán phá sản tín dụng, đường cong ROC ước lượng cho mô hình Naive Bayes được biểu diễn như sau:



Giá trị AUC ước lượng: 0.937, 95% khoảng tin cậy: (0.924, 0.95).

Phân tích đường cong ROC

Quy tắc đánh giá dựa trên AUC

Chúng ta có thể sử dụng quy tắc sau để đánh giá tính chính xác của mô hình phân loại:

AUC	Tính chính xác
0.5	sự đoán ngẫu nhiên
(0.5, 0.65]	thiếu chính xác
(0.65, 0.8]	chấp nhận được
(0.8, 0.95]	tốt
(0.95, 1)	rất tốt
1	hoàn hảo

Trong ví dụ của chúng ta, AUC ước tính là 0.937, 95% khoảng tin cậy cho AUC (0.924, 0.95), do đó mô hình Naive Bayes có độ chính xác tốt để dự đoán một người có khả năng bị phá sản tín dụng.


Khi so sánh nhiều mô hình phân loại, mô hình nào có AUC lớn hơn, mô hình đó có xu hướng được lựa chọn sử dụng.

1 Đánh giá mô hình phân loại


2 Chiến lược với dữ liệu không cân bằng

Dữ liệu không cân bằng


Trong bài toán phân loại, dữ liệu không cân bằng được thể hiện bởi sự mất cân bằng về dữ liệu được quan sát giữa các nhóm cần phân loại.



(a)



(b)



(c)

Dữ liệu không cân bằng

Vấn đề

Trong những trường hợp dữ liệu không cân bằng, trừ khi các nhóm dễ dàng được phân tách, mô hình phân loại chính xác nhất có thể là mô hình phân loại mọi thứ thành “0”.


Ví dụ: nếu chỉ có 0.1% người duyệt web tại một cửa hàng trực tuyến thực sự mua hàng.

- một mô hình dự đoán rằng mỗi người duyệt web sẽ rời đi mà không mua hàng sẽ có độ chính xác 99,9%;
- tuy nhiên, mô hình này sẽ là vô dụng.

Thay vào đó, chúng ta sẽ hài lòng với một mô hình


- ít chính xác hơn về tổng thể;
- nhưng tốt trong việc nhận diện những người mua hàng;
- và ta sẽ chấp nhận các trường hợp bị dương tính giả.

Một số chiến lược cơ bản



- under-sampling: cắt bỏ bớt dữ liệu trong nhóm có nhiều quan sát;
- oversampling: làm đầy thêm dữ liệu trong nhóm có ít quan sát, dựa trên quan sát có sẵn trong nhóm đó;
- data generation (data augmentation): làm đầy dữ liệu trong nhóm có ít quan sát bằng cách giả lập dữ liệu.

Under-sampling



Under-sampling

Yêu cầu:

- dữ liệu đủ lớn (khoảng 1000 cho lớp ít quan sát);
- các quan sát là độc lập nhau.

Ý tưởng

Ý tưởng cơ bản của giảm mẫu là dữ liệu của nhóm có nhiều quan sát (có nhiều quan sát dư thừa), thông qua một quá trình chọn mẫu ngẫu nhiên đơn giản không lặp lại.

Việc xử lý một tập dữ liệu nhỏ hơn, cân bằng hơn sẽ

- mang lại lợi ích cho hiệu suất mô hình;
- làm cho việc chuẩn bị dữ liệu dễ dàng hơn, cũng như việc khám phá và thử nghiệm các mô hình.

Lưu ý: Dữ liệu càng dễ phân biệt các trường hợp 1 với các trường hợp 0, thì càng ít quan sát cần thiết.

Over-sampling

Phương pháp under-sampling có một số nhược điểm:

- loại bỏ đi dữ liệu (có thể quan trọng);
- không tận dụng được toàn bộ thông tin;
- không thể được sử dụng khi cỡ mẫu tương đối bé.


Trong trường hợp này, thay vì cắt giảm dữ liệu của nhóm có nhiều quan sát, ta sẽ làm đầy quan sát cho nhóm ít quan sát, thông qua quá trình lấy mẫu có lặp lại (bootstrap).

Một cách khác là ta có thể thêm trọng số vào trong các quan sát:

- trọng số nhỏ cho các quan sát trong nhóm nhiều;
- trọng số lớn cho các quan sát trong nhóm ít;

khi đó, hàm lượng quan sát vẫn được giữ nguyên nhưng tính quan trọng của các quan sát sẽ thay đổi.

Over-sampling



Data generation

Trong thực tế lấy mẫu:

- ta chỉ quan sát được một tập hợp hạn chế các trường hợp;
↪ thuật toán không có một tập hợp thông tin phong phú để xây dựng các “quy tắc” phân loại.

Tuy nhiên, nếu ta có thể tạo ra các quan sát mới tương tự nhưng không giống hết các quan sát hiện có

↪ thuật toán có cơ hội học một tập hợp các quy tắc mạnh mẽ hơn.

Data generation

Một biến thể của phương pháp tăng mẫu thông qua bootstrapping là tạo dữ liệu bằng cách làm nhiều các quan sát hiện có để tạo ra các quan sát mới.

Data generation

SMOTE

Thuật toán SMOTE viết tắt của “Synthetic Minority Oversampling Technique”.

Thuật toán SMOTE

- tìm một quan sát tương tự với quan sát đang được gia tăng mẫu;
- tạo ra một quan sát tổng hợp là trung bình có trọng số ngẫu nhiên của quan sát gốc và quan sát lân cận;
- trọng số được tạo riêng cho mỗi biến dự đoán.

Số lượng quan sát tổng hợp được tạo ra phụ thuộc vào tỷ lệ gia tăng mẫu cần thiết để đưa tập dữ liệu vào trạng thái cân bằng xấp xỉ, với các lớp kết quả.

Quy trình áp dụng thực tế

Quy trình xử lý dữ liệu cho bài toán phân loại:

1. Chuẩn bị dữ liệu:
 - kiểm tra số lượng quan sát trong các nhóm;
 - áp dụng under-sampling/over-sampling/SMOTE khi dữ liệu có dấu hiệu mất cân bằng lớn.
2. Xây dựng và huấn luyện mô hình: sử dụng các thuật toán phân loại.
3. Đánh giá độ chính xác của mô hình: sử dụng ROC curve, và AUC để tìm ra mô hình tốt nhất.
4. Áp dụng mô hình và giám sát.