

Bài giảng R, số 7

-Bài toán phân loại-

TS.Tô Đức Khánh

19/05/2024

1 Các mô hình phân loại cơ bản

1.1 Mô hình logistic

Mô hình hồi quy logistic:

$$\log\left(\frac{p(\mathbf{x})}{1-p(\mathbf{x})}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Trong R, để ước lượng mô hình hồi quy logistic, ta sử dụng hàm `glm()` như sau:

```
glm(formula = y ~ x1 + x2 + ..., data = ..., family = binomial, ...)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng, `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `...` là các đối thêm, được sử dụng trong các trường hợp cụ thể.

Sau khi ước lượng mô hình, ta sử dụng các hàm sau:

- `summary()`: in ra bảng tổng hợp kết quả tổng hợp của phân tích mô hình;
- `coef()`: truy xuất ra ước lượng hệ số của mô hình;
- `predict()`: tiên đoán giá trị của biến đáp ứng dựa vào một hoặc nhiều giá trị được cho trước của các biến đáp ứng.

Sau khi tính xác suất dự đoán $\hat{p}(\mathbf{x})$, chúng ta có thể áp dụng quy tắc phân loại cho biến đáp ứng nhị phân để thu được nhóm dự đoán $\hat{C}(\mathbf{x})$:

$$\hat{C}(\mathbf{x}) = \begin{cases} 0 & \text{if } \hat{p}(\mathbf{x}) \leq c \\ 1 & \text{if } \hat{p}(\mathbf{x}) > c, \end{cases}$$

với c là ngưỡng hoặc xác suất giới hạn, $c \in (0, 1)$. Lựa chọn tiêu chuẩn cho c là đặt $c = 0.5$. Tác vụ này có thể được thực hiện bằng cách sử dụng hàm `ifelse(z > c, 1, 0)`, trong đó $\mathbf{z}$ là kết quả của $\hat{p}(\mathbf{x})$

Ví dụ 1: Để phân biệt bệnh tim mạch vành với những đối tượng không mắc bệnh, một nghiên cứu trên 462 nam giới đã được thực hiện ở Western Cape, Nam Phi. Trong quá trình nghiên cứu, một số biến được thu thập:

- trạng thái bệnh tim mạch vành (`chd`): 1 (bị bệnh) hoặc 0 (không bị)

- huyết áp tâm thu (`sbp`)
- lượng thuốc lá tích lũy (`tobacco`)
- lượng cholesterol lipoprotein mật độ thấp (`ldl`)
- tiền sử gia đình về bệnh tim mạch vành (`famhist`): `Absent` hoặc `Present`
- tuổi (`age`)
- mức tiêu thụ rượu hiện tại (`alcohol`)
- và một số biến khác ...

Toàn bộ dữ liệu được cung cấp trong tệp `SAheart.csv`.

Với thông tin của một người đàn ông về huyết áp tâm thu, lượng cholesterol lipoprotein mật độ thấp, lượng thuốc lá tích lũy và tiền sử gia đình mắc bệnh tim mạch vành, làm thế nào chúng ta có thể phân loại anh ta vào nhóm bị bệnh tim mạch vành?

```
SAheart <- read_csv(file = "datasets/SAheart.csv")
SAheart <- SAheart |>
  mutate(famhist = factor(famhist, levels = c("Absent", "Present")),
         chd = factor(chd))
```

Ta xem xét mô hình hồi quy sau:

$$\log\left(\frac{p(\mathbf{x})}{1-p(\mathbf{x})}\right) = \beta_0 + \beta_1 \text{sbp} + \beta_2 \text{tobacco} + \beta_3 \text{ldl} + \beta_4 \text{famhist}$$

Mô hình được ước lượng như sau:

```
out_md <- glm(formula = chd ~ sbp + tobacco + ldl + famhist, data = SAheart,
              family = binomial)
```

Kết quả tổng hợp như sau:

```
summary(out_md)

##
## Call:
## glm(formula = chd ~ sbp + tobacco + ldl + famhist, family = binomial,
##      data = SAheart)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -4.252750   0.778578  -5.462 4.70e-08 ***
## sbp           0.011982   0.005317   2.253 0.024234 *
## tobacco       0.118880   0.024727   4.808 1.53e-06 ***
## ldl           0.203350   0.053841   3.777 0.000159 ***
## famhistPresent 1.050498   0.218629   4.805 1.55e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 596.11  on 461  degrees of freedom
## Residual deviance: 502.17  on 457  degrees of freedom
## AIC: 512.17
##
## Number of Fisher Scoring iterations: 4
```

Một vài nhận xét từ kết quả tổng hợp

- Tất cả các ước tính $\hat{\beta}_j$ (với $j = 1, 2, 3$) đều dương, vì vậy, nếu một người đàn ông có **sbp** (huyết áp tâm thu) lớn, thì thay đổi mắc bệnh tim mạch vành tăng lên.
- $\hat{\beta}_4 > 0$, nghĩa là nếu thành viên gia đình của một người đàn ông mắc bệnh tim mạch vành thì khả năng người đó mắc bệnh tim là cao.
- Ta thấy tất cả các giá trị p đều nhỏ hơn $\alpha = 0.05$, điều đó có nghĩa là tất cả các biến đều có ý nghĩa thống kê đối với mô hình logistic. Và chúng rất hữu ích trong việc phân loại các đối tượng mắc bệnh tim mạch vành.

Bây giờ, giả sử chúng ta có một số thông tin về 4 người đàn ông và chúng ta muốn dự đoán xác suất họ mắc bệnh tim mạch vành. Thông tin được đưa ra như dưới đây

	id	sbp	tobacco	ldl	famhist
	1	115	1	3	Absent
	2	145	8	9	Absent
	3	125	2	6	Present
	4	135	5	8	Present

```
new_data <- tibble(sbp = c(115, 145, 125, 135),
                   tobacco = c(1, 8, 2, 5),
                   ldl = c(3, 9, 6, 8),
                   famhist = factor(c("Absent", "Absent", "Present", "Present"),
                                   levels = c("Absent", "Present")))
predict(out_md, newdata = new_data, type = "response")
```

```
##           1           2           3           4
## 0.1047200 0.5660823 0.4386619 0.6539774
```

Dựa trên xác suất dự đoán, chúng ta có thể phân loại 4 người đàn ông thành 2 nhóm: không mắc bệnh (hoặc 0) và bệnh (hoặc 1), bằng cách so sánh xác suất dự đoán với ngưỡng c . Ở đây, ta sử dụng $c = 0.5$.

```
pred_prob <- predict(out_md, newdata = new_data, type = "response")
ifelse(pred_prob > 0.5, "diseased", "non-diseased")
```

```
##           1           2           3           4
## "non-diseased" "diseased" "non-diseased" "diseased"
```

Thực hành 1: Xây dựng mô hình với những biến khác trong dữ liệu.

1.2 Phân loại Naive Bayes

Phân loại Naive Bayes được thi hành trong R bởi hàm `NaiveBayes()` trong thư viện `klaR`:

```
NaiveBayes(y ~ x1 + x2 + ..., data = ..., usekernel = FALSE)
```

trong đó

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng (gồm 2 hoặc nhiều nhóm), `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `usekernel` là lựa chọn ước lượng kernel cho hàm mật độ, mặc định là `FALSE` tức là ước lượng mật độ của phân phối chuẩn sẽ được áp dụng; nếu chọn `TRUE` thì ước lượng mật độ kernel được áp dụng.

Chú ý: Ta cần kiểm tra

- tính phân phối chuẩn của từng biến giải thích trong từng nhóm;

- sự độc lập của các biến giải thích;

trước khi tiến hành xây dựng mô hình Naive Bayes.

Sau khi đã ước lượng mô hình Bayes, để tiên đoán, ta sử dụng

```
predict(out_NB, newdata)
```

trong đó,

- `out_NB` là kết quả phân tích mô hình Naive Bayes;
- `newdata` là dữ liệu mới, dùng để tiên đoán, trong trường hợp mà ta không nhập, thì dữ liệu hiện tại sẽ được dùng.

Ví dụ 1: (tiếp theo) Ta áp dụng mô hình Naive Bayes cho dữ liệu `SAheart.csv`, với ước lượng hàm mật độ của phân phối chuẩn.

```
out_md_NB <- NaiveBayes(formula = chd ~ sbp + tobacco + ldl + famhist,
                        data = SAheart)
```

Với thông tin về 4 người đàn ông và chúng ta muốn dự đoán xác suất họ mắc bệnh tim mạch vành:

	id	sbp	tobacco	ldl	famhist
	1	115	1	3	Absent
	2	145	8	9	Absent
	3	125	2	6	Present
	4	135	5	8	Present

```
new_data <- tibble(sbp = c(115, 145, 125, 135),
                  tobacco = c(1, 8, 2, 5),
                  ldl = c(3, 9, 6, 8),
                  famhist = factor(c("Absent", "Absent", "Present", "Present"),
                                levels = c("Absent", "Present")))
pred_out_md_NB <- predict(out_md_NB, newdata = new_data)
```

Kết quả xác suất hậu nghiệm được lưu ở danh sách `posterior` của `pred_out_md_NB`.

```
pred_out_md_NB$posterior
```

```
##           0           1
## [1,] 0.9390189 0.06098106
## [2,] 0.2797191 0.72028085
## [3,] 0.6994431 0.30055686
## [4,] 0.3695696 0.63043037
```

cột 1 là xác suất hậu nghiệm cho nhóm “0”, và cột 2 là cho nhóm “1”. Ngoài ra, danh sách `class` của `pred_out_md_NB` sẽ là các nhóm được dự đoán dựa trên dữ liệu và phương pháp MAP. Kết quả này sẽ phù hợp trong trường hợp phân loại đa nhóm.

Thực hành 2: Áp dụng ước lượng mật độ kernel cho mô hình Naive Bayes, so sánh kết quả.

Thực hành 3: Xây dựng mô hình với các biến khác trong dữ liệu.

1.3 Phân loại LDA và QDA

Để xây dựng mô hình phân loại LDA và QDA trong R, ta sử dụng hàm `lda()` và `qda()` được cung cấp bởi thư viện MASS:

```
lda(y ~ x1 + x2 + ..., data = ...)
```

và

```
qda(y ~ x1 + x2 + ..., data = ...)
```

trong đó

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng (gồm 2 hoặc nhiều nhóm), `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình.

Ví dụ 1: (tiếp theo) Ta áp dụng mô hình LDA cho dữ liệu `SAheart.csv`, với giả định ma trận hiệp phương sai của các biến trong các nhóm là đồng nhất.

```
out_md_LDA <- lda(formula = chd ~ sbp + tobacco + ldl + famhist,  
                  data = SAheart)
```

Kết quả ước lượng hệ số như sau

```
out_md_LDA
```

```
## Call:  
## lda(chd ~ sbp + tobacco + ldl + famhist, data = SAheart)  
##  
## Prior probabilities of groups:  
##      0      1  
## 0.6536797 0.3463203  
##  
## Group means:  
##      sbp  tobacco      ldl famhistPresent  
## 0 135.4603 2.634735 4.344238      0.3178808  
## 1 143.7375 5.524875 5.487938      0.6000000  
##  
## Coefficients of linear discriminants:  
##              LD1  
## sbp              0.0119491  
## tobacco          0.1278937  
## ldl              0.2152361  
## famhistPresent  1.1032934
```

Với thông tin về 4 người đàn ông và chúng ta muốn dự đoán xác suất họ mắc bệnh tim mạch vành:

	id	sbp	tobacco	ldl	famhist
	1	115	1	3	Absent
	2	145	8	9	Absent
	3	125	2	6	Present
	4	135	5	8	Present

Khi đó, ta tiên đoán xác suất phân loại như sau:

```
new_data <- tibble(sbp = c(115, 145, 125, 135),  
                  tobacco = c(1, 8, 2, 5),  
                  ldl = c(3, 9, 6, 8),  
                  famhist = factor(c("Absent", "Absent", "Present", "Present"),  
                                   levels = c("Absent", "Present")))  
pred_out_md_LDA <- predict(out_md_LDA, newdata = new_data)
```

Kết quả xác suất hậu nghiệm được lưu ở danh sách `posterior` của `pred_out_md_LDA`.

```
pred_out_md_LDA$posterior
```

```
##           0           1
## 1 0.9075048 0.09249518
## 2 0.4188052 0.58119476
## 3 0.5585615 0.44143848
## 4 0.3268301 0.67316992
```

cột 1 là xác suất hậu nghiệm cho nhóm “0”, và cột 2 là cho nhóm “1”.

Thực hành 4: Xây dựng mô hình QDA với các biến được sử dụng trong ví dụ 1.

Thực hành 5: Xây dựng mô hình LDA và QDA với các biến khác trong dữ liệu.

1.4 Mô hình multinomial logistic

Để xây dựng mô hình phân loại đa nhóm với mô hình multinomial logistic trong R, ta sử dụng hàm `multinom()` được cung cấp bởi thư viện `nnet`:

```
multinom(y ~ x1 + x2 + ..., data = ..., maxit = 100)
```

trong đó,

- `formula = y ~ x1 + x2 + ...` là biểu thức tuyến tính của mô hình, với `y` là tên của biến đáp ứng (gồm 2 hoặc nhiều nhóm), `x1` và `x2` lần lượt là tên của các biến giải thích;
- `data` là tên của bộ dữ liệu chứa các biến cần cho việc ước lượng mô hình;
- `maxit` là số lần lặp tối đa của thuật toán.

Sau khi đã ước lượng mô hình multinomial logistic, để tiên đoán, ta sử dụng

```
predict(out_mult, newdata, type = c("probs", "class"))
```

trong đó,

- `out_mult` là kết quả phân tích mô hình multinomial logistic;
- `newdata` là dữ liệu mới, dùng để tiên đoán, trong trường hợp mà ta không nhập, thì dữ liệu hiện tại sẽ được dùng;
- `type` là dạng kết quả ta muốn tiên đoán, nếu `"probs"` kết quả trả về sẽ là xác suất phân loại của các nhóm, nếu `"class"` kết quả trả về là nhóm được dự đoán dựa trên phương pháp MAP.

Ví dụ 2: Ta xây dựng một mô hình để phân loại 3 loài hoa iris dựa trên các chỉ số đo về chiều dài và chiều rộng của lá đài hoặc cánh hoa. Ta sử dụng dữ liệu `iris` được cung cấp trong R:

```
data("iris")
iris <- iris |> janitor::clean_names()
glimpse(iris)
```

```
## Rows: 150
## Columns: 5
## $ sepal_length <dbl> 5.1, 4.9, 4.7, 4.6, 5.0, 5.4, 4.6, 5.0, 4.4, 4.9, 5.4, 4.8, 4.~
## $ sepal_width <dbl> 3.5, 3.0, 3.2, 3.1, 3.6, 3.9, 3.4, 3.4, 2.9, 3.1, 3.7, 3.4, 3.~
## $ petal_length <dbl> 1.4, 1.4, 1.3, 1.5, 1.4, 1.7, 1.4, 1.5, 1.4, 1.5, 1.5, 1.6, 1.~
## $ petal_width <dbl> 0.2, 0.2, 0.2, 0.2, 0.2, 0.4, 0.3, 0.2, 0.2, 0.1, 0.2, 0.2, 0.~
## $ species <fct> setosa, setosa, setosa, setosa, setosa, setosa, setosa, setosa, setosa~
```

Ta sử dụng hai biến `sepal_length` và `sepal_width` trong mô hình:

```
out_iris_mlogit <- multinom(species ~ sepal_length + sepal_width, data = iris,
                             maxit = 1500)
```

```
## # weights: 12 (6 variable)
## initial value 164.791843
## iter 10 value 62.715967
## iter 20 value 59.808291
## iter 30 value 55.445984
## iter 40 value 55.375704
## iter 50 value 55.346472
## iter 60 value 55.301707
## iter 70 value 55.253532
## iter 80 value 55.243230
## iter 90 value 55.230241
## iter 100 value 55.212479
## iter 110 value 55.202443
## iter 120 value 55.192705
## iter 130 value 55.191200
## iter 140 value 55.191033
## iter 150 value 55.190191
## iter 160 value 55.189448
## iter 170 value 55.188985
## iter 180 value 55.188556
## iter 190 value 55.187777
## iter 200 value 55.187265
## iter 210 value 55.186957
## iter 220 value 55.186595
## final value 55.185249
## converged
```

Như vậy, thuật toán hội tụ sau 220 lần lặp. Tổng hợp kết quả ước lượng mô hình như sau:

```
summary(out_iris_mlogit)
```

```
## Call:
## multinom(formula = species ~ sepal_length + sepal_width, data = iris,
##           maxit = 1500)
##
## Coefficients:
##               (Intercept) sepal_length sepal_width
## versicolor    -105.7787      41.81093    -37.79796
## virginica     -118.8205      43.71278    -37.39364
##
## Std. Errors:
##               (Intercept) sepal_length sepal_width
## versicolor     19.77263     17.56242     41.60040
## virginica      19.81677     17.55754     41.60719
##
## Residual Deviance: 110.3705
## AIC: 122.3705
```

Giả sử ta có số đo của một số bông hoa như sau:

id	sepal_length	sepal_width	petal_length	petal_width
1	4.8	3	1	0.4
2	6	3.2	3.9	1.4
3	6.7	4.3	5.3	2.4
4	5.6	2.8	4.5	0.7

Khi đó, ta tiên đoán xác suất phân loại như sau:

```
new_data_iris <- tibble(sepal_length = c(4.8, 6, 6.7, 5.6),
                        sepal_width = c(3, 3.2, 4.3, 2.8),
                        petal_length = c(1, 3.9, 5.3, 4.5),
                        petal_width = c(0.4, 1.4, 2.4, 0.7))

out_prob_mlogit_iris <- predict(out_iris_mlogit, newdata = new_data_iris,
                               type = "probs")

out_prob_mlogit_iris
```

```
##           setosa  versicolor  virginica
## 1 1.000000e+00 9.422496e-09 6.332977e-10
## 2 1.927510e-11 5.834194e-01 4.165806e-01
## 3 1.405305e-06 1.916651e-01 8.083335e-01
## 4 1.281222e-10 7.789050e-01 2.210950e-01
```

Và nhóm dự đoán là

```
out_class_mlogit_iris <- predict(out_iris_mlogit, newdata = new_data_iris,
                                type = "class")

out_class_mlogit_iris
```

```
## [1] setosa  versicolor virginica versicolor
## Levels: setosa versicolor virginica
```

Thực hành 6: Xây dựng mô hình phân loại loài hoa iris bằng Naive Bayes, LDA và QDA, sử dụng hai biến như trong ví dụ, và so sánh với kết quả tiên đoán.

Thực hành 7: Xây dựng mô hình phân loại loài hoa iris bằng multinomial logistic model, Naive Bayes, LDA và QDA, sử dụng hai biến còn lại và cả 4 biến; và so sánh với kết quả tiên đoán.

2 Đánh giá mô hình phân loại nhị phân

Để đánh giá độ chính xác của mô hình logistic, chúng ta sẽ sử dụng phân tích đường cong ROC và diện tích dưới đường cong (AUC). Công việc này sẽ được thực hiện dễ dàng bằng cách sử dụng các hàm trong gói pROC.

Để ước tính đường cong ROC và AUC, ta sử dụng hàm `roc()`. Đầu tiên, chúng ta cần tính toán xác suất dự đoán cho tất cả các quan sát trong dữ liệu.

```
prob_pred_dt <- predict(out_md, type = "response")
```

Để sử dụng `roc()`, chúng ta cần tải gói pROC:

```
library(pROC)
```

Sau đó, ta thực hiện

```
out_roc <- roc(SAheart$chd ~ prob_pred_dt)
```

Ước lượng AUC là

```
out_roc$auc
```



```
## Area under the curve: 0.7589
```


Để có được khoảng tin cậy 95% cho AUC, ta sử dụng hàm `ci.auc()`:

```
ci.auc(out_roc, conf.level = 0.95)
```

```
## 95% CI: 0.7128-0.805 (DeLong)
```

Để vẽ đường cong ROC ước lượng, chúng ta sử dụng hàm `plot()` như sau:

```
plot(out_roc, legacy.axes = TRUE, asp = 0)
```



Để đạt được ngưỡng tối ưu dựa trên phương pháp Youden index hoặc phương pháp closest top left, chúng tôi sử dụng hàm `coords()`:

```
out_youd <- coords(out_roc, "best", ret = c("threshold", "specificity", "sensitivity"),
               best.method = "youden")
print(out_youd)
```

```
##   threshold specificity sensitivity
## 1 0.3498213   0.7019868         0.7
```

Mã này cho chúng ta kết quả của phương pháp chỉ mục Youden. Đối với phương pháp closest top left, chúng ta thực hiện như sau:

```
out_clost <- coords(out_roc, "best", ret = c("threshold", "specificity", "sensitivity"),
               best.method = "closest.topleft")
print(out_clost)
```

```
##   threshold specificity sensitivity
## 1 0.3498213   0.7019868         0.7
```

Cả hai phương pháp đều đưa ra ngưỡng tối ưu giống nhau là 0.35. Bây giờ, chúng tôi áp dụng ngưỡng này để phân loại 4 nam giới (mới) được trình bày ở trên:

```
ifelse(pred_prob > out_youd$threshold, "diseased", "non-diseased")
```

```
##           1           2           3           4
## "non-diseased"    "diseased"    "diseased"    "diseased"
```

3 Bài tập

Bài tập 1: Tập dữ liệu `bmd.csv` chứa ghi chép về mật độ xương (đo mật độ khoáng xương) của 169 bệnh nhân. Các biến sau đây đã được ghi nhận:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của bệnh nhân
- `sex`: giới tính của bệnh nhân (M - nam/F - nữ)
- `fracture`: đã bị gãy xương hông (1 - có/0 - không)
- `weight_kg`: cân nặng, đơn vị kg
- `height_cm`: chiều cao, đơn vị cm
- `waiting_time`: thời gian bệnh nhân phải đợi đo mật độ xương, đơn vị phút
- `bmd`: đo mật độ khoáng xương ở hông
- `medication`: tình trạng chăm sóc y tế (No medication / Glucocorticoids / Anticonvulsant)

Mục đích nghiên cứu là xây dựng mô hình dự đoán khả năng sẽ bị gãy xương của bệnh nhân. Điều này có thể giúp y tá hoặc bác sĩ chăm sóc bệnh nhân tốt hơn.

- Xây dựng và ước lượng mô hình để dự đoán khả năng bị gãy xương của bệnh nhân, sử dụng các biến: `bmd`, `sex`, `age` và `weight_kg`.
- Đưa ra một số nhận xét có giá trị dựa trên kết quả.
- Đánh giá độ chính xác của mô hình được đề xuất.
- Giả sử chúng ta có một số thông tin của 4 bệnh nhân:

id	age	sex	weight_kg	bmd
1	45	M	50	0.8
2	45	F	50	0.8
3	45	M	50	0.72
4	45	F	50	0.72

Tiên đoán xác suất phân loại của các trẻ em này.

Bài tập 2: Dữ liệu `SBI.csv` chứa thông tin của hơn 2349 trẻ em đến các dịch vụ cấp cứu vì bị sốt và được xét nghiệm nhiễm vi khuẩn nghiêm trọng. Kết quả `sbi2` có 2 loại: 0 - Không áp dụng (không nhiễm trùng) và 1 (bị nhiễm: UTI / Pneum / Bact). Các biến sau đây cũng được bao gồm:

- `id`: số thứ tự của bệnh nhân
- `age`: tuổi của trẻ
- `fever_hours`: thời gian sốt tính bằng giờ
- `sex`: giới tính của trẻ (M/F)
- `wcc`: số lượng tế bào bạch cầu

- **prevAB**: có sử dụng kháng sinh trước đó (Yes/No)
- **pct**: procalcitonin
- **crp**: protein phản ứng c (c-reactive protein)

Mục đích của nghiên cứu là xây dựng mô hình dự đoán tình trạng nhiễm trùng của trẻ. Điều này có thể giúp bác sĩ đưa ra quyết định nhanh chóng và chăm sóc trẻ tốt hơn.

- Xây dựng và ước lượng mô hình để dự đoán khả năng trẻ bị nhiễm trùng (**sbi2**), dựa vào các biến: **wcc**, **age**, **prevAB**, **pct** và **crp**.
- Đưa ra một số nhận xét có giá trị dựa trên kết quả.
- Đánh giá độ chính xác của mô hình được đề xuất.
- Giả sử chúng ta có một số thông tin của 6 trẻ em:

id	age	wcc	prevAB	pct	crp
1	1	5	No	4	15
2	1	20	No	4	25
3	2	10	Yes	5	50
4	0.5	20	Yes	5	70
5	1.5	30	No	1	120
6	1.5	30	No	1	12

Tiên đoán xác suất phân loại của các trẻ em này.